📝 Las notas

5 mar 2026

Aprendizaje de Máquina (1/8) - a242b25

Invitados facundolucianna@gmail.com macroldan@fi.uba.ar Aprendizaje de Máquina - CEIA 24Co2025

Archivos adjuntos Aprendizaje de Máquina (1/8) - a242b25

Registros de la reunión Transcripción Grabación

Resumen

Revisión de estructura del curso con ocho clases centrándose en un proyecto final grupal para evaluar modelos de machine learning.

Estructura del Curso y Evaluación
La asignatura de Aprendizaje de Máquina consta de 7 clases teórico-prácticas más una de consulta con material disponible en GitHub. La aprobación depende de un trabajo práctico final grupal, que debe comenzar antes del final y consiste en implementar un modelo ML con un dataset elegido por el grupo.

Definiciones y Ciclo MLOps
Se revisaron las definiciones fundamentales del Machine Learning, incluyendo la distinción entre parámetros e hiperparámetros. Se cubrió el ciclo de vida de MLOps, enfatizando que el curso se centrará en la preparación, entrenamiento y evaluación de modelos, sin abordar el despliegue.

Enfoque del Proyecto Final
El proyecto final debe ser presentado en un notebook ejecutable y bien documentado que justifique la elección de algoritmos y el modelo de base. Se advirtió contra el uso de datasets excesivamente grandes para

enfocarse en la aplicación de modelos, no en el manejo de problemas de la máquina.

Detalles

- **Introducción y Presentaciones Iniciales**: La sesión comenzó con una bienvenida por parte de Ise posgrados, quien indicó que Facundo Lucianna se uniría en breve, aunque estaba demorado. Se mencionó que el problema técnico de Ise posgrados con compartir la pantalla persistía (00:00:00) (00:11:17). Gabriel Quiroga, Tomas Mc Nally y Alan Vignolo confirmaron que la pantalla compartida era visible al inicio (00:08:27).
- **Estructura y Metodología de la Materia**: La asignatura es "Aprendizaje de máquina" y será impartida por Ise posgrados y Facundo Lucianna. La materia consta de ocho clases, siete de las cuales son teórico-prácticas y la última es de consulta. Las clases incluirán diapositivas, demostraciones en notebooks y un repaso de 10 a 15 minutos sobre el material de la clase anterior (00:08:27).
- **Pausas y Llegada de Facundo Lucianna**: Se tienen programados dos recesos, aunque la programación es flexible y depende de las preguntas y la duración de las explicaciones. Facundo Lucianna llegó durante esta discusión, aunque no fue necesario hacer una presentación extensa ya que los estudiantes ya lo conocen (00:10:28).
- **Material del Curso y Repositorio**: El material para la clase estará disponible en el aula virtual de posgrado y en el repositorio de GitHub de la materia. El repositorio ya contiene todo el material, incluidas las diapositivas y las notebooks de demostración y ejercicios para las siete clases teóricas (00:11:17).
- **Canales de Consulta**: Para consultas, se recomienda usar el foro en el campus o enviar correos electrónicos a ambos profesores (00:12:08) (00:27:57). Esto asegura una respuesta más rápida y mantiene a ambos instructores al tanto de la conversación (00:13:28).
- **Evaluación: Trabajo Práctico Final**: La materia se aprueba con un trabajo práctico final, el cual debe ser entregado al final del curso, aunque el trabajo debe comenzar antes. Este proyecto es grupal, con grupos de dos a seis personas, y consiste en implementar un modelo de *machine learning* utilizando un conjunto de datos elegido por el grupo (00:13:28).

- **Recomendación de Conjuntos de Datos (Datasets)**: Se sugiere que los estudiantes utilicen, si lo desean, el mismo conjunto de datos que prepararon y utilizaron en la materia de Análisis de Datos, ya que esto les da una ventaja considerable al tener el trabajo de preparación adelantado (00:13:28). El foco del trabajo final debe estar en el entrenamiento y aplicación de los modelos, no en la simple preparación de datos (00:14:43).
- **Formato del Trabajo Final**: El trabajo debe presentarse como una *notebook* de Júpiter o un enlace a Google Colab (00:14:43). Es crucial que la *notebook* sea ejecutable, esté ejecutada y, sobre todo, que esté bien documentada, narrando la problemática, la metodología utilizada, y las conclusiones alcanzadas (00:15:52).
- **Criterios de Evaluación del Trabajo Final**: El criterio de evaluación considerará tanto la precisión del modelo obtenido como la justificación técnica detrás de la elección de los algoritmos utilizados (00:21:40). Se anima a entrenar varios modelos, pero se desaconseja entrenarlos todos, ya que el criterio de selección es parte de la justificación (00:24:00).
- **Consideraciones sobre la Complejidad del Dataset**: La elección de un *dataset* simple, como el Titanic, requerirá un trabajo más elaborado en la aplicación y optimización de los modelos, incluyendo la búsqueda de hiperparámetros, para compensar la simplicidad de los datos (00:24:00). No hay un modelo "único" correcto, siendo la justificación lo más importante (00:25:08).
- **Temas a Cubrir en la Materia**: La materia se enfocará en modelos de clasificación supervisada y no supervisada (00:17:27). Los temas a partir de la Clase 2 incluirán distintos modelos de aprendizaje supervisado (KNN, *Support Vector Machine*, Árboles de Decisión, Métodos de Ensamble). La Clase 6 abordará la calibración de modelos, y la Clase 7 se centrará en el aprendizaje no supervisado, como *clustering* (00:19:02).
- **Línea de Tiempo del Proyecto y Modelo Base (Baseline)**: El conocimiento necesario para el proyecto final se habrá cubierto en su totalidad después de la Clase 5, aunque se puede empezar a aplicar conceptos desde la Clase 2 (00:20:23). Se requiere que el trabajo final aborde un problema de aprendizaje supervisado (00:21:40). Además, se instruyó a los estudiantes a comenzar el proyecto con un modelo de base (*baseline*) basado en una heurística, no en un modelo de regresión lineal o logística, para establecer una métrica de comparación inicial (00:34:06).
- **Bibliografía Recomendada**: Se mencionaron libros como *The Elements of Statistical Learning* y *Pattern Recognition and Machine Learning* (Bishop),

destacando que este último es un libro histórico y riguroso de *machine learning* (00:29:03). Se enfatizó que los modelos clásicos cubiertos en la materia siguen siendo vigentes y útiles, a pesar de su antigüedad (00:31:24).

- **Justificación para el Uso de Modelos Clásicos**: Se explicó que los modelos *shallow* (no profundos) cubiertos en el curso resuelven el 90% de los casos y fueron dominantes desde los años 90 (00:32:45). Estos modelos ofrecen rapidez y requieren menos recursos de cómputo en comparación con los modelos de *deep learning* (00:34:06).
- **Definición y Aplicación del Aprendizaje Automático (Machine Learning)**: El aprendizaje automático implica que una computadora construye un modelo a partir de datos para generar una hipótesis, reconociendo patrones sin requerir instrucciones programadas explícitamente (00:36:55). Se debe usar cuando se tienen datos suficientes y cuando existen patrones que se pueden aprender, aunque no sean determinísticos (00:38:25).
- **Casos de Uso y No Uso del Machine Learning**: El *machine learning* no es una solución mágica para todos los problemas, y su aplicación debe valorarse por su necesidad y rentabilidad (00:38:25). Se discutieron ejemplos de su aplicación, como el filtrado adaptativo de señales biológicas en relojes inteligentes (00:41:14). Se mencionó que el proceso de *machine learning* a menudo comienza con la creación de la infraestructura para generar datos, en lugar de con el entrenamiento del modelo (00:39:50).
- **La Incertidumbre en Machine Learning**: Se destacó que el *machine learning* es un mundo de incertidumbre; nunca se tiene certeza de que el modelo haya aprendido correctamente o de que las predicciones sean perfectas (00:38:25) (00:56:20). Además, los datos utilizados para entrenar y predecir deben provenir de una distribución similar (00:49:37).
- **Estrategias para la Falta Inicial de Datos**: Cuando no hay datos disponibles, se sugiere una estrategia de "fake it till you make it", donde se utilizan predicciones humanas o heurísticas básicas, como recomendar el contenido más visto (*top 10*), para generar los primeros datos que posteriormente se usarán para entrenar un modelo (00:45:39).
- **Propósito y Medición del Machine Learning**: Los modelos de *machine learning* se usan para predecir y tienen que ser útiles (00:48:12). Las tareas deben ser repetitivas para que la máquina pueda aprender los patrones (00:52:26). Es crucial medir continuamente el rendimiento en producción, ya que los patrones cambian, lo que obliga a reentrenar o rediseñar los modelos (mejora continua) (00:50:57) (00:53:45).

- **Influencia del Modelo en la Predicción (Feedback Loop)**: Se destacó que la implementación de un modelo de predicción, especialmente de recomendación, influirá en el comportamiento humano y, por lo tanto, en los datos futuros. Esto genera un *feedback loop* que debe ser controlado, por ejemplo, mediante el uso periódico de recomendaciones aleatorias para romper el sesgo (00:55:11).
- **Consideraciones Éticas y Económicas**: El uso de modelos de *machine learning* puede generar una inversión inicial alta en infraestructura y talento, por lo que su uso debe justificarse cuando la solución es frecuente y sostenida en el tiempo (00:59:09). No deben usarse modelos de *machine learning* si el uso no es ético, si existen soluciones más simples que funcionan bien (como un controlador PID), o si el proyecto no resulta rentable (01:00:29).
- **Receso Anunciado**: Se anunció un receso de 10 minutos (01:03:23).
- **Gestión de Tiempo y Continuidad del Tema**: El orador reanudó la sesión después de un descanso de 10 minutos y confirmó la participación de la audiencia para continuar con el repaso de definiciones. La intención de esta revisión es refrescar los conceptos de inteligencia artificial, especialmente porque ha pasado tiempo desde la última vez que el grupo los abordó (01:04:25).
- **Definiciones Fundamentales en Machine Learning**: Se revisaron las estructuras de datos comunes, donde una fila se denomina "muestra", "observación" o "dato puntual", y cada columna representa una "característica", "feature" o "atributo". En el contexto general de predicción, la columna que se desea predecir se denomina "objetivo" o "respuestas" (01:16:21).
- **Estructura de Datos y Ejemplos de Features**: Se presentó un ejemplo de una estructura de datos típica de machine learning, donde cada fila es un empleado (observación) y las columnas incluyen características como posición, nivel de experiencia, habilidad y país. La última columna, el salario, se identifica como la "etiqueta" (label), que es el valor que el modelo de predicción busca aprender (01:17:55).
- **Parámetros e Hiperparámetros del Modelo**: Se diferenció entre los parámetros internos del modelo que se aprenden durante el entrenamiento y los "hiperparámetros", que deben configurarse antes del entrenamiento y no dependen de los datos. Ejemplos de hiperparámetros incluyen la función de activación de una red neuronal o la profundidad de un árbol en modelos de árboles (01:17:55).

- **Generalización y Tipos de Aprendizaje**: La "generalización" se define como la capacidad de un modelo para hacer predicciones correctas utilizando datos nuevos que nunca antes ha visto. Se mencionaron los tres tipos principales de aprendizaje: supervisado (con datos etiquetados), no supervisado (aprender la estructura de datos sin salida conocida) y por refuerzo (aprender a través de recompensas ambientales) (01:19:09).
- **Aprendizaje Profundo y Modelos Supervisados**: El aprendizaje profundo es un subcampo del machine learning que utiliza redes neuronales artificiales con estructuras jerárquicas, inspiradas en el cerebro humano. En el aprendizaje supervisado, los modelos ajustan sus parámetros internos a datos de entrada con etiquetas conocidas, y una vez entrenados, pueden usarse para hacer predicciones con nuevos datos (01:20:38).
- **Clasificación y Regresión en Aprendizaje Supervisado**: Los modelos de clasificación se usan para predecir una variable categórica, lo que puede ser una clasificación binaria (ej. detección de spam) o multiclase (ej. nivel socioeconómico) (01:22:06). Los modelos de regresión, por otro lado, aprenden a predecir una variable numérica ajustando una función matemática a los datos; un ejemplo típico es la predicción del valor de venta de una casa (01:23:36).
- **Clusterización y Reducción de Dimensionalidad**: La "clusterización" o agrupamiento es una aplicación clave del aprendizaje no supervisado que busca encontrar estructuras y grupos de observaciones similares en datos sin etiqueta (01:24:57). La reducción de dimensionalidad es otra utilidad que puede eliminar el ruido de los datos y simplificar los modelos al reducir el número de atributos sin perder información relevante (01:29:06).
- **Concepto de Embebidos y Desafíos de Overfitting**: Los "embebidos" (embeddings) condensan información, típicamente de texto, en un vector numérico y se usan para medir la proximidad conceptual entre textos (01:31:48). Un problema común es que un modelo de machine learning que utiliza embebidos muy grandes (ej. 3072 valores) puede sufrir de *overfitting* si el conjunto de datos no es suficientemente grande, lo que justifica el uso de la reducción de dimensionalidad (01:34:36).
- **Naturaleza del Aprendizaje Profundo y Modelos Convolucionales**: El aprendizaje profundo se caracteriza por su naturaleza extremadamente no lineal, lo que lo hace difícil de interpretar para los humanos (01:34:36). Los modelos convolucionales, usados frecuentemente en visión por computadora, procesan imágenes capa por capa, detectando primero

primitivas (líneas, colores) y luego construyendo la comprensión de figuras de mayor complejidad (01:37:10).

- **El Ciclo de Vida del Machine Learning (MLOps)**: El desarrollo de un modelo de machine learning es un proceso continuo que comienza con un problema de negocio y la definición clara de objetivos y métricas a mejorar (01:40:20). El ciclo incluye la recolección y preparación de datos, la ingeniería de *features* (como el cálculo de ratios), el entrenamiento, la evaluación y, finalmente, el despliegue del modelo en producción (01:42:09) (01:45:04).
- **Mantenimiento y Retroalimentación en MLOps**: El monitoreo del modelo es una fase continua en el ciclo de vida para identificar cuándo el modelo comienza a "pudrirse" (decayendo el rendimiento) debido a cambios en la distribución de datos (01:45:04). La evaluación puede disparar la necesidad de reentrenar el modelo, mejorar *features*, recolectar más datos o, si es necesario, redefinir los objetivos iniciales (01:46:09).
- **Importancia del Almacenamiento de Datos**: Se enfatizó la necesidad de guardar todos los datos generados por los sistemas, ya que son uno de los activos más valiosos de las empresas. Los datos que hoy parecen inútiles pueden ser fundamentales para entrenar modelos futuros y su almacenamiento es relativamente económico (01:48:50).
- **Enfoque de la Materia Actual y el MLOps Futuro**: El enfoque de la materia actual se centrará en la parte inicial del ciclo de vida del machine learning, hasta la evaluación del modelo. El despliegue a producción y los procesos de ingeniería más avanzados (como Docker y arquitecturas de servicio) se abordarán en una materia posterior enfocada en operaciones de aprendizaje automático (MLOps) (01:49:50).
- **Conexión entre Métricas Técnicas y Objetivos de Negocio**: Se advirtió que los *data scientists* a menudo se centran demasiado en mejorar métricas técnicas (como *accuracy*), mientras que las empresas valoran el impacto comercial real (01:51:10). Es crucial poder conectar las métricas técnicas con un resultado de negocio tangible (ej. más ingresos, más usuarios activos, menor tasa de abandono) para asegurar el financiamiento del proyecto (01:52:33).
- **Casos de Uso Populares y Métricas Directas**: La predicción de la tasa de clics (CTR) en anuncios y la detección de fraude son casos de uso muy comunes en machine learning debido a que su rendimiento se puede vincular directamente con métricas de negocio. Por ejemplo, detener transacciones fraudulentas se traduce directamente en un ahorro económico real (01:55:31).

- **La Necesidad de Experimentos y la Comprensión del Negocio**: Para validar el valor de un modelo, se requiere de la realización de experimentos (como las pruebas A/B) que midan el desempeño de las métricas comerciales (01:56:49). Para generar modelos útiles, el *data scientist* debe hacer un análisis exhaustivo y comprender profundamente cómo se generan los datos y los procesos internos del negocio (01:58:39).
- **Sesgos en la Recolección de Datos (Ejemplo COVID-19)**: Se proporcionó un ejemplo de fallas en modelos de predicción de COVID-19, donde los modelos aprendieron sesgos no intencionados de la recolección de datos. Los modelos no aprendieron a detectar la enfermedad, sino que se convirtieron en excelentes predictores de la calidad de la imagen médica o de si el paciente fue enviado a una máquina de rayos X de mejor resolución (un sesgo introducido por los médicos) (02:01:29).
- **La importancia del entendimiento del negocio en la ciencia de datos**: Facundo Lucianna enfatizó que muchos proyectos de *machine learning*, especialmente en el ámbito médico, fracasan por una falta de entendimiento del negocio. Señalaron que las diferencias en los equipos médicos, aunque sutiles para los humanos, generan problemas en los modelos de *machine learning*, haciendo insuficiente el uso de datos de un solo hospital para crear un modelo que generalice bien (02:04:24). Es crucial entender el proceso, cómo se generan los datos y cómo se utilizarán los modelos, lo que implica ir a investigar en lugar de solo procesar la imagen recibida (02:05:32).
- **El futuro contenido del curso y la preparación para la próxima clase**: Facundo Lucianna mencionó que la próxima clase se centrará en el modelo K-Nearest Neighbors (KNN), el cual es complejo porque involucra mediciones de distancia y diferentes formas de funcionamiento. También cubrirán métodos de ajuste de hiperparámetros y métodos de búsqueda que serán útiles para todos los modelos futuros (02:06:31). Se les pidió a los estudiantes que estén preparados, ya que la próxima clase será más intensa (02:07:49).
- ****Proceso de selección de grupos y *datasets****: Ise posgrados informó que compartirían por correo una planilla para que los estudiantes anoten sus grupos y el *dataset* elegido, y el plazo límite para esto es la clase tres (02:07:49). Cesar Orellana preguntó sobre dónde encontrar posibles *datasets*, a lo que Ise posgrados respondió que hay ejemplos en la sección de "Evaluación" del campus y en la presentación. Se sugirió a los estudiantes usar el *dataset* que utilizaron en la materia de Análisis de Datos, ya que se encuentra limpio y listo para entrenar (02:08:49).

- **Consideraciones sobre la elección y tamaño de los *datasets***: Facundo Lucianna y Ise posgrados discutieron que los *datasets* provistos ya están limpios y preparados, lo cual facilita el entrenamiento, aunque el uso excesivo de un mismo *dataset* puede ser menos beneficioso para los estudiantes (02:09:45). Se desaconsejó el uso de *datasets* muy grandes (como el de 45 millones de datos) porque implica más tiempo lidiando con problemas de la máquina que practicando y entrenando diferentes modelos. En el caso de *datasets* grandes, se recomienda comenzar con un submuestreo (*subsample*) para asegurar la distribución y representabilidad de los datos, lo cual es una práctica natural (02:13:21).
- **Aclaraciones finales sobre los *datasets* y cierre de la sesión**: Facundo Lucianna confirmó que no hay problema si dos grupos eligen el mismo *dataset*, ya que esto ha ocurrido antes. Con esto, la clase concluyó, y Facundo Lucianna les dio la bienvenida (aunque tardíamente) y se despidió, indicando que la próxima clase comenzará con el contenido completo y la energía del año (02:14:38).

Pasos siguientes recomendados

- [ ] Facundo Lucianna y Ise posgrados enviarán un correo electrónico con la fecha límite para que el grupo informe sobre la composición del grupo y el conjunto de datos a utilizar en el trabajo final.
- [ ] Ise posgrados enviará por correo la planilla para anotar los grupos y los datasets elegidos, incluyendo la fecha límite específica para la entrega (17 o 19 de marzo, clase 3).

Revisa las notas de Gemini para asegurarte de que sean correctas. Obtén consejos y descubre cómo toma notas Gemini

Danos tu opinión sobre el uso de Gemini para tomar notas en una breve encuesta.

📖 Transcripción

5 mar 2026

Aprendizaje de Máquina (1/8) - a242b25 - Transcripción

00:00:00

Ise posgrados: Hola, buenas, buenas.
Gabriel Quiroga: Tal
Ise posgrados: ¿Cómo están?
Gabriel Quiroga: Yes.
Ise posgrados: No me van a prender la cámara, la clase uno un ratito. Hola, Leonardo. ¿Entraste con tu cuenta? Bueno, ¿cómo andan? Llegando a casa. Bueno, buenísimo. Bueno, primero que nada, eh, Facundo llega en un ratito, está un poco demorado, así que nosotros vamos a arrancar igual. Sí, para bueno, para ser puntual es más que nada la la clase uno, pero él viene enseguida y y toma la batuta. ¿Está bien? ¿Están contentos o o se buena suerte de tenernos de vuelta o más o menos? Esperemos que sí. O sea, no me respondan. Eh, lo bueno es que no hace falta presentarnos, ya nos conocen. Yo lo único que cruzo los dedos, yo ayer di clase y tuve un problema con compartir la pantalla, se me descompartía todo el tiempo y lo estuve tratando de resolver y no sé si está resuelto. Bueno, pero espero que sí y si no, bueno, mala suerte, haré lo que pueda, eh, así que voy a compartir la pantalla.

00:08:27

Ise posgrados: Bueno, e acá. Bueno, ahí se ve. Yo voy a No los veo. No sé si si me dicen si se ve. Yo voy a conectarme acá con el celular.
Tomas Mc Nally: Sí, sí se ve.
Gabriel Quiroga: Sí, se ve.
Alan Vignolo: Sí, se ve.
Ise posgrados: Sí, así los puedo ver. Espérenme un segundito. Em, ahí está. Bueno, no sé qué pasó acá. Se me pasó el Ahí está. Bueno. Bueno, entonces la materia que vamos a compartir es aprendizaje de máquina. Bueno, vamos a estar Facundo y yo en la materia. Ah, yo le puse slide. Esperen un segundo, se me va a pasar automáticamente. Voy a poner así mejor. Bueno, ahí. Bueno, la materia tiene ocho clases teórico prácticas. En verdad son siete clases teóricas. La última clase es de consulta. Sí, vamos a dar las clases con diapositivas, vamos a hacer

demostraciones en notebooks y normalmente eh lo que hacemos acá es 10 minutos, 15, depende de las dudas y las preguntas que tengan, de repaso de todo lo que se vio en la clase anterior, cosa que si se quedaron con dudas en ese momento se puede repasar y también como para retomar el tema eh está bueno como enganchar un poco con lo que ya sabían para enganchar con el tema que sigue, pero cada clase es una temática separada,

00:10:28

Ise posgrados: un tema nuevo. dos recreos también. Esto, bueno, es lo más o menos lo lo programado, pero siempre depende de las preguntas, de lo que tarden, eh, lo que se tarda en explicar un tema. Bueno, eso no hay ningún problema con, o sea, no es estricto, pero más o menos es lo que esperamos hacer. Ahí llegó Facundo, me engañó, no llego tan tarde. Hola.
Facundo Lucianna: Buena, buena, buena. Safé el
Ise posgrados: Bueno, lo bueno es que no tampoco había que hacer gran presentación porque ya nos conoce,
Facundo Lucianna: tránsito.
Ise posgrados: pero bueno, no sé si querés saludar. Yo sigo un par de dislikes y después te dejo te dejo la batuta como
Facundo Lucianna: Eh, dale si quer bienvenidos a todos.
Ise posgrados: aquí.
Facundo Lucianna: Eh, pero si querés seguir presentando un poquito más, eh, Kim, así yo voy preparando mis cosas.
Ise posgrados: Sí,
Facundo Lucianna: O sea, me senté
Ise posgrados: dale dale dale. Sí,
Facundo Lucianna: recién.
Ise posgrados: tranqui, tranqui. Pero ahí me acaba de pasar eso que se me descompartió la pantalla.

00:11:17

Ise posgrados: Estoy con un problema serio, pero no se preocupen.
Facundo Lucianna: Ah,
Ise posgrados: No,
Facundo Lucianna: okay.
Ise posgrados: no con es mi computadora, pero no, no pasa nada, eh. Ahí, ahí

seguimos. Eh,
Facundo Lucianna: Sí.
lse posgrados: bien. Bueno, entonces eso, ustedes me dicen si tienen alguna duda, alguna pregunta, no hay problema.
Facundo Lucianna: Sí.
lse posgrados: Así que bueno, vamos a seguir. El material para la clase. Bueno, vamos a tener el aula virtual en el posgrado. Ahora les muestro, lo tengo abierto en otra ventana y el repositorio de la materia en GitHub, así que eh lo tengo acá abierto para que eh lo vean. Bueno, el repositorio ya está todo el material de la materia. Eh, lo vi que lo subiste, ¿no? El brancho, del de lo que vimos el bimestre pasado ya está en el main.
Facundo Lucianna: que ya estáí
lse posgrados: Claro, claro. Buenísimo. Bueno, entonces acá el curioso, el ansioso, ya tiene todo. Si quiere ver toda la materia esta noche lo puede ver.

00:12:08

lse posgrados: Está todo acá subido. Como les decía, las siete clases teóricas. eh tienen adentro de cada clase el la diapositiva y la eh y las notebooks de demostración y notebook con notebooks con ejercicios. Así que bueno, ahí ya tienen absolutamente todo disponible. Y después en el campus también está por duplicado, ¿no? Acá está todo para la clase hoy, la diapositiva. Eh, bueno, acá hay un PDF eh en particular para la clase de hoy, un árbol de de modelos, pero después en general tiene la diapositiva y las notebooks, todas las clases, ¿no? Nada nada muy nada no esperable. Es lo que van a lo que vamos a ver en la materia. Acá no sé si hay algo especial para ver, pero simplemente Bueno, acá son poquitos, va poquitos. comparado eh comparado con lo que tuvimos el bimestre pasado en el análisis de datos y en las corte nueva que arrancó esta semana, que son 45, eh esto me parece repoquito. Eh, bueno, nada para especial para comentar acá, así que bueno, volvemos a la a la presentación. consultas en el foro, en el campus, o si no por mail, por favor, escríbanos a los dos porque a veces eh uno está más disponible que el otro para responder.

00:13:28

lse posgrados: Entonces, si necesitan una respuesta más rápida, va a ser mejor escribir a los dos y además para que los dos estemos al tanto y bueno, cuando uno no puede, el otro sigue la conversación y así. Y bueno, y con respecto a la

evaluación, eh en esta materia van a tener un trabajo práctico final que lo van a tener que eh entregar, no hacer, entregar al final de la materia, hacer lo deberían empezar a hacer apenas puedan, o sea, no la última semana. Y de hecho después les vamos a decir bien cuándo definir el tema. No lo van a definir en la semana 8o, lo van a tener que definir antes. Eso después les decimos bien. Eh, pero bueno, la materia se aprueba con el trabajo final, que es un trabajo grupal. A elección de ustedes en grupos de dos hasta seis personas y lo que van a tener que hacer es implementar un modelo de machine learning con un usando un conjunto de datos que ustedes eh decidan. Y en este caso, como ustedes ya tuvieron análisis de datos la el bimestre pasado o por ahí hay algún que otro alumno que no hizo el año pasado, pero lo hizo antes, perdón, el bimestre pasado, pero lo hizo antes, análisis de datos. Entonces, más justificado todavía.

00:14:43

lse posgrados: Si ustedes ya tienen los datos que usaron y que los prepararon y que lo dejaron listos para entrar a un modelo y lo quieren usar, está buenísimo porque ya tienen un gran trabajo realizado por delante e por adelantado, digo, entonces se van a poder enfocar bien en lo que es entrenar los modelos. Y si ustedes no tienen ese trabajo, no les gustó, no se quieren usar otro dataset, no hay ningún problema, van a tener que usar un tiempito extra para preparar esos datos. Pero igual el foco está en en los modelos, así como antes en análisis les decíamos que el foco estaba en analizar que ni se gasten en entrenar el modelo porque no era el foco. Acá es todo lo contrario. Tienen que preparar los datos, no pueden subir basura a los modelos, o sea, pueden, pero les va a dar cualquier cosa. Eh, el foco está en entrenar los modelos. E bueno, me estoy salteando, estoy explicando más lo de abajo, pero me salté esto. El trabajo se presenta en una notebook de Júpiter e o puede ser en en Colab, o sea, una notebook suelta o en Colab, un link al a las eh al Google Collab, eh un enlace, si no al repositorio que ustedes tengan.

00:15:52

lse posgrados: La cuestión es que nosotros podemos ver la notebook y que sea ejecutable y que esté ejecutada también, no den no nos den una cosa así por la mitad. Eso importante y superdocumentada, decir, no las celdas no más que hagan cosas, sino que interpretados con como un como si estuvieran contando un cuentito, bueno, tengo acá este dataset, tengo esta problemática, voy a probar esto, me dio así, me dio asá. conclusiones, o sea, como un cuento de todo lo que hicieron

y y las conclusiones, ¿no? Una lista de celdas ejecutadas con con, no sé, con llamadas o funciones, ¿no? No sirve eso. ¿Alguna pregunta? Está clarísimo. Bueno, en el caso que no tengan dataset, que quieran usar uno nuevo, acá tienen algunos links. Otra vez se me compartió algunos links a e a repositorios de donde pueden sacar datos. Siéntanse libres de buscar, de usar. Bueno, ahí está. Siéntanse libres de usar datos de acá o de donde sea que ustedes conozcan eh, que que hay datos disponibles, que sean datos potentes, interesantes, que no sean tratas chiquititos de juguete, porque muchos no muchos no van a aprender, la verdad.

00:17:27

Ise posgrados: Muchos desafíos no van a tener. La idea es que aprendan, que se enfrenten con problemas más o menos reales. En el aula virtual hay ejemplos, yo no me acuerdo bien dónde están, pero por eh por acá hay ejemplos de e si alguno tiene a mano o se acuerda o lo vio, pero por acá eh hay ejemplos de eh
Facundo Lucianna: en evalaciones Acá está.
Ise posgrados: evaluaciones. Puede ser acá,
Facundo Lucianna: Ahí está. Eh,
Ise posgrados: acá. Sí.
Facundo Lucianna: ahí está.
Ise posgrados: Acá tienen algunos datas de ejemplo que les pueden resultar de interés también. Pero como les decía, si a ustedes les pareció interesante el dataset que usaron para análisis de datos y ya tienen pero un montón de camino recorrido, lo tienen listo y pueden usar y explotar ese dataset con con eh sin problemas y van a poder dedicar su tiempo más a los modelos en sí. Eh, eso por ahí no sé, es una sería una buena una buena decisión también. No sé es indiferente lo que hagan, eh, o sea, es decisión de ustedes. Bueno, y acá ven las temáticas, lo que vamos a ver básicamente es modelos, o sea, modelos eh de eh clasificación supervisada y no supervisada.

00:19:02

Ise posgrados: Eso es todo lo que vamos a ver en esta materia. Bueno, hoy es introductorio, ¿no? Un poco qué es machine learning, aunque ya vieron un pantallazo en en inteligencia artificial, el ciclo de vida, un proyecto eh de aprendizaje automático, es son todas eh cuestiones introductorias, ¿no? generales, pero a partir de la clase que viene, en cada clase vamos a ver eh distintos modelos de de machine learning. En la clase dos, tres, cuatro, en casi todas, en realidad todos, tres,

cuatro, principalmente vamos a ver distintos modelos de aprendizaje eh supervisado, ¿sí? En el dos, los eh KNN principalmente, ¿no? Después otros por ahí que capaz que no están en el índice, pero en el dos KNN, en el tres eh support machine, en el cuatro árboles de decisión, en el cinco, métodos de ensamble, en la clase seis ahí no vamos a ver modelos, sino que vamos a ver una técnica que es calibración de modelos. que esto es algo que por ahí no es tan conocido, pero es muy útil en en modelos que son críticos, que es importante el resultado, que el resultado del modelo eh sea muy preciso. Bueno, ya lo vamos a ver, pero es es una técnica eh que ya no es un modelo como en todas las clases anteriores, es otro otra temática lo que vemos en la clase seis.

00:20:23

Ise posgrados: Y en la clase 7 vemos aprendizaje no supervisado, que este es mi favorito. Eh, ya es distinto a todos los anteriores. No sé si ya vieron algo, capaz que por arriba también en inteligencia artificial, donde se ve clastering, camins, que por ahí el más conocido de los métodos. E y nada más. Como les decía, la clase 8 es de consulta. Cuando hayan terminado la clase cinco, ya estarían listos en en conocimientos para poder eh hacer el trabajo final. En verdad lo pueden empezar mucho antes porque el trabajo final es entrenar modelos. Entonces, yo puedo ya desde la clase dos digo, "Bueno, voy a entrenar un KNN." O sea, desde la clase dos ya pueden empezar con el trabajo. Lo que pasa que la idea no es que agarren su dataset y corran todos los modelos que vimos. O sea, no tiene gracia eso. Tienen que aplicar modelos que sean interesantes para o útiles o recomendados para su dataset. No todos los modelos aplican en todos los casos. Entonces, también que tenga sentido eso. Yo elijo este modelo por tal y tal cosa. Sí. y no ponerse a entrenar todo porque sí, porque ahora lo pueden hacer, porque aparte los datas son chiquitos, pero en la vida real hay hay recursos de tiempo, de espacio, de cómputo que no que no están disponibles así no más.

00:21:40

Ise posgrados: Entonces, yo no puedo ponerme a gratuitamente a entrenar todos los modelos que se me ocurra. Eh, por eso es que hay que ser criterioso ya desde desde ahora, aunque sea con datos chiquititos o de juguete o lo que sea, pero ya desde la clase dos pueden empezar a aplicar los conceptos en su dataset elegido para el para el trabajo final. Eh, pero sí o sí después de la clase cinco ya vimos toda la teoría que ustedes eh necesitan para el trabajo. Lo de la clase seis pueden o no aplicarlo,

es totalmente opcional. Y ya la clase siete la pueden dejar a un costado, o sea, les sirve como conocimiento y les sirve, les va a servir a futuro, pero ya eh no no va a ser necesario porque el problema que tienen van a tener que resolver en la en el trabajo final es de aprendizaje supervisado. Por favor, una pregunta porque si no me dicen sí, dedito, dedito, yo no sé si están entendiendo. Una pregunta.
Pa. Santiago Rodriguez Castro: Yo voy con una se va a juzgar
Ise posgrados: Dale. Sí.
Pa. Santiago Rodriguez Castro: la tanto la calidad de la precisión del modelo que que obtengamos como también la la decisión técnica de ir por un algoritmo por sobre otro. Son son todos criterios que se van a tener en cuenta.

00:23:02

Ise posgrados: Eh, claro.
Pa. Santiago Rodriguez Castro: Ah.
Ise posgrados: Sí, sí, sí, sí. Exactamente. Y o sea, y la justificación, eh, que la justificación tenga sentido, que no invente cualquier cosa KNN porque porque me pareció bonito, ¿no? O sea, no que sea bueno, que tenga sentido, ¿no? Lo que hayan elegido, ¿sí? Y que esté justificado y explicado, ¿no? Si ustedes presentan una notebook, esté contado y van a ver ya en las notebooks de las clases, van a ver que tiene un poco ese estilo ya. Eh, quizás yo no conozco las notebook que vieron en inteligencia artificial, pero por ahí ya tienen ese mismo estilo, ¿no? De de ir contando, bueno, me tuve este problema, entonces ahora decido hacerlo de de esta otra manera y otra celda de código como un como un cuentito básicamente explicado, bien explicado y justificado.
Cesar Orellana: Ahí una consulta, ¿no? Me quedó un poco claro. ¿Podemosar entrenar varios modelos o simplemente elegimos uno y con ese nos
Ise posgrados: Sí, no. Sí, sí. Entren en varios modelos.
Cesar Orellana: quedamos?

00:24:00

Ise posgrados: O sea, entrenen más de uno. Lo que yo decía es no entrenen todos porque entonces no están mostrando tampoco un criterio de por qué eligieron uno u otro.
Cesar Orellana: Bien.
Ise posgrados: O sea, no entrenen uno solo y tampoco entrenen todos los que vimos.

Cesar Orellana: Yeah.
Ise posgrados: Hagan algo en el medio y justifiquen por qué eligieron esos y no otros. Eso sería a medida ahora, teniendo ustedes en mente la consigna del trabajo, a medida que pasen las clases, ustedes pregúntenos, ¿y eso, cuándo lo usaría ese modelo, pensando en sus trabajos finales también, cuándo lo usaría, cuándo no lo usaría? ¿Me conviene en tal caso?
Gabriela Sol Salazar: Sumo otra pregunta e con el tema de los datasets por ahí para ir teniéolo en
Ise posgrados: Sí.
Gabriela Sol Salazar: mente, ¿afe la complejidad del dataset a cómo se evalúa las elección de modelos y demás?
Ise posgrados: A cómo se evalúa, ¿no? Pero si vos elegís un dataset muy simple y muy chiquitito, elegís el Titanic, que ya lo conocemos todos, te vamos a pedir que hagas un trabajo mucho más elaborado, porque el Titanic es resencillo, ya está todo limpito,
Gabriela Sol Salazar: Ok.
Ise posgrados: es chiquitito, me va a andar bien.

00:25:08

Ise posgrados: Entonces, si elegís el Titanic y ponés dos modelitos y es muy pobre ese trabajo, tendrías que poner, no sé, esforzarte más con los modelos, hacer más búsqueda de hiperparámetros, que es un tema que vamos a ver, no sé, como hacerlo, complejizarlo de alguna manera para que compense la la simpleza de ese eh de ese dataset. Eso sería básicamente. Ay, gracias por compartir. Sí, se ve que no se resolvió con las cosas que hice. Tengo un problema importante.
Pa. Santiago Rodriguez Castro: M.
Facundo Lucianna: Sí, de de iba a sumar del trabajo y y algo algo pienso en el siguiente, o sea, no hay una selección y algo que vamos aprendiendo dentro de la materia. Ya veníamos viendo en otras, tanto en análisis de datos como inteligencia artificial, no va a haber el modelo, o sea, no es que si eligieron este modelo están desaprobados porque pues cómo elegí este modelo, o sea, siempre va a haber más una opción correcta, eh, o sea, lo importante es cómo sea la justificación y todo y más que muchos están la primera vez de trabajo, digamos, tampoco es una entrevista de trabajo esto, entonces eh nada tiene que estar justificado, tiene que una cuestión, Pero recuerden siempre que hay más de una forma de resolver el problema, o sea, no es que está un solo modelo y ese solo, ¿eh?

00:26:31

Facundo Lucianna: Y es generalmente es el desafío elegir el modelo, pero sepan de que si agarramos dos dos personas pueden resolver resultados similares con dos modelos totalmente distintos. Yo más que para que no se estresen, ¿eh? No, Santiago, no va a haber entrega clase a clase. Lo que va a haber es una fecha que vamos después mandar por mail que tienen que enviarnos cuál es el dataset que ustedes o sea cuál es el grupo que van a trabajar y si no hay cahut esta vez no. E pero digamos si nos demanda esa fecha, ¿cuál es el grupo y quiénes van a ser los cuál es el set que van a trabajar, cosa de que nosotros ya tengamos ya seguimiento de eso? Y además también para validarles, como decía Karina, si manda el Titanic, le vamos a decir, "Okay, pero más vale que armes un trabajazo e y que no me copie cualquier cosa que dando vuelta de internet porque es el dataset que está muy usado. Eh, ya vamos a pasar Andrés la la por ma la fecha. Eh, la habíamos definido Car,
lse posgrados: No me acuerdo,
Facundo Lucianna: pero no clando un mail
lse posgrados: pero más o menos la clase tres aproximadamente, después les confirmamos.
Facundo Lucianna: con la fecha, cosa que queda ahí validado y lo tengan en un en un lugar escrito, digamos, no hay problema, pero eh sí, sí, ya pasamos,

00:27:57

lse posgrados: Ah.
Facundo Lucianna: pero menos esa fecha para la clase tres ya de tener de vuelta tampoco
lse posgrados: Sí.
Facundo Lucianna: se estresen de vuelta poco lación de alta. Mi recomendación, la misma de Karina, si ya trabajaron con el de con el análisis de dat y lo tienen ahí, buenísimo, usenlo, se aborrecen ese trabajo, quieren hacer algo distinto y tengan algunos ya ustedes medio ya mapeado, digamos, pero mi recomendaciones, si ya tienen uno que trabajaron, aprovéchenlo.
lse posgrados: Eh, las clases las vamos a dar intercaladas, va, no intercaladas, no es uno y uno, o sea, algunas clases las va a dar Facundo, otras clases las voy a dar yo. A veces vamos a estar los dos, o sea, uno va a venir de de soporte, pero en general nos vamos a repartir. Pero nuevamente no significa que si yo doy la clase dos después solamente me consulten a mí. Cuando necesiten consultarnos, mandan a los dos siempre.
Facundo Lucianna: Si a mí no me manden de de

Ise posgrados: Ah, eso es lo único. No de KNN no le manden porque odia el modelo.
Facundo Lucianna: nada,
Ise posgrados: Ya

00:29:03

Facundo Lucianna: tengo un problema personal. ¿Es un problema personal?
Ise posgrados: spoiler.
Facundo Lucianna: No, no lo voy a comentar, son cuestiones
Ise posgrados: A mí no me molesta.
Facundo Lucianna: personales.
Ise posgrados: Así que de hecho creo que ya se los dije en análisis de datos cuando vimos algo de KNN, ya se los dije. O sea, a nosotros nos sirvió, así que yo no lo odio y no no hay ningún problema con el
Facundo Lucianna: Bueno,
Ise posgrados: KNN.
Facundo Lucianna: en serio, si cualquier cosa pregunten a los dos, aprovechen. Eh, usted me está contestando alguna otra. Ah, perdón, creo que quedó Gast Carina. Eh,
Ise posgrados: No, si llegamos biografía.
Facundo Lucianna: pasé está ahí.
Ise posgrados: No dije nada, pero bueno.
Facundo Lucianna: Bueno, menciono si rápido. Esta es nuestra biografía. Eh, siempre digamos básicamente está el libro por excelencia. Este libro ya tiene 1000 años. Me siento viejo verlo acá. El billop es un libro histórico, digamos, de machine learning. cuando estudiaba yo estudia como el libro y sigue siendo que ya todos los avances eh, pero a mí particularmente me gusta mucho porque es un poco más duro de RER ese libro.

00:30:11

Facundo Lucianna: Eh, básicamente introductionar shames o the element of static learning es de me parece interesante. Es un libro que no tiene tanta tanta otro más fuer es como más eh no sale la palabra, pero como mucho más estricto, no la palabra estricto matemáticamente hablando como que va mal la demostración otras cuestiones. Otros libros son más batas science si lo quieren pensar. Y este de acá, este es un libro un poco más shallow,
Ise posgrados: Ah.
Facundo Lucianna: como más general. Me parece que es demasiado general, pero

mi recomendación, insisto, estos dos libros son bastante buenos, eh, son compentan bastante entre ellos dos, hasta parecen que son como muy, no sé, me llama atención los la misma editorial, todo es muy raro, pero está bueno.
Gabriela Sol Salazar: Perdón, creo que nos estamos viendo el cursor.
Facundo Lucianna: Sí.
Gabriela Sol Salazar: O soy yo.
Ise posgrados: No,
Facundo Lucianna: Ah.
Gabriela Sol Salazar: Ahí.
Ise posgrados: ahora sí.
Facundo Lucianna: Ah, no est es que es que sabes que no tengo Ah, estoy en ¿Sabes qué pasa? No estoy en otro navegador, entonces no tengo todos los mismos elementos que Chrome. Entonces quería usar el pi pi pi el marcador y estoy como acostumbrado hacer eso.

00:31:24

Facundo Lucianna: Pero acá acá puedo marcar acá. Eh, hablo de estos dos, perdón.
Ise posgrados: Es un comentario,
Facundo Lucianna: Eh,
Ise posgrados: aunque diga, perdón, cuando aunque diga Facundo que este libro es reviejo,
Facundo Lucianna: sí.
Ise posgrados: no, no lo dejen de lado, porque de hecho los modelos que nosotros vemos en esta materia son modelos clásicos y modelos que están hace muchos años, que tampoco es que los damos para mostrarles la prehistoria, son modelos que se siguen usando, pero están desde hace muchos años vigentes. Entonces, por eso ya en libros viejos, bueno, viejos no son de hace 30 años, pero bueno, algunos son bastante más o menos. Bueno, 20. Eh, sí, de hecho yo el camín lo amo porque mi el primer modelo que aprendí hace, no quiero decir cuántos años, pero sí, más de 20. Bueno, eh, digo, libro viejo no significa que no no es válido, al contrario, o sea, estos modelos existen y y ya se explicaban hace esa cantidad de años.
Facundo Lucianna: Sí, es eso como detalle, o sea, record un poco, vamos a a a ver desde inteligencia artificial que vimos un pantallazo general de cosas, esta materia sigue en esta idea, la asignatura eh seguimos avanzando, o sea, la idea que ustedes van a ir avanzando en modelos más sencillos o chicos y después van a ir cuando llegan después a Deep learning van a empezar a ver los modelos más avanzados Y así van avanzando en conceptos,

00:32:45

Facundo Lucianna: pero primero tienen que, ¿cómo se primero hay que gatear para correr, tampoco sin irnos super al principio, pero son modelos que resuelven el 90% de los casos, normalmente tipo de modelos que yo le llamo shallow en general, modelos justamente no profundos, pero que resolvieron y que fueron los reyes durante desde los 90s, o sea, la Sí, los 90s, los 90, sí, los 90 desarrolló Super machine seon los 90, por ejemplo, si no me equivoco. Entonces son los 90 son modelos. Eh, principios 2000 yo me acuerdo cuando salió Kishb, siempre me acuerdo y me quiero sentir viejo eso porque todo el mundo, uh, salió de Kbost, pero todo el mundo está usando Kbost y están haciendo un un desecho de recursos porque están procesando mucho más cuando se puede resolver con la red lineal. Y piensen ahora que están usando data center gigante con los modelos de para resolver una pavada. Entonces me siento tan como estábamos hablando si era es un modelo una chiquinada es una cosa así al lado de lo que tenemos hoy en día por es pero me acuerdo salió KBUS es un modelo que vamos a ver en la clase cinco si no me equivoco, eh que que les va digamos le va a dar nada que fue su momento fue una bomba y no fue tan bueno así de vuelta estamos viejos este fue mínimo 15 años fue esto 2025

00:34:06

lse posgrados: H
Facundo Lucianna: cinco, eh, sí, haber sido 15 años más menos cuando me acuerdo salió ese modelo. fue una revolución cuando ese modelo ganó todas las competencias, fue increíble, pero bueno, hoy en día ese modelo resuelve un montón de problemas, un montón de problemas inclusive de muchos datos y pero el tema tenemos tanta big data que ahí sí ya empieza a justificarse los modelos de de más profundo y empezamos a usar modelos de de deep learning, de aplicado de redes, todo. Además que ya van a ver cuando lleguemos cuando ustedes llegan la materia de de lear una red por más que sea chiquita, tiene su trabajo, es mucho, es mucho más complejo en el desarrollo eh de una red, salvo uses redes que ya estructuras que ya están conocidas, eh pero bueno, parte siempre de una base eh requiere mucho más trabajo que muchos de estos modelos lo resuelven mucho más fácil y por ahí tú consigues resultados mucho mejores en mucho menos tiempo, No, entonces estos modelos no me no lo desprecien por ser eh viejos. Tengan en cuenta siempre su arsenal les puede dar mucha velocidad y mucha iteración rápida en desarrollo de cosas. Como también algo que sí eh está bueno que tengan que lo hagan en la para el proyecto final es eh y lo vamos a mencionar en varias veces para que les quede claro, hagan un modelo de base, lo que llama un baseline.

00:35:38

Facundo Lucianna: Y el baseline que van a hacer tiene que ser una heurística, no tiene que ser ni un modelo, no me dan una reacción lineal, no me digan o una reacción logística. Recuerden que yo amo la reacción logística. Mi modelo favorito es la reacción logística. No, no se olviden de cuando van a plantear y empezar el proyecto, empezar desde un modelo de base que sea baseado unaística porque ¿por qué eso es importante? Ese modelo o esa o esa jurística que hagan en base a su análisis que hicieron justamente por eso recomendamos que análisis de datos porque ya hicieron todo parte de ese proceso y ya tiene un cierto conocimiento de los datos, una orística que le permitan dar un primer puntapiéie inicial de por donde con lo más básico que se puede hacer. Bien, por ejemplo, no sé si yo quiero predecir eh la edad de de de nosotros, eh bueno, listo, hago el promedio, tengo el promedio de las personas y listo, tengo la edad de promedio y uso esa edad promedio como predicción. Voy a estar siempre pegando en el medio, tener un error, pero voy a estar siempre en el medio. Bien, eso. Es como me va a dar una métrica base que después voy a usar para comparar y tener como base cuando hago un modelo tiene que ser al menos mejor que eso y no se va y se van a hacer primer mundo a veces que les va a pasar muchos proyectos que a veces no pueden superar ese modelo de base por más que tengan un modelo.

00:36:55

Facundo Lucianna: Eso claramente indica mala calidad de los datos, mal trabajo de los datos. Ya vamos ahí viendo, más detalle más de lo que ya vieron a decir dato. Bien, entonces vamos para automático. Vamos a como cierta forma esta clase probamente sea más corta lo normal porque vamos a repasar ciertos conceptos que ustedes ya vieron, inteligencia artificial, vamos a profundiciar algunos de ellos o vamos a enfocarnos un poco más, vamos a ir repasando cosas que ya más o menos bien. Necesitamos esto porque tenemos que partir desde un lado. Bien. Ya habían visto eh la definición de aprendizaje automático, ¿no?, que era eh una computadora son algunos datos, construye un modelo basado en ellos y utiliza ese modelo como una hipótesis sobre el mundo. Además de es una pieza de software eh además de como una de de como una pieza de software capaz resolver problemas. Entonces, lo importante es recibe un conjunto de datos, aprende este conjunto de datos, reconoce el patrón entre los datos y realizciones y no requiere una persona programa instrucción. O sea, básicamente no hay una programación de ese

funcionamiento. Simplemente yo le enseño, enseño, enseño, enseño, el bicho aprende y una vez que ya aprendió función de los datos, justo sus parámetros para aprender esos datos y ahora el más va a empezar a dar una salida en función de lo que aprendió, esperando a que sea eh de lo que queremos, ¿no?

00:38:25

Facundo Lucianna: que de la la predicción que esperamos siempre un concepto de incertidumbre que ya vimos el riesgo empírico esa idea es eh estamos en un mundo siempre estamos en mundo machine learning es el mundo eh de la incertidumbre vamos a estar siempre trabajando ahí no es para para ansiosos este área eh nunca vas a saber si realmente las cosas funcionaron bien aprendieron bien básicamente este es el concepto. Entonces, la pregunta que siempre surge, eh, ¿cuándo usarlo? Bien, entonces eh machine learning no es una herramienta mágica para que parar sobre todos los problemas, obviamente. Eh, inclusive, como yo les mencionaba, en los casos donde puede ya aplicarse por ahí la solución tenía no pueden ser las óptimas. Entonces, cuando vamos a iniciar un proyecto de paisaje automático, eh debemos valorar realmente si es necesario rentable hacerlo así. Entonces, para que un sistema macharne aprenda, tenemos lo más importante que la siempre la pregunta, ¿no? Si viene alguien dice, yo quiero hacer un modelo y voy para aprender algo. Entonces, la pregunta uno siempre hace, ¿qué qué datos tenés? ¿Tenés datos? No, tengo un Excel viejo ahí tirado con dato. Ya empezaste mal. Ya sabes que te vas a meter en un lío que no vas a poder salir.

00:39:50

Facundo Lucianna: Entonces, claramente la respuesta importante es tener datos. A veces quizás el trabajo, muchas veces cuando uno va a trabajar un espacio de de proyectos de learning es llegas a un lugar que quieren hacer. Tu primer trabajo va a ser armar la generación de datos para que pueda tener datos, armar todos los pipeline y todo el proceso, vuelta todo la todo lo que vean si datos sirve para todo eso, digamos, de de armar lugares, bueno, listo, descentralizar de una base de datos, usar bquery, usar spark, no sé, un lugar donde est los datos que puedo usarlo para procesarlo, este, y quizás después, mucho tiempo después pueda pensar recién en un modelo. Y además otra cuestión también es que es que los vamos a tener que aplicar esto cuando este necesitamos que haya patrones que puedan aprenderse. Bien. Y ahí hay un juego muy interesante, o sea, tiene que haber patrones que que estén en los datos, pero que además no sean determinísticos. El ejemplo sería si yo

tengo un sistema, el ejemplo, antijemplo sería contraejemplo un controlador PID. Controlador PID, un controlador, por ejemplo, se usa para controlar temperatura en una incubadora, ¿no? En lugares donde me importa tener un muy buen control de temperatura, pero es un proceso, es una fórmula matemática que está dada, bien, o sea, está la fórmula matemática desarrollada.

00:41:14

Facundo Lucianna: No necesito eh tiene solución ya ese problema. Entonces, yo no necesito es un modelo que aprenda a controlar temperatura usando, o sea, usando, no sé, datos de medición, si ya puedo implementar eh la fórmula matemática para que haga el control, ahí pierde sentido esa esa estructura. Pero sí hay situaciones en donde por ahí generalmente hay soluciones tradicionales que a veces se usa machine learning, que es por ejemplo siendo mismo de ingeniería, el mismo mundo bastante chiquito, digamos, pero bueno. Eh, en señales, yo tengo señales y hago pensamiento de señales, tengo que filtrar señales. O sea, básicamente procedamiento de señales ya es una materia que se aprende, un área super tradicional, ingeniería de toda la vida hecha y derecha, eh, pero, o sea, tienes todos los filtros, todo, pero esos esos, por ejemplo, esos filtros fallaron en todos estos relojes inteligentes, que estos relojes inteligentes te mide el SG, te mide el latido, te mide todo, pero no está preparado todo eso para, ah, me muevo así, ah, me muevo así, así me estoy moviendo así y tiene que seguir midiendo, ¿no? Entonces, esos casos, esos filtros adicionales, entonces para evitar eso, eh, se biológicas, por ejemplo, usan machine learning como filtro, o sea, aprenden a entender cómo es la señal, como cuando empieza a haber ruido, pueda filtrarla, pero con lógica y con sentido a la señal, algo que los filtros tradicionales no lo pueden hacer.

00:42:49

Facundo Lucianna: filtro adaptativo, si lo queramos pensar, ¿no? Eh, o reconstruir parte, le falta un pedazo de señal y está mediéndote cuando estás caminando para saber tu ciclo, medos, todas esas cosas que hacen, reconstruyen el error de medición y con eso, o sea, hace una serie de tiempo, entonces hacen una una predicción de cómo son los valores y completan esa parte. Todo eso lo resonan con con con machine learning son situaciones que era un ejemplo donde uno diría, "No, acá no usaría y sí hay lugares donde la situación te lleva a por más que exista un área tradicional eh de ese mundo. A veces no es evidente si realmente existe un patrón, los datos y sobre todo esto es en el mundo de datos generados por

humanos, o sea, datos de interacción humana y comportamiento humano, o sea, cualquier eh no sé, comportamiento de usuario entrando un sitio de noticias y aquí noticias visitan y cosas así, va comportamiento humano que es bastante eh complejo de entender porque el humano es un ser complejo. Entonces, algo que nos puede pasar es que si existe quizás un patrón es tan complejo que es muy difícil capturarlo, sobre todo con estos modelos shallows, el ejemplo está eso. Podría existir un patrón en cómo son los tweet de los mask y la afectación de las criptomonedas.

00:44:14

Facundo Lucianna: No sé si se acuerdan, no sé, hace mucho no lo hace, pero una época decía DKA, el tipo mandaba un tweet así y hacía todo el mundo iba a comprar como uno sacado do coinían seían los valores de muchísimo. No se decía, no sé, decí sacar algo todo un sacado y todo, o sea, el tipo tenía un control muy fuerte sobre las criptomonedas. Ahora ha un modelo que lea Twet Don para hacer predicciones de valor es un patrón bastante complejo, ¿entendés? Porque aparte nada, no es un if twitea o no titea, sino es un comportamiento un poco más raro que disparía los dispar los los puntos picos esos de comportamiento. Pero bueno, uno podría hay un patrón hay una correlación entre ambas cosas, ¿no? Nada más que es sumamente no lineal y compleja de entender. Entonces, bueno, todo ese tipo de comportamientos, hacer modelaciones de todo lo que sea mercado bursátil es complejo de hacer porque justamente es comportamiento humano extremo, digamos. una cuestión que pasa muy seguido, eh, que es el caso de, okay, como yo les decía, si llegamos a un lugar, vamos a a trabajar, hacer unas mediciones y no, o sea, me pide hacer un modelo y no hay datos.

00:45:39

Facundo Lucianna: Bueno, ¿qué hacemos hasta que salen los datos? Muchas empresas sin desfoque fake it till you make it. Bien, mentilo hasta que lo haces. Es decir, es un un producto que pasa mucho. Eh, hace poco había salido ese que era el modelo LM y eran personas de la India haciendo las predicciones, digamos, predicciones hechas por humanos. Modo machine learning con la esperanza de de utilizar los datos generados para entrenar modelos posteriormente de dichos modelos. algo que acá no mejor usar predicciones hechas por humanos o o resultados también hablábamos laurística que mencionaba, no tener un modelo base algo mínimo para poder hacer el ejemplo trípico es yo tengo un sistema de

recomendaciones para recomendar por ejemplo una plataforma tipo Netflix y decir, "Bueno, tengo que hacer esta plataforma, estoy por salir, no tengo ningún dato, no tengo datos de cómo el comportamiento sario. ¿Qué es lo básico que haría?" Bueno, recomiendo, empiezo las primeras mediciones. Primero lo más básico, tiro al azar, qué sé yo, no sé, tiro el el, o sea, tenemos el histórico del del top más visto, algo en el D, una cosa así, poner los mejores, poner ahí, no sé, algo, ¿no?

00:46:54

Facundo Lucianna: Eh, Rocky uno, digamos, qué sé yo. Después empezas a tener mediciones y empezas a tomar una vez que tengas mediciones y bueno, listo, tomá el top 10 más visto de los usuarios. Ponte esa recomendación, ¿qué es la sistema de recomendación más básico te puede hacer? tomás datos de tu plataforma, agarras los más de la estadística, los más vistos y recomendas eso. Bien, y a donde hablábamos, recuerden, decía modelos de base difícil de romper o ganarles, ese es uno de ellos. Les puedo asegurar que podemos hacer un modelo, hacer un modelo mag learning que recomendación super personalizado, que se enfoque el usuario y que podamos si mejoramos mejoramos 1% más de lo que es ese modelo. Es muy difícil vencer al más al top más visto, ¿no? Siempre va a tener el Pareto, el problema de ese que va la mayoría de la gente hace todo lo mismo. Bueno, todo entonces más o menos va a estar. Entonces, son situaciones interesantes donde donde ejemplos donde son difícil de vencer por el modelo de base que que este de agarrar los mejores de o más si estás segregado si tenés segregado tus usuarios en grupos que puedes usar un modelo que vamos a ver en la última clase de clasterización ahí más porque pues tenés ya segrado por tipos de usuarios les hacés a ese grupito de usuarios cuáles son sus mejores cosas.

00:48:12

Facundo Lucianna: muy probablemente que ese entorno sean todos más o menos compartan al mismo gusto y sean y tengan, digamos, esa recomendación les sirve. Eh, pero bueno, ya ahí por si ya estás aplicando algo de machine learning, si estás haciendo un modelo no no supervisado, no dejas ser machos mayor están hechos. Algo tamb importante, los modos ma learning sirven para para ser usados. Ma learning aprendizaje automático. Una diferencia fundamental con estadística tradicional es que usamos las cosas para predecir. Bien, o sea, hacemos por más brí estadística, lo que sea, usamos para que nosotros queremos predecir, lo queremos usar. Si voy a hacer todo un trabajo para que después no me sirva de nada, perdí

tiempo. Bien, hicimos todo el modelo. Mira esta notebook, qué bonita esta gráfica y terminó y se lo guardó en un lugar, eh, no servir seó de nada. Bien, nosotros hacemos un modelo para después ser usado, hacer predicciones sobre ese modelo. Bien, tiene que tener una utilidad. Bien, eh, como y lo que buscamos es responder preguntas que sean predictivas. Bien. Eh, que es esas preguntas que son que sobre todo son alternativas esas preguntas que son una gran cantidad de predicciones, pero sean baratas, pero que sean aproximadas aparte de que tendremos a ser aproximados.

00:49:37

Facundo Lucianna: Eh, ¿cómo será el clima mañana? ¿Quién ganará el Superball este año? ¿Qué película querrá ver un usuario a continuación? ese tipo de pregunta responder machiller paréntesis en esta materia vamos a hacer un vamos a entrenar un modelo y vamos a hacer unos gráficos y vamos guardarl o se van a probar y lo van a guardar una caja. Sí, pero bueno, porque están aprendiendo. Bien, mi comentario de eh estamos haciendo eh para hacer cosas útiles. Excepcionemos acá. Bueno, acá la utilidad de usted aprobó la materia, digamos, tiene un tiene un fin. Eh, Alber. E algo importante que que sí tiene que ser muy importante, muy muy importante, los datos que yo use para entrenar y los datos que después van a a estar usados para para hacer predicciones tienen que ser más o menos prevenir la misma distribución o son muy similares porque si yo los datos que entreno son muy distintos los datos que después van a estar siendo usados para predecir, mi modelo aprendió algo que no que no sirve, digamos. sería algo una distribución que los datos no no es eh digamos que no es lo que modelo aprender. Entonces el tema es cómo sé que la distribución de los datos que vien son las mismas.

00:50:57

Facundo Lucianna: Bien, porque yo no puedo hacer futurología, se está ocurriendo el evento, entonces no tengo todavía información de lo que estoy queriendo predecir. Nunca vamos a ver con certeza, como le dije, macho no es para gente ansiosa, digamos. Eh, nunca sabes si realmente lo que estás viendo es realmente eh es las mismas distribuciones. Estamos usando lo que está lo que se está usando en producción es lo mismo que lo que eh de lo que entrené mi modelo. Siempre estás con ese con ese terror. Cuando saliste a producción, tu modelo empieza a ser usado. Si realmente haces lo que tiene que hacer, eh, y no te queda otra que darte cuenta cuando estás en el baile. Bien. O sea, cuando estés en digamos eh est en producción

y empiezas a ver las métricas una vez que ocurran los eventos. Por eso siempre tenés que medir cuando salción siempre nunca parás eso. No entraste un modelo y terminó el trabajo, ¿no? que salir, tienes que seguir midiendo si los resultados están bien, tienes que hacer todo es todo ese análisis y si vas viendo que un eficiente un rendimiento deficiente, unamiento que no está esperado dentro de los decisiones que se tomaron de de diseño, eh va a poder tomar decisiones sobre eso, ver si cortar experimento, nada, ya en otra materia vamos a ver cómo se hace, por ejemplo, este tipo de análisis de, okay, tengo que hacer eh pruebas en producción, bueno, ¿cómo hago?

00:52:26

Facundo Lucianna: tesab o diferentes formas que puedo probar, comparar entre diferentes poblaciones para poder atacar este problema que es, no sé, yo no puedo saber hasta que estoy en producción si estoy rindiendo bien o no, si realmente está atrayendo el beneficio que estoy esperando que va a traer cuando eh también, o sea, cuando vamos a la tarea tiene que ser repetitiva, si el patrón que se va estando se repite varias veces la máquina va a poder aprender. Si no, si un patrón que se de una sola vez cada entonces cada un montón de tiempo, no hay forma que el modelo pueda aprender ese patrón. Entonces tiene que ser información que tiene cierta estructura, que se que se dé ese patrón para que para que el modelo logre capturar esa esa información. Ahora lo importante es que los patrones cambian constantemente, las culturas cambian, los gustos cambian, las tecnologías también, lo que está moda puede ser noticia vieja mañana. Entonces conseguimos, por ejemplo, la tarea de clasificar el correo no deseado. Lo que hoy un diicio de spam puede ser un príncipe nigeriano, ¿no? El príncipe nigeriano, ese mail que mandaban de spam para que mañana puedes un escritor bien a mí angustiado, ¿no? Entonces, ¿eso qué significa? Que los datos cambian.

00:53:45

Facundo Lucianna: Yo entrené mi modelo para que logre predecir si eh si esano o no y estoy viendo si están esas palabras o algún modelo de bebidos que logre capturar ese ese concepto. Eh, si me parece el principio cristal angustiado no va no va a funcionar, va a fallar. Entonces, César,
Cesar Orellana: Y qué hacer en esos casos cuando los datos cambian.
Facundo Lucianna: sí,
Cesar Orellana: O sea, vos creas tu modelo para entrenar cierto ciertas tareas

repetitivas, cierto patrón y eso en el futuro cambia. Se vuelve a reentrenar con los nuevos datos.
Facundo Lucianna: exacto. Hay procesos de retrenamientos o procesos, o sea, son procesos de mejora continua continuamente. Hay procesos que pueden disparar nuevos entrenamientos para poder controlar nuevos nuevos nuevos eh nuevos patrones que se están ocurriendo o hay a veces que que implican un rediseño de todo de todo el modelo, inclusive cambiar de modelo, cambiar cambiar los tipos de datos, cambiar los features, siempre hay todo un un como digo, un proceso de mejora. Nunca termina el proceso de nunca termina donde yo entré en un modelo y termina el trabajo, siempre sigue, sigue porque los datos cambian. Eh, además de que van a cambiar, eh, yo cuando ponga un modelo que haga predicciones sobre algo, probablemente voy a estar yo influyendo las predicciones.

00:55:11

Facundo Lucianna: Va a haber un feedback loop ahí siempre. Entonces eso también nos va nos va a generar cambios y nos va a generar cambios distribuciones ya de base porque estoy poniendo un modelo, sobre todo si estoy poniendo un modelo que de vuelta interacción un humano sobre ese modelo para tomar decisiones de vuelta los modelos de recomendaciones. El ejemplo más sencillo de entender ese ejemplo. Si yo te estoy recomendando películas, obvio tú probablemente que esté te estés sesgando a vos a elegir películas en base a mis recomendaciones. Entonces, ya tu comportamiento fue influenciado por mi modelo. decir, bueno, pero esa señal después voy a user para entrar otro modelo y estoy usando la información misma y está viendo filología y por ahí puedesores predicciones o se sega el modelo. ¿Cómo hago para salir de eso? Cada tanto tengo que tomar datos aleatorios, darle predicciones aleatorias al usuario para ver si romper un poco ese tipo de cuestiones, ¿no? Entonces, formas de romper esa forma de de feedback que te puede generar problemas en modelos. Entonces, ten en cuenta siempre y es y es siempre vamos a estar influenciando los datos y nosotros somos un modelo cada predicciones, ¿ci? Entonces tengan en cuenta que en la mayoría de los casos nuestro modelo mismo va a estar influenciando.

00:56:20

Facundo Lucianna: Por ejemplo, el caso de de de gente que escribe spam, si un detector de spam que detecta príncipe nigeriano, probablemente la persona decida cambiar de país, ya sea un príncipe o un escritor vietnamita, porque sabiendo que

me va a luchar contra mi sistema porque no quiere que quiere pasar mis barreras de spam. No hay siempre el spam, mundo de spam, hay una guerra siempre constante entre los que hacen filtro de spam y la gente que escribe spam. Entonces todo el tiempo hay una influencia constante. Entonces tenemos que estar todo el tiempo mejorando los modelos porque nada, te descuidar un segundo ya te llenó de spam todo el todo toda tu casilla de correo. Algo importante es que los modelos se equivocan. Algo muy difícil de indicarles, stakeholders es que los modelos, insisto, se equivocan. van aimar. Sabemos que se van a equivocar, nunca van a ser perfectos, eh, y a veces no vamos a saber eh, qué tanto se equivocar. Nunca tenemos ni una certeza, nunca podemos ni siquiera asegurar en qué orden, o sea, nunca nunca tenés 100% seguridad de eso. Eh, entonces, por ejemplo, el el un desafío enorme son desarrollar vehículos autónomos porque eh claramente un error ahí puede provocar la muerte.

00:57:49

Facundo Lucianna: de muchas personas, no solamente del conductor. Ahora, ¿por qué las empresas desarrollan o sig invirtiendo desarrollo en esto si error puede ser catastrófico? Y claramente en este caso sí, el punto de vista económico, el eh el desarrollo de vehículos autónomos tiene el potencial de salvar más vidas de las que puede llegar a matar, o sea, estadísticamente, ¿no? O sea, porque el humano maneja, es un desastre manejando el humano, es unas fuentes, las accidentes viales son unas fuentes de muerte más grandes que hay eh siempre en todos en todos lados, en todos países. Entonces, el lo el potencial beneficio desarrollar esta tecnología va a ser mucho mejor inclusive en el camino que te va a llevar, ¿no? Entonces, un caso en donde quizás no es eh uno diría es antilógico desarrollar ahí modelo machine learning. El beneficio y el potencial beneficio es el por qué ocurre este esta decisión. Eh, pero bueno, también toda cuestión de de de PR, ¿no? Cuando un autoónomo choca una persona, el humano, una cuestión ahí para mí más de de psicología, ¿no? Antropológica inclusive de los robots nos dan miedo. Los robots nos dan miedo y lo vemos como un alien.

00:59:09

Facundo Lucianna: Entonces, cuando un robot hace algo malo y por más que el humano sea 10 veces peor, ¿no? O sea, siempre el impacto va a ser mucho más fuerte cuando algo ajeno a nosotros haga algo mal que se y y cuando nos empiecen a challengear la inteligencia nuestra, un comportamiento, no no digo lo tiene, sino

que tiene un comportamiento similar al humano, ahí empieza a ver como ese reticencia a los robots, a los bichos, a los bots frente a eh humanos. Entonces, tengan en cuenta que siempre vemos eso, ¿no? Vehículo autónomo mató a un perro que cruzaba cuando pues estadísticas de de accidentes humanos. Ya, bueno, perdón. Ya. Eh, algo importante es eh que si cuando hacemos una inversión de aprendizaje automático, cuando hac un modelo, cuando se toma decisión de ese modelo, generalmente es una solución cara inicial, o sea, la inversión inicial cara porque tenemos que desarrollar todas las infraestructuras, sobre todo cuando no está en un lugar donde no hay nada desarrollado. Entonces, desarrollar un modelo requiere armar toda la toda la infra de datos, o sea, necesitamos datos, lugar donde guardar esos datos, necesitamos cómputos para poder procesarlos, eh, y además un talento talento que que sea el que haga este todo este proceso.

01:00:29

Facundo Lucianna: Entonces, obviamente, se justifica el uso de dicha solución cuando es frecuente sostener el tiempo, o sea, cuando tenemos que usar esas predicciones de forma continua para que tenga un valor, un beneficio, ¿no? ¿Cuándo no debería usarse un modelo mail? El primero sí es para mí es más cris porque la ética de cada uno es distinto. La ética es una cuestión personal. Eh, no es ético. Bien. O sea, no para si lo voy a usar para discriminar personas y no deberías usarlo. Bien. El ejemplo típico es el caso siempre que pasa y pasa precisamente Estados Unidos porque están obsesionados con las razas. es eh es modelos de de que hacen de contratación de personas que usaban igual ahora un poco con el tema de los agentes, pero en su momento modelos de de contratación de personas eh nada usan usaban los datos bien los datos tienen sesgos porque los humanos somos somos tenemos sesgos y algunos son no voy a entrar, pero digamos hay cuestiones culturales, no se contratan más cierta persona de cierto tipo, de ciertas de ciertas cuestiones. Entonces, si yo entré los modelos con eso, obviamente que el modelo va a ser va a ser racista, digamos. No, no, no es que el modelo racista, no es que el bot es racista, los datos son racistas.

01:01:54

Facundo Lucianna: Entonces, eh terminaba pasando que contrataban, contrataban personas de personas de color, no las contrataban o mujeres no las contaban y había situaciones tan bizarras como si te si te ponías así los ojos, el bicho se pensaba que era asiático y y cosa, o sea, situaciones de ese tipo, te encontrabas

noticias así, digamos, y porque los asiáticos sí tenían en Estados Unidos, no sé, contaban más asiáticos y eso generaba mejores ofertas laborales con mejores trabajos Eso no está mal, eso no es ético. Entonces ahí no debería usarse. Eh, además este existen soluciones más simples que funcionan bien. Claramente es un casos no tiene sentido. Si tengo algo más simple que funciona bien y que está dentro de los resultados que nosotros queremos usar o dentro de los de los el rango de valores nosotros queremos que lo dentro de las cosas si las predicciones están dentro esperáamos que sea eh apenas se usa eso, digamos. Eh, ejemplo, controlador de temperatura, yo el PID, no tenía sentido ha una inversión y todo eso. Si ya tengo algo que está supervalidado, funciona y eh la última no resulta rentable, ¿no? Lógicamente si me genera un gasto muy grande al punto que el beneficio que me puede dar es muy bajo, no no tiene sentido.

01:03:23

Facundo Lucianna: Generalmente eso justamente es el modelo de base y todo el primer análisis inicial que hacemos de pararte una primera idea. Si lo mínimo me da este este rango para ahí me doy cuenta que poder hace algo hacer muchísimo esfuerzo y ese esfuerzo me puede llevar a un costo muy alto que no va nunca va a lograr tener un beneficio que logre eh recuperar la inversión que se hizo en eso. Entonces, veamos un par de definiciones. Un de vuelta hacer más de repaso frente a lo que ustedes habían visto en en May. Son las 8. Un recreo. Lo acabo de ver ahora. Justo me lo repar para este momento. Eh, hago un pequeño recreo de 10 minutitos. Voy a hacer ahí. Tengo que hacer acá. No, no, no. ¿Qué estás haciendo? A ver. Ahí. No, no. Estás haciendo cualquier cosa. Ahí está. No, está haciendo cualquier cosa. A ver acá no.
Ise posgrados: ¿Quieres que ponga un temporizador de acá del Sí,
Facundo Lucianna: Ah, verdad que tenemos tempor acá.

01:04:25

Ise posgrados: sí, si quieres lo pongo.
Facundo Lucianna: Me olvidado que tenemos 10
Ise posgrados: ¿Qué dijiste? 10, no, cinco. No sé qué dije.
Facundo Lucianna: minutos.
Ise posgrados: 10. Listo.
Facundo Lucianna: Listo. Bueno, estamos recréditos. Volvemos 10 minutitos. Bueno, estaba en tiempo, ¿eh? Hay gente. Bueno, veo dos manos, tres manos. Tres manos

alcanza. Yo siempre tres manos es mi número. Entonces seguimos. Eh, quiste, quisiste mandar emoción, eh, reacción y te pasaste la mano. Pasa, pasa, sigue pasando. Bien, eh. Vamos entonces. Bueno, ahora vamos a hacer un repaso de definiciones que ya habíamos visto en inteligencia artificial, solo para recordar y para que vuelta tengamos acá fresco esta materia más ustedes que estuvieron pasó un año desde la última vez que lo vimos un año. Bueno, pasaron meses, no pasaron tantos, pero hubo el cambio de año en el medio, al menos un periodo de un mes, si chirola entre la última clase y ahora entonces está bueno que repasemos eh dos meses que pasa básica, algo típico que normalmente manejamos en machine learning, la forma más común de manejar datos es usando raíz de dos dimensiones, eh, o notación vectorial para guardar para referirnos a las diferentes cosas Y dado esa estructura que estamos

01:16:21

Facundo Lucianna: mencionando, eh cuando hablamos de una fila de esa RA, eh le vamos a llamar una muestra, una observación, un dato puntual, bien son observaciones desde que fueron eventos ocurriendo de nuestro lo que vamos a usar para nuestro modelo y donde cada columna va a representar una característica feature o atributos que es de la observación mencionada del punto anterior, ¿no? O sea, por ejemplo, estamos midiendo eh no sé, eso es muy malo para estas cosas, para ejemplos rápidos. Eh, personas quiero hacer predicciones algo de una persona, estoy midiendo cada observación va a ser una persona y este una característica va a ser, qué sé yo, eh, altura, peso, una variable fisiológica de la persona. Si quiero saber el tiene una enfermedad. Entonces, eh esa característica se acada la columna. En el caso más general que vamos queremos hacer, vamos tener el valor que queremos predecir, que es la columna que va a llamar objetivo lequito respuestas y que va a tener ese valor justamente que queremos, pretendemos predecir. No siempre estará para eso cuando llegamos a aprendizaj supervisado, vamos a ver casos donde esa valor no está. E entonces l un ejemplo concreto de lo que sería un típico estructura de datos de de estado para machine learning, tenemos esta este ray donde, por ejemplo, tenemos queremos predecir salario de las personas en base a ciertas características.

01:17:55

Facundo Lucianna: Vemos, por ejemplo, que tenemos cada fila es una observación, es un empleado distinto, tenemos las diferentes observaciones y después tenemos

la ficha que son las columnas como la posición del empleado, nivel de experiencia, la habilidad, qué país está, en qué sido está. Y tenemos esta última columna que la que llamamos label o etiqueta, que es la que consideramos que la queremos predecir, en este caso el salario, ¿no? Entonces, que hace un modelo de predicción de de salario, es el ese es el la columna que quiere usar para entregar un modelo que aprenda a predecir ese valor. Además, los modelos machin learning tienen parámetros internos que yo son eh que no dependen de los datos, o sea, que no se aprenden. Tengo que configurarlos antes de que eh de que usted use el modelo para entrenar que se se llaman hiperparámetros. Ejemplo de una red horonal tiene como hiperparámetro la función de activación o la tasa de aprendizaje que se llama learning rate o por ejemplo modelos de árboles que vamos a ver tiene cuánta profundidad del árbol, eh cuántas hojas va a tener, entre otras características. Como digo, tengo que yo primero eh definir para poder entrenar ese modelo. Si no tengo esa información, no puedo entrenar el modelo.

01:19:09

Facundo Lucianna: Por otro lado, tenemos el concepto de generalización que habíamos visto encia artificial que es la capacidad de un modelo para hacer predicciones correcta utilizando datos nuevos. Entonces, cuando hacemos cuando vemos que nuestro modelo funciona como queremos y hace predicciones correctas, datos que nunca vio, eh decimos que el modelo generaliza. Hay dos grandes grupos de aprendizajes, eh, tipo de aprendizajes. Real hay tres, porque lo vimos en la otra inteligencia artificial. aprendizajes supervisados e cuáles son aquellos que hemos visto que eran modelos que que le enseño con datos con el label para que aprenda. A pesar que no supervisado es cuando le eh no le damos eh salida conocida, entonces usamos, o sea, no tiene una variable, no tiene un una salida conocida, entonces tiene que aprender la estructura de los datos. Eh, respeta aprendizaje por refuerzo que que vimos en en inteligencia artificial, que es eh le yo no le enseño al modelo, no le muestro qué valor y qué valor para que aprenda, sino que le enseño hace algo y sobre eso el ambiente te da recompensas para ver si está haciendo bien o mal las cosas y con eso aprende el modelo, o sea, no le doy los datos, sino que el modelo tiene que hacer generar el el el comportamiento para luego ser juzgado.

01:20:38

Facundo Lucianna: Y después está el concepto de aprendizaje profundo que es un subcampo de machine learning, digamos, que utiliza modelo de jerarquía, estructura

jerárquica de redes neuronales artificiales. Tienden a a estructurarse por lo menos en un principio, unas bases de toda la base de de a pesar que profundo de bienes de la universidad computacional. Entonces tiende a tener una estructura similar a al cerebro humano, pero bomelón que es como una inspiración, una bioinspiración, no significa que está imitando el cerebro humano. Entonces, siendo más detalle, aprendizaje supervisados, los modelos aprenden estados conocidos y realizan ajustes de sus parámetros internos para adaptarse a los datos de entradas. Una vez que el modelo ha sido entrenado adecuadamente y sus parámetros externos son coherentes con los datos de entrado, los resultados conjunto de entrenamiento, el modelo se puede usar para hacer predicciones. la típica estructura o nuestro como un diagrama de bloque de cómo es el desarrollo de modelo. Tenemos el los datos de entrenamientos con el label, o sea, una vez que justamente ustedes vieron análisis de datos, o sea, llegan a ese dataset usado para entrenar, entrenan el modelo, el modelo aprende. Entonces el modelo una vez que está aprendió, se ajustó sus parámetros que son aprendidos, tenemos el modelo predictivo que utiliza para nos llevar nuevos datos predicciones.

01:22:06

Facundo Lucianna: Bien, básicamente eso dentro de los grandes tipos de modelos de clasificación, de vuelta repasando ustedes ya vieron inteligencia artificial, tengo los modelos de clasificación, son modelos que aprenden a clasificar, se usa para cuando se le enseña una variable categórica. Bien, entonces quiero predecir si de qué categoría pertenece esa variable que estoy queriendo o ese label que estoy queriendo entregar. Llama por se llama problema de clasificación. Y eh hay básicamente eh como dos grupos de esos clasificación binarias que son, ¿okay? Es o no es tipo detección de spam, es o no es spam y clasificación multiplace cuando ya tengo que clasificar eh más de una categoría, ¿no? Entonces quiero clasificar el nivel socioeconómico de una persona, eh si es nivel clase alta, clase media o clase baja, es un modelo de mult tiene múltip salida. Sí, algo que si cuando podemos graficar a nuestros datos, por ejemplo, tenemos dos atributos y yo puedo tener esos puntos que ven ahí son diferentes observaciones que tenemos de de los datos y el color sería qué clase pertenece, en este caso, la roja o la azul binaria. Lo que hacen estos modelos es poner una frontera ahí de de clasificación, o sea, si pone una una o lo que llama como una frontera, una algo que separa eh los datos de un lado para el otro, ¿no?

01:23:36

Facundo Lucianna: Este caso es un caso extremo que tiene una forma muy serpentosa. Generalmente no tiene esa forma, ser rectas o formas mucho más concretas o geométricas y además que se van a equivocar. es un modelo, un ejemplo extremo solamente. Y después tenemos otro modelo que es el modelo de regresión. En este caso, en vez de aprender una varia teórica, aprende una variable numérica. Entonces, quiere predecir el valor que de esa variable numérica. Entonces va a ajustar una función matemática al conjunto de datos para encontrar esa esa esa fórmula que logra prcir el número, ¿no? La fórmula cuando digo fórmula, no no no digo una fórmula cuando modelos no usante lineales y grandes si uno quisiera llegar a la representación de la fórmula ser una una cosa muy compleja porque solamente no lineal, pero sí siempre hay una hay una fórmula matemática detrás de estos modelos. Eh, el aguación lineal es el ejemplo que ya vieron en inteligencia en inteligencia artificial. Es un modelo muy básico, pone la recta, el modelo que también lineal ahí la vimos la vimos en el concepto de machine learning, pero obviamente la reacción lineal es un concepto de estadística eh de toda la vida. Entonces, bueno, la pintamos ser una reina recta que minimiza la distancia entre los puntos de la muestra y la línea ajustadas.

01:24:57

Facundo Lucianna: Eh, y un ejemplo típico es, quiero predecir, precios de valor de las casas en venta de la ciudad, dado el barrio, la cantidad de habitaciones que tienen y otras características. Quiero decir cuánto vale la casa cuando la quiero vender, la quiero vender el máximo precio que la pueda vender dentro de un lado sin poner un número nacional, quiero vender rápido, entonces quiero poner un valor donde el mercado, el valor del mercado, bien, eh, que es algo muy difícil de de saber. Y después para que supervisado tenemos eh lo que llamamos cluster agrupamiento. Es una de las principales aplicaciones de de mensaje no supervisado que es eh okay, yo tengo mis datos, no tiene etiqueta, tengo datos eh y quiero ver si tiene una estructura que se se agrupan en ciertos grupos. Bien, quiero ver eso, quiero encontrar sios tienen ese tipo de agrupamiento, ¿no? Si está todo distribuido al azar y es una cuestión eh o homogénea o realmente hay como cúmulos de datos dados ciertas ciertas combinaciones de features. Eh, lo que buscan estos grupos es encontrar eh grupos de objetos o de observaciones similares que se diferencian de los otros grupos. O sea, tengo este grupo que tiene estas características que es distinto esto. Eh, el objetivo es obtener esos grupos, pero obviamente yo no sé cuáles son.

01:26:26

Facundo Lucianna: Bien. Eh, el ejemplo típico de esto es, por ejemplo, analizar el comportamiento de múltiples cadenas de comida y terminar cómo se agrupa el mercado para su verdaderos competidores. Es decir, yo puedo ver eh en función de de sus ventas, eh datos de que tienen estas estas cadenas de comidas como s yo, McDonald's, Barrel King, qué s yo y las cadenas más chiquitas de de comida. Entonces yo voy a ver ciertos comportamientos que tienen en sus en sus ventas, en su forma de de su de su oferta y lo que tienen y puedo intentar ver cómo se agrupan y quiénes son eh posibles competidores que no son obvios para estas cadenas, ¿no? Ese tipo de análisis hacen estas grandes empresas. decir, "Bueno, listo, yo quiero ver quién me puede competir a mí en este mercado que yo no te conozco porque soy muy grande y no puedo ver porque soy gigante, no tengo ojo para todo el mercado posible y me puede parecer que aparece, por ejemplo, un competidor para McDonald's en algún lugar porque es una comida sustituta o algo en ese contexto de ese lugar, esa cultura, esas otras personas tienen comportamientos distintos, lugares distintos, qué sé yo, un una tienda eh chiquita que empezó a abrir varias como sucursales de venta de algún producto, ejemplo de acá en Argentina de Choripam, ¿no?

01:27:49

Facundo Lucianna: Choriz y empiezas una cadena del choripan mágico y tú por todos lados, pero solamente se reduce a ese mercado, ¿no? A ese mercado de ese lugar mientras digo, McDonald tiene entonces se puede dar cuenta con este tipo de análisis, cuál puede ser un posible competidor que tenga que hacer algo para luchar contra ese competidor para no dejarlo crecer más de lo que ya está. Bien, porque si bien se empieza a irse del a otra ciudad y empieza a crecer, se puede empezar a transformar en un competidor eh grande. Entonces hacen esos análisis de ese tipo de clasterizaciones para saber cuál están alrededor de ellos de cosas que ellos no saben que existen. Bien, 15 ya saben que competidor necesitan hacer análisis estadístico para saber eso. El ejemplo típico de eso de unais que digamos que me tocaba ser amigoente para para McDonald un trabajo era obviamente salió a la luz durante fue la época del mundial pasado, eh, que que Mustazan estaba comiendo el mercado a niveles astronómicos, digamos, en Argentina, eh, y no lo sabían, no lo habían mapeado a ese a ese detalle. decir, es obvio, ¿no? O sea, hoy en día ya en su momento estamos recién empezando, o sea, hoy en día ya comió muchísimo más.

01:29:06

Facundo Lucianna: No sé qué pasó 1000 años que hice ese trabajo, por su momento todavía no había escalado. Mostas de pronto subió mucho su su, ¿cómo llama? su shade de mercado, pero en su momento no era obvio y en su momento ya salá y te das cuenta decía hamburguesa, obvio, ¿no? Pero también había un comportamiento de los usuarios alrededor de eso que era muy parecido al comportamiento de los usuarios que consumían McDonald's que inclusive era diferente a los que usaban parking porque había una diferencia ahí que hacía claramente decirte, "Che, mira este, este te puede competir, no te preocupes tanto en Barg." Y otro típico eh uso pensar que un supervisado eh es reducción diimensional, que en esta materia no lo vemos. No me acuerdo si por cina eso, pero si lo vean esto algo en en análisis de datos.
lse posgrados: Si vimos reducción dimensionalidad, pero no para hacer clasificación, pero vimos el concepto, ya deberían, creo, si se acuerdan, deberían saber lo que es reducción de dimensionalidad. Algo también vieron con Martín en análisis matemático.
Facundo Lucianna: Perfecto. O sea, esos conceptos los vieron ahí, no los vamos a incapar acá. O sea, por reducción sí general tiene esa utilidad que ustedes ya vieron estas en est esas materias, sobre todo análisis de datos.

01:30:27

Facundo Lucianna: Me sirve para eh poder le podemos llamar técnicas de eliminen ruido de los datos, me quiten variabilidad que a mí no me importa para hacer para usar para un modelo, por ejemplo, para predicción. Entonces, eh me sirve ese tipo de de estructura o o de técnicas para hacer eso. Oigo, generalmente no usamos muchos para un resultado final, sino más para un resultado para permitirnos hacer uso de esa información. Tal como no me lo dicen, ya lo han visto, o sea, bastante situaciones en donde puedo encontrar alguna transformación que me reduzca en números de atributos en un en este caso a dos, eh, que me permita, por ejemplo, en este caso tengo los datos que tienen, imagínense estos colores como una relación. Bien, entonces yo tengo eh desde color rojo un valor muy bajo, un valor muy alto, bueno, valor muy alto, valor muy raro, azul que tropezar un valor más bajo, entonces un valor muy raro, pero fíjense en que los atributos hacen que los datos estén como una especie de loop. hacer un modelo de reacción de eso es prácticamente eh imposible y es muy difícil es un modelo gigante, me va a fitear todo, má un desastre.

Con simplemente eh una transformación logro romper el rulo y abrirlo y de esa forma puedo bajar a dos variables que me muestre el rulo abierto y eso es un modelo muy sencillo de predicción, ¿no?

01:31:48

Facundo Lucianna: Modelo red de probablemente red lineal ya me alcance para para poder explicar estos datos o algunos muy básicos. Entonces ese sería el ejemplo feliz de de de un caso de uso de redalidad, pero generalmente es para eso, para reduc tengo muchos datos, no tengo suficiente procesamiento, tengo que reducir una forma. El clásico ejemplo de esto es eh para no escucharon el concepto de embebidos. A ver, pongan manito alguien que sabe lo que si sale por lo menos de escuchó la palabra embebidos. Al tiene que haber escuchado porque me acuerdo que había gente acá que ahí está Gabriel. Sí, Gabriel, sí, Gabriel sí. Marcos también, Agustín, Tomás, todos sabía en mi vida al final para había uno que no sabía. Bueno, pero para aquellos que no saben, viido es un eh digamos condensamos una información en un vector numérico. Bien, generalmente se usa mucho en texto. Eso está muy de moda porque los modelos delem y todo esto también utilizan en en inter cosas que usan en bebidos de esto. Pero bueno, básicamente yo entreno algo que aprenda ciertos conceptos y los puedo beber en un vector. Después con esos conceptos puedo luego usar vectores para acercarme en conceptos. Y hay hoy en día, por ejemplo, hablando de estos estos estas grandes empresas, hoy en día desarrollo de de modelos, todos tienen sus embebidos, eh, tipo los de Open Ey, que son embebidos de 3200 eh vectores de 3200

01:33:16

Facundo Lucianna: valores. se llama porque enve un vector que enveción donde enveen conceptos, o sea, yo agarro un texto y lo transformo usando un modelo de ellos en un en un modelo que genera una embida. Insisto, ese es un vector, un número. Y puedo usar eso para después yo tengo un texto y quiero otro texto y quiero ver qué tanto se aproxima en conceptos. Si hago después distancia cosenos o ciertas operaciones de vectores, puedo obtener esa idea y después con clasterizaciones puedo encontrar cler vectores similares para hacer eh agrupar concepto. Por ejemplo, no sé, eh te sirve mucho para hacer búsqueda, por ejemplo, búsqueda semántica. Yo quiero hacer un buscador, tengo un catálogo de de música, ¿no? De canciones, ¿no? Y tengo estos bebidos que que lo bebí bebí el título con cierta información de los de la banda. Envío un texto y lo enveo con ese vector.

Luego hago un buscador que música rock country del 88. Y si y si está bien hecho ese sistema viido, me puede buscar correctamente usando vectores para saber cuál es y ciertas formas de búsqueda. Obviamente vector div o conceptos de un poco más avanzado puedo encontrar esa esa búsqueda.

01:34:36

Facundo Lucianna: ¿Cuál es el problema de eso? Yo a veces tengo mis bídos tienen 30,72 valores. Bien, quiero hacer un modelo de de machine learning que hago usé a embebido para hacer predicciones. Bueno, tengo 3072 valores, es un montón y por ahí si tengo un atas no muy grande me empieza a dar overfitting. Entonces, eh muchas veces lo que se termina haciendo a veces reducendo reducción de dimensionalidad paraal dimensionalidad a veces pagamos el precio de perdemos variabilidad, vamos a perder un poco de capacidad que tiene ese embebido, pero puedo reducir un tamaño donde mi modelo ya no va a verfitear y no va a tener problemas para para aprendizaje. Bien, no tienes tú muchísimos datos para para hacerlo. Es sería el ejemplo típico eh de rón dimensional que se usa mucho. Y hablando de paisaje profundo, digamos, eh análisis profundo es si ya los modelos mayores que estamos viendo acá son mayorías no lineales, eh este entramos en en un mundo extremadamente no lineal, o sea, todo la base de todo de aprendizaje profundo es que es no lineal, no lineal. Y toda operación matemática internamente es no lineal. Entonces ese es el secreto de por qué funciona tan raro que humanos no entendemos.

01:35:58

Facundo Lucianna: Lo humano resolvimos muy bien matemáticamente hicimos ya una álgebra hermosa, todo un desarrollo hermoso, un cálculo hermoso, todo alrededor del concepto de linealidad. Bien, cuando basamos no lineal, la matemática se empieza a caer, digamos como que no hay desarrollos porque es un seto mucho más complejo. Eh, y estos modelos son así. Por eso también es por qué no entendemos cómo funcionan las redes neuronales. Sí, si son modelos sumamente no lineales, por eso no entendemos cómo internamente ocurren las cosas. No, no podemos discepcionar exactamente cómo aprenden o qué realmente tienen. Se puede dar ideas o conceptos. Hay hay hay muy interesantes, hay ciertos análisis interesantes, pero nunca podes decir, ah, exactamente por cómo funciona. Eh, la red de caporal tiende a tomar datos brutos como entradas. En general, esto tomarlo con pinza, en general se puede hacer esto, pero realmente no lo hace. Uno toma los

datos como entrada, los procesa, extrae información y las transfiere la siguiente capa como sabía, como que va tomando, procesando y haciendo cosas. Eh, este paso se va pasando por capas en el cual va procesando y trayendo información hasta que llega la capa en donde tiene que hacer la predicción final.

01:37:10

Facundo Lucianna: Este este resultado se compara con un con un resultado conocido y mediante un análisis inverso, o sea, eh desde la salida hacia adentro atrás aprender los factores que conducen a la salida como que va ajustándose los pesos o las diferentes componentes que tienen estas redes de forma de adelante para atrás. Eh, a pensar que profundo es la base de todo lo que hoy en día existe. O sea, todos los agentes, estos bichos gigantes que hoy en día están dando vueltas son modelos de pensaje profundo usando un tipo de estructura que descubrió Google que llama Transformers que revolucionó el mundo de Magel. Eh, pero bueno, algo sí, Alejandro es propagation con de otra forma. Cristo. Eh, pero sí es el concepto de preparation. Como decíamos un día casi todos los usos de de grandes de modelos usapizensaje profundo, pero bueno, uno de los muy típicos es algo que ustedes van a hacer en análisis en visión por computadoras van a ser recomendágenes. Y es muy interesante que esos modelos son un poco más chiquitos, entre comillas. Hay modelos, se puede hacer modelos chiquitos, hay modelos muy grandes, pero modelos más chiquitos, donde podemos de vuelta diseccionar cómo funcionan. y entender qué hacen las diferentes capas. Y es muy interesante son principal de los modelos que se llaman convolucionales porque van como armando eh una imagen y empiezan detectando ciertas primitivas de las imágenes como por ejemplo direccionalidades o eh colores y esas formas y después van bando puntos

01:38:50

Facundo Lucianna: de mayor eh complejidad. Eh, por ejemplo, ya no detecta eh líneas, sino ya detecta eh figuras geométricas y así va como avanzando en la comprensión para poder comprender y con eso puede lograr reconocer si es un perro, un gato. Y lo gracioso que tiene eso es porque, digamos, siempre me gusta ese ejemplo porque cuando vos diseccionas un cerebro literalmente como funciona la cortesa visual, las neuronas visuales hacen exactamente el mismo proceso. Nosotros entendemos en imagen. Eso creo que ya hablamos este ejemplo de cómo se hacía cuando hacemos el ejemplo del gatito. El gato, eh, el gato se acuerdan de

de de tenía el dibujo eh de cosas era como una de cosas de este de a los muertos, digamos. Y como nosotros podemos entender que es un gato del día de los muertos, ¿no? Entonces, ese concepto y bueno, ¿cómo hace el cerebro para lograr diseccionar? Bueno, estos modelos funcionan. Eh, la persona que por refuerzo eh pregunta Alan eh es un aprendizaje más bien dio es no es ni supervisado ni no supervisado ni profundo para refuerzos inteligencia artificial es otra área de inteligencia artificial que pueda usar neuronas para hacer supervisado perdónaje por refuerzo seguro si se hace pero es un área aprendizaje ¿Qué tiene que profundo?

01:40:20

Facundo Lucianna: Todo el mundo lo quiere usar. Obviamente el tema decir, "Ah, sí una renun lo que hice, hice una renun de 20 capas." Digo, ahora ya no dicen antes. Antes se hablaban de capas, ahora te hablan de parámetros. como cambia terminología 8 millones de parámetros entren un un modelo y vos no es una versión logística este, ¿cuál es el problema de eso? 8 millones de parámetros. 8 millones de parámetros. Para poder entrar 8 millones de parámetros están muchísimos datos de entrenamiento. Bien, porque si no van a fitear como el loco. Bien. Las redes son expertas overfiteadoras. Tienes que hacer un montón de de cosas raras para que no se te overfiteen, ¿no? Que quitasle conexiones, que hace esto, que no pa regularizaciones, un lío bárbaro para para poder que que no se te no se te overfite overfitean muy sencillamente todo eso como lo van a ver más lo van a ver más profundidad en otras materias profundo visión por computadora y algunas que me esté pasando bien, pero van a seguir viendo estos conceptos. lo que era el concepto de ciclo de vida de mach como como yo decía, el el desarrollar un modelo machine learning no es un solo un proceso una sola vez si terminó seleciono good shop y la cosa no nunca termina es un proceso siempre de mejor y es un proceso largo como ven acá todo todo proyecto de aprendizaje automático Casi todo proyecto de ingeniería en general arranca de un problema de negocio.

01:42:09

Facundo Lucianna: Sabemos, tenemos un problema y tenemos que resolver ese problema. Bien, siempre surge obviamente de un lado eh de una necesidad, ¿no? Hay una necesidad de hacer resolver algo. Ese problema después empieza la etapa, una de las etapas más importantes de este proceso que la división de objetivo. Tenemos que definir eh cuáles son los objetivos que tenemos que hacer para para resolver nuestro nuestro problema, ¿no? O sea, bueno, decir, bueno, listo. ¿Qué es lo

que queremos hacer? ¿Qué métrica queremos mejorar? Bien, se referir muy claro cuáles son las cosas porque son las que vamos a estar comparando para saber si esto funciona. Una vez que tenemos eso hecho, vamos a la etapa de recoleación de datos y preparación. Esto, esta parte van a ver es más fuerte lo que es el videoanálisis de datos, hacer recolección de datos, eh prepararlos, guardar en un lugar donde sean accesibles, que sean fácilmente eh sea accesibles, que estén guardados, seguros, cumplan ciertos requerimientos de de que te permite cierta acceso a esos datos. Luego estaremos en un proceso de análisis que se va trabajando feure y nos buscar qué tipo de eh de features se puede hacer para usando esos esos datos, ya sea de usar los features tal como están, adaptarlos, hacer ciertos tengo variables categóricas, hacer encoding tipo onehot encoding, otro tipo de encoding, eh usar e o hacer que yo tengo eh unas dos variables Y quiero combinar con una tipo generalmente operaciones matemáticas.

01:43:46

Facundo Lucianna: Bien. Eh, un típico es hablo. Siempre ejemplos míos porque me lo que tengo a mano, ¿no? Eh, una vez hicimos modelos de de de detección de de ¿cómo se llama? de en base a la naveación de internet saber si es una persona, o sea, que que identificación de personas, eh, y una variable que funcionaba muy bien, o sea, tenías el ancho y el alto del monitor que usaba, eh, eso no funcionaba muy bien, pero usabas el ratio era muy buena, tenía muy buena capacidad proyectiva, lograba tener mucho mejor resultado usando el ratio del ancho y el alto en el monitor que tener el ancho y el alto por por junto. darle ya esa información masticada al modelo les funcionaba mejor que el modelo tengan que encontrar el internamente para aprender calcular el ratio. Bien, eh una vez tenemos esas cosas definidas, esamos de entrenamientos de validación de testeos, etcétera. Pasamos lo que es el concepto de entrenamiento del modelo. Entrenamos un modelo, el modelo, evaluamos con el de testeo. Recuerden, ese testeo no lo tocan. Es ese testeo es no lo usan en ningún proceso de de búsqueda de prepararámetro, de nada.

01:45:04

Facundo Lucianna: No lo usan para nada porque tienen que usar el último paso para realmente saber si el modelo generaliza un montón de cuestiones. Evalo el modelo. Si el modelo va bien, estoy dando primero el camino feliz. Ahora vamos a ver los feedback que se ven ahí. Si el modelo va bien, hay que desplegarlo, hay que sacar la producción. Entonces, empieza el proceso de despliegue, el modelo, cómo vamos a

sacar ese modelo a producción, dónde va a vivir, que arquitectura va a estar funcionando, va a ser una API que va a estar consumo, va a ser un proceso en Bach que va a estar los datos. Bueno, tenemos que ver cómo va a hacer eso y tenemos que ver cómo vamos a desplegar eso. Desarrollar ese modelo que acabo de decir, servicio del modelo. Va a ser una API, una AP Rest, va a ser un graph un un un Docker en un lado, en un o NX en BQU, o sea, donde en un lugar tiene que estar con alguna lógica. Eh eh además que una que precón tengo que hacer un monitoreo de ese modelo para ir viendo esté funcionando en producción, está todo en orden y llega el mantenimiento del modelo para ver obviamente si si hay eh cambio, distribuciones o si está empezando a ver performance.

01:46:09

Facundo Lucianna: A ver. Entonces, fíjense ese ciclo que el monitoreo queda todo el tiempo activo. Y fíjense que hay flechas de de vuelta ahí hay como retroceso porque claramente estos procesos nos pueden disparar es mejoras continuas. Es un proceso que nunca termina. Entonces, fíjense acá un proceso de hacemos todo este proceso, nos va dando cierta información. Acá hay flechas que faltan. Por ejemplo, ficha engineer muchas veces te puede volver para atrás para recolección de datos porque está en usted que hay cierta información que no que no que no no te alcanza o tu ed tu análisis estadístico inicial te va dando cierta información que te va dando patrones que por ahí te está faltando, entonces tenés queceder. Pero cuando entrenamos el modelo y evaluamos y vemos las métricas y vemos que no alcanzamos los nuestras métricas prentado en nuestros objetivos, eso puede disparar, retrenar el modelo o mejorar features o recolectar más datos porque cuenta que los datos que estamos recolectando eran eficientes. Eh, o por ahí los puede plantear redefinir los objetivos. Claramente estábamos planteando algo que no se podía hacer, ya no algo que no era correcto. Eh, como también toda esta ra etapa, el monitoreo de modelo, estamos viendo si el modelo de pronto vemos que empieza a a pudrirse.

01:47:24

Facundo Lucianna: Los modelos como cualquier empieza a subar se pudre, es decir, las predicciones empiezan a ser cada vez peor. Pueden redisparar procesos de reentrenamiento con nuevos datos para volver a actualizarlos, como habíamos visto el ejemplo de hoy de de estos datos cambiados que montaba César. Bueno, ejemplo, acá si monitoreamos y vemos que en una métrica que nosotros elegimos como tal

es general esta métrica no es la métrica típica que usamos mag learning acá generalmente son métricas de negocio. Bien, entonces si quiero medir por ejemplo algo que me genere plata GNB, o sea, cuánto plata ingresa, si estoy viendo de pronto tenía ciertos valores, de pronto empiezan a caer, acá algo pasa. Entonces por ahí tengo que reentrenar para que ajustar los datos acá. Decime, Alejandro.
Alejandro Valle: Eh, existen pipelines para poder reentrenamiento de modelos. Digamos que ocupamos urgentemente que se reentrene con nuevos datos. Hay pipelines automáticos. Para eso siempre hay un proceso de prueba primero.
Facundo Lucianna: Eh, hay eso todo esto lo vamos otra materia, pero si hay dependiendo de dónde estés hay ya desarrollos donde esto está automatizado, bien, pero el 98% de las empresas no tienen ese proceso automatizado. hay humanos detrás tomando decisiones, viendo tableros o lugares donde est disparan, pero sí hay desarrollos de pipeline, ese tipo de cosas.

01:48:50

Facundo Lucianna: Eh, y como decía, el mantenimiento del modelo también, el mantenimiento del modelo tenemos que mejorar los objetivos cambian, entonces obviamente me puede disparar, seguir recolectando datos, recolectando datos siempre tiene que estar, eso nunca tiene que parar bien. Y siempre les recuerdo, sobre todo los que son desarrolladores, ese es generalmente mi choque más grande que tengo con los desarrolladores, programador tradicional de toda la vida. Eh, le encanta tirar datos. Ellos, ellos no te guardan un dato, no te no te logue algo y lo tiran a la basura. Se olvidó. No, no, no, no, no. Guardame todos los datos, viejo. Guardame todos los datos porque hoy día los datos que estás sacando en tu sistema vale oro. Es un los asets más valiosos que tienen las empresas. Entonces, todo dato que se genera de todo proceso importante que se ha guardado, sobre todo con lo barato que hoy en día el almacenamiento que hay, el almacenamiento está regalado el mundo de la nube, inclusive ahora con más que todos los discos rígidos, todos los precios de todo está subiendo porque la empresa de de entrenamiento de grandes modelos están se están consumiendo todo el mercado, pero por lo menos la nubes que son esos los que están haciendo eso, son baratos ellos.

01:49:50

Facundo Lucianna: E es barato el giga, es barato. Entonces, guarda los datos. Esos datos son cosas que hoy en día por ahí no te sirven. El día de mañana por ahí pueden servir para un mejor modelo. Entonces guarden los datos. Entonces

procesos, por favor, no tienen datos. Si lo pueden guardar, guárdenlos. Esta materia, como les decía, vamos a ver solamente la parte de arriba, bien. Vamos a quedar en este parte del proceso que es eh que llegga hasta la evaluación del modelo. Por eso el trabajo final de esta materia llega hasta acá. Terminar evaluación. Ese sería después decir, bueno, listo, ¿cómo saco el modelo de producción? Es el siguiente paso que es el trabajo de la materia que viene, que operaciones de máquina uno. Bien, operaciones de máquina, eh operaciones de aprendizaje de máquinas uno. Eh, vemos esta parte, ¿bien? Y después está la en la maestría la operación de aprendizaje máquinas 2 que continúa esa historia, ¿no? Pero es un tema más ingenierí puro ahí donde siempre digo donde menos me van a querer ahí donde me terminan odiando, me terminan queriendo en la inteligencia artificial, me terminan odiando en el aprendizaje, operaciones aprendizaje máquina azul eh porque prepárense sobre todo aquellos no son no tienen tanta formación en el mundo de de programación esas cuestiones hay que meter cosas más de ingeniería, ¿no?

01:51:10

Facundo Lucianna: Docker, cuestiones más avanzados, bien, más de esa área, bien, no son más avanzados, simplemente son más específicos. Eh, pero bueno, es un punto muy importante porque siempre eh salía los avances y sobre todo las necesidades hoy de negocio en búsquedas laborales, esa necesidad antes de la data scientis era como, "No, vos con un notebook está todo bien y vos puedes conseguir trabajos con solo notebook." día cada vez menos eso ocurre, cada vez se pide más el tipo de de desarrollos de esta área. Entonces, está bueno tener por lo menos un conocimiento cosa que esté de pie para poder desarrollar independientemente que después tu trabajo el día a día quizás no esté 100% metido ahí, pero en el momento tenés que, o sea, tenés que saber dónde tu modelo va a servir, obviamente, si no te vas a tener incompleta la figura de lo que está ocurriendo. Bien, y creo que este es el último tema que entendimiento del negocio, ¿qué es esta yo le decía? O sea, algo que sí hac que hacemos mal los data scientist es cuando hac un proyecto de de aprendizaje automático los vamos a los a las métricas técnicas, ¿no? Medimos la precisión, el F de un score, latencia de diferencia, otras cosas. El tema está en que a veces el equipo invierte en grandes recursos para mejorar estas métricas, ¿no?

01:52:33

Facundo Lucianna: Pasado del 94 a 94,5% de accuracy, ¿no? de de Eso, ¿qué significa? ¿Qué significa para el negocio y para el donde estamos desarrollando las

cosas? La realidad es que la mayoría de empresas esas mejoras no les importa un comino, digamos. O sea, ¿qué importa eso? Eso lo usan porque uno es nervio hacer mejor modelo, quiero hacer mejor resultado. Eh, lo importante es que eso tenga tener un impacto comercial real. Bien, tiene un impacto que genere una mejora en el proceso donde esté funcionando. Y cuando hablo de comercial no lo pienses solamente puramente monetario, sino también tienen procesos de optimizaciones en lugares donde sea necesario. para que un proecto machine learning y sobre todo yo tengo que defender y tengo que decir, "Okay, necesito plata estos recursos, no solo plata, sino recursos económicos de de de necesito gente, contratar personas, necesito armar un equipo, necesito eh tiempo, otro recurso económico muy importante, tengo que conectar las métricas técnicas que tengo con el resultado de negocio. Yo no puedo si mi si mi métrica de accuracy no significa una mejora en la métrica de negocio, si no puedo lograr esa conexión, no hay forma que me eh me financen o tengo un presupuesto para hacer esto.

01:54:01

Facundo Lucianna: Bien, entonces es muy importante entender ese negocio para poder hacer ese análisis. Algunas preguntas conviene plantearse son, ¿qué indicadores de negocio buscan mejorar el sistema de earning? No, o sea, si yo aplico este modelo, ¿qué va a ser realmente el beneficio? No siempre necesariamente va a ser que va mayor es un sistema de recomendaciones que más gente va a comprar. Hoy día algo que está muy en boga en todos los mundos de TikTok y todo eso es qué tan engagement o qué tan adictivo es tu sistema y eso necesariamente les traduce en una métrica pura de cuánta plata entra. El beneficio va a venir posteriormente porque la persona está más tiempo en tus redes social, no sale más y eso hace que pueda vender más publicidad y después de esa publicidad va a hacer más ingresos, pero no es el necesariamente el resultado del modelo que venda más publicidad, sino que sea más adictivo. Es otro viene después y entonces yo tengo que me digo métricas de engagement que se llama o por ejemplo más ingresos por publicidad, mayor número de usuarios activos también a veces quiero eso, ¿no? A veces quiero no mejor de vuelta, no mejorar métricas puras de de económicas, sino quiero tener más usuario activo en mis plataformas o menor tasa de abandono, que no me dejen bien mi sistema no lo abandone porque no le no le sirve para lo que están buscando hacer y entonces tengo que ese tipo de preguntas tengo que hacerme a la hora de buscar cuáles son las medidas de negocio y después de eso llevarlas a okay, cómo voy a medir el modelo y cómo voy a saber si esto va a tener un impacto y cuando vaya a reunión con este holder tenga

01:55:31

Facundo Lucianna: eh tenga mejor digamos mejor resultado y por eso puedo lograr financiar y sostener más tiempo mis proyectos. Una de las razones por las que es eh por la que las predicciones de tasa de o sea uno de los motivos por qué eh la predicción de tasa de clic en el anuncio, no sé cuántas personas ZR que cuántas personas hace clic en un anuncio o la detección de fraude es uno de los causos más populares de mach learning. O sea, yo siempre si ustedes eh ven, digamos, plata scientist en toca tocar en en un proceso de entrevistas de de personas, digamos, que ten un puesto, van a encontrar que la mayoría de la gente trabajó principalmente detección de fraudes, es realmente uno de los modelos que más gente trabaja en el mundo de hoy día de de cualquier empresa, digamos, obviamente un banco va a tener ese tipo de cosas, pero es un como un típico típico caso de uso típico. Pero, ¿por qué ocurre eso? Porque es muy fácil asignar rendimiento de los modelos a las métricas de negocios. Es directa, es prácticamente es puramente directa. Cada a momento de la tasa de crisis ingresan posiciones reales más plata. O sea, si yo predecir el ZR voy a tener como muy buen resultado. O si logro eh predecir las transiciones fraudulentas detenidas, obviamente una dinero real.

01:56:49

Facundo Lucianna: puedo puedo vincularlo muy fácilmente. Eso por eso es encontramos tanto en el mundo de machine learning estas dos tipos de de modelo, digo, sobre todo detección de fraudes. Yo no sé, me he cansado de ver personas que han trabajado en detección de fraudes. Ahora para una respuesta algo que los comenté hoy de a la respuesta definitiva de la pregunta de cómo las métricas y influyen en las métricas de negocio. Es necesito hacer un experimento. Sin experimento yo no puedo saber si lo que estoy haciendo funciona o no funciona. Bien, si yo un modelo, mando a producción y sale y no mido nada o no mido contra algo, ¿cómo sé que es mejor? Bien, necesito hacer pruebas tipo experimento AB que me permitan probar, por ejemplo, un grupo de personas o un grupo de la gente o donde estoy hacer predicciones sin el modelo, con el modelo y ver cómo performan instituciones iguales o similares y ver cómo esas métricas eh mejoran. Pero fíjense que las métricas son las comerciales, ¿no? No me importan las métricas de mayor en este contexto. Ahí ya no me importa las métricas mayor. Por eso digo, no se vuelvan locos cuando hablemos de métricas tipo cura que si tiene un 70. En realidad generalmente no sabemos eh o es muy importante lograr traducir esos a beneficios y muchas veces a veces una por más que la métrica veamos uh esta es malísima, pero con que es un poquito mejor con lo que ya es ya te puede generar una diferencia abismal en ingresos o o de ahorro económico dependiendo se Entonces

esa es muy importante eso, que no se obsesionen con las métricas de de machine learning porque no neamente significan que van a muy

01:58:39

Facundo Lucianna: buenas o muy malas porque tod figura de para qué hacemos esto. Entonces, eso es lo importante que quiero que quiero destacar y que tengan en cuenta bien, más le hacemos para algo, tiene que ser útil. cuando digo tiene que ser útil tiene que dar un beneficio donde estemos usándolo. Y para eso tenemos que traducir eso a métricas de negocio. Para poder traducir métricas de negocio que se entiende y tengan sentido, tenemos un muy buen análisis de entendimiento del negocio. Para entender el negocio tenemos que meterlo en cada parte del proceso donde crean nuestros datos, hasta cóm hasta dónde van. Tenemos que ser muy muy metidos, muy metidos. Preguntarle a todo el mundo son los procesos, dónde ocurren ser y entender muy bien cómo son los datos. Generalmente una falla muy grande que hay data scientist en empresas que no te mida entender cómo sus datos se generan. Si vos entendés como se genera no hay forma que puedas un buen modelo de machine learning porque no entendés cómo funcionan las datos, cómo son cómo cómo ocurren las cosas, los procesos dentro donde vos estés o cómo ocurre, o sea, no solo procesos, sino tenés, bueno, tenemos usuarios interaccionados con tu plataforma que puedan hacer cierta forma o tienen ciertos comportamientos, entender esos comportamientos muy buen análisis, por eso los edas son fundamentales, pero son los edas con propósitos hacemos análisis, no es hacer distribuciones por distribuciones, análisis esas distribuciones que tengan sentido entendimiento.

02:00:01

Facundo Lucianna: Bien, y toda la parte de de ver, de hacer cualitativas, de ver eh también cómo se ve la experiencia con una cosa la otra, independientemente de las métricas generales, también funciona mucho porque te da intuición, le podemos llamarlo más llamado, no me gusta el concepto de intuición, odio. deducciones de de qué está pasando, que puede estar pasando, que te permita a nuestro entendimiento humano que es limitado, ver rápidamente, pero sí sobre todo hagan cosas que les permitan ver patrones porque el humano es muy bueno encontrando patrones. Entonces hagan eso, preven, entiendan y eso les va a dar muchísimo más beneficios. Y si momento pueden y siolaten a una métrica de negocio a su modelo y logren mostrarle a un deholder que depende de él para que vos puedas financiar

este proyecto o que no te despidan, puedes seguir haciendo. Eh, es, okay, lo mira, yo lo que hice con este modelo logré vos antes tenías esto, ahora te logré esto en este beneficio con esta inversión que fue mucho menos de lo que va a estar en el beneficio. Bien, eso para mí es la parte fundamental de esto es fundamental en match learning esto. Si ustedes no tienen que lograr esto, es un gran parte del esfuerzo de hacer esto. Entonces, por ejemplo, ahora los en los datos que tenemos son de juguetes, por más que no sean de juguetes, son más complejos, son más estáticos, sería la palabra correcta.

02:01:29

Facundo Lucianna: Por ahí es difícil lograr reproducir ese ese aspecto de un trabajo típico porque tenemos una parte más viva que no no tenemos, pero sí podemos sí les recomiendo que hagan además de ese dataset, ¿no? O sea, le van a llegar datos que tiene datas, no sé el, no sé, alguno de no me acuerdo, alguno de esos típicos, pero tiene datos de tener datos. Bueno, pero indagar un poco más de dónde vinieron esos datos, cómo se generaron. Bien, que algo puede ser fundamental, por ejemplo, do un ejemplo bueno esto para cerrando esta idea, época de la pandemia, ¿no? Esa época nefasta, eh, todo el mundo salió de ser modelos de predicción de si una persona tenía COVID o no COVID en base a imágenes de médicas, ¿no? Modelos fallaron, eran inusables, venían con métrica, ¿no? Mira este modelo te mire, pero te saca perfecto. La persona tiene COVID, te da una vez una placa del pecho, así te la pega perfecto. Si probaba, fallaba terriblemente. Pasó muchísimo eso. Eh, ¿y qué pasaba? ¿Por qué pasaba esto? ¿Qué es lo que estaba pasando? Y cuando se empezó nada un poco más, se encontró que estos modelos que se agarraba el dataset del hospital X y el hospital X tiene máquinas rayo X de una marca específica, de una máquina de modelo específico, con las características específicas,

02:03:04

Facundo Lucianna: con ciertas cuestiones específicas y en en una situación en un en un tipo más sala de rayos específica, que eso también cambia y cambia comportamiento. Y algo, por ejemplo, el caso más extremo había pasado que había un caso que era así que queado como extremo de de absurdo. Era muy bueno el modelo de unación bárbar usar los datos de un tal hospital. lo que después empezaron aar, o sea, porque cuando querían generalizarlo otro lado no fallaba terriblemente porque cuando empezaron a analizar un poco más y entendimiento del negocio es okay lo que hacían los médicos sient sospechaba que la persona podía

tener COVID lo mandaban a una máquina rayo X que era mucho mejor o mejor resolución que a las personas que no sospechaban de rayo X. Ya había un sesgo enorme ahí porque la imagen médica cambiaba totalmente eh la calidad, o sea, tenía otra resolución. El modelo son una porquería los modelos machine learning te van a aprender la cosa siempre la cosa que más digamos esos patrones obvios en este caso detectaba que tenía mejor resolución. Listo. O sea, el modelo era un excelente predictor de resolución. Oó otro caso más extremo que era también parecido en situaciones, pero tenía tip, o sea, tiene la tipografía, ¿viste? A veces me ponen tipografía, tienen texto ahí.

02:04:24

Facundo Lucianna: Bueno, el modelo había detectado las tipografías y haba aprendido a predecir con las tipografías, no usaba nada del resto del de la placa, digamos. Y decir, son obvios errores, ¿sí? No, sí, evidentemente claramente no lo eran, pues un montón de proyectos así que fallaron terriamente y eso por la poca falta de entendimiento de negocio. Y el clásico ejemplo en en el mundo médico, por mi formación tengo bastante conocimiento, fallan generalmente los equipos machinar porque no saben entender que los equipos médicos son distintos y los equipos médicos te van a generar diferencias que para humano no es no es notable, pero para un equipo para un modelo sí lo es. Una imagen va a ser distinta de un equipo de de Philips de características de un equipo de los 80 porque aparte los equipos los lugares Ros tiene equipos muy viejos, muy modernos con muchas características, muchos cambios o la máquina que mide, no sé, diferentes variables de sangre tiene ciertas calibraciones, ciertas cuestiones y son todas distintas y eso te va a generar problema. Entonces, con usar un solo hospital no te va a alcanzar para hacer un buen modelo que generalice. Bien, entonces son esos casos donde es muy importante meterte y entender muy bien cómo son las cosas y dónde se va a usar, cómo se va a usar, qué va a hacer, cómo va a hacer.

02:05:32

Facundo Lucianna: Entender los ciclos que hacen los médicos, ¿okay? Ah, la gente que sospecha más que tiene COVID más. Entonces, cuando voy a hacer el datac entrenamiento, tengo que tener en cuenta eso a la hora de hacer para que modelen ustedes ese sesgo. A eso me refiero meterse en toda parte del proceso, ir averiguar cómo funciona, cómo son los procesos de generación de imagen, ¿no? Ah, me llegó esta imagen, yo la proceso, no, yo proceso. No, hay que levantarse e ir a averiguar.

Eso te va a generar la diferencia entre un buen desarrollo y un modelo que pueda servir a un modelo que no. Bien, entonces eso es muy importante para mí en este concepto y que me me gusta inculcarlo independientemente de los modelos que veamos en esta materia, las cosas que hagamos, que son esas cosas que son difícil de enseñar, que más que decírselas más que que entiendan, digamos, es como es un un camino que tienen camin aquellos que no lo han hecho todavía. Y bueno, con eso terminé mi monólogo. Eh, ¿cuándo terminamos la clase de hoy? Código la clase que viene. Ya vamos a ver que jugando con Karina.

02:06:31

Facundo Lucianna: Vamos a ver. Eh, tengo que no hay una forma rápida de hacer esto. A ver, eh, eh, acá. Ahí está. Eh, vamos a ver. CL KNN. Veamos, creo que ese modelo esa clase, sí. KNN. Eh, como van a ver o tema que van a ver que es bastante más complejo porque mediciones de distancia diferentes formas en que funciona, entonces lleva toda una clase. Es un modelo, ah no, perdón, está la otra parte de abajo que el otro que eh es un modelo. Bueno, bueno, es un modelo,
Ise posgrados: Sí.
Facundo Lucianna: está no voy a seguir no voy a seguir hablando de eso. Este y sí hay métodos de ajuste, van a también método de ajuste los hiperparámetros, o sea, vamos a ver más profundidad inteligente artificial hicieron como una primera avance de eso, pero no no muy profundo. Vamos a ver más profundo, método de ajuste hiperparámetros que te permiten hacer método de búsqueda de hiperparámetros. Y cuando digo método de búsquedas recuerde tiene que ser artificial que vimos método de búsqueda tener un contexto más de de búsqueda de pararámetros, pero la idea es es muchos elementos en comunes con eso y van a ver frameworks de específicos creados para resolver este problema.

02:07:49

Facundo Lucianna: Pero bueno, eso veremos el jueves que estén preparados porque va a ser más intens estar más intensos acá.
Ise posgrados: Sí, todo eso. Tengan en cuenta que todo lo que es esto hiperparámetros y y búsqueda de hiperparámetros eh les va a servir para todos los modelos en adelante. No es que es algo específico, lo vamos a ver ejemplificado con KNN, pero es algo que después lo van a poder seguir aplicando en todos los modelos que veamos en las siguientes clases.
Facundo Lucianna: Exacto. Por eso lo damos en ese momento, cosa que ya les

sirvan ese conocimiento para el resto de las clases y ya puedan seguir con su proyecto lo que estén haciendo. Eh, bien. Yo no tengo nada más para decir. Boscarina falta lo que haya dicho.
Ise posgrados: Sí, ahí les comparto,
Facundo Lucianna: Ah.
Ise posgrados: les mando igual por mail eh la planilla donde van a poder anotar los grupos que formen y los datasets que elijan. Ahí está para el ansioso, ansiosa que quiera verlo ya o que ya tenga su grupo,
Facundo Lucianna: Espectacular.
Ise posgrados: pero igual ahora se los estoy mandando por correo.
Facundo Lucianna: Y en el correo mandamos la fecha,

02:08:49

Ise posgrados: Sí,
Facundo Lucianna: ¿no?
Ise posgrados: es la clase tres el límite.
Facundo Lucianna: Dale, creo que correo mandemos el el día específico.
Ise posgrados: Sí,
Facundo Lucianna: Si no queda duda,
Ise posgrados: sí, sí, sí, ahí lo puse.
Facundo Lucianna: pero Ah,
Ise posgrados: Sí, sí, sí.
Facundo Lucianna: buenísim.
Ise posgrados: 19 17 o 19 de marzo.
Facundo Lucianna: Ok.
Ise posgrados: A ver.
Cesar Orellana: consulta, ¿dónde eran que podemos ver los posibles datas?
Ise posgrados: En el campus donde está la parte de, ¿cómo era? Evaluación, se llama exámenes, evaluación, entregas.
Facundo Lucianna: Sí,
Ise posgrados: Ahí adentro hay ejemplos.
Facundo Lucianna: que
Ise posgrados: Y si no, acá en esta presentación al principio en alguna parte también eh hay
Facundo Lucianna: lo
Ise posgrados: algunos eh ejemplos y si no si te encantó
Cesar Orellana: Ah, listo. Perfect.
Ise posgrados: el dataset que usaste en análisis de datos, usas ese que ya está. impecable, listo para entrenar. Es otra posibilidad.

Facundo Lucianna: Ah, para No, no, no, No, no.

02:09:45

Facundo Lucianna: Uh, no. Me estoy doxeando. No, pongo eso no hay que hacer para ingreso. Ahora sí. Sí, estaba dentro al lado. SH Window. No vio nadie el nombre de usuario. No quedó grabado eso. Eh, tenía que muteado el micrófono.
Ise posgrados: Ah.
Facundo Lucianna: ¿Saben que también ha habido, obviamente creo que uno de ustedes está haciendo eso, eh, robo de claves o tipo escuchando el ruido del teclado se puede predecir bastante bien. Vale que nadie tenga metido ese modelo. A ver, de máquina.
Ise posgrados: Tenés que hacer acá se me caen varias otas. Tenés que hacer como hacía Susana Jiménez.
Facundo Lucianna: Ah, sabes que era una adelantada los modelos eh Z acá son alta Z los datas es, pero como como te dijo Karina, o sea, mi recomendación también es si ya tiene de ya hicieron un laburo enorme, entiendo con el de análisis de datos, aprovéchenlo, digamos, es es realmente beneficio de ustedes, pero bueno, obviamente están los desafíos, si alguien quiere hacer usar otro, eso, están disponibles.
Ise posgrados: Sí, obviamente esos datos que ya están ahí muchas veces ya están bastante limpios, por eso es que tampoco se los permitimos elegir a ustedes en análisis de datos, porque ya están bastante preparados para para entrenar, entonces no le tienen que hacer una gran un gran preprocesamiento.

02:11:34

Facundo Lucianna: Sí, el que usan mucho, ya me lo sé memoria este que eso para mí no es tan bueno para ustedes porque ya sé, ya lo conozco tanto, entonces cuando no hacen algo que
Ise posgrados: Sí, es verdad.
Facundo Lucianna: este es bastante complejo, está bueno, pero bueno, es uno típico este también. Este este es muy sencillo, se bastante nada si alguien lo toma porque hay como hay unos atributos que son como obvios este mide el contento del usuario en una enolínea. Entonces hay algunos que llegó en tiempo, obviamente está contento. No llego fuera de tiempo obviamente enojado, no tengo que hacer un if, no tengo que hacer mucho, pero este está bien, tiene cierta particularización interesante. ¿Cuál MVD? Está recontra quemado ese, pero obviamente lo puedes

usar pasaros por mail porque ahí estamos hablando el mismo o no, pero pasaros y última lo vemos. ya tenés, pero es uno muy conocido, pero no es tan eh obvio como el de Titanic, digamos, ese como el s super obvio que que tiene aparte dos datos chiquitito, el Titanic hubieron son pocos pasajeros, fue un montón tragedia pero a nivel chiquit modelo pero última si haciendo.
lse posgrados: No, igual el de cine, nosotros vimos uno, porque hay varias versiones, vimos uno en en análisis de datos que estaba bastante bastante grande el dataset y con qué y yo con con algunos desafíos.

02:13:21

Facundo Lucianna: Ah, ese sígo.
lse posgrados: Yo creo que hay varias hay varias versiones de de la base.
Facundo Lucianna: Sí, sí, sí, si. Ese es monstruoso. Entonces,
lse posgrados: Sí,
Facundo Lucianna: igual es ese me parece que por ahí puede ser demasiado grande para est
lse posgrados: es mucho. Hm.
Facundo Lucianna: hablando que hay uno básico que que siempre lo usa. Okay. Si vos quieres meterte en esa, eh, sí. O sea, pero probablemente probablemente te recomendamos quizás reducir hacer un subsample. Eso es mucho. 45 millones de datos son muchísimos y eso implica que quizás
lse posgrados: Sí, que también pueden perder más tiempo luchando con el el con la máquina que no se les cuelgue entrenando, que lo que van a poder practicar y entrenar distintos modelos, o sea, que no se les vaya la energía y los recursos en en pelear por los millones de datos. Mejor aprovechen eso para ese tiempo para trabajar en más modelos con un dataset más simple, ¿no? El Titanic.
Facundo Lucianna: Sí. O o como digo, muchas veces se puede eh cuando uno trabaja primero cuando vos trabaj tienes muchísimos datos, siempre uno arranca de un susamp porque es como básico porque puedo procesar mi computador todo y empezar a ver y

02:14:38

lse posgrados: Claro.
Facundo Lucianna: si veo que hay cosas ahí empiezo a crecer. Es algo que es natural y normal hacer. Si hace un buen sampleo asegurando una buena distribución y que no pierda representabilidad, le puedes hacer. Y Luis, no hay ningún problema. Si de

dos proyectos, o dos eh eh dos equipos, dos grupos hacen eh el mismo dataset, no pasa nada. ha pasado más de una vez eso, o sea, no es que cada uno tiene que ser distinto. ¿Alguna otra duda que antes que cortemos por hoy? Bueno, entonces estamos. Eh, no les dije bienvenido, se les digo. Ahora llegué tarde, no sería como no daba. Eh, pero bueno, eh, nos vemos ya la clase que viene. Ya contenido más full y arrancando la energía del año. Vamos que arrancamos, vamos que arrancamos. Cuesta arrancar, pero ya estamos estamos a full. Eh, que tengan lindo linda fin de semana o semana,
Cristian A. Aballay: Yeah.
Facundo Lucianna: lo que sea y lo vemos el jueves que viene.
Lucia T. Capon Paul: Chao. Gracias.
Ise posgrados: Chao. Chao.
Facundo Lucianna: Este es el lo metiste este y a
Ise posgrados: El R. Sí. Para que lo mato acá. El e igual el R ya lo van a sacar porque
Facundo Lucianna: Gem. Sí, la grabación también. Así.
Ise posgrados: ahora están experimentando con el Gemini. Va experimentando, o sea, es la primera vez que lo incorporan.

La transcripción finalizó después de 02:16:32

Esta transcripción editable se ha generado por ordenador y puede contener errores. Los usuarios también pueden cambiar el texto después de que se haya generado.