📝 Las notas

12 mar 2026

Aprendizaje de Máquina (2/8) - a242b25

Invitados facundolucianna@gmail.com macroldan@fi.uba.ar Aprendizaje de Máquina - CEIA 24Co2025

Archivos adjuntos Aprendizaje de Máquina (2/8) - a242b25

Registros de la reunión Transcripción Grabación

Resumen

Finalizada la explicación teórica de los clasificadores con la introducción al algoritmo K-Nearest Neighbors y la revisión de la optimización de hiperparámetros vía métodos de búsqueda.

Clasificador KNN y Generalización
La discusión cubrió los tipos de aprendizaje automático, las métricas de distancia clave como la euclidiana, y la necesidad de escalar los datos antes de usar K-Nearest Neighbors. La generalización se destacó como la capacidad del modelo para hacer predicciones precisas sobre datos nunca vistos.

Implementación del Clasificador KNN
El clasificador KNN fue entrenado y evaluado, mostrando una precisión de 0.73, lo que fue una mejora significativa con respecto al modelo de regresión logística de base. Se enfatizó la importancia de la normalización de los datos y se explicó que el clasificador no genera una salida probabilística para su evaluación con la curva ROC.

Optimización de Hiperparámetros y Optuna
Se introdujeron los métodos de búsqueda de hiperparámetros, incluyendo Grid Search, Randomized Search y la búsqueda bayesiana, siendo Optuna un framework avanzado que utiliza el estimador

Tree-structured Parzen. El proceso de optimización busca la mejor combinación de hiperparámetros para maximizar una métrica de rendimiento específica.

Detalles

- **Finalización de la configuración del grupo**: Se recordó a los participantes la importancia de completar la hoja de cálculo de grupos con la información de los integrantes, el tema elegido o el conjunto de datos. Se especificó que el conjunto de datos debe incluir el nombre y un enlace a la fuente, especialmente si no es un conjunto de datos bien conocido (00:00:00).
- **Introducción a la clase de clasificadores y optimización de hiperparámetros**: Se inició la clase, la cual se dividiría en dos partes: el clasificador K vecinos más cercanos (KNN) y la optimización de hiperparámetros. La optimización es un concepto aplicable tanto a KNN como a los algoritmos que se verán en clases posteriores (00:08:29).
- **Repaso de los tipos de aprendizaje automático**: Se hizo un repaso del aprendizaje supervisado, el cual utiliza un conjunto de datos con características y una etiqueta para entrenar un modelo que prediga etiquetas nuevas. Este tipo se divide en regresión (predicción de un número) y clasificación (predicción de una clase) (00:09:57).
- **Repaso de aprendizaje no supervisado y reducción de dimensionalidad**: El aprendizaje no supervisado implica agrupar datos sin etiquetas o reglas predefinidas. La reducción de dimensionalidad es un concepto relacionado con el aprendizaje no supervisado que también se revisó en el análisis de datos (00:09:57).
- **Alcance del curso y temas fuera de él**: El aprendizaje profundo, que se centra en las redes neuronales, está fuera del alcance de la materia y se cubre en un curso específico. En esta clase se verán principalmente algoritmos de clasificación supervisada, con una clase dedicada al aprendizaje no supervisado (00:11:20).
- **Terminología clave de los datos**: Se establecieron los términos estándar: las características (features) o variables son las columnas del conjunto de datos; la etiqueta (label) es el valor a predecir; y las filas son las observaciones. Los hiperparámetros, como el valor K en KNN, son parámetros que se deben definir antes de entrenar el modelo y son independientes de los datos (00:12:38).

- **Generalización y el flujo de trabajo de datos**: La generalización se define como la capacidad del modelo para realizar predicciones precisas con datos nuevos o no vistos. El flujo de trabajo implica la separación inicial del conjunto de datos en entrenamiento y prueba, seguido de la limpieza, codificación y normalización (00:14:10). Después de entrenar el modelo con los datos de entrenamiento, se evalúa su rendimiento con los datos de prueba que no fueron vistos (00:15:28).
- **Introducción al clasificador KNN (K Nearest Neighbors)**: KNN significa K vecinos más cercanos, donde K es el número de vecinos (un hiperparámetro) que se consideran para la clasificación. El algoritmo utiliza la proximidad de las observaciones vecinas para clasificar un punto de datos nuevo (00:16:53).
- **Regla de votación y selección de K**: Para clasificar una nueva observación, el algoritmo busca los K vecinos más cercanos y asigna la clase que más se repite mediante un sistema de votación (00:18:07). Se sugiere utilizar siempre un valor K impar para evitar empates en la clasificación (00:19:06). Se explicó que la elección de K influye en la clasificación, ejemplificando que una K igual a 3 puede dar un resultado diferente a una K igual a 5 para el mismo punto (00:38:18).
- **Justificación del algoritmo KNN**: La base de KNN se inspira en la vida real, donde es más probable que una persona aleatoria en una región tenga características o ascendencia similar a la población predominante de esa área (00:20:16). El algoritmo no garantiza la exactitud, pero se basa en la probabilidad de que los puntos cercanos compartan la misma clase (00:21:20).
- **Definición de distancia y la métrica euclidiana**: La dificultad de KNN reside en definir qué constituye un vecino o estar "cerca" en múltiples dimensiones. La distancia euclidiana, calculada mediante el teorema de Pitágoras (raíz cuadrada de la suma de las diferencias al cuadrado entre los ejes), es la medida de distancia más común y es aplicable a múltiples columnas (00:22:28).
- **Métricas de distancia de Manhattan y Chebychev**: La distancia de Manhattan (también conocida como "distancia taxi" o "distancia de cuadras") es otra métrica que se calcula sumando las diferencias absolutas entre las coordenadas, simulando el camino en ángulos rectos (00:25:00). La distancia de Chebychev toma la máxima de esas distancias absolutas (00:26:09).
- **Generalización de métricas de distancia y la distancia coseno**: Las métricas de distancia pueden generalizarse con una fórmula que involucra la potencia P, siendo P=2 la distancia euclidiana y P=1 la distancia de Manhattan

(00:26:09). La distancia coseno mide la similitud entre vectores basándose en el ángulo entre ellos, siendo una métrica común en el procesamiento de lenguaje, y la distancia es inversamente proporcional a la similitud (00:27:32).

- **Métricas para datos binarios y mixtos**: Para observaciones con valores binarios (ceros o unos), se pueden usar la distancia de Jaccard y la distancia de Hamming. La distancia de Jaccard se calcula como uno menos la intersección de las observaciones dividida por la unión (00:30:08). La distancia de Hamming simplemente cuenta el número de lugares donde los valores binarios son diferentes. También existe una distancia combinada que usa distancias ponderadas de Manhattan para datos numéricos y 0/1 para datos categóricos (00:31:23).
- **Consideraciones sobre la escala de los datos**: Es crucial que los datos estén escalados o normalizados antes de usar KNN, ya que si no lo están, las columnas con valores más grandes (como el salario) tendrán un peso desproporcionadamente mayor en el cálculo de la distancia que las columnas con valores más pequeños (como la edad) (00:32:51).
- **Características del algoritmo KNN y entrenamiento**: Los valores pequeños de K resultan en una alta varianza y un sesgo bajo, mientras que los valores de K más grandes son más estables (00:35:15). Una característica clave de KNN es que no se entrena, sino que se realizan los cálculos de distancia en el momento de la predicción: se calcula la distancia del nuevo punto a todas las observaciones existentes, se ordenan y se seleccionan los K más cercanos para determinar la clase (00:36:28).
- **Optimización de la búsqueda de vecinos con K-D Tree (Árbol K-D)**: Para evitar el cálculo exhaustivo de distancias en conjuntos de datos grandes, se utiliza la optimización, como la construcción de un árbol de búsqueda llamado K-D Tree (00:39:41). Este árbol se construye dividiendo recursivamente el espacio de datos, alternando entre dimensiones, para acotar la búsqueda de los vecinos más cercanos a una rama específica del árbol (00:41:10). El K-D Tree es más eficiente que la comparación exhaustiva de todos los puntos (00:46:56).
- **La maldición de la dimensionalidad y el algoritmo Ball Tree**: La maldición de la dimensionalidad es un problema donde tener demasiadas dimensiones puede hacer que la búsqueda en el árbol K-D sea menos eficiente (00:48:14). El algoritmo Ball Tree (Árbol de Bolas) es un método alternativo más óptimo para conjuntos de datos con muchas dimensiones, que construye esferas o circunferencias anidadas para acotar la búsqueda del vecino más cercano (00:49:34).

- **Implementación de algoritmos de búsqueda en Scikit-learn**: La biblioteca Scikit-learn gestiona automáticamente el método de búsqueda de vecinos: si hay pocos datos, utiliza la fuerza bruta; si hay muchos datos pero pocas dimensiones, usa el K-D Tree; y si hay muchas dimensiones, emplea el Ball Tree (00:51:03). Se puede permitir que la biblioteca elija el método por sí sola (00:54:13).
- **Uso de métricas de rendimiento para la selección del modelo**: Para determinar si KNN es un algoritmo adecuado para un conjunto de datos en particular, o para comparar diferentes configuraciones de K, se deben usar métricas de rendimiento. Esto es preferible a la mera intuición (00:55:20) (00:58:24).
- **Repaso de la matriz de confusión y métricas asociadas**: La matriz de confusión, para el caso de dos clases, muestra los valores predichos frente a los reales, lo que permite calcular los verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos (00:56:49). A partir de estos, se derivan métricas como la sensibilidad, exactitud, precisión, *recall* y F1 score (00:58:24).
- **Limitación de la curva ROC para KNN**: La curva ROC (Receiver Operating Characteristic) es una métrica útil para evaluar la calidad de un modelo. Sin embargo, no es adecuada para KNN porque este algoritmo clasifica directamente la clase de pertenencia en lugar de proporcionar una puntuación de probabilidad, que es necesaria para construir la curva ROC (00:59:40).
- **Limitaciones de la Curva ROC con KNN**: El modelo K vecinos más cercanos (KNN) no genera una salida probabilística, sino que clasifica los puntos de forma categórica (por ejemplo, "es verde" o "es magenta"), lo que hace que el concepto de la curva ROC no tenga sentido para su evaluación. Esto se debe a que KNN asigna una clase directamente en lugar de una probabilidad de pertenencia a una clase (01:01:06).
- **Ejemplo de Clasificación con KNN y Regresión Logística de Base**: El clasificador KNN se demostró utilizando un conjunto de datos CSV simple que incluye el balance de tarjeta de crédito, los ingresos y si la persona es estudiante o no, para predecir si cumplieron con el pago (01:02:20). Primero se estableció un modelo de regresión logística como línea de base, y su matriz de confusión inicial mostró 324 casos donde la etiqueta real era cero pero el modelo predijo uno, lo que indica errores que el modelo idealmente debería minimizar (01:03:46). Las métricas de este modelo de regresión logística inicial mostraron una precisión muy baja, de 0.19 (01:06:04).

- **Entrenamiento y Evaluación del Clasificador KNN**: El clasificador KNN se entrenó utilizando la función `KNeighborsClassifier` de Scikit-learn, inicialmente configurado con 23 vecinos y la distancia euclidiana (Minkowski con P=2) (01:06:04). La matriz de confusión resultante para el KNN mostró una mejora respecto al modelo de regresión logística base. Específicamente, la precisión para el KNN fue de 0.73, lo que representa una mejora significativa en comparación con la precisión anterior (01:07:15).
- **Importancia de la Normalización en KNN**: Se discutió que idealmente se debería normalizar o estandarizar los datos antes de entrenar un modelo KNN. Esto se debe a que si una variable tiene una magnitud de valores mucho mayor que las otras, su peso en el cálculo de la distancia será desproporcionadamente grande, lo que podría afectar el cálculo de las distancias (01:08:32).
- **Introducción a los Métodos de Ajuste de Hiperparámetros**: Los hiperparámetros son valores que caracterizan un modelo y deben definirse antes de su entrenamiento, y estos valores no cambian durante el proceso de entrenamiento. La elección de los hiperparámetros impacta directamente en el rendimiento del modelo, y el hiperparámetro óptimo es dependiente del conjunto de datos específico que se esté utilizando (01:19:12). El proceso para elegir estos hiperparámetros se denomina ajuste u optimización de hiperparámetros, y busca el conjunto que maximice una métrica de rendimiento elegida, como el F1 score (01:20:24).
- **Métodos de Búsqueda de Hiperparámetros (Grid Search y Random Search)**: Se presentaron dos métodos comunes de búsqueda: la búsqueda en grilla (`Grid Search`) y la búsqueda aleatoria (`Randomized Search`). El *Grid Search* implica probar exhaustivamente todas las combinaciones posibles dentro de un espacio de parámetros definido, lo cual puede ser muy costoso computacionalmente y no ser viable si el espacio de posibilidades no es finito (01:25:26). La *Randomized Search* es un método más rápido y menos costoso que selecciona combinaciones aleatorias de hiperparámetros, aunque existe la desventaja de que podría no encontrar la solución óptima si esta no es seleccionada (01:26:42).
- **Implementación de Búsqueda en Grilla y Resultados Óptimos**: Se implementó el `Grid Search CV` de Scikit-learn, definiendo una grilla de 1,800 combinaciones posibles de vecinos, pesos y potencias de distancia, solicitando que el método buscara el conjunto que maximizara el F1 score (01:29:14) (01:33:55). El método determinó que la mejor combinación fue 10 vecinos, un valor P de 15 para la fórmula de Minkowski y pesos calculados basados en la distancia (no uniformes) (01:30:29). Se debe evaluar si las

métricas obtenidas con estos parámetros óptimos mejoraron con respecto a las pruebas iniciales (01:32:07).

- **Implementación de Búsqueda Aleatoria y Resultados**: Se implementó la búsqueda aleatoria con `Randomized Search CV`, que definió un espacio de búsqueda mucho más amplio pero se limitó a probar aleatoriamente 100 combinaciones de la grilla definida, usando F1 score como métrica de comparación (01:35:21). Esta búsqueda arrojó un resultado óptimo diferente al de la búsqueda en grilla: un valor P de 95 y 10 vecinos, a pesar de que el rango de prueba para vecinos era de hasta 100 (01:36:42). El uso de validación cruzada en ambos métodos ayuda a prevenir el *overfitting* de los hiperparámetros (01:38:13).
- **Búsqueda con Gradiente y Limitaciones**: Una alternativa a los métodos de grilla y aleatorio es la búsqueda utilizando métodos basados en gradiente, donde el proceso comienza en un punto de la grilla y se mueve hacia combinaciones adyacentes que ofrezcan mejores resultados. La desventaja principal de este método es el riesgo de converger en un máximo o mínimo local, perdiendo la verdadera solución óptima global (01:42:48).
- **Introducción a la Búsqueda Bayesiana**: La búsqueda bayesiana busca optimizar una función objetivo desconocida, costosa de evaluar y cuya forma no se asume fija, mediante la construcción de un modelo probabilístico (01:44:21). La función objetivo en este contexto recibe combinaciones de hiperparámetros (como el número de vecinos) y devuelve una métrica de rendimiento (como la precisión o F1 score) (01:45:38). Este método ayuda a encontrar la función de rendimiento para determinar el valor máximo, lo cual indica la mejor combinación de hiperparámetros (01:47:01).
- **Conceptos de Exploración y Explotación en la Búsqueda Bayesiana**: La búsqueda bayesiana utiliza el modelo probabilístico para decidir dónde muestrear la próxima combinación de hiperparámetros, equilibrando dos estrategias: *explotar* (buscar en zonas que ya han dado buenos resultados con la esperanza de mejorarlos) y *explorar* (buscar en zonas inciertas donde la varianza del modelo probabilístico es alta) (01:48:13). La búsqueda itera hasta que se encuentra un máximo satisfactorio sin la necesidad de probar todas las combinaciones posibles (01:51:40).
- **Componentes y Función de Adquisición en el Modelo Bayesiano**: Los dos componentes principales de la optimización bayesiana son el modelo probabilístico (por ejemplo, un proceso gaussiano) y la función de adquisición. La función de adquisición, como el *Expected Improvement*, sugiere dónde buscar en la siguiente iteración para equilibrar la exploración y

la explotación (01:52:49) (01:55:29). Al ajustar un parámetro dentro de esta función, se puede dar más peso a la exploración (enfocándose en áreas con gran incertidumbre/varianza) o a la explotación (enfocándose en la mejora del mejor valor actual) (01:59:09).

- **Descripción general del proceso de búsqueda de hiperparámetros:**: Ise posgrados describió el proceso de búsqueda iterativa de hiperparámetros, comenzando con cinco vecinos elegidos al azar y su respectiva precisión, para luego entrar en un bucle donde se utiliza la función *expected improvement* para decidir entre explorar o explotar (02:00:29). Este proceso evalúa y añade nuevos puntos a la lista de puntos experimentados en cada iteración, volviendo a entrenar el modelo en el punto de mayor valor hasta completar un número predefinido de iteraciones (en este caso, 15), y quedándose con el mejor resultado, que fue de 29 vecinos (02:01:47).
- **Aclaración del entrenamiento por iteración:**: Martin Amagliani preguntó si se evalúa un punto nuevo o un conjunto de puntos nuevos en cada iteración, a lo que Ise posgrados aclaró que el modelo probabilístico (*expected improvement*) se evalúa para todos los candidatos, pero se elige solo el mejor candidato para entrenar el modelo K-Nearest Neighbors (KNN) y añadirlo como un punto real a la lista de puntos experimentados. Este punto real se agrega al conjunto de datos antes de la siguiente vuelta del bucle (02:03:05) (02:08:26).
- **Discusión sobre el ajuste de la función probabilística:**: Gabriel Quiroga y Ise posgrados discutieron cómo el modelo probabilístico puede ajustarse sin reevaluar el KNN para todos los puntos en cada iteración (02:04:26). Facundo Lucianna intervino para explicar que la función real está acotada por métricas como la precisión (máximo uno, mínimo cero) y la suposición de continuidad, lo que evita la estimación de picos infinitos o discontinuidades, permitiendo al modelo probabilístico estimar la curva verdadera (02:05:55). Se confirmó que solo el mejor punto elegido por el modelo probabilístico es el que se usa para el entrenamiento real del KNN (02:07:07).
- **Efecto del número de iteraciones en la mejora del puntaje:**: Lucia T. Capon Paul preguntó si el *scoring* siempre mejora con las iteraciones. Ise posgrados explicó que el puntaje de precisión puede mejorar o no en cada iteración, y el sistema se queda con el mejor resultado que se haya encontrado hasta ese momento. Facundo Lucianna comparó la estimación con intentar adivinar un número en una lotería no aleatoria, señalando que la estimación no garantiza una mejora segura (02:10:23).

- **Propósito y límite de las iteraciones en la búsqueda:**: La discusión abordó el número de iteraciones y su relación con la eficiencia del método, concluyendo que el método de búsqueda bayesiana se utiliza para ahorrar el tiempo que requeriría una búsqueda exhaustiva o en cuadrícula. Facundo Lucianna añadió que estos métodos son especialmente útiles en modelos grandes donde el entrenamiento puede demorar mucho tiempo (por ejemplo, un día), limitando el número finito de pruebas posibles (02:11:25).
- **Segundo ejemplo de búsqueda con múltiples hiperparámetros (Ejemplo Artesanal):**: Ise posgrados presentó un segundo ejemplo de búsqueda de hiperparámetros, que incluye la cantidad de vecinos, los pesos y la métrica a utilizar, usando una función objetivo F1 Score (02:14:02). Este ejemplo implementa un enfoque "casero y artesanal" donde en cada iteración solo se cambia aleatoriamente uno de los tres parámetros para moverse ligeramente en el espacio de posibilidades y se evalúa el nuevo *score* (02:15:24). La mejor combinación encontrada fue de 11 vecinos con distancia euclidiana, lo que resultó en un F1 Score de 0.39 (02:16:38).
- **Discusión sobre la aleatoriedad en el ejemplo artesanal:**: Gabriel Quiroga preguntó por qué la misma combinación de hiperparámetros (K=11) se repetía varias veces en las iteraciones (02:18:11). Ise posgrados confirmó que esto se debe a la selección totalmente aleatoria de parámetros en este ejemplo, y si se quisiera evitar la repetición, se podría implementar un filtro en el código, similar al ejemplo anterior (02:19:16). Martin Amagliani señaló que este enfoque tiene un alto potencial para quedarse atascado en máximos locales, aunque Ise posgrados respondió que el equilibrio entre explorar y explotar ayuda a evitar obsesionarse con un único máximo local (02:20:04).
- **Introducción al Framework Optuna:**: Se presentó Optuna como un framework de búsqueda de hiperparámetros más avanzado, ideal para trabajos de mayor escala y complejidad, aunque se mostró un ejemplo sencillo para fines educativos (02:21:12). Optuna opera en dos etapas: la selección de hiperparámetros que probablemente den buenos resultados y la "poda" (pruning) de subconjuntos que no conducirán a un buen resultado. Internamente, Optuna utiliza un estimador llamado Tree-structured Parzen Estimator (TPE) y una estrategia evolutiva junto con una matriz de covarianza (02:29:09).
- **Explicación del Estimador Tree-structured Parzen (TPE) de Optuna:**: El TPE es un modelo probabilístico que construye dos distribuciones de probabilidad separadas (H para resultados buenos o "high" y L para resultados malos o "low"), basadas en un umbral predefinido en la función objetivo (02:30:47). La función de adquisición de Optuna elige muestras que maximizan el cociente

de la probabilidad de resultados buenos dividida por la probabilidad de resultados malos ($P(H) / P(L)$) (02:33:27). Esto permite a Optuna enfocarse en las áreas del espacio de búsqueda donde es más probable encontrar buenos resultados, equilibrando la exploración de zonas nuevas y la explotación de zonas ya conocidas como prometedoras (02:34:45).

- **Uso práctico de Optuna y ventajas:**: En la práctica, se inicializa un *estudio* de Optuna, se define la función objetivo (que incluye el espacio de búsqueda) y luego se llama a la función de optimización, especificando un número de pruebas (por ejemplo, 1000). Optuna realiza la búsqueda y devuelve la mejor combinación de parámetros, que en el ejemplo fue 10 vecinos (02:37:24). Ise posgrados destacó que la principal ventaja de Optuna es la practicidad que ofrece para modelos con muchos hiperparámetros y un tiempo de ejecución largo, ya que permite desentenderse de la búsqueda manual y obtener resultados sin supervisión constante (02:38:56).
- **Recomendaciones sobre cuándo usar diferentes enfoques de búsqueda:**: Lucia T. Capon Paul preguntó cuándo se debería usar un algoritmo de búsqueda u otro (por ejemplo, Optuna frente a los métodos bayesianos anteriores) (02:41:38). Ise posgrados aconsejó que si el espacio de búsqueda es acotado y no hay grandes exigencias en las métricas, un enfoque simple o manual puede ser suficiente. Sin embargo, si el espacio de búsqueda es muy grande y se desconoce dónde se encuentran los parámetros óptimos, el enfoque bayesiano resultará más conveniente para ahorrar tiempo (02:42:46).
- **Consideraciones finales y ejercicios de práctica:**: Se mencionó que los ejemplos se realizaron con KNN, pero que las técnicas de búsqueda de hiperparámetros son aplicables a cualquier modelo futuro (02:41:38). Ise posgrados animó a los participantes a comenzar a practicar con KNN utilizando sus propios conjuntos de datos para el trabajo grupal, con el fin de avanzar en las tareas y prepararse para los modelos que se verán en las próximas clases (02:42:46).

Pasos siguientes recomendados

No se encontraron próximos pasos sugeridos para esta reunión.

Revisa las notas de Gemini para asegurarte de que sean correctas. Obtén consejos y descubre cómo toma notas Gemini

Danos tu opinión sobre el uso de Gemini para tomar notas en una breve encuesta.

📖 Transcripción

12 mar 2026

Aprendizaje de Máquina (2/8) - a242b25 - Transcripción

00:00:00

Gabriela Sol Salazar: Buenas tardes,
lse posgrados: Hola,
Gabriel Quiroga: ¿Qué tal?
lse posgrados: Hola, ¿qué tal?
Cesar Orellana: Buenas tardes,
lse posgrados: Hola, César. Hola,
Facundo Lucianna: Buenas,
lse posgrados: ¿cómo?
Facundo Lucianna: buenas.
lse posgrados: Hola a todas, todos.
Cristian A. Aballay: Buenas tardes,
Jose Miguel Silva: Hola,
lse posgrados: Antes que nada y antes que arranquemos con la clase y antes que me olvide, eh, qué cantidad de gente que ya completó la los grupos, eh, impresionante. No se olviden, está la planillita ahí disponible para que no se olviden porque dijimos clase tres como para poner una fecha, no es que si no completan ese día el grupo desaprueban la materia, pero la idea es que lo tengan definido. Si perdieron el link, se los paso ahora por el chat. Esperen acá. Ahí empezaron a entrar, así que lo tienen al link. Ahí está. Acuérdense ponen quiénes son los integrantes del grupo y el eh el tema o el dataset que eligieron. El dataset pueden poner el nombre y el link a la fuente de datos como para que tengamos idea de dónde lo sacaron.

00:08:29

lse posgrados: Si es un dataset que no es conocido, no tenemos idea de dónde salió. Bueno, básicamente eso. No se distraigan ahora. Ahora vamos a la clase, pero era para que no se olviden. ¿Está bien? Bueno, dicho eso, estamos para arrancar. Ya resolví mi problema de la de compartir la pantalla que el otro día no me andaba. Por suerte, eso ya está resuelto. Compartir. Bueno, vamos a arrancar la clase de hoy. Vamos a ver eh clasificador KNN y optimización de hiperparámetros. Son dos temas

distintos. Primero un clasificador y después lo que es optimización de hiperparámetros. es algo que va a ser aplicable tanto para lo que veamos de KNN como para lo que veamos en las próximas clases. Sí, como que dividida en dos partes la clase de hoy. Primero hacemos un como siempre un repaso rápido de va breve, no rápido breve de lo que vimos la clase pasada que fue bastante introductorio, la definición de de qué es aprendizaje de máquina y los tipos de aprendizaje. Un poco para repasar así a grandes rasgos la clasificación de eh tipos de aprendizaje.

00:09:57

Ise posgrados: Tenemos el aprendizaje supervisado, que ¿qué significa? tenemos un dataset con un montón de de features o o columnas o características y una etiqueta. Con ese dataset nosotros entrenamos un modelo para que el modelo descubra patrones y después cuando nosotros le damos una observación nueva, el modelo va a ser capaz de predecir cuál es su etiqueta. Eso es básicamente el aprendizaje supervisado y tenemos dos grandes grupos, la regresión cuando estamos prediciendo un número básicamente y la clasificación cuando estamos prediciendo una una clase, cuando la etiqueta es una clase. Después tenemos el no supervisado, que es agrupar sin una etiqueta predefinida. Le damos un dataset y le decimos, "Bueno, con todo esto, fíjate si me lo puedes agrupar en dos, en tres, en cuatro o la cantidad que yo le diga de grupos. Eso sería no supervisado, no hay una etiqueta predefinida ni tampoco reglas ni nada. le digo al algoritmo, o sea, al a la máquina le digo, "Tomá, fíjate si puedes encontrar grupos acá, como sea." Y reducción de dimensionalidad es un concepto que se ve, nosotros lo vimos en análisis de datos, se ve en eh tiene incidencia también en lo que es el aprendizaje no supervisado, o sea, se puede usar para para aprendizaje no supervisado.

00:11:20

Ise posgrados: Y por último tenemos el aprendizaje profundo que tiene que ver básicamente con las redes neuronales y eso es totalmente está fuera del alcance de esta materia. Lo ven en aprendizaje eh justamente la materia que se llama aprendizaje profundo. Ahí van a eh ver en detalle este tipo de de aprendizaje. Nosotros acá en la materia vamos a ver principalmente algoritmos de aprendizaje supervisado de clasificación. es lo que vamos a ver más que nada en las en cinco clases, creo que son o seis, no me acuerdo, cinco creo. Y después vamos a ver una clase específica de aprendizaje no supervisado. Eso para que se ubiquen más o

menos. Tengo acá abierta la esto acá, no sé si vieron este PDF que está en la en el repositorio que tiene un arbolito de distintos distintas técnicas de aprendizaje. Lo que les decía recién es esto. Nosotros vamos a ver acá en la materia principalmente estos métodos, no es no exactamente esta lista, pero bueno, principalmente estos eh métodos de aprendizaje en la clase, creo que es la seis, pero no me acuerdo exactamente qué número de clase es. Vamos a ver estos algoritmos de aprendizaje no supervisado y aprendizaje por refuerzo es totalmente ajeno a lo que a lo que vamos a ver nosotros acá. Eso solo para que tengan un poco una idea del panorama de dónde estamos parados acá.

00:12:38

Ise posgrados: KNN es el algoritmo que vamos a ver hoy. Y ahora se me perdió el se me perdió el el acá. Está bueno, para que tengamos así hablemos todo el mismo el mismo idioma, ¿qué tenemos? Las características que le llamamos o features o son las distintas variables, las columnas de nuestro dataset. En este ejemplo, bueno, son personas y salarios. Tenemos la columna que es la etiqueta o label, que es lo que vamos a querer predecir en este caso que tenemos valores, sería un ejemplo de regresión. Y cada una de las filas de nuestro datete es lo que le vamos a llamar observación. Esto solo para que nos ubiquemos y hablemos todos la misma terminología. Sí, independientemente de qué algoritmo estemos usando o implementando, vamos a tener el concepto de hiperparámetros, que son parámetros que son independientes de los datos, son parámetros que tenemos que definir antes de entrenar un modelo. Hoy vamos a ver el algoritmo de KNN que tiene un parámetro principal que es el valor de K. Ahora vamos a ver qué es K. Y a veces los modelos tienen así un solo hiperparámetro, dos hiperparámetros, pero por ejemplo en redes neuronales van a ver que tienen eh un montón de parámetros, unos cuantos parámetros, que son básicamente valores que vamos a tener que definir antes de entrenar el modelo.

00:14:10

Ise posgrados: Y hoy la segunda parte de la clase vamos a hablar mucho de los hiperparámetros. Y por último, acá simplemente a modo de definición, generalización le llamamos a la capacidad de cualquiera de estos modelos de hacer predicciones e nuevas con datos nuevos, pero hacer predicciones buenas, o sea, ser capaz de predecir bien cuando yo le doy un dato que nunca vio. Eso es lo que eh nombramos así, generalización. Y por último tenemos este cuadrito. Eh, si recuerdan

en análisis de datos habíamos visto otro no exactamente igual, medio parecido, pero con la misma idea de cómo vamos a trabajar con nuestros datos. Esto resume el cuadrito que vimos antes. Tenemos los datos y la etiqueta. Con estos datos lo que hacemos primero que nada, además de limpiarlos, eh hacer codificación, bueno, todo lo que se le hace a los datos y que lo vimos con mucho detalle en análisis de datos, después de hacer todo eso eh y antes de entrenar vamos a tener que tener hacer esta separación, perdón, la separación es eh antes de hacer todo ese preprozamiento. separamos en entrenamiento y testing. Hacemos toda la la limpieza, codificación, normalización, todo lo que querramos hacerle o necesiten eh nuestros datos.

00:15:28

Ise posgrados: Y después que los datos ya están listos, los datos de testing los guardamos a un costadito y con los de entrenamiento entrenamos el modelo, el modelo que sea o los modelos que querramos entrenar. Y cuando el modelo ya está entrenado, entonces ahí sí vamos y buscamos los datos que habíamos guardado, los de testing, y evaluamos. Vemos que también se comporta ese modelo con estos otros datos que al entrenarlo el modelo no tenía ni idea que existían. Yo al evaluar con datos que el modelo nunca vio, voy a poder tener una medida certera de si mi modelo me sirve o no me sirve. Y una vez que yo evalué y ya estoy contenta con mi con mi modelo, entonces ahí lo voy a usar para predecir. Voy a traer nuevos datos y voy a predecir que qué significa predecir encontrar la etiqueta esa nueva para los datos eh que yo le estoy pasando al modelo. Ese es como el ciclo a grandes rasgos. No les estoy dando ninguna ninguna noticia. Es todo lo que ustedes ya se supone que ya entienden todo este ciclo y es solo a modo de repaso. ¿Alguna pregunta con todo esto? Estamos bien. Bueno. Bueno, entonces ahora sí vamos a meternos en el en el primer clasificador que vamos a ver, que es el clasificador KNN.

00:16:53

Ise posgrados: KNN es eh la sigla de vecinos más cercanos en inglés, Nurse neighbor. K es el número de vecinos. La letra K es un número, es un parámetro que un hiperparámetro de nuestro modelo. Este algoritmo lo que hace es utilizar la proximidad de vecinos. Vecinos son otras observaciones. Usa la proximidad de los vecinos para clasificar. Por ejemplo, imagínense que yo tengo eh en 2D, que siempre es más fácil explicarlo con dos dimensiones, tengo dos variables, dos features en mi dataset, x1 y x2. Y acá tengo graficadas todas mis observaciones y el color me dice

cuál es la etiqueta, ¿no? Yo tengo una clasificación, tengo dos clases en este ejemplo, la clase verde y la clase magenta. Entonces están acá dibujaditos y el color me está indicando a qué clase pertenece cada uno de esos puntitos o observaciones. Entonces, si yo traigo una observación nueva, que es este punto gris, y lo quiero clasificar, la idea de este algoritmo es que yo miro los vecinos. Intuitivamente los vecinos son los que están cerca. Miro los vecinos y en base a eso digo, "Ah, sí, es verde. La etiqueta va a ser verde o la etiqueta va a ser magenta.

00:18:07

lse posgrados: Yo tengo que saber cuántos vecinos mirar qué son los vecinos. Este que está acá o todos estos son vecinos. Eso es algo que yo tengo que saber de entrada. Yo digo que K, que K es el número de vecinos, K es igual a 3. Entonces, voy a mirar tres vecinos. Eso es lo que hago acá. me fijo cuáles son los tres que están más cerca, o sea, los tres vecinos que están más cerca y son estos tres. Y por un sistema de voto digo, bueno, si tengo si mis tres vecinos son uno magenta y dos verdes, mi puntito seguramente es verde y lo clasifico como verde. Le pongo etiqueta verde. Así funciona este algoritmo, este modelo.
Lucia T. Capon Paul: Eh, perdón. ¿Y clasifica en dos distintos o porque estaba pensando qué pasa si esos tres tres vecinos que estás analizando están muy lejos? que hay que definir que es lejos, ¿no?
lse posgrados: Hay que Exactamente eso, a eso vamos ahora vamos a ver qué es lejos y qué es cerca, pero independientemente si es lejos o cerca, si yo necesito tres vecinos, si los más cerca están reljos, los voy a ir a buscar. O sea,

00:19:06

Lucia T. Capon Paul: Listo. Gracias.
lse posgrados: sí, sí, no, no es que hay un mínimo y si ahí no hay nada,
Alejandro Valle: Yeah.
lse posgrados: no lo clasifico. Amplío mi lugar hasta que mi espacio hasta que aparecen los tres, los tres que están más cerca. Ahora enseguida vamos a ver qué es un vecino y qué es cerca y qué es lejos. Eh, sí, Alejandro.
Alejandro Valle: Este algoritmo está basado en regresión logística
lse posgrados: No, no es un algoritmo diferente.
Alejandro Valle: Oh.
lse posgrados: Un algoritmo diferente eh a lo que ya conocen. Ahora lo vamos a ver en detalle cómo funciona. Una cosa a tener en cuenta es que el número de vecinos

que uso, el número K, voy a tratar que sea siempre impar para para lograr desempates. Porque si yo dijera, voy a trabajar con cuatro vecinos y resulta que hay dos verdes y dos magentas, entonces me quedo ahí eh recalculando, no sé cómo clasificarlo. Entonces tratamos de que sea siempre impar para poder desempatar. En este caso, tengo dos y uno. Bueno, es verde. Y ahora, ¿a quién se le ocurrió que porque yo esté acá y todos los que están alrededor mío son verdes, yo voy a ser verdes y yo podría ser de otro color?

00:20:16

lse posgrados: O sea, ¿a quién se le ocurrió que mis vecinos sean verdes eso significa que yo sea verde? Eso está inspirado, bueno, la vida misma, ¿no? Imagínense acá, no hace falta imaginarse, esos son casos reales. Acá tenemos un pedacito de un mapa del noreste de la Argentina donde están con banderitas dibujadas eh colonias de inmigraciones establecidas acá en la provincia. Entonces, por ejemplo, si yo me paro acá, ¿no? Acá en el se ve el cursor, sí, me paro acá y veo banderitas escandinavas, ¿no? Acá Noruega, Suecia, Finlandia. Si yo me voy ahí y agarro una persona random, ¿no? Agarro una persona random de ese lugar, ¿qué es más probable que esa persona tenga ascendencia o pariente o relaciones con un escandinavo o con un japonés? ¿Qué es más probable? No, que es seguro. ¿Qué es lo más probable?
Lucia T. Capon Paul: Sí, un escandinado.
lse posgrados: es más probable, capaz que no es seguro, me puedo equivocar, pero es mucho más probable que sea un escandinhoa, que sea un japonés. Entonces, en eso se basa.

00:21:20

lse posgrados: Puede ser que haya un japonés así acá. Sí, claro que puede haber,
Lucia T. Capon Paul: H
lse posgrados: pero es mucho más probable que el que yo agarre acá se parezca mucho a todos los otros que viven ahí. Entonces, en eso se basa el algoritmo. Acá lo mismo en un mapa de eh población de Estados Unidos vemos, bueno, hay muchos tipos de muchos orígenes, ¿no?, de inmigración, pero el que se nota por ahí más claro y más cercano a nosotros para entenderlo es todo el
Lucia T. Capon Paul: He.
lse posgrados: borde este rosado que son los mexicanos. ¿Y por qué? porque están al lado de México. Tiene más sentido que yo cualquier persona que encuentre acá

tenga ascendencia o relación o origen de México, eh es más probable eso a que sea una persona con ascendencia alemana, por ejemplo. Bueno, se basa en eso y nuevamente no es que sí o sí, si yo lo encontré ahí va a ser mexicano o si yo lo encontré acá va a ser escandinavo. No es una regla así exacta, pero es bastante probable que yo le pegue, digamos, si si razono de esa manera. En eso se basa el algoritmo. Pero ahora queda, como decía Lucía, quedan las dudas.

00:22:28

Ise posgrados: Bueno, ¿qué es un vecino? Porque acá yo lo miro en dos dimensiones y y señalo, marco con una regla y me fijo cuál es el más cercano. Pero en muchas dimensiones, ¿qué es un vecino? ¿Qué significa que una observación esté cerca de otra? y además eh qué es cerca y qué es lejos, ¿no? Bueno, eso lo vamos a definir ahora. Y hay muchas maneras de definir distancia. Lo vamos a definir para ejemplificar con dos dimensiones porque es lo más fácil, porque lo podemos graficar, pero esto eh aplica a todas las dimensiones, a la cantidad de columnas que nosotros querramos. es exactamente lo mismo, solo que en dos dimensiones es más fácil de verlo. Y la primera forma de medir distancia, ya se se la habrán imaginado, la vimos ahí sin calcular nada. ¿Cómo sería? ¿La más obvia o la más intuitiva? Si yo tengo dos dos puntos en en un plano,
Lucia T. Capon Paul: el largo de la recta que las une,
Ise posgrados: la recta que las une, eso lo hacemos con el cálculo de la distancia euclidiana, Pitágoras, que lo vimos en la escuela. Yo tengo dos puntos y hago la diferencia acá en el eje de las X^2AD, la diferencia en el eje de la Y al cuadrado y raíz cuadrada y ya está.

00:23:43

Ise posgrados: Esa es la distancia, la recta, la distancia mínima entre dos puntos. Eso me sirve para cuando tengo dos columnas, pero cuando tengo n columnas voy haciendo las diferencias una a una raíz cuadrada y es lo mismo. Y me da una distancia entre dos observaciones, entre dos observaciones de mi dataset. Y esta es una de las distancias más utilizadas, uno de los métodos de distancia más utilizada. Es la más conocida y una de las más utilizadas, pero no es la única. Hay un montón de métricas de distancia. ¿Se les ocurre otra para estos mismos dos puntos? Otra medida que yo pueda decir la distancia entre x e y la calculo de esta otra manera.
Gabriela Sol Salazar: podría hacer las otras los otros dos catetos del triángulo, digamos, otro camino. M.

lse posgrados: otro camino. Esa sería otra forma, calcular otro camino. En vez de hacer la línea recta, me vengo caminando derechito. Vengo derecho caminando por acá y después subo caminando derecho por acá. Y en este ejemplo sería 1 2 3 4 5 sería la distancia. Esa es otra otro método de distancia. Y ese método se llama distancia de Manhattan.

00:25:00

lse posgrados: Imagínense que estoy en una ciudad, este es un plano de la plata, la ciudad de la Plata, que tiene una cuadrícula bastante eh precisa. Está diagramada a propósito. Así. Imagínense que ustedes son personas caminando y tienen que ir desde este punto hasta este punto. Bueno, si hay una diagonal pueden ir derecho, pero si tienen que ir en otro lugar que no hay diagonales desde acá hasta acá no caminan por arriba de las casas, caminan por las cuadras, o sea, caminan en ángulos rectos, ¿no? Entonces esa distancia que ustedes caminan sería la distancia de Manhattan. Van caminando por las cuadras. Por eso tiene otros nombres esta distancia también. Acá tiene otros nombres equivalentes. Distancia taxis, distancia de cuadras. Eh, y tenía otros nombres que no están acá, pero se la conoce con varios nombres, pero principalmente es la distancia de Manhattan. Se usa más que nada cuando eh los datos pueden, o sea, cuando tengo los datos e los datos no tienen relaciones lineales entre ellos, esta distancia a veces puede ser más conveniente. Es otra, es otra y se usa también eh mucho, pero hay más. Ahora vemos más.

00:26:09

lse posgrados: Bueno, la formulita de la distancia Manhattan es parecida a la de recién, pero sin elevar al cuadrado ni raíz cuadrada, ¿no? Hago la resta de las de las x y la resta de las de las y o tomo el valor absoluto y esa es la la suma de esas medidas es la distancia. Otra media distancia es la distancia de Chevf o módulo infinito y consiste en tomar la máxima de esas distancias. ¿Vieron la de Manhattan? Que yo me muevo así y así. Bueno, en este caso tomo de las dos direcciones tomo la máxima y me quedo con esa. Y acá hay una fórmula generalizada de las que vimos recién, que es tomo la diferencia en cada en cada eje, en cada dimensión, tomo la diferencia, lo elevo a la potencia P y después toda la suma le saco la raíz P, o sea, elevo a la 1 dividido P. es lo mismo, o sea, es la generalización de las métricas anteriores. Y en este dibujito me compara distintas métricas, por ejemplo, P = 2 es la euclidiana, que si se fijan es este círculo celeste. No sé si alcanza a ver el círculo

celeste son puntos que están a la misma distancia del punto central calculados con la distancia euclidiana.

00:27:32

Ise posgrados: Si se fijan, es, o sea, es intuitivo. Yo tengo un círculo y de acá a acá es la misma distancia que de acá a acá, que de acá a acá, o sea, a cualquier punto del círculo celeste, si lo calculo con la distancia, la distancia es exactamente la misma. Y con las otras métricas, por ejemplo, acá P1 es Manhattan, este cuadrado girado. Si se fijan, la distancia de acá a acá, calculado con el la fórmula de Manhattan, es lo mismo que la distancia de acá a acá y de acá a acá. Bueno, esa es la idea de todas estas figuritas. En las en el repositorio hay una notebook que tiene esto ejemplificado con datos ficticios. Hay más distancias, más métodos de distancia. Está la distancia coseno que donde se usa principalmente lo van a ver en procesamiento de lenguaje. Es muy común de usar distancia coseno cuando se trabaja con con embedings y lo que mide es la similitud. Hay un índice de similitud entre dos vectores. O sea, si dos vectores están juntos o mejor dicho apuntando hacia el mismo lado, son iguales. A medida que se van separando esa esa ese índice de similitud se va haciendo más chiquitito, es decir, que son más están más distantes.

00:28:53

Ise posgrados: O sea, la similitud es inversamente proporcional a la distancia. Acá no importa eh la distancia de los de los de los puntos, sino que importa eh la magnitud de este ángulo. Acá tengo la fórmula de la similitud coseno y la distancia es 1 menos la similitud. Es decir, que cuanto más parecidos son, más chiquita es la distancia. Y acá no importa si el vector es es largo, chiquito, o sea, la magnitud del vector no importa, importa la la separación y la Sí, la separación. ¿Cuánto se separan las direcciones, no? Hacia dónde apuntan. Cuanto más diferentes sean, la distancia se considera mayor.
Cesar Orellana: O sea, sería el ángulo
Ise posgrados: El ángulo, sí, el ángulo me determina si es más grande el ángulo, es mayor la distancia. Bueno, acá hay otra distancia que yo realmente nunca la vi aplicada, pero así como esta que les estoy mostrando, quizás las primeras son las más usadas, pero hay muchas más que las que les estamos mostrando acá. Esto es como una distancia de Manhattan ponderada. Bueno, es una variante. Y vieron que todas estas cosas que vimos hasta acá, estas distancias son numéricas, ¿no?

00:30:08

Ise posgrados: Si yo tengo observaciones numéricas, en el caso que tenga observaciones con valores binarios, o sea, ceros o unos, tengo acá dos distancias más. Una es la distancia de Shakard y la otra es la distancia de hamming. Y esto es así. La de Shakar es la intersección de las observaciones dividido la unión. Supónganse que tienen acá dos observaciones, X e Y. Y esto que está acá son todas las eh las columnas que tiene mi dataset. Tiene 4, 5, 6, 7, ocho columnas con ceros y unos. En todos los casos que tengo un uno, por ejemplo, acá y acá, la intersección es uno y si no es cero. Y cuando tengo unos y ceros, la unión es uno. Y si tengo cero, la unión es cero. Si yo hago la intersección dividido la unión, me da este índice de que es 2/5 y la distancia es 1 menos este valor, es decir, 3/5. Entonces, si todos fueran 1 1 1 1 1 1 1 1 1 1, 1, índice de shakar sería 5 sobre 5 y la distancia sería 1 menos eso sería cer.

00:31:23

Ise posgrados: Sí, la distancia me mide qué tan distintos son eh uno a uno estas estos valores binarios. Y después tenemos la distancia de Jamen, que simplemente cuenta en cuántos lugares son distintas. Por ejemplo, acá son iguales, son iguales, acá son distintos, acá son iguales, acá son distintos y acá son distintos. en tres de las columnas son distintos, entonces la distancia es tres. Y acá tenemos una distancia que lo que hace es combina cuando tengo datos numéricos y categóricos. Cuando tengo numéricos, es decir, yo tengo columnas mezcladas, ¿no? Numéricas y categóricas. En cada columna numérica yo calculo la distancia usando Manhattan ponderada. Y en cada columna categórica le asigno uno o cero según si es igual el valor o es distinto. Es como muy generalizada esta comparación porque categórico, qué sé yo, no sé, a mí me gustaría medir qué tan categóricos, capaz que son un poco parecidos, muy parecidos, muy distintos, no sé, pero acá es 01. Pero bueno, es una forma de comparar dos observaciones donde tengo mezcla de de tipos de datos. Como les decía, no es exhaustiva la lista esa de métricas.

00:32:51

Ise posgrados: Hay un montón más. Estas son las más usadas o las más conocidas. Sobre todo creo que lejos, lejos está la Euclidiana y Manhattan. Bueno, ecco coseno

es para casos muy particulares que se usa, pero eh después hay otras y ustedes incluso se pueden inventar medidas de distancia si les ocurriera otra cosa. Lo importante es que una vez que definieron qué métrica de distancia van a usar, usen siempre la misma para entrenar y para comparar y todo, porque si no después estarían comparando peras con bananas. O sea, una vez que definieron, voy a usar euclidiana, usen euclidiana para comparar distintas ejecuciones, por ejemplo, un mismo modelo. Eso sí.
Gabriela Sol Salazar: Una consulta.
lse posgrados: Sí.
Gabriela Sol Salazar: Em, ¿se hace algún trabajo especial? Me imagino que por ahí alguna escalada o algo cuando tenés eh datos con escalas distintas o por ahí los usas para un grupo, un subconjunto y no para todo. No sé cómo.
lse posgrados: Es que justamente, claro, eso como vimos,
Gabriela Sol Salazar: No.
lse posgrados: como vimos en la materia anterior, es importante que los datos estén escalados para este tipo de modelos, porque si yo no los escalo, la medida de distancia le va a dar mucho más peso a unas a unas columnas que a otras, salvo que yo quiera eso, ¿no?

00:34:02

lse posgrados: Pero si yo tengo columnas que tiene, por ejemplo, edad y salario,
Gabriela Sol Salazar: Ok.
lse posgrados: la edad va a ser un número que se mueva entre, no sé, entre 20 y 60 y el salario se va a mover en 300,000 a 5 millones. Cuando yo calcule la distancia, va a pesar un montón el salario en ese en ese cálculo de distancia y la edad va a pasar casi desapercibida en el en el número final que yo calcule. Entonces, eh si yo ya sé que voy a usar este modelo, sí o sí debería normalizar los datos antes. Bien, entonces eh repasando, yo ya tengo la métrica de distancia que voy a usar. Por ejemplo, voy a usar euclidiana y ahora voy a definir cuántos vecinos eh voy a considerar para el el para el algoritmo. Defino el valor de K. Sí, si K es igual a 1, busco el primer vecino, el más cercano de todos, que va a ser un uno solo. El primero que encuentro es rojo en el ejemplo anterior o verde. Bueno, mi observación le pongo verde. Si digo que cae 100, busco los 100 vecinos alrededor. Bueno, 101 porque dije impar y el que más se repite asigno esa clase.

00:35:15

Ise posgrados: Acá los ejemplos los estoy haciendo con dos clases, pero no necesitan ser dos clases, pueden ser más. E bien. ¿Qué más yo tengo que poder eh definir? Bueno, el valor de K. Una de las cosas que vamos a hacer es qué uso como K, qué me conviene o qué sería mejor. Tres vecinos, 5, 25. Bueno, eso es algo que vamos a tener que definir. Algo a tener en cuenta es que si yo uso un valor de K muy chiquitito, voy a tener una varianza alta, pero un sesgo bajo. O sea, si yo uso vecinos tres, cualquier punto que se me mueva ahí en los vecinos, puede ser que ahora digo verde, dentro un ratito me fijé y digo magenta porque eh nada, tengo muy poquitos puntos para comparar. Entonces ahí eh eh puedo tener ese ese riesgo, ¿no? Si tengo un número de K más grande, ya eso es más estable. Se mueve un punto, no me mueve la aguja. La clasificación capaz termina siendo la misma. Lo de lo del número impar ya lo dijimos para evitar empates. Y algo a tener en cuenta es que este algoritmo no se entrena. ¿Por qué?

00:36:28

Ise posgrados: Porque yo lo que hago con un punto nuevo no es que le digo a un algoritmo que me prediga nada, yo voy y busco los vecinos y ahí ya tengo eh el poder de decidir a qué clase pertenece. Lo que yo sí tengo que hacer antes es calcular a ver las distancias a esos vecinos.
Lucia T. Capon Paul: Pero ahí, por ejemplo, eh vos siempre vas a estar como actualizando el último vecino que agregaste y, o sea, te quedan estáticos porque estoy pensando depende el orden en que vayan apareciendo también,
Ise posgrados: CL. Bueno, sí, claro. Vos sí, pero en general vos tenés ya precalculada la los vecinos. A ver, perdón, agarrass un punto nuevo, supe que tenés 100 observaciones,
Lucia T. Capon Paul: Sí.
Ise posgrados: agarras un punto nuevo y calculas la distancia a cada uno. Ahora vamos a ver que no es necesariamente así, pero empezamos completamente de cero. Inventamos esto recién. Bueno, ¿cómo haría? Agarro una observación nueva y calculo las 100 distancias. De este a este la distancia es uno. De este a este es 40. De este a este es cinco.

00:37:27

Ise posgrados: De este a Así a cada uno de los 100. Los ordeno del más cerca más

lejos y agarro los tres primeros. Me fijo de qué clase es y ahí le asigno.
Lucia T. Capon Paul: Claro, pero ese no te modifica los 100 que tenías, o sea,
lse posgrados: No me voy.
Lucia T. Capon Paul: como que todos los que vay
lse posgrados: Claro,
Leonardo Villalva: Ah.
lse posgrados: claro. Agarro uno nuevo,
Lucia T. Capon Paul: Ok.
lse posgrados: calculo. O sea, en teoría, ahora vamos a ver que no están así porque me muero haciendo todas esas cuentas. Estoy diciendo 100, que es re chiquitito el número. Imagínense un datascet de 1000 o de 10,000 es inviable. Pero bueno, siendo ingenuos, vamos a decir, traigo uno nuevo, calculo las 100 distancias, lo ordeno de la distancia de menor a mayor y agarro los primeros tres o cinco o lo que sea que yo haya definido como K, como K vecinos. Miro qué etiquetas tiene y agarro la que más se repite y esa es la etiqueta de mi nuevo eh de mi nuevo dato, de mi nueva observación.

00:38:18

lse posgrados: Así que el algoritmo no es que se entrena, pero sí yo tengo que e hacer ese cálculo de las distancias. Y aquí tenemos unos ejemplos con los mismos puntitos del ejemplo anterior. ¿Qué pasa si yo digo k es ig a 1? Este puntito se clasifica como verde. Si yo dijera k = 3, estos son los tres más cercanos, se clasificaría como verde. Si yo digo k = 5, este mismo puntito, resulta que ahora se clasificaría como magenta porque tengo tres vecinos magenta y dos verdes. A pesar que intuitivamente si yo miro así esto, yo digo, para mí es verde porque está cerca más cerca de los verdes que de los magenta. Entonces, también hay otra otra variante que es darle más peso, a pesar de que yo mire cinco vecinos, darle más peso a los que están más cerca, porque este verde está muchísimo más cerca que todos estos magenta. Entonces, eso sería como una variante también del algoritmo. Miro cinco vecinos, pero estos me van a pesar más, entonces quizás termino clasificándolo como verde. No son variantes. Y bueno, lo que decía recién, ¿cómo encontramos a los vecinos? La forma básica e ingenua sería, bueno, calculo todo.

00:39:41

lse posgrados: Yo tengo este nuevo celeste y para saber cuáles son sus vecinos más cercanos, calculo la distancia a esto, la distancia de esto, la distancia a esto y

así la distancia a todos y cada uno de los eh de las observaciones de mi dataset. Pero la verdad que hay que buscar otra forma más óptima porque esto se agranda el dataset y es inviable directamente. Hay varias formas de optimizar esa búsqueda de los vecinos más cercanos. Una forma es la construcción de un árbol de búsqueda que se llama Cadetri, que se basa en el concepto de que si el punto A está lejos del B y el B está cerca del C, yo ya sé que el A va a estar lejos del C y no necesito hacer esa cuenta. Yo ya asumo que el A va a estar lejos de ese punto C. En eso se basa el la construcción de este árbol. para que después yo no tenga que hacer todas las cuentas posibles. Me voy a restringir a un pedacito de mi dataset para hacer cuentas y el resto ya voy a asumir que están lejos. Ahora vamos a ver cómo funciona. Vamos a este ejemplo que está acá abajo es el mismo que está en la próxima slide, pero escrito de otra forma. Este es mi ejemplo. Tengo solamente siete puntos que están dibujados acá en dos dimensiones y tiene dos atributos que puede ser cualquier cosa, la edad y no sé los años de, no sé, los la cantidad de hermanos que tiene, no sé, lo que ustedes se les ocurra.

00:41:10

Ise posgrados: Son dos atributos de cada una de esas seis observaciones. Entonces, lo que voy a hacer es construir un árbol con estas observaciones. Estas son las que yo ya tengo, conozco y no las quiero etiquetar. O sea, la etiqueta ya la conozco, ¿no? No me estoy preocupando ahora de las etiquetas. Yo solamente estoy tratando de entender cómo hacer para construir ese árbol de búsqueda de distancias. Para empezar, agarro una muest una observación de acá random. Agarré la tres, podría haber agarrado otra, esta 54 cuada acá. Y a partir de ahí empiezo a construir un árbol. Lo que hago es una línea vertical, es decir, una línea que me divida la primer dimensión, que es el X1, me la divida en dos, en ese punto donde estoy parada. Y entonces ahora me muevo en el otro eje, me voy para arriba hasta que me choco con el primer punto y de este otro lado me voy para abajo hasta que me choco con el primer punto y trazo esas líneas horizontales. Y estos puntos van a ser las primeras ramas de ese árbol. Este 26 está acá y este 133 está acá. Y sigo haciendo lo mismo.

00:42:22

Ise posgrados: Horizontal, vertical, horizontal, vertical. Ahora me paro en el vertical. Estaba ahí. Bueno, me muevo hacia la derecha hasta que me choco con este punto y hacia la izquierda ya no tengo nada. Se acabó el plano, no hay más puntos.

Entonces, acá tengo una sola rama. Y de este otro lado también, eh, tenía ¿Dónde estaba el tres? Me perdí. A ver, ¿cuál era? Acá. Ahí está. Bueno, me muevo para Me perdí de verdad. Me muevo y genero estas dos ramas acá. 102, que es esta, ahí está. Y 87, que es esta. Y tengo mi árbol. Todavía no sé cómo lo voy a usar. Lo único que estoy haciendo es construyendo un árbol. En este caso, que son poquitos puntos, hice un árbol exhaustivo y llegué hasta las hojas donde ya no me puedo mover más. No tengo más puntos. Podría haber cortado antes, es una variante, pero acá yo hice un árbol completo con todos los puntos.

00:43:25

lse posgrados: Y esto sería lo que podríamos considerar de entrenamiento, el modelo armar el árbol. No puedo hacer más nada que eso antes de de traer una muestra nueva a ver de qué clase es. tengo el árbol, con eso arranco y entonces ahora yo traigo una observación nueva y quiero encontrar los vecinos más cercanos. En vez de calcular la distancia acá, todos y cada uno de los otros puntos, yo ahora voy a usar el árbol. Y entonces, ¿cómo hago? Este punto nuevo es 94. Como yo la primera división que hice fue en el eje de las x, o sea, del x1, voy a comparar el valor x de mi punto, que es 9, con el valor x de la raíz del árbol que es 5. Como es mayor que 5, me voy a mover hacia la derecha. La segunda división que yo hice fue a lo largo del otro eje del x2. Entonces, ahora comparo el 4 con el 3 y el cu mayor, entonces me sigo moviendo hacia la derecha. Entonces, así me muevo a la derecha o a la izquierda según eh cómo me dé esa comparación. Y ahora estoy parada acá. Estoy parada acá con toda esa comparación y esa búsqueda que dicen el arbolito.

00:44:36

lse posgrados: Estoy parada acá. Y lo que yo ya puedo saber es que los vecinos más cercanos van a estar en este pedacito del árbol. Yo sin hacer ninguna cuenta más, yo ya sé que este, por ejemplo, está reljos, no va a estar entre mis vecinos cercanos. este 31 que es este de acá abajo. Entonces esta búsqueda me limita o me acota la búsqueda a solamente este pedacito del árbol. Lo que yo hago una vez que llegué acá a la hoja es calculo la distancia al eh puntito este más cercano que está acá y acá me genera una búsqueda que va estar acotada a esta parte del árbol. Es decir, yo vuelvo acá a la a la raíz de ese de esa hoja donde estoy y busco acá, o sea, calculo las distancias a esta hoja que es 133 es esta, calculo la distancia esta, o sea, me muevo en este pedacito del árbol y me quedo con el más chiquito. Y este resulta que es el vecino más cercano al punto nuevo. Pero yo no tuve que calcular las

distancias a todos los valores estos. O sea, ni siquiera llegué acá. No me moví por acá, me moví solamente en esta ramita del árbol y ahí encontré el vecino más cercano de todos que es uno.

00:45:56

lse posgrados: Si yo quisiera hacer la variante para tres vecinos, bueno, modifico un poco el algoritmo, pero siempre me voy a estar moviendo acá. No necesito recorrer todo el árbol. Sí, sí, Alejandro.
Alejandro Valle: ¿Cuál es cuál es la regla para armar el árbol? El árbol, por ejemplo, un árbol binarios, los nodos izquierdos son menores que el padre y los nodos
lse posgrados: En este caso sí. En este caso sí,
Alejandro Valle: derechos.
lse posgrados: pero eso es una cuestión más de implementación. Vos puedes implementarlo como vos te convenga. De hecho, no vas a tener que implementarlo porque las librerías de Lar ya tiene todo implementado. Pero si vos lo quisieras hacer a mano, es es un una cuestión de de criterios de cómo vos quieras programar el árbol. O sea, eso es más un detalle de implementación que no te va a cambiar el la lógica general que uno busca, eh, y el objetivo general que uno busca acá,
Alejandro Valle: Sí,
lse posgrados: ¿no?
Alejandro Valle: sí. Es que me perdí con el montón de líneas en el gráfico,
lse posgrados: Ah, sí,
Alejandro Valle: pero me preguntaba si seguía me preguntaba si seguía alguna regla como los árboles
lse posgrados: porque pero si es que de hecho es un árbol binario, vos te vas abriendo en dos,

00:46:56

Alejandro Valle: binarios.
lse posgrados: en dos, en dos, pero ni te compliques con cuestiones de detalle implementación porque no, o sea, no vas a tener que hacerlo. Lo importante es entender la idea,
Alejandro Valle: Gracias. M.
lse posgrados: ¿no? De nada. Y también puede pasar que vos acá, bueno, acá tenemos puntos que los contamos con los dedos de la mano, pero si tuviéramos muchísimos por ahí, no hace falta ir a hasta el nivel de detalle de todas las

observaciones. Me puedo quedar parada acá y en un punto, si acá tuviera, qué sé yo, tres o cuatro puntos más, los calculo a mano, no hace falta que estén todos en el árbol. De todas maneras, esto es mucho más eficiente que hacer una búsqueda o una comparación exhaustiva con todo el 100% de los datos que tengo en el dataset. Este es el Kri, así se llama. Ah, bueno, esto es lo que les acabo de decir, que a lo mejor acá quedaban más puntitos que no estaban en el árbol, pero no importa. Puedo calcular la distancia a mano a cada uno de esos tres puntitos, que siempre va a ser mejor que calcular la distancia a absolutamente todos los puntos del del dataset.
Leonardo Villalva: Ah, perdón.

00:48:14

Leonardo Villalva: Pueden quedar puntos fuera del árbol
Ise posgrados: Claro, sí podría quedar,
Leonardo Villalva: entonces.
Ise posgrados: o sea, si yo no hago el árbol, eh, yo podría hacer el árbol completo de todo, pero por ahí no es necesario.
Leonardo Villalva: Ah,
Ise posgrados: Me me quedo acá, no lo hago completo,
Leonardo Villalva: entiendo.
Ise posgrados: me quedo hasta acá y los puntos que no llegaron a entrar en el árbol quedarán por acá y eh y bueno, esos sí los tendré que calcular a mano. Sí, esa es sería como otra una variante,
Leonardo Villalva: Okay,
Ise posgrados: ¿no?, de de este ejemplo que este ejemplo es exhaustivo, están absolutamente todos los puntos acá.
Leonardo Villalva: okay. Gracias. Yeah.
Ise posgrados: Y bueno, ese algoritmo funciona bien cuando tengo pocas dimensiones. Ahora, no sé si escucharon hablar de la maldición de la dimensión o la maldición de la dimensionalidad. ¿Y a qué se refiere? Uno a veces piensa y no siempre tiene la razón, que cuantos más datos o más dimensiones tengo, capaz que es mejor porque tengo más información, pero a veces en realidad es todo lo contrario. Cuanto más dimensiones tengo, más problemas me trae. Uno de los problemas de la, en este caso, de tener muchas dimensiones que termina siendo caótico y el árbol es más difícil buscar en el árbol que hacer el cálculo de la fuerza bruta.

00:49:34

lse posgrados: para resolver ese tema cuando tengo muchas dimensiones. Una opción es usar otro método que en vez de el arbolito que les mostré es otro que se llama volt, que la idea es parecida, pero se construyen esferas. En vez de un árbol con ramas se construyen esferas. Yo tengo mi punto nuevo acá y calculo la distancia a los dos puntos más alejados y a partir de ahí voy construyendo una esfera esfera, circunferencias en este caso de un plano y otras circunferencias adentro de otras circunferencias sería el equivalente del árbol, las ramitas. En realidad voy armando eh circunferencias adentro de otras y después cuando me aparece este punto que yo quiero saber cuáles son sus vecinos cercanos, lo que hago es buscar la menor circunferencia que lo contiene, que sería esa. Entonces, ahí es donde yo sé que están los vecinos más cercanos. Ahí calculo y ya. O sea, la idea es la misma, solo que cambia la estructura que se usa para almacenar toda esta información. En vez de árbol tengo eh circunferencias o esferas anidadas. Y bueno, como dice acá, es más pesada, lleva más tiempo de armarla, pero eh es más óptima para cuando tenemos más dimensiones. Y como les decía recién, Secret learn ya hace todo esto por nosotros, ¿no?

00:51:03

lse posgrados: Que tenemos que hacer el programa para calcular estos estas estructuras. Si dejamos que el algoritmo de cycle learn elija solo el método, si tengo pocos datos, directamente usa fuerza bruta, calcula todos contratos, o sea, agarra el dato y calcula las distancias a todas y cada uno de las de los datos que tengo. Si tengo muchos datos y pocas dimensiones, usa el Ketri. Y si tengo muchas dimensiones, usa el volt, que es este. Pero eso lo hace la biblioteca sola, no tenemos que hacer nada, no le tenemos que ni decir, lo hace. Y eso lo pueden ver. viene la documentación. ¿Hasta ahí, ¿alguna otra pregunta de cómo funciona el algoritmo? Ahora igual lo vamos a ver en un ejemplo en una notebook, pero la idea del algoritmo se entendió. ¿Alguna pregunta? ¿Todo bien?
Andrés Pablo García: Yo tengo un par de preguntas,
lse posgrados: Sí,
Andrés Pablo García: profe.
lse posgrados: Andrés. Pablo,
Andrés Pablo García: Eh,
lse posgrados: vos sos Pablo,
Andrés Pablo García: la Sí.
lse posgrados: ¿no sos Andrés?
Andrés Pablo García: Eh, Andrés, Andrés,

lse posgrados: Ah,
Andrés Pablo García: Andrés.
lse posgrados: bueno, sí.

00:52:08

Andrés Pablo García: E cuando vos tenés cuando vos tenés dos dimensiones y mostrás cómo calcular, por ejemplo, la distancia euclidiana, no es es obvio cuál es el más cercano.
lse posgrados: Sí,
Andrés Pablo García: Vos lo dijiste al principio,
lse posgrados: sí,
Andrés Pablo García: pero cuando tenés muchas dimensiones ya no es tan obvio cuál es el más cercano,
lse posgrados: sí.
Andrés Pablo García: porque tenés múltiples eh dimensiones en las que se mide la distancia. Si vos lo tenés todo escalado, normalizado,
lse posgrados: Sí,
Andrés Pablo García: todo lindo, igual cómo se priorizan las e distancias.
lse posgrados: sí.
Andrés Pablo García: ¿Hay una que pese más que otra o sumas todas las distancias y dices, "Bueno, esta es la menor?
lse posgrados: Claro, vos sum que en vez de dos, para hacerlo simple también, en vez de dos tenés tres columnas, ¿no? Tres e eh atributos.
Andrés Pablo García: Sí.
lse posgrados: Calculas la distancia de la primera,
Andrés Pablo García: Ah, ok.
lse posgrados: o sea, la diferencia, ¿no? Y al cuadrado. Vamos a hacer la euclidiana. La distancia de la primera columna al cuadrado, la segunda al cuadrado, la tercera al cuadrado, sumas todo raíz cuadrada.

00:53:07

lse posgrados: Ese es el cálculo. Así es el cálculo. Si vos quisieras dar más peso a una de esas columnas porque no sé, porque a vos te viene bien para tu caso de uso particular, tu negocio, tu regla de negocio, vos necesitas darle más peso a una columna. puedes adaptar esa medida de ese cálculo y decir, qué sé yo, la distancia, la diferencia de la primera más la diferencia de la segunda más la diferencia de la

segunda de la tercera multiplicada por 1.2, que sé, yo estoy inventando. Eh, podés darle como un peso a alguna de las columnas si es que a vos te interesa que esa pese más en la distancia, pero si no es simplemente columna, columna, distancia al cuadrado, distancia al cuadrado, distancia al cuadrado, perdón, diferencia, sumas todo raíz cuadrada.
Andrés Pablo García: Está bien. Y lo otro que te iba a preguntar es este tema de cómo hacer efectivamente la búsqueda si fuerza bruta o los otros algoritmos que es algún parámetro.
lse posgrados: Hm.
Andrés Pablo García: Lo elegís como parámetro en las librerías y le pones usa este, usa este otro. Esa es una pregunta y va acompañado con, ¿y cuánto es muchos datos y cuánto es poco y y cuándo usar cada uno?
lse posgrados: Y eso todo es muy relativo.

00:54:13

lse posgrados: Es como que yo iría probando, no te puedo decir una respuesta.
Andrés Pablo García: Aquí probando.
lse posgrados: Sí, pero igual como te eh como te decía recién la la el secondarn,
Andrés Pablo García: Ok.
lse posgrados: si vos no le decís nada, elige solo. Así que quizás incluso yo no lo sé de memoria, pero en la biblioteca, perdón, en la documentación quizás te dice te dice cuándo, en qué momento usa uno habría que mirar la documentación por ahí. por ahí te lo dice. Eh,
Andrés Pablo García: Ok.
lse posgrados: lo más fácil de entrada, si nunca ejecutaste este este modelo, nunca lo entrenaste, es no decirle nada y que se arregle la biblioteca.
Andrés Pablo García: Ok.
lse posgrados: Bueno, bueno.
Gabriela Sol Salazar: Yo tengo otra pregunta,
lse posgrados: Sí, sí, sí, sí.
Gabriela Sol Salazar: perdón.
lse posgrados: Sol.
Gabriela Sol Salazar: Justamente cuando vos lo tenés en dos dimensiones, por ahí te das cuenta que los datos están eh separados en subgrupos y decís, "Okay, esto me puede funcionar." En el caso que tenés muchas eh dimensiones, muchas variables, ¿cómo te darías cuenta que este algoritmo es adecuado para tus datos?
lse posgrados: ¿Cómo te darías cuenta que se
Gabriela Sol Salazar: O sea, ¿cuál sería el proceso de pensamiento?

00:55:20

Gabriela Sol Salazar: decir, eh, okay,
Ise posgrados: de
Gabriela Sol Salazar: yo con estos datos tiendo a decir que podría funcionar KNN.
Ise posgrados: midiendo las métricas de performance como con cualquier algoritmo, vos justo lo que vamos a ver ahora, un repaso, vos decís, "Bueno, me importa mucho la precisión y calculando la precisión, si la precisión te da alta, va a ser un buen algoritmo para tu para tus datos. Si te da mal es porque no es por ahí. Es un poco eso. No sé si por ahí mi respuesta es muy muy amplia, muy genérica, pero no pero es eso, con cualquier algoritmo que vos uses es por ahí, digamos, ver cuál es la métrica que a vos te resulta de interés, no siempre va a ser la precisión, es un ejemplo nada más. a lo mejor te importa otra métrica y es comparar esa métrica con distintos modelos y ver cuál te da mejor. Capaz que este algoritmo,
Gabriela Sol Salazar: Okay.
Ise posgrados: este modelo particularmente no es bueno para datasetes, eso sí, por más que tengas el árbol y todo, quizás no es el mejor para cuando tenes dataset muy muy gigantescos. Eso sería ponerle una pauta. Sí, Facundo quiere aportar.
Facundo Lucianna: Sí, iba a agregar el el tal como dice tenemos, o sea, tenemos las métricas de evaluación, pero también bueno cuando vayan a ver la voy porque hablaste la pregunta de si los datos están agrupados o no.

00:56:49

Facundo Lucianna: O sea, sobre ese caso, cuando veamos presaje no supervisado, donde vamos a ver algoritmos que buscan cleros y ver si tiene sentido que esté clasterizando, vamos a ver métricas que te miden qué tan agrupados están los datos, eh, o cómo se se llaman clusters, pero acá en este caso por este modelo en sí no podría ser como una medida
Ise posgrados: Sí.
Facundo Lucianna: accesoria, pero pero en basamos más en las métricas propias del modelo, o sea, las métricas estamos que estás mencionando que vamos a repasar ahora.
Gabriela Sol Salazar: Bueno, gracias.
Ise posgrados: Y aquí dejo de lado un ratito el KNN y vemos esto que es algo genérico para todos los modelos estos de clasificación, eh, y que ya lo habrán visto en en Introducción a inteligencia artificial, pero es a modo repaso. Si recuerdan, la

matriz de confusión es esta matriz para un caso de dos clases, ¿no? donde tenemos la clase uno y cero o true y false, en las columnas, los valores reales, en la, perdón, si en las columnas, en las filas los datos predichos y según si la predicción fue buena o mala, tenemos los verdaderos positivos, los verdaderos negativos, los falsos positivos y los falsos negativos. Los ponemos así y a partir de estas cuatro eh métricas derivamos todas estas o todas las que ustedes se les ocurra inventar.

00:58:24

Ise posgrados: las más usadas, la sensibilidad, la exactitud, la precisión, el recall, pero bueno, hay hay otras más que tampoco están mencionadas acá. el F1 score, que es como un equilibrio entre precision y recall cuando las dos métricas son importantes. Eh, pero esto es un poco a modo de repaso qué métricas podemos usar para ver si eh un modelo es bueno o un modelo es mejor que otro. Necesitamos sí o sí una de estas métricas para poder comparar, porque si no es solo intuición. Lo miro y digo, "Ah, sí, más o menos bien." Pero si yo realmente estoy queriendo buscar un modelo que me funcione o eh si el único modelo que existiera en el mundo fuese el KNN, yo quiero ver qué es mejor, KNN, con tres vecinos o con cinco o con 25. Bueno, para poder comparar yo necesito un una regla, una métrica. ¿Qué comparo? ¿Los miro y digo más o menos o comparo la precisión? Bueno, entreno mi modelo con tres vecinos y miro la precisión, 080. Entreno con cinco vecinos, miro a precisión, 094. Ah, buenísimo. O sea, sería mejor eh adoptar esta opción de cinco vecinos.

00:59:40

Ise posgrados: Entonces, para eso me van a servir ahora eh las métricas, elegir una que sea, no no siempre eh precisión por ahí en la que uno enseguida dice, "Bueno, miro la precisión, pero no necesariamente la precisión es la mejor métrica para mi para mi caso de uso." Eh, pero bueno, uno elige una métrica y dice, "Bueno, con esta métrica voy a comparar este modelo con este con este o este modelo con estas variantes y y bueno, me quedo con el que mejor precisión tenga en el ejemplo o mejor F1 SCE o mejor lo que sea." Y otro concepto que seguramente también lo vieron, que es la curva rock que tenemos acá. la tasa de falsos positivos, la tasa de verdaderos positivos y según el dibujito de la curva nos damos una idea de qué tan bueno es el el modelo. Lo vieron con regresión seguramente en en inteligencia artificial. Si la curva rock me da algo así como la curva magenta, es un modelo bastante bueno. Si la curva me da recta, en realidad no es una curva, este es un

modelo muy malo que está adivinando básicamente lo que me está diciendo. ¿Y a qué viene la curva rock en este momento? que la curva rock es muy buena, pero para el KNN no nos sirve porque el KNN nos dice eh a qué clase pertenece.

01:01:06

Ise posgrados: Pertenece al en el ejemplo original que vimos, pertenece a la clase magenta, pertenece a la clase verde y es tajante, pertenece a esta clase, no me dice y en un 80% me parece que pertenece a la verde, o sea, no tengo esa salida probabilística. El KN me dice es verde, es magenta, entonces es imposible que yo pueda dibujar una curva roca. O sea, ahí no tiene no tiene ningún sentido este concepto para el KNN. Y esa creo que es una de las cosas que a Facundo no le gusta este modelo. ¿Recuerdan la curva rock? ¿Se acuerdan de haberla usado? Sí, más o menos la van a seguir usando, la van a volver a usar y todo, pero bueno, no. con KNN porque no tiene ningún sentido. O sea, KNN no me da una salida probabilística. KNN me dice es esta clase nada más. Bueno, y ahora entonces vamos a ver eh un poquito la notebook. Eh, esto ya lo vimos. Vamos a ver acá. Ah, lo primero que les decía, esto es nada más para que vean ejemplos de medidas de distancia. Eh, bajo acá.

01:02:20

Ise posgrados: Estos son puntos random y esto es no es más que el mismo dibujito que vimos en la diapositiva, eh, puntos que están a la misma distancia del punto central según qué distancia utilice. Nada más es un ejemplo así eh curioso, ¿no? No es nada más que eso. Está esta notebook. Esto es lo que vamos a ver, clasificación. Eh, bien. Bueno, primero que nada importamos acá las mismas eh eh funciones de que ya ustedes deben conocer del split de trenitest, eh estas métricas para para medir la el desempeño modelo. Y lo que vamos a hacer es una un ejemplo de clasificación usando KNN con este dataset de CSB que me parece que ustedes ya lo conocen. Habrán visto algún ejemplo en clase dos, estoy en cualquier lado. ¿Habrá visto algún ejemplo con ese creo no con ese con ese dataset en inteligencia artificial? Acá este es el dataset. Es este tiene solamente cuatro columnas. Muy sencillito, tiene el balance de creo que es de la tarjeta de crédito, los ingresos, si es estudiante o no y si pagó, no pagó la tarjeta de crédito. Entonces, leo el dataset. Voy a bajar.

01:03:46

Ise posgrados: Miro más o menos que hago una preparación así muy rápida lo que es e acá lo que es categórico lo convierto en en ceros y unos, o sea, una preparación muy muy exprés de de estos datos para poder entrenarlos. Bajo, bajo, bajo. Y acá lo ploteo para mirar, tener un poco de idea qué qué son los datos, la el balance de la tarjeta, los ingresos y en color yo estoy viendo si cumplió o no cumplió con el pago de la tarjeta. Acá veo un poco de mezcla, ¿no? O sea, como que a simple vista no es tan directo clasificar en usando estas variables, pero bueno, vamos a ver qué hace el KNN. Y primero algo que siempre van a hacer es entrenar con un modelo de base, ¿no? Para tener un punto de comparación. Si ustedes arrancan con el KNN y les da un número, ustedes por ahí no tienen mucha forma de saber si eso es bueno o malo. Es mejor arrancar con uno simple de base siempre, no necesariamente hoy con el KNN en general con una base, en este caso una regresión logística. Tenemos acá el dataset. Separo entre test. Entreno, hago las predicciones, creo la matriz de confusión y tenemos esto.

01:04:59

Ise posgrados: Y este es nuestro primer modelo a simple vista. ¿Qué les parece? ¿Qué qué ven acá? Algo que les llame la atención. Super bueno. ¿Qué tiene este modelo? Este 324, ¿les parece bien? Tendría que decir 1000 acá, 2000 o cero. Para empezar,
Gabriel Quiroga: debería decir cero.
Leonardo Villalva: Claro.
Ise posgrados: idealmente debería ser cero porque estos son casos donde la etiqueta real es cero
Leonardo Villalva: Mhm.
Ise posgrados: y el modelo me predijo un uno. O sea, son eh son errores del del modelo, cosas que yo no quiero. Quiero un cero acá, lo mismo que acá. Entonces, esto es un modelo que no es el ideal, no es mucho lo que yo estoy esperando. Quiero bajar este numerito en principio. Bueno, eso modo ejemplo. En realidad, después habría que calcular la métrica que me interese y ver cuánto me da para después compararla con el KNN. A ver si con el KNN mejora o no mejora. Acá abajo están calculadas algunas métricas.

01:06:04

Ise posgrados: La sensibilidad 094, especificidad 086, la precisión 019, bajísima. Bueno, estas son las métricas para este eh clasificador de regresión logística. Y entonces ahora sí vamos a clasificar con KNN. Para eso vamos a usar el clasificador de SEIT Learn, que acá está el link a la documentación. Y fíjense acá lo importo. Y cómo eh hago para entrenar con KNN. Acá tengo la función K neighbors classifier y como parámetros le paso la cantidad de vecinos. Le paso 23. ¿Por qué? Porque se me ocurrió, o sea, puedo pasarle el número que yo quiera. Le estoy pasando 23 vecinos. La métrica es otro parámetro. Y fíjense, Minkowski 2. Minkowski es esa métrica genérica, la fórmula, ¿se acuerdan? La genérica que yo le paso una potencia, un P que es 2 3 4 cuando la potencia es dos, es la euclidiana. O sea, acá Minkowski P = 2 es lo mismo que decir distancia euclidiana. Entonces yo voy a entrenar el KNN con 23 vecinos y voy a usar la distancia euclidiana.

01:07:15

Ise posgrados: Estos son los hiperparámetros del modelo, cantidad de vecinos y la métrica de de distancia que voy a utilizar. Acá hago el entrenamiento, acá hago la predicción y acá armo la matriz de confusión. ¿Qué es esta? A simple vista, ¿qué podemos decir?
Martin Amagliani: Da mejor que el anterior, pero tenés mucho falso negativo.
Ise posgrados: Todavía tengo Sí, pero da mejor que el anterior. Y si miramos las métricas, pues habría que hacer una tablita y comparar, ¿no? Pero acá están las métricas para el KNN. Eh, la precisión no más que me acuerdo que era bajísima, era 020 y algo, creo. Acá ya me da 073, o sea, subió muchísimo. Habría que ver el resto, no me acuerdo los números, pero bueno, la idea es que yo calculo acá las métricas y las comparo con aquella original y miro a ver cómo vengo, si está mejor. Incluso el KNN, bueno, yo puse 23 vecinos. ¿Qué pasa si ponía cinco? ¿Qué pasa si ponía 101? No sé, habría que ver.

01:08:32

Ise posgrados: Y por último, acá tenemos eh acá abajo de todo sigo bajando este dibujito con la frontera de decisión. Lo que yo esperaría es que el modelo me clasifique perfecto, que toda esta área sea toda naranja y toda esta área sea toda azul y que no haya puntos colados en el área equivocada. Pero bueno, por ahora con este modelo así que le tiré un 23 totalmente random anduvo bastante bien. Ese es el

modelo KNN. Sí, Martín,
Martin Amagliani: Lo ide lo ideal acá para que tengan el mismo peso ambas variables sería también primero normalizar o estandarizar, ¿no?
Ise posgrados: sí. Lo ideal,
Martin Amagliani: Oh, no necesario.
Ise posgrados: lo ideal sí. Sí, lo ideal sí, porque cuando calculas las distancias, eh, lo que decíamos antes, si un una columna tiene valores mucho más, no sé si está normalizado acá arriba, eh, pero si una de las de las variables tiene mucho más eh un número magnitudes mucho más grandes que las otras, va a pesar más en la media de distancia. A lo mejor si yo solo quiero que me impacte el salario en este en estos cálculos eh o los perdón, el salario no, los sí los ingresos eh y no normalizo, por ahí no importa, por ahí funciona bien igual, pero sí lo ideal sería normalizar.

01:09:50

Martin Amagliani: Genial.
Ise posgrados: ¿Alguna otra consulta? Sí, sí,
Facundo Lucianna: No, yo quiero preguntar si les eso que está diciendo de ah ponemos un número y vemos alguien
Ise posgrados: Facundo.
Facundo Lucianna: incomodidadmente. estar aprendiendo de probamos y vemos tendría que haber un método un poco
Gabriela Sol Salazar: y un poco.
Gabriel Quiroga: Sí.
Gabriela Sol Salazar: Yo creo que por lógica elegiría como,
Ise posgrados: Quería es muy buena
Gabriela Sol Salazar: OK, uno muy grande, uno medio chiquito, algo en el medio y vamos.
Ise posgrados: esa. La vamos a retomar dentro de un ratito. tu idea. Eh, si quieren hacemos un corte chiquito. Son las 8, ¿les parece? Bueno, a ver, vamos a poner el temporizador hasta el cuarto. No. Bueno, estamos para continuar. Sí. Bueno, entonces ahora eh dejando un poquito de lado, pero un poquito nada más el KNN, vamos a hablar de los métodos de ajuste de hiperparámetros. Hoy vamos a ver ejemplos aplicados al eh al método de KNN, al modelo eh a este tipo de modelos, pero esto que vamos a ver ahora se aplica a cualquier otro modelo.

01:19:12

Ise posgrados: Es es hoy es a modo introductorio, lo vamos a aplicar con el modelo que vimos hoy. ¿Qué son los métodos de ajuste de hiperparámetros? Ya vimos recién y al principio de la clase que los hiperparámetros son parámetros que caracterizan un modelo y los tengo que definir antes de entrenar el modelo con los datos que tengo. O sea, yo al modelo lo voy a entrenar y antes de entrenarlo yo no solamente le voy a dar mis datos, sino que le voy a decir, "Mira, los parámetros son este, este y este." Es decir, que cuando yo entreno el modelo, esos parámetros no cambian. Ya los defino de entrada. Por ejemplo, con el KNN, yo le digo, "Bueno, entrenar el modelo con cinco vecinos y ese cinco es cinco. El modelo no va en el medio del camino, no me va a decir, "Ah, pero acá mejor le pongo siete." O sea, el cinco es el parámetro inicial y ya después entrena con ese número y ya está. Por supuesto, no es lo mismo que si yo digo cinco o que digo 23, como hice recién en la notebook o digo cualquier otro número. Me va a dar diferentes resultados. No da igual poner cualquier número que a mí se me ocurra.

01:20:24

Ise posgrados: Eh, hay una una un impacto en el desempeño del modelo según cómo yo elija esos hiperparámetros. Y otra cosa es que el hiperparámetro óptimo va a depender del conjunto de datos. Si yo hoy entreno con este ejemplito del archivito default, el KNN con 23 y me dio perfecto, no significa que yo traigo otro archivo de datos y le voy a poner 23 vecinos y me va a dar bien. Ese 23 me va a funcionar a lo mejor para este conjunto, para otro conjunto de datos voy a tener que volver a probar y ver. Eh, sí, César,
Cesar Orellana: Sí. Por ejemplo, para el caso este de KNN, e la elección de la distancia de la fórmula sería un imperparámetro
Ise posgrados: sí. Sí,
Cesar Orellana: también.
Ise posgrados: también en este caso tenemos un hiperparámetro que es la cantidad de vecinos y otro hiperparámetro que es la distancia, el método de distancia. Entonces yo podría hacer combinaciones. Pruebo la euclidiana con tres vecinos, pruebo la de Manhattan con cinco vecinos. Serían las combinaciones de hiperparámetros que yo podría probar con con KNN. El proceso de selección de estos hiperparámetros, es decir, con qué, con cuántos vecinos pruebo, con cuál media de distancia, o sea, ese proceso se llama, se conoce con el nombre de ajuste de hiperparámetros o optimización de hiperparámetros.

01:21:46

Ise posgrados: Es decir, yo voy a elegir los hiperparámetros que me minimicen un error, que me minimicen una métrica. Por eso les hablaba hoy de las métricas. Si yo no tengo una métrica de referencia, difícilmente yo pueda comparar a ver qué me dio mejor, 23 vecinos o cinco vecinos. Yo voy a elegir una métrica de rendimiento, por ejemplo, el F1 score y yo voy a buscar el conjunto de hiperparámetros que me minimicen ese F1 score. Entonces, la métrica que yo voy a minimizar, por supuesto, va a depender de los datos, de claramente de mi negocio, porque depende el tipo de de datos que yo tenga, me puede importar más una métrica que otra, pero bueno, eh en general va a depender de la arquitectura, del modelo que yo elegí, de los datos que tengo, eh, de los propios hiperparámetros y de la métrica. Todo eso yo tengo que tener en cuenta para ver cómo hago esta búsqueda de per parámetros y qué es lo que quiero minimizar o maximizar, porque a veces puedo querer maximizar, a veces que puedo querer minimizar. Eh, realidad acá está mal esto. Estoy buscando hiperparámetros que maximicen la métrica de rendimiento. O sea, quiero los hiperparámetros que me den el el la quiero así más alto, por ejemplo.

01:23:03

Ise posgrados: Pasa que a veces lo que yo quiero es minimizar el error, por ejemplo. No siempre quiero maximizar algo, a veces quiero minimizarlo. Por ahí puede ser confuso eso. Lo que en resumen, lo que quiero es buscar el conjunto de hiperparámetros que me maximicen una métrica que yo elegí. Más allá de eso, otra cosa tener en cuenta es el tema de la validación cruzada, que seguramente ya lo vieron también, que eh me va a ayudar a encontrar un resultado más robusto. Es decir, si yo no uso validación cruzada, a lo mejor tengo un buen resultado y puede ser que me dio por azar, porque justo la combinación, cómo separé tren y test, no sé, la pegué y me dio muy bien y me dio re bien la métrica. Eh, pero resulta que si yo hago validación cruzada, capaz que me doy cuenta que no era tan buena esa opción, esa combinación de de parámetros que había con el que había entrenado un modelo. Entonces, ahí la validación cruzada también me me ayuda eh en este sentido. Y bueno, entonces volvamos a la búsqueda de hiperparámetros. Yo puedo decir, bueno, como dijo Sol, pruebo con poquitos vecinos, con más o menos y con muchos.

01:24:13

Ise posgrados: Pruebo con tres, con, no sé, con 23 y con 101. Puedo hacer eso si quiero. Lo que yo necesito es una forma eh por ahí metódica, porque cuando tengo pocos datos o pocos hiperparámetros, capaz que es fácil decidir con qué cosas voy a probar, pero a veces eh si tengo muchos hiperparámetros ya todas las combinaciones se vuelven inmanejables. Así que yo lo que necesito es una forma de moverme por eso que llamo el espacio de búsqueda. El espacio de búsqueda es todas las posibilidades que tengo de hiperparámetros, ¿no? Y la búsqueda, ¿en qué consiste? en elegir el modelo que voy a entrenar, en ver el espacio de parámetros del espacio, sería todas las opciones posibles de de combinaciones de parámetros en elegir un método, cómo voy a buscar cuáles son los parámetros mejores en elegir un método, un esquema de validación cruzada y en elegir la función que me va a dar un puntaje, que me va a decir, "Esto es bueno o no es tan bueno o es mejor que el otro." Si yo necesito una serie de de cuestiones para buscar eh los mejores hiperparámetros. Y lo que vamos a ver ahora es el métodos de búsqueda, o sea, de toda esa lista de cosas vamos a ver métodos de búsqueda.

01:25:26

Ise posgrados: ¿Cómo hago yo para buscar qué hiperparámetros probar para después ver con cuáles me quedo? Y dos métodos muy típicos son la búsqueda de grilla, que consiste en armar una grilla de todas las posibilidades. Supongamos que como en el KNN tenemos dos hiperparámetros, esto es fácil, yo tengo acá el hiperparámetro A, que sería la cantidad de vecinos. Entonces, yo puedo decir acá un vecino, tres vecinos, cinco vecinos. Y en el hiperparámetro B puedo decir la media distancia. Voy a probar con Euclideana y Manhattan. Y entonces armo una grilla de todas las combinaciones. Un vecino con euclidiana, un vecino con Manhattan, tres vecinos con euclidiana, tres vecinos con Manhattan, cinco con una, cinco con la otra. Y esa sería mi grilla. Y después, ¿qué hago? Voy y entreno el modelo. Para cada una de las combinaciones que armé, hago una tablita con eh la precisión, por ejemplo, que yo hubiera dicho, "Voy a comparar la precisión y me quedo con la mejor." ¿Qué desventajas le ven a esto?
Lucia T. Capon Paul: y el tiempo no de base.
Ise posgrados: El tiempo uno sería el tiempo de entrenamiento, de probar todas las combinaciones posibles.

01:26:42

Ise posgrados: Otra desventaja es que, por ejemplo, en el caso de los vecinos, yo no tiene tope esto porque yo no digo, bueno, no tengo un número fijo de vecinos, puedo decir 1 3 5 7 9 11 y y no termina más. El límite es el tamaño mediata set. Entonces es como se vuelve imposible manejar esa grilla, o sea, no no tiene un tope, no tengo un número finito de posibilidades para armar esta grilla.
Lucia T. Capon Paul: H
Ise posgrados: Entonces esas serían dos desventajas grandes de la búsqueda de grilla. Otra posibilidad sería la búsqueda aleatoria, o sea, yo tengo mi grilla de de base, pero en realidad después tomo en forma random, no sé, cuatro opciones, cinco, algunas de acá. Y esto, ¿qué ventajas y desventajas tiene?
Pa. Santiago Rodriguez Castro: Se puede no converger a la mejor solución, pero es más rápido y más menos costoso computacionalmente.
Ise posgrados: Es más rápido, es menos costoso, pero cómo no te escuché al principio.
Pa. Santiago Rodriguez Castro: puede no llegar a la mejor solución.
Ise posgrados: Puede no llegar. Puede ser que la opción que estaba acá era la mejor y me la perdí. Nunca me enteré. Eso puede pasar.

01:27:53

Ise posgrados: Otra eh opción que es una mejora que se puede hacer a cualquiera de esas dos es incorporar lo que se llama el successive halving o la reducción a la mitad sucesiva, que es así, eh, agarro un subconjunto de los datos, no entreno con todo para no hacer todo ese tema de los tiempos, del costo computacional, agarro un subconjunto chiquito y busco ahí eh los hiperparámetros, una búsqueda exhaustiva, por ejemplo, Por ejemplo, cuando termino, elijo las que me dieron y agrego, ¿cómo se llama? E amplío mi dataset, vuelvo a entrenar con un datacen más grande, con esos parámetros que me dieron bien, entreno todo, me quedo con los mejores y con esos amplío el dataset, o sea, voy agrandando el dataset, pero entrenando con ese dataset grande solo los modelos que me van dando mejor. voy achicando la cantidad de módulos posibles y agrandando el dataset hasta que me quedo con uno que me anduvo eh mejor que todo el resto. Eso sería como una variante que de entrada no es que hago una búsqueda de hiperparámetros exhaustiva con con el dataset gigante y todas las combinaciones, sino que lo voy como de a poquito este mejorando y y buscando esa esa mejor solución. Sería una variante.

01:29:14

Ise posgrados: Y ahora vamos a ver una notebook. que implementa un poquito esto que les acabo de contar. Tenemos acá arriba nada nuevo, lo mismo de recién, lo mismo de siempre y la búsqueda de hiperparámetros y vamos a trabajar con el mismo e con el mismo dataset. Vamos a seguir trabajando con It learn. Y ahí la biblioteca nos ofrece las dos búsquedas que les mostré, búsqueda de grilla y búsqueda búsqueda aleatoria. Primero vamos a ver acá la búsqueda de grilla. Tenemos acá de cyc learn grid search CB. El CB es de cross validation. Y para poder usar esta búsqueda con una grilla, tengo que armar la grilla. ¿Cuáles son las opciones de mi grilla? Eso lo armo acá. En este caso le voy a decir, "Bueno, vecinos, probá de 1 a 30, a 29. de 1 a 29 Pro un vecino, 2 3 4 hasta 29. El otro parámetro que este no lo vimos que es los pesos, si le voy a dar el mismo peso a todos los vecinos o le voy a dar más peso a los que están más cerca. Eso que les mencionaba hoy en la diapositiva, esto es otro hiperparámetro del modelo.

01:30:29

Ise posgrados: Así que le voy a pedir a la a la al método este de búsqueda grilla que considere también estas combinaciones. Y por último le voy a pedir que e como método de distancia use por defecto usa Minkowski, o sea, la fórmula esa genérica que vimos con estas potencias 1 2 3 4 5 6 7 hasta 29. Todas estas combinaciones son 30* 30* 2. ¿Cuánto me da eso? 30, 900, 1800 combinaciones. Yo con la búsqueda de grilla le voy a decir que pruebe 1800 entrenamientos. Sí, eso sería lo que le estoy pidiendo con con esta grilla. A la grilla le paso el clasificador, que lo definí acá arriba, la grilla y acá la métrica que yo quiero que compare para saber con cuál se queda. el F1, el F1 score y entreno al poner grid fit entrena las 18 combinaciones y me va a decir cuál es la mejor de esas 1800. Bajo acá y este ves params me va a decir cuál es la mejor combinación. que resulta que la mejor combinación fue 10 vecinos, el P de la potencia de la fórmula de Mikowski 15 y los pesos me dijo que los pesos calculados en la distancia, es decir, no el uniforme, sino el que le da más peso a la distancia, eso fue el la combinación que mejor dio.

01:32:07

Ise posgrados: Acá estoy entrenando con esos parámetros que me que me dijo el el método de la búsqueda. Me dijo, "Estos son los mejores parámetros." Bueno, voy a entrenar con esos parámetros que son supuestamente los mejores. Hago la

evaluación, armo la matriz de confusión y estos son los resultados que obtengo luego de entrenar con la mejor combinación según la búsqueda eh de grilla que acabo de hacer. Aquí están calculadas las métricas. Y bueno, nuevamente habría que ver si estas métricas son mejores o no que eh las que habíamos probado antes. Habíamos probado con 23 vecinos que supuestamente está contemplado en esta en estas 18. E bueno, habría que ver cuánto cuánto mejoraron o no las las métricas estas. Ahora que probamos con la mejor combinación de 1800 posibilidades. Bien, ahora entonces como segunda opción vamos a ver la random. La random es esa que elijo esta, aquella, aquella y por ahí tengo tanta mala suerte que la mejor se me quedó afuera. Sí, Gabriel.
Gabriel Quiroga: Sí, no, no me quedó claro con qué métrica se evaluó, cuál era la mejor combinación de hiperparámetros.
lse posgrados: Acá subo otra vez. Yo armé acá una grilla de todas las opciones que le que le voy a pedir a Seent que pruebe.

01:33:55

lse posgrados: O sea, yo le estoy armando acá todo el espacio de búsqueda.
Gabriel Quiroga: Sí,
lse posgrados: Le doy acá la grilla.
Gabriel Quiroga: digo la la métrica con la cual elige los
lse posgrados: Sí.
Gabriel Quiroga: mejores parámetros.
lse posgrados: Ah, acá el F1 score.
Gabriel Quiroga: Ah,
lse posgrados: Sí. O sea,
Gabriel Quiroga: gracias.
lse posgrados: en la búsqueda hizo todas estas combinaciones y comparó esta métrica y la que mejor le dio, la combinación que le dio el mejor F1 Score fue esta.
Gabriel Quiroga: Perfecto.
lse posgrados: Sí, Leandro.
Leandro Britez: una consulta. Eh, de todas maneras, para este tipo de método, ¿no existe algún cálculo, alguna horística como para ver para lación de los K en relación a la cantidad de observaciones o la cantidad de
lse posgrados: No,
Leandro Britez: parámetros?
lse posgrados: que yo conozca, que yo conozca, no, en realidad yo lo lo que he visto normalmente que trabajas con no trabajas con 200 vecinos con con estos con estos valores así 15, bueno, 10 justos es par y lleva la me lleva la contra todo lo que dije antes que tenía que ser impar, pero pero con eh una cantidad 5 15 vecinos

normalmente eh te va a andar bien, pero no sé si realmente hay una heurística que te diga, "Andá por acá" o se podría buscar,

01:35:21

Leandro Britez: Bueno, Gracias.
Ise posgrados: ¿eh? No estoy diciendo que no. Bueno, entonces ahora vamos a la otra, a la random. Estamos acá bajo de vuelta y acá estamos. La random también con cycit learn tenemos este randomized search CB. Otra vez le digo yo, le armo yo una grilla, pero después de acá va a elegir en forma random. O sea, esta es la grilla completa, pero no es la que va a probar. Yo le digo, vecinos de 1 a 100, bueno, de 1 a 99. E los pesos uniformes o de distancia y el P, o sea, la potencia de la formulita de 1 a 99 también. O sea, que acá tenemos eh bueno, miles, no sé cuántos cuántos hay, un montón de combinaciones, pero la búsqueda random les le voy a decir que elija en forma random 100. O sea, de todas las combinaciones posibles de esta grilla que estoy definiendo acá, al método este, yo le estoy diciendo elegí en forma aleatoria 100. 1800 es el mismo número, la misma cantidad de de opciones que habíamos puesto arriba, pero arriba yo le dije, "Exactamente son estas 1800. Acá yo le estoy dando muchas más. 100 por 100 son 10,000 como 20,000 opciones son estas." Y de acá le estoy diciendo,

01:36:42

Ise posgrados: "Bueno, elegí 1800 y entrená esas. La métrica es la misma que antes, F1." Y listo. Le digo, "Entrena." Y acá le pregunto, bueno, ¿qué fue lo que te dio mejor? Eh, con P la potencia 95, lo cual es rarísimo porque es es raro imaginarse que qué me esa distancia elevada a la 95 y raíz 95. No tengo idea porque eso sería mejor que la raíz cuadrada, pero bueno, haciendo cuentas la potencia 95 le dio mejor y con 10 vecinos también. A pesar que yo le dije que probara hasta 100 vecinos, con 10 dio mejor. Entonces, este resultado no es igual que el anterior, es distinto. Sí,
Andrés Pablo García: consulta.
Ise posgrados: Andrés, con todo.
Andrés Pablo García: Y no es como capaz capaz que mal lo acabo de decir, pero no es como overfitearlo un poquito. intuitivamente me hace sentir eso, como que estoy ajustando demasiado y si después me cambian un poco los datos en la realidad.
Ise posgrados: Es que acá, a ver, mientras pienso la respuesta. Cuando quiere decir algo.
Facundo Lucianna: Eh, por la respuesta a eso, estás haciendo validación cruzada ahí

de tres, o sea,

01:38:13

lse posgrados: Hm.
Facundo Lucianna: te estás asegurando de que no haya problemas de de overfitting,
lse posgrados: Acá.
Facundo Lucianna: o sea, estás haciendo, o sea, para cada combinación estás haciendo valización cruzada de tres modelos, los evalúa y saca el promedio. Entonces, y si ten elas grande, te estás asegurando que que no deberías fitear igual, eh,
Andrés Pablo García: Ok.
Facundo Lucianna: después vas a hacer el test final y vas a ver si si no estás perfiteando.
Andrés Pablo García: Ok.
Facundo Lucianna: Y además eh no va a superfitear con hiperparámetros. Es muy difícilar con hiperparámetros porque son simplemente parámetros de ajustes que hac son valores de números que eso no es eh o sea, no es un hiperparámetro. la cantidad de datos de entrenamiento no debería serlo, digamos. Eh, y ahí el 95 juega es como Minkowski 95 es la sería muy cercana a la distancia eh, ¿cómo se llama? Infinito,
lse posgrados: infinito.
Facundo Lucianna: ¿sí? que sería como una de las dimensiones la usa como como la más grande de las dimensiones. Básicamente está te está diciendo eso indirectamente, o sea, que está usando la distancia infinito.

01:39:23

lse posgrados: Es verdad, eso no lo dije, no mencioné. Eh, no veo quién levantó la man
Gabriela Sol Salazar: Yo sí e pregunta de acá podrías obtener también como el por ejemplo top c
lse posgrados: sol.
Gabriela Sol Salazar: de mejores resultados porque quizás un hiperparámetro me da muy bien pero nivel
lse posgrados: Sí.
Gabriela Sol Salazar: costos implica mucho más esfuerzo, no sé recursos quizás no este caso, pero con imágenes o otros casos y no sé si con estos métodos, por

ejemplo, para estos modelos podríamos tenerlo.
Ise posgrados: Sí, tenés ahí. Bueno, no me sé de memoria la la configuración, los las propiedades del de la del de esta grilla, pero sí vos tenés posibilidad de sacar más información de acá.
Mariano Jauffroy: Yeah.
Ise posgrados: Acá solamente estamos usando esta esta este método, pero sí,
Gabriela Sol Salazar: Okay.
Ise posgrados: por arriba está la documentación, está el a la documentación donde seguramente eh tiene la respuesta a tu pregunta. Em, bien. Bueno, con este aleatorio nuevamente calcula acá las métricas y como dice acá, ambos enfoques se refiere a la búsqueda a la grilla completa o a la random. Ambas tienen sus ventajas y desventajas, ya las dijimos antes cuando estamos viendo las diapositivas. Y bueno, va a depender de de qué tan grande es el espacio hiperparámetros, los recursos que tenemos.

01:40:58

Ise posgrados: Pero bueno, estas son dos métodos eh muy comunes, muy usados y básicos de búsqueda hiperparámetros. Eh, vamos a ver más ahora otros. ¿Alguna otra pregunta de esto? No. Bueno, volvemos a la presentación. métodos más avanzados. Bueno, e como dice como dice la diapositiva, cuando tenemos un modelo muy complejo, eh un método clásico se vuelve costoso. Tenemos lo que ya mencionamos antes, eh, en juego el tiempo de entrenamiento, el tiempo que nos demora estimar los conjuntos hiperparámetros eh óptimos. Entonces, acá vamos a ir a a buscar otros métodos más avanzados. Ustedes habían visto en inteligencia artificial algoritmos de búsqueda, no necesariamente per parámetros, algoritmos de búsqueda en general y esos algoritmos se pueden usar para buscar hiperparámetros. Acá hay algunos métodos eh algoritmos de búsqueda, una lista de algoritmos de búsqueda que son el gradiente descendente o ascendente. Ahora vamos a ver eh un ejemplito de cómo nos puede servir eso para buscar hiperparámetros. Acá hay algunos que acá no nos van a importar en este caso. Y después, por último, está la búsqueda valleciana, que sí vamos a ver cómo usar una búsqueda valleciana para el caso de eh buscar hiperparámetros.

01:42:48

Ise posgrados: Primero, en el caso del gradiente, descendente o ascendente, ¿en qué consistiría esta búsqueda cuando tenemos eh que buscar hiperparámetros?

Nosotros tendremos acá la grilla, la misma que teníamos antes, ¿no? Y podemos empezar acá. Y suponiendo que esta esta opción, esta combinación de hiperparámetros nos da bien, podemos decidir ir a buscar acá a los eh valores adyacentes, ¿no?, de la de la grilla. Miramos acá, probamos, entrenamos esta combinación con esta combinación de hiperparámetros, venimos acá y entrenamos con esta combinación y así. Y según a dónde nos dé mejor, nos vamos moviendo hacia ese lado y seguimos buscando. Esa sería una forma que no es ni la búsqueda exhaustiva de todas las combinaciones ni una búsqueda aleatoria, sino que nos vamos moviendo para donde vemos que tenemos más posibilidades. La desventaja de esto es que si estamos en un máximo en un mínimo local, por ahí nos estamos perdiendo en realidad el verdadero de la verdadera combinación óptima de hiperparámetros. Eso sería un problema de esta de este método. Y lo otro que vamos a ver es ahora sí con más detalle es la búsqueda valleciana. La búsqueda valleciana eh consiste en eh en general, no para búsqueda de hiperparámetros.

01:44:21

Ise posgrados: En general cuando hablamos de búsqueda valleciana consiste en buscar una función, optimizar una función que no conocemos. Y en este caso, para la búsqueda de per parámetros, la función que vamos a optimizar va a ser una que nos encuentre el mejor el modelo con el mejor rendimiento en función de sus hiperparámetros. Ahora lo vamos a ver con un ejemplo. En general, la búsqueda valleciana se usa para optimizar una función no solo desconocida, sino que es costosa de evaluar. Eh, y otra característica de esta función es que no, o sea, no la conocemos, no tenemos, no sabemos ni cómo es ni qué forma tiene. Entonces, no asumimos una forma fija, una forma fija de esta función, sino que construimos un modelo probabilístico. Todo esto que puede ser así super abstracto, lo vamos a a bajar un poquito a tierra ahora con unos ejemplos. Imagínense este eh esta función. Supónganse que tenemos un solo hiperparámetro, que es la cantidad de vecinos. Entonces, acá en el eje de las X vamos a poner un vecino, 2 3 4 5 6 7 8 9 10, ¿no? Esto en el eje de las X y en el eje de la Y nuestra función objetivo.

01:45:38

Ise posgrados: Supónganse que nosotros queremos maximizar la precisión. Entonces acá vamos a poner la precisión. Supónganse que nosotros entrenamos el modelo con dos vecinos y la precisión nos dio 080 y es este puntito negro. Probamos con cuatro vecinos y la precisión nos dio 082. Es este puntito negro. Y

probamos acá y acá y acá. Probamos cinco combinaciones con cinco números de vecinos cualquiera. Esta función sería la función que recibe como parámetro el número de vecinos y la función me dice cuál es la precisión. Yo no conozco esa función, o sea, si la conociera no estaría buscando hiperparámetros. Me fijo cuál es el máximo y digo, "Este es el máximo, por ejemplo." Y digo, "Ah, listo, la mejor combinación es usar tres eh vecinos. Si este es el máximo, digo, la mejor combinación es usar ocho vecinos." Pero justamente la gracia es esa, que yo esta función no la conozco. Yo sé que existe una función, ¿no?, que dados los números de vecinos me dice cuál es el la precisión. En este ejemplo, funciona objetivo de la precisión. Esta es la función y si yo busco el máximo, listo, ya sé cuál es el mejor eh número de vecinos para mi eh para mi modelo.

01:47:01

Ise posgrados: El tema es que la búsqueda valleciana me va a ayudar a encontrar esta función y una vez que yo tenga la función, tomo el valor máximo y ya sé cuál es el valor de mi de mi número de vecinos, de mi hiperparámetro que me conviene usar. Acá en azul y en verde hay dos posibles funciones porque son dos funciones que pasan por todos mis puntos. O sea, cualquiera de estas dos puede ser la verdadera. Yo no la sé. Son dos posibilidades. ¿Me siguen la idea de la de las funciones? está. El ejemplo que les estoy dando es para un solo hiperparámetro,
Leonardo Villalva: M.
Ise posgrados: que es el número de vecinos. Ahora, si yo tuviera más, por ejemplo, número de vecinos y distancia, no importa, es lo mismo acá. En vez de un número es un set de hiperparámetros. con un vecino y distancia euclidiana acá me dio esto. Con tres vecinos y euclidiana me dio esto. Con cuatro vecinos y no sé y y Manhattan me dio esto. O sea, no esto no es necesariamente para un solo parámetro. es acá yo tengo la combinación de hiperparámetros y acá yo tengo cuánto me da la función objetivo.

01:48:13

Ise posgrados: En este ejemplo yo, vamos a suponer que eh entrené el modelo con cinco combinaciones posibles de hiperparámetros y este es el valor que me dio la función objetivo. La idea de la búsqueda valesiana es construir un modelo probabilístico de esta función para decidir a dónde voy a entrenar la próxima vez buscina de de hiperparámetros. Por ejemplo, si yo ya sé que acá me dio un valor alto y acá me dio un valor alto, puedo decidir entrenar acá con esta combinación de

hiperparámetros porque tengo la esperanza de que acá me dé más alto todavía, porque me lo imagino, porque la acá tengo una idea de que la función va a ir por acá. Entonces, esto es lo que voy a llamar explotar. O sea, este lugar es muy prometedor, este espacio, este pedacito del espacio parámetros. Entonces, yo creo que si busco acá y entreno con esto, con esta combinación de acá, voy a tener un buen resultado. Y otra cosa que puedo hacer en lugares donde no tengo mucha idea, porque acá la función capaz que es esta, pero también capaz que es esta y no lo sé. Entonces, en lugares donde eso es muy incierto, también puedo probar. Digo, "Bueno, ¿y qué tal si pruebo con estos hiperparámetros? A lo mejor tengo un buen resultado." Esto es lo que llamo explorar.

01:49:36

Ise posgrados: Entonces, la búsqueda en qué consiste? en construir un modelo de esta función y después ver. Bueno, y a partir de acá a dónde me conviene muestrear y podría ser acá y podría ser acá. Bueno, entreno con este conjunto de hiperparámetros este y tengo un nuevo puntito. Entreno acá, tengo un nuevo puntito y después vuelvo a ver a ver cómo está esa función. A ver dónde me conviene ahora. Iero, itero, itero hasta que encuentro un lugar donde esa función tiene un máximo y ese conjunto de hiperparámetros que me devuelve ese máximo es sería el conjunto ideal para mi para mi modelo. Cuando dice acá construir un modelo probabilístico, hay muchos modelos probabilísticos posibles. Uno de esos modelos y que lo vamos a ver después en un ejemplo de la notebook es un modelo gauciano. Y el modelo gauciano, ¿qué hace? Me dice, por ejemplo, no, supónganse que acá es un eh vecinos, no sé, tres vecinos, quiero probar con tres vecinos. Yo el modelo le voy a lo voy a entrenar con estos cinco puntos. En este ejemplo no tengo cinco puntos. Al modelo, lo voy a entrenar con estos cinco puntos.

01:50:44

Ise posgrados: ¿Y qué va a ser ese modelo? Yo después le voy a decir al modelo este probabilístico, le voy a preguntar, bueno, si yo ejecutara mi modelo de KNN con tres vecinos, ¿cuánto me daría la precisión? ¿Cuánto daría esta función? Nuevamente precisión es un ejemplo que yo puse acá puede ser F1 score, precisión, record, lo que ustedes quieran. ¿Cuánto me daría? Y el modelo probabilístico me va a decir, "Y mira, si vos entrenás con tres vecinos, en promedio, yo creo que la precisión te va a dar 0,91 con un desvío de 0,01." Eso me va a decir, no me va a decir te va a dar tanto porque no sabe. Es un justamente un modelo probabilístico, me va

a dar una probabilidad. me va a decir más o si entrenas con tres más o menos te va a dar por acá y yo al modelo probalístico le voy a preguntar y si yo entreno con nueve vecinos, ¿cuánto crees que me va a dar? y me va a decir, "Bueno, si entrenas con nueve, te va a dar en promedio, yo creo que 085 con un desvío de 0,2, o sea, con un desvío gigante. Puede darte acá,

01:51:40

Ise posgrados: puede darte acá, puede darte acá, o sea, me va a dar acá como una amplitud un poco incierto lo que me va a decir acerca de este punto, capaz ese modelo. Bueno, yo con eso decido a dónde voy a mostrar la próxima vez. Digo, bueno, está bien, voy a probar acá y voy a probar acá. Y entonces empiezo a iterar, itero, itero hasta que llego a un una solución que me convenza. Y la idea es que yo no voy a probar, si yo tengo 100 vecinos acá, no voy a probar 100, porque para eso hago la la la prueba a mano uno por uno y listo. O sea, la búsqueda valleciana la idea es también ahorrarse ejecuciones. No voy a ejecutar todas las combinaciones posibles, voy a ir haciendo esa búsqueda un determinado número de veces, una, no sé, cinco iteraciones, 10, no sé, no voy a iterar infinitas veces hasta llegar a un máximo. Eh, la idea es un poco esa también. ¿Alguna pregunta con esto? Bueno, entonces, eh, ¿en qué consiste la optimización valleciana para la búsqueda de hiperparámetros? Tengo por un lado un modelo probabilístico.

01:52:49

Ise posgrados: Ese modelo puede ser un modelo gauciano como el del ejemplo y como el que vamos a ver en la notebook. Puede ser un árbol, puede ser uno que se llama estimador triparsen, que lo vamos a ver al final de la clase y hay otros modelos que se pueden usar, pero el modelo gauciano por ahí es el más simple de más simple de entender eso por un lado, el modelo y por otro lado, una función de adquisición. Una función de adquisición es una función que me va a decir por dónde me conviene ir a buscar en la próxima iteración con el objetivo de explorar o explotar. explorar zonas inciertas o explotar donde yo ya veo que me va bien, seguir buscando, seguir indagando por ese por ese lugar. Y acá tenemos otro ejemplo. Imagínense, estos puntitos negros son los mismos que los del dibujo anterior. Yo ya probé acá y la función objetivo me dio acá bastante alta. Probé acá y la función objetivo me dio por acá, no tan alta. La función de adquisición, que es este segundo componente, me dice, me está diciendo, mira, la próxima vez te conviene buscar por acá, entrenar por acá. Esta línea punteada es la función, la verdadera, la que yo

desconozco, la que estoy tratando de modelar.

01:54:09

Ise posgrados: La función de descripción me dijo, "Prueba por acá." Bueno, pruebo por acá y en la siguiente iteración yo ya tengo un punto nuevo. El modelo probabilístico se ajusta. Ahora vieron que esta función que está allá arriba, eh, perdón, esto acá se mueve un poquito, por decirlo de alguna manera, la función se va ajustando y la próxima vez la función de adquisición me dice, "Bueno, ahora te convendría buscar por acá." Y bueno, y se va ajustando, se va ajustando hasta que digo, "Bueno, listo, paro acá y creo que esta es mi mejor eh mi mejor combinación de de hiperparámetros. Vamos a ver e acá en un par de ejemplos, dos ejemplos vamos a ver en esta notebook. Acá importamos una serie de de funciones de secert que las vamos a usar ahora y después, bueno, las métricas, lo mismo de siempre y el mismo dataset con el que venimos trabajando. Vamos a bajar un poquito. Separamos trainit y vamos a hacer primero una búsqueda valleciana de un parámetro, de uno solo. Voy a buscar el número de vecinos. O sea, este ejemplo es solo para buscar eh cuál es el número de vecinos óptimo para mi modelo.

01:55:29

Ise posgrados: Habíamos dicho, tenemos que definir una función objetivo. ¿Cuál es la función que vamos a maximizar? O sea, la función esa me devuelve un número, es eh esa es mi función objetivo. Lo que yo quiero maximizar es el acurasí. El modelo probabilístico. Vamos a usar un proceso gaciano, que es el que les explicaba en el ejemplo. Y como función de adquisición vamos a implementar la que se llama expected improvement, que lo que me dice es me da una idea de cuánto mejoraría mi función si yo elijo esta combinación de hiperparámetros. Entonces acá implement, bueno, acá hacemos una función que lo que hace es recibe el número de vecinos, por ejemplo, cinco, entrene y me dice cuánto es el el accuracy, que es la eh función objetivo que yo decidí usar. Acá dice así podría usar otra cosa. Esta función es eso es la función objetivo. Le digo cinco vecinos y me dice, bueno, con cinco vecinos son el acuracy es tanto. Acá está el modelo probabilístico, el modelo gauciano tiene unos cuantos parámetros. pueden ir a la a la documentación para mirar bien cómo se define, pero bueno, es eso está todo acá en esta línea de código.

01:56:43

Ise posgrados: Y la función de adquisición, expected improvement es la que me dice por dónde voy a buscar en la próxima iteración. La que me sugiere anda por acá o anda por allá, es la que me dice dónde explorar y dónde explotar. ¿Cómo es esta función? Yo le paso una lista de candidatos. Candidatos serían eh una lista de vecinos. que yo todavía no probé, ¿no? Una lista de X. No importa qué valores yo ponga ahí, eh, son valores de cantidad de vecinos que aún no tengo ni idea cuánto es el acurasis si yo probara con esos vecinos. Acá le paso la función probabilística, el modelo, perdón, que es este que definí arriba. Acá le paso cuál es el máximo accuracy que yo tengo hasta este momento. Supónganse que yo estoy iterando, ¿no? Voy por la iteración número cinco. Hasta ahora de las cinco iteraciones, el mejor valor me dio 084. Bueno, ese es el best. Y ahora vemos que es este parámetro. ¿Qué hace el expected improvement? Primero hace esa predicción. Yo le digo, "Bueno, eso que les mostraba en el ejemplo, si yo pasara cinco vecinos, ¿cuánto crees que me va a dar el acura así?" Entonces me va a decir,

01:57:55

Ise posgrados: "Y bueno, el acur sigma, te va a dar 080 y con un desvío de 0,02, por ejemplo. Eso es lo que me va a devolver acá. Luego yo calculo cuánto estaría mejorando mi función si yo usara este número de vecinos en vez del que venía haciendo el mejor hasta este momento. Yo hasta este momento había tenido una combinación que me decía que la era 080. Y con esta combinación y esta esta distribución que me están estimando acá, dice, bueno, podés acá hay una resta, es una resta no más. me dice, "Con esta mejoraría 0 com 1,", no sé, me dice, "¿Cuánto mejoraría?" Y con esto yo entonces sé si esa es un área buena para ir a a probar o no. Si me dice que mejor mucho, empiezo a buscar por ahí. Eso sería explotar. Ahora, si yo quiero explorar más que explotar, yo le paso acá, supongamos que esto es cero. Esta es una resta simplemente entre el valor que yo tenía mejor hasta ahora y el nuevo valor posible. Si yo acá le paso un número 0,5, no sé, cualquier número, acá por defecto es un número muy chiquitito.

01:59:09

Ise posgrados: Si yo le paso acá un número más grande, este improvement se haría más chiquitito y el valor que devuelve la función dependería casi exclusivamente de la del sigma, de la varianza de esos datos. Si se acuerdan, a ver, esperen si puedo

volver a la presentación para para no perderlos. Les muestro de vuelta el ejemplo acá. Si ese parámetro yo se lo paso en cero, la función depende exclusivamente de la varianza. Entonces, si yo le digo, si yo pruebo por acá, ¿cuánto sería la la función objetivo? Me va a decir 0,8 + menos 0,2. O sea, me va a decir que acá la varianza es muy grande. Las posibilidades son tanto de que me dé mal como que me dé bien. En ese caso, este número, ese sigma va a ser grande y este número va a ser grande. O sea, si yo le paso un parámetro un poquito grande acá, le estoy dando más peso a la exploración. En definitiva, esto lo juegan ustedes con estos parámetros. Si quieren darle más peso a explorar o explotar. La cuestión es que esta función me va a devolver cuál es el número de vecinos que me conviene más en este momento, en esta iteración.

02:00:29

Ise posgrados: Es un poco eh es un poco hay que pensarlo mucho y venir muchas veces sobre este código para entenderlo, pero bueno, la idea, lo importante es que se lleven la idea de qué es lo que estoy haciendo. Eh, eso está acá en el código, en el loop principal. Yo primero arranco con cinco vecinos totalmente aleatorios. 5, 32, 22, 37. O sea, son cantidad de vecinos realmente random. Y esta es la precisión, el acuracy, perdón, para cada uno de esos vecinos. Si yo entreno con 37 vecinos, el acuracy es 097. Con 22 vecinos, 097. Y así. Y con esto arranco. Este es mi punto de partida. Son los puntitos negros del dibujo. Y acá está el loop. Le digo, "Bueno, con todos estos vecinos todavía no probé. Llamo a la función expected improvement que me va a decir a partir de lo que yo ya tengo, dónde me conviene explorar o explotar. Acá lo que estoy haciendo es eligiendo ese camino en base a la respuesta de esta función. Y vuelvo, itero, itero haciendo eso.

02:01:47

Ise posgrados: Entreno y miro por dónde conviene explorar o explotar y y vuelvo a iterar, vuelvo a entrenar y vuelvo a a ver por dónde me conviene seguir. Y acá tengo abajo la salida de estas iteraciones. Primero probé con vecinos igual a uno. Este es el curací. Y acá me va diciendo cuál es el mejor hasta ahora. En la segunda iteración prueba con K = 33. El akurasi eh mejoró. Bueno, en cada iteración me va diciendo cómo estoy parada y en la iteración 15, que yo le puse 15, podría haber puesto 10, podría haber puesto 20. En la 15 termina y se queda con el mejor. El mejor hasta ese momento fue 29 vecinos. Si quieren entender este código, mucha paciencia. Lo tienen que mirar despacito, una vez, otra vez, otra vez hasta que le hasta que le

encuentran la vuelta. Pero la idea es como les mostré en el dibujito, e miro, me fijo más o menos dónde me conviene la próxima vez, evalúo ahí la función y sumo puntitos y hago otra vuelta y hago otra vuelta y otra vuelta hasta que termino la cantidad de iteraciones que decidí hacer, que en este caso son 15 y me quedo con lo mejor.

02:03:05

lse posgrados: ¿Alguna pregunta? Es totalmente normal si los perdí a todos porque no es no es simple la idea esta, o sea, la primera vez después que lo ven varias veces van a decir así. Martín,
Martin Amagliani: Vos por iteración vas eh evaluando un punto nuevo o evaluas un
lse posgrados: sí, sí.
Martin Amagliani: conjunto de puntos nuevos.
lse posgrados: Acá eh eh no evaluas un conjunto de puntos, pero después elegís uno acá, acá abajo. Elegís uno y lo sumas a tu lista de puntitos de de puntos eh que
Martin Amagliani: Claro, en la segunda iteración tenes seis
lse posgrados: experimentas. Claro. O sea,
Martin Amagliani: puntos.
lse posgrados: acá evaluas todos los candidatos. Evaluar todos los candidatos es eh llamar al expected improvement. eh, o sea, evalúa el modelo ese probabilístico, no es que entrena el KNN, lo que hace es evaluar ese modelo probabilístico y se queda con el Y de todos esos que evaluó se queda con el mejor, con el que le dio el valor más alto estas funciones imprudement. Eh, toma el e devuelve los valores y vos te quedas con eso, de esos te quedas con el máximo, con el que dio mejor, lo agregas a tu lista y haces otra vuelta.

02:04:26

Martin Amagliani: Ah, no es que cuando sacas ese mejor ahí entrenas el KNN y ves con esa cantidad.
lse posgrados: No, no, no.
Martin Amagliani: Okay.
lse posgrados: Em, acá, claro, vos elected improvement, si te fijas, voy para arriba, lo que hace es eh entrenar el modelo probabilístico, no el KNN, el modelo probabilístico con esos puntos que ya tenía, se fija como que reajusta esa función, cada vez va a recibir más puntos esta este modelo probabilístico. tenía cuatro, pu tener cinco, pueda tener seis, vuelve a ajustar esa función y para un número que yo le digo, yo le

digo cinco vecinos, me va a devolver y bueno, con cinco vecinos más o menos va a andar por acá. Eso es lo que hace esta este predicto. Sí, Gabriel.
Gabriel Quiroga: Pero, ¿cómo puede ajustar esa función sin volver a evaluar el KNN? Para esa nosotros teníamos una función que que era la línea punteada, la que no conocíamos,
lse posgrados: Sí,
Gabriel Quiroga: pero que era la resultante.
lse posgrados: porque está claro, porque está tratando de ver cuál es la mejor función que pasa por todos estos puntos. Es independiente de de que esto salió de un KNN. Vos tenés estos cuatro puntos y lo que está tratando de ver es la función que que mejor ajusta a estos a estos puntos.

02:05:55

Gabriel Quiroga: Pero ahí puede haber una función, por ejemplo, que en cierto x se vaya hasta el más infinito y sería válido.
lse posgrados: Eh, si podría en realidad estos son dos posibles funciones,
Gabriel Quiroga: O sea, tengan claro,
lse posgrados: pero igual
Gabriel Quiroga: esa función que no conocemos,
lse posgrados: Esperé.
Gabriel Quiroga: que no no sabemos qué forma tiene, no entiendo cómo se evalúa después para decir, bueno, si este el punto es mejor.
lse posgrados: Espérate.
Facundo Lucianna: Eh, no,
lse posgrados: Sí,
Facundo Lucianna: per no va a ocurrir nunca esa situación de que va el mundo infinito porque la
lse posgrados: sí.
Facundo Lucianna: función real está acotada, o sea, porque son valores. Vos si pudieras medir todas las precisiones va a tener un valor por cada una de las nunca va a tener un valor de de discontinuidades. justamente esa asunción de continuidad le permite hacer las estimaciones de, "Okay, ¿cuál de toda cuál interpolación puedo es la que se ajusta mejor? Estoy estimando que se ajusta mejor la verdad de la curva, pero matemáticamente está acotado, o sea, no vas a tener los casos de discontinuidades o situaciones de tipo o de asign." Bueno, continuidades. Sí.

02:07:07

Gabriel Quiroga: Sí, igual,
Facundo Lucianna: M.
Gabriel Quiroga: o sea, dije infinito, por decir en realidad un número grande, ¿no? No me refería a la parte de discontinuidades, sino que podría tener un pico muy alto. Si no conozco la función, podría tener cualquier forma. Eso y que incluye un pico muy alto.
Facundo Lucianna: Claro, no tenés idea igual, o sea, digo, hay ciertos acotados porque son son las métricas de evaluación, o sea, si estás usando precisión, máximo va a ser uno, mínimo va a ser cero, no puede tener un valor distinto a eso. Y además eh sí, claro, ese es el chiste, o sea, no sabes cuál es la curva, estás estimando y estás usando puntos cada tanto para ir agregando y mejorando la estimación.
Ise posgrados: Eh, igual una cosita acá que capaz que acá es Gabriel donde por ahí estás esperando esta respuesta. Eh, eso es eh eso que dice Facundo es cierto en esta parte que es donde está eh tratando de ajustar esa curva y buscando la mejor la mejor eh forma, ¿no? Y esto lo ejecuta para todos esos candidatos que yo le pase. le paso 10 posibles número de vecinos y acá eh esta función calcula las el modelo probabilístico para las 10 posibilidades, pero una vez que encontró el mejor acá entrena el KNN con ese para obtener un punto verdadero, digamos, de un punto real,

02:08:26

Gabriel Quiroga: Ah, okay. Bien.
Ise posgrados: no inventado,
Gabriel Quiroga: O sea,
Ise posgrados: digamos. Acá sí, acá lo entrena,
Gabriel Quiroga: el
Ise posgrados: pero con ese punto que eligió, ¿no? Con todas las posibilidades, porque si no al final no estoy ganando nada.
Gabriel Quiroga: claro.
Ise posgrados: Esto lo que hace es calcular el modelo probabilístico para todos los candidatos que yo le le quiera pasar acá, ¿no? El gaciano, el proceso gaciano está buscando esa función, pero después cuando encontró la mejor, según si yo le dije explorada, explotada, cuando encontró una, esa acá entrena el modelo con esa y ese punto lo agrega a mi a mi set de esos cinco puntitos negros que tenía. Yo ahora tengo seis. Ese punto ya no es un punto simulado,
Gabriel Quiroga: Claro, perfecto.
Ise posgrados: ya es un punto que yo lo entrené acá.
Gabriel Quiroga: Claro, ¿no? Sí, lo que me había perdido en realidad era que ese todo

esto está dentro de otro book for, o sea, ahí voy agregando el punto, después vuelvo a calcular los aspectos de improvement y voy agregando puntos así.
lse posgrados: Sí,
Gabriel Quiroga: Está está claro ahora.

02:09:23

lse posgrados: sí, igual después lo pueden mirar despacio este código y bueno,
Gabriel Quiroga: Y sí,
lse posgrados: para seguirlo mejor porque no es muy sencillo.
Gabriel Quiroga: me parece también se ve a que me quedé perdido en el
lse posgrados: Sí, sí.
Gabriel Quiroga: código y después es el parámetro XV. Eh, no se varía para ir pasando exploración a explotación.
lse posgrados: Acá yo ya decido. Podes hacer variantes de que vaya cambiando según en qué etapa del ciclo esté. O sea, no no tiene por qué ser fijo siempre, pero acá está fijo para todo. Para siempre le doy un peso muy chiquitito, pero yo podría darle un peso grande o podría ir moviendo este parámetro. No importa eso. Según como yo quiera ir explorando o explotando. Si lo pones chiquitito va a ser más explotación, como está implementada,
Gabriel Quiroga: Okay,
lse posgrados: ¿no? El espectum arriba, si le pones un número grande va a ser más exploración.
Gabriel Quiroga: perfecto. Gracias.
Lucia T. Capon Paul: pregunta y, o sea,
lse posgrados: Sí,
Lucia T. Capon Paul: a medida que vos vas iterando que vas eligiendo un nuevo punto desde dónde ir,

02:10:23

lse posgrados: sí,
Lucia T. Capon Paul: e, o sea,
lse posgrados: sí va a ir
Lucia T. Capon Paul: siempre va a ir mejorando ahí el scoring. ¿Es sabido o no?
lse posgrados: mejorando porque vos elegís uno y te vas quedando con el mejor. A lo mejor, a lo mejor lo traías arrastrando de antes y en esta vuelta no encontraste nada mejor.

Lucia T. Capon Paul: Sí.
Ise posgrados: Fíjate acá abajo que va imprimiendo la salida de cada iteración. Eh, el mejor hasta ahora en realidad siempre, en realidad nunca cambió el mejor siempre.
Lucia T. Capon Paul: No, sí hay un momento cambio,
Ise posgrados: 97 97 97 puede
Lucia T. Capon Paul: pero si cada iteración puede
Ise posgrados: mejorar o no. Sí, sí, sí, sí.
Facundo Lucianna: Voy a ser exagerado, pero es como intentar pegarle cuál va a ser el número que en la quiniela, o sea, un punto que vas, o sea,
Ise posgrados: Ah.
Facundo Lucianna: estás estimando, pero obviamente no vas,
Lucia T. Capon Paul: Yeah.
Facundo Lucianna: no tenés seguridad de que va a ser, o sea, obviamente se acerca es de basa como dice Karina en base a pero es justamente está jugando sobre algo desconocido, estáando bueno por acá porque quiero explorar más, quiero explotar más porque estoy asumiendo cosas, pero al fin y al cabo pensarlo como eso.

02:11:25

Facundo Lucianna: ¿Querés ganar? O sea, pegar cuál el número que gana la no aleatorio, pero digamos la idea.
Lucia T. Capon Paul: Porque estaba pensando como cuántas, o sea, acá fueron 15 iteraciones, pero no sé si hay algún número que digamos
Ise posgrados: Si vos dijeras, "Voy a hacer 100 iteraciones, al final ni sirve esta búsqueda, más vale hacer a mano una un search o otra cosa." Esto es como para ahorrarte también la el full buscar todas las comisiones posibles. Es como buscar de la forma un poco más óptima y y cortar antes, digamos, no no tener que estar buscando
Lucia T. Capon Paul: Hm.
Ise posgrados: así.
Facundo Lucianna: y agrego estos métodos que son más evolucionados. Estamos viendo con KN porque es el ejemplo, lo está ayudando a nuestra lo entender, pero está pensado para modelos grandes donde entrenar un modelo de eso me puede llevar mucho tiempo y digo, bueno, no puedo hacer una búsqueda grilla ni una aleatoria porque cada entrenamiento puede hacer que muore un día, existe ese con ese caso y entonces eh ahí usa estos métodos porque decir,
Lucia T. Capon Paul: Ya.
Ise posgrados: Hm.
Facundo Lucianna: bueno, listo, intento estimar porque si no no tengo un número finito de pruebas que puedo hacer.

02:12:30

Facundo Lucianna: M.
Lucia T. Capon Paul: H
lse posgrados: Bueno, después de todas estas vueltas encontró que 29 vecinos será el mejor de todo lo que probó. Eh, acá simplemente acá abajo está graficando e todo lo que fue probando, o sea, las 15 iteraciones. Este fue el mejor hasta el momento, que claro, primero empezó abajo y después se estabilizó. Y acá el mejor K, el mejor valor, los 29 los encontró en más o menos en la iteración 10. Acá es nada, una visualización de lo que hizo nada más. Y acá está visualizando eh cuál es el expected improvement que le devolvió cada iteración. Nada, no sirve mucho. Esto es simplemente algo de color. Facundo.
Facundo Lucianna: Y agrego, el problema de este problema es porque estamos cambia mucho diferentes búsquedas el número de vecinos porque ahí se ve en la gráfica que es medio que satura en un punto eh la no.
lse posgrados: Hm.
Facundo Lucianna: Entonces, como que en 26 parece que es más arriba, pero real te pones a ver el que está 27, supongo que 28 lo que están al lado. Y son también más o menos muy similares en valores, como que el problema es que es el problema es como que rápidamente saturan y te queda ahí y no y entonces que cuando haces búsqueda se queda dando vuelta por esa zona que ya de por sí ya estás en la zona que es buena y es muy difícil, no vas a mejorar mucho más después de eso.

02:14:02

lse posgrados: Claro,
Facundo Lucianna: Yeah.
lse posgrados: de hecho acá bajó y no sé y si hubiera hecho 20 iteraciones capaz que se quedaba acá. Bueno, y acá otro ejemplito que es para buscar más parámetros, pero el model ejemplo este es mucho más sencillo que el anterior. En este caso vamos a buscar todos los hiperparámetros, la cantidad de vecinos, los pesos y cuál métrica usar. La función objetivo que en este caso vamos a usar es el F1, pero eh como modelo probabilístico y función de adquisición vamos a hacer algo totalmente casero y artesanal que lo vamos a implementar directamente en el loop. van a ver, es s simple este ejemplo. Eh, acá es la función objetivo. Es eh lo mismo que antes. Yo le paso los parámetros y entrena y me dice cuál es el el F1 score. Esto es igual que antes, solamente que ahora en vez de recibir número de vecinos recibo

la combinación de de parámetros. E bueno, sigo bajando. Elijo para arrancar elijo cinco puntos. Ahora no son cinco puntos, no son cinco valores de vecinos, sino que son cinco combinaciones de parámetros. Esto es para arrancar. Para empezar entreno cinco veces el KNN con 39 vecinos.

02:15:24

Ise posgrados: Esto fue elegido totalmente totalmente random. 39 vecinos basados en la distancia euclidiana, 15 vecinos eh basados en una distancia uniforme eh con Manhattan. Bueno, así esto es totalmente elección random de combinación de parámetros. evalúo y me da con la primera combinación 035 el F1 score con la segunda combinación 038 y así. Y con esto empiezo. Estos son mis cinco puntos en el gráfico del ejemplo. Son mis cinco puntitos con los que arranco. Y el loop es esto. Es s simple, nada que ver con el otro que vimos antes. Es este pedacito de código. Nada más empiezo. Eh, me fijo cuáles son los mejores para decidir si explorar o explotar. Lo único que hago es cambio aleatoriamente cualquiera de los tres parámetros. Eh, digo, bueno, cambio los vecinos. En vez de lo que tenía, elijo uno aleatorio entre 1 y 50, o sea, recontra aleatorio, cambio uno solito. O sea, como sería como que me muevo un poquitito nada más en alguna de las posibilidades. Eh, evalúo el nuevo score y me fijo si es mejor, si no es mejor que el anterior y y pego la vuelta.

02:16:38

Ise posgrados: O sea, es solo esto. Sería casi como una búsqueda, eh, es como la búsqueda, el diagramita que mostramos del gradiente descendente, que me muevo despacito para un costado, para el otro. No es lo mismo, pero pueden imaginarse que es un poco lo mismo. Me muevo un poquitito para un costado, para el otro y evalúo. Eh, eh, acá agrego el nueve. Estoy viendo dónde es eh Scor, estoy viendo par acá, acá cambio los parámetros, evalúo el nuevo, lo agrego y pego. Sí, no es eso, solo. Eh, acá muestra cómo me está yendo las distintas iteraciones y la mejor combinación encontrada es con 11 vecinos con la distancia eucleiana. Y el F1 score que me dio en ese caso es 039. En realidad no lo fue eh comparando cada vuelta, sino que después al final de todo se fijó de todas las combinaciones cuál le dio mejor. Eh, la visualización es un poco nada, eh, ya ni me acuerdo los que eran estos, pero es un poco muestra lo que lo que estuvo haciendo en las iteraciones, eh, cuál cuál fue la cantidad de vecinos que que fue probando, cuáles fueron los pesos, o sea, cuál fue las combinaciones de parámetros que fue probando, nada más.

02:18:11

lse posgrados: Y acá abajo de todo es eh también en cada
Lucia T. Capon Paul: M.
lse posgrados: iteración cuál fue el el F1 score que le fue dando y acá me muestra cuál es eh el mejor la mejor combinación que fue, o sea, este es el F1 SCOR, ¿no? El mayor de todos es con 11 vecinos. Y acá por último entrena con con esa combinación de hiperparámetros y estos son los resultados que obtuvo. Eh, sí, Gabriel,
Gabriel Quiroga: Sí, volviendo a la parte donde están las interacciones,
lse posgrados: sí.
Gabriel Quiroga: me quedó una duda.
lse posgrados: Acá,
Gabriel Quiroga: Eh,
lse posgrados: no,
Gabriel Quiroga: más sí acá el que ganó,
lse posgrados: acá.
Gabriel Quiroga: que es, bueno, es el último,
lse posgrados: Este 039 no es el último.
Gabriel Quiroga: el penúltimo. Ajá.
lse posgrados: No sé si es este o este acá arriba.
Gabriel Quiroga: El penúltimo.
lse posgrados: Bueno, uno de los dos. Este sí con K11.
Gabriel Quiroga: Bueno, es que esa es la pregunta porque se ve que se repite varias veces la misma
lse posgrados: Sí.
Gabriel Quiroga: combinación.

02:19:16

lse posgrados: Y capaz que es un error es por un tema de selección random.
Gabriel Quiroga: ¿Es por un tema de la selección random o o qué es lo que se está mostrando ahí?
lse posgrados: Si yo no quisiera que se repita,
Gabriel Quiroga: Ah, okay,
lse posgrados: podría ser acá tipo un agregar algo como el código que estaba arriba que filtraba,

Gabriel Quiroga: listo.
lse posgrados: que no fuera uno de los que ya probé. sería,
Gabriel Quiroga: No, no está bien.
lse posgrados: pero sí es porque es random.
Gabriel Quiroga: Era para saber si era por eso o estaba mostrando otra cosa y la iteración.
lse posgrados: Sí, no es porque es random y justo me agarró el 11 varias veces, pero pero bueno, sí lo puedes mejorar como quieras. Era era como para mostrar un ejemplo contra completamente opuesto al otro que era bastante sofisticado y esto para que vean que puede ser tan simple como quieran también.
Gabriel Quiroga: Claro, no está clarísimo.
lse posgrados: O sea, la idea es tengo la función inicial y empiezo a buscar, me fijo más o menos por dónde me conviene, busco acá, busco acá y en un momento paro y y esa es la idea general del de la búsqueda.
Martin Amagliani: Este este esto tiene un gran potencial de guiarse en máximos locales,

02:20:04

lse posgrados: Martín.
Martin Amagliani: ¿no? Porque agarras el mejor de ese momento que fue alatorio y vas cambiando a poquito.
lse posgrados: Claro, lo que pasa es que tampoco es que yo me quedo buscando en un lugar, ¿viste? Como el ejemplo de diapositiva, puedo buscar acá eh donde tengo máximos, puedo buscar acá donde hay más incertidumbre, no es que me, por decirlo entre comillas, me encapricho con un lugar donde encontré un máximo y me quedo ahí buscando, buscando, buscando. O sea, puedo hacer una como un equilibrio entre explorar y y explotar. Entonces, eh me evito ahí de de quedarme en un lugar donde capaz que no era una buena una buena solución. No sé si eso responde tu
Martin Amagliani: Ah,
lse posgrados: pregunta.
Martin Amagliani: pensé que tal vez vi mal. Pensé que agarraba y fijaba uno así, solo cambiaba un hiperparámetro a la vez en base al de mejor resultado que vio en la última iteración.
lse posgrados: En este ejemplo acá no está como cambiándole teoría cualquier cualquier parámetro como para moverse de a poquito para un lado, para el otro, ¿no?
Martin Amagliani: Ah,
lse posgrados: Eh,
Martin Amagliani: ok.

02:21:12

Martin Amagliani: Ok,
Ise posgrados: en este ejemplo, como ves,
Lucia T. Capon Paul: Ah.
Ise posgrados: es totalmente artesanal.
Martin Amagliani: ok.
Ise posgrados: Vos lo podés armar como quieras, la verdad, la búsqued, la selección esa como que se mueve de de algún parámetro aleatorio, cualquiera de los tres parámetros se mueve un poquito para un costado para otro. Es como el propósito de mostrar un ejemplo redistinto al primero, pero bueno, de ahí entre los dos podés inventarte la el método como vos eh como
Martin Amagliani: Claro.
Ise posgrados: vos te guste o lo quieras hacer.
Martin Amagliani: Genial.
Ise posgrados: Em, bueno, para no quemarles la cabeza, si quieren hacemos un corte chiquitito y volvemos a la última, que que es poquito, pero bueno, para que se despejen un poco y después vemos lo que es el framework de búsqueda obtuna, que es lo último de la del día de hoy. Sí. Bueno, estamos el último, el último pedacito. Vamos a ver ahora un framework de búsqueda que se llama eh Optuna, que lo vamos a ver, bueno, aplicado a este ejemplo ser sencillo que estuvimos trabajando, con el que estuvimos trabajando hoy. Una en verdad es un framework con lo que eso implica.

02:29:09

Ise posgrados: Es como para trabajos realmente más grandes, más pesados en la nube, o sea, es una es otra escala. Lo vamos a ver acá para que lo conozcan y vean de qué se trata, pero eh piensen, imagínen imagínense ya de entrada que es un montón usar esto para estos ejemplos, o sea, no no necesitamos usar obtuna para este eh esta magnitud de de ejemplos, ejercicios que estamos haciendo acá. Nada, dicho eso, eh Optona nos ofrece técnicas avanzadas de búsqueda de hiperparámetros y si es una forma simple también de hacerlo, sobre todo cuando tenemos modelos más complejos con un montón de parámetros. Eh, y funciona de la siguiente manera. Hace dos cosas. Primero, selección de hiperparámetros, que elige los hiperparámetros que sabe que le pueden dar buenos resultados y después hace una poda donde corta los subconjuntos hiperparámetros que sabe que no van

a conducir a un a un buen destino. Básicamente esa sería la metodología de cómo funciona este framework internamente. Lo que hace es la forma en que trabaja, usa un estimador que se los mencioné antes que se llama triparsen y después usa una estrategia evolutiva en conjunto con una matriz de covarianza, que no vamos a ver nada de los detalles de cómo funciona internamente, pero digamos estas serían las los dos componentes que hacen que este framework funcione cuando busca hiperparámetros.

02:30:47

lse posgrados: para que entiendan un poquito de qué se trata este estimador triparsen. Así como antes mencionamos en los ejemplos que vimos, el estimador eh perdón, el eh el modelo probabilístico, explicamos el el gauciano, bueno, otro modelo posible es este estimador, es decir, es otro modelo diferente que tiene el mismo objetivo. En este caso, este estimador lo que hace es construir dos modelos separados. Imagínense nuevamente este dibujito que tiene la función objetivo en el eje de la I, en el eje de las X tiene las combinaciones de hiperparámetros o si queremos simplificar tendría, por ejemplo, el número de vecinos 1 2 3 4 5. Y los puntitos igual que antes son cuánto me dio la función objetivos para esa combinación de hiperparámetros. Por ejemplo, para un vecino me dio 04, para dos vecinos me dio 05, para 10 vecinos me dio 080. Sí. Es decir, que este dibujito es el mismo, este gráfico es el mismo que eh lo que vimos antes. La diferencia es que acá tenemos una línea imaginaria con un umbral que podría ser, por ejemplo, 079, por decir cualquier cosa, un umbral. Y todo lo que está arriba del umbral son resultados que consideramos buenos.

02:32:02

lse posgrados: Y todo lo que está abajo son resultados que consideramos malos. Lo que hace el estimador es construir dos modelos separados. Uno para eh la distribución de los puntitos rosas y otro para ver la distribución de los puntitos celestes. Entonces, la distribución H de high es la distribución de los hiperparámetros que llamamos buenos y la L de low es la distribución de los parámetros malos. Lo que hace este estimador es estima la densidad de probabilidades de cada uno de los puntitos, es decir, cada una de esas curvitas, es cómo se distribuye esa ese esa combinación en particular, cómo es la distribución de probabilidades de eh de la función objetivo y después las combina y tiene dos distribuciones, la celeste y la rosa. La rosa es la de los parámetros buenos y la

celeste es la de los parámetros malos. Y esto, ¿qué significa? Vieron que acá está como transparente. Esto como intuitivamente significa que si yo me paro por acá en este espacio de búsqueda, en este pedacito de por acá, tengo bastantes posibilidades de que eh la función objetivo me dé bien, como que me dé mal. O sea, no no es una zona clara de hiperparámetros buenos. Si yo me paro acá, casi con certeza, cualquier combinación de hiperparámetros que yo elija por acá me van a dar un resultado.

02:33:27

lse posgrados: Bueno, eso sería como la interpretación. eh simple de este gráfico. Y si me paro por acá esta combinación de hiperparámetros probablemente me dé mal. Entonces, si yo hiciera este cociente, la probabilidad de los buenos dividido la probabilidad de los malos, yo podría asegurar que los mejores hiperparámetros son los que maximizan esto. ¿Por qué? Porque si la probabilidad de los malos es bajita, este número es grande, este cociente es grande. Y en otras palabras, esto me está diciendo lo mismo que lo que dije antes. Si yo me paro acá, voy a tener buenos hiperparámetros. Si me paro acá, ese cociente eh me va a dar mal. Y significa, en otras palabras, que estoy eligiendo una combinación mala de hiperparámetros. Lo mismo acá. Si me paro acá, este número va a ser mucho más grande porque este número va a ser cero en realidad. Entonces, estos parámetros van a ser malos. Esto es lo que acabo de decir. Entonces, en la búsqueda utilizando este estimador, lo que voy a elegir la función de adquis, ¿se acuerdan que porque esto está basado en la búsqueda valleciana?

02:34:45

lse posgrados: No lo dije, perdón. Eh, ¿se acuerdan que teníamos un estimador y una función de adquisición? Bueno, acá el estimador es este el que construye estas eh distribuciones de probabilidad y la función de adquisición, que es la que me dice por dónde buscar la próxima vez, lo que va a hacer es elegir muestras que maximicen este cociente. Así es como funciona eh Optuna con este estimador y esta función de adquisición. Esto es un diagrama de flujo que un poco dice lo mismo, pero en otras palabras. Y lo único que acá eh hace la distinción entre explorar y explotar. Explotar, ¿qué es? Buscar puntos al azar que maximicen ese cociente. O sea, vuelvo al anterior, es buscar puntos al azar acá, porque acá es donde el cociente da eh eh mayores valores. Es buscar acá. Vuelvo al diagramita y explorar. es muestrear al azar puntos de la probabilidad high, perdón que voy y vengo, pero vuelvo acá. Es eh

buscar puntos de toda esta zona rosa, independientemente de lo que hay en celeste. Explorar es buscar dentro de esta zona rosa y explotar es buscar solo donde el cociente es máximo, o sea, donde solo hay rosa y no tengo nada celeste por debajo.

02:36:08

Ise posgrados: Esas serían las dos combinaciones, las dos opciones acá de explorar y explotar. Después, esto es lo mismo que lo que ya hablamos, es iterar eh con la función de adquisición, buscar los puntos donde me conviene eh eh cómo se llama, entrenar el modelo. La próxima vez sumo ese punto y vuelvo. O sea, la iteración, toda esta vueltita es lo mismo que ya vimos en los ejemplos anteriores, pero con otro método, con otro estimador diferente. Y lo otro que usa Optuna es una un algoritmo de optimización basado en evolución. basado en evolución, que significa que tiene como soluciones posibles que las va combinando para encontrar mejores soluciones. Eso es el concepto de eh evolución. y además construye una matriz de covarianza de las combinaciones hiperparámetros que la usa para saber por dónde eh por dónde seguir buscando. Un poco simplificado. Eso es lo que hace eh con este con este algoritmo. Y para no eh aburrirlos más con la teoría esa, vamos rápido a buscar eh a mirar esta notebook. Como les decía, Optuna es un poco demasiado para los ejemplos que queremos hacer acá, pero bueno, a modo ejemplo sirve. Lo que hago es acá, ahora les muestro la página de Optuna y acá tienen el link.

02:37:24

Ise posgrados: Lo que hago acá es importar optuna. Después acá es todo lo mismo. Agarro el dataset, el mismo que antes, eh, y acá abajo lo que hago para usar Optuna es primero creo lo que se llama un estudio, que sería como inicializarlo, vamos a decir. Le digo acá, bueno, lo que tiene que hacer el objetivo, me lo salté, está por allá arriba, perdón. Eh, acá la función objetivo la defino acá. le digo que eh quiero maximizar el F1 Score. Le paso acá eh toda la el espacio de de búsqueda hiperparámetros, es decir, defino todo acá en esta función objetivo y abajo, después de inicializar o crear el estudio, llamo a esta función de optimizar y le paso como parámetro esa función objetivo. Le digo que haga 1000 pruebas en este ejemplo y ya está. Y ahí Optuna se encarga de hacer toda la búsqueda. Y al último le pregunto, "Bueno, ¿y con toda esa búsqueda, ¿qué encontraste?" Y con toda esa búsqueda Optuna me dice, "Encontré que la mejor combinación son 10 vecinos con eh el método de de con los pesos basados en la distancia y con P = a 90. Y eso es todo. Acá entreno con los mejores eh parámetros posibles y acá eh tengo la matriz de

confusión.

02:38:56

Ise posgrados: O sea, todo esto es lo mismo que que en todos los ejemplos anteriores. Calculo las métricas y acá tengo las métricas de haber después de haber entrenado KNN con los parámetros que Optuna me dijo que eran los mejores para el espacio de búsqueda que yo le dije, ¿no? Fíjense esto que dice, "Este resultado puede variar con cada ejecución porque, bueno, por ahí cuando usa valores random no siempre va a usar la misma la misma la la aleatoriedad nos va a decir que justamente que no siempre vamos a tener el mismo el mismo resultado. Y tal como les decía recién, en ejemplos así chiquitos como acá no vale la pena usar esto, pero Optuna sí va a ser bueno para modelos más grandes, sobre todo, bueno, en deep learning, eh, ahí tiene más más relevancia. Yo particularmente, por ejemplo, Optuna lo usé para entrenar unos modelos de deep learning que no eran pesados, pero sí lo que sucede es que llevan demora mucho tiempo en en ejecutarse, en entrenarse. Tengo muchos hiperparámetros, tenía que s yo me acuerdo, cinco o seis hiperparámetros y entonces que eso te ahorra la paciencia de estar enfrente de la pantalla esperando que termine y ponerse a ejecutar otro y ver cómo dio, o sea, uno se desentiende, le tira toda la combinación lo que quiere probar y lo pone a correr y se va y a las 2 horas vuelve y ya están todos los resultados.

02:40:23

Ise posgrados: O sea, es la ventaja esa, no tanto porque el modelo hubiese sido monstruoso ni porque tuviera que ejecutarlo en la nube, no, no era para tanto, pero sí es esa practicidad de que cuando son modelos que tienen muchos hiperparámetros y y cada ejecución demora bastante, yo eh puedo hacer eso, armarlo, lo pongo a ejecutar y chao y me olvido. Entonces, eso en ese sentido para mí está bueno. Les muestro acá la página de de Optuna que la tengo acá abierta, ¿dónde quedó? Tengo acá abierta, fíjense. Bueno, acá está Optuna. Eh, ay, se me truló el teclado. Ahí está. Eh, fíjense que acá dice que se puede usar con distintas bibliotecas. Nosotros acá lo estamos usando con cit learn, pero acá para redes neuronales pueden usar con py torch, con tensor flow, con keras. Bueno, eh hay algunos ejemplos. Se puede eh armar un dashboard con con resultados de lo que de lo que están entrenando. Bueno, no sé, está bueno para eh explorarlo y jugar con esto. Fui un poco rápido, no quiero terminar a las 10 porque me van a matar.

02:41:38

lse posgrados: Por eso fui medio acelerada, pero bueno, es eso. Básicamente es este otra vez les digo, hoy hicimos todos los ejemplos con KNN, todo lo que vimos de búsqueda de perparámetros lo van a usar en con de acá a futuro con cualquier otro modelo que entrenen. O sea, KNN fue a modo de ejemplo. Sí. preguntas sobre esto.
Lucia T. Capon Paul: A mí como que un poco lo que me queda la duda es eh como que no sa como que no termino de entender, tal vez me mi cerebro está un poco frito también, ¿no? Pero eh como que por dónde arrancaría a usar los algoritmos, ¿viste? O sea, es como, bueno, quiero hacer este esto de elegir mis hiperparámetros, o sea, ¿hay alguna que me convenga? Tipo, empiezo por Optuna, empiezo por el lo anterior que vimos. como que no sé si es, o sea, entendí que si tengo algo que es más de caja negra, que no sé cómo se va a distribuir, que s yo, tengo que usar algo más como lo valleciano, ¿no? como esa es la base,
lse posgrados: En realidad,
Lucia T. Capon Paul: pero

02:42:46

lse posgrados: el valleciano te va a ahorrar mucho tiempo si vos tenés un espacio de búsqueda muy gigante, eh,
Lucia T. Capon Paul: sí,
lse posgrados: y realmente no tenés idea por dónde están los parámetros buenos, te va a convenir.
Lucia T. Capon Paul: claro.
lse posgrados: Si vos tenés algo más acotado y no te quieres complicar y ya sabes que con poquitos vecinos te viene bien, no hace falta enredarse con con eso. Probas con, como decía hoy Sol, sino pruebo con tres vecinos, con 10 y con 30 y más o menos me fijo y a lo mejor con eso ya es suficiente y te sirve,
Lucia T. Capon Paul: Hm.
lse posgrados: no estás muy exigente con las métricas, es una prueba de concepto que estás haciendo, qué sé yo. Entonces, no te vas a complicar con ni con un framework ni con un algoritmo de búsqueda s sofisticado, con algo sencillito, una búsqueda simple, con un número acotado de posibilidades de de parámetros. Ya
Lucia T. Capon Paul: Okay.
lse posgrados: está.

Lucia T. Capon Paul: Bueno, sale. Vale, vale.
Ise posgrados: ¿Alguien más? Bueno, para los que tengan ganas y tiempo, tienen como siempre eh acá para si quieren practicar en la clase dos, ejercicios para practicar eh con KNN. Eh, bueno, nada, les quería mencionar eso no más lo tienen acá en la misma carpeta de de la clase dos. Y bueno, nada más voy a dejar de compartir. No sé si está Facundo por ahí quiere decir algo.
Facundo Lucianna: Oh,
Ise posgrados: Bueno, bueno, no hay más preguntas.
Cristian A. Aballay: Ah.
Ise posgrados: Si ya tienen su dataset elegido para el trabajo grupal, pueden ir empezar a probar, aunque después este modelo les dé mal o no les guste, eh les sirve para practicar. Pueden empezar probando eh entrenar con KNN ya. Y esto va a ser lo mismo para las próximas clases. La próxima clase veremos otro modelo que no me acuerdo cuál es. Y bueno, ahí tendrán otra posibilidad de otro modelo para entrenar y así pueden ir haciendo de a poquito el trabajo y no se les amontona para el último. Estamos los liberamos. Buenas noches.
Facundo Lucianna: Gente,
Ise posgrados: Chao. Oh.

La transcripción finalizó después de 02:45:46

Esta transcripción editable se ha generado por ordenador y puede contener errores. Los usuarios también pueden cambiar el texto después de que se haya generado.