📝 Las notas

19 mar 2026

Aprendizaje de Máquina (3/8) - a242b25

Invitados facundolucianna@gmail.com macroldan@fi.uba.ar Aprendizaje de Máquina - CEIA 24Co2025

Archivos adjuntos Aprendizaje de Máquina (3/8) - a242b25

Registros de la reunión Transcripción Grabación

Resumen

Clase debatió la clasificación con K vecinos más cercanos y métodos de búsqueda de hiperparámetros con enfoque principal en máquinas de vectores de soporte.

Clasificación, KNN, hiperparámetros revisados
La sesión comenzó con una revisión de la clasificación y el clasificador de vecinos cercanos, destacando su dependencia de la moda de los vecinos más cercanos. Se cubrieron el ajuste de hiperparámetros como la K y la función de distancia, concluyendo que la búsqueda aleatoria es más rápida aunque puede omitir combinaciones óptimas.

Clasificadores lineales, Soft Margin SVM
Se introdujeron los clasificadores lineales con el concepto de hiperplano y se definió el clasificador de máximo margen. Se discutieron los problemas de rigidez del margen estricto, llevando a la presentación del margen suave, que permite errores a través del hiperparámetro C.

Kernels, regresión SVR y práctica
Para los datos no separables linealmente, se introdujeron los kernels, que proyectan los datos a una dimensión superior para lograr la separación. La Máquina de Vectores de Soporte para Regresión fue

aplicada a un conjunto de datos real, demostrando una mejora del rendimiento del 23% sobre la regresión Ridge.

Detalles

- **Anotación de grupos y elección de temas**: Antes de iniciar la clase, lse posgrados compartió un enlace a una hoja de cálculo y solicitó a los participantes que se inscribieran en grupos, indicando su tema y conjunto de datos elegidos. Luis Ali consultó sobre la asignación de números de grupo, a lo que lse posgrados aclaró que el número es indiferente, siempre y cuando los integrantes del mismo grupo usen el mismo número para identificarse (00:00:00). Luis Ali y su compañero indicaron que aceptaban más integrantes y lse posgrados les sugirió agregar una nota en la planilla que dijera "Aceptamos integrantes" (00:05:12).
- **Repaso de clasificación y KNN**: La clase comenzó revisando los conceptos de clasificación, destacando que se trata de tener un conjunto de datos con una etiqueta que define una clase (como condiciones médicas o transacciones fraudulentas) (00:06:46). El objetivo de un clasificador es predecir la clase de una nueva observación basándose en el aprendizaje del conjunto de datos original (00:08:03). También se revisó el clasificador de vecinos cercanos (KNN), el cual asigna una clase a un dato nuevo basándose en la moda de sus vecinos más cercanos, definidos por una medida de distancia (00:09:31).
- **Ajuste de hiperparámetros**: Se hizo un repaso del concepto de ajuste de hiperparámetros, que son parámetros definidos antes del entrenamiento del modelo (00:09:31). En el caso de KNN, los hiperparámetros son la cantidad de vecinos a considerar (K) y el tipo de función de distancia utilizada. Se concluyó que la combinación óptima de hiperparámetros es específica para cada conjunto de datos y se elige aquella que ofrece, por ejemplo, la mejor precisión (00:11:00).
- **Métodos de búsqueda de hiperparámetros**: Se discutieron dos métodos de búsqueda de hiperparámetros: la búsqueda de grilla (exhaustiva) y la búsqueda aleatoria. La búsqueda de grilla evalúa todas las combinaciones posibles, lo cual es ineficiente; la búsqueda aleatoria toma muestras al azar, lo que es más rápido pero puede omitir combinaciones óptimas. También se mencionaron variantes como la búsqueda bayesiana y el framework Optuna, señalando que las herramientas de la librería scikit-learn son suficientes para las próximas clases (00:12:14).

- **Introducción a clasificadores lineales (ejemplo de los gatitos)**: Se introdujeron los clasificadores lineales con un ejemplo de gatitos en un espacio 3D, donde el objetivo es separarlos en dos clases ("inquietos" y "tranquilos") mediante un plano o hiperplano (00:13:30). El entrenamiento del modelo equivale a encontrar la posición de ese hiperplano (00:17:07). Este ejemplo ilustró problemas iniciales, como un punto mal clasificado y otro en el límite del plano, destacando la necesidad de optimizar la ubicación del hiperplano (00:15:54).
- **Definición de hiperplano y ecuación matemática**: Se definió un hiperplano como un subespacio de una dimensión menor al espacio de trabajo (una recta en 2D, un plano en 3D) (00:18:25). La ecuación matemática del hiperplano se presentó en 2D y P dimensiones (00:19:24). Se estableció la convención de asignar etiquetas de clase -1 y 1 (00:20:28).
- **Clasificación basada en el hiperplano**: Se explicó que al reemplazar las coordenadas de un punto en la fórmula del hiperplano, un resultado positivo indica pertenencia a la clase 1, y un resultado negativo a la clase -1 (00:20:28). Cuanto más lejos se encuentra un punto del hiperplano, más segura es la clasificación (00:23:14).
- **El clasificador de máximo margen (Hard Margin SVM)**: Se introdujo el concepto de margen, que es la distancia más pequeña de un punto de entrenamiento al hiperplano (00:25:52). El clasificador de máximo margen busca el hiperplano que maximiza esta distancia para separar las clases de la mejor manera posible (00:27:01). Este clasificador se define solo por los puntos que se encuentran en el margen, llamados vectores de soporte, y el hiperplano no se mueve si se manipulan otros puntos (00:28:22).
- **Optimización y la restricción de la norma (Introducción a la distancia)**: Para encontrar el hiperplano óptimo, es necesario resolver un problema de optimización que asegure que los puntos estén más allá del margen (mayor que m) y que restrinja la norma de los coeficientes B a ser igual a uno (00:29:41). Esta restricción (norma de B igual a uno) permite que la ecuación represente una distancia perpendicular a la recta (00:32:08).
- **Problemas del clasificador de máximo margen**: Se identificaron dos problemas con el clasificador de máximo margen: es muy sensible al conjunto de entrenamiento, y requiere que las clases sean perfectamente separables por el hiperplano. La adición de un nuevo punto puede mover drásticamente el hiperplano óptimo (00:35:05).
- **Clasificador de margen suave (Soft Margin SVM)**: Para abordar la rigidez del modelo anterior, se introdujo el clasificador de margen suave, que permite que

algunas observaciones estén mal clasificadas o incorrectamente posicionadas (00:36:19). Esto se logra mediante la adición de regularización al problema de optimización (00:39:02).

- **Implementación de la regularización con épsilon y C**: El problema de optimización de margen suave incluye las variables ϵ_i (épsilon subí) y el hiperparámetro C. ϵ_i mide el error de cada observación individual (si está entre el hiperplano y el margen, o del lado incorrecto), y C es un límite superior a la suma total de estos errores (00:39:02) (00:52:07). C es un hiperparámetro que se pasa al modelo para controlar qué tantos errores se permiten (00:48:21).
- **El papel del hiperparámetro C**: Se confirmó que C es siempre positivo y que un valor pequeño de C permite una sumatoria de errores (ϵ_i) más grande, tolerando más errores (00:46:04). Por el contrario, un C muy grande restringe mucho el límite de la sumatoria de errores, acercándose al caso original de margen estricto (cero errores) (00:47:18) (00:54:58). En el margen suave, todos los puntos dentro del margen son considerados vectores de soporte porque afectan la sumatoria de errores, y por lo tanto, el hiperplano (00:49:28).
- **Simplificación de la fórmula (Eliminación de M)**: Para simplificar las ecuaciones, se reescribió el problema de optimización en términos de la norma de los coeficientes (B) sin usar la restricción explícita de que la norma sea uno (00:56:09). En lugar de depender de la restricción, se normaliza la ecuación del hiperplano dividiéndola por la norma de B para que siga representando una distancia (00:58:44).
- **Restricción de errores y transición a la práctica**: La condición final para la clasificación es la desigualdad que todos los puntos deben cumplir para pertenecer a una clase específica, donde los errores épsilon están limitados por una sumatoria. Para la práctica, se utilizan las bibliotecas estándar de Python, incluyendo el módulo SVC de Scikit-learn, que se utilizará para entrenar el modelo de máquina de vectores de soporte (SVM). El primer ejemplo práctico utiliza un dataset sintético de datos inventados, los cuales son perfectamente separables, para el modelo de margen estricto (hard margin), que no permite errores (01:00:05).
- **Entrenamiento con margen estricto (Hard Margin)**: Para entrenar el modelo SVC sin errores, se pasa un valor de parámetro C extremadamente grande (1e5 o 100,000), lo que resulta en un valor $1/C$ muy pequeño, no permitiendo errores (01:01:55) (01:04:16). El modelo entrenado con datos sintéticos perfectamente separables resulta en un hiperplano que separa las

clases perfectamente sin ninguna observación mal clasificada en el medio (01:02:59). La predicción utilizando un conjunto de datos de prueba genera una matriz de confusión perfecta, demostrando que no hay errores de clasificación para estos datos de juguete (01:04:16).

- **Introducción al Margen Suave (Soft Margin) y errores permitidos**: En un caso más real, se generan nuevos datos con cierta superposición, haciendo imposible separarlos perfectamente sin errores. Inicialmente, se entrena el modelo con un valor de C muy grande, lo que produce un hiperplano deficiente y una clasificación "malísima" porque fuerza la no existencia de errores donde son inevitables (01:04:16).
- **Búsqueda de hiperparámetros con Grid Search**: Para mejorar el rendimiento, se realiza una búsqueda de hiperparámetros (Grid Search) probando una variedad de valores para el parámetro C (desde 0.001 hasta 100), utilizando la exactitud (accuracy) como métrica de comparación (01:05:42). El Grid Search determinó que el mejor hiperparámetro para ese conjunto de entrenamiento era $C = 0.1$, resultando en un modelo cuyo hiperplano es el mejor hallado, aunque aún hay errores inevitables debido a la mezcla de datos (01:07:08). La función utilizada para la clasificación es siempre la misma, y solo se juega con el parámetro C, que debe pasarse incluso para el caso estricto (con un C grande para evitar errores) (01:08:33).
- **Implicaciones del parámetro C y la saturación del modelo**: Andrés Pablo García preguntó si un C demasiado alto podría causar un error si el conjunto de datos no puede satisfacer el mínimo de error solicitado, a lo que se respondió que el algoritmo siempre devolverá un hiperplano, aunque la solución pueda ser mala con una precisión baja (01:08:33). Un C saturado no genera un error de algoritmo, sino una mala solución, ya que el modelo intentará hacer lo mejor posible bajo una restricción de error imposible de cumplir (01:10:02).
- **Interpretación de los márgenes en Soft Margin**: Gabriel Quiroga consultó sobre si los puntos mal clasificados deben permanecer dentro del margen, y se explicó que los puntos pueden cruzar el hiperplano y el margen, permitiéndose la clasificación errónea (01:10:02). El margen define la frontera de las dos clases, y su ancho se relaciona con la restricción de que la suma de todos los errores (épsilon) no supere el umbral $1/C$ (01:11:09).
- **El papel del margen y los épsilon**: Los puntos dentro del margen tienen un valor de épsilon asociado entre 0 y 1, mientras que los puntos que cruzan el margen y están en el lado opuesto (clasificados erróneamente) tienen un épsilon mayor que 1 (01:12:32). El margen se mueve de forma conjunta con la

suma de errores; si se desean menos errores, el margen sería más angosto. Facundo Lucianna reforzó que el margen es relevante a nivel de entrenamiento y ayuda a la regularización para mejorar las métricas en los conjuntos de prueba (01:13:39).

- **Generalización y el uso de Kernels (Support Vector Machine)**: El modelo generalizado, llamado Support Vector Machine (SVM), se necesita para casos que no son linealmente separables, donde un clasificador lineal sería inútil (01:16:11). La mejora se logra ampliando el espacio de atributos con *kernels*, que son funciones que llevan los datos a una dimensión superior (por ejemplo, de 2D a 3D) (01:28:39). En la nueva dimensión, se encuentra un hiperplano que separa perfectamente las clases, manteniendo la noción de usar un plano, pero con el "truco" del kernel (01:30:02).
- **Kernels y fronteras de decisión no lineales**: La idea del kernel es transformar la función de clasificación original mediante un producto interno, lo que solo se calcula para los vectores de soporte (01:31:11). El uso de diferentes kernels (lineal, polinomial, radial) permite obtener distintas formas de fronteras de decisión no lineales al regresar al espacio original. La incorporación de un kernel no modifica el concepto de vectores de soporte o el parámetro C que limita los errores (01:34:03).
- **Clasificación Multiclase (One-versus-One y One-versus-All)**: Para adaptar el modelo binario a problemas con más de dos clases, existen dos estrategias: *One-versus-One (OvO)*, que entrena modelos por pares y usa una votación de las clases, y *One-versus-All (One-versus-Rest, OBR)*, que entrena un modelo para cada clase contra el resto de las clases (01:35:14). Un ejemplo práctico con datos sintéticos de tres clases demuestra el uso del kernel radial y la estrategia OvO, resultando en fronteras de decisión que separan bien las tres clases (01:41:31).
- **Aplicación de Kernels en Grid Search**: Se realizó un Grid Search para un kernel polinómico, donde se probaron valores de C y el grado del polinomio, encontrando que la mejor combinación fue $C=1$ y grado 5, lo que resultó en una frontera de separación graficada (01:37:08). Para un conjunto de datos con disposición anular, se aplicó un kernel radial (RBF), buscando combinaciones de C y el hiperparámetro γ (gamma), que influye en la importancia de los puntos según su ubicación respecto al hiperplano. La mejor combinación para el kernel radial resultó ser $C=5$ y $\gamma=0.5$, logrando una exactitud del 86% en el conjunto de prueba (01:40:02).
- **Caso práctico con datos reales (Heart Disease)**: Se utilizó un dataset real de enfermedad coronaria con variables de pacientes y un objetivo binario (dos

clases) (01:44:24). Se prepararon los datos (creación de variables *dummy*, escalamiento) y se ejecutó un Grid Search probando las combinaciones de hiperparámetros para kernels lineal, radial y polinómico, ya que no todas las combinaciones de hiperparámetros son válidas para cada kernel (01:45:40). El Grid Search determinó que la mejor solución fue el kernel lineal con $C=5$, alcanzando una exactitud de 0.86 y un área bajo la curva ROC de 0.90 (01:47:10).

- **Support Vector Regression (SVR)**: Existe una variante del modelo para regresión llamada Support Vector Regression (SVR) (01:50:20). Mientras que la clasificación busca un hiperplano que deje todos los puntos de un lado o del otro de los márgenes, la regresión (SVR) busca el mejor hiperplano que deja la mayoría de los puntos *adentro* de ese camino, ajustando la recta (01:51:40). A diferencia de los mínimos cuadrados, SVR permite pequeños errores y no desplaza la recta por valores atípicos (outliers), enfocándose en mantener el hiperplano donde está la mayoría de los puntos (01:52:48).
- **Ejemplo práctico de Support Vector Regression (SVR)**: Para SVR, se utiliza la clase `SVR` de Scikit-learn, y el ejemplo práctico usa un dataset de estadísticas de jugadores de béisbol para predecir el salario (01:54:13). Debido a que el salario es asimétrico, se aplica el logaritmo para transformar la variable, ayudando al modelo a funcionar mejor (01:57:06). El Grid Search en SVR prueba combinaciones de hiperparámetros para kernels lineal, radial y polinómico, al igual que en el caso de clasificación con datos reales (01:58:20).
- **Evaluación del Modelo SVR y Comparación con Regresión Ridge**: Ise posgrados presentó los resultados de un modelo de Máquinas de Vectores de Soporte para Regresión (SVR), identificando el mejor rendimiento con un kernel radial, gama de 0.1 y valor C de 10. Al comparar el SVR de regresión con una regresión Ridge (que sirvió como modelo base), el SVR mejoró el rendimiento en un 23%. Se enfatizó la importancia de comparar cualquier modelo propuesto con un modelo base para evaluar su desempeño real, una práctica que siempre se debe seguir (01:59:54).
- **Ejercicios Prácticos Propuestos**: Se propusieron dos ejercicios para que los estudiantes practiquen el uso del modelo SVR. El primer ejercicio consiste en usar un conjunto de datos de calidad de vino para realizar un análisis exploratorio de datos (EDA) y construir un modelo SVR de regresión o clasificación multiclase. El segundo ejercicio implica volver a usar un conjunto de datos visto en la clase anterior con el modelo de vecinos más cercanos (KNN), pero esta vez para entrenar un modelo SVR de clasificación y comparar los resultados obtenidos con ambos modelos (02:01:18).

- **Aclaración sobre la Distancia en el Modelo de Regresión**: Alejandro Valle preguntó si el modelo de regresión SVR consideraba la distancia al cuadrado de los puntos. Ise posgrados aclaró que el modelo no considera la distancia al cuadrado, sino que funciona de manera diferente al método de mínimos cuadrados, asegurando que los puntos permanezcan dentro de los márgenes definidos (02:03:19).
- **Sensibilidad al Sesgo y Separación de Clases**: Gabriela Sol Salazar preguntó si el modelo SVR es sensible al sesgo, especialmente cuando hay clases con divisiones no muy claras. Ise posgrados respondió que la capacidad del modelo para clasificar clases depende más de la naturaleza de los datos que del modelo en sí, sugiriendo que si las clases están muy mezcladas, es probable que ningún modelo funcione bien, y que la mejor estrategia es siempre probar los datos con diferentes modelos (02:04:56).
- **Invitación a la Práctica y Mención del Trabajo Final**: Ise posgrados alentó a los estudiantes a practicar con los modelos, ya que es fundamental para la materia, y señaló que continuarán incorporando más modelos de clasificación en las próximas semanas. Se recordó a los estudiantes que deben aplicar estos conceptos a sus trabajos finales (02:03:19).

Pasos siguientes recomendados

- [ ] Ise posgrados considerará la nota sobre si el valor C en la fórmula de optimización es siempre positivo, que surgió durante la explicación del margen suave.
- [ ] Luis Ali agregará una nota de "Aceptamos integrantes" debajo de los nombres del grupo en la planilla compartida.

Revisa las notas de Gemini para asegurarte de que sean correctas. Obtén consejos y descubre cómo toma notas Gemini

Danos tu opinión sobre el uso de Gemini para tomar notas en una breve encuesta.

📖 Transcripción

19 mar 2026

Aprendizaje de Máquina (3/8) - a242b25 - Transcripción

00:00:00

Gabriel Quiroga: ¿Qué tal?
lse posgrados: Hola, ¿qué tal?
Luis Ali: Hola, buenas tardes.
lse posgrados: Hola. Hola.
Facundo Lucianna: Buenas,
Alan Vignolo: Buenas tardes,
Gabriel Quiroga: Buenas tardes,
lse posgrados: Hola,
Alejandro Valle: Bueno,
Luis Ali: está muteada por las dudas. Si una consulta
lse posgrados: Perdón, gracias. No, no decía nada importante, solamente que hay que anotarse en el Ahí les compartí el link a la planilla para que se anoten los grupos con su tema elegido, su dataset elegido.
Luis Ali: con
lse posgrados: Se anotaron poquitos por ahora. Estamos para empezar. No hay muchos conectados, me parece. O sí, 20. Bueno,
Facundo Lucianna: No son poquitos.
lse posgrados: vamos. Son poquitos. ¿Podrías pasar de nuevo? Ahí sí. Ah, porque entraste justo. Espera. Ahí, ahí está. Sí,
Luis Ali: respecto a los grupos,
lse posgrados: Luis,
Luis Ali: este, los números se lo asignan ustedes, ¿no? directamente.
lse posgrados: es indiferente ponerle el número que quieras.

00:05:12

lse posgrados: Lo importante es que esté los integrantes como que nos demos cuenta que es el mismo grupo. Si vos te anotas junto con otra persona, póngase el mismo numerito para que se entienda que es el mismo
Luis Ali: Sí, nosotros por ahora somos dos personas y bueno,

lse posgrados: grupo.
Luis Ali: aceptamos a más. Quienes tengan el mismo tema, quienes elijan el mismo tema, los aceptamos también que nos
lse posgrados: Podrías poner,
Luis Ali: unan.
lse posgrados: mira, ahí este abajo de los nombres de ustedes podrías poner una notita. Aceptamos.
Luis Ali: Sí,
lse posgrados: Aceptamos integrantes.
Luis Ali: acept.
lse posgrados: Mira,
Luis Ali: Bueno,
lse posgrados: para que porque eso tiene, espera que a ver si me funciona acá.
Luis Ali: Perfecto. Muchas
lse posgrados: Aceptamos integrantes. A ver si funciona el la lista desplegable.
Luis Ali: gracias.
lse posgrados: Al final de todo tienes un aceptamos integrantes. Entonces ponen eso y por ahí alguno que anda medio perdido. Nada. Bueno, eh igual no se emocionen ahora cargando datos ahí que vamos a la vamos a empezar la clase. Eh, voy a compartir. Bueno, bueno, vamos a empezar hoy clase número tres.

00:06:46

lse posgrados: Vamos a ver máquinas de vectores de soporte o support vector machine, como los habrán escuchado quizás más comúnmente, no sé cuántos conocerán, pero quizás escuchar o nombrar estos clasificadores. Pero antes de eso, un rápido o breve repaso por lo que vimos la clase anterior. Esperemos que se acuerden qué es lo que vimos. Primero, eh, vimos KNN, nuestro primer clasificador, el primer clasificador que vimos en esta materia. Eh, después vimos un método ajuste hiperparámetros que eh fue como la introducción porque lo vamos a seguir usando esto en todas las clases. Después vimos búsqueda de grilla, búsqueda aleatoria y otras búsquedas. Ahora lo ampliamos un poquito en las próximas diapositivas. Primero que nada, como un repasito, eh, que es un problema de clasificación. Cuando estamos con un problema frente a un problema de clasificación, ¿a qué nos referimos? Tenemos un conjunto de datos y una etiqueta, una columna que es una etiqueta y esa etiqueta tiene una una clase, una clase como en estos ejemplos que tenemos acá. Una persona llega a una guardia con síntomas atribuidos a una condición médica. Esa condición médica es una clase. Puede ser el nombre de una condición o puede ser simplemente A, B, C, una etiqueta.

00:08:03

Ise posgrados: Sí. Y esa es la clase y lo que nosotros queremos hacer con ese dataset es poder clasificar una nueva persona. Llega una nueva persona y en base a todos los síntomas decimos a qué clase pertenece, a cuál de esas tres condiciones médicas pertenece en base a lo que aprendimos con el dataset original. ¿Estamos de acuerdo con eso? Esa es como la base del un modelo de clasificación y vamos a estar hablando de modelo de clasificación todas estas clases. Así que esto debería ser como lo básico que no pueden no saber. Eh, otros ejemplos, un servicio de banca donde vamos a querer determinar si una transacción es fraudulenta o no es fraudulenta. Entonces, la clase, la etiqueta acá es puede ser true, false, puede ser fraudulenta, no fraudulenta, o sea, el nombre que le pongamos a la clase es lo de menos. Lo importante es entender que tenemos esa etiqueta que es una clase y lo que vamos a querer es clasificar cuando venga eh supongamos que el dataset, cada fila del dataset es eh una eh una operación. Entonces, cuando viene una nueva operación, en base a todas las propiedades o los atributos, podemos llegar a clasificarla como fraudulenta o no fraudulenta. Y la última no venimo ni a explicarla porque es un ejemplo de de ADN donde yo no no caso no caso una no es mi temática, no la entiendo, pero bueno, eh a lo que vamos con este ejemplo es que podemos clasificar eh todo tipo de datos médicos de banca, de eh de redes sociales, de lo que ustedes se les ocurra.

00:09:31

Ise posgrados: En verdad estamos bien, rápidamente acá un repaso del clasificador de vecinos cercanos que fue el que vimos la clase pasada, que se basa en la proximidad de los vecinos, en la proximidad utilizando una medida de distancia. vimos varias medidas de distancia y entonces cuando tenemos un dato nuevo que queremos clasificarlo, nos fijamos en la distancia a los vecinos, es decir, a las observaciones que están cerca y en base a eso usamos la moda para eh asignarle una clase a a esa nueva observación. En este ejemplo aparece el gris entre clase fucsia, eh sí, magenta y verde. Hacemos un radio de tres vecinos. En este caso, k es ig a 3 y el valor que más se repite es el verde. Entonces decimos, bueno, este puntito o esta observación va a ser verde o va a pertenecer a la clase verde. Así como funciona el algoritmo de clasificación de eh vecinos cercanos. Y como les decía recién, otra cosa que vimos el otro día, la clase pasada, fue ajuste hiperparámetros, que e es un método para buscar los mejores hiperparámetros cuando estamos

entrenando un modelo. Cuando tenemos un modelo siempre tenemos hiperparámetros, o sea, un parámetro que se define antes de entrenar.

00:11:00

lse posgrados: Por ejemplo, con los vecinos cercanos. ¿Se acuerda cuáles eran los hiperparámetros? ¿Alguno se acuerda cuáles son los hiperparámetros cuando
Gabriel Quiroga: la cantidad de vecinos.
lse posgrados: clasificar?
Leonardo Villalva: La cantidad de vecinos a considerar.
lse posgrados: Cantidad de sinos. Sí. ¿Y qué más?
Cesar Orellana: la función que mide la distancia, ¿qué tipo de distancia?
lse posgrados: La distancia.
Leonardo Villalva: Exacto.
lse posgrados: La distancia. Exacto. Esos dos hiperparámetros pueden ser pu tomar muchos valores y nosotros podríamos jugar adivinar a ver cuál nos viene mejor o hacer algo más metódico y hacer una búsqueda a ver cuál es la combinación que mejor funciona para el dataset que nosotros tenemos porque no es lo mismo si yo tengo un dataset acá que me anda con tres vecinos y la distancia euclidiana, no significa que yo traiga otro dataset y me va a funcionar la misma combinación de hiperparámetros. Entonces, para el dataset que tengo, yo busco con algún método y encuentro la mejor combinación, la que me va a resultar mejor. Eh, y ese mejor es depende de qué es lo que yo esté buscando. Si estoy buscando precisión, miro distintas combinaciones de hiperparámetros y el que me dé mejor precisión, bueno, esa va a ser la combinación de hiperparámetros con la que me voy a quedar.

00:12:14

lse posgrados: Vimos dos métodos básicos, uno es la búsqueda de grilla, la búsqueda exhaustiva. Es decir, hacemos una grilla con todas las combinaciones posibles de todos los hiperparámetros y entrenamos el modelo tantas veces como combinaciones de hiperparámetros tenemos, lo cual puede ser una cosa eh inagotable de de búsqueda y de ejecuciones, lo o sea, no es eficiente absolutamente para nada, pero es una una opción. Después tenemos la búsqueda aleatoria, que de toda esa grilla completa tomamos en forma random algunas combinaciones. No nos va a llevar tanto tiempo, pero puede ser que tengamos tanta mala suerte que al tomar aleatoriamente dejamos afuera opciones muy buenas. Vimos el otro día algunas variantes, el método de ir buscando con un primero con un dataset chiquito

y después ir combinando soluciones, este, agrandando el dataset y agregando combinaciones, o sea, como un método iterativo. Después vimos la búsqueda valleciana y después vimos el framework Optuna. No sé si alguno tuvo la oportunidad de mirarlo, de chusmearlo o de experimentar con con el framework, eh, que hace las cosas mucho más más fáciles. Por detrás, obtuna usa la búsqueda valesiana, pero en particular tiene eh su propio método, ¿no?, para buscar.

00:13:30

Ise posgrados: Y y bueno, y está muy bueno, sobre todo cuando para problemas grandes, cuando escalamos, ayuda muchísimo esta esta posibilidad de de usar este framework. Y eso fue todo lo que vimos el otro día. estos métodos de de búsqueda de hiperparámetros. Bueno, Optun es un framework que no necesitan usarlo, la verdad, o sea, lo pueden usar, pero no es necesario. Tenemos con simplemente en nuestra notebook con la biblioteca de it learn, nos podemos arreglar para hacer búsqueda de hiperparámetros y vamos a seguir usándola en las próximas clases. Y hasta ahí llegamos. Y ahora sí vamos a lo que es la clase de hoy. Como les comentaba el otro día, en las primeras clases, creo que son las primeras cinco, vamos a ver clasificadores y lo que vamos a ver es clasificación supervisada, ¿sí? O sea, un clasificador donde tenemos una etiqueta, un target, una variable target. Hoy vamos a ver clasificadores lineales y acá tienen una imagen muy tierna de unos gatitos y y ustedes dirán qué tiene que ver. Vamos a ejemplificar el clasificador lineal con esta imagen de de gatito. Si ustedes entienden este ejemplo que les voy a explicar ahora, ¿entendieron todos los clasificadores de la clase.

00:14:46

Ise posgrados: Para que se dé una idea, imagínense esto que está en 3D, ¿no? Una foto, esto está en 3D. Tenemos gatitos y los queremos clasificar en inquietos, que serían los que están arriba de las cajas saltando por cualquier lado, trepándose y los tranquilos, que serían los que están caminando por el piso o tirados, durmiendo. Estos serían los tranquilos. ¿Se ve el cursor? Sí, eso sería lo que yo quiero hacer. Y estos gatitos que están acá son mi set de entrenamiento y yo los voy a etiquetar. Sí, como les decía, los que están en el piso son los tranquilos, los que están por acá arriba dando vueltas son los inquietos o intranquilos. Sí, es mi set de entrenamiento. Entonces, una cosa que a mí se me puede ocurrir superfácil y directa es le mando un plano así imaginario, ¿no? Así en el medio de la sala y todo lo que quede arriba del plano o hiperplano, digo, estos son inquietos, todo lo que está abajo son tranquilos.

Sí. Entonces, tengo dos clases de gatos y con un plano las dividí en dos y ya sé a qué clase pertenece cada uno.

00:15:54

Ise posgrados: Entonces yo vengo ahora con otro gatito, lo suelto en la sala y veo qué hace. Si se queda tirado en el piso, para mí es un gatito tranquilo. Si sale saltando para arriba, es un gatito inquieto. Así lo clasifico. O sea, una vez que yo ya dije, "Mi plano es este, si un gato va para arriba, para abajo, ya sé cómo lo voy a clasificar. ¿Está bien el ejemplo o les parece muy pavo o muy sofisticado? ¿Le ven algún problema esto?
Gabriel Quiroga: El gatito que está abajo a la derecha.
Ise posgrados: Abajo a la derecha. Acá hay un gato mal clasificado. Nos quedó afuera. Está cerca del piso, pero yo dije que si se trepan las cajas es inquieto. Nos quedó mal clasificado. ¿Qué otro problema? Acá tenemos uno que está en el límite. Está dudoso, o sea, quedó pisando el plano. Si yo ponía el plano un poquito más arriba, más abajo, me quedaba mal. También está como muy muy en el límite, como dudoso. Esos son problemas que tiene este hiperplano que yo mandé ahí medio a ojo, no puse el plano ahí.

00:17:07

Ise posgrados: Pero entonces ahí viene la segunda parte que es yo puedo jugar con ese plano y acomodarlo mejor. Entonces lo giro un poquito como está acá y ahí me quedan perfectamente clasificados todos. Este de acá abajo me quedó como inquieto. Este no quedó pegado en el plano, quedó bastante separado, bastante bien. Quedaron todos en su lugar. Y entonces este sí es un buen hiperplano para clasificar mis gatitos. Y esa es toda la magia de este clasificador. Busco un hiperplano, lo acomodo para que me quede lo mejor posible y ya está. O sea, el entrenamiento del modelo es encontrar dónde voy a poner el hiperplano. Una vez que lo ubiqué, ya tengo mi clasificador. Y ahora sí vamos a los clasificadores más más de verdad. Vamos a ver como varias versiones, como una evolución del del clasificador. Primero que nada, vamos a ver el clasificador de máximo margen o hard margin SBN o maximal margin classifier, como le quieran llamar. Eso de hard es porque es muy estricto. Siempre estamos hablando de eh de dos clases, eh clasificador binario. Y primero que nada vamos a ver muy poquito de álgebra.

00:18:25

Ise posgrados: Hay cosas que vamos a mencionar hoy que por ahí si les suena que que no entienden muy bien de qué estamos hablando. Eh, la solución es ir a mirar las clases de Martín. Si se las olvidaron es un momento para repasarlas. Tampoco va a ser muy complicado lo que veamos, pero donde se queden un poco ahí como tecleando, que no no sabemos dónde estamos parados, toda esta todas las respuestas y todos los fundamentos y las explicaciones están en las clases de Martín. Igual vamos a tratar de no irnos al a los a los detalles tan matemáticos, pero sí es necesario repasar esto. Primero, el ejemplo que les mostré recién es de 3D, ¿sí? En en tres dimensiones, pero en general en dos dimensiones, tres o 20 dimensiones, vamos a hablar de hiperplanos, ¿sí? Que es un subespacio de una dimensión menos. Por ejemplo, estábamos en la sala de 3D. El hiperplano tiene dos dimensiones. En 2D, o sea, en una grilla de 2D, X e I, el hiperplano es una recta que es de una dimensión, una recta simplemente. Y la definición matemática es esta que está acá abajo.

00:19:24

Ise posgrados: En dos dimensiones tenemos estos coeficientes B0, B1, B2. Y este es el puntito, cada punto X1, X2. Esta es la ecuación de esa de ese hiperplano, o sea, de la recta cuando estamos en dos dimensiones. Sí, los puntos x1, x2 que cumplen esta condición son los que están sobre la recta. Y en P dimensiones es lo mismo, pero bueno, hasta B sub P, X sub. Todo punto que e que cumple esta condición son los puntos que caen exactamente en el plano, en el hiperplano S. Esto es una definición, ¿no? Nada, nada del otro mundo. Lo interesante de esto es lo siguiente. Acá está. Bueno, como siempre, en dos dimensiones más fácil explicar esto. Todo lo que expliquemos se aplica después a tres, a cuatro dimensiones a las que quieran. Pero acá estamos con dos dimensiones. Es decir, serían dos atributos de mi dataset. Tengo dos columnas nada más, que es esta y esta de acá. Y mi hiperplano, el que me va a separar las clases, va a ser una recta. Y esta es la ecuación de la recta.

00:20:28

Ise posgrados: ¿Sí? Lo interesante de esto es que si yo tomo un punto cualquiera acá en todo este espacio, tomo un punto cualquiera y lo reemplazo en la fórmula esta, si el punto está por acá, como este azul, esta cuentita que yo haga acá me va a dar positiva, mayor que cero. Y si yo agarro este punto que está acá en magenta y lo

reemplazo, reemplazo las coordenadas en esta fórmula, la de la recta, me va a dar negativo. Y si yo agarro cualquier punto que está sobre la recta y lo reemplazo en la fórmula de la ecuación esta, me va a dar igual a cer. Entonces esta característica de igualar la fórmula a cero o más mayor que cer o menor que cer según qué punto yo tome, es lo que vamos a usar para clasificar por convención y porque queda mejor y más fácil reemplazando después en todas las ecuaciones. A las dos clases les vamos a poner -1 y 1. O sea, las clases nuestras van a ser -1 y 1. Esas son las dos clases. Y acá tenemos el mismo ejemplo, es decir, de dos dimensiones, un hiperplano que es este violeta y todos los puntitos estos que son mis mis observaciones. Lo que dijimos recién, cualquiera de estos puntos reemplazados en la fórmula va a dar eh el resultado de la fórmula va a dar mayor que cer menor que cer según dónde está el punto.

00:22:00

Ise posgrados: Entonces, si estoy de un lado de la recta, de este lado de la recta y la cuentita esta me da mayor que cero, vamos a decir que estamos con los que los puntos esos pertenecen a la clase uno y todos los que están acá que reemplazados en la fórmula me da menor que cero, vamos a decir que son de la clase -1. O dicho al revés, si estos puntos son pertenecen a la clase -1, yo vengo la cuentita, ya sé que esto me va a dar menor que cero. Y los puntos de la clase uno o azul, si yo agarro cualquiera de esos y lo reemplazo en la fórmula, esa fórmula me va a dar mayor que cero. Me avisan si algo no se entiende y me frenan, ¿eh? Y fíjense que esto que está acá, estas dos primeros renglones son equivalentes a esta otra cuentita que está acá abajo. Cualquiera, o sea, las dos estas están resumidas en esta de acá abajo. ¿Por qué? Porque si estoy en la clase uno, o sea, y subí igual a 1, esto es un punto subí, un punto subí que es x1 subí, x2 subí. Si estoy en la clase uno, esto que está acá arriba es lo mismo que acá multiplicado por uno.

00:23:14

Ise posgrados: Es igual, solo que lo estoy multiplicando por uno. Y la del medio, si estoy en la clase -1 y multiplico esto por -1, se da vuelta al signo y es lo mismo que lo que está acá abajo. Dicho eso, entonces, ¿cómo clasificamos? Suponemos que ya tenemos entrenado esto. ¿Qué significa que lo tenemos entrenado? Que en base a todos esos puntos ya definí cuál es mi hiperplano. Mi hiperplano va a ser este que está acá. Eso es entrenar. Agarro todos los puntos de entrenamiento y busco el hiperplano que me separa las dos clases, que es este. ¿Cómo clasifico? Ahora

defino una función. Yo agarro un punto cualquiera y cómo predigo a qué clase pertenece. Hago toda la cuentita esta de la ecuación que vimos recién y si el resultado me da positivo, entonces la clase de mi punto es uno. Si reemplazo y me da negativo, entonces la clase es -1. O sea, le asigno a la clase según si esto me da mayor que cer o me da menor que cer. Y por ahora intuitivamente, pero después lo vamos a ver en una fórmula, cuanto más lejos yo esté de este hiperplano, mayor me va a dar este número.

00:24:27

lse posgrados: Entonces, más segura estoy todavía que pertenece a la clase uno o que pertenece a la clase -1. Si el punto está muy cerquita de la recta, esta cuenta me va a dar muy cerquita cero, pero igual me va a dar positivo y yo igual lo voy a clasificar como uno. En el caso de un punto que esté de esta área, del lado azul. Este es el mismo ejemplo, los mismos puntos azules y magenta, pero acá yo tengo tres posibles hiperplanos porque nunca dijimos que había un único hiperplano posible. El caso de los gatitos, yo lo primero lo puse horizontal, después lo giré, pero podría haber seguido girándolo hasta acomodarlo mejor y todas eran soluciones. Acá lo mismo, cualquiera de estos, si se fijan, deja los azules de un lado y los magenta del otro. Cualquiera de las tres líneas posibles. Intuitivamente, a ustedes que les parece cuál de estas tres sería la mejor solución y por qué.
Gabriel Quiroga: la más horizontal porque es la que más lejos le pasa todos los
lse posgrados: Está la que más lejos le pasa a todos.
Gabriel Quiroga: puntos. Ajá. Esa misma.
lse posgrados: ¿Están de acuerdo o alguno piensa otra cosa? Esta horizontal le está lejos de los azules, pero está casi tocando el fucsia.

00:25:52

lse posgrados: Mira el fucsia. Digo, el magenta. Yo te digo, para mí esta del medio es la que está más lejos. Mira, esta está bueno por ahí en la escala capaz que tendría que venir con una regla, pero bueno, esta seguro que no. Eso seguro porque está tocando el azul ahí. Es como el gatito ese que está arriba del plano. Esta seguro que no porque es es muy dudoso este punto azul. Pero bueno, no podemos elegir un hiperplano a ojo. Hay que ir, digamos, con con unas cuentas, con con una matemática a elegir un hiperplano. Entonces, para hacer eso, primero vamos a definir el concepto de margen. Cada hiperplano tiene un margen. ¿Y cómo se calcula? Por ejemplo, este que está vertical, tomo la distancia de todos los puntos al

hiperplano, o sea, la distancia eh perpendicular, ¿no? De este punto al hiperplano, de este punto al hiperplano, de este, de este, o sea, de cada uno de los puntos de todas de las dos clases, la distancia del hiperplano. Y la distancia más chiquitita, ese es el margen. Por ejemplo, acá la distancia más chiquita es es esta distancia del punto azul que es casi cero.

00:27:01

Ise posgrados: Ese es el margen de este hiperplano. Y así cada hiperplano tiene su margen, que es la menor distancia a uno de los puntos de entrenamiento. Y entonces acá este que está dibujado acá es el del medio. Vuelvo para atrás, es este del medio. Era el mejor, perdón, era el que tenía el margen más grande, que en realidad ese va a ser nuestro mejor hiperplano. El que tenga el margen más grande. ¿Por qué? porque es el que va a quedar el que va a separar mejor las clases. Acá va a haber suficiente espacio como imagínense que si yo camino por acá no tengo obstáculos, no me choco con ningún punto y quiero que este espacio que está acá que estoy marcando sea lo más ancho posible para que no quede lugar a dudas que cuando un punto es azul es azul de verdad no tengo dudas, no está cerca del hiperplano, no voy a cometer errores, no me voy a confundir. Entonces, de todos los hiperplanos posibles, el que tenga el margen más grande, ese va a ser mi solución, la que yo voy a quar. El clasificador, el que llamamos maximal margin classifier, hace esto, encuentra este hiperplano que tiene el máximo margen y usa este hiperplano para clasificar todo lo que caiga de un lado del margen, no del hiperplano ahora ya, sino del margen.

00:28:22

Ise posgrados: Todo lo que caiga del margen para acá es eh magenta y todo lo que caiga del margen para allá es azul. ¿Se les ocurre alguna algún problema, algún alguna dificultad con esto o estamos bien? ¿O les parece que tiene sentido este clasificador?
Pa. Santiago Rodriguez Castro: Con esta definición estricta, parecería que solamente estamos armando el hiperplano con los puntos más cercanos de cada una de las dos clases y no tiene ninguna injerencia todos los que están más lejos. Okay.
Ise posgrados: Bien, eso no es un problema, sino que eso es parte de la definición del clasificador. De hecho, estos puntos que quedaron acá en el margen, estos tres puntos son los que se llaman vectores de soporte y son los que soportan al

hiperplano. ¿Y esto qué significa? Justamente lo que vos decías, cualquiera de estos puntos de entrenamiento, si yo los muevo más cerca, más lejos, los pongo recontra lejos, no me impactan para nada. El hiperplano sigue siendo el mismo. Los vectores de soporte son soportan a ese hiperplano y el hiperplano no se va a mover. Lo mismo con los azules, los puedo mover como quiera que el hiperplano va a estar ahí quietito. Ahora, cualquiera de estos que se mueva de su lugar, me mueven el al hiperplano.

00:29:41

lse posgrados: Es es parte de la definición. Está definido así. Tengo los vectores de soporte, el el hiperplano está definido o soportado por esos puntos y ya está. tiene algunos problemas esto, pero los vamos a ver ahora en un ratito, pero eso que decías es parte de la definición de de este clasificador. Bueno, esto es lo que acabo de decir, ¿no? Estos son los vectores de soporte. El hiperplano depende únicamente de esos, en este caso, esos tres puntitos. Podrían ser dos, podrían ser cuatro. En este caso son tres. Bueno, ¿y ahora cómo hacemos? O sea, tenemos las definiciones. Lo que queremos es el hiperplano que mejor se pare, que tenga el margen lo más ancho posible. Pero, ¿cómo lo encontramos? Para encontrarlo, lo que tenemos que hacer es resolver un problema de optimización que tiene dos partes. Por un lado, esta formulita que es la misma que venimos explicando desde hace tres slides, que es la fórmula. Esta es la fórmula del hiperplano y lo que queremos es que los puntos de la clase 1 y -1 estén alejados más allá del margen.

00:30:54

lse posgrados: Es decir, antes habíamos dicho que esto sea mayor que cero para que estén de un lado del otro hiperplano. Ahora lo que queremos es que sea mayor que m. O sea, queremos que los puntos estén después del margen, no queremos puntos acá dentro. un punto que esté más allá del margen de este lado va a ser magenta y más allá del margen del otro lado va a ser azul. Entonces, por un lado tenemos esto y por otro lado vamos a poner una restricción y es que la suma de todos estos coeficientes sea uno. ¿Alguno tiene alguna idea? Y acá si remontamos a análisis matemático. ¿Alguno tiene alguna idea de qué es esto? ¿Por qué se me ocurre poner esta cosa acá?
Alejandro Valle: Se parece a R cuadrado de regresión lineal.
lse posgrados: Se parece, pero no.
Alejandro Valle: La suma de las distancias al cuadrado,

Ise posgrados: Sí se parece una suma de un valor al cuadrado,
Alejandro Valle: Bra.
Ise posgrados: pero solamente se parece en eso. No, no es eso. En este caso
Gabriel Quiroga: Tendrá que ver con que sea ortanormal.
Ise posgrados: tiene que ver quién dijo eso?
Gabriel Quiroga: Si está bien.

00:32:08

Ise posgrados: Gabriel, tiene que ver, eh, sí, esto, si se fijan acá es un producto interno entre el vector B1, B2, B3, etcétera, y el vector, el puntito, cada puntito de mi set de entrenamiento, el X eh 1, x2, X3, es un producto interno. Y si yo separo los componentes, el mi punto de entrenamiento y el vector este de los B sub, este vector, el vector de los B sub es un vector perpendicular o normal al hiperplano, a la recta en este caso. Y si yo restrinjo que ese vector normal a la recta tenga norma uno, porque esta es la norma del vector, tenga norma uno, entonces esto lo puedo considerar como la distancia a la recta, la distancia perpendicular, ¿no? A la recta. Entonces ahí sí estaría hablando de que esto es una distancia, m es una distancia y esto cuanto más lejos está el punto más más eh mayor me va a dar este valor y más lejos voy a estar de ese margen. Es decir, esta esta restricción es para que la distancia esta dependa exclusivamente del de los valores eh x sub y no de los coeficientes b sub. Lo vamos a ir repitiendo esta fórmula varias veces más, así que si no les queda claro en esta slide vamos a volver a esta fórmula todo el tiempo.

00:33:40

Ise posgrados: Pero esa es la idea, esa es la idea de poner esta restricción acá, que esto realmente represente una distancia del punto de cada uno de los puntos a el margen de este o este. Y una cosa más, fíjense esto. Si yo agarro la ecuación esta, la misma que venimos arrastrando de de las slides anteriores, agarro esta ecuación y la igualo a cero, es decir, que estoy parada sobre el plano y la multiplico por un valor K, esto me va a seguir dando cero. Entonces, si yo distribuyo el K acá dentro de esta suma, voy a tener nuevos coeficientes B, B sub, que me van a cumplir la ecuación, la desigualdad o la igualdad en este caso. Con lo cual, esto me está diciendo que hay infinitas soluciones. Yo lo que quiero es una solución. Por eso también es que ponemos la restricción para encontrar una única solución. Y todo esto que está acá no es ni más ni menos que lo que acabo de lo que acabo de decir. Tenemos esto para que la norma sea uno, para que esto sea una distancia y para tener una única

solución. Y acá para el curioso que le interese, hay una referencia eh bibliográfica para ir a ver toda la explicación del trasfondo de toda este problema de optimización.

00:35:05

Ise posgrados: Pero el que no le interesa o tiene quemada la cabeza ya a esta altura del de la clase que apenas pasamos tres o cuatro slides, se puede quedar simplemente con la idea que tenemos el hiperplano y con esta formulita lo que estoy viendo es qué tan lejos yo estoy del hiperplano. Y si estoy, si la distancia a la cual estoy es mayor que m, yo con seguridad puedo decir que ese punto que yo reemplacé en la fórmula pertenece a una clase o pertenece a la otra. Y ahora, volviendo a la eh al tema de, bueno, tenemos un hiperplano, como lo planteamos, como lo acabamos de definir, ¿no? Que es el mejor, el que mejor separa las clases, el que tiene el margen más grande, etcétera. Eh, el tema con este hiperplano es que es muy sensible al set de entrenamiento. Lo que les decía, si este puntito azul se mueve un poquito, el hiperplano se mueve. Acá, por ejemplo, aparece un punto azul acá entrenamiento. Supongamos que en vez de este, de repente el set entrenamiento es este. Y ya el hiperplano no es el que dije, va a ser este otro que es bien diferente porque mi hiperplano tiene que separar perfectamente las dos clases. Así que este no me sirve.

00:36:19

Ise posgrados: Ahora es este. Entonces es muy sensible el modelo este al set de entrenamiento que yo tenga. Y otro problema que tiene es que yo necesito poder separar perfectamente con una, en este caso de dos dimensiones, con una línea. Y acá en este ejemplo acá es imposible. O sea, no hay una línea que me separe las dos clases, no no existe una, no hay no hay solución, no se puede. Entonces, para superar esas dos cuestiones, vamos a ver una versión un poquito mejorada de este modelo y es el que se llama de eh margen suave o margen blando, como lo quieran traducir. es un eh es un clasificador que eh no es tan estricto, por eso el nombre cambia el nombre del clasificador. Este esta nueva versión va a permitir que algunas observaciones estén del lado, entre comillas, incorrecto, que algunas observaciones estén mal clasificadas. Vamos a ser un poquito permisivos, un poquito nada más, no mucho porque si no se nos va se nos va de las manos el clasificador, pero vamos a permitir un poquito de errores. ¿Qué vamos a permitir? Esto sería como un zoom, ¿no? Del de los ejemplos. Lo miro muy de cerca. Este es mi hiperplano y esto es el

margen.

00:37:50

Ise posgrados: ¿Sí? Y de este lado tengo una clase y de este lado tengo la otra. Y acá lo que estoy permitiendo es que algunos puntos estén entre la recta, o sea, el hiperplano y el margen. Estoy permitiendo que haya un punto acá, este ocho, en el modelo original no permitíamos nada. Acá esto tenía que estar libre de obstáculos, libre de puntos. Acá estoy permitiendo y acá también estoy permitiendo que el uno esté acá dentro. Eh, estos son los vectores de soporte que están justo ahí. El uno está dentro, el ocho está dentro. Y en este otro ejemplo estoy incluso permitiendo puntos mal clasificados. Este 11 debería estar de este lado. Acá tengo todos los magentas, pero se fue del otro lado. Se coló del otro lado. Y este 12 también está reljos del resto de los azules. Pero bueno, yo ahora lo voy a permitir a eso con ciertas restricciones. No voy a permitir que todo esté mal porque si no el clasificador al final es cualquier cosa, no sirve para nada. Voy a permitir contados errores, ¿no? Ahora vamos a ver cómo lo limitamos, pero eh esto es como más permisivo que el original.

00:39:02

Ise posgrados: Para construir entonces esta versión más flexible, lo que vamos a hacer es modificar el problema de optimización agregándole regularización. ¿Cómo es eso? Tenemos acá lo mismo que antes, ¿no? Tenemos la restricción esta de la norma de los coeficientes. Tenemos acá nuestra desigualdad como la teníamos antes. Esto es mayor o igual que m. Y ahora le agregamos esto acá 1 menil para cada uno de los puntos de entrenamiento y le agregamos esta condición acá. ¿Y qué es todo esto? Por un lado, estos sub me van a permitir que las observaciones estén en el lado incorrecto. Eso que les mostré en la slide recién, que las observaciones estén o entre el hiperplano y el margen o incluso del lado equivocado. Eso lo voy a regular, el qué tanto voy a permitir lo voy a regular con estos SUV. Y por otro lado tenemos acá un hiperparámetro del modelo que es este C, que me va a imponer un límite de cuánto me puedo equivocar. O sea, los subí me permiten equivocarme, pero esta desigualdad me dice hasta dónde me puedo equivocar. Y ahora vamos a ver un ejemplito con numeritos para que se entienda más eh cómo juega esta variable, estas variables, porque son muchas.

00:40:25

Ise posgrados: El SVI es uno para cada uno de los puntitos de entrenamiento y un C que es un único valor, C que es un hiperparámetro. Bueno, acá tenemos otra vez la fórmula copiada. Esto es lo mismo de recién. toda la desigualdad mayor o igual que m multi mulplicada por 1 men es. Y acá la segunda restricción. Fíjense, si sub, si todos los sub iguales a cero, yo no permito ningún error. Sería que yo no permito ningún error. Si es cero, esto es igual a m, ¿no? Y todo esto es lo mismo que tenía antes. O sea, eso vi igual a 0 no me cambia nada. Es el mismo clasificador clasificador que tenía originalmente. No cambia nada. Todos mis puntos están del margen para allá o del margen para acá y listo. O sea, ese es el caso original. Ahora, si es sub está entre 0 y 1, este esta parte de la desigualdad, ¿entre qué valores se mueve?
Gabriel Quiroga: entre 0 y m.
Ise posgrados: entre 0 y m. Eso significa que el punto va a estar va a ser eh, o sea, esta expresión me va a dar un número que va a ser mayor o igual que un número entre 0 y m.

00:42:01

Ise posgrados: Eso significa que el punto puede estar acá en este pedacito o en esto, o sea, acá que esto entre 0 y m significa que el punto puede estar acá. entre cero sería sobre el hiperplano y m sería sobre la sobre el margen. Cuando es sub está entre 0 y 1, el punto, o sea, el punto, si yo lo reemplazo acá en esta desigualdad puede estar, le estoy permitiendo que esté en cualquier lugar de por acá. Y si es mayor que uno, entonces ya le estoy permitiendo al punto que esté en cualquier lado. Por ejemplo, este 12 no está del lado de su clase, está del otro lado. O sea, según qué grande o chiquito sea SUV, es lo que yo le estoy permitiendo a los puntitos estos de entrenamiento. Y ahora viene la otra parte. Esto, esta sumatoria lo que está haciendo es ponerme un límite a la cantidad de errores, porque si yo eh permito que todos los puntos estén en cualquier lado, el clasificador se, o sea, realmente no va a clasificar nada, va a ser cualquier cosa. Yo quiero decir, bueno, permito que un punto, que dos, que tres puntos estén mal clasificados, pero no todos los puntos, porque eh no tendría sentido un clasificador donde todos los puntos están donde se se les ocurre.

00:43:28

Ise posgrados: Yo con esto le pongo un límite. Supongamos que este esta división es 10. Esto es 1 sobre C porque el hiperparámetro del del modelo en Python en la biblioteca es C, pero la desigualdad compara contra 1 div. Por eso está raro. Así está como el C en el denominador. Pero supongamos que esto es 10, o sea, que C es un décimo. Supongamos que esto es 10. La suma de todos los subí no puede ser mayor que 10. Y con eso yo ya estoy limitando cuántos de los puntos de entrenamiento pueden estar del lado equivocado. Si los puntos están todos en su lugar, yo tengo como permiso para que un punto esté del lado equivocado y el SUV sea 0,5 y la sumatoria de los SUV no va a estar muy lejos de este límite. Entonces, yo tengo tres puntos equivocados. cuando sume acá todavía esto va a ser mucho menor que 10 y así, o sea, eh la cantidad de errores y el tipo de error se va se van a ir acumulando según el valor de sub, se van a ir acumulando, acumulando, pero yo no voy a permitir que toda la suma de esos SUV sea mayor que este 10 que por dar un ejemplo, ¿no?

00:44:46

Ise posgrados: Si C fue fuese 0,1. ¿Tiene alguna pregunta con esto? Sí, Gabriel.
Gabriel Quiroga: Sí, ahí en el segundo el segundo íem que dice si 1 sobre C mayor a 0,
Ise posgrados: Sí.
Gabriel Quiroga: no debería ser siempre mayor a cero es siempre positivo.
Ise posgrados: Eh, sé siempre positivo. A ver, si tenés razón,
Gabriel Quiroga: No.
Ise posgrados: es siempre positivo. Eh, capaz que habrá querido decir, a ver, no más que uno sobre C pueden estar del lado, ¿eh? Sí, hacé de cuenta, después lo pienso bien, pero hac de cuenta que esto no está porque en verdad es siempre positivo. Sí, sí,
Gabriel Quiroga: era una ser.
Ise posgrados: en realidad no. lo que quizás es, no sé, lo estoy pensando como en voz alta ahora. Lo que está queriendo decir es que si yo tengo esta restricción, no más que uno sobre observaciones pueden estar del lado equivocado. A ver, ¿será eso? Ahora no quiero no quiero decir una pavada, pero pero es verdad. Así sé siempre positivo. Una cosa, bueno, después pienso bien esto que habrá querido decir acá, pero es verdad que es siempre positivo esto.

00:46:04

Ise posgrados: Y una cosa es acá, si se es chiquito, este esta división es muy grande, entonces estoy permitiendo más más este más errores. Eso es lo importante, que si sé más chiquito, o más grande estoy permitiendo más o menos errores.
Cesar Orellana: Yeah.
Ise posgrados: Eso lo tenemos que tener en cuenta porque ese es un parámetro que le vamos a pasar a la función cuando entrenemos este modelo. El caso original, el que no permitía errores tiene todos los sub y c eh sí. ¿Quién habló? Eh,
Luis Ali: Sí, perdón,
Ise posgrados: Mariana.
Luis Ali: me había quedado una duda nada más de lo que estaba leyendo.
Ise posgrados: Sí, sí,
Luis Ali: C dice C es un hiperparámetro, o sea,
Ise posgrados: sí.
Luis Ali: C es la cantidad de observaciones o 1 sobre C es la cantidad de observaciones.
Ise posgrados: No, ninguno de los dos. O sea, C es un hiperparámetro que me va a decir qué que me va a limitar la cantidad de errores que puedo tener y del tipo de errores, porque eh suponente que C es 0,1, entonces esto es 10. La suma de los SUV no puede superar a 10. Entonces, si yo digo, bueno, el e tengo 10 observaciones con un e cercano a uno.

00:47:18

Ise posgrados: Si yo sumo todos los subí, eso me va a dar casi 10. Entonces, yo puedo tener hasta 10 observaciones del lado equivocado. No voy a poder, no voy a permitir más porque ya con 10 ya llegué acá al límite máximo posible que yo le permití a mi modelo.
Luis Ali: Okay. Entonces, C, ¿qué sería?
Ise posgrados: Sí, claro que lo único que, o sea, lo único lo que para lo que sirve es para decir permito más errores o permito menos errores. Si s es chiquitito, este número es muy grande, entonces estoy permitiendo más errores. Si C es muy grande, esto es muy chiquitito. Incluso si C es recontra grande, esto es casi cero. Lo que significa que no estoy permitiendo ningún error, que es el caso original. En la notebook por ahí capaz que se entiende más porque ahí vamos a a probar con distintos valores de C.
Luis Ali: Bueno, muchas gracias.
Ise posgrados: Y nada, ¿quién más? Mariano habló, ¿no? Luis, ¿tenías una?

Mariano Jauffroy: Eh, sí,
Ise posgrados: Sí.
Mariano Jauffroy: era un poco la misma duda, este, porque se me está escapando un poco la diferencia entre E y C,

00:48:21

Ise posgrados: Eh,
Mariano Jauffroy: porque hay dos y es casi lo mismo.
Ise posgrados: sí, es que es no es un hiperparámetro. Subi es cuánto se equivoca cada observación individual. Si yo tengo 100 puntos, voy a tener 100silon, 100 eh valoritos acá chiquititos. Si un punto está el lado correcto, este es E sub va a ser cero. Si un punto está del otro lado, este es sub va a ser dos. ser, no sé, un número grande mayor que uno. O sea, de este es distinto este valor para cada uno de los puntitos, pero no es un valor que yo le digo, "Te vas a equivocar tanto." Es un es un valor que va a depender de dónde está el hiperplano. Eh, los errores van a ser distintos de cada uno de los puntos, pero no es de ninguna manera un hiperparámetro, es un valor que va a depender de dónde cae cada punto. En cambio, el C es un hiperparámetro. Yo al modelo le voy a decir, bueno, e te voy a entrenar con C = 1, con C = 100,000. es un hiperparámetro que yo le voy a pasar al modelo y el hiperparámetro lo que va a hacer es limitar o permitir determinada cantidad de errores.

00:49:28

Ise posgrados: Es decir, el modelo va va a ir buscando un hiperplano, va a calcular de qué lado quedan cada cada uno de los puntos, va a hacer todas las cuentitas y se va a fijar que yo no me esté pasando de esta de este límite que le puse acá.
Alejandro Valle: Y al aceptar esos errores, ¿qué hacemos con esos errores después? O septan y ya.
Ise posgrados: Se aceptan y se aceptan y ya. Acá fíjense, eh, el valor de C es el que me va a decir o o según qué valor de C yo le ponga, voy a tener determinada cantidad de puntos acá dentro. eh entre el margen y hiperplano o del lado equivocado. Cuanto más grande sea el C, más restrictivo va a ser esto y menos puntos voy a tener acá en el medio. Si el C es recontra re grande, no voy a tener nada acá dentro y va a ser el caso original, el primero de todos. O sea, cuanto más grande es el C, más restrictivo va a ser el eh lo que yo permita acá dentro. Y una cosa, tener en cuenta que en este modelo todos los puntos que están acá dentro son vectores

de soporte, no solamente los que están sobre el margen, todos estos también son vectores de soporte.

00:50:53

lse posgrados: ¿Y por qué? Porque si yo los muevo, cualquiera de estos que yo mueva hacia afuera, hacia adentro, hacia el otro lado, me están modificando el error, el silon asociado y por lo tanto me están modificando la sumatoria. que yo tengo ahí de de condición, voy para atrás, me están modificando. Si yo muevo un punto de esos que están ahí, se mueve esto. Entonces, yo tengo que estar controlando todo el tiempo que esto no supere el tope este que le puse acá. Por lo tanto, todos estos se consideran vectores de soporte también porque juegan ahí en en la búsqueda de ese hiper hiperplano. Y nuevamente todo lo que esté afuera no tiene importancia para el modelo. Se pueden mover todo lo que quieran estos, el hiperplano va a seguir ahí, pero los que están adentro si se mueven me van a estar condicionando. No, no necesariamente. Si se mueven por ahí el hiperplano ya no es el mismo y se va a mover porque yo no puedo mover libremente esto. Si yo agarro este azul y lo muevo para allá, a lo mejor me pasé de largo en ese en esa sumatoria menor o igual que 1 sobre C. Entonces ahí ya ese hiperplano no me sirve.

00:52:07

lse posgrados: El hiperplano será otro. Sí, Gabriel.
Gabriel Quiroga: Entonces, C lo que limita no es el número de observaciones que se cruzan del plano, sino que es lo que limita es la sumatoria de los errores de esas que se
lse posgrados: Exacto. No es la cantidad de puntos,
Gabriel Quiroga: cruzan.
lse posgrados: sino la sumatoria de los errores de esos puntos que están en cualquier lado. Sí.
Gabriel Quiroga: Bien,
lse posgrados: Sí.
Gabriel Quiroga: gracias.
lse posgrados: Es decir,
Gabriel Quiroga: Buenas noches. Gracias.
lse posgrados: que quizás es lo mismo tres puntos acá en este pedacito que un solo punto del lado incorrecto del plano. O sea, no es la cantidad de observaciones, sino es una combinación de la cantidad de observaciones y qué tan equivocadas están,

digamos, qué tan mal posicionadas están en el plano, qué tan lejos están de del hiperplano. Bueno, nuevamente el valor de C juega acá en eh lo que decíamos que si el C es chiquitito, o sea, el original acá el margen es muy grande, tengo muchos vectores de soporte, pero también tengo menos exactitud y un C. Eh, si el C, perdón, dije, no sé si dije si el C es chico, si el C es muy grande, en este caso me pasa todo lo contrario, más varianza, pero también eh yo acá tengo más exactitud y tengo muchísimos menos eh me equivoco mucho menos en este caso.

00:53:49

Ise posgrados: Hasta ahí no pretendo que entiendan perfecto todos los conceptos y todas las cuentitas, pero que más o menos entiendan la idea del clasificador, porque eso es lo más importante a la hora que de hacer una notebook, no vamos a hacer todas estas cuentas. Lo importante es entender que C. Le vamos a pasar un parámetro C, entender qué es lo que estamos diciendo, ¿no? Estamos eh inventando, voy a jugar con C = 1000, C = 1. ¿Y qué es? O sea, lo importante es saber qué es ese que le estamos diciendo al al vector, al perdón, al a la función, al clasificador. Hay una mano ahí. Sí, pues no veo quién es, pero veo una mano levantada.
Pa. Santiago Rodriguez Castro: Sí, perdón, me queda una duda. A ver si si estoy entendiendo bien.
Ise posgrados: Sí.
Pa. Santiago Rodriguez Castro: Un valor chico de C permitiría un ysilon más grande y a medida
Ise posgrados: una sumatoria más grande de épsilon,
Pa. Santiago Rodriguez Castro: que bien
Ise posgrados: o sea, más errores sería o errores más grandes. Sí.
Pa. Santiago Rodriguez Castro: y a medida que se va achicando C se aproximaría la optimización a de alguna manera minimizar la suma de todas las distancias, de todos los puntos con con un hiperplano.

00:54:58

Ise posgrados: A medida que se agranda C, se agranda C, se achica el límite de esa sumatoria. C es el denominador del del límite,
Pa. Santiago Rodriguez Castro: Claro.
Ise posgrados: pero sí, sí, sí,
Pa. Santiago Rodriguez Castro: Okay.
Ise posgrados: sí, es así.

Pa. Santiago Rodriguez Castro: sería sería un margen mucho más comprimido y la línea podría Vale.
lse posgrados: Claro, hasta el punto tal que hasta el punto tal que eh llegas al al clasificador original que es super estricto y no permite ni un solo error. Si el C es super grande,
Andrés Pablo García: Yeah.
lse posgrados: no permites ningún solo error, ni un solo punto en el lado equivocado del del de los márgenes. Sí. ¿Quién más? Había otra
Andrés Pablo García: Si yo pregunta la variación
lse posgrados: mano.
Andrés Pablo García: variar, ¿qué me afecta? ¿Solo digamos el me termina afectando el margen o me afecta también la posición del hiperplano? M.
lse posgrados: Las dos cosas va buscando y va acomodando.
Andrés Pablo García: Ah, es como que el algoritmo va buscando cómo moverse,
lse posgrados: Claro, el hiperplano.
Andrés Pablo García: claro,
lse posgrados: Sí.
Andrés Pablo García: las dos cosas para que se para que se cumpla la condición.

00:56:09

lse posgrados: Sí.
Andrés Pablo García: Ok.
lse posgrados: Igual no se enamoren del margen porque ahora nos vamos a sacar de encima esa variable, pero lo importante es que se entienda ese concepto. Sí, sí, sí. Con ese yo voy jugando con eso y voy viendo también qué tan permisiva soy con los errores que le permito al al clasificador. Eh, y ahí vamos a deshacernos del margen ahora para simplificar todas estas cuentitas. Eh, fíjense esto nuevamente. Todo esto que está acá arriba es lo que ya dijimos antes, ¿no? Lo mismo de antes, la formulita esta, la desigualdad. Esto es mayor o igual que m multi mulplicado por 1-sil. Esta es la restricción con el parámetro y el hiperparámetro C. Y esta es la condición que no la vimos en la la idea de recién, pero la vimos antes, que es la condición que me limita los coeficientes B para que ese este vector tenga norma uno. Y si este vector tiene norma uno, esto realmente me representa la distancia de cada eh de cada vector xubi al hiperplano. Todo esto lo vamos a reescribir, o sea, no vamos a incorporar conceptos nuevos, simplemente lo vamos a reescribir de otra manera.

00:57:24

Ise posgrados: Esto lo vamos a escribir así. La norma de B es igual a 1. Es un cambio de notación. Y esto, como decíamos antes, esto es un producto interno. También cambiamos la anotación y lo escribimos así, ¿sí? O sea, de acá hasta acá lo único que hay es cambio de notación. ¿Y qué vamos a hacer ahora? Vamos a hacer unos truquitos. Am lo vamos a definir como uno sobre la norma de B. Independientemente de cuál es B, M para nosotros ahora va a ser uno sobre la norma de B. No nos importa en verdad esto, eh, cuál era M, porque el modelo va a ajustar el mejor el mejor hiperplano e y nosotros ahora queremos que se cumpla esto, o sea, no no nos interesa. Nosotros no nos importa cuando entrenamos cuánto vale m, no le vamos a preguntar al modelo, no vamos a usar para nada ese número. Así que eh podemos redefinirlo. Eh y esto va a funcionar igual. m para nosotros ahora va a ser 1 sobre norma de B. Y otra cosa que vamos a hacer es sacarnos de encima esta restricción, o sea, no la vamos a usar más, no vamos a limitar más los coeficientes.

00:58:44

Ise posgrados: Pero, ¿qué pasa si nosotros no limitamos los coeficientes? Esto ya no es una distancia. dijimos que era una distancia si la suma, o sea, la norma de B era uno. Pero si nosotros nos eh nos olvidamos de esa restricción, para que esto sea realmente una distancia, tenemos que normalizar esto y lo normalizamos dividiéndolo por la norma de B. Se parece un trabalenguas, pero en verdad lo que estamos haciendo acá es normalizar esto para que esto sea una distancia y para no tener que depender de esta restricción. O sea, esta restricción nos vamos a olvidar, no la vamos a tener más en cuenta. En vez de restringir la norma de B, vamos a eh normalizar esta esta ecuación dividiéndola por la norma de B. Digamos que era lo mismo, o hacer esto con esta restricción o hacer esto, un producto con los B eh sin ningún límite, pero normalizado. Y una vez que tenemos esta desigualdad, cancelamos la norma de B y nos quedamos con esto. Y esto es lo que el clasificador va a tener que resolver. Nos quedamos con esto. Y acá no está copiado, pero esto no nos olvidamos.

01:00:05

Ise posgrados: Esto sigue estando la el límite este de los errores menor o igual que 1 sobre C. Esto sigue estando. Lo que nos sacamos de encima fue esta restricción de

acá arriba. Nuestro modelo final es esta desigualdad. Todos los puntos que cumplen esta desigualdad van a pertenecer a la clase un o a la menos1. Y siempre voy a tener que eh voy a tener estos épsilon limitados por esta sumatoria que está acá arriba. Esta es la última y definitiva cuentita que va a tener que resolver el clasificador. Vamos a la notebook. Así ponemos un poco, bajamos a tierra todo esto. Bueno, eh, se ve bien ahí. Tenemos las bibliotecas de siempre, eh la matriz de confusión que la vamos a usar. Y acá tenemos el SBC, que es la eh el módulo de SBM, perdón, acá que es el módulo de Cycl que vamos a estar usando. SBC es support vector machine, que es eh el módulo, el perdón, la función que vamos a estar usando para para entrenar este modelo. Y vamos a empezar por el el H margin, el que es super estricto y no permite ningún tipo de errores. Primero vamos a hacer un acá un dataset de sintético, datos inventados, perfectamente separables.

01:01:55

Ise posgrados: Tenemos acá y acá y acá muy fácilmente vamos a poder poner un hiperplano que separe los dos grupos sin ningún error en el medio, ¿no? No lo vamos a hacer nosotros, lo va a hacer el modelo, pero generamos estos datos a propósito que sea superfácil de separarlo en dos. Acá, como siempre, tienen un link a la a la documentación. Y acá es donde vamos a entrenar el modelo. Fíjense que yo le digo SBC. Este es el modelo, el primero de todos, el que no tenía, no permitía errores. Yo lo único que quiero es que me metas un hiperplano ahí que me separe bien. Igual, de todas maneras, yo le tengo que pasar el hiperparámetro C porque es un, perdón, el parámetro de la función, el parámetro C se lo tengo que pasar. Entonces, ¿qué hago? Le paso un valor super grande para que no me permita errores. Fíjense que acá dice 1 por e a la es 1 e5, ¿lo ven? Es sería como eh 10,000 o 100,000, ¿no? Ceros. Es un número gigante, o sea, no voy a permitir errores.

01:02:59

Ise posgrados: 100,000 sería se igual a 100,000 y le paso esto. Lo vamos a ver en un ratito por ahora. Eh, ignoren, hagan de cuenta que no vieron esto, pero eso lo vamos a ver en un ratito. Le pasan KN lineal, bueno, en verdad eh lineal es que vamos a pasar alguna recta, se lo tienen que pasar como parámetro. Entonces, un C hiper grande para que no me permita errores y kernel lineal. Pero como les digo, esto lo vamos a ver en un ratito qué significa. entrenamos y acá dibujamos el resultado del entrenamiento. Fíjense que acá yo le puedo pedir a a la variable donde guardé todo el modelo entrenado, le puedo pedir los vectores de soporte. Si los pido acá para

dibujarlos. Sí, acá están los vectores de soporte, las líneas, el hiperplano que me separa perfectamente. Acá en el medio no tengo ni una sola observación, no hay nada mal clasificado, o sea, está todo fácil y perfecto. Este es el primero de todos los los ejemplos que vimos. Sigo bajando y acá genero un dataset de de test, o sea, poquitos poquitos datos, pero con la misma distribución de los datos sintéticos originales.

01:04:16

Ise posgrados: Hago la predicción, hago la matriz de confusión y me da pero perfecta, perfecta, porque son datos perfectamente de juguetes que a propósito los hice bien separados, entonces no hay forma que yo me equivoque. Yo estos datos se los mandé al clasificador y el clasificador puso perfecto cada punto donde correspondía porque acá arriba el hiperplano pasaba bien por acá, no hay forma de que se equivoque. Por supuesto, esto en la vida real no les va a pasar nunca. Pero bueno, ese es el clasificador, el primero de todos con un C super grande. Por lo tanto, eh 1 sobre C me va a dar un número super chiquito y es decir que no voy a permitir ni un solo error. Y ahora sí vamos a un caso un poco más real, que es el que me permite algunos errores, que es el soft margin. Así que generamos otros datos, pero esta vez un poquito superpuestos, cosa que si yo hago un hiperplano, por ejemplo, pasa por acá, voy a tener tres o cuatro puntos magenta del lado azul y viceversa. Perfectamente no lo voy a poder separar, es imposible, están mezclados, pero podemos hacer el mejor esfuerzo para que eh pase un hiperplano para acá y sean poquitos los errores. Primero que nada, lo voy a entrenar con los mismos parámetros de antes, ¿no?

01:05:42

Ise posgrados: Con un C super grande para no permitir errores. ¿Y qué va a ser? Va a ser cualquier cosa, porque este va a ser mi hiperplano. Acá va a estar lleno de puntos mal clasificados. Esto realmente es malísimo, ¿no? No me sirve. Yo eh si quiero clasificar con este clasificador me va a funcionar bastante mal. Y entonces empiezo con variantes. Acá pruebo con C = 10. Y se supone que esto es un poquito mejor que el de arriba. Sigo bajando y lo que voy a hacer ahora es buscar mejor hiperparámetros con el grid search. Esto es lo que vimos el otro día. Si se acuerdan, con grid search le pasamos eh un como un Jason de acá de todas las combinaciones de parámetros que quiero que pruebe. Acá nuestro hiperparámetro es C, entonces le pido que pruebe con C = 0,001. igual a 0,01 = 01. Bueno, hasta C =

100. Le paso acá una variedad de valores de C. Le digo que mi eh que mi métrica la que quiero comparar es accuracy y bueno, que entrene a ver qué le da mejor.

01:07:08

Ise posgrados: Y acá el GD Search me dijo, bueno, el mejor hiperparámetro para este set de entrenamiento, para estas combinaciones que me diste, es C = 0,1. O sea, con C 0,1, la desigualdad esa que habíamos visto en de los errores permitidos me da menor o igual que eh 10, o sea, 1 sobre C. Acá lo que le estoy preguntando, lo que le estoy diciendo es, bueno, eh, no entreno de vuelta, ya el GRD Search ya me entrenó el modelo, entonces yo acá ya le pido los resultados. y lo dibujo acá. A simple vista, capaz que parecen todos los gráficos iguales, pero se supone que este es el mejor con el dataset que yo le di, este es el mejor eh resultado, el mejor hiperp hiperplano que encontró. Por supuesto, acá hay un montón de azules que están en este en este pedacito entre el hiperplano y el margen. Hay un poquito de azules acá en el lado equivocado y lo mismo los magenta. Esto es inevitable porque ya los datos están mezclados. No, no puedo hacer magia con el hiperplano. Magia no se puede hacer. Lo que lo que puedo hacer es minimizar la cantidad de de errores.

01:08:33

Ise posgrados: Sigo otra vez lo mismo. Genero datos de test, hago la predicción, la matriz de confusión y esto es lo que tengo como resultado. Y con una exactitud del 70%. Fíjense que el original, el primero de todos y el segundo que probé, la función es la misma. Estoy usando siempre la misma, solo que le cambio los parámetros. Estoy jugando con el parámetro C. Se lo tengo que pasar siempre, aunque yo quiera el estricto, el que se para perfectamente los dos las dos clases, yo igual le tengo que pasar el C. Le paso un C super grande para que no me permita errores. Sí, hay una pregunta.
Andrés Pablo García: Sí. Em, si vos eh levantás el C admitís menos errores, ¿no? Bien,
Ise posgrados: Sí.
Andrés Pablo García: puede pasar que a nivel acá ya haciéndolo en el notebook y a nivel algoritmo, le subas demasiado el C y tengas un set de datos que no lo pueda cumplir y te tire algún error o siempre te va a devolver algo.
Ise posgrados: que te va a dar algo que te va a dar una precisión baja, o sea, siempre te va a dar algo, te va a dar un hiperplano, pero por ahí el hiperplano, o sea, la solución es mala, no te va a dar error, te va a dar un hiperplano, pero la cuando vos

predigas con ese con ese modelo, te va a andar mal.

01:10:02

Andrés Pablo García: Okay. Pero es como si lo saturaras de alguna forma porque le estás estás pidiendo un mínimo error que no te lo puede dar porque no es posible,
lse posgrados: que no va a poder darte. Claro.
Andrés Pablo García: te va a hacer lo mejor que pueda.
lse posgrados: Sí,
Andrés Pablo García: Ah.
lse posgrados: sí, Gabriel.
Gabriel Quiroga: Eh, en el caso este, el de del margen suave, los puntos que cruzan erróneamente el hiperplano no deberían pasarse más allá del margen, o sea, debería estar sí o sí dentro del margen o puede ser que se
lse posgrados: No, en realidad se pasan, fíjate que se pasan.
Gabriel Quiroga: salga.
lse posgrados: O sea, yo tengo más, esta es mi zona magenta de la clase magenta. Eh, acá ya están un poquito mal porque yo originalmente no quería que pasen de, o sea, que esta franca la quiero vacía, no está vacía. Y estos que están acá se están pasando de largo para el otro lado. Yo lo voy a permitir.
Gabriel Quiroga: Claro,
lse posgrados: Lo que no voy a permitir es que la suma de todos los errores estos supere 1 sobre
Gabriel Quiroga: perdón.
lse posgrados: C.
Gabriel Quiroga: Okay. Pero entonces yo, por ejemplo, yendo hacia abajo, podría tener un puntito celeste que se salga del

01:11:09

lse posgrados: Sí, sí, sí,
Gabriel Quiroga: margen.
lse posgrados: sí, sí, sí.
Gabriel Quiroga: Okay. Entonces, ¿para qué función cumpliría el margen en este tipo de modelo?
lse posgrados: El margen te está limitando, o sea, eh el margen el margen te está te está definiendo dónde está el hiperplano, o sea, ¿hasta dónde dónde está la división de las dos clases, mejor dicho, el margen lo que está diciendo es dónde dónde está

la frontera entre las dos clases. el ancho de esto, lo que te está diciendo o lo que te está restringiendo es las es la de alguna manera la suma esa la suma del la sumatoria de los y ésilon menor que 1 sobre c depende de de este margen también, o sea, está todo atado, no no es que es independiente, porque si este margen fuese más grande, más chiquito, la sumatoria esa te va a dar diferente. Si este margen estuviera acá, habría muchos más errores en verdad. Si este margen está reljos, eh, perdón, si este margen estuviera acá, este habría menos. Lo dije al revés, perdón. Si este margen estuviera acá chiquitito, estos azules no estarían errados, estarían bien.
Gabriel Quiroga: Ah,
lse posgrados: Se te modifica esa sumatoria.

01:12:32

Gabriel Quiroga: si los puntos están dentro del margen significa que no no se clasificaron para ningún lado. estarían mal
lse posgrados: Si están dentro,
Gabriel Quiroga: siempre.
lse posgrados: ese está entre 0 y 1. O sea, con este margen que está dibujado acá, todos estos azules tienen asociado un épsilon entre 0 y 1. Y estos azules tienen un épsilon mayor que uno asociado.
Gabriel Quiroga: Ok.
lse posgrados: Cada puntito tiene asociado un épsilon. El C, acordate esa fíjate esa slide que decía C 1, C2. Había cuatro versiones de C. Según el valor de C, este margen va a estar más lejos o más cerca del hiperplano. Entonces, en este ejemplo puntual que estamos viendo acá, todos estos puntos azules tienen cada uno tiene un épsilon asociado entre 0 y un y estos azules que están acá tienen un épsilon mayor que uno y el magenta al revés. Estos magentas que están acá tienen un épsilon subida asociado que está entre 0 y 1 y estos tienen un épsilon mayor que uno y estos que están por afuera eh no tienen errores, están bien clasificados y estas también. Es como que se mueve todo junto, digamos, ¿no? No es que es una cosa independiente de la otra.

01:13:39

Gabriel Quiroga: Ok.
lse posgrados: Para permitir menos errores, este margen, yo permitir menos errores, este margen estaría más cerquita, estaría por acá.
Leonardo Villalva: Ah.

lse posgrados: Y este y este también porque es simétrico, no estaría así super angostito si yo no permitiera muchos errores. Facundo.
Facundo Lucianna: Sí, ahí si querés religo más. E recuerden que el margen es a nivel de entrenamiento, ¿no? Una vez está entrenado ya siempre plano para arriba, para otro lado, ya. Pero el margen ahí es son aquellos del misma clase que están en la zona que no debería estar. O sea, si volvemos al clasificado original de margen, no debe haber nadie en ese margen. Esa es la regla que habamos puesto. Acá decimos, bueno, dejamos que algunos se equivoquen, se equivoquen entre comillas, ni siquiera es que se equivoquen, sino que estén dentro de la misma de la misma piper plano,
Gabriel Quiroga: Ahí.
Facundo Lucianna: pero que estén dentro del margen. Por eso hay un margen ahí. es que y después están los otros estamos directamente aquellos que eh directamente clasificamos mal en pos de que cuando vayamos a un set un set set de test o vamos a usarlo el modelo alter un poco regularización de toda

01:14:58

lse posgrados: Gracias.
Facundo Lucianna: la vida, entonces hacer un poco más duro entre comillas y no se tanto bien los datos de entrenamiento,
lse posgrados: ¿Hay
Facundo Lucianna: podemos dar mejor mejores métricas, digamos, mejor generalización
Gabriel Quiroga: Bien, gracias.
lse posgrados: otra pregunta? Ve una mano, otra
Leonardo Villalva: Sí. Eh, recordando al principio creo que habíamos mencionado que el hiperplano se calculaba
lse posgrados: mano.
Leonardo Villalva: maximizando el margen, o sea, el margen aparece en el primero de los casos, en el más rígido incluso. Me parece que es soporte para calcular el hiperplano, ¿no? O sea,
lse posgrados: Sí buscabas un plano que maximizara el
Leonardo Villalva: después se lo Claro.
lse posgrados: margen. Es en el en el estricto de Sí,
Leonardo Villalva: Exacto.
lse posgrados: sí.
Leonardo Villalva: Exactamente. Después se vuelve permisivo con respecto al margen,
lse posgrados: Sí,

Leonardo Villalva: pero me parece el margen es para eso, es para para calcular el hiperplano.
Ise posgrados: para delimitarte. Claro, en realidad sí es para calcular el hiperplano y para delimitarte esa frontera de dónde
Leonardo Villalva: Ok.
Ise posgrados: vos estás clasificando bien y dónde estás permitiendo los errores.

01:16:11

Facundo Lucianna: Claro, sí,
Leonardo Villalva: No.
Facundo Lucianna: sí son el que al fin y al cabo es verdad en el sentido de que son aquellos el margen termina dando los vectores soporte que son los que termina formando la fórmula para el hiperplano. Sí, sí, sí. O sea, va de la mano es esa es esa misma idea, pero ahora con penalización, pero sí es correcto.
Leonardo Villalva: Gracias.
Ise posgrados: Bueno, volvemos a ¿Qué hora es? Eh, ¿quieren un cortecito? 10 minutos. Sí. Bueno, vamos a poner
Andrés Pablo García: No.
Ise posgrados: Estamos Bueno, vamos a ver ahora el el que verdaderamente se llama support vector machine, que es como más la generalización de lo que vimos hasta ahora. Como ya vieron, lo que vimos hasta ahora en dos dimensiones, pero como les decía, sirve para tres, cuatro, las que sea, es para casos completamente separables, para casos lineales. Yo pongo una línea con más, con menos errores, pero es con una línea que yo separo todo y así me debería funcionar o espero que funcione. Lo que pasa es que un caso como este, la verdad que es como dice acá, completamente inútil. No importa qué hiperplan lo yo ponga, voy a tener montones de errores.

01:28:39

Ise posgrados: Esto no me va a separar nada porque está eh dispuesto de una manera que no tiene nada que ver con una separación lineal. definitivamente yo puedo intentar o como preguntaban antes, sí puedo entrenar un modelo que me separe, pero no me sirve absolutamente para nada este modelo. Una posibilidad sería empezar a buscar soluciones, como por ejemplo ajustar un polinomio con un montón de de de, ¿cómo se llama?, de coeficientes, no sé, una cosa totalmente inmanejable que no digo que no se puede hacer, pero ya estaríamos además

inventando otra cosa que nos estamos yendo de tema que no tiene nada que ver con estos clasificadores que estamos viendo hoy. Entonces, eh, ¿qué pasa con eso? ¿Se puede intentar algo? Se puede, pero nosotros vamos a ir por el camino de mejorar nuestro clasificador lineal. ¿Y cómo lo vamos a mejorar? Bueno, el modelo, como les decía, que generaliza todo esto es el llamado support vector machine. Y lo que nos va a permitir este modelo es ampliar el espacio de atributos con kernels. Si yo estoy en un espacio de tres dimensiones, lo voy a aumentar a cuatro dimensiones usando un kernel. Y ahora vamos a ver un ejemplo. Miren por un momento solamente acá.

01:30:02

Ise posgrados: esto de la izquierda, este grilla de dos dimensiones, que yo tengo acá puntos de dos clases que la verdad que este ejemplo puntualmente yo podría separarlo con una línea, pero vamos a imaginarnos que queremos una separación perfecta y una separación perfecta no se puede con una línea. Entonces, nos podemos imaginar una tercera dimensión. Imagínense acá un eje Z, ¿no? Una tercera dimensión. Y yo le aplico a estos puntos, le aplico una función que lo que hace es traerme, bueno, yo me traigo, ustedes imagín la la orientación, ¿no? Me traigo hacia el eje Z, me aplicando esa función, me traigo los puntos azules hacia mí y los magenta, los dejo en el fondo o al revés. Y una vez que hice eso, después que apliqué la función y los separé hacia esta dimensión, meto un plano ahí y ahí los logré separar. ¿Se entiende la idea? Lo separo perfectamente. Yo aplico la función y lo separo con un plano. No pierdo la noción o la idea de usar un plano. La uso, pero con este truco. Y esto sería en 3D. ¿Cómo quedaría?

01:31:11

Ise posgrados: Eh, tengo un plano y de un lado del plano quedan eh los de la clase azul y del otro lado del plano quedan los de la clase magenta. Mis datos originales tenían dos dimensiones y ahora con el kernel aplicado, que el kernel no es más que una función, con el kernel aplicado tengo esto en tres dimensiones, pero eh las dos clases o las observaciones de las dos clases están separadas por un plano, que es la misma idea que teníamos originalmente. Acá un poquito cómo nos cambia la anotación. Nosotros antes usábamos para clasificar teníamos x es el punto que tenemos que clasificar. ¿Y qué función aplicábamos? teníamos acá la eh, ¿se acuerdan el producto interno de estos coeficientes, el vector este B y el X de la de nuestro set de entrenamiento, o sea, entrenamos el modelo de esta manera y ahora medio que lo vamos a transformar así como una sumatoria de coeficientes A sub B

y un producto interno entre el punto este que queremos clasificar y las observaciones de entrenamiento. No se no se enrosquen con esto porque simplemente esto es como algo como un camino como un este como una fórmula intermedia que vamos que nos va a llevar a la del kernel. Imagínense que si yo tengo 1000 puntos de entrenamiento, tendría 1000 combinaciones acá, 1000 coeficientes a subir.

01:32:39

Ise posgrados: No es eso lo que vamos a tener en realidad. Esta cuentita la vamos a hacer únicamente para los vectores de soporte. que son estos acá. Este i pertenece a h se está haciendo referencia a los vectores de soporte. O sea, lo que vamos a querer es esta función, ¿no? Con esta sumatoria, con estos coeficientes y este producto interno. ¿A dónde vamos con todo esto? Al uso de los kernel. una función kernel es una, no, no sé si habrán visto kernels en alguna materia, me parece que no. Después van a ver, van a verlo en, o sea, por lo menos en visión por computadora si usan kernels. Un kernel es una función que es como eh no hace más que esto combinar eh en este caso más simple como que combina dos vectores, es como el parecido al producto interno pero como con variantes, como para decirlo de una forma simple. Eh, estos son simplemente ejemplos un carnal lineal. un kernel polinómico, un kernel radial, o sea, son funciones donde yo combino mi vector con otra cosa. O sea, mírenlo como como eso. La forma más fácil de entenderlo es cuando cuando están eh eh cuando lo aplicamos a un a un caso una grilla con puntitos de en dos dimensiones, que ahora lo vamos a ver.

01:34:03

Ise posgrados: E por esp, no quiero olvidarme de nada. Acá lo que estamos incorporando a nuestro modelo son los kernel, pero todo lo que dijimos antes de los vectores de soporte, el perparámetro C que me limita los errores, todo eso es lo mismo, no cambia nada. Lo único que cambia ahora es que vamos a usar un kernel como parte del modelo. Eso sería lo que cambia con respecto a lo que vimos antes. Y acá tenemos ejemplos. Esto es lo que teníamos hasta ahora. Y si se acuerdan en el notebook que yo le pasaba como parámetro kern k kernel lineal significa que haga esto. Le estamos diciendo al modelo que haga esto, lo que ya vimos. Ahora, si yo uso un kernel polinomial, lo que hace el modelo es lleva todo a otra dimensión, o sea, le aplica ese ese kernel, ahí busca la frontera de decisión entre las dos clases y después cuando yo lo vuelvo a mi a mi dimensión original, que en este caso es dos,

la frontera me queda así. Lo mismo cuando uso un kernal radial. Este es un ejemplo de una sigmoidea, es decir, dependiendo del kernel que yo use, voy a tener distintas formas de de fronteras de decisión. Pero la cuestión es es esta.

01:35:14

Ise posgrados: Yo tengo acá en estos ejemplos dos dimensiones con el kernel yo lo llevo a tres dimensiones. Ahí busco la separación y después cuando vuelvo a mi espacio original, que en este caso son dos dimensiones, tengo una separación eh de mis clases que no podría haberla obtenido con el con el modelo original, el modelo lineal original que es este. a nivel de implementación en Python es una pavada ir de uno al otro, o sea, no es nada complicado, pero la idea es esa, que yo voy a poder tener estas fronteras que no son rectas en el caso de de dos dimensiones, no son una recta, sino que tienen otra otra formita. Y bueno, como para cerrar un poquito esta parte, eh nosotros hasta ahora siempre siempre en todos los casos estuvimos hablando de dos clases. Sí, siempre en los ejemplitos magenta y azul. Bueno, siempre dos clases. Ahora, si nosotros eh nos encanta este modelo y decimos, "p****, pero yo tengo más clases, ¿cómo puedo hacer? ¿Cómo lo puedo adaptar?" Eh, tenemos en principio dos posibilidades, el one versus one y el one versus all. ¿En qué consiste? Supóngase que yo tengo tres clases, A, B y C. El one versus one lo que hace es entrenamos con el support machine eh de a dos de pares A con B, B con C, A con C y después hago como una competencia como que veo cada puntito cuando lo quiero clasificar lo paso por los tres modelos y veo cuál eh cuál clase fue más votada entre esos tres y ahí decido mi puntito a cuál de las tres clases pertenece y el one versus all entreno A, no A,

01:37:08

Ise posgrados: o sea, como cada clase por separado, entreno es A o no es A y otro entreno otro modelo, es clase B o no es clase B y entreno otro modelo, es clase C o no es clase C. Y lo mismo viene un puntito nuevo que lo quiero clasificar, lo paso por los tres modelos y veo cuál de ellos me dio más confianza. ¿Cuál me dijo eh, o sea, qué es más probable? ¿Que sea A según el primer modelo, que sea B según el segundo o que sea C según el tercero? y ahí decido a qué clase pertenece mi punto. Son como estrategias para usar el modelo que es binario, pero para clasificar eh cuando tengo más de dos clases. Ya vamos a ver con un ejemplo. Primero voy a cerrar acá esta ventanita. Está primero. Vamos a ver, se me bajó esto acá. Primero vamos a ver los kernals. Si se acuerdan en los primeros ejemplos de arriba le

pasábamos como parámetro kernel lineal. Ahora le vamos a pasar el tipo de kernel eh que queremos implementar. En este caso vamos a implementar un kernel polinómico y vamos a hacer un grid search. Le paso como opciones de hiperparámetros para C le paso tres valores 1, 5 y 10. Y acá este es otro hiperparámetro que en el caso del kernel polinómico le tengo que pasar el grado del polinomio.

01:38:34

Ise posgrados: Entonces le paso dos, 3, cu y 5. Lo entreno y vamos a ver el el grid search que me dice. Esto es simplemente muestro los resultados de lo que me devolvió el el grid search, todas las combinaciones que me dio que probó y qué resultado les dio. Están ordenados por ranking. Es solamente para explorar. Esto lo pueden hacer con este modelo, con el KNN. Cada vez que usen el grit search pueden hacer esto. Lo que pasa que el otro día no lo no lo vimos. Es para mirar no más cómo le dio cada una de las combinaciones que probó. Acá están todas las combinaciones de C. y las combinaciones de los eh del grado de los polinomios. La cuestión es que después de probar todo eso, me dijo, "La mejor combinación es con C = 1 y el grado del polinomio igual a 5. Agarro esa mejor combinación, grafico y me da esta frontera. Y esta es la frontera eh que me separa las dos clases. Eso con polinomio. Acá hay otro ejemplo. Tenemos un set de datos que es el mismo de las diapositivas que tiene eh esta disposición.

01:40:02

Ise posgrados: Las dos clases están, las azules en el medio y las otras están afuera. Va afuera de los dos costados. Y entonces vamos a probar con un kernel radial. Esto lo hacemos así. Este es el parámetro kernel RBF. Hacemos un grid search. En este caso le decimos el parámetro C, pero va con todas estas combinaciones y el kernal radial tiene otro parámetro, otro hiperparámetro este modelo que es gama, que el valor de gama me dice qué tanto darle importancia a los puntos según la eh si están cerquitas o lejos de el hiperplano. Es como le da distinta importancia a los a los puntos según su ubicación. Entreno y me dice que la mejor combinación es con C = 5 gama 0,5. Agarro esa combinación que anduvo mejor y la grafico y me queda así, me queda perfecto. O sea, hay algunos errores chiquitos ahí, pero esto con un con un eh clasificador lineal directamente era imposible. Y acá quedó superb. Hago la predicción con un con el dataset de test, dibujo la matriz de confusión y me queda bastante bien, se ve bastante bien. Y en este caso el porcentaje de esa actitud me da

86%.

01:41:31

Ise posgrados: Y eso es aplicando los kernals y después esto que les comentaba recién del multiclase. El multiclase puede tomar dos formas. Acá se llama Ovo el all el one versus one y OBR el one versus rest que es uno versus el todo el resto o one versus all es lo mismo. Tenemos acá un ejemplo también datos sintéticos. Tenemos tres clases, entrenamos el modelo, en este caso con un kernel radial y con la estrategia eh ovo, one versus one. Después de entrenar, dibujamos acá tenemos los vectores de soporte para poder hacer el dibujito. Y estas son las fronteras que me eh quedaron después de entrenar el el modelo. Quedaron bastante bien separadas las tres clases con el acá como combiné, ¿no? El kernel radial y la estrategia esta para multiclase y quedaron bastante bien separadas las tres clases. Sigo bajando, creo que no hay mucho más, ¿no? Simplemente otra visualización de dónde están las fronteras de cada una de las tres combinaciones que probó, ¿no? Porque cuando era One versus one va combin va entrenando por separado cada par de clases. Y así es como me quedó cuando entreno el rosa.

01:43:05

Ise posgrados: Me quedó el rosa versus, supongo que, bueno, acá no lo veo muy bien. Son como las tres fronteras distintas de las tres combinaciones que fueron entrenadas. preguntas con esto. Es es la verdad que es bastante simple. Quizás lo más difícil es entender de entrada de qué estamos hablando, pero después esto es como nada, es bastante simple y es y es probar y y sobre todo probar el con la búsqueda de hiperparámetros, probar las mejores combinaciones, eh, y ya está. Ninguna pregunta.
Alejandro Valle: ¿Cuáles serían los hiperparámetros en este modelo? El
Ise posgrados: de este model.
Alejandro Valle: kernel.
Ise posgrados: En realidad el kernel se lo estamos pasando, o sea, subo. Eh, el kernel lo estoy definiendo acá, no usé busque hiperparámetros, o sea, el kernel es un parámetro hiperparámetro del modelo, pero arriba donde hice búsqueda de hiperparámetros no le dije que pruebe con varios eh con varios eh kernel directamente. Estoy buscando dónde lo uso. Eh, estoy subiendo subiendo acá directamente el kernel. Yo ya se lo paso fijo, no estoy preguntando cuál es el mejor kernal, yo ya le digo, quiero radial.

01:44:24

lse posgrados: Y con el grid sech lo que estoy buscando son las distintas combinaciones de gama, que es uno de los hiperparámetros, y las distintas de C, que es el hiperparámetro que está siempre en todos los en todas las versiones que vimos hoy
Alejandro Valle: Pero la elección de un kernel depende más que todo de la distribución de los
lse posgrados: de la distribución. Sí,
Alejandro Valle: datos.
lse posgrados: sí, sí, sí. Y si no tenés mucha idea cuál es la distribución, porque acá es fácil verlo, ¿no? En 2D, pero en varias dimensiones no tenés mucha idea, puedes probar varios. Ahora lo vamos a ver en un en un ejemplito que de hecho lo podríamos ver. Ahora acá hay un caso práctico, o sea, todo esto que estuvimos viendo hasta ahora son todos datos sintéticos inventados a propósito con esa forma para hacer la demostración, ¿no? Pero acá tenemos un caso eh un caso con un dataset con datos de verdad. Eh, tenemos eh un dataset acá de Hert, que es un set de datos con datos de pacientes y atributos de de variables de los pacientes y una eh columna, una variable target que dice si el paciente tiene una enfermedad coronaria o no. Ese es el dataset, lo tienen acá.

01:45:40

lse posgrados: clase tres. Este es el dataset. Todos los pacientes tienen la edad, el sexo. Acá un montón de variables que tienen que ver con variables del del de la salud o de la cuestiones de cada persona. Eh, y acá la variable target 01, o sea, son dos clases. Tiene enfermedad coronaria, ¿sí? No. Acá está la descripción del dataset. Eh, una breve descripción. Estos son los datos. Acá hacemos una pequeña transformación. Ponemos creamos las variables DAMI, o sea, lo mínimo que hacemos para entrenar un modelo. Sí. Eh, acá escalamos los datos y ya los tenemos listos para entrenarlo. Y acá hacemos un grid search. Fíjense esto que no recuerdo si vimos un ejemplo así el otro día en la búsqueda de hiperparámetros. Tenemos como varias grupos de hiperparámetros. ¿Por qué? Porque por ejemplo, el kernal radial tiene asociado con el hiperparámetro gama, pero el kernel lineal no usa ese parámetro gama. Entonces no todas las combinaciones de hiperparámetros son válidas, por eso las separo como en grupos.

01:47:10

Ise posgrados: Tengo una ray de diccionarios o una ray de estructuras de Jason. El primer elemento tengo acá, le estoy pidiendo que pruebe el kernel lineal con todos estos valores de C. Después le le digo que además pruebe el kernel radial con estos valores de gama y con estos valores de C. Y además que pruebe el kernel polinómico. Y acá un poco lo que preguntabas, no me acuerdo que me había preguntado, si era un hiperparámetro el kernel. O sea, el kernel es un hiperparámetro, solo que en los ejemplos anteriores no lo usé para el grid search. Acá sí lo estoy usando para el grid search. Le estoy diciendo que pruebe con distintos kernels, pero estoy discriminando bien qué combinaciones y hiperparámetros eh le voy a pedir que pruebe. Entonces, por último, acá le digo que pruebe el polinómico con estos grados para el polinomio 2 3 4 5 y 6 y con estos valores de C. Entonces, el research va a probar estos tres grupos de combinaciones de hiperparámetros. Le digo que entrene y después de entrenar me dice, "Bueno, la mejor combinación fue un kernel lineal con C = 5." Es decir, yo mirando los datos que los tengo acá, si yo miro no más esto, no tengo idea si me va a andar bien un radial, un lineal, o sea, no lo puedo saber, la verdad, mirando esto así no más.

01:48:32

Ise posgrados: La solución fácil fue hacer todo esto. Le digo, "Bueno, fíjate más o menos todas estas combinaciones." Y resultó que el lineal eh fue el mejor de todos esos. Así que eh bueno, agarro esa solución, la mejor de todas. Calculo acá algunas métricas. Me dice que la exactitud fue del 086. Eh, calculo acá también el F1 score, la precisión, al recol. Bueno, las métricas siempre que uno le interesen las puede calcular. Dibujo la matriz de confusión, la tengo acá, que se ve bastante bien. Y por último, esto no lo vimos antes, dibujo una curva rock. E y como se observa acá, el valor de área bajo la curva dio bastante bastante alto, o sea, se puede ver, pero además el numerito lo vemos acá, 090. Y esto es con un dataset con datos reales, ¿no? Todos los datos sintéticos inventados que que estuvimos viendo en los ejemplos anteriores. Se dan una idea cómo lo pueden usar entonces para para entrenar, para usarlo para sus eh propios datass. O sea, el uso, la puesta en práctica es muy simple. Como les decía recién, la idea es entender qué es lo que hace el modelo, pero una vez que lo entendieron, usarlo es realmente muy simple.

01:50:20

lse posgrados: Bueno, si no hay preguntas, volvemos a la presentación. Hasta ahora vimos todo lo que es clasificación, un modelo que eh nos permite clasificar en dos clases, pero también vimos una variante para poder clasificar en varias clases. Y si recontra y si resulta que la recontra encantó el modelo y dicen, "Bueno, pero en realidad yo lo quiero para regresión." Bueno, también existe la variante para regresión de este mismo modelo lineal. ¿Y en qué consiste? Volvemos a las formulitas, no me maten. Teníamos esto. Espero que no se hayan olvidado lo que es esta fórmula. ¿Se acuerdan lo que es esta fórmula?
Cesar Orellana: las rectas.
lse posgrados: La recta. Yo tengo acá el hiperplano. Le podemos llamar recta porque son para los ejemplos que vimos, pero es es la la recta en el caso de dos dimensiones o el hiperplano.
Cesar Orellana: Exacto.
lse posgrados: Claro. La clase 1 men 1. Y esta es la condición. Yo quiero que los, o sea, los puntos de la clase -1 o la clase uno están más allá del margen. Yo tenía dibujado una un hiperplano, tenía un margen y esto lo que le estoy diciendo es que todos los de la clase uno están de un lado del margen y los de la clase dos están del otro lado del margen.

01:51:40

lse posgrados: Entonces, tengo una, lo que yo le llamo una pasarela, un caminito en el medio que está el hiperplano y los dos márgenes. Ese caminito está totalmente despejado, no hay nada ahí adentro y todos los puntos están de un lado o están del otro. Si eso fue lo que vimos al principio, el primero de todos los casos que no tenía ni siquiera un error, estaba todo despejado en el medio y tengo todo lo de una clase de un lado y todo lo de otra clase del otro. Si yo eso lo modifico levemente esto y lo escribo así, esto lo voy a usar para hacer regresión. ¿Qué es lo que estoy queriendo hacer con esta transformación? Es, en vez de agarrar ese caminito y dejarlo vacío y poner los los eh elementos de la clase azul de un lado y magenta del otro, lo que voy a hacer es dejarlos todos adentro, buscar todos los puntos que están adentro. En vez de buscar los que están afuera, buscar los que están adentro. Como esto, busco el mejor hiperplano que me deja todos los puntos adentro. O sea, exactamente lo contrario de lo que hice antes. Yo buscaba el mejor hiperplano que me dejaba todo afuera de un lado y del otro.

01:52:48

Ise posgrados: Ahora voy a buscar el mejor hiperplano que me deja todos los puntos del lado de adentro. Y entonces ese hiperplano va a ser la recta que yo voy a estar ajustando con ese modelo de regresión. Olvidándose de esto que hablamos del hiperplano, del margen y de todo. Esto sí le suena la recta, la regresión, una función. Busco los coeficientes que me ajustan mejor esa esos puntos. Sí, la diferencia con una eh no sé, los mínimos cuadrados que seguramente los que ustedes ya conocen la la gran diferencia que hay, porque ustedes lo van a ver como muy parecido, muy igual, es lo mismo. Estoy buscando una recta que se ajuste, que ajuste bien, eh, que mis puntos se ajuste bien a esa a esa recta. La gran diferencia es que acá voy a pasar esto un poquito acá. Acá yo voy a permitir errores. Entonces, ¿qué pasa con esto? Supónganse que yo tengo acá dos puntitos que están alejados de de esta de esta recta. Están todos acá los más lindos y acá hay un par alejados. Yo con el mínimos cuadrados, estos puntos que están alejados me van a mover la recta un poquito. Me inevitablemente yo para minimizar los errores, esta recta quizás se gira un poquito, se acuesta un poquito más para ajustar bien a este punto y a este punto.

01:54:13

Ise posgrados: En cambio, en este modelo, este hiperplano, si yo permito estos mínimos errores, este hiperplano se va a quedar acá, que es la mejor recta. va a ignorar de alguna manera, no es que los va a ignorar, pero eh va a permitir que estos errores estén acá con los mismos criterios. Bueno, esto es un poquito parecido, no es igual igual, pero tengo el mismo las mismas restricciones, una sumatoria que va a estar por debajo de un umbral, o sea, voy a permitir unos pequeños errores. En este caso tengo este error y este error, pero mi hiperplano va a estar acá donde está la mayoría de los puntos. Esa es la idea de la regresión con este modelo. Y acá también se pueden usar kernels y todo lo demás, pero lo importante es eso, que a diferencia de los de los modelos anteriores, en vez de buscar el hiperplano que me deja los puntos afuera, busco el hiperplano que me deja los puntos adentro y voy a permitir también algunos pequeños errores.
Alejandro Valle: M.
Ise posgrados: Así que vamos a ver esto en una notebook. Para usar support vector machines como regresión tengo otra clase de cycle l que es SBR. Antes teníamos SBC, ahora tenemos acá SBR. Y para practicar, para el ejemplo de esta notebook, vamos a usar un dataset de jugadores de béisbol, eh, que, a ver, lo vamos a acá lo vamos a abrir.

01:55:48

Ise posgrados: Tenemos jugadores, o sea, cada una de estas observaciones es un jugador y cada una de estas atributos son eh hitos que hizo jugando al béisbol, diferentes eh no sé, no sé cómo se llaman las las cosas que puedes hacer uno en béisbol porque no tengo ni idea, pero son distintas cosas que tus jugadores hicieron. Eh, y lo que voy a querer estadísticas de lo que hicieron los jugadores.
Mariano Jauffroy: Serían como las estadísticas del jugador.
Ise posgrados: Exactamente. Eh, no me animo a decir como si fuese si fuese fútbol serían goles y muchas otras cosas más, pero en béisbol no tengo los tantos que no tengo ni idea. Pero bueno, el que sepa béisbol por ahí le va a tener le va a hacer más sentido todo esto. La cuestión es que son todas las estadísticas de lo que hizo cada jugador y al final de, no sé si está al final o por ahí en algún lado está acá, no era la última, pero casi el salario. Lo que voy a querer predecir, o sea, mi variable target de esta regresión que voy a querer ajustar este modelo de regresión, el abre target es el salario que está acá. Bien, entonces acá abro el dataset. Lo miro un poco para ver que que por dónde se mueven las variables con miro las estadísticas.

01:57:06

Ise posgrados: Y una cosa que voy a hacer con el salario, miren acá este dibujito que al costado en la izquierda es el salario. Fíjense que hay valores, muchos valores acá cercanos, no digo a cero porque acá no estoy viendo exacto los valores, pero quizás cercanos a 100. Hay muchísimos valores y después baja muy de repente hasta el 1000, 1000 y pico y acá hay algunos valores muy extremos. Esta este dibujo, el salario es como demasiado asimétrico a la izquierda. Yo para ayudar al modelo, lo que estoy haciendo acá es aplicarle el logaritmo al salario. Al aplicar el logaritmo me queda esta figura. es simplemente para ayudar al modelo. Fíjense que ahora el logaritmo de salario me queda 4, 5, esto no es un salario, no tiene sentido. Yo el salario es 6, o sea, no tiene ningún sentido, pero eh con esta transformación yo le estoy ayudando al modelo. El modelo va a andar mejor que si yo le paso este dato. Y acá esto no lo tienen en el repo porque esta curvita la hice hace un rato. me muestra el salario versus el log del salario, porque la vez pasada, en el bimestre pasado, la había algunas personas que se quedaban como preocupadas de que yo acá estaba inventando algo.

01:58:20

Ise posgrados: ¿Cómo puede ser que cómo puede ser que este dibujo al aplicarle el logaritmo cambie tanto la forma? Y y bueno, acá un poco esta esta figura me explica, digamos, cómo es que se mueve eh la variable, por qué de estar así pasa a tener este dibujito, pero es nada, es una cuestión visual. Esto que está acá me está dibujando simplemente esta variable versus esta. Y bueno, el objetivo no es más que ese que les decía, para que el modelo funcione mejor, eh, bajo un poquito, lo mismo de siempre. Miro un poquito las estadísticas, transformo las variables, creo las damis. Bueno, lo mismo es siempre, ¿no? Preparo el dataset para poder entrenarlo. Separo trainy test, escalo, hago el escalamiento de las variables y acá importo esto que les decía, el SBR. Acá está importando, estoy importando el SBR. Nuevamente voy a hacer un grid search parecido al de la al del caso práctico que vimos. recién de las enfermedades coronarias, el grid search le mando acá las tres combinaciones de hiperparámetros para un kernel lineal, para un kernel eh radial y para un kernel eh polinómico. Eh, no sé si es igual, si no es muy parecida a las combinaciones que eh usamos en la otra notebook y le voy a decir que entrene.

01:59:54

Ise posgrados: Después que entrenó le digo, "Bueno, ¿cuál te dio mejor?" Y en este caso le dio mejor el kernel radial con gama 0.1 y valor de C ig a 10. Le pido que prediga. Allá arriba había separado en TR y test, así que ya tengo acá los datos de test para predecir. Calculo algunas estadísticas y para saber, bueno, me dio así, ¿esto es bueno o malo? O sea, ¿contra qué lo comparo? Y bueno, lo vamos a comparar con una regresión rich. Acá está el Ah, esto cambia. Yo me olvidé de subirla. Esto no sé si era necesario. Le puse acá el link a la documentación de Rich por las dudas. Eh, lo estoy importando acá. También busco eh para Rich, también busco hiperparámetros con grid search. Acá tengo la mejor combinación y acá las estadísticas. Comparando esto, Rich contra el SBM de regresión que está allá arriba, la versión del SBR mejoró un 23% con respecto a la regresión de Rich, o sea, nos nos dio mejor. Esto es un poco también lo que tienen que hacer siempre, ¿no?

02:01:18

Ise posgrados: O sea, un modelo suelto en el aire podemos darnos una idea que anda bien, pero si no lo comparamos con un modelo base nos quedamos cortos. Como siempre, la idea es tener un modelo base y después ir comparando y

mejorándolo contra otros modelos o contra variantes de otros modelos. Pero básicamente eso es eh todo lo que lo que implica eh usar este modelo SBM para regresión. ¿Alguna pregunta? Me parece, creo que esa era la última slide. Sí, esa la última slide. Tienen acá como siempre en la clase ejercicios para practicar esto. Hay dos ejercicios. Uno usando un dataset de calidad de vino que está acá dentro. Lo mismo también tienen todas las observaciones, distintas propiedades químicas de de los vinos y la calidad, un índice de calidad. Entonces, con ese dataset acá les eh les pide que eh hagan una un análisis eh una limpieza, una eh cómo se llama, un EDA básico del dataset. y eh construir un modelo eh SBM o de regresión o de clasificación multiclase, según lo que ustedes quieran predecir eh con esos datos eh según lo que quieran eh hacer, clasificar o o predecir alguna de las variables del del dataset. Y después un segundo ejercicio que es usando este dataset que ya lo vimos la clase pasada, lo vimos con KNN.

02:03:19

lse posgrados: Bueno, ahora eh volver a usar el mismo dataset para entrenar un modelo SBM de clasificación y comparar, ¿no? O sea, cómo les dio eh antes y cómo les da ahora. Todo M.
Alejandro Valle: Este modelo de regresión no me quedó claro si si toma en consideración la distancia al cuadrado de los puntos o solamente que quede dentro de los
lse posgrados: No, que quede entre los márkers porque justamente es un modelo que funciona distinto al de mínimos
Alejandro Valle: márgenes.
lse posgrados: cuadrados. Funciona diferente, como la idea de regresión es la misma, pero funciona diferente.
Alejandro Valle: Okay, gracias. Yeah.
lse posgrados: Y nada, bueno, y eso sería todo. No tienen preguntas. Practiquen, practiquen, porque de eso se trata la materia. Vamos a seguir incorporando modelos de clasificación la semana que viene, la otra y les puede gustar más uno más otro, pero la idea va a ser siempre lo mismo. Partan de uno y van complejizando y van viendo si les da mejor. Eh, y eso es todo. Eh, eso es lo que van a tener que hacer también para sus trabajos, que no sé si habrán empezado, si están ahí, si están muy demasiado relajados, cuenten.

02:04:56

lse posgrados: Se quedan todos calladitos.
Gabriela Sol Salazar: Yo tengo una pregunta e con respecto al sesgo,
lse posgrados: Sí, Sol.
Gabriela Sol Salazar: cuando tenés muchas eh por ejemplo que en los casos que tenías tres eh clases distintas, si es muy regular la forma que vimos en los gráficos, por ahí tiende a agrupar bien un cierto una cierta clase y con las otras dos quizás es más e no es tan clara la división al momento ya después de de testear. pasa mucho eso de que puedes tener eh preferencia hacia una variable o una variable muy bien definida y con las otras dos tener estos, o sea, es muy sensible al sesgo,
lse posgrados: M.
Gabriela Sol Salazar: digamos, este modelo en general.
lse posgrados: No sé si te termino de entender la pregunta, pero el tema de la de cómo te va a clasificar las clases, yo creo que más que del modelo va a depender de tus datos. Si si tus datos no están muy bien separadas, las clases muy fáciles de separar, capaz que cualquier modelo que elijas te va a andar más o menos bien o más o menos mal. A lo mejor si las clases realmente están mezcladas, no importa si vos sucedes este que vimos hoy o veas otro modelo, capaz que ninguno te anda muy bien. O sea, creo que no depende tanto del, me parece a mí, no depende tanto del modelo como de los datos. tuyos que tengas. Es una impresión. Yo creo que siempre la la palabra la tiene la ir y probar. Lamentablemente no hay una respuesta, me parece única para eso.
Gabriela Sol Salazar: Okay, gracias. M.
lse posgrados: ¿Alguna otra cuestión? Acá hay preguntas en el chat, yo no los había visto. No sé si alguien la que dice el criterio por Bueno, ya tarde, ¿no? Que estamos hablando, son de las 7:30 de la tarde. Bueno, chicos, si no tienen más preguntas, eso fue todo por hoy. No sé si tienen preguntas del trabajo final o algo. Si no estamos todo bien.
Alejandro Valle: Gracias.
lse posgrados: Se las Bueno, bueno, buenas noches. Los liberamos, chicos.
Santiago Bartolini: Chao.
Gabriel Quiroga: Muchas gracias.
lse posgrados: Hasta la semana que viene.
Marcos Lund: Muchas gracias.
lse posgrados: Chao.
Martin Lacheski: M.

La transcripción finalizó después de 02:07:46

Esta transcripción editable se ha generado por ordenador y puede contener errores.
Los usuarios también pueden cambiar el texto después de que se haya generado.