📝 Las notas

26 mar 2026

Aprendizaje de Máquina (4/8) - a242b25

Invitados facundolucianna@gmail.com macroldan@fi.uba.ar Aprendizaje de Máquina - CEIA 24Co2025

Archivos adjuntos Aprendizaje de Máquina (4/8) - a242b25

Registros de la reunión Transcripción Grabación

Resumen

Revisión de Support Vector Machines con énfasis en regularización y funciones kernel, contrastándola con la teoría y aplicación de árboles de decisión en regresión y clasificación, y abordando el sobreajuste mediante poda.

Repaso de Support Vector Machines
Se repasaron las Support Vector Machines, desde el Maximal Margin Classifier hasta la aplicación de funciones kernel para fronteras no lineales. Se enfatizó que la regularización en SVM se aplica a nivel de observación a través del hiperparámetro C, permitiendo controlar el balance entre sesgo y varianza.

Regresión con Árboles de Decisión
La construcción de árboles de regresión busca minimizar la suma de residuos al cuadrado mediante el algoritmo *greedy* de división binaria recursiva. Para evitar el sobreajuste se utiliza la poda, regularizando con el parámetro α para generar un conjunto de subárboles y seleccionando el óptimo mediante validación cruzada.

Árboles de Clasificación y Pureza
Los árboles de clasificación predicen la clase por voto mayoritario en las hojas, usando métricas de pureza como el índice de Gini o la Entropía

para guiar la división. La búsqueda de hiperparámetros con Optuna ajustó el modelo para un problema de enfermedades cardíacas, resultando en un modelo con alta explicabilidad y una métrica F1 de 0.66.

Detalles

- **Introducción y Contexto de la Clase**: La sesión comenzó con los saludos y la presentación del tema central, los árboles de decisión, que forman el núcleo de modelos más avanzados que se abordarán posteriormente. El objetivo de la sesión es revisar los fundamentos de los árboles antes de avanzar a los modelos de "bosques" (forests) (00:00:00).
- **Repaso de Support Vector Machines (SVM)**: Se inició el repaso recordando las Support Vector Machines (Máquinas de Vectores de Soporte), modelos muy populares en los años 90 debido a su sencillez, facilidad de entrenamiento, y buenos resultados, lo que permitió desplazar a las redes neuronales de la época (00:00:00).
- **Modelo Base: Maximal Margin Classifier**: El modelo base de SVM es el Maximal Margin Classifier, que busca maximizar la distancia (el margen) entre las clases mediante una línea recta. Este modelo solo funciona si el problema es linealmente separable (00:08:40).
- **Limitaciones del Maximal Margin Classifier y Soluciones**: El Maximal Margin Classifier tiene un gran error de varianza, ya que pequeños cambios en las observaciones (vectores de soporte) pueden modificar drásticamente la ubicación de la recta de clasificación (00:08:40). Para mejorar la generalización y reducir la varianza, se introdujo la idea de relajar las exigencias, aceptando errores de clasificación o que algunos datos caigan dentro del margen, lo cual aumenta el error de sesgo, pero reduce significativamente la varianza (00:10:40).
- **Regularización en SVM vs. Regresión Lineal**: Se diferenció la regularización en SVM de modelos como Ridge o Lasso, donde la penalización se aplica a las características (features). En SVM, la regularización se aplica a nivel de observación a través de un hiperparámetro C, permitiendo aceptar errores de clasificación o dentro del margen (00:12:19). Un C muy pequeño hace que la recta sea menos sensible a las observaciones (menos varianza) y un C muy grande permite menos penalizaciones, lo que la hace muy sensible (más varianza) (00:14:10).

- **Uso de Kernel Functions en SVM**: El concepto de Support Vector Machine se extiende para usar fronteras no lineales mediante una transformación con funciones kernel, que permiten pasar a un espacio vectorial diferente. En este nuevo espacio, la clasificación se realiza con una recta (un hiperplano), y al antitransformarla, se obtiene la frontera no lineal deseada, como la forma polinomial o radial (00:15:32) (00:22:53).
- **Discusión sobre la Elección del Modelo SVM (Kernel)**: Se presentó un ejemplo visual comparando los resultados de un kernel polinomial de orden 3 y un kernel radial sobre el mismo conjunto de datos, lo que llevó a la conclusión de que la elección del mejor modelo depende del problema, especialmente de cómo se originan los datos y de las regiones donde se realizará la predicción (00:20:04). Se destacó que un modelo no debe usarse para predecir fuera de la zona donde fue entrenado (00:21:32).
- **SVM para Regresión (SVR)**: En regresión (SVR), el modelo busca ubicar una recta que incluya la mayor cantidad de puntos dentro de un margen, y la penalización se enfoca en cuántos puntos están fuera del margen (00:22:53). Este enfoque es ventajoso frente a la regresión lineal tradicional porque permite ignorar los valores atípicos (outliers) mediante la regularización, dándole control sobre las observaciones específicas en lugar de solo sobre las características (00:25:49).
- **Introducción a los Árboles de Decisión**: Los árboles de decisión son modelos antiguos y potentes que sirven tanto para clasificación como para regresión (00:27:07). Su estructura jerárquica permite generar reglas, ofreciendo una alta interpretabilidad y facilidad para explicar el proceso de clasificación o regresión (00:28:39).
- **Mecánica de los Árboles de Regresión**: Para la regresión, el espacio de las observaciones se divide en J regiones rectangulares no solapadas, donde el valor predicho para cualquier observación dentro de una región es una medida de posición central (generalmente la media) de los valores de entrenamiento en esa región (00:32:36) (00:35:10).
- **Construcción del Árbol (Algoritmo Greedy)**: El objetivo al construir el árbol es encontrar las combinaciones de regiones que minimicen la suma de los residuos al cuadrado (RSS) (00:36:37). La división se realiza mediante un algoritmo "greedy" llamado "recursive binary splitting" o "top-down recursive splitting". El algoritmo comienza desde la raíz y, en cada paso, elige la bifurcación que más reduce el error cuadrático (RSS) sin considerar el efecto a futuro (00:38:03).

- **Método de Selección de Divisiones**: Para decidir dónde cortar las regiones, el algoritmo prueba todas las combinaciones posibles de variables y valores de corte (00:39:26). La combinación que inicialmente reduce el RSS en mayor medida es la seleccionada, lo que explica por qué se eligen valores de corte específicos (como 4.5 años o 117.5 hits en el ejemplo) (00:40:40) (00:43:13).
- **Problema de Sobreajuste (Overfitting) y Poda (Pruning)**: Si se permite que el árbol siga creciendo hasta que cada hoja contenga una sola observación, el RSS será cero, lo que constituye un sobreajuste máximo (00:44:34). Para evitar esto, es necesario podar el árbol y obtener una versión más simple, lo que resulta en menos varianza pero un leve aumento del sesgo. La estrategia de usar un umbral para el RSS no es la mejor (00:46:09).
- **Regularización para el Podado de Árboles**: El método más sistemático para podar árboles incluye la regularización. Se define una métrica que minimiza el RSS más un factor de penalización que incluye α (el parámetro de complejidad) y L (el número de hojas) (00:47:41). Este método permite que, al aumentar α desde cero, las ramas se poden de forma anidada y predecible, lo que hace que la búsqueda del mejor α sea computacionalmente eficiente (00:48:57).
- **Algoritmo Completo de Regresión con Árboles**: El algoritmo final incluye el Recursive Binary Splitting para crear el árbol más grande (deteniéndose con un número mínimo de observaciones por hoja), seguido por la aplicación de la poda para generar el conjunto de subárboles posibles en función de α. Finalmente, se utiliza validación cruzada para seleccionar el α óptimo que equilibre el error de varianza y sesgo (00:50:11).
- **Implementación Práctica del Modelo (Python)**: Se comenzó la demostración práctica utilizando el conjunto de datos de jugadores de béisbol, preprocesando los datos al eliminar las observaciones con salario nulo y aplicando el logaritmo al salario para mejorar la distribución y predecir mejor el orden de magnitud (00:51:55).
- **Uso de DecisionTreeRegressor en scikit-learn**: Se presentó la implementación del árbol de regresión mediante `DecisionTreeRegressor` en scikit-learn, señalando que los parámetros por defecto incluyen el criterio de error cuadrático (square error) y la elección del mejor separador (`splitter='best'`) (00:54:56) (00:57:44). Se destacó la importancia de reservar una proporción adecuada de datos para *testeo*, especialmente cuando se tienen pocas observaciones (00:53:16).
- **Visualización del Árbol Generado**: Se demostró cómo visualizar el árbol generado, notando que el árbol resultante era demasiado grande para ser

interpretable (00:59:05). El análisis inicial mostró que la variable "años" fue seleccionada como la que mejor separaba los datos en la raíz, coincidiendo con la diapositiva inicial y validando la lógica del algoritmo *greedy* (01:00:29).

- **Análisis de la Interpretación de Árboles de Regresión y Overfitting**: El análisis de un árbol de regresión grande demostró que es "ininterpretable" y un ejemplo de *overfitting*, ya que cada hoja contenía una sola muestra, resultando en un error cuadrático de cero. El error de entrenamiento era 0.0, mientras que el error de prueba (testeo) era 0.46, confirmando el *overfitting* (01:02:50). Este modelo, aunque sobreajustado, se desempeñó mejor que un modelo de regresión lineal simple, el cual arrojó un error de 0.52 (01:04:26).
- **Optimización y Poda de Árboles mediante el Parámetro Alfa**: Se experimentó con el parámetro alfa para podar el árbol y mejorar su capacidad de generalización. La validación cruzada con un alfa de 0.0 resultó en un error medio de 0.54 (01:06:02). Se realizó una búsqueda de parámetros en grilla, explorando distintos valores de alfa para encontrar el valor óptimo, y también se guardó el número de hojas resultante para cada configuración (01:07:37).
- **Análisis de Métricas y Selección del Mejor Árbol**: El gráfico de la métrica (error absoluto medio o MAE) en función del tamaño del árbol mostró un patrón inicial de caída y posterior subida, alineado con la curva de varianza-sesgo (01:08:46). Se seleccionó un valor de alfa de 0.06, lo que resultó en un error de 0.49; aunque el error no mejoró significativamente, este valor aseguró que el modelo ya no estuviera sobreajustado y era mejor que el modelo de regresión lineal (01:09:55). El árbol resultante con este alfa fue el mismo que se mostró en la diapositiva inicial y demostró ser el mejor para este problema (01:10:54).
- **Ventajas de la Explicabilidad del Árbol de Decisión**: Se destacó la ventaja de la interpretabilidad de los árboles de decisión, lo cual es útil para aplicar un protocolo o tomar decisiones claras basadas en métricas, como el ejemplo de la oferta salarial a un jugador (01:12:21). Se compararon los errores de los modelos de regresión, siendo el árbol (0.49) ligeramente mejor que la regresión lineal (0.52) y la regresión Ridge (0.51). Aunque los árboles no son los mejores modelos predictivos, son superiores cuando la explicabilidad es el factor clave, y su estructura simple permite la construcción de modelos de ensambles (01:13:40).
- **Consulta sobre la Aplicación de Logaritmos a Datos con Distribuciones Múltiples**: Gabriela Sol Salazar consultó sobre la validez de aplicar logaritmos a datos que presentan picos secundarios más bajos en su distribución. La

respuesta indicó que es una transformación matemáticamente correcta, cuyo objetivo es mejorar la distribución de los datos, ya que el modelo podría prestar menos atención a los valores atípicos con pocas observaciones si no se aplica la transformación (01:15:03). La aplicación de logaritmos ayuda a unificar mejor los datos y es útil cuando se desea retener la información de *outliers* que son valores genuinos, como en el caso de jugadores de fútbol excepcionales (01:16:35).

- **Introducción a los Árboles de Clasificación y la Métrica de Predicción**: La discusión pasó a los árboles de clasificación, los cuales son similares a los árboles de regresión, pero la predicción en las hojas se realiza mediante el voto mayoritario de la clase más popular en esa hoja (01:17:46). Es importante no solo obtener la predicción, sino también la proporción de clases para medir la seguridad de la predicción en esa hoja; una proporción más extrema indica mayor seguridad. Para la separación, el error cuadrático medio se reemplaza por métricas que maximizan la pureza de las hojas, como el índice de Gini o la entropía, ya que el error de clasificación simple no es suficientemente sensible para árboles complejos (01:30:23).
- **Métricas de Pureza en Árboles de Clasificación (Gini y Entropía)**: El índice de Gini, una métrica macroeconómica adaptada, mide la impureza de un nodo terminal; un valor de cero indica un nodo puro (una sola clase), y 0.5 es el peor caso (clases distribuidas equitativamente) (01:32:13). Los árboles de clasificación son inherentemente multiclase, y el índice de Gini funciona independientemente del número de clases. La entropía, proveniente de la teoría de la información, también mide el desorden; una entropía de cero indica que todas las observaciones pertenecen a una sola clase (01:35:07). Ambas métricas (Gini y Entropía) son preferibles al error de clasificación porque muestran una mayor sensibilidad a pequeños cambios en la proporción de la clase (01:37:50).
- **Ejemplo Práctico de Árbol de Clasificación (Dataset de Enfermedades Cardíacas)**: Se aplicó un árbol de clasificación al conjunto de datos de enfermedades cardíacas, el cual originalmente contenía duplicados y tuvo que ser limpiado para reducir las observaciones a 302 pacientes (01:39:00). Aunque se reconoció que el tratamiento de las variables, como el sexo codificado como numérico, no era óptimo, los árboles son robustos a este tipo de problemas (01:40:45). Dado que el *target* estaba casi perfectamente balanceado (cerca de 50/50), se eligió F1 como la métrica de evaluación para encontrar un balance entre *precision* y *recall* (01:42:00).
- **Desarrollo y Optimización del Árbol de Clasificación**: Se creó un clasificador con el criterio de entropía, resultando inicialmente en un árbol gigante con un

rendimiento de entrenamiento perfecto y un valor numérico para el testeo. La visualización del árbol de clasificación utiliza coloración para indicar la pureza de la hoja, donde un color (naranja) representa no tener la enfermedad y el otro (azul) representa tenerla (01:43:26) (01:46:18). Se destacó que las variables seleccionadas por el árbol (presión arterial y edad) tenían sentido en el contexto del problema, lo que ayuda a validar el modelo (01:44:59).

- **Búsqueda de Hiperparámetros y Evaluación del Modelo Final**: Se utilizó Optuna para realizar una búsqueda de hiperparámetros (criterio Gini/Entropía, profundidad, muestras para split, y muestras por hoja) con el objetivo de maximizar la media del F1 mediante validación cruzada (01:47:54). Después de la optimización, se encontró que el mejor árbol tenía una profundidad máxima de 20, criterio Gini, 7 muestras mínimas para split y 2 muestras mínimas por hoja (01:49:21). El modelo final ajustado con estos parámetros arrojó métricas de testeo de 0.62 para F1 y 0.70 para precisión, que, aunque ligeramente peor que el árbol inicial en el testeo, no estaba sobreajustado (01:50:37).
- **Discusión sobre la Estructura y Robustez de los Árboles (Problemas en la Clasificación)**: Se discutió que el proceso de diagnóstico de los médicos se asemeja a la estructura de un árbol de decisión (01:52:03). Gabriel Quiroga señaló que un nodo específico del árbol final falló en la clasificación, dejando una impureza (uno de cada clase) (01:53:04). Esto se atribuyó a las restricciones de los hiperparámetros establecidos durante la búsqueda, específicamente la exigencia de un mínimo de 7 muestras para realizar un split, lo que impidió que el nodo se separara más para mejorar la pureza (01:54:14). A pesar de los resultados variables y la generación de un árbol inicialmente "feo", el modelo final ajustado mostró una métrica de F1 de 0.66 y una precisión de 0.72 (01:56:42).
- **Ventajas del Árbol de Decisión Simple**: El modelo de árbol de decisión presentado, a pesar de su sencillez, demostró ser un mejor clasificador que otro árbol más grande, utilizando solo la presión, la edad y el sexo (02:00:15). Este modelo tiene la ventaja de una alta explicabilidad, lo que facilita explicar la ocurrencia de eventos a personas no expertas y se asemeja al razonamiento hipotético-deductivo utilizado en diagnósticos médicos (02:01:48).
- **Características y Limitaciones de los Árboles de Decisión**: Las fronteras de clasificación de los modelos de árboles son rectangulares, lo que difiere de otros modelos que usan fronteras lineales o circulares (02:01:48). Una ventaja clave es su robustez con respecto a los tipos de variables, ya que maneja variables categóricas sin necesidad de codificación (como *one hot

encoding* o *label encoding*). Sin embargo, la desventaja principal de los árboles de decisión únicos es que son modelos "malos" de base, careciendo de la precisión predictiva de otros modelos y siendo poco robustos, ya que pequeños cambios en los datos de entrenamiento pueden alterar drásticamente la construcción del árbol (02:04:36).

- ****Impacto del Algoritmo *Greedy* y la Representación Gráfica****: La naturaleza del algoritmo *greedy* en la construcción de los árboles puede generar predicciones inciertas debido a cambios en el entrenamiento. Para la representación gráfica, los árboles de decisión funcionan mejor cuando las regiones de clasificación son cuadradas, mientras que les resulta difícil ajustarse a fronteras lineales debido a la necesidad de "pixelar" la línea (02:04:36).
- **Introducción a Modelos Avanzados Basados en Árboles**: El árbol de decisión único sirve como introducción a modelos más avanzados como *boosting*, *bagging* y árboles aleatorios, los cuales utilizan la combinación de muchos árboles para lograr clasificaciones muy efectivas. Estos modelos de *boosting*, a pesar de basarse en los árboles simples, son capaces de resolver la mayoría de los problemas de *machine learning* e incluso superar modelos de *deep learning* en algunos casos debido a su precio y facilidad de implementación (02:08:03).
- **Logística de la Próxima Clase y Proyecto Final**: La clase concluyó 50 minutos antes de lo previsto, ofreciendo a los participantes ese tiempo para trabajar en su proyecto final, mientras el instructor se queda para responder dudas. Se confirmó que la próxima clase, la cual será impartida por Karina, se llevará a cabo el jueves siguiente a pesar de ser Semana Santa, aunque no habrá asistencia obligatoria (02:09:26).

Pasos siguientes recomendados

- [ ] [Karina] Impartir Clase: Dictar próxima sesión académica. Tratar modelos boosting árboles aleatorios.

Revisa las notas de Gemini para asegurarte de que sean correctas. Obtén consejos y descubre cómo toma notas Gemini

Danos tu opinión sobre el uso de Gemini para tomar notas en una breve encuesta.

📖 Transcripción

26 mar 2026

Aprendizaje de Máquina (4/8) - a242b25 - Transcripción

00:00:00

Cesar Orellana: Buenas tardes,
lse posgrados: Hola, buenas.
Cristian A. Aballay: Yeah.
lse posgrados: Buenas,
Jose Miguel Silva: Buenas,
Cristian A. Aballay: Bueno,
lse posgrados: Hola,
Cesar Orellana: Bueno,
lse posgrados: Bueno, estamos casi Ahora sí estamos casi todos. Vamos a arrancar. Entonces, bueno, vamos a estar en la clase cuatro hoy de mensaje de máquinas. Imagino que ya tienen todos grupos, proyectos, ya están arrancando, ya están terminando. Bueno, tanto no, pero eh ya tienen por lo menos el el dataset y se están poniendo de acuerdo entre ustedes para trabajar. Entonces, bueno, hoy vamos a ver un tipo de modelos muy básicos, pero que son el corazón de otros modelos que puedan a ver la clase que viene, con lo cual está bueno tenerlos por separado y después cuando vean modelos de árboles de bosques, perdón, eh van a terminar de completar más, o sea, como que más claro desde esa perspectiva momento que entienden árboles. Entonces, bueno, hoy vamos a ver árboles, pero como siempre vamos a hacer primero un repaso de la clase anterior. La clase que vieron el jueves pasado con Karina era los famosos Super Machines, modelos muy populares, los 90, los 90, uno se pone a ver por ahí, pero cosa los 90 todos Super Machine fueron los Reyers durante esa época desplazaron fuertemente a los modelos de de redes neuronales de esa época porque claramente eran más sencillos de usar, más fácil entrenal y lograban muy muy buenos resultados para para el contexto de la

00:08:40

lse posgrados: época. Inicialmente vimos lo el modelo base por el cual luego empezamos a a construir el supuesto machine, que es el maximal machine classifiers, que es un modelo que es que separa con una recta los conjuntos de

datos. El tema que siempre la la pregunta ante eso es cuál cuál conjunto, cuál recta es la mejor para poner, ¿no? Si ponemos ahí o lo ponemos por acá. Bueno, eso no es una recta, pero se entiende, ¿no? Eh, entonces lo que intenta este modelo es buscar una recta que maximice la distancia e el margen, digamos, o sea, la distancia entre las clases, bien, o sea, la genere el margen más grande posible. Entonces, o sea, busca que ese grosor sea lo más grande posible. Obviamente esto solo puede hacerse si el el problema es linealmente separable. Bien, los problemas que podemos separar con una línea recta entre dos se llaman problemas linealmente separables. Si estos modelos obviamente funciona si estamos en ese problema. Ahora el problema está haban visto que si el problema no esamente separable, no como acabo podemos aplicar este modelo y además es sumamente tiene muchísimo error de varianza este modelo con solo tocar algunas de las observaciones que vemos ahí de que son de box soportes, me cambia totalmente el modelo, cambia totalmente la dónde va la línea de dónde se ubica la recta.

00:10:40

Ise posgrados: Es decir, con con cambios del C entrenamientos puedo tener mucho error de varianza y eso me hacen malas clasificaciones. Entonces, e intentamos de alguna forma relajar las exigencias para que podamos tener mejor un mejor modelo. Y lo que habíamos visto era que, bueno, aceptamos cuando en este caso eh lo que le vamos a meter es un aceptar, equivocarse en nuestros datos de entrenamiento. Vamos a aceptar que algunos datos no estén o dentro del margen o queden del otro lado de la del digamos de la recta de clasificación en pos de poder mejorar eh generalizarlo. O sea, permite que este modelo funcione para problemas no lineamentos separables o que tenga no tenga tanto error de varianza, o sea, bajar un poco el de varianza, ¿no? Algo que recuerdan de allá me hace mucho inteligencia artificial, si vamos a bajar el error de varianza, obvio que vamos a subir el error de sesjo. Siempre vamos a hacer eso. Este es contraposición de uno del otro. Entonces, si voy a bajar el error de varianza, voy a subir error de sesgos. El punto es que bajo tanto el error de alianza que eres sego me me afecta poco. Entonces, cuando yo empiezo a a tener cada vez menos, digamos, aceptar cada vez más errores, obviamente el sesgo aumenta y para eso ponemos un un hiperparámetro que los permite hacer una regularización.

00:12:19

Ise posgrados: Lo tiene interesante esta regularización que vieron la clase pasada es

que es una regularización distintas a las regularizaciones que hab visto, por ejemplo, cuando mismo modelo de rige o de lazo, en el cual rige la nosotros le poníamos eh una penalización a los a los features, vamos a decir, ¿no? O sea, cuánto queremos que le le afectamos, como ejemplo la pendiente, si decir, de la de la de la recta, ¿no? los modelos de regresión y eso lo hacíamos justamente penalizando los features, de tal forma que con inclusive con lazo podíamos hacer selección de features y trabajábamos usab un buen usab un buen criterio para hacer selecciones más el TPD de de regresión ustedes hacían eso, o sea, usaban las y se encontraban que una de las uno de los features se podía quitar. En este caso, la regularización no ocurre a nivel ficher, sino ocurre a nivel observación, ¿no? Si ponemos esta regularización que me permite aceptar errores, o sea, error de clasificación o error de dentro del margen, es otra forma de revisar, pero en cierta forma lo estoy volviendo más duro, se deco, a medida que más aceptemos errores se hace menos varianza, o sea, que la recta varíe menos en función de las observaciones, el entrenamiento porque obviamente si pongo un error muy grande como está bueno un cooquer un C muy chiquito que sería un porque uno sobre C como tiene metido alquilar e o seaj dejamos que muchos observaciones puedan estar más clasificadas y pensamos eso un punto de vista extremo, básicamente si yo pongo una línea recta o una línea que no tiene ningún lugar sin ningún criterio,

00:14:10

lse posgrados: eh siempre va a ser malo, digamos, lo que voy siempre va a estar dentro de ese va a cumplir ese criterio. Y por más que cambie los entrenamientos, cambie los datos, más o menos siempre pasa igual. Bien, eso se le al extremo este, ¿no? Que dejamos tener mucho error. Entonces el error de alto acá porque claramente estamos viendo que esta recta no va a depender realmente de las observaciones. Entonces, yo cambio las observaciones va a ser lo mismo. en el otro extremo cuando tenemos un C muy grande, digamos, pues un sobre C, insisto, si vamos a permitir menos penalizaciones, vamos al más cercano el caso anterior, un pequeño dato que cambie de lugar me va a cambiar tremendamente la recta. Entonces, entgamientos distintos tener un error varianza más alto. Entonces el clasificado de vector soportes, obviamente busca siempre con una busca de parámetro encontrar ese punto equilibrio ese C que nos dé las suficientes penalizaciones para que no seamos tan sensibos de entrenamiento, pero que siga siendo un buen clasificador. Recuerden que una vez que entrenamos el modelo y termina de aprender y queda definida la recta, la recta queda definida solamente por las observaciones que están en los márgenes dentro o más clasificadas.

00:15:32

Ise posgrados: Esas observaciones son las que únicas que forman parte del juego del entrenamiento del clasificador. Si yo entrenara lo mismo, el mismo modelo, pero sin los otros datos, voy a dar lo mismo. No va a cambiar nada. Entonces, la frontera, o sea, hab visto cómo era, cómo era el cálculo, había estado estudiando eso. Lo que sí, ahora llegamos modelo support machine, el cual, okay, tenemos una frontera de clasificación de una línea recta, pero nada nos impide poder pasar otro tipo de frontera usando una transformación con funciones kernel que nos permite transformar las fronteras a otro tipo de fronteras. Esto lo hacemos justamente pasando a otro espacio vectorial en el cual ese espacio va a ser una recta, lo que en este espacio va a ser la forma que elijamos. Si vamos a elegir una forma de de polinomio, la forma radial, los diferentes ternos que vieron con Karina. Eh, eso ya eh en función del diseño que uno quiere es un hiperparámetro más al fin y al cabo, uno va a definir la frontera de decisión. Entonces el C sigue siendo lo mismo, sigue teniendo el mismo contexto, sigue siendo la penalización que estamos hablando o este parámetro regularización. Y la como digo, la función carnal ahora tiene que ver con esta idea de edición de de distancia de una forma de un espacio vectorial distinto.

00:17:02

Ise posgrados: Es decir, podemos pasar de rectas a este tipo de cosas como acá, que este caso es interesante porque acá tenemos en el medio magenta y alrededor azul. Y en estos dos problemas, o sea, este usamos un en este caso un problema de orden 3 y este un radial. Y siempre hago esta pregunta para ustedes, ¿cuál creen que es mejor? ¿Cuál creen los dos modelos mejor? ¿Alguno tiene alguna preferencia por alguno?
Cristian A. Aballay: Imagino que depende del problema también.
Ise posgrados: Bien, Cristian,
Cristian A. Aballay: Ah.
Ise posgrados: ¿por qué decís eso? ¿Qué es lo que te hace llevar a esa a ese comentario?
Cristian A. Aballay: Y en este caso por el por los ejemplos que vemos en
Ise posgrados: Pues fíjate, son los es el mismo datas,
Cristian A. Aballay: este
Ise posgrados: ¿no? Nada más que us un modelo radial acá y un modelo polinomio de orden 3. Ambos están clasificando bastante bien si te pones a ver, o sea, todos los magentes acá en el medio y estos los más gente acá y los está afuera. ¿Por qué? ¿Por qué radial sería mejor o sería mejor? Esa sería la pregunta.

00:18:25

Cristian A. Aballay: Ha.
lse posgrados: César.
Cesar Orellana: Sí, no sé si sí, en realidad el el de polinomio podría aceptar o podría clasificar puntos eh de color rosa mucho más que el que el que el radial, porque uno es un un circulito más concentrado.
Gabriela Sol Salazar: Ahí, perdón,
lse posgrados: Okay.
Gabriela Sol Salazar: puede ser que tengan algo que ver también los que aparecenos como márgenes. ¿Dónde están esas regiones?
lse posgrados: No, no necesariamente. O sea, e no porque fue hecho para entrenar el modelo. Una vez que tenemos el modelo,
Gabriela Sol Salazar: Oke.
lse posgrados: ya simplemente usamos la la frontera, ¿no? podido a a modo de de de crear el modelo, no hagamos no es un no es un punto importante para para la pregunta particular. Bien, César dice que el este por ahí es mejor porque este como que está más concentradito. ¿Alguien quiere challengear esa idea? Cristian dice, "Depende del problema." Ten un poquito más de para terminar de cerrar la idea, pero eh y alguien que le guste más este o nadie le gusta este. Les parece feo a todo el mundo.
Cesar Orellana: igual que todo va a depender del problema.

00:20:04

Cesar Orellana: O sea, uno va a clasificar ciertos puntos y el otro otros no. o por ejemplo, punto que sea radial azul, capaz que en el polinomial sea eh rosa. Entonces, todo dependerá del problema que queremos a dónde queremos llegar, ¿no? Queremos.
lse posgrados: Muy bien, muy bien. Sigue va por ahí. O sea, en realidad el C de entrenamiento solo se foca en esta parte. Bien. O sea, yo entrené en esta región no más o indistinto, ¿no? O sea, no importa dóe estemos parados. Entonces, el punto está en ¿Qué pasa si hay un punto acá? No, o sea, ¿qué pasaría ahí? Bueno, en realidad como no usé dato de entrenamiento ahí el modelo no sabe. Entonces y si yo tuviera hacer una predicción sobre esta zona cuando entrené en otra zona, es que sería estaría prediciendo una zona que el modelo no fue entrenado. Entonces la respuesta del modelo va a ser whatever porque bueno, cuando entrenó nunca tuvo

datos de ese lugar. Entonces, un poco como decí vos César, dijiste vos Cristian, depende el el del problema, porque yo de cómo se origen los magentas va a depender un poco de de cuál de los dos va a ser mejor, pero para poder hacer eso y una búsqueda de, por ejemplo, hiperparámetro me hubiese dado un poco más de pista es que si yo hubiese tenido datos acá, si yo no tengo datos en esta zona, bueno, qué s yo cualquiera de los dos, va a andar bien para este problema.

00:21:32

lse posgrados: Cuando nos vamos de la zona donde entrenamos, preparémonos. O sea, justamente en general no hay que hacer eso. Hay que intentar que los datos que vayamos usar para predicción tengan que estar en la misma zona que los datos de entrenamientos o si algún día no los tenemos recopilarlos para que en el futuro tengamos datos acá y el label verdadero y con eso ajustar el modelo, ¿no? O sea, porque tranquilamente este radial hubiese he dicho algo así por ahí, porque radial no es supamente una esfera perfecta. eh y hubiese estado bien o no, no sé, dependerá también cómo se originan los datos, ¿no? Si si esto deviene de una distribución normal de dos dimensiones, está perfecto porque este lo rongloba bien y este no. Bien, entonces son ese tipo de cositas que no a priori no son fácil de de saber hasta que no tengas el problema. Pero está bueno este este ejemplo porque te muestra esa idea, ¿no? Que para un set de entrenamiento, para un sedado, pu cualquier dos modelos son buenos. Este es el ejemplo que típico, ¿no? ¿Cuál es el mejor modelo? ¿Cómo elegir un mejor modelo? Acá el ejemplo, claro, el cual tiene un caso en donde los dos modelos son igual de buenos por andar bien, pero bueno, está bien bueno para lo que se usó para entrenar.

00:22:53

lse posgrados: Cuando lo vayamos de ahí, no sé, es más, no no deberían usar los modelos cuando se van de zona de usted entrenador o saben tengan las consecuencias de eso, ¿no? Y este es el ejemplo claro. Está lo que yo les decía, o sea, un poco la idea de un un una frontera que no es lineal, la función carne lo que hace lo transforma en otro espacio, en este caso, por ejemplo, tridimensional, el cual esa este transformación, esa esa frontera va a ser una recta. Entonces, en realidad lo que el problema hace es resuelve el problema en esa en este espacio, poniendo la recta igual que el modelo lo que vimos al principio de del de separación por por una recta, en este caso un hiperplano en realidad, digamos, dependiendo en qué espacio vectoral estemos. pone un plano acá y eso ese plano en haciéndola

antitransformada, volviendo al mundo este se significa un una forma de este tipo, por ejemplo. Entonces ese es el juego que hacemos con los carners. Y después vieron por último lo que es eh super machine en regresión, el cual se hace un poco de vuelta de tuerca. Acá se busca encontrar la recta que mejor mete todos los puntos dentro del margen, no fuera del margen con el clasificador o los carnes si queremos otro tipos de de de digamos de formas digamos y la penalización es cuánto aceptamos que esté afuera.

00:24:36

lse posgrados: Este es el ejemplo eh típico. Yo también en inteligencia artificial allá hace mucho para usted hace mucho porque fue pasó un año en el medio. Eh es el ejemplo de yo le decía, hay otros modelos de redacción que ponen una recta que no es el el modelo de de reacción lineal que ustedes que vimos con mínimos cuadrados. Este es el ejemplo claro de eso. La recta que va a ubicar este modelo va a ser distinta a la recta que va a poner el modelo de reción lineal con métodos mínimos cuadrados. ¿Cuál es mejor recta? y va a depender del problema, va a depender las suposiciones. Recuerden que en la reacción lineal, para que lo que decía el teorema ese deción lineal era que si se cumplieran las condiciones la recta que se ubicaban era la mejor, no iba mejor recta que esa. El tema que el 99,9% de los casos no se cumple las condiciones del teorema. Entonces probábamos, entrenábamos el modelo resolineal, veíamos si funciona más o menos bien, pero este es otro problema, otra forma de ubicar la recta, insisto, o sea, son eh otro modelo de regción que mete una recta, pero no necesariamente es un modelo de regresión lineal con métodos mínimos cuadrados.

00:25:49

lse posgrados: Ahí está. Esto es lo que yo decí las reflexiones. Entonces, con esto que tiene interesante frente al radción lineal, por ejemplo, recuerden la radiación lineal, nosotros teníamos los métodos de regularizaciones, pero los métodos de regularizaciones solo se enfocaban en los parámetros, en los features. podía ver cuál feature generaba tenía menos dependencia con con el, o sea, lo que terminaba haciendo indirectamente las modelos Riset, aquellas features que menos importancia tenían para la para el label, digamos, eh le daba menor importancia y eso hacía que la recta no se enfocaran tanto en sus obaciones. En cambio, en esos casos, en cambio en este es para el caso en el que pasaba muy seguido que la reacción lineal era un dolor de cabeza. Si tenías un no layer acá o tenías un valor

alejado, la reacción lineal, eso lo hacía pelota porque hacía que tu recta, que podía haber sido perfecta, se te fuera para arriba porque ese valor lo la empujaba, ¿no? Con este modelo lo que tenemos de ventaja es que yo puedo usar esta pronunciación para decir, "Che, los valores alejados, ignoraros." Bien, en cierta forma estoy diciendo eso, es como los valores alejados, digamos, aquellos valores que estén por fuera, digamos, del margen, o sea, aceptalo, aceptar valores por fuera del margen.

00:27:07

lse posgrados: Entonces, no lo no lo escuches a estos labios, no le des bola para tu ubicación de la recta y de esa forma con este modelo podemos tener buenas rectas que no se enfocan en los obliers. tengo más control mi regularización sobre las observaciones particulares y no tanto contra con respecto a los features. Bien, en cuenta eso, este no le va a dar tanta eh importancia a los features. Entonces, voy a seguir usando todos los features. El tema es que no importancia observaciones específicas. Bien, entienden esa diferencia porque eso está bueno para cuando veces tienen que tener en cuenta. Si ustedes van a tener problemas donde van a tener un layer de observaciones y más le interesa la regulsación de observaciones, es mejor enfocarse en este tipo de modelo y no tanto los de radiación lineal, lazo, R, etcétera. Bien, entonces tengan en cuenta es esa es una forma decir, bueno, ¿cuándo uso este modelo? Bueno, este es un ejemplo. Bueno, y bueno, vamos a lo que es lo que vamos a ver. Árboles, decisiones. Los pequeños y hermosos árboles. Los árboles, vamos a empezar. Fui muy rápido. Los árboles son, digamos, unas formas de clasificación, regresiones super viejas también son modelos muy muy de mucho tiempo atrás.

00:28:39

lse posgrados: Poderosa es una palabra que me parece demasiado exagerada, es una técnica de aprendizaje automático que tiene est doble utilidad, o sea, son modelos que te puedes usar tanto para para clasificación como regresión. Lo que tiene interesante es que tiene una estructura jerárquica de árboles que me permiten armar reglas, digamos, y y sobre todo me da mucha eh mucha interpretabilidad sobre lo sobre cómo cómo se hace la clasificación. Entonces, si necesito eh explicabilidad, los son buenos para eso. Muy fácil de entender cómo es que se hace la clasificación o la regresión, o sea, cómo es que llegamos a eso. Para eso vamos a hacer el ejemplo que vieron la clase pasada de los jugadores de béisbol, el modelo

redes que vieron que era, queremos predecir el salario del siguiente año de los jugadores de béisbol en base a sus estadísticas que tuvieron eh en el año anterior, ¿no? O sea, como le fue en el 86 redecir el salario del 87. Entonces, en este caso tenemos este árbol chiquito a modo ejemplo, el cual define que si vos tenés menos de 4,5 años de jugador, Ecuador tiene menos 4 5 años de experiencia, va a ganar 165,000 mensual, supongo. No sé, son jugadores se ganar mucho, poco, no tengo ni idea cuánto g un jugador este número que ven acá es porque es el logaritmo, hizo sobre logaritmo, pero a modo de eh que también ya lo vieron con Karina, pero bueno, este número que no importa son 165,000.

00:30:26

lse posgrados: Ahora, si el jugador tuvo más de tiene más de 4,5 años de experiencia, vemos la estadística de hits. ¿Cuántos hits tuvo durante el 86? Hit Hit será, será, no no me me acuerdo. acuerdo. Dice Dice acá, acá, no no me me acuerdo. acuerdo. Mientras Mientras indica indica el el número número de de hit hit logrados logrados. no No dice dice nada. nada. Esto Esto no no dice dice nada. nada. Pero Pero el el hit hit un un número número de de hit hit logrado. logrado. Creo Creo que que Hit Hill cuando cuando le le pegan, pegan, creo creo que que es es cada cada vez vez que que le le pegan, pegan, no no es es cada cada vez vez que que eh eh no no es es home, home, no no sabes, sabes, ni ni no no ni ni corrida, corrida, nada. nada. cada vez que le pegan, creo. Eh, entonces si tuvo menos de 117,5 va a ganar $400,000 y si tuvo más de eso $,000 50,000.

00:31:15

lse posgrados: Bien, entonces fíjense que tiene es muy fácil de interpretar, es muy fácil de ver. Listo, cuando tanto tanto años, listo, ganar esto. Tiene tanto tanto tiempo, tiene más de tantos años, eh, tantos hits, tanto tanto. Bien. muy muy fácil de leer y interpretar lo que está cómo está haciendo las cosas. Recuerden el problema que con la forma que lo resolvió Karina, que esto no era obvio cuando hac el modelo, los modelos de de super machine, ¿no? Entonces, lo que estamos viendo acá es que básicamente tenemos como tres regiones, ¿no? La región uno que está formada por dado la variable ir -45, o sea, todos los todas las observaciones que tienen -4,5. Este caso tiene todas las observaciones que tiene mayor 4,5 y menor a 17,5 y este cu observaciones que tiene mayor año 4,5 y hit mayor 11 11,7,5. Es decir, si vemos el set de entrenamiento, veríamos que están divididas estas regiones, ¿no? La región uno es esta que ven acá. Esta es la otra región. Eh, tengo el Esta es la región dos

acá. Y esta es la región tres, en el cual digo, estos son los el entrenamiento, ¿no?

00:32:36

Ise posgrados: O sea, son los datos que usted para entrenar y tengo dividido todos los jugadores acá. Ahora, el número ese que acabo de dar, es el número mágico, ¿no? Este número raro decir, ¿por qué este número tan específico? lo obtengo de agarrar y decir, "Bueno, agarro todos estos jugadores que tengo mi entrenamiento, todos estos jugadores, todos la región uno y le calculo el promedio del salario que cobran ellos, ¿no? Entonces para la región uno, el salario que estimo que va a tener un jugador es el promedio de los el salario de los jugadores. En la región dos hago lo mismo y la región 3 hago lo mismo. Entonces, ese número que estoy prediciendo label es el promedio, la medición de posición central que estoy eligiendo para ese caso. Eh, ya te dijo Gabriel. Obviamente podemos usar cualquier otra medición de posición central, no necesariamente la media, puede ser la mediana, otra cosa. Decíme, Gabriel.
Gabriel Quiroga: Sí. Eh, si yo calculo el promedio de todos los jugadores de la región uno, la cual determiné a partir del promedio, no es como cuál va primero en ese caso, porque porque sí, o sea, hace 4 años y medio lo saqué de de esa de esa

00:33:54

Ise posgrados: No, no, ya ya vamos a ver cómo cómo se trataforman las regiones.
Gabriel Quiroga: región.
Ise posgrados: Todavía no no llegamos ahí, pero pero o sea, una vez que tengo la región,
Gabriel Quiroga: Ok.
Ise posgrados: calculo el promedio y tengo el el cuánto va a ganar, pero ahora vamos a ver cómo se construyen los
Gabriel Quiroga: Amén.
Mariano Jauffroy: Eh, mi pregunta era un poco lo mismo,
Ise posgrados: vale
Mariano Jauffroy: este, ¿cómo haces para determinar eh el año, digamos, para dividir las regiones? ¿Cómo elegí ese año?
Ise posgrados: una muy buena pregunta. de ambos, digamos, justamente ahora vamos a ver cómo cómo se construyen estos árboles, cómo se hace esa cosa tan arbitraria como por qué elegí 4,5 años, qué me llevó a hacer eso entonces antes de decir un poco más, un poco más de definiciones, cuando hablemos de hojas del

árbol, estamos hablando de los donde está la predicción final. Bien, eso son las hojas o leit. Y cuando hablemos de las partes donde se divide son siempre árboles binarios, ¿no? Para un lado, para el otro en función de un valor o de una clase, porque si varas categóricas este modelo no tiene un problema si es de una clase o no es de esa clase, es de boca, no es de boca.

00:35:10

Ise posgrados: Entonces va moviendo así. Eh, se llama ramas, branch interno. Como digo, esta es una una simplificación excesiva, digamos, entre hits, pero como le digo, empezar como construimos el árbol lo su ventaja es est fácil interpretar una vez que no importa, mágicamente apareció este árbol es okay, es fácil interpretar. Yo más o menos sé que un jugador que que está menos de 4,5 años va a ganar alrededor de esto. Bien. Y fíjense que es interesante, que frente a otros modelos de regresión este no intenta decir perfectamente cada una de las observaciones, sino tener una idea más general construida alrededor de cada región. Bien, o sea, en los otros modelos de redón veíamos que una observación intentamos redecir perfectamente esa ese esa observación. En este caso no tan así. Entonces, ¿cómo hacemos para armar eso? Estamos diciendo que ahora sí respondemos las preguntas. Entonces, dividimos el espacio de observaciones, es decir, conjunto de valores posibles de x1, x2, x2, xp en j regional distinta y no sola pad de R1 alrededor de RJ. Es decir, vamos a definir primero antes de empezar aar el árbol es que vamos a separar el árbol en rectángulos, no solapados.

00:36:37

Ise posgrados: Bien, como vimos, rectángulos porque son usando esos atributos. Bueno, esto ya lo dije como eh esto es lo que acabo de decir, no no voy a perdón, quería hacer esto. ¿Cómo divimos eso? Esa es como armamos el como les decía, la vamos a dividir en regiones rectangulares porque simplifica el modelo, pero tranquilamente podía haberse otro tipo de regiones. El objetivo, vamos a tener que encontrar una métrica que nos permite minimizar en este caso las la las combinaciones de regiones que minimicen la suma de los residuos al cuadrado. ¿Cómo calculamos la suma de los residuos al cuadrado? es la suma para cada una de las regiones que tengo. Dentro de cada región calculo la distancia de una observación, el de label de la observación menos el valor promedio, el valor central que estoy usando al cuadrado. Entonces, quiero encontrar la sumatoria de todos estos valores que minimicen este número. Bien, decir, para cada región, cada

muestra, la distancia de esto al cuadrado y el valor más chico de esto. Eso va a ser lo que me va a ayudar a construir el esa métrica. Entonces, ¿cómo ha llegado a cabo la división? Es bastante fuerza bruta.

00:38:03

Ise posgrados: Si lo pensamos buscar todas las combinaciones, obviamente no es algo que podemos hacer. Vamos a seguir probando todas las comiones, no va a llevar infinito, pero vamos a hacer un un algoritmo que es griy que vaya desde arriba para abajo separando de forma binaria el las regiones. Se llama top, se llama recurs down. Empezamos desde el tronco del árbol a empezar desde la primera clasificación hacia abajo hacia las ramas y gride porque gride cada paso vamos a elegir la bifurcación que más reduzca este error cuadrático. Bien, sin considerar el efecto del lugar, siempre vamos a ir por el más el más cambio más grande porque sabemos de aquello de aquello inteligencia artificial que hay caminos a veces que por ahí en un paso inicial hubiera decidido pierdo menos RSS, pero si sigo avanzando me voy a encontrar un mejor una mejor digamos separación que hace que ese camino fuera mejor. En este caso no siempre vamos a mostrar una sola observación por vez. Decme, Gabriel.
Gabriela Sol Salazar: Sí, hay una pregunta. En general, el tronco de largo es algo también que lo elegís aleatoriamente si tenés muchas features, por ejemplo, ¿qué tomas vos como tu punto de partida?
Ise posgrados: Bien, justo que lo me dejas para la siguiente diapositiva.

00:39:26

Gabriela Sol Salazar: Okay.
Ise posgrados: ¿Cómo partimos? Eh, básicamente yo tengo un montón, tengo las variables. Entonces empiezo a probar, elijo la variable uno y empiezo a probar diferentes niveles de cortes. ¿Qué pasó acá? ¿Por qué se hizo eso? Eh, perdón, se me rompió todo. Se me rompió el concepto. Ahora sí, eh, o sea, elijo, por ejemplo, eh, años, empiezo un sian números enteros. En este caso número entero voy doblando o la mitad, ¿no? O sea, para hacerlo más fácil 0,5 1,5 y va probando. Hits es un número. Empieza a probar. diferentes valores. Bueno, si un número un número un número, digamos, sí, flotante, bueno, lo va lo va a discretizar, digamos, de una forma, va a separar en región. Lo importante es que lo va a separar y va ir probando todas las combinas, o sea, todos los casos y va a ir con cada uno y probando esto. Va a separar al espacio inicial que es uno solo, tenemos todo el C entrenamiento en dos

regiones y va a probar todas las combinaciones, separación de rol de regiones.

00:40:40

Ise posgrados: En cada una de ellas va a calcular el RSS. Bien, yo tengo el RS inicial porque yo tengo la el promedio de todas las observaciones puedo hacer y el los valores calculo del RCS y después pruebo la suma de las nuevas dos regiones que voy probando, pero voy probando todas las comid todas las combinaciones y me quedo con la que mejor eh mejor reduce este ese valor. Bien, el que minimiza la suma de los residuos del cuadrado más en esa combinación, pero es probar todas las combinaciones. Si tengo 20 variables, probar las 20 variables con todos los valores posibles. Así todo es relativamente rápido hacer eso, no le lleva mucho computacionalmente. Parece bastante tedioso, pero tampoco es el fin del mundo. Pero es eso. ¿Cómo eligió año 4,5? Literalmente probó año, hits, whatever. y se encontró que el que mejor inicialmente se paraban mejor en dos al centamiento era años en 4,5. Eso es toda la explicación, no hay mucho más. Luego va agarrando y es muy parecido, ¿se acuerdan cuando hicieron el de el de KNN que cómo hacía para encontrar la distancia y que iba como separando un?

00:41:59

Ise posgrados: Bueno, acá va a hacer lo mismo. Va a separar dos regiones. Luego va a ir a una región de las dos y va a hacer lo mismo. Va a separar en dos y encontrar aquella combinación de variables y se para y así va probando en todas las combinaciones hasta que llega un punto de corte que es decir, bueno, listo, acá cortamos y llega esa profundidad del árbol. Ahora vamos a ver por cuándo cortamos eso. Pero hay un criterio de decisión podemos podemos cortar por un valor de RSS, por un valor de profundidad del árbol, por otros tipos de criterios. Entonces, acá está el ejemplo, ¿no? Es decir, voy a usar color amarillo si tenemos otro colorinta, ¿no? Entonces, ¿qué significa esto? Fíjense, en la primer en el en la raíz, fíjense, tenemos dos variables, tenemos la x2 y la x1, no este problema. en la prim en la raíz en la región entera, entonces voy a poner acá arriba para hacerlo más fácil de la región entera de de clasificación de del perdón de regresión del x2 de entrenamiento x1 se encontró que t1 es el que mejor reducía el RS ese que está por acá. Entonces ahora tiene dos regiones, tiene región de la izquierda y la región de la derecha.

00:43:13

Ise posgrados: Son las dos ramas que ven acá esta rama, una rama, cada uno una región. para esta rama que ven acá dice, se observa que luego que sería este de acá, esta zona de acá, que si x2 es menor que t2 va a reducir más el RSS y lo pone por acá. Pum. Y para esta rama, fíjense, vuelve a ser X1 porque no significa que en cada nivel pue tiene que ser otra variable. Puede ser la misma variable porque vuelve a entrar en juego en cada nivel. Nada más que ahora la región que va a tener va a ser de acá a acá, no va a ser de todo el rango de valores. Y acá control que en T3. Entonces acá pum, se para. Esta le quedó la región tres. Esta es la región, le vamos a llamar región dos y la región un. Y luego para esta región que le quedó encontró que eh cuando x2 menor que 3 cuidan dos regiones y eso es toda la ciencia, todo el secreto que hace. No hace nada de otro mundo, simplemente prueba y siempre va quedándose con el que más le genera cambio en RS. El que mayor delta le genera ese dije y con ese separa.

00:44:34

Ise posgrados: Eso es todo. Bien. Ahora, ¿qué problema tenemos? Yo puedo armar un árbol que tenga RS C0. Bien. ¿Cuál es ese valor? ¿Se acuerdan que habíamos dicho que una región va una región y tengo las observaciones? Calculábamos el valor cuadrático del del digamos del valor del label con respecto al al valor posición central. Yo tengo el caso extremo en que cada región tiene una sola observación. El error cuadrático va a ser cero porque la observación es el mismo promedio, es el mismo número, digamos, el entonces el label de de ese de esa observación va a ser el valor promedio. Entonces eso menos eso al cuadrado cer la suma de todo va a ser cero. Entonces, si yo este árbol lo dejo, lo dejo construir, construir con este algoritmo, lo que va a terminar construyendo es un árbol enorme en donde cada hoja va a ser una sola observación y ese árbol va a ser perfecto la del RCS, o sea, para el ser entrenamiento va a tener un valor cero de error cuadrático. Eso es un overfeitting de acá la China, no estoy overfiteando al máximo, o sea, estoy poniendo una hoja por cada observación.

00:46:09

Ise posgrados: es algo que no está bueno, que no tenemos que hacer. Entonces lo que se hace se poda el árbol. Bien, como le decía acá, eh, una hoja por cada punto. Entonces, un árbol más pequeño con menos regiones puede tener menos varianzas

porque este va a tener muchísimo error de varianza, ¿no? El árbol grande. Si yo cambio es entrenamiento, me cambia totalmente el árbol, todos árbol distintos. Entonces, un árbol más pequeño con menos regiones va a tener menos varianzas, ofrece mejor interpretatividad, pero vamos a tener un leve aumento del C al punto que tengo en contra ese punto de equilibrio. La estrategia más obvia sería construir el árbol únicamente mientras la disminución de RS sea mayor a un valor umbral, ¿no? Decimos, "Bueno, listo, vamos a poner un nivel, eh, un un valor, decimos, listo, si ya llega reducido hasta este valor, cortamos el árbol, este, y listo." ¿Cuál problema tiene esto? es que un resultado va a quedar aos más pequeños, va a ser mejor, pero va a ser que tengamos que, por ejemplo, situaciones en donde podemos perder eh cortar en un momento donde podem haber reducido mucho el RC, bien, y eso nada, vamos a perder un mejor árbol que tenga mejor, digamos, eh resultados sin perder generalidad.

00:47:41

Ise posgrados: Entonces es por eso que no es la mejor estrategia cortar dado un valor umbral de RS. Entonces, ¿qué otra forma lo podemos hacer? Es como decía, podar es eliminar hacia atrás. Para eso es control el árbol gigante de cero y luego lo vamos podando para obtener un árbol más simple. Entonces, que cómo lo hacemos intuitivamente buscamos un subárbol que minimice el error de validación. Tenemos que medir validación y ver cómo hacerlo. El tema está en que esto también es complejo resolver mediante simple iteración por lo que tenemos que estar haciendo muchísimas pruebas. Entonces se busca un método más sistemático y obvio que iba a aparecer la regularización, ¿no? O sea, siempre que tenemos error de varianza, tenemos la regularización como herramientas para ayudarnos a encontrar un mejor árbol de caso. Fíjense en que ahora vamos a definir al eh la métrica del árbol como el RSS más un factor de penalización en el cual L es el número de hojas de este árbol. Entonces, fíjense que si tengo el árbol muy grande, el infinitamente grande, con tantas hojas como observaciones, esto va a ser muy grande. Entonces, por más que sea cero esto, este valor lo va a penalizar.

00:48:57

Ise posgrados: Bien. Entonces, este va a hace que evitemos irnos a un al máximo al árbol más grande de todos. Entonces, con este valor alfa yo encuentro el compromiso entre la complejidad del árbol y la capacidad del ajuste. No tengo encontrar ese punto. Si elijo alfa cer tengo el árbol más grande posible. A medida

que alfa aumenta, el costo por tamaño de la crece, forciendo modelos más simples. Algo interesante que pasa con el alfa es que aumentamos desde cero las ramas se ponen de forma anidada y predecible. Es decir, si yo lo que puedo hacer es no tengo que armar para cada valor de alfa y ver qué árbol tengo, yo puedo armar el T0, el árbol más grande y después agarrar, construir todos los árboles porque se se van reduciendo de forma predecible, tal por como el algoritmo de Gridi, la forma en que se va a ir siempre quitando va a ser sistemáticamente igual. Entonces, yo puedo tener en un solo paso todos los árboles posibles que voy a tener dependiendo del valor de alfa. O sea, no no necesito construirlo para cada alfa, uno distinto. O sea, ya sé si elijo un valor de alfa cómo se va a podar ese árbol.

00:50:11

Ise posgrados: Entonces, eso es lo bueno tienes. Como no tengo que estar construyendo yo, insisto, la búsqueda de parámetro es mucho más barata porque ya está, lo una sola vez y listo. Después busco el Balfa y inmediatamente lo encuentro. ¿Cómo seleccionamos alfa? obviamente con búsqueda de per parámetros, variación cruzada y por eso podemos encontrar aquel valor de mejor eh el mejor algo. Entonces, ¿cómo es el algoritmo completo en regresación? Utilizamos recursive Bor Splitting, el cual creamos el árbol más grande con el conjunto de entrenamiento, determinando el proceso cuando cada hoja contenga menos de un número mínimo de observaciones. Luego aplicamos la técnica de poda del árbol para coner el conjunto de subárboles. Funciona el parámetro alfa. Como digo, tenemos todos los subárboles posibles y usamos valón cruzada para determinar mejor alfa, que nos va a decir, bueno, este es el que mejor reduce el error de varianza antes que suba el sesgo. Entonces, este va a ser mejor. Elegimos el mejor subárbol y ese sería el que vamos a usar. Vamos un poco a la práctica para entender un poco más lo que estoy diciendo. Bien, entonces si ustedes se fijan en la clase cuebook de Júpiter árboles, tenemos este notebook llamado árboles que vamos a usar para inicialmente el dataset este que vimos recién de los jugadores de Entonces cargamos el dataset, veamos un pequeña información de dataset,

00:51:55

Ise posgrados: vemos que tenemos diferentes atributos como kits, hemos visto home runs, corridas son las corridas de que lo entiendo que son las corridas en una de Y no es toda la vuelta, creo que es solamente de una base a la otra base o este creo que era toda la vuelta y este era bueno una de las dos era, no importa la

cantidad de años que tiene de experiencia y otras estadísticas más que ven acá. Y eh como ven acá el salario es una de las métricas de que es el label queremos predecir descripción. Esto es un una descripción de los atributos. No tiene ningún valor nulo, no tiene nada raro, está bastante limpio de base. Como digo, acá quitamos de heer el salario. Ah, perdón, sí tienen los nulos. ¿Qué dije? Eh, este no, este no lo mide acá, perdón. Justo el único, el que tiene valores nulos es justo el salario. Unos jugadores no tenemos el salario. Eh, quitamos aquellos porque obviamente no me sirve nada de esas observaciones porque yo quiero predecir salario. Entonces, obviamente que no tiene sentido tener. Y luego calculo el logaritmo está muy chico, el logaritmo de el salario.

00:53:16

Ise posgrados: Acá graficamos y vemos algo que ya le había mostrado Karina de cómo se transforma el salario, algoritmo del salario que hace que sea más es mejor predecir, digamos, el orden de magnitud, mejor la distribución que eh que el valor exacto. En cierta forma, en cierta forma el organismo salario es decir eso, el orden de magnitud me importa más que el valor exacto. Aparte tiene este tipo de mejor este tipo de distribuciones, digamos que es se pegan todo para un lado y te queda un poco valor alejado, tiende a distribuir mejor los valores. Entonces, para para trabajar el modelo, para modo de simplificar un poco el problema, voy a separar solamente estas observaciones, bien, estas, perdón, estas features. ¿Por qué? Porque quiero, no, no hay ninguna aplicación. Eso se llama el X y el I. Y ahora vamos a separar el dataset. Fíjense en que un 40% me quedo observaciones para testeo. ¿Por qué? No nos olvidemos que cuando menos observaciones tengamos más le tengo que dar a testeo en proporción porque si no no voy a tener suficiente para probar realmente si el modelo bien. Bien. Recuerden eso, la proporción cuando más observaciones tenés, más chico puede hacer esto y más poso para entrenar pero cuando tenés poco dato de entrenamiento es mejorar más proporcional de testeo para poder medir si realmente estás generalizando el modelo.

00:54:56

Ise posgrados: Entonces, ¿cómo usamos un árbol en Sey learn? Tenemos el dentro de la sublibrería dentro de Skinan Tree tenemos el módulo Tri, digo, tenemos decision regreso. Eso implementa el modelo de de árbol que dijimos. Si hacemos clic en este link, voy a llevar tengo páginas que no quiero que vean. Ahora sí. Eh, si ustedes se van acá a la a la librería en general está bastante buena, está bastante

descriptiva. Ustedes tienen la guía de usuario también tiene como más detalle inclusive cómo funcionan. Eh, y está toda la explicación muy similar a la que acabo de dar yo, ¿no? Entonces, tiene bastante buena la documentación. Y fíjense que dentro de los argumentos que vamos a tener, tenemos el criterio, el error cuadrático, que es lo que estamos usando la métrica que yo les dije, splitter best, porque tiene dos tipos de de separación. ¿Ves? Es el que mejor reduzca el el error cuadrático y después tiene uno que llama random, que no nosotros no lo vamos a usar ahora, no tiene mucho sentido, que es eh usado para separa el azar, no realmente no utiliza eso, se para el azar, es para otro tipo de cosas.

00:56:17

Ise posgrados: Además puedo contar hasta qué profundidad quiero llegar, cuántas muestras mínimos quiero usar para hacer un split. Este caso, por defecto está el mínimo posible. Tiene que haber dos muestras para hacer un split. El c la tienda de muestras mínimas por hoja está hecho el extremo más grande, una sola. Eh, después tienen estos yo puedo dar como importancias a a pesos de valores de separar. Eh, esto si quiero controlar cuántas features máximas quiero usar. Esto sirve para algo que ya la clase que viene. Eh, esto clásico random state y eh el que me importa. Esto también son otras cosas que ya van a ver más adelante. Este que es importa. Este es el alfa que les acabo de mencionar. Este es el parámetro que controlamos el podado. Entonces, yo cambiando este valor puedo encontrar el alfa que yo quiero. Bien, si quieren ver por acá la explicación. Bueno, si aparece alfa. Acá está. eh complejidad usado para el pruning de mínimo costo de complejidad. Entonces acá fíjense que está también de vuelta, insisto, la explicación se aceran de algo muy parecido, lo estamos mencionando por si quieren ver también la documentación aparte de la biografía de de la materia.

00:57:44

Ise posgrados: Volvamos a la al notebook. Entonces creamos el árbol. Fíjense el criterio. Error cuadrático. Splitter best. Eh, máxima profundidad ninguna, o sea, lajamos que llega hasta el final. Es dos de mínimos muestra y de hoja uno y debe dejar random state simplemente por reproducibilidad. Recuerden, est eran parámetros por defecto. En realidad, yo no tenía ninguna necesidad hacer esto. Yo tranquilamente podía haber generado hacer esto y es lo mismo. O sea, siempre estoy dejando explícito para que les quede eh que usamos, pero en realidad esos valores que acabamos de elegir por defecto los eliges. Hay que hacer esto es lo

mismo que acabo poner ahí. Fíjense, ¿ves? Eh, mínimos dos, un tres y square por defecto son esos. Fíjense que esto les pone rojo e cuando ustedes modifican alguno de los valores. Bueno, acá está de vuelta lo mismo, ¿no? Ahora hay armad entre lo bueno de los árboles que podemos ver los árboles. Eso es algo tiene muy bueno frente a otros modelos. Yo puedo ver cómo es el cómo se armamos el árbol.

00:59:05

Ise posgrados: Para eso podemos usar la eh librería esta que se llama dentro de de Cam la función export grabis. Y fíjense acá le paso el modelo, le pongo el archivo que quiero que genere, los nombres de los features, que redondee y esto ya que va a colorear ya con eso vamos a ver o lo podemos ver directamenteado. El tema es que fíjense que el árbol es tan grande que no tiene sentido. No sé. No se ve nada. Entonces, con Grad Bits, para los que no saben qué es Grad Bits, es una eh no sé si es una librería, un estándar, que sé, que te permite graficar grafos. Bien, te genera un archivo de texto que ustedes se pueden a ver este que genera acá, que tiene armado un grafo con los distintos nodos, con valores y cómo se unen, ¿ven? las conexiones. Entonces, yo puedo construir cualquier tipo de grafo con esto. Es bastante sencillo de entender. Parece parece un montón de texto y María, pero en realidad es bastante sencillo de usar. Yo me acuerdo para para otro tipo de trabajos en su momento creé eh mi propio gerado de graf usando esto un poco de lógica y lo armaba, o sea, quería armar de tipos de nada unos unos unos unos pipeline quería ver y lo hacía con eso y funcionaba re bien es bastante sencilla de usar.

01:00:29

Ise posgrados: En este caso podemos usar esta página para que vemos que nos permite visualizarlos. Bien, entonces acá voy a pegar. Fíjense acá un ejemplo. Gráfico, generan, ¿ven? Entonces voy a pegar el archivo ese que acabamos de generar el contenido. Lo voy a pegar ahí. Veamos. Y acá se genera el grafo. Fíjense en que, o sorpresa, años no estaba al azar cuando armé la diapositiva. Es el que mejor se para inicialmente los datos. Bien, ese aquel que el mismo de que acabamos de armar GD mejor se para los datos. Y acá fíjense que empieza información interesante que nos arma. Tenemos el valor, el error cuadrático, cómo era inicialmente y fíjense cuando vamos a los nodos, cómo reduce de cada región. Paso de 077,49 a 0,3 + 0,4. Tenemos que sumar esos dos para saber la relación. Es más chico. 0 com a A ver, 0 es más chico. Estoy loco yo. Pon L. Creo que sí.

01:01:48

Ise posgrados: Sí, es un poquito más, chico. Entonces, recuerde, al reducir las regiones tienden a tener que bajar los valores. Después me dice, ¿cuántas muestras tiene esta región? 157. Y el valor es el valor promedio, o sea, el valor el valor si yo estuviera parado en este nodo, ¿cuál sería el valor que predecería? Como no es una hoja, no es el valor de predicción. 5,9. Cuando se paró para la true, por ejemplo, acá ahora le quedó 51 muestra de este lado. De otro lado quedó el resto de las muestras. Acá de vuelta para volver a separar usa de vuelta years y ahora separa este false. Esto creo que es true, ¿no? Ya perdí. Creo que es para este lado tr, no me acuerdo. E y fíjense, se va armando toda la decisión, ¿no? Y fíjense que el color que están viendo es el valor. Cuando más grande es el valor, más oscuro es el nodo. Bien, es para eso usa el color. Cuando yo puse feel true es usó esta idea, rena con color para usar esta este colorado.

01:02:50

Ise posgrados: Obviamente uno dice, "Pero esto vos decís que interpretable esto. Esto es un asco." Sí, es un asco, ¿no? Este no es interpretable este árbol. Este un árbol muy grande que además tiene, fíjense, en cada hoja tiene una sola muestra. El error cuadrático es cero. Claro, porque tiene una sola muestra. Este no es un árbol interpretable, lindo de usar. Este es un árbol quefitea y que es una porquería. Bien, entonces se mira lo que es ese árbol, una basofia. Pero eh vamos a apodarlo un poquito y con eso vamos a ver cómo mejora. Importante es que lo bueno tiene esta herramienta nos permite dar una idea o noción de qué está pasando. Bien, por dónde van las cosas. Entonces ahora miramos las métricas, ¿no? Tenemos el error de la predicción. Vamos a hacer una predicción y la el del tren del digamos vamos a ver el el cómo predice el modelo con el C de entregamiento y el C de testeo y vamos a medir el la media absoluta, error de error medio absoluto. Fíjense error de entrenamiento 0,0 y claro, obvio, si hicimos un overfeitting, perfecto, 0,46 sería el error de testeo.

01:04:26

Ise posgrados: El resultado claramente estaba diciendo overfitting, entonces tenemos que buscar, como les decía, algo que nos permita eh mejorarlo. Ahora,

veamos dónde estamos parados. Entonces, para ver eso, voy a armar una reacción lineal simplemente para saber cómo estoy parado frente a esto que acabo de hacer. O sea, estoy bien, estoy mal, qué sé yo, es 046. Realmente tengo overfitting. Sé que para ahí tengo que arreglar esto, pero este número que ven acá es bueno o malo, no sé, no tengo referencia. primero eh un modelo re lineal, no me acuerdo los cómo le había dado Karina con la eh con el caso de la super machine, pero en este caso es una reacción lineal. Voy a primero estandarizar las los features porque esto es un modelo de reacción lineal y vamos a ver cómo nos va. Ah, R era eh no da 052, o sea, así todo con lo malo que es es mejor que una recio línea. Bien, ahora es mejor, pero tampoco hay no más y sabemos que esto es inviable. Bien, cuando, o sea, recuerden esto, si ustedes tienen esto es inviable. Por más que sea mejor que esto, esto es inviable. No, no pueden tener un modelo así, no pueden vivir con este nivel de overfeitting porque saben que cualquier cosa les va a reventar, bien, les va a explotar en la cara, no está generalizando este modelo, pero bueno, así todo es mejor que una reacción lineal.

01:06:02

Ise posgrados: Juguemos con el valor, yo les decía el alfa. Bien, entonces para eso lo voy a hacer es ahora crear el árbol. y hacer variación cruzada. Eh, ¿qué dice acá? Eh, ah, de prueba, perdón. Hago validación cruzada con el caso del árbol, digamos, de más grande posible, ¿no? Con BFA igual a CER. Vayación cruzada de C. Usamos el error absoluto medio. Eh, error absoluto medio. Recuerden negativo por cómo funciona esta función. Eh, simplemente es eso, se usa esa función, usa el negativo por como está hecho para encuentre el valor más alto, entonces usa el negativo para el valor más bajo, perdón. Entonces usar el negativo le sirve invertirlo le sirve para poder generalizar cualquier tipo de búsqueda. Y en el shops era para que use la mayor cantidad de procesos que tenga mi máquina que pueda disparar Python acá. Entoncesamos esto para no lo ¿Por qué hizo eso? No tenía que haber hecho si no había portado. Sospechoso, muy sospechoso. Bueno, eh vemos que el error medio cuando alfa es 0 es 054. No es esta vez me dio muy distinto.

01:07:37

Ise posgrados: Okay. Bueno, 054 no es muy cercano. 54 46 no es muy bueno. Vamos ahora a hacer búsqueda de parámetro de una forma una búsqueda en grilla, de una forma más berreta posible la forma que vieron inteligencia artificial. Ciclo for que voy probando todos los valores posibles de alfacular la la variación cruzada. Y listo.

Un data frame con los resultados. Bien, recuerden que con la búsqueda grilla esto lo tienen todo resuelto, no tienen que hacerlo de esta forma. Nos quedo acá para qu de forma explícita, pero nada más. Y lo que Ah, sí, por hice esto, porque yo quiero guardar esta información que es quiero guardar cuántas hojas les queda eh en cada árbol de la búsqueda en grilla. No voy a poder sacar esa información. Yo aprovecho esto y puedo sacar información extra. Por eso lo implementé así. Entonces, fíjense que acá obtengo todos los árboles con alfa, cer distinto valor de alfas. Estos son, acuerdas, son cinco árboles cada uno y eh la métrica, el valor, el valor de la del de error cuadrático medio paraación cruzada.

01:08:46

lse posgrados: ¿Y cuántas hojas? ¿Ven? En el caso alfa 0 tengo 153 hojas porque eh es la máxima cantidad de separación que tiene el árbol. Cuando basamos a un alfa de 0,5 tenemos 67 hojas. Fíjense como reduce y así van disminuyendo. Entonces si graficamos eso, vamos a ver esta métrica. ¿Ven? Acá vemos el tamaño del árbol en función de del error cuadrático en función del del tamaño del árbol. Inicialmente tiene un valor muy alto, cae mucho, o sea, un árbol muy obviamente un árbol de muy poco nivel, un valor alto cae y luego sube y se estabiliza en el valor este que veíamos hoy, 054 más o menos con esta varianza, una varianza muy grande. O el valor de alfa versus mae, vemos que el mínimo está en esta región de acá, o sea, vemos que inicialmente está abajo, cae y sube. Esta forma que habíamos visto, ¿se acuerdan cuando habíamos mostrado una variancia sesgo? Más o menos nos da esa gráficaente nunca tan linda como vemos en los libros, pero est idea es eso. ¿Qué valor de alfa elegir?

01:09:55

lse posgrados: Un valor que está por acá. Uno diría, bueno, pero ¿por qué elijo este, no este acá? No, este acá es que no importa porque en realidad eh en toda esa región el árbol el árbol siempre se genera el mismo árbol en realidad. El podado sistemático, ¿se acuerdan que les decía que el árbol el árbol que se genera no es que si elige ese valor de alfa siempre va a elegir el mismo árbol por cómo se construye. Entonces todos los valores de alfa ahí construyen el mismo árbol. Recién cambia cuando este valor. ¿Por qué? No, nada como el el problema en particular. Yo elijo un valor de alfa de 0,06. Con eso me da este valor. Entonces ahora creamos un alfa de 0,06 y volvemos a calcular todas las métricas y algunas más. Y fíjense que ahora nos quedamos en 049, es decir, el modelo no mejoró, pero al menos ahora sé

que no estoy overfiteando. Es mejor que modelo regón lineal y no estoy overfiteando. Bien, entonces esto me da seguridad que está al menos pareciera ser que está generalizando.

01:10:54

Ise posgrados: Bien, entonces estoy pagando un precio de super ten un poquito más de error, pero el precio de pero el beneficio es saber que no estoy bfiteando. Veamos cómo nos va, cómo es el árbol este que armamos. Bien, mucho más chiquito también viendo. Fíjense, acuérdense en el anterior era este. Este era mucho más chico. Se van a sorprender mucho. ¿Qué árbol es? Teníamos el árbol viejo. Generamos. Oh, y este árbol es el mismo que vimos la diapositiva inicial. El mejor árbol para este problema particular, para ese subset de features, es el árbol que vimos en la diapositiva uno. Es año mejor menor 4,5 true, si no es false y hits se fija hits y si es hit va para un lado para el otro va a ser un valor. Uno dirá, uh, pero 17 18 17,5, pero este es menor o igual. no no cambio mucho, es lo mismo, básicamente. E él es el mejor árbol y es mejor que la reacción lineal. A uno le parece malo eso sí a uno no le gusta esto.

01:12:21

Ise posgrados: A Alejandro le gusta. Alejandro dice, "A mí me gusta el car." Lo bueno que tiene esto es la interpretabilidad. O sea, se imagínense ustedes tienen que tienen que fichar jugadores o no sé, eso de un club, no sé cómo hace esto el mundo del béisbol, pero sabes cuánto ofertar un jugador, como te da una idea de cuánto le voy a ofertar un jugador yendo sus métricas si quiero comprar, no sé, se compran jugadores en el bé, no sé cómo es, eh, porque acá veo muy claro, me preguntan, "Che, pero ¿cómo es?" Bueno, si tien 4,5 años, los salarios están alrededor de 30,000, algo así. Si está mayor de 4,5 tiene que fijarte los hits, cómo le fue en hits. Bien, es muy claro y muy fácil de explicar esto. Tiene muchísima explicabilidad, pero agresión lineal no tanto, no hubiese sido tan fácil. Entonces, esa es su ventaja. Ahora, obviamente uno dirá, bueno, hay mejores modelos que van a ser mejor estos métricos seguro, pero tiene mucha muy buena explicabilidad. Antes de vayamos al recreo, comparemos cómo nos fue con respecto a las otras modelos que veníamos trabajar.

01:13:40

Ise posgrados: La revisión lineal tuvo 052, la reacción de RGE 051, el árbol 049. Uno dirá, bueno, no hay mucha diferencia. Sí, no hay mucha diferencia, la verdad, pero vieron lo que era ese árbol. Era así viene una pavada. Así todo se porfó bastante bien. Estoy bastante sorprendido con los obviamente que un super machine le pasa el trapo por encima. Bien, 39, pero perdemos eh perdemos, ¿cómo se llama? Explicabilidad. Entonces, recuerden esto, explicabilidad árboles. Son pésimos los modelos de árboles, ¿no? No vamos a a querer venderlos mucho más de lo que ya son. O sea, no son buenos modelos, no van a tener buenos modelos con los árboles, pero cuando ustedes tienen un problema de que quieren tener explicabilidad, los árboles son los mejores. Otra cuestión que te vieron, se construyen fácil. El algoritmo de construcción es fácil de hacer. Uno dice, "Tién probar todas las combinaciones, así, pero no es tiene que probar tanto. Pon no es tan loco el el en la en la forma que construir. Es decir, con esto puedo construir ensambles que van a la clase que viene, que puedo tener poner 100 árboles, 200 árboles, 1000 árbol y ahora cuando tenés 1000 árboles cambia totalmente el comportamiento, el punto que empieza a ser de los mejores modelos que hay.

01:15:03

Ise posgrados: El tema está en cómo poner esos 1000 árboles que van a ver la clase que viene. Se hagamos un pequeño recreo de unos 10 minutitos y seguimos con árboles de clasificación. Vamos a poner acá temporizador.
Gabriela Sol Salazar: Puedo hacer una consulta rápida
Ise posgrados: Sí.
Gabriela Sol Salazar: de es de lo que diste antes del logaritmo, pero bueno, por ahí lo vi en algo que estamos haciendo el proyecto y me saco la duda ya que estoy cuando vas a aplicar logaritmo sobre los datos, si tenemos alguna un segundo pico mucho más bajo, ¿no? el primero a, por ejemplo, no sé, los 2000, eh, sería válido igualmente la el logaritmo porque por ahí la relación después cuando la ploteamos te da también cuando haces digamos el salario versus el logaritmo tenés la relación marcada, pero no sé si por ahí eso es válido y se suele hacer.
Ise posgrados: Es una transformación que podes hacer. Eh, sí, obviamente el tema está en esto. Verá mucho de lo que vos querés eh saber, digamos, cómo se, pero además es que vos querés mejorar la distribución de tus datos. es una transformación que matemáticamente es correcta y después volvas para atrás, no no te estás generando ningún cambio en sí en los datos más que transformarlo en el momento para hacer lo que vayas a hacer.

01:16:35

Ise posgrados: que nunca tenés que olvidarte que después tenés que aplicar el antilogaritmo, ¿no? El exponencial para poder obtener los valores. Pero la idea es esta, es mejorar la distribución porque si no te queda muy, o sea, cuando el modelo empieza a aprender va a aprender es como que lo va a llevar muy por
Gabriela Sol Salazar: Ah. Yeah.
Ise posgrados: acá y estos valores alejados por ahí lo va le llamas apretar atención menos porque tenés pocas observaciones acá. Cuando aplicas logaritmo tiende a unificar mejor porque como los logra distribuir mejor en todo el rango, entonces eso va debería mejorar, debería pongo entre ot comillas porque depende mucho de del caso de uso,
Gabriela Sol Salazar: Okay.
Ise posgrados: ¿no?
Gabriela Sol Salazar: Sería como en el caso que tengo estas distribuciones y por ahí tengo outliers que no son outliers, o sea, que tienen información y lo quiero
Ise posgrados: Claro, ahí hay hay un caso, sí, porque es un layer que no es un ler,
Gabriela Sol Salazar: bien.
Ise posgrados: o sea, es valor que vos querés genuino y lo queres tener. El ejemplo siempre doy es si tuviéramos los al jugadores del fútbol tenés Messi. Messi obviamente está muy alejado de todos como super pero ese valor por ahí lo querés porque por ahí vos querés los valores de Messi como punto de tu modelo pues queres predecir el siguiente el siguiente Messi quieres predecir no sé algo así.

01:17:46

Ise posgrados: Entonces hay un ejemplo donde hacer ese logarismo para lograr no perder ese dato.
Gabriela Sol Salazar: Listo. Muchas gracias.
Ise posgrados: Bueno, arrancamos recreo. Arrancó 10 minutos. Volvemos. M. Bueno, estamos. Parece que hay gente. Bueno, vamos. Bueno, ahora sí. A ver, cambio, cambio. Estoy compartiendo. Sigamos. con los árboles de clasificación. Molesto de A ver, ahora sí. Entonces, el árbol de clasificación es muy parecido al árbol de redención, pero ahora la diferencia obviamente vamos decir una variable cualitativa. En el caso de la reacción, cuando llegábamos a una hoja, teníamos tomábamos el valor promedio de las observaciones y con eso predecíamos el valor. Ahora, en el caso de el de clasificación, en vez de usar por medio de los valores, vamos a usar

simplemente una un voto de la mayoría, o sea, de las clases que la clase más popular de esa hoja es la clase que va a predecir. Tuviéramos que predecir si es de Boca o de o no es de Boca o Boca o de River, digamos, para dar dos dos equipos.

01:30:23

Ise posgrados: Eh, si tengo más de Boca que de River en esa hoja en particular, vo decir que es de Boca. Eh, lo que tiene interesante este tipo de de casos es que a veces nos interesa no solo obtener la cuál es la predicción, sino también la proporción. O sea, ¿qué tan es eh o sea en esa región? ¿Cuántas hay de boca que se lon de la de la digamos cuando entrené entrenamiento cuando quedaron que son de boca y cuántas quedaron que de arriba? Entonces tener esa proporción me sirve para saber qué tan seguro es esa hoja a la hora de predecir, ¿no? Cuando más extremo sea cuando más de un solo de las dos estados de las dos de los dos tipos de clasificación sean más tengamos, significa que esa hoja es más segura a la hora de clasificar. Si tenemos 50 y 50 es que tenemos está básicamente adivinando el árbol en la en la hoja en particular en ese lugar. Bien, entonces tengamos en cuenta D. Entonces eh para crear un árbol de este tipo queremos justamente algo que nos permita armar hojas que maximicen esa separación, que generen las hojas con mayor eh proporción de una clase sola. Bien, quiero tener hojas que cada hoja tengan observaciones de una sola clase idealmente. Para eso reemplazamos el el error cuadrático medio que hacíamos hoy por otra métrica, por ejemplo, el error cuadrático, el cual se mide como 1 menos la proporción de la clase más popular, ¿no?

01:32:13

Ise posgrados: Si tengo, supongamos en una hoja 10 muestras, tengo 10 eh nueve de Boca y uno de River, el error sería acá tengo 0,9 porque la mayor proporción 0,9 hay nueve de boca y uno de arriba 0,9 1 menos eso me da 0,1 ahora tengo 50%, o sea, tengo la mitad y mitad, tengo 5 de boca, 5 de River, el máximo es 0,5 1 men 0,5 me da 0,5 Cco. Entonces, yo quiero minimizar ese para que busque que sea eh, insisto, que cada hoja tenga la mayor proporción de clase posible de de una de alguna de las dos clases. Ahora, el tema es tiene esta métrica en sí es que no es suficientemente sensible para construir árboles complejos. La explicación de eso ya vamos a ver un poquito cuando veamos por cómo se como una gráfica donde va a ver un poquito más explícito eso. Por eso usa básicamente otras dos medidas. Reemplazamos en vez de usar esta medida usamos otra o el índice de shini o la

entropía. El índice de Shini es un índice que fue creado como una métrica macroeconómica, digamos, el cual medía inicialmente la desigualdad entre clases sociales dentro de un país o media, ¿no?

01:33:37

Ise posgrados: hasta el día de hoy estoy usando, pero se creó en su momento para eso, que es eh y la métrica en sí mide para nosotros importa esta forma para cada una o se de las clases que hay dentro de la digamos para cada una de las clases, la proporción de esa clase por uno menos la proporción de esa clase que en cierta forma lo podemos interpretar como una medida de las varianzas de estas clases. Fíjense en que el índice de Shini es bajo si todos estos valores son cercanos a 0 y uno. Porque fíjense en el caso ideal donde tuviéramos, volvemos al caso de River Boca, si tuviéramos los 10 de Boca y cero de River, este valor sería 1 cucame por 1 men 1 es 0, entonces hace 0 más el caso de River. Esto es 0 * 1 - 1 es 1. 0 * 1 es 0. Entonces el shini sería cero para ese caso, porque sería el caso en donde justo eh tenemos todo una sola clase, entonces un valor muy bajo. Y en cambio, si tuviéramos 50 y 50, bien, 5 y 5, acá me daría 0,5 men 0,5 me da 0,25 más la otra clase vamos a tener 0,5 men 0,5 025 la suma me da 0,5 que el peor caso dice shini es 0,5 el caso más alto que las proporciones están parejas en dentro de del dentro de la hoja.

01:35:07

Ise posgrados: Obviamente que como ven acá este K que representa la cantidad de clases, los árboles de clasificación que tiene bueno es que ya son por naturaleza multiclases, no es como el caso que vimos en los modelos super aut machine que son por son modelos binarios que después usamos otras técnicas para armar eh clasificadores multiclases. Los árboles de clasificación son multiclase de base. Bien, entonces con el shin me funciona independientemente tenga una clase eh dos clases o 50 clases, puedo calcularlo igual. Entonces, el índice de shini, por eso mide la pudreza de un nodo terminal, porque como digo, si el índice de shini es cero, significa que ese nodo es puro, tiene una sola clase. Si el de shin es 0,5 es lo peor, es totalmente impuro, tiene la mitad y mitad o tiene una proporción similar de todas las clases. Bien, entonces recordemos, nosotros queremos llegar a los nodos del árbol una sola clase porque yo quiero clasificar algo dado las condiciones que estamos viendo. La entropía es otra métrica que viene de la teoría de la información, que nos da una idea de cómo es el mide el desorden. Justamente tropina mide es una

métrica bastante similar al caso de la del shin nada más que cambia que mide que es la proporción de la clase por el logaritmo de la clase.

01:36:36

lse posgrados: Bien, eh por el logaritmo de la proporción. Y eso sumamos cada clase multiplicado por menos para que sea negativo. Si todas las observaciones, fíjense, entrenamiento de una hoja pertene una sola clase, la entropie es cero porque fíjense si este fuera 1 por logaritmo de 1, este logaritmo de 1 es 0, eh, esto se hace 0 por 1 es cero el resto, eh, como este es cero, cero. Uno dice, bueno, pero el logaritmo de cero no existe. Sí. No, bueno, pero nunca tenés la proporción perfecta, digamos. Tima podés hacer una eh un par, o sea, una unos le puedes hacer como una pariente que si p es cer eh listo, no calcule el otro y ya está. Valores de P se car a un producen entropía baja, mientras queonesciones similares generan entropía alta. Está bien, es la misma idea. Si lo ponemos a ver una métrica, fíjense la proporción de una clase y vemos cómo cambian las diferentes estas dos estos estas tres formas que vimos de calcular eh la pureza, podos decir, el nodo, vemos que, por ejemplo, el índice de shini es de naranja, tiene esta forma, ¿ven?

01:37:50

lse posgrados: O sea, a medida que tiene cer o uno y a medida que no sé cómo 0,5 hace una bombita que queda en 0,5 y baja. ¿Ven? Esta bombita y el dice la entropía es similar, nada más que lle un valor más alto, pero tiene una estructura muy similar. Cambia un poco la forma es un poco más abombada que el otro. No hay ninguna explicación de por qué es uno mejor que el otro, nada, simplemente la forma que tienen. Pero sí se ve que el error de clasificación un poco vemos el tema que mencionaba de que no tiene suficiente discriminabilidad. Fíjense que es como constante para todo valor de p, ¿ven? Como la variación del de este error es constante para todo valor de p. En cambio, en el caso de de los otros dos, un pequeño cambio en la proporción en esta zona, la zona donde me interesa, genera grandes variaciones, entonces se me mueve rápido para valores bajos. Entonces eso hace que el árbol se comporte mejor. Esa variación acá constante como siempre es todo lo mismo, digamos. Entonces, nada, es por eso que estos dos tienden a funcionar mejor matemáticamente que el error de clasificación.

01:39:00

lse posgrados: El resto es todo igual, o sea, el mismo algoritmo, con las mismas técnicas, con todo lo mismo. No hay ninguna diferencia porque simplemente cambiamos la métrica usamos para como medida de separación del árbol. Bien, entonces todo lo demás es lo mismo. Todo funciona igual, la poda, la selección, todo exactamente lo mismo. No hay ninguna diferencia. Entonces vamos a otro. Vamos a otro ejemplo. Entonces, no sé qué pas acá. Entonces, acá fíjense, tenemos vamos a trabajar con el datas de her, el de los del corazón, ¿eh? que son 312 302 pacientes con tres atributos fisiológicos y queremos medir si el paciente tiene una enfermedad cardíaca no. Entonces sí este dataset por cómo viene internet, no me pregunten por qué, eh en algún lugar se contaminó, alguien hizo una trampa y fíjense que tiene más observaciones que 302, tiene 1026. Yo me acuerdo lo usaba, me daba perfecto, me daba muy buena. Yo usaba este Tacet. Sí. mucho mirarlo y me daban con muy buenas clasificaciones sin importar qué modelo. Y nada, fui viendo que tenía un montón de duplicado, está como duplicado varias veces las observaciones y después viendo un foro de internet hablaban de lo mismo, como que en algún momento en algún lado alguien duplicó la información o algo y rompió el

01:40:45

lse posgrados: el el dataset. Hay que hay que eliminar siempre los duplicados para que no tengamos ese problema. Entonces, por eso quitamos los duplicados y nos queda 302. Miden diferentes variables como la edad, el sexo de la persona, eh este es la presión arterial, entre otras variables. El tratamiento que hacemos de las variables acá no es el mejor del mundo, aunque los árboles eso no tienen tanto problema porque el problema que tiene, por ejemplo, el sexo acá le pone cero y uno, pero es una variable categórica. Entonces acá la habado leer con numérica no es lo mejor. Tenemos que hacer un mejor uso. Eh, Karina no le no le no le gustaría nada lo que estamos haciendo acá que viene el mundo de análisis de datos. Claramente el tratamiento es muy malo de variables, pero en modo de ejemplo, digamos. Y los árboles esos son bastante robustos, no va a tener problemas en eh en mancarse eh ese tipo de cosas. como que el árbol eso no es problema, pero sí, obviamente no deberíamos hacer acá de hacer un codificaciones y ser mejores. Entonces, si ponemos a ver, por ejemplo, el target tenemos casi 5050 prácticamente tenemos mitad y mitad.

01:42:00

lse posgrados: Eh, entonces podemos no vamos no tenemos un problema de de de clasificación desbalanceado, o sea, es un problema bastante es de los mejores que te puede tocar porque tenes casi 50. Entonces vamos a usar dado que tampoco tengo ni una decisión de por qué, qué me gustaría darle más importancia. En este caso no tengo ganas de análisis. En realidad vamos a elegir F1 porque quiero, pero en realidad obviamente también teníamos que hacer un buen análisis de cuál será el error que nos importa porque eso es un infarto y que si por ahí conviene saber si es un falso positivo, que un falso negativo, etcétera, ¿no? O sea, es como que obviamente uno debería eh analizar mejor esto. Acá vamos a generar F1 como métrica valor, digamos, de veamos de del que recuerden que el F1 buscaba la media armónica entre eh precision y recall, va a encontrar como ese punto intermedio. Entonces, nos quedamos con todos los atributos menos obviamente label y y quitamos el label y los guardamos en luego separamos el dataset, nos quedamos un 30% para clasificar, para perdón para para evaluar y el resto para clasificar. Creamos un árbol. Fíjense que ahora en vez de llamar un regresor es un classifier, pero lo demás es muy parecido.

01:43:26

lse posgrados: Usamos el criterio que acá ponemos shini entropy y tenemos también eh también el error, el error ese que que veíamos nada más que el logaritmo del error también lo tenemos, lo podemos elegir, pero este acá voy a elegir ent porque quiero. Vamos a armar el árbol más grande posible. Vamos a clasificar. tenemos los parámetros como fíjense los parámetros que que tiene el modelo y lo podemos hacer exactamente lo mismo. Vamos a ver lo que tenemos acá. Vamos a abrir y masajer el árbol. Obviamente, inicialmente es un árbol gigante porque hicimos el árbol más grande posible. No es tan grande. Bastante bien, ¿eh? Bastante bien, ¿no? Ahora, lo lindo tien los árboles de clasificación, la forma de colorea en este caso es que te colorea el color eh de una de las clases. Cuando es más naranja es que no tiene enfermedad y cuando más azul es que tiene enfermedad. ¿Y por qué más azul o más naranja? Es porque recuerden la pureza de la hoja. Entonces, acá abajo del todo, cada uno, como este es el árbol más extremos, se queda con una o dos muestras, tres muestras máximos, que cuando llega el punto en donde ya tiene perfectamente una clase, termina el árbol.

01:44:59

Ise posgrados: En este caso no no llega hasta una hoja de una sola observación porque no necesita para ser perfecto el árbol, va a tener un berfitil porque se llega un punto donde tenés todo solo observaciones de una clase, listo, ya llegó ahí abajo, no tiene más. Entonces vemos que cuandoito más naranja más proporciones una sola observación con la entropía cero. ¿Ven? Y acá la entropía también más que tenga dos observaciones entropía cero porque las dos clases son de eh que tiene enfermedad cardíaca. Entonces acá algo interesante es por ahí eh este para es interesante que es eh la presión arterial, o sea, empieza todo desde la presión arterial tiene sentido. O sea, para para cardíacas, obviamente la presión cardíaca tiene un factor muy importante, digamos, siempre se habla en eso y que hayan elegido ese inicialmente conocimiento del problema te ayuda a entender a veces si esto está bien hecho. Bueno, sí tiene sentido que la presión arterial sea una de las primeras cosas de segundo nivel. Es interesante que mira si la presión está por debajo la edad de la persona y también siempre, ¿no? Las enfermedades cardíacas aumentan con eh la edad, digamos. En realidad es una un factor de riesgo. Entonces tienen sentido las cosas están apareciendo.

01:46:18

Ise posgrados: Después todo me acuerdo qué era. Era algo que con el SG, pero no me acuerdo bien exactamente qué lo estaba midiendo. Igual también este no me acuerdo qué, pero así a priori se ven cosas interesantes. Y entonces fíjense que si acá es true para este lado, false para tron. Sí, voy a decir eso, jovencito, tener menor que tal cosa. Ah, el colesterol también está un cierto nivel aparece. Eh, quiero ver si este creo que es el cas. Bueno, no, no, no es el mejor árbol. Estamos analizando sobre algo que estáfiteando y para no lo mejor, pero eh van viendo los que tienen interesante el árbol de clasificación tal como lo colorea, es más fácil de ver o interpretar visualmente con con los colores ya puedo empezar a entender cosas. Hagamos el notebook. Veamos cómo le va a este modelo eh con respecto a el F1. Para sorpresa de nadie, obviamente entregamiento fue perfecto y bueno, el testeo nada, un número. Eh, además podemos porque esto quedó mal acá, no tiene que estar acá. Entonces ahora vamos a buscar se busca parámetro bien para encontrar un mejor algo.

01:47:54

Ise posgrados: En este caso no voy a elegir el alfa como valor, voy a elegir parámetros porque además quiero también quiero probar los diferentes criterios, el de shine y el de entropía. Quiero probar en este caso diferentes niveles de profundidad, el mínimo muestras para hacer split y las mínimas muestras por hoja. Bien, de 2 a 20 para este, de 1 a 20 para este, de 1 a 30 para para la máxima profundidad y criterio estas dos clases. Voy a usar opto una porque quiero, no hay ningún motivo más porque quiero usarlo y voy a usar como como score la validación cruzada usando f1 ig a men1 para hacer lo más rápido posible. Lo que me interesa que una optimice es la media, ¿no?, del F1. Entonces hacemos esto, ejecutamos el entrenamiento. Entonces damos un ratito, va a hacer 1000 pruebas, o sea, 1000 trials, va a buscar maximizar el F1. Entonces, fíjense en cómo va logrando maximizar el F1. Pasó de 07 a 082. Ahora por ahí 1000 era un poquito mucho, parece. Eh, veamos si va a demorar mucho esto.

01:49:21

Ise posgrados: Si no cortamos ponemos 100 tr. No, no está 38 segundos. No, no, no lo apuren tanto. Pobre. Igual no logró mejor que el 42. Ah, el 42 ya llegó al mejor. Entonces el mejor el mejor árbol que otro es máxima profundidad de 20. Eh, criterio shini con mínimas muestras de para separar de siete y con las mínimas muestras por hojas dos. Bien, con toda esa combinación. Lo que podemos hacer, lo que está bueno es que esto se genera un diccionario, ¿no? El estudio generado los mejores parámetros que un diccionario. Yo usando Python no necesito cargar esto a mano. Le puedo pasar con el doble doble un diccionario con el doble asterisco para indicar esto transforma lo que son las llaves de un árbol de un de un diccionario en argumentos de una función. Entonces, con eso directamente le cargo los parámetros de una. Entonces, sacarme el árbol con los parámetros que encontré. Hacemos un fit. Fíjense, están los parámetros que hemos elegido. Y calculemos ahora sus métricas. 062 071 de vuelta.

01:50:37

Ise posgrados: Empeoró un poco. Uno diría, bueno, empeora con respecto al al testeo de acá, sí, pero no estáfiteado y realidad es prácticamente el mismo, digamos. cambio muy poco, eh, la precisión 0070 y un poquito más de recol. Ahora veamos este árbol. Este árbol es un poquito más chiquito. Es un poquito, chicos. 1 2

3 4 5 6 7 un poquito más grande que normalmente crea, no sé por qué tan, pero bueno. Eh, generalmente ha nivel si este es un nivel un poquito más grande. De vuelta, recuerden, los árboles siempre son iguales, por eso no no hay ni una diferencia al principio con respecto al mismo porque siempre genera el mismo árbol. Bueno, acá puede seramiento, no dije nada porque estamos cambiando la métrica para haber sido distinto. Eh, pero si es la misma métrica siempre los árboles empiezan iguales porque el algoritmo de Gridy siempre genera lo mismo. Lo que va a cambiar es cuando corta abajo algunas cuestiones, pero generalmente los primeros pasos son iguales. En este caso no era necesario porque estábamos usando shini, aunque tampoco es tan distinto entre shini y tropía.

01:52:03

lse posgrados: Bien, entonces se para de vuelta. Eh, ah, sí, cambio bien, si no aparece la edad, eh, uso old y después empezó a armar. Eh, a ver, entonces, ¿qué le decí esto? ¿Qué tiene de explicar? Poder hacer un protocolo para después para definir para un médico. Bien, porque un proceso que hacen los médicos no es muy lejos de un árbol a la hora de diagnosticar enfermedad, de aplicar tratamiento, como tienen ciertos pasos, ellos van repitiendo y la estructura que eligieron es esa, es como un árbol. Bien, entonces va, llega un paciente, pum, le mide la presión pa, le da menor que 0,5. Listo, fíjate en el LSG este valor. Pum, si le dio que es true, fíjate este otro valor que no me acuerdo qué era. Le do leo menor que 0,5. ¿Y qué edad tenés? Bueno, se fija la edad, eh, menor de 42 años. Ah, este no tiene nada. Esteate. Salid de acá. Eh, ten más de 42 años.

01:53:04

lse posgrados: Hm. Veamos este métrica. Uh, te digo, eh, mayor que eso. Uh, veamos el colesterol. ¡Uf! Es rato. Menor que esto, tenés enfermedad cardíaca. Ah, acá, acá, fíjense, es interesante este. En realidad acá este fue un mal un mal caso. Fíjense que acá generó un árbol. Acá no hay no hay clasificación, básicamente. ¿Ven? O sea, que básicamente eh está uno en uno, o sea, hay dos muestras y las dos tienen dos clases distintas. Bien. Básicamente te puedes quedar con esta clasificación, tiene cardíaca. Eh, entonces eso, es el mejor árbol, obviamente que no. Es el mejor clasificador, obviamente que no. es uno de los peores. C1 es mejor que NN probablemente, eh, pero bueno, es unisto, que les permite es un modelo que nos va a permitir construir muy buenos modelos después. Decime, Gabriel.
Gabriel Quiroga: Sí, en ese caso que veas recién que que si es que no no clasificó, no

hay en el árbol el que está mal

01:54:14

lse posgrados: Ah, bueno,
Gabriel Quiroga: clasificado,
lse posgrados: igual igual.
Gabriel Quiroga: es decir que agregó una hoja innecesariamente.
lse posgrados: Sí.
Gabriel Quiroga: Eso, ¿por qué se puede dar? O sea, porque más arriba puso la comparación esa de colesterol. Eh, sin embargo, ahí te deja uno y uno.
lse posgrados: Y
Gabriel Quiroga: ¿Por qué? ¿Por qué se puede dar en general?
lse posgrados: sí, es una buena pregunta. ¿Por qué hizo esto? Porque estoy viendo que acá no reduce. Creo que es por las condiciones que tenían de las otras condiciones que les pusimos, porque estoy viendo que acá no creo que mejore el el índice de Shini, ¿no? O sea, como que da igual. Eh, eso habría que ver bien para mí es una cuestión de de los otros parámetros que pusimos de exigencias de que, por ejemplo, uses siete muestras para separar. Eh, me parece que eso puede haber jugado un juego en contra para que pase estas cosas.
Gabriel Quiroga: Ah, claro.
lse posgrados: Este es un para mí un motivo por el cual pasó esto. Sí. Pero, ¿cómo es el las otras hiperparámetros como jugaron para afectar el?

01:55:40

Gabriel Quiroga: Ok.
lse posgrados: Sí, son esas cosas que son difíciles de explicar porque depende del algoritmo cómo lo fue tomado, pero en sí es esto. Obame es este eh que está jugando en contra. ¿Cuántas muestras necesitas para hacer el split mínimo? Y eso ayuda a que no tuv, o sea, ahí por ejemplo no separó en dos porque tenía que haber separado en dos. Si puedo tenido los dos, separaba dos hojas y listo, pero no hizo eso porque no podía por esto, por estos dos que le pide
Gabriel Quiroga: Ah, y claro,
lse posgrados: que dos
Gabriel Quiroga: será por el de abajo. Es el min samples lif un mínimo de dos.
lse posgrados: tres.
Gabriel Quiroga: En ese caso hubiera quedado uno de un lado y 15 del otro.

Ise posgrados: Claro, claro,
Gabriel Quiroga: Claro,
Ise posgrados: por ejemplo. Sí, ese es un ejemplo.
Gabriel Quiroga: tiene sentido.
Ise posgrados: Sí, sí. Acá juego en cuanto a los parámetros. Por eso a veces mejor el alfa, porque ese tipo de cosas no te la no te genera ese dolor de cabeza. No sé por qué esta vez normalmente gen un mejor árbol. No sé por qué tan feo.

01:56:42

Ise posgrados: Esta vez gen un árbol feo porque porque quiso, ven, porque yo puse level 7, pero generalmente generar un árbol de nivel si que era mucho mejor. Está bien. Es el azar que te lleva la búsqueda de prepararámetros, ¿no? O sea, como te llegó por un lado, me llevo por un lado, por ahí, ¿no? Al mejor. A ver, promo de vuel a ver qué pasa. Si otro otros 30 segundos, unos 40 segunditos más. A ver, no nos queda mucho tiempo de clase. Queda 82 otra vez. Mejor un poquito ahí. Vamos a dejar acá para ver si se mejora un poco. puesto menos trem me parece que est control este mucho más chico. Este árbol está el nivel tres. Pasó nivel 20 a un nivel tres. Eh, vemos que aparece las métricas vamos de vuelta abajo, así las podemos comparar. 0 fue bastante mejor. 66 bastante mejor. Okay. Vamos a ver nos armó. Está la la este es el la materia de confusión. unastre para estoy viendo.

01:58:40

Ise posgrados: No, está bien, estoy viendo. No, no, no fue tan malo, ¿no? Per, lo critiqué demasiado. Veamos este nuevo árbol que se armó ahí porque no me está marcando. Creo que encontró el árbol que yo quería encontrar porque no me marca cambios en el repo. Es el mismo que tenía antes. Veamos ahora. Ya les pongo ahí. Sí, ahí me gustaba. Ahora sí. Ahora está más lindo, digamos. Aunque acá es un acá un desastre, eh, porque ahora se acuerdan que era más grande el valor que había puesto el minio, pero bueno, eh, puede ser un poco mejor ahí. Quizás suponemos igual esto fue lo que mejor encontró que de vuelta busqué parámetro que pero bueno acá encontró uso tropía ahora también es interesante carini uso tropía entonces ahora aparece bien h cp eso insisto como cuando usamos entropía las primeras o sea no va a cambiar nada las primeras hojas a medida que vamos profundizando empiezan a correr las otras restricciones y pueden cambiar el árbol Pero digamos en general los principios van a ser iguales y este caso es mucho más sencillo, o sea, fíjense en pasa de código código posterior de la presión arterial, la

edad, el género de la persona.

02:00:15

Ise posgrados: Y fíjense interesante que con saber la presión, la edad y el género, el sexo, perdón, de la persona, eh, también porque acá hizo cualquier cosa, no importa. Eh, fue mejor que el otro árbol. Otro árbol mucho más grande y todo fue peor que este. Es un más sencillo de entender. Tiene cierto nivel, tiene cierta explicabilidad. Obviamente podremos mejorar, trabajar mejor con los hiperparámetros, no haber usado los otros hiperparámetros, usar el alfa y solamente se búsqueda el alfa realmente encuentra mejores resultados porque elegí otros para mostrar otra otra forma de hacerlo, ¿bien? O sea, simplemente es por eso si vemos la la batería de confusión está está no está mal no está mal para lo que es el modelo. Lo que era, era así, una cosita así un par de hojas y nada más. Este está bastante bien para lo que es la para el modelo. Segundos la curva rock, una curva decente. Yo 87 bajo la curva de compro acá en China, ¿no? O sea, es un algo bastante es un modelo bastante bueno para lo que es limitado que es. Acá tengo para comparar, creo que decir hizo Karina la clase pasada, obviamente Super Machine le pasa el trapo de acá a la China.

02:01:48

Ise posgrados: Es una cosa muy superior a este árbol, pero esto es un árbol. ¿Vieron? Insisto, vieron lo que es ese modelo. Es yo loito así nada más, digamos, no es mucho más que eso. Bien, por eso insisto, es un modelo muy sencillo, muy básico, pero que digamos tiene una sola ventaja que es muy buena. Explicabilidad. Es muy fácil de explicar por qué las cosas ocurren, porque ocurre dentro de estos modelos. Y luego cuando empezamos a usar en cantidades, empieza a tener un comportamiento muy superior, muy muy superior, de los mejores modelos que hay cuando pasamos a muchos árboles. Si queremos ver la frontera, modo de ejemplo, fí este caso voy aar solamente dos variables para que podamos ver una bolito ahí chiquito para que veamos. Ven, vemos las regiones que arman son rectangulares. Bien, las fronteras de clasificaciones para el modelo de árboles son rectángulos, que es algo bastante distinto a lo que veíamos antes, que era una frontera, una recta o un círculo, que sea. Acá hablan como bloquecitos que se van armando. Bien, entonces tiene esa es la forma que arman los árboles.

02:03:06

Ise posgrados: Entonces, para terminar hoy una clase, creo que hablé muy rápido, por eso me pasó muy rápido la clase. ¿Qué ventaja tienen los árboles? Como les dije, va a ser explicar las personas, sobre todo aquellas que no son eh del tema, digamos, gente no está no son masa de magar. Tenemos que hacer una explicación sobre todo stakeholder que depende de ellos para que se haga un proyecto estamos trabajando. Los tienen esa ventaja, son fácil de explicar, demostrar, mira, esto ocurre por esto, esto y esto. Lo que tiene interesante que se aproxima la forma de pensar humana, en el sentido de que yo les decía, por ejemplo, los médicos, el método hipotético deductivo, que ellos llaman a la hora de hacer un diagnóstico de enfermedades, eh se basa un árbol, ellos hacen un árbol mentalmente, es llega la persona, indica un un alguna dolencia, algo, eso dispara, ah, si tiene indica tal cosa, le tengo que mandar a hacer un estudio de que sé yo de de una placa de rayo X. Bueno, me trae la placa de rayo X. Verifico, si verifico y eso me va a abrir ahora otras posibilidades que pueda hacer cosas lo más nuestro estudio o etcétera, ¿no? O sea, van haciendo van haciendo todo ese proceso hipotético de deducción hasta que llegue a una enfermedad, como que van reduciendo posibilidades.

02:04:36

Ise posgrados: Bueno, el árbol tiende a hacer eso, como que vas una estructura que vas partiendo desde un lado, tenés diferentes posibilidades y te vas moviendo hasta que llegas a una conclusión, una clasificación, la redión. se pueden representar gráficamente como acabo de mostrar que es algo que que tiene muy interesante. Luego le puedes tirar cualquier tipo de variable la para de pechito sin ningún problema. Creo que es el modelo que menos problema tiene con las tipo de variables, sobre todo las categóricas, las reacciones y todo lineal supuesto machine, tenemos que hacer one hot encoding o cualquier otro tipo de encodeo, label encoding, cualquier cualquier tipo de otro encodeo para poder eh expresar ese tipo de variable. Acá no importa, no importa tres combinos, no importa tres combinos, no importa se porque es binario, entonces e o no es, entonces va pum pum pum pum separando, no le importa el tipo de variable. Obviamente, ¿qué desventaja tienen? No tiene ningún nivel de precisión predictiva que otros modelos porque es son modelos malos, sépanlo de base, nunca van a ser buenos modelos con árboles y no son robustos. Bien, eh pequeños cambios los datos de entrenamientos pueden generarci predicciones, eh, porque van a cambiar los árbol totalmente cómo se construyen los mismos, cómo es el algoritmo gridy y nos lleva a ese camino cuando tiene utridad y esto es medio raro porque uno normente no sabe cómo es, pero obviamente si tu frontera de clasificación es una recta, como ven el ejemplo de arriba, El árbol no le va

a costar mucho poder ajustar las regiones

02:06:24

lse posgrados: porque tiene que como digitalizarlo, perdón, como tiene que noizar la palabra e tiene que eh se me escuela para tiene que sí es digitalizar. Bueno, pixelarle vamos a decir una línea recta. Ven, es como el el problema que tiene los el problema que tiene que tuvo el mundo computacional cuando tuvieron que representar o hacer eh gráficas en computadoras que tienen píxeles. Bien, entonces cuando tenés situaciones de líneas o zonas que no son suaves, lo que sea, obviamente algo que genera cuadraditos, no le va a costar mucho poder encontrar la mejor. Ahora, cuando tus regiones de clasificaciones o tus datos se separan en regiones cuadradas, obviamente que el árbol va a ser perfecto, porque es literalmente eso lo que hace el árbol frente a un modelo de de digamos clasificado lineal, justamente ese tipo de casos son malísimos para ellos porque es muy difícil hacerlo. Ahora, la pregunta del millón, ¿cuál problema tiene esto? y básicamente ninguno. Entonces, no conozco ningún caso hasta ahora en mi vida que los datos se organizan de esta forma, pero puede existir, no voy a a debe haber un problema en el mundo en donde los datos se se tienden a a a guardar en regiones bien cuadraditas. Perfecto.

02:08:03

lse posgrados: Pero bueno, tengan en cuenta ese tipo de cosas. Y como les decía, esto era todo la clase. Creo que hablé muy rápido y por eso la pasé muy rápido la clase. E y es un tema que, como digo, muy que les da una introducción porque en la clase que viene van a ver los modelo de boosting, de de árboles aleatorios, vaging, que son modelos que usan principalmente árboles eh para construir con muchos de ellos muy buenas clasificaciones. Eso es muy loco. Es lo que uno dirá, esto es una basura, esto, para qué usamos esto por qué vimos esta clase, para qué perdimos tiempo con esto visto otros modelos mucho más sofisticado y la clase que viene a decir, "Ah, ahora entiendo por qué." Bien, entonces como a modo de de de suspenso, les digo, miren ahora este estos modelos que parecen ser una porquería cuando los ponés muchos tienen mejores comportamientos que hay antes que pases un modelo deep learning y hay veces que superan los modelos deep learning porque el precio implementarlo es mucho más sencillo que implementar un modelo deep learning. eh al punto que hoy en día la mayoría de los problemas que hagas, digamos, de machine learning lo puedes resolver con modelo de boosting sin ningún problema eh vas a resolver bien.

02:09:26

Ise posgrados: El modelo de boosting utiliza, insisto, árboles por detrás, muchos, 100, 200, 1000 ese número, pero bueno, no dejan de ser árboles, ¿eh? Y con eso terminamos por hoy. Eh, como digo, terminamos una hora 50 minutos antes. Eh, le damos 50 minutos para que puedan trabajar si quieren el proyecto final. Obviamente nos quedamos cualquier dudas tengan, pero si no nos vemos el Ah, eso sí, avisamos por las dudas. Jueves que viene clase, ¿eh? No, nada de Semana Santa esas cositas. No, no, no, no. Acá hay clase. Va a tener con Karina. Yo sí me voy de descanso, pero eh vamos a a las reglas que hacemos es que no hay asistencia, o sea, está bien, esa es la parte que que hacemos de buenos. Eh, sin asistencia, o sea, nada más tengan en cuenta eso, eh, después queda grabada la clase, pero no paramos porque generalmente parar es mucho más complicado. El motivo de semana esta es porque es mucho más complicado parar y organizar, recuperar la clase porque generalmente no tienen otro horario. Entonces es nada, Semana Santa generalmente el que más cuestionan porque es como el más universalmente feriado, eh, pero bueno, nada, van a tener clases el jueves que viene con cariño. Si no hay alguna otra duda o si no hay una duda, perdón, ninguna duda. Nos vemos el jueves que viene, que tengan una semana y estamos en contacto.
Santiago Bartolini: Chao. Gracias.
Ise posgrados: Ciao.
Marcos Lund: Muchaso. Gracias.

La transcripción finalizó después de 02:11:20

Esta transcripción editable se ha generado por ordenador y puede contener errores. Los usuarios también pueden cambiar el texto después de que se haya generado.