📝 Las notas

2 abr 2026

Aprendizaje de Máquina (5/8) - a242b25

Invitados facundolucianna@gmail.com macroldan@fi.uba.ar Aprendizaje de Máquina - CEIA 24Co2025

Archivos adjuntos Aprendizaje de Máquina (5/8) - a242b25

Registros de la reunión Transcripción Grabación

Resumen

Actualización de la presentación con la revisión de árboles de decisión e introducción a métodos de ensamble para robustecer la predicción.

Introducción y Poda de Árboles
Revisión de la clase anterior sobre árboles de decisión, destacando su simplicidad y el uso de índices de impureza como Gini y entropía para la clasificación. Se explicó la poda como técnica crucial para evitar el sobreajuste en los árboles de decisión.

Conceptos de Ensamble de Modelos
Presentación de los métodos de ensamble basados en la 'sabiduría de la multitud' para combinar múltiples predicciones y obtener un resultado final robusto. Se detallaron las estrategias de votación (hard/soft voting) y el stacking para mejorar la precisión del modelo.

Bagging, Random Forest y Boosting
Introducción a Bagging y Random Forest, destacando la selección aleatoria de atributos para asegurar la diversidad de los árboles y la importancia de las variables. Se concluyó que XGBoost superó a los otros modelos de ensamble en la demostración práctica con un dataset de precios de casas.

Detalles

- **Reacomodo de la Presentación y Repaso de la Clase Anterior**: Ise posgrados informó a los participantes sobre una pequeña actualización en la presentación actual, aconsejando que volvieran a descargar los materiales del repositorio, aunque el contenido seguía siendo el mismo (00:00:00). Posteriormente, se realizó un breve repaso de la clase anterior sobre árboles de decisión (clasificación y regresión), destacando su simplicidad e interpretabilidad, y explicando el concepto de particionar el *dataset* en regiones (rectángulos) para tomar decisiones (00:05:45). Se mencionó que los árboles buscan minimizar un error basado en la distancia de los puntos a la media de cada región y se introdujo el concepto de poda para evitar el sobreajuste (00:08:39).
- **Arboles de Clasificación e Índices de Pureza**: Se explicó que los árboles pueden usarse para clasificación (predecir una variable cualitativa) y que la clase predicha es la más frecuente en la hoja o región correspondiente. Se hizo referencia a índices como la entropía y el Gini, que se utilizan para medir la pureza de las hojas, buscando que las divisiones sean lo más parejas posible en el reparto de observaciones (00:10:03).
- **Introducción a los Métodos de Ensamble (Ensemble Methods)**: Ise posgrados presentó los métodos de ensamble, mencionando que la idea se inspira en un experimento de la "sabiduría de la multitud" (ley de los grandes números) donde el promedio de 800 estimaciones independientes del peso de un buey resultó ser muy cercano al peso real (00:11:28). El concepto central es que el promedio de muchas predicciones individuales y dispersas generará un valor final muy preciso, a diferencia de tomar cualquier resultado individual (00:12:52).
- **Concepto y Aplicación del Ensamble de Modelos**: Un ensamble consiste en combinar múltiples modelos, como 100 árboles distintos, entrenando cada uno con un subconjunto de datos de entrenamiento diferente, para obtener un resultado más robusto. Para la clasificación, la clase final se determina mediante una votación de los resultados de los modelos individuales, mientras que, en problemas sencillos, los ensambles podrían no ser necesarios (00:14:06).
- **Modelos de Votación (Voting Classifiers) y Estrategias Hard/Soft**: Se detallaron los métodos de votación para clasificación, que combinan las predicciones de varios modelos (regresión logística, árboles, etc.) sobre una observación nueva (00:15:45). La estrategia de *hard voting* (votación dura)

se basa en la moda, eligiendo la clase que tiene la mayoría de los votos, mientras que el *soft voting* (votación suave) se aplica cuando los clasificadores pueden estimar probabilidades, ponderando los resultados con base en la certeza que cada modelo tiene en su predicción (00:17:12).

- **Estrategias de Votación y Manejo de Errores**: Se proporcionó un ejemplo de *hard voting* en una clasificación binaria, donde la predicción final se determina por el valor que más se repite (00:18:28). Se señaló que, si la mayoría de los modelos se equivocan, la matriz de confusión lo indicará y el modelo deberá ser ajustado. Se enfatizó que para que el ensamble sea beneficioso, los modelos deben ser lo más independientes y diversos posible, ya sea por el tipo de arquitectura o por estar configurados de manera muy distinta (00:19:48).
- **Soft Voting, Regresión y Stacking**: En el *soft voting*, la predicción de un ensamble se basa en un promedio ponderado de las probabilidades de cada clase dadas por los modelos individuales, lo que permite que los modelos con mayor confianza tengan más peso (00:20:44). En el caso de regresiones, la predicción del ensamble es simplemente el promedio de las respuestas de todos los modelos (00:18:28) (00:22:58). Como un paso más allá, el *stacking* o apilamiento, implica entrenar un modelo adicional con los resultados de varios modelos base para determinar la predicción final (00:24:01).
- **Demostración de Implementación y Comparación de Métricas**: Se inició una demostración en una *notebook* de Python, cuyo código estaba diseñado para encapsular la preparación de datos y las métricas, permitiendo enfocarse en la implementación del ensamble (00:25:12). Se entrenaron cuatro modelos individuales y tres tipos de ensambles (hard voting, soft voting, y stacking con regresión logística) con un *dataset* de enfermedades cardíacas (00:29:09). Los resultados mostraron que el Support Vector Machine performó ligeramente mejor en *accuracy* que los ensambles, aunque estos últimos quedaron muy cerca, lo que podría deberse a la simplicidad del *dataset* utilizado para la demostración (00:33:11).
- **Aclaración sobre Stacking y Bagging (Bootstrap Aggregating)**: Se aclaró que el *stacking* es un tipo de ensamble donde un modelo superior (metamodelo) utiliza las predicciones de los modelos base como sus datos de entrada para decidir la salida, en lugar de promediarlas (00:40:08). Posteriormente, se introdujo el concepto de *Bagging* (*Bootstrap Aggregating*), que busca la diversidad en los modelos entrenando la misma arquitectura con subconjuntos de datos diferentes (00:43:50). Este muestreo

se realiza con reposición o reemplazo (bootstrap), permitiendo que las observaciones se repitan en las muestras de entrenamiento (00:46:30).

- **Resumen de *Bagging* y Concepto de *Random Forest***: *Ise posgrados* repasó que los modelos de conjunto (*ensemble models*) se entrenan en paralelo y sus salidas se promedian para obtener un resultado teóricamente superior a las salidas individuales, como en el caso de *Bagging* (00:57:27). Se introdujo el concepto de *Random Forest*, que se considera una mejora de *Bagging* porque no solo usa submuestras del *dataset* original, sino que también implementa una selección aleatoria de atributos (*feature selection*) para el entrenamiento de cada árbol (01:10:13). Esta selección aleatoria de atributos asegura que los árboles sean distintos y evita que todos particionen por un predictor fuerte, lo que limitaría la capacidad del ensamble (01:11:48).
- **Ventajas de la Selección Aleatoria de Atributos en *Random Forest***: La ventaja de la selección aleatoria de variables es más evidente cuando se tienen muchos atributos, ya que garantiza una gran variedad de árboles. *Ise posgrados* explicó que *Random Forest* tiene la capacidad de identificar las variables más importantes (*feature importance*) y descubrir relaciones entre ellas, lo cual se visualiza en un gráfico que muestra la importancia de las variables para el modelo (01:13:03).
- **Enfoques para Determinar la Importancia de las Variables:**: Existen dos enfoques principales para determinar la importancia de las variables para el modelo: la disminución de la precisión y la disminución de la impureza. El enfoque de disminución de la precisión implica desordenar una columna de datos; si la salida del modelo no cambia significativamente, la variable no era importante, pero si el rendimiento empeora drásticamente, la variable era crucial (01:14:29). El enfoque de disminución de la impureza utiliza índices como la entropía para medir cuánto disminuye la impureza después de dividir el *dataset* por un atributo; cuanto mayor sea la disminución, mayor será la importancia de la variable (01:15:59).
- **Dudas sobre los *Shap Values* y el Enfoque de Permutación:**: *Pa. Santiago Rodriguez Castro* preguntó si el análisis de los *Shap values* estaba relacionado con el enfoque de permutación (disminución de la precisión) (01:15:59). *Ise posgrados* no pudo confirmarlo con seguridad, sugiriendo que *Shap values* podrían involucrar la eliminación directa de la variable, pero indicó que podría tratarse de una variante (01:17:19).
- **Introducción al *Boosting* y Diferencia con *Bagging***: *Ise posgrados* presentó el *Boosting* como una técnica de entrenamiento secuencial, a diferencia de *Bagging*, que utiliza modelos paralelos (01:17:19). El

Boosting implica correr múltiples modelos uno tras otro, siendo un proceso más lento pero buscando resultados superiores a un modelo individual. Se mencionó que el enfoque más simple de *Boosting* es el *Adaptive Boosting* o *Adaboost*, el cual usa árboles de decisión simples (01:18:23).

- **Mecanismo de *Adaboost***: En *Adaboost*, el entrenamiento comienza dando la misma importancia a todas las observaciones, y después de la primera iteración, se identifican las observaciones mal clasificadas y se les asigna un peso mayor (01:18:23). Cada modelo subsiguiente se entrena enfocándose en clasificar correctamente las observaciones que el modelo anterior clasificó incorrectamente. Finalmente, todas las predicciones se combinan de manera ponderada, donde el peso de cada modelo se determina por su desempeño (01:19:49).
- **Mecanismo de *Gradient Boosting* y Su Relación con *Gradient Descent***: A diferencia de *Adaboost*, que pondera las observaciones mal clasificadas, *Gradient Boosting* entrena el modelo siguiente utilizando los residuos (errores) del modelo anterior. El objetivo es que estos residuos se hagan cada vez más pequeños, ajustando el modelo hasta que los errores tiendan a cero (01:21:16). *Alejandro Valle* confirmó que el predictor que ajusta los residuos es similar a un algoritmo de *Gradient Descent*, lo cual da origen al nombre de la técnica (01:24:01).
- **Comparación General entre *Bagging* y *Boosting***: La principal diferencia entre *Bagging* y *Boosting* es que el primero utiliza múltiples modelos independientes entrenados en subconjuntos aleatorios de datos, mientras que el segundo construye modelos secuencialmente, centrándose cada uno en corregir los errores del anterior (01:26:44). El entrenamiento de *Bagging* puede ser más rápido ya que es independiente, mientras que *Boosting* es potencialmente más lento porque cada modelo depende de que el anterior termine. *Gabriela Sol Salazar* confirmó que la técnica de *Boosting* está vinculada al concepto de *learning rate* utilizado para disminuir el error (01:28:08).
- **Implementación de *XGBoost* y Conceptos de *Hyperparámetros***: *Ise posgrados* introdujo *XGBoost* como una implementación de *Gradient Boosting* (01:28:08). Se indicó que tiene muchos hiperparámetros, incluyendo el *learning rate* (llamado ETA), que actúa como un mecanismo de regularización para evitar el sobreajuste. Se notó que *XGBoost* utiliza muestreo sin reemplazo (*pasting*) y es compatible con la interfaz *Scikit-learn*, lo que facilita su uso (01:29:26).

- **Modelos de Ensamble de Clasificación y Regresión en *Scikit-learn***: Se destacó que la documentación de *Scikit-learn* ofrece versiones de clasificación y regresión para todas las técnicas de ensamble vistas, incluyendo *Adaboost*, *Bagging* y *Random Forest* (01:31:14). Esto significa que los participantes pueden aplicar estas técnicas a una variedad de problemas, no solo los de regresión vistos en los ejemplos (01:32:46).
- **Revisión de Ejemplos en la *Notebook***: Los ejemplos prácticos utilizaron un *dataset* de precios de casas de California para predecir precios (01:32:46). Se entrenaron una regresión lineal y un árbol de regresión como modelos base para establecer una línea de comparación. Los resultados iniciales mostraron que *Bagging* mejoró las métricas en comparación con los modelos base y *Random Forest* fue el mejor de los cuatro modelos iniciales probados (01:34:20).
- **Resultados de *Adaboost* y *XGBoost***: El modelo *Adaboost* tuvo un rendimiento bajo en el ejemplo de la *notebook*. *XGBoost*, una vez instalado, demostró ser el mejor modelo de ensamble para este *dataset* específico, superando significativamente al resto (01:37:14). Se mostró la función de *Feature Importance* de *XGBoost*, que reveló que una variable relacionada con la ubicación (*mediana income*) era el predictor más fuerte para el precio de las casas (01:38:39).
- **Instrucciones para el Trabajo Final de la Materia:**: *Ise posgrados* confirmó que el material cubierto hasta la clase actual es suficiente para completar los trabajos finales, los cuales requieren abordar un problema de predicción con un *dataset* elegido (01:40:11). Los estudiantes deben entrenar varios modelos (tres o cuatro) con una justificación clara, comparándolos con un modelo base (01:43:11). Es crucial documentar los pasos en una *notebook* con un estilo de narrativa (*storytelling*), justificando la selección de cada modelo y, sobre todo, incluyendo una conclusión sobre los hallazgos y resultados (01:44:12).
- **Vínculo del Ensamble con el Balance de Datos:**: Finalmente, *Ise posgrados* explicó que el tema de ensamble se relacionaba con el análisis de datos porque es una técnica que puede mitigar el desbalance en la variable objetivo en problemas de clasificación (01:45:03). Al usar *Bagging* con muestreo, se puede crear una estrategia para generar submuestras balanceadas, reduciendo el impacto negativo de un *dataset* desbalanceado en el rendimiento del modelo (01:46:34).

Pasos siguientes recomendados

- [ ] [El grupo] Sincronizar Archivos: Realizar pull de nuevo o descargar la presentación actualizada del repositorio.
- [ ] [El grupo] Enviar Preguntas: Enviar preguntas al correo sobre dudas del proyecto final. No esperar al último momento para resolverlas.

Revisa las notas de Gemini para asegurarte de que sean correctas. [Obtén consejos y descubre cómo toma notas Gemini]

Danos tu opinión sobre el uso de Gemini para tomar notas en una [breve encuesta.]

📖 Transcripción

2 abr 2026

Aprendizaje de Máquina (5/8) - a242b25 - Transcripción

00:00:00

Leonardo Villalva: M.
Gabriela Sol Salazar: Hola, buenas tardes.
Leonardo Villalva: Hola,
lse posgrados: Hola,
Leonardo Villalva: buenas tardes.
Jose Miguel Silva: Buenas tardes,
lse posgrados: Hola, buenas tardes. Hola, buenas. ¿Cómo andan?
Alan Vignolo: Hola, buenas.
lse posgrados: Hola, hola a todas. Bueno, bastantes. Pensé que no venía nadie. Me conecté a las 19:00 y no había nadie. Hola, Tomás. Eh, bien. Bueno, espero que no se les haga pesado el feriado. Vamos a tratar de que no sea muy larga la clase. Se extiende dependiendo las preguntas que tengan, porque la verdad que el contenido no es mucho. Así que bueno, vamos ahí comparto eh por si se hicieron el pull desde el principio de la, o sea, desde antes les comento que hice una pequeña actualización a la presentación de hoy, que se pueden hacer pull de vuelta o bajarlo del repo. Eh, no es más contenido, simplemente reacomodé algunas cosas, así que la presentación de ahora no es exactamente igual a la que por ahí ustedes ya tienen ahí. Solo eso les quería comentar.

00:05:45

lse posgrados: Bien, se ve bien ahí. No veo, no veo las manitos nada porque no tengo otra pantalla, entonces eh me pueden hablar.
Lucia T. Capon Paul: Sí, se ve.
Alejandro Valle: Sí,
lse posgrados: Bueno,
Alejandro Valle: se ve.
lse posgrados: gracias. Bien, como siempre, primero un pequeño repaso de la clase anterior muy breve que vieron con Facundo árboles de decisión que en particular, bueno, pueden hacer con árboles, pueden hacer regresión o pueden hacer

clasificación. Los árboles son los modelos prácticamente los más simples que hay porque son muy interpretables. No se necesita quizás mucho conocimiento de fondo de qué es un modelo para entender un árbol. Un árbol es como su nombre lo indica, una rama y hojas que se van bifurcando y uno va recorriendo el árbol hasta llegar a una hoja y toma una decisión. Es básicamente eso. Eh, los árboles se conocen también como kart por la sigla en inglés de árboles de clasificación y regresión. Y lo bueno que tienen, aparte que son simples, justamente es eso que son fáciles de interpretar. Tenemos acá un ejemplo que lo vieron el otro día. Eh, un ejemplo de regresión, de cómo se usaría un árbol para regresión con un dataset que tenía información de jugadores, no me acuerdo de qué de deporte eran y uno de los atributos del dataset era los años eh los años, no sé, los años de de antigüedad tal vez era de que estaban jugando y los hits y esto simplemente si en la columna no en el atributo años el valor es menor que 4,5 me muevo para acá en el árbol y si es mayor o igual me muevo para acá y así me voy moviendo por el árbol,

00:07:24

Ise posgrados: por las distintas ramas o branch branches. Bien. Y cuando llego a una a una hoja puedo tomar una decisión que en este caso el la regresión era para predecir el salario y en este caso lo que voy a si vengo por este lado, lo que voy a predecir es que el salario es 165000. Si voy por este lado, tengo que seguir bpurcando y así hasta llegar a una hoja donde tomo una decisión de cuál es el valor de la de la regresión. Y eso visto de otra manera, funciona así. La primera bifurcación del árbol en realidad es particionar el conjunto en dos, ¿no? Acá estoy partiendo el x1 mayor o menor que el valor t sub1. Sería acá este es el eje de la variable x1. Este es el valor t sub1. Entonces, con esta línea vertical, yo estoy dividiendo todo mi dataset en dos subconjuntos. Este subconjunto acá a su vez lo estoy volviendo a dividir acá donde dice si x2 es menor que t2 voy para un lado y si no voy para el otro y es esta división horizontal R1 y R2 y así voy subdividiendo y todo el dataset me queda dividido en rectángulos eh que cubren toda el área, no se superponen los rectángulos.

00:08:39

Ise posgrados: Entonces cada una de las observaciones mi dataset va a ir a parar alguno de estas de estos de estas cuadrículas. Y yo en el caso de una regresión, la predicción que hago es el promedio de todas las observaciones que del dataset de entrenamiento, de todas las observaciones que cayeron en ese rectángulo, el

promedio o la o la mediana o bueno, sí, el promedio en general. Así es como yo hago la predicción de eh de lo de la de una observación. Si yo al recorrer el árbol caigo acá, la predicción va se va a basar en el promedio de las observaciones eh que estaban acá cuando yo entrené eh y construí ese árbol. Y la forma en que se construyen eh todas estas áreas, lo que buscan es minimizar este error, que es la suma de todas las combinaciones, de todas las distancias de los puntos a la media de cada una de las regiones. Esa es básicamente la idea de cómo está construido este árbol. está el concepto de poda de árboles, porque uno podría hacer un una partición siempre binaria, ¿no? Particiono, particiono así hasta llegar al final y que cada hojita sea una observación, estaría recontra sobreajustando ahí y podría ser un árbol tan simple como tengo la raíz y tengo dos hojas y nada más y ahí se terminó mi árbol.

00:10:03

lse posgrados: En el medio hay muchas variantes y acá esto que está acá es un factor que lo que me hace es regularizar. Es como un compromiso entre la complejidad de ese árbol de hacerlo super grande y que sobreajuste o que o hacerlo super chiquito con poquitas hojas y que sea muy impreciso. Eh, así que con esto se puede jugar para saber hasta dónde voy a llevar de profundo ese árbol. Y por supuesto, los árboles, además de eh para regresión, se pueden usar para clasificar, o sea, predigo una variable cualitativa en vez de un número eh cualquiera, digamos. La clase que se que se predice es la más eh la más frecuente entre todas las muestras que cayeron en esa hoja o en la región esa. Esa sería la diferencia de en el momento de predecir. Bien. Y acá tenemos unos índices, eh, creo, no me acuerdo si el otro día explicó Facundo cada índice cómo se construye, pero la entropía, si se la acuerdan, la vimos la habíamos visto en detalle cómo se hacía la cuentita en análisis de datos. Básicamente son distintos índices para medir la pureza de las hojas. Lo que yo quiero cuando eh agrego una nueva división al árbol es eh ser lo más pareja posible, que se repartan parejas las las distintas eh las distintas observaciones.

00:11:28

lse posgrados: Entonces, para medir eso, uso alguno de estos índices. Y eso fue todo. Eh, no sé si tienen alguna pregunta con eso. Acuérdense, no tengo otra pantalla. Si necesitan algo, me dicen porque no veo si me hacen si me levantan la manita o algo. Eh, bien, hoy vamos a ver métodos de ensamble. No tengo idea si alguno recordará al haber escuchado la palabra o la la expresión, el método de

ensamble en análisis de datos los mencionamos en un momento cerca de la materia. No sé si alguien tendrá algún recuerdo, pero pueden empezar a remover ahí en su cabeza. Eh, lo mencionamos y y en un ratito voy a retomar qué fue lo que dijimos en ese momento. Métodos de ensamble. Eh, ¿qué son acá? Bueno, tienen una eh como un eh no me sale la palabra, un resumen, ¿no? Como una explicación de un de un eh de un experimento que se hizo en un momento, que por ahí da lugar a toda la idea esta de los ensambles. ¿Y de qué se trata? de un concurso donde le pidieron a 800 personas que adivinen el peso de un buey, pero esas 800 personas eran 800 personas distintas que no hablaban entre ellas, que no se consultaban, que no miraban lo que votaba el otro cada una por separado.

00:12:52

Ise posgrados: Dijo, "Yo creo que pesa tanto." Entonces se obtuvieron 800 valores distintos, muy dispersos entre sí. Y a pesar de esa dispersión, cuando se calculó el promedio de esas 800 estimaciones, se vio que el número resultante era muy cercano al peso real de ese animal. Entonces, eso es lo que se conoce como sabiduría, sabiduría de la multitud, que en estadística por ahí lo van a ver más relacionado con la ley de los grandes números. O sea, cuanto más número y saak azar de está, en este caso son votos de personas, más se va a acercar ese número promedio al real, al verdadero. Y en eso se inspira el el los métodos de ensamble. La idea es que si yo tengo 800 modelos, para hacer un número igual a eso, ¿no? 800 modelos que me predicen un valor, en vez de 800 personas tengo 800 modelos y paso mi eh mi observación que yo quiero usar para predecir. La paso por los 800 modelos, voy a tener 800 predicciones. Y si yo promedio esas 800 predicciones, muy probablemente ese valor final va a ser muy preciso y mucho mejor que tomar individualmente cualquiera de esas 800 resultados.

00:14:06

Ise posgrados: ¿Me siguen la idea? Eso es lo que se conoce como ensamble y ese método, la técnica se llama métodos de ensamble y eso es lo que vamos a ver ahora. Yo voy, si me dan un segundo, me voy a conectar del celular, así puedo verlos, porque si no me por ahí me me no voy a decir que me desespera, pero prefiero prefiero verlos. Eh, a ver si me esperan un segundito. Ya va, eh. Ahí está. Bueno, listo. Entonces, métodos de ensamble son lo que vamos a ver hoy. Es básicamente combinar modelos para generar un resultado a partir de muchos modelos y no a partir de un único modelo. Esa es la idea de los distintos métodos que vamos a ver

hoy. A modo ejemplo, yo puedo tener un grupo de árboles, vamos a suponer 100 árboles distintos e y cada uno lo uso para predecir, pero usando un diferente un conjunto un subconjunto diferente de mis datos de entrenamiento. Y luego con todo eso yo tengo distintas predicciones y después voy a determinar en el caso de una clasificación voy a determinar la clase final mediante una votación de todas las votaciones de los perdón, de todos los resultados de esos árboles individuales.

00:15:45

Ise posgrados: Ahora vamos a ver un ejemplo para que quede eh más claro. ¿Cuándo usaríamos un método ensamble? Si nosotros tenemos un problema s simple, superfácil de entender, ya sabemos cuál es el modelo que me sirve más. Eh, por ahí no hace falta meterse en este lío de ensamblar cosas. Eh, pero bueno, si yo tengo arquitecturas simples o modelos simples que no me están dando resultado, una posibilidad para mejorar mis resultados es hacer esto. Y al combinar muchos modelos, puedo decir que tengo un único modelo que es más robusto que los modelos individuales. Vamos a empezar por los modelos que votan. Yo tengo un dataset que lo voy a usar para entrenar y vamos a suponer que tengo acá, bueno, n modelos. Acá tengo como ejemplo cuatro, pero bueno, pueden ser muchos más, ¿no? Tengo una regresión logística, una eh logística, una eh eh modelo de vectores de soporte, una red, un árbol como los que vieron la clase pasada, etcétera. Tengo varios. Yo lo que voy a hacer una vez que entreno cada uno de esos modelos, vengo con una observación nueva con la que quiero predecir, ya sea no importa si es regresión o clasificación, quiero predecir entonces esa observación la paso por este modelo, la paso por este, por cada uno de los modelos y obtengo una predicción para cada uno de ellos.

00:17:12

Ise posgrados: Yo tengo que decidir con cuál me quedo, con qué combinación me quedo de todas esas eh esos resultados. Entonces, hay distintas formas de decidir. Una es el hard voting, que es una estrategia que se basa en la moda. En el caso de clasificación, si yo tengo eh clases rojo, amarillo y verde y el y tres modelos clasifican a mi observación como verde y un modelo me lo clasifica como rojo, bueno, eh la moda es verde y entonces voy a decir que esa esa predicción va a ser verde, es decir, por por e por mayoría. Básicamente sería en la el la predicción, la clase que más votos tuvo. Esa es con la que me quedo. Eh, la que se llama soft es en el caso que los clasificadores puedan estimar probabilidades. Es decir, no solo

me dicen que es rojo, sino que me dicen que es rojo con 0,6 eh% de certeza. Con esas probabilidades eh yo puedo ponderar todos esos resultados y a partir de esa de esa ponderación obtener cuál es la predicción que yo elijo de entre todas esas de todos mis modelos. Nuevamente ahora vamos a ver un ejemplo con numeritos para que quede más claro cuál es la diferencia entre entre estas dos.

00:18:28

lse posgrados: Y en el caso de regresiones, lo que se hace es yo paso mi observación por cada uno de los modelos, agarro todas las respuestas de cada uno de los modelos y las promedio y listo. Bueno, en el caso de la del soft, la ventaja que tiene es que los modelos que más confianza tienen en sus resultados eh van a tener más peso en ese eh en todo ese ensamble. Y acá vamos a los ejemplos. En el caso del hard voting sería así. Tengo mi dataset y lo paso por estos cuatro cinco modelos. Acá el modelo que ustedes quieran, imagínense, es un dataset donde yo tengo eh una clasificación en binaria, clase cer y uno. Estos tres clasificaron mi observación como uno, dijeron, "Es clase uno" y estos dos dijeron, "Mi observación es clase cero." Nos quedamos con la moda, o sea, con el valor que más se repite. Y la predicción de mi ensamble de modelos me da clase uno, o sea, uno es la salida de mi predicción. Hasta ahí estamos bien. Tenemos en este caso dos modelos distintos.
Leonardo Villalva: Una una consulta,
lse posgrados: Sí,
Leonardo Villalva: puede ser que esa que los tres modelos se equivoquen,
lse posgrados: decime.

00:19:48

Leonardo Villalva: por ejemplo, ser binario y que el correcto sea el otro, el cero,
lse posgrados: Sí,
Leonardo Villalva: por ejemplo.
lse posgrados: sí, claro que puede ser. Sí,
Leonardo Villalva: Y esa situación,
lse posgrados: sí.
Leonardo Villalva: ¿cómo cómo se resuelve? Va, queda como que no
lse posgrados: Siempre va, siempre vas a tener al Siempre vas a tener al último la matriz de confusión que te va a decir,
Leonardo Villalva: predice.
lse posgrados: "Te dio todo mal. Este,

Leonardo Villalva: Okay.
lse posgrados: y bueno,
Leonardo Villalva: Claro,
lse posgrados: va a haber que ajustarlo.
Leonardo Villalva: es verdad.
lse posgrados: Sí,
Leonardo Villalva: Gracias. Yeah.
lse posgrados: nada de nada. Eh, bien. Una cosa a tener en cuenta es que estos métodos en este caso, bueno, van a funcionar mejor cuanto más independientes sean los modelos. Porque si yo, por ejemplo, acá tengo a lo mejor dos árboles que son reiguales y cambiaron en un hiperparámetro, eh muy probablemente la la predicción de este árbol y de este sea casi la misma o sea la misma. Entonces yo si estoy poniendo modelos que se dependen entre ellos o son muy parecidos entre ellos, no me estoy beneficiando de tener un ensamble, estoy poniendo cosas muy parecidas.

00:20:44

lse posgrados: La idea es que todo esto sea lo más distinto posible entre sí, ya sea que sea otro tipo de modelo, como en este ejemplo que son recontradistintos o que esté configurado muy distinto o que yo le pase datos distintos. Es decir, yo tengo que buscar variedad en todo ese esa combinación de modelos que estoy haciendo para poder realmente sacar una ventaja de ahí. Si no, no estoy ganando nada. En el caso del soft es así, yo no solo predigo, sino que yo el modelo me dice, bueno, esto es clase uno, eh, y e digamos no está tan seguro que la clase es uno porque me da un 0,52% de de certeza de que la clase sea uno. Digamos, esta es la probabilidad que me dio de que la clase sea uno, o sea, es casi es bastante bastante mala porque no no está muy seguro de que sea uno, la verdad, muy cerca 050. Lo mismo esta y lo mismo esta. Y acá, aunque yo tengo solamente dos modelos que me dijeron el resultado es cero, están pero casi seguros que es cero porque me da 0,98 la probabilidad de que sea cero. Entonces en este caso, yo mirando esto, sin hacer ninguna cuenta, yo miro esto y digo, "No, seguramente que es uno la clase. Estos,

00:21:59

lse posgrados: la verdad que son retruchos estos modelos me están dando cualquier cosa. Yo lo que hago en este caso es acá un promedio ponderado por las probabilidades y al haciendo al hacer la ponderación me da que la clase cero es

mucho más fuerte. Tengo mucha más certeza de que la clase sea cero a que sea uno. Entonces mi predicción, la predicción del ensamble va a ser cero. Son dos métodos de votación. El primero es más estricto, agarra la moda, el que más se repite y este le da bolilla a las probabilidades. Entonces hace la cuenta ponderada. Sí,
Leandro Britez: Consulta. En el en el método de hard,
lse posgrados: sí,
Leandro Britez: eh, ¿qué pasa si tenés una cantidad de modelos pares y te da igual en esto que es binario? ¿Quién quién desempata ahí?
lse posgrados: te tendrías que poner impares. En ese caso, tendrías que poner impares.
Leandro Britez: Okay.
lse posgrados: Eh, ahí te aseguras que no que no va a pasar. Idealmente también tendrías que asegurarte que sean suficientemente distintos para no tener que llegar a a desempatar.

00:22:58

Leandro Britez: Ah, eso.
lse posgrados: Claro. Bueno, esos dos son para el caso de clasificación. Ahora, para el caso de regresión, simplemente yo promedio. Supónganse que yo tengo la misma muy parecida a la arquitectura, el ensamble a los anteriores. Solamente que acá, bueno, me está mostrando una regresión lineal. Eh, paso mi observación nueva por cada uno de estos modelos y esto es lo que me predice. 050. No son probabilidades porque justo quedaron todos números chiquitos menores que uno. No son probabilidades. Estas son el resultado de la predicción 050, 031, 057. La predicción del ensamble del ensamble es simplemente el promedio. Entonces mi ensamble predice 056 para esa observación en particular. Sí, Alejandro.
Alejandro Valle: Creo que no entendí el softboting de que lo que usa son
lse posgrados: Sí.
Alejandro Valle: probabilidades de que pertenezca a una clase o la otra, similar a regresión logística,
lse posgrados: Claro, es eso.
Alejandro Valle: pero entonces cada modelo entonces habría que ajustarlo que en lugar de predecir
lse posgrados: Sí,
Alejandro Valle: o una o la otra que retorne probabilidades.

00:24:01

lse posgrados: que te devuelva la probabilidad. Sí, exactamente.
Alejandro Valle: Entonces,
lse posgrados: Sí, sí, sí, sí. Después en la notebook vamos a ver un ejemplo, pero sí es así como decís.
Alejandro Valle: okay, gracias. Yeah.
lse posgrados: Y esos son los modelos que votan. tengo en la clasificación el voto por la moda, el voto según las probabilidades y en la regresión tenemos simplemente el promedio de todos los modelos. Ahora, una variante de todo esto, o sea, un paso más adelante, es lo que se llama stacking o apilamiento. Yo tengo mi dataset, lo paso por varios modelos y el resultado de cada uno de con los resultados de cada uno de todos esos modelos, yo entreno otro modelo que me va a decir e cuál sería mi predicción. Es como meterle un modelo arriba de los modelos y ese modelo puede ser cualquier cosa. En la notebook vamos a ver un ejemplo eh de esto también es como complejizar un poquito. En vez de decir, "Bueno, promedio todo esto." Lo que voy a hacer es eh entrenar un modelo con todo esto para ver cuál sería la mejor la mejor salida. El modelo este me puede decir, bueno, en vez de hacer un, supongamos una regresión, ¿no?

00:25:12

lse posgrados: Este modelo puede eh llegar a darse cuenta que el mejor valor no es promediar todo, sino poner, qué sé yo, un 40% eh de ponderación darle a esta de modelo y el resto repartirlo entre estos otros. No sé, como una formulita matemática que me va a decir que los pondere de tal manera, ¿no?, que haga el promedio así liso y llano de de todos los modelos. Eh, eso sería como un pasito más, pero no deja de ser entrenar todos mis modelos en paralelo y después a partir de eso combinarlos de alguna manera y sacar un resultado. Bueno, vamos a practicar muy rápido. Vamos a practicar dónde está el acá. Eh, bien. Voy a cerrar esto, total tengo otra pantalla. Ahí está. Bueno, ¿cómo hacemos esto de los ensambles? Eh, tenemos, primero que nada, les voy a mostrar acá un código en Python acá, que el objetivo este no lo voy a mirar todo en detalle. Esto si ustedes les interesa lo pueden mirar después. El único objetivo de este código es simplificar la notebook, que la notebook pueda enfocarse solamente en mostrar los ensambles y todo lo todos los detalles de implementación de cada cosa están acá.

00:26:31

Ise posgrados: eh como para aislarlo un poquito, separarlo y no confundir en la en la notebook con tanto con tanto código y aparte con tanto código que por ahí se repite, ¿no? ¿Qué hace este? Les doy así como en general qué es lo que tiene este este documento, este código. Tenemos acá los importes siempre, el split, el scaler, las métricas, los modelos. Acá los modelos que vamos a usar para los ejemplos son regresión logística, vecinos, eh support vector machine, eh árbol y lo primero que hay acá es una clase. Vamos a trabajar con el archivo de Hert, que ya lo usamos en otras ejemplos en clases anteriores de enfermedades cardíacas. Y esta clase lo que hace es lee el archivo que lo tengo acá, se los muestro por si no se acuerdan. Tenemos acá todas estas observaciones y a la derecha acá tenemos el si tiene enfermedad coronaria 01. Sí. Bueno, vuelvo al código. Acá lo que hace es lee ese archivo, hace toda la codificación, hace el, ¿cómo se llama?, el escalamiento y hace el split de train y test y lo deja todo encapsulado en una en una variable. Entonces, en vez de estar poniendo todo ese código, está todo encapsulado en esta clase.

00:27:49

Ise posgrados: Y todo esto es la clase hasta acá. Y otra cosa que tiene este código es eh una función que le paso un un eh un modelo y los datos de entrenamiento y me devuelve las métricas. Y después más acá abajo tengo una función para cada uno de los modelos que voy a probar. La función lo que hace es entrenar el modelo y devolverme las métricas, los resultados. O sea, es no hace casi nada, digamos, no es mucho lo que hace cada función, pero me ahorra líneas de código en la notebook. tengo para la revisión logística, para el SBC, para el árbol de decisión y creo que ahí termina. Sí. Bueno, eso es lo que está en este código. Es como abstraer un poco eh y encapsular las las funcionalidades, así la notebook queda más más simple. Así que me vuelvo a la notebook. Bien, acá importa otra vez estos modelos porque vamos, lo que vamos a hacer es entrenarlos por separado y después entrenar el el modelo ensamblado. Voy a bajar un poquito acá. Lo primero que hace es importar el código Python y me crea una variable que se llama dataset hert que lo que hace es simplemente estasear un objeto de esa clase que les mostré recién. Entonces, yo acá con esto ya tengo ahí encapsulado todas esas funcionalidad, ya tengo el split hecho, la codificación, todo tengo hecho, ¿no?

00:29:09

Ise posgrados: No tengo que hacer nada porque ya lo hizo acá. Lo que vamos a hacer en esta notebook es entrenar los modelos por separado y después hacer un ensamble y comparar todos los resultados de los modelos individuales y el ensamble. Así que esto que está acá, esta celda está entrenando los modelos cada uno por separado, usando las funciones que están allá en el código Python. ¿Vieron? Acá en una sola celda ya entrené cuatro modelos, eh, los cuatro que les mencioné. Al final de la notebook vamos a ver los resultados de esto. Ahora vamos con el ensamble. Vamos a crear un ensamble. Acá tenemos el voting classifier de cycit learn, que es el para hacer es el que me sirve para hacer el el los votos estos que que les mostré recién, las distintas estrategias para votar. Primero vas a empezar con el hard voting. Acá hago el import. Sí. Y acá creo el ensamble. ¿Cómo lo creo? Creo cuatro eh modelos. Acá los asigno a cuatro variables. Una regresión logística, un árbol, un SBC, un vecinos cercanos. Armo acá una estructura, un diccionario, le pongo un nombre a cada una de esas variables, un nombre más descriptivo, línea regression a la variable LR1 y así.

00:30:25

Ise posgrados: Y acá creo el vouing classifier al que le paso toda esta información. Le digo cuál es la estrategia que quiero que use. Lo estoy construyendo. Todavía no entrené nada. Estoy construyendo un voting classifier, un clasificador que va a votar por el método hard. Si yo lo miro acá, fíjense que a diferencia de lo que conocían ustedes hasta ahora, que aparecía uno solo. Acá tengo todo el ensamble. Tengo los cuatro modelos. Yo le puedo hacer clic acá y me muestra los detalles. Lo cierro. Tengo acá este el ensamble que preparé. Lo que hago ahora es entrenar acá con el fit. El fit eh me entrena todo lo que yo le puse al ensamble, o sea, me entrena esos cuatro modelos. Y acá una predicción de una observación en particular de una, o sea, de Sí, yo ya tengo, como les dije, en la en la en el objeto este ya tengo hecho el split, lo hice todo ahí en la clase esa donde encapsulé todo y acá hago la evaluación también con una función que estaba ahí en ese código Python. Está todo ahí. Si ustedes quieren ver los detalles, está todo allá en el código Python.

00:31:35

Ise posgrados: Entonces, entreno, predigo y hago la evaluación. Hago lo mismo para el soft. Repito, exactamente todo lo mismo. Creo otros modelos, armo esta

estructura y creo un voting classifier con votación soft. Creo el ensamble y acá entreno, predigo. Acá está haciendo las dos cosas. decir así a secas que me diga es clase cero, clase uno. Y acá con probabilidades, como preguntaba recién Alejandro, acá le pido que me diga las probabilidades de cada una de las predicciones y acá evalúo. Y por último, el stacking. Vieron que eh si recuerdan la diapositiva, yo tengo el ensamble de todos los modelos y abajo abajo al costado en el dibujito, en vez de hacer un promedio, una moda o lo que sea, le meto otro modelo eh que me va a decir cuál es el resultado. E acá el stacking, le paso todo este ensamble que estoy armando acá, o sea, todos estos cuatro modelos y mi modelo que le voy a estaquear, el que voy a poner al final, le puedo poner cualquier modelo, le estoy poniendo acá una regresión logística, o sea, tengo mi ensamble con cuatro modelos y a la salida de esos cuatro pongo una regresión logística y la regresión logística va a ser la que va a decidir eh cuál es la salida.

00:33:11

Ise posgrados: Acá solamente lo estoy creando. Acá lo entreno, acá predigo lo mismo que antes, predigo y acá evalúo. Después que hice todo eso, me construyo un data frame con las métricas para poder mostrarlas más fácilmente. Y acá tengo los resultados ordenados de forma descendente por Acuracy. No sé si se alcanza a ver o está medio chiquito. Acá están todo lo que entrené. Si se fijan los modelos que entrené al principio sueltos sin ningún ensamble que son este la revisión logística y estos dos y después está el hard voting classifier, el softvat voting classifier y el stacking classifier quedaron en este orden. Digamos que el support Vector Machine fue el que mejor performó desde el punto de vista de la curacy, pero muy cerquita el hard voting, la regresión logística, o sea, no hay mucha diferencia entre ellos, pero el mejor de todos no fue precisamente un ensamble que no está mal, tenemos un modelo, no sé, un modelo, un dataset simple, o sea, no no hacía falta esto es solo para que veamos cómo se hace un ensamble, ¿no? En este caso no hacía falta hacer todo esto, por eso que los resultados son bastante cercanos entre sí. Pero bueno, en este orden quedaron los eh los ensambles, quedaron acá como en el medio.

00:34:30

Ise posgrados: Hasta ahí. Sí, sí.
Alejandro Valle: Tengo una consulta, digamos que tuviéramos un dataset más complejo y pero, ¿cuál sería la diferencia o o al menos eh cómo es la palabra? Superioridad de ensambles, digamos, entrenar unos 10 modelos en lugar de una red

neuronal.
lse posgrados: Eh, en verdad las redes neuronales las usaríamos para cosas realmente muchísimo más complejas que esto. Para este tipo de problemas, los modelos clásicos de machine learning son suficientes. una red neuronal por ahí no te cambia tanto en los resultados que obtengas, pero e eh por el contrario te requieren mucho más procesamiento, muchas más, GPU, o sea, estás invirtiendo un montón de esfuerzo para obtener un resultado parecido, capaz que ni vale la pena en cosas como esta, eh, una red neuronal. Y en cuanto a poner o no poner un ensamble o qué cantidad de árboles, eh eso lo podéis ir evaluando con los resultados. Si vos tenés una simple regresión logística y nada más y evaluaste y la matriz de confusión te lleó bastante bien, suficiente, no hace falta que hagas más nada. Es un poco
Alejandro Valle: Sí,
lse posgrados: eso.
Alejandro Valle: solo pensaba que el entrenar muchos modelos sería quizá menos eficiente, pero entiendo. Gracias.

00:35:49

lse posgrados: Sí.
Alejandro Valle: Okay.
lse posgrados: Bueno, sí,
Pa. Santiago Rodriguez Castro: Perdón, ¿qué modelo habíamos elegido para stacking?
lse posgrados: sí.
Pa. Santiago Rodriguez Castro: porque me llama mucho la atención que dé exactamente el mismo resultado que el soft voting. Bien.
lse posgrados: a una regresión logística acá y quizás porque la el dataset es muy simple y muy eh, ¿cómo se llama?
Pa. Santiago Rodriguez Castro: Claro,
lse posgrados: Muy predecible,
Pa. Santiago Rodriguez Castro: claro.
lse posgrados: probablemente. De nada. Bueno, y acá una simple variante también usando funciones que están implementadas ahí en el en el código Python. E lo que hace esta variante es mirar el mejor umbral de las salidas probabilísticas para lograr una mejor e eh predicción y con ese que acá tiene la función obtain best thien el mejor umbral de cada una de las de las eh de las predicciones. Entonces, de cada uno de los modelos, quiero decir. Entonces, con esa salida hace nuevamente, bueno, acá usando ese ese umbral clasifica como a mano, digamos, le pone clase 10 a cada uno de los modelos y nuevamente e arma acá las recupera las métricas, arma un data frame y muestra los resultados.

00:37:16

lse posgrados: Acá cambió un poquito con respecto a lo de arriba, pero nuevamente los eh los ensambles no quedaron top, digamos, están por acá. Como les digo, este caso quizás es demasiado simple para andar haciendo todo un ensamble, pero bueno, la idea es mostrar, digamos, cómo se hace, cómo se implementa y cómo miramos a ver si nos dio bien o nos dio mal. Acá están todas las las salidas. Y por último acá,
Leonardo Villalva: Una consulta,
lse posgrados: sí, sí,
Leonardo Villalva: que el stacking eh se utiliza solamente para evaluar cuál es el mejor de los modelos
lse posgrados: decime.
Leonardo Villalva: y a partir de ahí empezamos a trabajar con ese modelo nada más como para descartar el
lse posgrados: No los descartás en realidad porque la predicción es el conjunto de todo.
Leonardo Villalva: resto.
lse posgrados: Usas todo para predecir. No es que la descartas, no es que vas a usar una,
Leonardo Villalva: Eh,
lse posgrados: a ver, voy para arriba, ¿eh?
Leonardo Villalva: sí, por ejemplo,
lse posgrados: ¿Dónde está?
Leonardo Villalva: decía que creo que SBC era el mejor ahí
lse posgrados: Acá.
Leonardo Villalva: abajo en la tablita.
lse posgrados: Ah, estoy entendiendo mal por ahí.

00:38:18

lse posgrados: Empecemos.
Leonardo Villalva: La tablita te da
lse posgrados: No, no voy a empezar de vuelta. Sí, sí, sí. Este, en realidad,
Leonardo Villalva: ahí.
lse posgrados: ojo, eh, regresión logística. Esta es la regresión logística suelta, no es la del stacking.

Leonardo Villalva: No entiendo. La redión logística del STIN te arroja esta tabla, digamos,
lse posgrados: No,
Leonardo Villalva: donde te evalúa Ah.
lse posgrados: tampoco. No, no, tampoco. Por ahí vuelvo para no confir porque si se genera una confusión es mejor vuelvo otra vez. Eh,
Leonardo Villalva: Perdón.
lse posgrados: no voy a mirar el código. Entrené cada modelo por separado, suelto. Háganse que de cuenta que el ensamble no existe, el los ensambles.
Leonardo Villalva: Sí,
lse posgrados: Entrené la revisión logística, el que era el KNN. Bueno, entrené cuatro modelos por separado. Eso por un lado. Por otro lado,
Leonardo Villalva: por el otro lado.
lse posgrados: entrené los cuatro ensamblados. Hice un ensamble con softvating y ahí tengo un resultado.

00:38:56

Leonardo Villalva: No.
lse posgrados: Por otro lado, agarré los cuatro juntos, hice un ensamble y eh usé el en uno usé el hard, en otro usé el soft voting. Entonces ahí ya tengo cuatro, cinco, seis, seis entrenamientos separados. Y por último, el séptimo, agarré los cuatro, los ensamblé, les metí arriba una regresión logística, es esto acá, el stacking, y con eso tengo otro modelo más que entreno. Entonces, tengo creo que siete, si no me pier si no me perdí en el camino, tengo siete entrenamientos distintos,
Leonardo Villalva: M.
lse posgrados: cuatro simples y tres 1 2s 3 tres ensambles. Entonces, yo lo que tengo acá en la tabla, esta son las salidas de esos siete entrenamientos que hice. 1 2 3 4 5 6 7.
Leonardo Villalva: Bien. Y una vez que tenés la tabla,
lse posgrados: La tabla es para ver cómo me dio cada uno, eh, y con cuál me quedo.
Leonardo Villalva: que
lse posgrados: Si yo me quiero quedar con el stacking, eh, no es que, o sea, me ese va a ser mi modelo, pero no es un modelo simple, sino que es un ensamble. Este stackin es un ensamble de cinco cosas, cuatro modelos,

00:40:08

Leonardo Villalva: claro.
lse posgrados: cuatro modelos más uno que le puse arriba.
Leonardo Villalva: Okay, okay,
lse posgrados: Sí,
Leonardo Villalva: bien.
lse posgrados: no sé cuál había sido la confusión, pero espero que haber
Leonardo Villalva: Sí,
lse posgrados: aclarado.
Leonardo Villalva: sí había entendido que que el stacking en definitiva te lo utilizas para seleccionar qué modelo, pero no. El stacking es uno de esos modelos.
lse posgrados: No es uno de los ensambles. Stacking es un ensamble donde tengo una serie de modelos que corren en paralelo y cuya salida se combina
Leonardo Villalva: Exacto.
lse posgrados: en un modelo eh estaqueado o apilado, que es en este caso una revisión logística, pero podría haber sido otra cosa.
Leonardo Villalva: Okay.
lse posgrados: Eh, sí, Alejandro.
Alejandro Valle: Pero entonces ese modelo de regresión logística de stacking no solamente tiene cinco entradas, no sería un poco, no sé, que no tenga poder predictivo. No sé si me deja a entender.
lse posgrados: ese lo que ese stack eh perdón, esa reción logística lo que hace no es eh predecir a partir de tus datos, de tu dataset, sino que lo que hace es encontrarte la mejor, o sea, la combinación de la salida de los modelos que mejor predice eh que mejor predice.

00:41:21

lse posgrados: Es decir, combina la salida de los modelos, ¿no? mira tus datos originales. Lo que mira la el lo que alimenta los datos que alimentan a esa revisión logística son las predicciones de los modelos de los modelos ensamblados. Y lo que vos querés con esa revisión logística es que la salida sea la mejor predicción posible. Es decir, vos vas a armar una matriz de confusión de de esa salida y y ahí te vas a dar cuenta si esa regresión logística eh acomodó bien esas, o sea, la regresión logística lo que va a hacer es ponderar las salidas de las predicciones. Va a decir, eh le doy más peso al al KNN, por ejemplo, descarto la salida del, no sé, del del SBC y de las otras agarro un poquito. O sea, como que hace una ponderación de las predicciones de las del ensamble, hace la mejor ponderación posible, cosa que la predicción final sea la mejor posible en

Alejandro Valle: Pero,
lse posgrados: definitiva.
Alejandro Valle: pero, ¿cómo, o sea, solo usa la salida de los modelos,
lse posgrados: Sí,
Alejandro Valle: pero cómo hace las relaciones sin ver los datos originales?
lse posgrados: sí.
Alejandro Valle: Digamos, digamos que tuviera una regresión lineal al final, ¿cómo la regresión lineal va a saber dónde dibujar la la recta sin ver los datos?

00:42:39

Alejandro Valle: Ah, perdón.
lse posgrados: Es los dat,
Alejandro Valle: Los datos entonces serían la salida de los modelos.
lse posgrados: claro, los datos son las salidas de los de los modelos anteriores, no no es que predice de vuelta, porque si predijera de vuelta no necesitaríamos el ensamble, le estaríamos dando otra vez el dataset original.
Alejandro Valle: Sí.
Leonardo Villalva: Es como es como es como,
Alejandro Valle: Ok.
Leonardo Villalva: perdón, no es como si el stacking fuera un método de ensamble donde al final en vez de utilizar
lse posgrados: Sí,
Leonardo Villalva: hard voting, soft voting o regression utiliza utiliza otro método.
lse posgrados: es usa su propio método. Sería claro.
Leonardo Villalva: Claro, es sería eso es un caso particular de ensamble.
lse posgrados: Sí, es un caso particular de voto. En todo caso, si quisieras decirle, no es que vota,
Leonardo Villalva: Claro,
lse posgrados: pero digamos yo,
Leonardo Villalva: deo.
lse posgrados: claro, cuando tengo un ensable tengo muchos modelos.
Leonardo Villalva: Exacto.
lse posgrados: ¿Qué hago con todas las salidas? Las promedio, las pondo o les meto un modelo arriba que decida qué hacer
Leonardo Villalva: Tak.
lse posgrados: sería. Bueno, entonces acá tengo la salida de todos y por último acá y por último tengo acá la curva rock de todas las de esas siete cosas que hicimos.

00:43:50

Ise posgrados: Y en este caso son todas, bueno, acá hay unas dos medio malas, pero estas son todas bastante parecidas. Si se fijan en la tablita, todas decían aquí 088 85, eran muy parecidas y y acá eh bueno, en la curva rock también se ven todas muy altas. acá es como que son bastante buenas todas y y bueno, eh eso a modo de demostrativo de qué de cómo puedo hacer yo para ensamblar y qué resultados tengo, pero bueno, así es como lo así es como quedó el resultado final de de todo esto. Bueno, volvemos a la presentación. Eh, vamos a ver ahora eh otra forma de ensambling de ensamble de ensamble que se llama Baging. ¿De qué se trata? Como yo les decía hace un ratito, lo que queremos es diversidad en los modelos, porque si son muy parecidos o dependen entre ellos o lo que sea, es como que no estamos ganando nada haciendo un ensamble si ponemos todas cosas muy similares entre sí. O por ejemplo, supóngase que pongo dos árboles muy parecidos, eh, y tengo una variable, ya lo vamos a ver mejor en un ratito, pero eh tengo una variable que es muy muy fuerte, una predictora muy fuerte de la variable target.

00:45:17

Ise posgrados: Los dos árboles al principio van a empezar iguales, van a partir, supóngase el ejemplo que veíamos que era el los años, ¿no? El ejemplo de la clase pasada que dividía años, si era menor que 4,5 para un lado, mayor para el otro. Tengo dos árboles tan parecidos que los dos empiezan partiendo por el año. Ya de entrada son me están haciendo la misma clasificación. A lo mejor en algún punto del árbol difieren, pero si ya de entrada me están partiendo por la misma variable, ya no son tan diferentes esos árboles y ya ese ensamble eh no es tan diverso. Yo lo que quiero es que sea lo más diverso posible todos los modelos que yo meta ahí. Bueno, una forma de obtener esa diversidad es eh bueno, poniendo arquitecturas o modelos bien distintos, ¿no? Pero otra forma sería uso la misma arquitectura, incluso el mismo árbol, ¿no? El mismo árbol repetido 10 veces, pero cada árbol lo entreno con un subconjunto distinto de mi dataset. Entonces, si yo lo entreno con un conjunto distinto, el árbol va a ser distinto. Y ese conjunto yo lo hago haciendo un muestreo, un muestreo de mis datos. Tengo todos mis datos, hago un muestreo, saco un conjunto de datos y entreno con ese subconjunto.

00:46:30

Ise posgrados: Eh, el modelo. Tengo básicamente dos métodos de muestreo. Uno

que es baging, que se realiza con reposición o reemplazo. ¿Y en qué consiste? Supónganse que yo tengo un dataset de 1000 observaciones y yo quiero hacer una muestra de 100 y con esos 100 entrenar el modelo. Ese muestreo con reposición, ¿en qué consiste? Yo tengo los los las observaciones ahí. Agarro una y la pongo en mi muestra. La devuelvo a la bolsa de a la bolsa de observaciones. Agarro otra y la pongo en mi muestra. Y puede ser que yo vuelva a agarrar la misma. Va a quedar repetida, no importa. Eso es con reposición. O imagínense algo, un caso más simple. Yo tengo una bolsa con numeritos del un sorteo, tengo 100 números. Saco un número, sale el dos. Lo anoto en mi en mi pizarra, devuelvo el dos a la bolsa, saco otro número, sale otra vez el dos, anoto el dos, lo devuelvo, saco otro número, ahora me sale el cinco, anoto el cinco.

00:47:24

Ise posgrados: Eso es con reposición. Pueden salir repetidas, a lo mejor no salen repetidas, pero eh pero yo estoy permitiendo que que salgan repetidas. Y el pastosición. Saco el dos, lo anoto, tiro el numerito, no vuelve a aparecer más. saco otro, sale el 10, saco otro. Esas son las dos eh los dos métodos para hacer el muestreo, con o sin reposición. Entonces, las observaciones pueden aparecer repetidas o no. De esa forma hago distintas muestras, entreno varias veces, puede ser el mismo árbol, eh, pero con distintos subconjuntos, distintas muestras de mis datos. Entonces, los árboles van a ser diferentes. Vamos a ver primero para entender cómo funciona Baging. Vamos a ver el concepto de bootstrapping que no sé, ustedes vieron, les voy a mostrar para que se entienda, un ejemplo más básico, eh, con una con una notebook. No sé si la habrá vieron interval desconfiasa o todavía no en proba.
Cristian A. Aballay: Sí, sí.
Ise posgrados: ¿Ya vieron? ¿Vieron esta notebook? Porque esta notebook es de prueba sí no se sabe.

00:48:43

Ise posgrados: No sabe, no contesta.
Cristian A. Aballay: No recuerdo, pero yo creo que sí.
Ise posgrados: Bueno, no importa. Igual no les voy a mostrar, solo quiero mostrarles una eh una cosita muy particular y por las dudas que no lo hayan visto o que no se acuerden, e esta N lo que hace es calcular intervalos de confianza. Un intervalo de confianza, como dice acá, es un rango de valores que con cierta probabilidad

contiene el valor verdadero de un parámetro poblacional. Esto, ¿qué significa? Imagínense, por ejemplo, el caso que les decía del Wy, de adivinar el peso del Way, eh cuantas más muestras yo tenga, eh más y si yo las promedio, más cerca voy a estar al al verdadero valor de ese de ese peso de ese buey. Un intervalo de confianza es un rango. Si el hu pesa 1000 kg y yo digo, bueno, mi intervalo de confianza va a ser entre, voy a decir que con 95% de probabilidad el peso verdadero está entre 985 y 1015 kg, ¿no? Eso sería un intervalo de confianza, un rango valores que me acota el verdadero valor. Ahora, hay muchas formas de calcular ese intervalo de confianza cuando yo conozco más o menos la distribución de los datos.

00:49:52

Ise posgrados: Entonces, hay muchos métodos para calcularlo, pero lo que pasa es que si yo tengo pocos datos o no conozco la distribución de mis datos, entonces todos esos métodos que existan no me sirven. Y una posibilidad, una posible forma de calcular un intervalo de confianza es con bootstrapping. Entonces, acá al final de todo hay un ejemplo. Esta notebook no, yo no se la subí porque es una notebook de probabilidades que seguramente la tienen en el campus. Eh, y acá está el cálculo de la media con bootstrap. O sea, lo que hace este método es, yo tengo repoquitos datos, pero con esos datos y la técnica de bootstrapping, que es muestreo con reposición, calcula un intervalo de confianza para la media. Esto funciona así. Yo tengo un ejemplo acá, 10 datos. Imagínense que estos pueden ser las edades de personas. Tengo 10 datos. El 25, 28, 30, la 50. ¿Están ordenados? No, no están. Sí están ordenados. Bueno, estos son 10 edades. Yo podría promediarlas y me da, no sé, 35. No sé cuánto da el promedio, pero supóngase que me da 35. Promediarla yo puedo, pero dar un intervalo de confianza para la población, o sea, decir entre cuánto y cuánto está el promedio de toda la población,

00:51:06

Ise posgrados: salvo siendo que yo tengo como muestra solamente 10 valores, no se puede hacer con ninguna técnica conocida. Entonces, con el Bootstrap lo que hago es saco muestras de acá con reposición. saco de acá, por ejemplo, cinco datos con reposición. Yo podría sacar el 25, el 25, el 28, el 30 y el 30. Eso con reposición porque aparecen repetidos. Y ahí tengo una muestra. Hago otra muestra y saco el 50, el 50, el 50, el 45 y el 25. Esa sería otra muestra. O sea, saco muchas muestras de tamaño cinco con reposición, entonces van a haber números repetidos y no pasa nada porque así está hecho el experimento. En este caso estoy haciendo 10,000

muestras, o sea, a partir de 10 datos hago 10,000 veces eso, sacar muestras. En este caso los tamaños de la muestra son de 10, o sea, hago una muestra de 10 donde pueden ser los 10 distintos o pueden aparecer 10 veces el 25. Es indiferente. Lo hago 10,000 veces.

00:52:08

lse posgrados: Eso lo eso es lo que hace toda esta celda, armar el armar el muestreo ese. A partir de hacer eso, yo tengo le calculo la media a esas muestras y tengo 10,000 números, o sea, 10,000 promedios que lo saqué de esas 10,000 muestras. Esos 10,000 promedios yo los ordeno y supóng que el promedio esto es 36. Todos esos números, todos esos 10,000 promedios, van a estar todos bastante cerca, el 35, 36 seguramente o o la mayoría tal vez. Esto funciona, o sea, esto está demostrado que funciona, o sea, no es un invento de la notebook para sacar un un valor. Esto está demostrado que funciona. Ordeno esos 10,000 valores, esas 10,000 esos 10,000 promedios. Le calculo el percentil 2,5, o sea, le calculo los el percentil 2,5 de 97,5, es decir, que le le quito el 5% de de arriba y de abajo. Y eso que me queda ahí es un intervalo de confianza.

00:53:08

lse posgrados: Eso me dice que hay un 95% de probabilidades que la media de esta población, no de estos 10 valores, sino de la población entera, esté entre, en este caso, entre 31,7 y 41. Acá abajo está dibujadito. Estas son las 10. Acá están graficados los 10,000 valores de esas 10,000 muestras, las 10,000 medias. Y esto que está en rojo es el intervalo calculado a partir de esas 10,000 muestras hechas con Bootstrap. La media verdadera, o sea, la media verdadera, ¿no?, de la muestra original de mis 10 datitos que tenía era 36. Y este intervalo se obtuvo a partir de esa técnica de hacer 10,000 muestras con reposición. O sea, esta es una aplicación de el muestreo con reposición. Y esto funciona para cualquier set de datos. No importa, yo no me fijé si tenían distribución normal, si eran uniforme, o sea, no me fijé qué distribución tenían esos datos. Eran 10 datos, era todo lo que tenía. Entonces, si volvemos acá, esto es un poco lo mismo que les acabo de mostrar en el notebook.

00:54:25

lse posgrados: Es la misma idea. Tengo la muestra, hago mis remuestras. computo

un estadístico, es decir, en este caso computé la media. Es gráficamente exactamente lo mismo que les mostré en la notebook. Y esto de sacar muestras con reposición es lo que se denomina bootstrapping. Y eso a qué viene? A que lo podemos trasladar al concepto de de modelos y ensamble. Bagin es el significado de bagin es bootstrap aggregating, o sea, la vez de Bootstrap. Y esto de bueno de agregación sería la idea. Es así como yo tenía 10,000 muestras acá puedo tener 10,000 modelos. O sea, reemplazamos el concepto de muestras por el concepto de modelos junto de 10,000 modelos y e bueno, 10,000 se me fue la mano, pero la idea es esa. Agarro un montón de modelos que pueden ser todos iguales. Acá en este dibujo son todos distintos, pero pueden ser todos iguales, pero la gracia acá es cambiar los datasets. Estos datasets que yo voy a usar se van a construir con un muestreo con reemplazo, o sea, del dataset original hago muestreos con reemplazo y con cada dataset yo entreno el modelo que como les digo, pueden ser todos árboles, no importa, todos iguales, pero cada uno va a recibir un dataset diferente.

00:55:49

Ise posgrados: Entonces, cada modelo, si yo traigo una observación y la paso por este modelo y la logro que me saque una predicción, voy a tener 10,000 predicciones hechas con el mismo modelo, pero entrenadas con distintos dataset. Y todas esas predicciones, si yo las eh promedio, se supone que me va a dar un número muy eh muy preciso. Esa es la gracia de hacer esto. En vez de complicarme inventando modelos super diferentes entre sí, yo podría usar el mismo modelo, pero enfocarme en hacer diferentes entre sí los datos de entrenamiento. Bueno, esto es un detalle. En todos estos casos que estuvimos viendo, todos estos modelos pueden ser entrenados en paralelo. E la idea es que los tengo que entrenar todos de todas maneras, en paralelo no en paralelo. La salida de todo esto no no sucede hasta que no se entrenaron todos, ¿no? Porque de eso se trata el ensamble. Lo más común en bagin es usar un solo tipo de modelo. Como les decía, yo cambio el dataset, hago muestras con reemplazo y arriba, o sea, los modelos pueden ser todos árboles, que de hecho es lo más común y esto sirve tanto para clasificación como regresión. cada árbol.

00:57:27

Ise posgrados: Esto es un poco lo mismo dicho en otras palabras, o sea, es lo mismo que vimos recién, pero suponiendo que tengamos todos árboles, cada árbol se entrena con una muestra diferente, entonces cada árbol va a ser distinto del otro.

Todos van a ser distintos entre sí. Los árboles pueden ser muy profundos, pero eh si promediamos todos esos árboles, vamos a reducir eh esa varianza que hay entre los árboles y vamos a lograr un un el promedio va a lograr un equilibrio ahí eh en la salida, como dice acá, bueno, mejores resultados cuando tenemos escalado esto a muchísimos árboles. ¿Quieren hacer una pausita?
Cristian A. Aballay: Sí, sí.
Ise posgrados: Sí. Bueno, así después seguimos con el otro con el otro tema. Eh, 10 minutos. Bueno, seguimos. Bien, repasando entonces estamos viendo modelos de ensamble, vimos que la idea básicamente es tenemos unos cuantos modelos que los vamos a entrenar en paralelo, eh, de manera que después de alguna manera con alguna técnica vamos a promediar la salida de todos esos eh modelos y vamos a tener una salida que en teoría o lo que esperamos es que sea mejor que las salidas individuales. de cualquiera de esos modelos y en particular recién vimos Bagin que eh consiste en entrenar quizás con el mismo modelo repetido un montón de veces, pero con distintos datas de entrenamientos que los vamos a sacar muestreando el dataset original.

01:10:13

Ise posgrados: Es decir, tenemos el dataset original, sacamos su muestras todas distintas y con eso entrenamos los modelos y eh luego los los meramos, digamos, en una única salida. Y ahora lo que vamos a ver son los eh bosques aleatorios. Es la traducción, pero probablemente los hayan escuchado nombrar como random forest, que es lo más usual. Eh, es lo mismo. ¿Qué son una mejora del vagin? El waging usa eh muestras distintas. Eh los bosques aleatorios también, pero agregan una selección de atributos, es decir, para entrenar no usan todos los atributos. Por regla general, si yo tengo eh en este ejemplo 13 atributos, los árboles en Random Forest van a usar cuatro atributos random, no los 13, solo cuatro. En cada eh cuando está armando el árbol, en cada nodo va va a elegir cuatro atributos al azar para hacer el para hacer el split el split del del árbol, ¿no? En en hojas en o en subramas. ¿Y qué gracia tiene hacer esto? Porque uno diría, bueno, si yo tengo 14 atributos y usa solo cuatro, estoy perdiendo información, no estoy usando todo, me estoy me estoy quedando corta, no sé. Pero tiene una un razonamiento muy bueno que imagínense que yo tengo un atributo que es un predictor muy fuerte.

01:11:48

Ise posgrados: Por ejemplo, como les decía antes, les mencionaba en el ejemplo

este del eh de la clase pasada, yo tengo la edad, supóng que la edad es una una un predictor muy fuerte del salario, no es la edad, es años, años de no sé, de jugando, no sé. Eh, esa esa variable es un atributo, un predictor muy fuerte de la variable target. todos los árboles que yo tenga, no importa el dataset de entrenamiento que yo les pase, van a empezar particionando por esa columna. Entonces, van a terminar siendo estos muy parecidos, aunque el dataset de entrenamiento sea bien distinto. Eh, bien, una vez más, si pasa eso, voy a estar limitando la capacidad del ensamble y no estoy sacando provecho de eh de mi ensamble. Random Forest, como elige un subconjunto de las de las de los de las variables, entonces tengo la certeza que en alguno de esos árboles, por lo menos esa variable, ese esa que era muy una proyectora muy fuerte, no se va a usar. Habrá algún árbol que no use esa columna del ejemplo de esa columna Yar, algún árbol no la va a usar. Entonces ahí me aseguro que los árboles van a ser distintos y y no van a empezar todos particionando por year en dos.

01:13:03

lse posgrados: Eh, esa es la eh la ganancia que yo tengo de eh elegir eh en forma random determinadas eh variables y que van a ser distintas entre los distintos árboles. La gracia de esto también en particular es hacerlo cuando tengo muchos atributos, porque si tengo si tengo cuatro no más y el bosque me va a elegir eh tres es como tampoco estoy ganando mucho. Si yo tengo 100 atributos y el o 125, ¿cuánto es la raíz cuadra de 125? No, no es cinco. Hágame una cuenta. Eh, 10* 10 100. Yo tengo 100 atributos. Eh, el random Forest me va a elegir 10. Eh, ahí sí tengo una gran variedad de árboles. Si cada uno me elige 10 atributos diferentes. Bien, que me estoy perdiendo de esta de esta slide. los eh random forest tienen la capacidad de darse cuenta cuáles son las variables más importantes o las más eh fuertes, descubrir relaciones entre ellas que otros algoritmos por ahí no no ven. Y esto en particular es un dibujito que después lo vamos a ver en la un dibujito, un gráfico que después lo vamos a ver en la notebook, eh, que muestra la importancia, lo que se llama la feature importance, que es la importancia de las variables para para el modelo.

01:14:29

lse posgrados: Acá, por ejemplo, me está diciendo es que esta variable es muy importante o muy más que importante es una fuerte predictora de la variable target y todas las otras no tienen tanta importancia eh para la predicción. Eso es lo que

muestra esto en la notebook. Después lo vamos a ver. Ahora, eh existen dos enfoques para determinar cuáles son las variables fuertes eh y más predictoras de eh de la variable target para, o sea, esto le sirve al árbol para saber cómo cómo elegir y cómo ir haciendo el split. Hay dos enfoques. Uno es por disminución de la precisión. Y lo que hace esto es, por ejemplo, siguiendo con el mismo ejemplo, yo agarro la columna year, ¿no? Y hago un las las desordeno, desordeno los valores de esa columna, los pongo en cualquier orden. Tengo mi dataset así y esa columna la mezclo toda. Si la salida de ese modelo me da bastante parecido a lo que me daba cuando la columna estaba en su lugar, significa que esa variable no era tan importante para el modelo, porque no me cambió nada. Pero si yo la si yo desordeno y el modelo era buenísimo y ahora me da una porquería es porque la variable era realmente importante. O sea, esa es la base de esta de este enfoque para darse cuenta si una variable es importante o no eh para el modelo.

01:15:59

Ise posgrados: Y el otro enfoque es usando los índices eh que ya vimos que puede ser entropía, puede ser otro. Y el enfoque se llama por disminución de la impureza, es decir, se calcula el ag se agarra un un atributo y se divide el dataset en dos y se calcula la impureza de esa división. Si con alguno de esos índices, entonces se, o sea, se mide cuánto disminuye la impureza. Cuanto más disminuye disminuya más es la importancia de la variable. O sea, de acuerdo al resultado de los índices, me doy cuenta si esa separación me está dando eh ramas puras o eh o impuras. Y en base a eso eh se determina la importancia de las variables. Son como dos enfoques para determinar cuál importante es un atributo o no en la predicción de la de variable target. Sí.
Pa. Santiago Rodriguez Castro: Sí, perdón, una duda.
Ise posgrados: Sí.
Pa. Santiago Rodriguez Castro: Eh, estaba pensando en los los shap values, el análisis de Shap values eh de los modelos. Se me hace parecido al primero, al de permutación,
Ise posgrados: Sí.
Pa. Santiago Rodriguez Castro: pero no me acuerdo si ya valio era quitar directamente la variable y ver cómo pierde precisión el modelo, o esto de cambiarlo por la variable completamente aleatorizada y ver cómo pierde precisión el modelo,

01:17:19

lse posgrados: Me parece que no estoy segura,
Pa. Santiago Rodriguez Castro: si son Ah,
lse posgrados: pero me parece que es quitar, pero no estoy segura,
Pa. Santiago Rodriguez Castro: perfecto.
lse posgrados: eh, no te lo prometo.
Pa. Santiago Rodriguez Castro: Podría ser una variante en todo caso y gracias.
lse posgrados: Podría ser. Sí, sí,
Pa. Santiago Rodriguez Castro: M.
lse posgrados: de nada. Eh, bien, en la notebook vamos a ver ejemplos de Random Forest. Ahora vamos a pasar a boosting, que es baging versus boosting. Boosting es otra cosa. Vieron que hasta ahora lo que vimos fue eh tenemos un montón de modelos secuencia eh perdón paralelos, los corremos todos y después vemos qué salida sale qué salida obtenemos. El boosting es un entrenamiento secuencial. También tenemos muchos modelos, pero es uno atrás del otro, o sea, es una gran diferencia. El otro son todos en paralelo. Eh, sí, todos en paralelo. Y a partir de ahí veo con qué me quedo como promedio o lo que sea. Y boosting es un montón de modelos, pero corre uno atrás de ese otro, atrás de ese otro, todos encadenados secuencialmente.

01:18:23

lse posgrados: Para boosting lo más común es usar árboles de decisión simples, o sea, con pocos con pocos nodos. Y al correr modelo secuencialmente, esto es algo un poco más lento, tampoco es, oh, qué lento, no lo voy a poder correr, pero eh la idea es que el resultado sea mejor que eh quedarme con un solo árbol. O sea, siempre ese es el objetivo. El la versión más simple de boosting es uno que se llama adaptive boosting o adab boost, no sé si lo habrán escuchado nombrar. Eh, piensen que tengo entonces varios árboles y los voy a correr uno atrás del otro. Y digamos, ¿en qué consiste? Yo empiezo, tengo mi dataset de entrenamiento y todas mis muestras, vamos a suponer que tengo 100. Las 100, las 100 observaciones para mí tienen la misma importancia, el mismo valor y yo entreno con un árbol, ese eh entreno con ese dataset un árbol, un árbol simple. calculo el error del modelo, me fijo cuáles observaciones fueron mal clasificadas y ahora les doy un peso, les doy un peso un poquito más que al resto, o sea, que les doy más importancia. Al modelo siguiente yo le digo, "Mira, este es dataset, pero a estas filas dale más importancia." O sea,

01:19:49

Ise posgrados: eh le pido al modelo que se enfoque en clasificar bien, si es una cuestión de clasificación, en clasificar bien esas en particular que el modelo anterior clasificó mal. Entonces, el segundo modelo se entrena teniendo en cuenta eso. Nuevamente me fijo el error, me fijo en cuáles se equivocó, actualizo los pesos y vuelvo, o sea, itero así mirando, dándole más, ajustando los pesos y entreno, entreno, entreno toda la secuencia de modelos. Al final combino todas las predicciones ponderadas. Tengo dos eh dos eh pesos distintos, dos ponderaciones distintas. Uno es el peso acá que le doy a las eh acá donde dice este cinco rojo. Estos son los pesos de las observaciones que el modelo anterior clasificó mal. Pero además luego de entrenar cada modelo, según cómo funcionó el modelo, le doy un peso al modelo. También el modelo le doy un peso, si funcionó bien, le doy un peso alto, si funcionó mal le doy un peso bajo. Y después combino todo. O sea, es una salida ponderada de todos los resultados, de todos los modelos. Eso sería la salida final del adabost. Esto sería como bueno, una formulita que me dice, sumo todo, pondero con las con los pesos llamados alfa, pero la idea es esa, o sea, sumo todas las salidas ponderadas.

01:21:16

Ise posgrados: Cada entrenamiento usó el resultado del modelo anterior y se enfocó en lo que el modelo anterior se equivocó. Esa sería la idea del adabust. Y por otro por otro lado tenemos el gradient boosting. A diferencia del boost que e funciona así ponder las observaciones mal clasificadas, el gradient boost lo que hace es entrena un un modelo, calcula los errores y esos residuos, esos errores se usan para entrenar el modelo siguiente. O sea, el modelo siguiente entrena sobre esos residuos. que se van arrastrando y cada vez deberían ser más chiquititos. O sea, la idea es que ajuste, se vaya ajustando el modelo para que esos residuos sean cada vez más chiquititos. E y nada, se van. Nada, eso es el ese es el gradient boosting que ahora a ver con un dibujito, esto más o menos trata de representar la idea. Yo tengo acá abajo es eh esto rosado es como eh la salida del modelo, ¿no? Los verdes son los puntos, supongamos que esto es una regresión, ¿no? Los verdes son todos los puntos, las observaciones que yo tengo. El rosa es la predicción de la primera vuelta, que acá es bastante bastante mala.

01:22:38

Ise posgrados: una recta así dramática que me ignora todo esto y todos estos son mis residuos, ¿no? Las distancias a la verdadera al verdadero valor. Esos residuos son los que se usan para la segunda iteración. La segunda iteración va a ajustar los residuos y la y la salida, la predicción va a ser la combinación de la salida del modelo anterior y el ajuste de los residuos. O sea, el segundo modelo, el tercero, el cuarto van a ser las salidas de los modelos que van ajustando los residuos. No es que ajusto, no entreno sobre todos los valores originales, sino que yo lo que hago en cada iteración es entrenar eh para que esos residuos, o sea, tomo los residuos y hago un ajuste de los residuos para que esas esos residuos sean cada vez más chiquititos. Acá como bueno, ya estarían cercanos a cero en la tercera iteración. En este ejemplo, acá la salida, si se fijan, es una combinación de los tres modelos, del primero, del segundo y del tercero. O sea, la primera es una salida bastante bruta, por decirlo de alguna manera. La segunda agarra la salida a la primera y ajusta, hace un ajuste, hace un entrenamiento con los residuos de la primera y acá acumula la salida de los dos modelos, del primero el principal con el ajuste de los residuos y así eh cada uno va tomando los residuos del anterior y se va se va ajustando cada vez más.

01:24:01

Ise posgrados: Sí.
Alejandro Valle: El el predictor que ajusta los residuos tiene que ser un modelo o es grading descent, por ejemplo.
Ise posgrados: A ver, es, espérenme un segundito, me está sonando el teléfono, disculpen. Ahí estoy, disculpen. E ya estoy presentar. Eh, me decías quién era, Alejandro, estaba preguntando.
Alejandro Valle: Sí, era yo.
Ise posgrados: No.
Alejandro Valle: No me quedó claro si en esta técnica de boosting eh el paso que actualiza los pesos o bueno, la los errores es otro modelo o es un algoritmo como grading descens.
Ise posgrados: Es como Gre Descent, sí, porque está tomando, está Sí, se está moviendo por el por el eh como que está buscando eh dónde dónde se está equivocando el anterior para ir ajustando. Exactamente. Es eso. De de por de ahí sale el nombre.
Alejandro Valle: Pero siempre usan varios modelos como Week Learners o solamente es un modelo.
Ise posgrados: Es un modelo. Es un modelo. Vamos, vamos a ver también un

ejemplo en el en el Igual puedes elegirlo. Es como un parámetro también del de la de la función de Cy Ren. Lo puedes elegir
Alejandro Valle: Okay.

01:26:44

Ise posgrados: acá a grandes rasgos la comparación, ¿no?, entre vagin y boosting. El primero que vimos son múltiples modelos que son independientes, que se entrenan en subconjuntos aleatorios de de los datos de entrenamiento y el boosting construye los modelos en forma secuencial, uno tras del otro y cada uno de esos se centra en corregir el error del anterior en el en toda esa secuencia. Eh, ¿qué otra cosa? Bueno, acá después lo lo pueden mirar, pero otra cosa que hayamos dicho recién, eh, bueno, es un poco nada entender que que en qué ventajas y desventajas tiene cada uno, pero bueno, la principal ventaja es eh perdón, la principal diferencia quiero decir es que uno tiene todos los modelos en paralelo y a partir de ahí sacan una un resultado. El boosting son todos eh secuenciales y depende. Habíamos visto el Adabost que tiene una una técnica para para ir enlazando los modelos y el gradient que lo que hace es ir ajustando en base a los errores del del anterior, va ajustándolo eh se va moviendo hacia la solución perfecta, digamos, se va por los errores achicándolos cada vez más. Después, no sé, cosas medio obvias, el tiempo de entrenamiento, esto se construye en forma independiente, puede ser más rápido.

01:28:08

Ise posgrados: Esto es como cada uno requiere que el anterior termine porque están todos enlazados, puede ser más lento. Bueno, eso es relativo también depende del tamaño del dataset, depende la complejidad de los modelos, depende el equipo que con donde estén corriendo el modelo. Así que eso bueno, bastante relativo en realidad.
Gabriela Sol Salazar: Una pregunta,
Ise posgrados: Sí.
Gabriela Sol Salazar: esto del boosting me hace bastante al learning rate y a irlo ajustando, digamos,
Ise posgrados: Sí,
Gabriela Sol Salazar: para disminuir también el error. ¿Está vinculado o no?
Ise posgrados: sí, sí,
Gabriela Sol Salazar: M.
Ise posgrados: sí, sí, sí. Y de hecho ahora vamos a mencionarlo. Sí, si es este está

vinculado al rate. Normalmente eh lo vamos a mencionar más o va a venir más este al al a nuestra notebook cuando cuando vean e redes neuronales. Es un parámetro que siempre está en los modelos, pero sí, sí, sí, sí. Ahora lo vamos a mencionar.
Gabriela Sol Salazar: Bien, gracias.
Ise posgrados: Bueno, exhibost, no sé si lo habrán escuchado nombrar, es una implementación, es una biblioteca que es una implementación del gradient boosting. Acá tienen el link a la biblioteca, la librería y acá un paper donde se explica eh en qué se basa eh toda esta implementación.

01:29:26

Ise posgrados: Eh, pero bueno, es un caso particular, una implementación del grading boosting, que es lo que acabamos de de ver. Tiene justo acá lo que preguntaba Sol, tiene muchos hiperparámetros. Uno de ellos acá, esto que preguntaba Sol, el se llama ETA, pero es el learning rate, básicamente, que es un un eh eh tiene la función, digamos, de escalar cuánto eh ir regularizando, digamos, cuánto vas eh ajustando cada eh cada modelo respecto del anterior para que no el el ajuste no sea demasiado rápido y eh terminar sobreajustando. Es como como una especie de regularización que haces con este parámetro. Y este otro hiperparámetro subsample, eh, si se acuerdan que mencionamos hace un rato el muestreo con reemplazo e y sin reemplazo, eh este esta biblioteca usa eh sin reemplazo, que es el pasting, no sé si lo había nombrado yo, pero en la diapositiva lo mencionaba que era pasting. Estos son como los más importantes, pero tiene un montón de parámetros este modelo y algo como esto creció creció digo, surgió antes y en forma totalmente independiente y learn tiene su propio paradigma y sus propias eh interfaces eh que son bien distintas a lo que estamos acostumbrados con Pychit learn Learn. Y entonces, justamente por ser tan diferentes después ellos crearon una nueva interfaz, o sea, ustedes pueden usar Exibost en su forma nativa o usando la eh API de Sec learn Learn, que es eh al usar eh exhibost, digamos,

01:31:14

Ise posgrados: es muy parecida a la anotación y además es compatible con cycle learn. Esa sería como la diferencia entre estas dos. Y acá está esto que les comentaba, el parámetro, el hiperparámetro ETA en esta interfaz se llama learning rate. También tiene parámetros para regularizar, bueno, tiene un montón de parámetros, pero estos que están mencionados acá serían como quizás los más usados o los más relevantes. Y después hay otras implementaciones muy conocidas

también y muy usadas que son la HBM y CATBOST. Y acá están los links a cada una de ellas. La verdad que todas estas tres, o sea, Xibost, LGBM y Catbost, todas se usan y no hay forma de decir esta es mejor que la otra. La idea es que ustedes si las quieren usar que entren, investiguen, las miren, las prueben y cada uno le encontrará lo mejor o lo más adecuado al problema que ustedes quieran resolver. Sí, en la notebook ahora vamos a ver un ejemplo con exhibost, pero eh bueno, sepan que estas dos no es que sean menos importantes ni mucho menos, simplemente son otras implementaciones. Antes de ir a la notebook, les quería mostrar acá, si se fijan en la documentación de Py Learn, en la parte de ensamble, o sea, de los ensambles, van a ver que para todas las cosas que estuvimos viendo existe la versión de clasificación y de regresión, porque nosotros en los ejemplos de la notebook por ahí hacemos solo regresión, pero está la versión de clasificación.

01:32:46

Ise posgrados: Por ejemplo, acá el adabost que lo vamos a ver ahora en la notebook está el clasificador y el y la versión para hacer regresión. Vaging también, classifier y regresor, todo, todas las cosas. Random forest classifier regresor. O sea, para cada una de las eh de las opciones de ensamble que vimos hoy están las dos posibilidades de hacer clasificación y de hacer regresión con secondarn. Sí, están todas las ahí pueden eh investigar todas las todas las opciones que tienen. Y bueno, entonces acá tenemos la notebook. Bueno, un pequeña introducción. Es lo mismo que ya vimos eh recién, vaging, random forest, boosting, que es cada cosa. Y vamos al a los ejemplos. Eh, tenemos acá precios de casas de California, un dataset que Ahí está, acá está la descripción de los datos que tiene la el dataset, unas cuantas eh variables predictoras y eh se quiere predecir el precio. Acá está transcripto también la descripción de cada uno. El el gráfico que les mostraba de las eh del future importance era de este dataset. Bien, acá obtenemos el dataset, hacemos el split, hacemos eh no hacemos más nada, el split nada más.

01:34:20

Ise posgrados: E entrenamos dos modelos de base para tenerlos como para comparar, ¿no? Una regresión lineal y un árbol. Esos son de base para compararlo contra el eh contra las los ensambles. Primero entrenamos la regresión lineal. Acá obtenemos las métricas, están acá. Después entrenamos el árbol de regresión. Acá están las métricas del árbol de regresión. Y estas las vamos a usar para compararlas después. A ver si me fue bien o me fue mejor con los ensambles o era

suficiente con con estos modelos simples. Voy a subir un poco. Empezamos con Bagin. Acá tenemos el link. Es la misma página de la documentación de Sakir que les mostraba recién. Tenemos el vagin regresor. Acá le pasamos los árboles. Vieron que yo les dije podemos hacerlo y lo más común es tener todos árboles, pero ustedes le pueden pasar otra causa acá que no sea árbol. Hacemos el fit, hacemos el predict y obtenemos las métricas. Y acá comparamos el vagin contra esos dos modelos iniciales de base que habíamos eh e que habíamos entrenado.

01:35:48

lse posgrados: Estoy viendo cuál es la métrica que dice acá que subió un 37%. Eh, no veo ningún 37 acá, pero bueno, el mae es mejor en el baging. Está claro, está ordenado por ma. Es mejor en el vagin que en las en el árbol de regresión y en la regresión lineal. Acá ya vemos que mejoró. Vamos a ver el random forest. Lo mismo, una regresión, ¿no? Con random forest. Acá tenemos el random forest regressor, que no le pasó ningún parámetro, solamente la semilla. Entrenamos esto siempre la a nivel de código de de Python es como siempre lo mismo. Entreno, predigo y calculo las métricas. Sumo a mi data frame los resultados del random forest. Y ahora el random forest es el mejor de todos, de los cuatro. Tampoco es una barbaridad que cambie mucho, pero es mejor es mucho mejor y los dos están mucho arriba, mucho más arriba, en resultados mucho mejores que los dos primeros que que habíamos probado. Seguimos con boosting, con Adabost, Adabost Regresor. Acá lo construimos, lo entrenamos, predecimos.

01:37:14

lse posgrados: y calculamos las métricas. El adabús quedó medio allá abajo, no le fue tan bien.
Lucia T. Capon Paul: Perdón,
lse posgrados: Sí.
Lucia T. Capon Paul: ahí hicieron una Eh,
lse posgrados: Ah, sí. Decime, Lucía, por
Lucia T. Capon Paul: dicen,
lse posgrados: favor.
Lucia T. Capon Paul: "El stacking en este caso es correr una logística cuyos inputs son la salida de otros modelos.
lse posgrados: El el input del stacking es la salida de los otros modelos. Sí, sí, sí. Y ahora vamos a ver el exibot. Como les decía, es otra biblioteca, entonces la van a

tener que instalar. Acá están las instrucciones para hacerlo con Conda, con PIT, con Poetry. E es una biblioteca aparte. Acá está como la importamos. Este es el X B regresor para inicializar un un exhibost para hacer regresión. Acá entrenamos, acá precimos lo mismo, ¿no? Y acá obtenemos las métricas. Y este le pasa el trapo, ¿no? A las otras. El exhibus fue lejos el mejor, aunque bueno, no tan lejos de Random Forest, pero bueno, fue el mejor de todos hasta acá, hasta este momento de todo lo que vinimos haciendo.

01:38:39

lse posgrados: Esto es lo que les decía de la future importance. tiene acá eh simplemente invoco a Feature Importance y ya me trae la las resultados de cuáles fueron para este para este eh modelo las eh las variables más importantes. En este caso, internamente, Lex Boost no usa eh no usa ninguna de las dos métodos que vimos, esa de mezclar aleatoriamente la columna o eh calcular el índice de Gini o entropía. tiene como su propio método de calcular cuáles son las variables más importantes, pero bueno, según sus propios métodos, la importancia de las eh las variables es en este orden. Esta med segura de qué significa, qué qué variable es en la en el dataset. Creo que es algo de la ubicación de las algo de la ubicación la las ¿cómo se llama? como si fuese el barrio, como si fuese una un, ¿cómo se llama? Una una no, el barrio, ¿cómo se dice? Cuando está dividida una, ¿cómo es la palabra? Una ciudad dividida en en comuna o en algo por el estilo, algo de eso me parece que es, pero no estoy segura. Eh, pero bueno, por lejos esta variable es como la predictora más fuerte de todo el dataset con respecto al valor de las casas. un bloque.

01:40:11

lse posgrados: Acá está. Es un son bloques, bloques de casas o serían como las cuadras. La verdad que no lo sé. Eh, bien. Bueno, eso es eso es. Fíjense que a nivel de implementación no tiene ninguna complejidad. Esto lo importante es entender qué es lo que está haciendo cada modelo por detrás o de de qué se trata, ¿no? Pero a nivel de implementación, fíjense que yo inicializo el modelo y después como siempre lo entreno, después predigo y después miro las métricas a ver cómo me dieron. Es no tiene más más ciencia que eso. ¿Alguna otra pregunta? Me parece que ahí estamos, ¿eh? Sí, ahí terminó la ahí ya estamos con la presentación. ¿Alguna otra pregunta, chicos, con esto? Estamos. Bueno, bueno, eh, cerrando un poco todo esto, los ensambles vieron que estamos juntando modelos de todos los modelos que ya

vimos y y con esto se cierra todo el tema de eh modelos de clasificación supervisada. Dicho esto, ustedes ya tienen todo el material para trabajar en sus trabajos finales de la materia. Lo que vamos a ver eh de acá en adelante no son más modelos de Ahora les cuento lo que vamos a ver, pero ya con lo que vimos hasta hoy ya vimos todos los modelos que están previstos para para la materia y no significa que sea la lista exhaustiva de modelos que existen, pero sí son los más básicos, los más conocidos, los más usados y con esto les alcanza y les sobra para eh entrenar y para trabajar en sus en sus

01:42:00

lse posgrados: proyectos este de la materia. Eh, la semana que viene vamos a ver calibración de modelos, que si bien está relacionado con los modelos que hemos visto, no es algo que se requiera para hacer los trabajos. Si ustedes quieren incorporarlo, pueden hacerlo, pero no es es algo como extra, ¿no? No es algo que necesiten. Sí, esa va a ser la temática de la semana que viene, que es la clase seis. Y la clase siete vamos a ver clasificación no supervisada, que también no tiene nada que ver con el proyecto que ustedes eligieron y tienen que hacer para el trabajo de la materia. O sea, es un tema que que es superinesante y es muy útil y todo, pero no está incluido en lo que se evalúa en la materia. Así que eh dicho esto, con lo que vieron hasta hoy ya tienen todo para poder trabajar en sus en sus proyectos. por las dudas, por si no tienen mucha idea que como a qué se apunta con el trabajo, eh hacemos como un repaso. Ustedes tienen un dataset elegido, tienen que con un problema de de predicción,
Leonardo Villalva: M.
lse posgrados: ¿no? Tienen que predecir algo con ese modelo, eh, con ese modelo, con ese dataset.

01:43:11

lse posgrados: La idea es que ustedes elijan de todos los modelos que vimos o si se les ocurre otro que no lo dimos también es válido que ustedes elijan qué modelos entrenar. No se queden con uno, no entren un modelo, entrenen tres, cuatro, no sé, lo que ustedes quieran con una justificación. Es decir, no entrenen los más fáciles o los los que dimos en la clase de hoy, o sea, entrenen con un criterio, elijan un modelo de base y digan, "Bueno, elijo de como hemos hecho en las clases, elijo de base una reveleión lineal porque es lo más fácil y a partir de ahí voy a entrenar este otro, este otro, este otro y voy a comparar. Si no eligen el de base, no tienen contra qué

comparar, básicamente. Entonces, eligen uno de base, que ande más o menos bien, y después entrenan otros para ir mejorando ese primero que habían elegido. Y después lo que tienen, o sea, lo que deberían hacer es armar una notebook. Si no les entra en una notebook, armen dos, pero bueno, en una debería ser suficiente. Agarran el dataset y van contando como un como un cuentito, digamos, como un storytelling. Tengo este dataset, quiero predecir esto, voy a probar con este modelo de base.

01:44:12

Ise posgrados: Y ahí lo prueban y muestran resultado. Bueno, me dio bien, me dio mal, voy a intentar este otro. ¿Y por qué? Porque, ¿por qué eligen ese modelo? Porque no todos los modelos son para todos los problemas. Alguno es más adecuado para una cosa, para otra. Entonces eso no no tampoco entrenar todos los modelos que existen. Entreno esto, este, entreno todo y y este es mi resultado. ¿Por qué? Primero porque no están poniendo un criterio de de selección, pero además porque en la vida real no van a entrenar todos los modelos que hay, porque no les va a dar el el ancho de banda, digamos. En la vida real no entrenan todos los modelos posibles para elegir el mejor, hacen una selección. Entonces, un poco la idea también es esa, como describir con un cuentito bien explicado e ir mostrando todos los pasos de las cosas que van haciendo y después no olvidarse una conclusión, o sea, no que queden los resultados de los modelos ahí tirados en la notebook, sí o sí una conclusión, ¿qué obtuvieron? ¿Qué les pareció bien? ¿Qué les pareció mal?

01:45:03

Ise posgrados: ¿Qué no pudieron hacer? ¿Qué qué se qué les sorprendió de los resultados? No sé, una conclusión, elaboren una conclusión de todo lo que de todo lo que vieron. No sé si están encaminados por ese lado, si se imaginaban eso, pero un poco eso es lo que lo que se espera. Sí. Y no, no dejen de hacer preguntas, mándenos preguntas por correo, o sea, si tienen dudas, eh, no, o sea, no se traen y no esperen tampoco último momento para para resolverlo, porque por ahí subestiman el tiempo que les puede llevar si dejan todo por último momento y bueno, no es la idea que después no puedan no puedan llegar con con el trabajo. Ninguna pregunta de eso? Bueno, y nadie me preguntó y nadie le dio curiosidad por qué habíamos hablado de ensamble en análisis de datos. No les importó. Nadie preguntó, nadie se acordó. Bueno, no sé, no sé si les importaba. Yo les cuento igual. Eh, en las en una de las últimas clases de análisis de datos habíamos visto en una

de las últimas clases habíamos visto eh el desbalance y eh teníamos una slide donde habíamos visto técnicas para eh mejorar el balance de los datos cuando estamos en un problema de clasificación, ¿no?

01:46:34

Ise posgrados: Lo que queremos es que la target esté bastante balanceada. Si yo tengo un problema de clasificación, no sé, de personas si tienen enfermedad coronaria, sí, no y tengo con enfermedad 10 personas y si en la enfermedad 90 personas, o sea, esa variable de target está muy desbalanceada. Yo lo que quiero para que un modelo me ande bien es que esté más balanceada porque si no el modelo me va a performar mal, me va a predecir capaz que siempre que me va a decir que la persona no está enferma. Bueno, no es lo ideal tener tan desbalanceado. Entonces, habíamos visto que podíamos hacer under sampling o oversampling para emparejar eso, pero que después habían técnicas para mitigar el desbalance. Una de las técnicas es el ensamble. Por ejemplo, cuando hacemos el el vaging, que hacemos muestreos eh random de la del dataset de entrenamiento, el dataset de entrenamiento está desbalanceado, pero nosotros al hacer muestras de ahí, a lo mejor en muchas de las muestras el desbalance ya no es tan así. A lo mejor ahí voy eh eh mitigando ese desbalance. En muchas de las muestras a lo mejor saco cosas desbalanceadas y a lo mejor saco cosas muy balanceadas o a lo mejor eh puedo armar una estrategia que no sea tan random, no sea muestrear tan random, sino que sea muestrear en forma balanceada.

01:47:51

Ise posgrados: Si yo ya sé que está desbalanceado, hago una, o sea, implemento una técnica muestreo que sea sacar siempre 10 personas enfermas y 10 no enfermas random de las 90 que tenía y y así me voy construyendo todas esas suestras en el ensamble, ¿no? Todas sus muestras que están bastante balanceadas, pero todas distintas y entonces ahí eh ya no voy a tener ese impacto negativo del dataset desbalanceado. Esa sería como una de las técnicas que en su momento mencionamos, pero ni explicamos porque no tenía sentido en ese momento explicarlas, pero bueno, de eso se trataba. Así que ahora van a poder dormir porque ya tienen la ya conocen la respuesta, ¿no? No tiene más el signo de pregunta y y bueno, y eso era todo. Creo espero no haberme olvidado de nada, pero eso era todo por ahora. E nada, ahora ya son libres de trabajar porque ya tienen todo el material. Eh, de mi parte nada más eso era todo el contenido. Los libero tempranito, un día

feriado. Eh, si no tienen preguntas, eh, terminamos entonces la la clase. Si alguien tiene alguna pregunta de la clase o del trabajo, o lo que sea, nos podemos quedar un ratito, no hay ningún problema. Se quedan todos.
Santiago Bartolini: Hola, Karina.
Ise posgrados: Sí,
Santiago Bartolini: Yo tengo una consulta administrativa.
Ise posgrados: sí,
Santiago Bartolini: Eh,
Ise posgrados: sí,
Santiago Bartolini: yo la semana pasada estuve de viaje, eh,
Ise posgrados: sí,
Santiago Bartolini: y la mitad de la clase estuve con el teléfono.
Ise posgrados: sí,

La transcripción finalizó después de 01:49:29

Esta transcripción editable se ha generado por ordenador y puede contener errores. Los usuarios también pueden cambiar el texto después de que se haya generado.