📝 Las notas

abr 9, 2026

Aprendizaje de Máquina (6/8) - a242b25

Invitado facundolucianna@gmail.com macroldan@fi.uba.ar
Aprendizaje de Máquina - CEIA 24Co2025

Archivos adjuntos Aprendizaje de Máquina (6/8) - a242b25

Registros de la reunión Transcripción Grabación

Resumen

La sesión sobre métodos de ensamblaje y votación derivó en una discusión detallada sobre el aprendizaje no supervisado con K-Means, el modelo de mixtura gausiana y el clustering jerárquico.

Métodos de Ensamblaje y Bagging
Se revisaron los métodos de ensamblaje, destacando la votación, el Bagging, y Random Forest, los cuales combinan modelos para aumentar la precisión. Bagging utiliza Bootstrap Sampling para entrenar modelos con muestras de datos distintas, garantizando variedad en los resultados.

Introducción al Aprendizaje No Supervisado
Se introdujo el aprendizaje no supervisado, el cual se enfoca en descubrir patrones y estructuras en los datos, ausente de una variable objetivo. Los métodos para determinar la cantidad óptima de clústeres son el método del codo, el índice de la silueta y la fuerza de predicción.

Clustering K-Means y Jerárquico
K-Means fue el primer algoritmo de clustering revisado, buscando minimizar la inercia para crear grupos compactos; su limitación son las

formas circulares. El modelo de mixtura gausiana y el clustering jerárquico ofrecen soluciones a estas limitaciones, permitiendo clústeres de formas más complejas sin requerir una predefinición del número de grupos.

Próximos pasos

- ☐ [El grupo] Probar Librerías: Revisar documentación de librerías HIVM y Catbost. Instalar y entrenar modelos utilizando estas nuevas bibliotecas.
- ☐ [El grupo] Entregar Trabajo: Entregar trabajo final; incluir justificación, modelos elegidos y comparaciones. No olvidar conclusiones.
- ☐ [Ise posgrados] Confirmar Fecha: Confirmar la fecha exacta de entrega del trabajo la semana siguiente.

Detalles

- **Introducción y Repaso de Métodos de Ensamblaje (Ensemble Methods)**: La reunión comenzó con la notificación de un cambio en el plan de estudios, donde hoy se abordaría el aprendizaje no supervisado y la calibración se pospondría. Se realizó un repaso rápido de la clase anterior, que cubrió los métodos de ensamblaje, los cuales combinan modelos para obtener predicciones más precisas que los modelos individuales (00:00:00). Estos métodos se prueban cuando las arquitecturas simples, tras ajustar datos y parámetros, no ofrecen resultados convincentes (00:07:13).
- **Variantes de Métodos de Ensamblaje y Votación (Voting)**: Se discutieron las variantes de los métodos de ensamblaje, incluyendo modelos que votan, *bagging*, *random forest* y *boosting* (00:00:00). Para la clasificación, se revisaron los clasificadores de votación dura (*hard voting*) que se quedan con la clase más votada, y los de votación suave (*soft voting*) que ponderan las salidas probabilísticas de los modelos (00:07:13). En el caso de la regresión, la salida de los modelos se combina promediando las predicciones individuales (00:08:33).
- **Bagging y Bootstrap Sampling**: El *bagging* es una alternativa donde los modelos pueden ser iguales o distintos, pero se diferencian principalmente por los datos con los que son entrenados. Esto se logra mediante el muestreo

aleatorio con reemplazo (*bootstrapping*), creando una muestra de datos diferente para cada modelo, lo que asegura la variedad en los resultados (00:08:33).

- **Random Forest y Boosting**: *Random Forest* se presentó como una mejora del *bagging* que incorpora aleatoriedad en los datos y una selección aleatoria de las características (*features*) para cada árbol, asegurando que los bosques sean distintos y sus salidas variadas (00:09:50). En contraste con el *bagging*, el *boosting* utiliza modelos que corren secuencialmente. Se mencionaron dos categorías: el *boosting* adaptativo (*Adaboost*), que asigna mayor peso a las muestras mal clasificadas para que el siguiente modelo se enfoque en ellas, y el *gradient boosting*, donde cada modelo intenta corregir los errores del modelo anterior (00:11:17).
- **Implementaciones de Gradient Boosting y Aprendizaje No Supervisado**: Se destacaron implementaciones populares de *gradient boosting* como ExBoost, LightGBM (LGBM) y CatBoost (00:11:17). A continuación, se introdujo el tema del aprendizaje no supervisado, el cual se diferencia del supervisado por la ausencia de una variable objetivo (*target*) para predecir, enfocándose en la creación de grupos de observaciones (00:12:33).
- **Desafíos del Aprendizaje No Supervisado y Justificación**: Los desafíos principales son determinar la cantidad óptima de grupos (*clusters*) y la falta de una métrica de validación, ya que no hay una variable objetivo contra la cual contrastar los resultados. El objetivo de estos algoritmos es descubrir patrones o estructuras ocultas en los datos, como la clasificación de tipos de consumidores en un sitio de comercio electrónico para campañas de marketing o modificaciones web (00:13:56).
- **Concepto de Clustering y Medidas de Distancia**: El *clustering* se refiere a las técnicas para formar grupos de observaciones llamadas *clusters*. El objetivo es que las observaciones dentro de un mismo *cluster* sean muy similares entre sí y muy distintas de las de otros *clusters* (00:16:17). Esto requiere la definición de medidas de distancia, como la euclidiana y la de Manhattan, para cuantificar el parecido o la diferencia entre puntos (00:17:42). También se mencionó la distancia coseno, importante para el procesamiento de lenguaje y las redes neuronales (00:20:03).
- **Linkage: Cálculo de Distancias entre Clusters**: Para el *clustering*, se necesitan métodos para calcular las distancias entre distintos *clusters*, lo que se denomina *linkage* (00:20:03). Una de las formas es definir el centroide o centro de masa para cada *cluster* y calcular la distancia entre ellos. Otras métricas incluyen el *single linkage* (distancia mínima), el

complete linkage (distancia máxima) y el *average linkage* (distancia promedio), además del método Ward (00:21:24).

- **Algoritmo K-Means: Concepto e Inicialización**: K-Means es el primer algoritmo de aprendizaje no supervisado discutido, donde K es la cantidad de *clusters* que deben definirse de antemano como un hiperparámetro (00:23:53). El algoritmo busca minimizar una métrica llamada W sub C, que representa la variación dentro de un *cluster*, con el objetivo de hacer que los grupos sean lo más compactos posible (00:25:01) (00:29:40). La inicialización se puede hacer asignando puntos aleatoriamente a los *clusters* o colocando los centroides de forma aleatoria y asignando luego los puntos al centroide más cercano (00:32:32).
- **Proceso Iterativo de K-Means y Métrica de Inercia**: K-Means es un proceso iterativo que recalcula los centroides y reasigna las observaciones al centroide más cercano, basándose en una métrica de distancia predefinida (00:35:42) (00:37:32). Este proceso se detiene cuando ya no hay más movimientos o se alcanza un límite de iteraciones (00:36:35). La métrica de calidad del K-Means se llama inercia, y el algoritmo está diseñado para minimizarla en cada iteración, garantizando que los *clusters* sean más compactos (00:29:40) (00:38:38).
- **Problema de la Inicialización Aleatoria y Soluciones**: Debido a la selección aleatoria de los centroides iniciales, la ejecución repetida de K-Means con el mismo conjunto de datos puede producir resultados diferentes. La solución es ejecutar el algoritmo varias veces, calcular la inercia final de cada ejecución y seleccionar la solución con la inercia más baja (00:34:41) (00:39:48).
- **Métodos para Elegir el Número Óptimo de Clusters (K)**: Dado que K-Means requiere definir la cantidad de *clusters* antes de entrenar, y el número óptimo generalmente es desconocido, existen métodos para determinarlo, incluyendo el método del codo (*elbow method*) y el índice de la silueta (00:41:01).
- **Método del Codo (Elbow Method)**: El método del codo es una aproximación visual (*ojímetro*) que implica ejecutar K-Means para diferentes valores de K (por ejemplo, de 2 a 10), calcular la inercia para cada ejecución y graficar los resultados (00:42:13). El valor de K óptimo se encuentra en el punto donde la inercia comienza a disminuir marginalmente, formando un "codo" en el gráfico, indicando que aumentar K ya no produce una mejora significativa (00:43:14).
- **Índice de la Silueta (Silhouette Index)**: El índice de la silueta es una métrica precisa que combina la cohesión (cuán cerca está un punto de su *cluster*) y

la separación (cuán lejos está un punto de otros *clusters*) (00:45:35). El índice idealmente debe ser cercano a 1 (alta cohesión y separación), un valor cercano a 0 indica superposición de *clusters*, y un valor negativo sugiere que la observación está mal asignada (00:46:46).

- **Interpretación Visual y Cálculo del Promedio de la Silueta**: En la práctica, la silueta se calcula típicamente comparando cada punto contra el centroide de su propio *cluster* y los centroides de los otros *clusters*, reduciendo el costo computacional (00:47:57). Aunque el índice individual ofrece información detallada, generalmente se utiliza el promedio del índice de la silueta para evaluar la calidad general de la agrupación (00:56:17). Se realiza un proceso similar al del codo: se entrena K-Means para diferentes K, se calcula el índice de la silueta promedio para cada uno, y se elige el K que maximiza este promedio (00:57:20).
- **Fuerza de Predicción (Prediction Strength)**: La fuerza de predicción es un índice inspirado en los clasificadores supervisados, enfocado en el error de predicción en lugar de la inercia o la cohesión. Para calcularlo, se dividen los datos en conjuntos de entrenamiento (*train*) y prueba (*test*), y se entrena K-Means en ambos conjuntos con el mismo valor de K (00:58:51).
- **Mecanismo de la Fuerza de Predicción**: El índice evalúa cuántas conexiones entre observaciones se mantienen entre los conjuntos de *train* y *test* (01:02:41). Si el número de *clusters* es apropiado, los centroides de *train* y *test* serán similares, y la fuerza de predicción será alta. Si el número de *clusters* no es adecuado, los centroides se dispersarán, dando como resultado una baja fuerza de predicción (01:04:16).
- **Métodos de validación cruzada para grandes conjuntos de datos**: La validación cruzada es una alternativa a la división simple en conjuntos de entrenamiento y prueba cuando se dispone de un conjunto de datos considerable. La técnica consiste en crear carpetas de datos de manera iterativa, dejando una fuera para la prueba y utilizando las demás para el entrenamiento, realizando luego las pruebas cruzadas (01:05:33).
- **Introducción al clúster K-Means con datos de clientes**: El método de *clustering* K-Means se introduce utilizando un conjunto de datos de clientes que incluye género, edad, ingresos y una puntuación (01:05:33). Este conjunto de datos, que se utiliza como ejemplo, contiene 200 observaciones (01:06:44).
- **Preprocesamiento y configuración del modelo K-Means**: Antes de aplicar K-Means, se deben escalar los datos, lo cual es crucial debido al uso de medidas de distancia. Para la configuración, es necesario importar K-Means de scikit-learn y especificar de antemano la cantidad deseada de *clusters*.

La inicialización por defecto utiliza K-Means++, un método que ayuda a que el algoritmo converja rápidamente al preanalizar la muestra de datos (01:06:44).

- **Entrenamiento y evaluación iterativa de *clusters***: Para encontrar el número óptimo de *clusters*, se entrena el modelo de K-Means en un bucle que va desde 1 a 20 *clusters*. El algoritmo se ejecuta 10 veces para cada número de *clusters* y retiene el mejor resultado, guardando los valores de inercia para crear gráficos de codo (01:08:07).
- **Determinación del número óptimo de *clusters* mediante el método del codo y la silueta**: Después de entrenar, se grafica el codo, donde el cambio de pendiente más notorio sugiere un número de *clusters* óptimo, que en el ejemplo se identifica alrededor de cinco. El índice de silueta también se calcula, dándole un valor promedio de 0.555 para el entrenamiento con cinco *clusters* (01:09:15). El máximo valor del índice de silueta se observa con cinco *clusters* (01:10:38).
- **Aplicación de la fuerza de predicción para la optimización de *clusters***: La fuerza de predicción, que es un método implementado manualmente con validación cruzada, también se utiliza para evaluar la cantidad óptima de *clusters* (01:10:38). La fuerza de predicción sugiere que tanto cinco como tres son buenas cantidades de *clusters* para K-Means con esta métrica. Los métodos del codo, silueta y fuerza de predicción son herramientas generales para determinar la cantidad óptima de *clusters* en varios algoritmos (01:11:57).
- **Interpretación de los resultados de la clústerización K-Means**: Una vez finalizada la clústerización (por ejemplo, con cinco grupos), el algoritmo asigna un número de *cluster* a cada observación. La tarea del analista es interpretar lo que representa cada *cluster*, ya que el algoritmo solo agrupa datos similares, pero no etiqueta los grupos (por ejemplo, "clientes gastadores" o "conservadores") (01:13:10). Estas etiquetas deben agregarse manualmente después de un análisis exploratorio (01:14:34).
- **Revisión de conceptos clave del aprendizaje no supervisado**: Se revisaron conceptos de aprendizaje no supervisado, el cual opera sin una variable objetivo (*target*). K-Means se enfoca en clústerizar observaciones, y sus principales hiperparámetros son el número de *clusters* y la métrica de distancia utilizada, como la euclidiana (01:17:08). Los métodos principales para determinar el número óptimo de *clusters* son el método del codo, el índice de silueta y la fuerza de predicción (01:29:13).
- **Limitaciones del algoritmo K-Means y necesidad de modelos más complejos**: K-Means tiene una naturaleza no probabilística, asignando observaciones a *clusters* sin expresar el grado de certeza (01:30:20). Además, K-Means

busca formas circulares o esféricas en los datos, lo que le impide encontrar *clusters* que tengan formas más complejas o alargadas (01:31:37).

- **Introducción al modelo de mixtura gausiana como solución a las limitaciones de K-Means**: El modelo de mixtura gausiana resuelve los problemas de K-Means al poder encontrar *clusters* con diversas formas. Este modelo encuentra distribuciones normales (gausianas) y describe la media y la varianza de los datos en cada *cluster* (01:32:46). A diferencia de K-Means, este modelo proporciona una probabilidad de pertenencia a un *cluster*, lo que permite identificar observaciones dudosas o que se encuentran en el borde (01:33:59).
- **Funcionamiento del modelo de mixtura gausiana (MGM) y el algoritmo EM**: El MGM es una combinación de funciones de distribución normal multivariada, donde cada una tiene un peso (fi), una media (μ) y una covarianza (Σ) (01:35:14). El algoritmo de Expectation-Maximization (EM) es un proceso iterativo de optimización basado en el criterio de máxima verosimilitud que se utiliza para entrenar y encontrar estos parámetros desconocidos (01:36:36) (01:40:10).
- **Proceso iterativo del algoritmo EM para estimar parámetros**: En cada iteración, el algoritmo EM estima las probabilidades de que cada observación pertenezca a una distribución gausiana con parámetros inicializados (a menudo de forma aleatoria) (01:40:10) (01:43:36). Luego, utiliza estas probabilidades ponderadas para recalcular y actualizar los valores de la media (μ), la varianza (Σ), y el peso (fi) de cada campana (01:47:07). Este proceso se repite hasta que los parámetros se estabilizan (01:52:29).
- **Clústerización final y asignación de probabilidad en MGM**: Una vez que el algoritmo ha encontrado las distribuciones gausianas y sus parámetros (media, varianza y peso), estos se utilizan para calcular la probabilidad de que una observación pertenezca a un *cluster* específico (01:54:59). Se puede optar por la asignación fuerte (el *cluster* con mayor probabilidad) o la asignación débil (manteniendo las probabilidades de pertenencia) (01:56:19).
- **Opciones de forma y complejidad en el modelo de mixtura gausiana**: Cuando se tienen múltiples variables, el modelo trabaja con un vector de medias y una matriz de covarianza, lo que permite que los *clusters* tengan diferentes formas, como elipses, en lugar de solo círculos (01:57:47). El usuario puede especificar el grado de complejidad de la forma del *cluster* que el modelo debe buscar, lo que puede influir en el costo computacional (01:59:18).
- ****Evaluación del número óptimo de *clusters* para el modelo de mixtura gausiana****: A diferencia de K-Means, el método de distancias no es

adecuado para MGM debido a la naturaleza no esférica de los *clusters* (02:01:38). En cambio, se utilizan criterios estadísticos como el Criterio de Información de Akaike (AIC) o el Criterio de Información Bayesiano (BIC) para seleccionar el número óptimo de *clusters*. En un ejemplo, los índices AIC y BIC sugieren que el número óptimo de *clusters* se encuentra entre 6 y 12 (02:02:52).

- **Discusión sobre la Unificación Manual de Datos**: Ise posgrados indicó a Gabriel Quiroga que, en un ejemplo específico, sería necesario revisar y unificar manualmente los datos si la intención es agruparlos en dos categorías, ya que las herramientas no lo harían automáticamente (02:05:18).
- **Implementación de la Mixtura Gauciana con Scikit-learn**: Ise posgrados explicó el uso de la Mixtura Gauciana de scikit-learn, especificando cinco componentes (distribuciones gaucianas) y un tipo de covarianza 'full' para lograr el mejor resultado posible (02:05:18). El proceso incluye el *fit* para encontrar los parámetros y el *predict* para asignar probabilidades y clústeres, lo cual se aplicó a un ejemplo de clientes, resultando en agrupaciones similares a las encontradas con K-Means (02:06:27).
- **Aclaración sobre el Parámetro de Covarianza**: Alejandro Valle preguntó si el cálculo de la covarianza era por cada clúster o por todos los *features* (características). Ise posgrados confirmó que el parámetro de covarianza se aplica a todo el entrenamiento y que la opción 'full' es la más adaptable, ya que permite al algoritmo encontrar clústeres de diferentes formas y orientaciones, a diferencia de un parámetro que buscaría formas más redondas similares a K-Means (02:08:10).
- **Introducción al Clustering Jerárquico**: Ise posgrados presentó el clúster jerárquico como una solución a la potencial desventaja de tener que predefinir el número de clústeres en los métodos anteriores (K-Means, Mixtura Gauciana) (02:09:23). Este método no requiere un número inicial de clústeres y se basa en la construcción de una estructura de árbol, similar a un dendrograma (02:21:33).
- **Funcionamiento y Representación del Clustering Jerárquico**: El algoritmo construye un árbol agrupando iterativamente las observaciones más similares hasta unirlas todas en una raíz (02:22:45). El dendrograma es la representación gráfica de esta estructura, donde la longitud de las ramas indica la similitud o diferencia entre las agrupaciones (02:23:58).
- **Determinación del Número de Clústeres mediante el Dendrograma**: Se explicó que una vez que el algoritmo construye el árbol, la decisión sobre el número de clústeres se toma trazando una línea horizontal de corte sobre el

dendrograma. La altura de esta línea determinará la cantidad de clústeres formados, donde cada rama cortada representa un clúster (02:25:16).

- **Mecánica del Algoritmo Jerárquico**: El algoritmo comienza con cada observación como un clúster separado (hojas) y luego itera calculando la distancia entre todos los pares de clústeres usando un método de *linkage* (como centroides, mínima, máxima, promedio o Ward). Los clústeres más cercanos se fusionan en uno nuevo, y el proceso se repite hasta que todos están unidos en una raíz (02:27:55).
- **Explicación del Método de Linkage Ward**: Se detalló que el método Ward calcula la distancia midiendo cuánto aumenta la varianza de un clúster si se fusionan dos sub-clústeres (02:29:07). El algoritmo selecciona para la fusión aquellos clústeres cuya unión modifique menos esa varianza (02:30:11).
- **Implementación del Clustering Jerárquico con SciPy**: lse posgrados mostró cómo usar el paquete SciPy para el clustering jerárquico, utilizando la función `linkage` con el método Ward para calcular la jerarquía, y luego la función `dendrogram` para dibujarla (02:31:35). Posteriormente, se usa `fcluster` para solicitar un número específico de clústeres (por ejemplo, tres) basándose en la estructura calculada (02:32:47).
- **Implementación con Scikit-learn (Agglomerative Clustering)**: El método *Agglomerative Clustering* de scikit-learn utiliza por defecto la distancia euclidiana y el método Ward, pero requiere que se le indique el número de clústeres deseado de antemano (por ejemplo, `n_clusters=3`). El algoritmo construye el árbol hasta alcanzar el número de clústeres solicitado y luego se detiene (02:33:56).
- **Comparación de Resultados en Datos de Clientes**: Tras aplicar los tres métodos (K-Means, Mixtura Gauciana y Clustering Jerárquico) a los datos de los clientes, lse posgrados señaló que las agrupaciones resultantes eran visualmente muy similares, con solo diferencias mínimas debido a que los datos eran sintéticos y limpios (02:35:15).
- **Ejemplos Avanzados de Clustering en Scikit-learn**: lse posgrados mostró la documentación de scikit-learn, destacando que existen muchos métodos de clustering no vistos, incluyendo aquellos que resuelven formas complejas, como el ejemplo de las "medialunas" que K-Means y Mixtura Gauciana no resuelven bien (02:37:55).
- **Aplicación de Clustering a Imágenes Satelitales (Bonus)**: Se presentó un ejemplo de aplicación de clustering a una imagen satelital para clasificar tipos de suelo, como la nieve, el valle o lagunas (02:39:11). La dificultad de clasificar los 10,000 píxeles de una imagen 100x100 con métodos

individuales se señaló, lo que llevó a la propuesta de combinar métodos (02:40:24).

- **Combinación de K-Means y Clustering Jerárquico en Imágenes**: Una técnica presentada implica tomar una muestra de 1,000 píxeles y clasificarlos inicialmente con K-Means en 20 clases (02:41:27). Luego, se aplica el clustering jerárquico a esas 20 clases para construir un dendrograma, permitiendo al usuario decidir cuántos clústeres finales (por ejemplo, 2, 3 o 5) son más útiles al cortar la línea horizontal (02:42:29).
- **Consulta sobre Fechas de Entrega del Trabajo**: Alejandro Valle preguntó sobre las fechas de presentación, y lse posgrados aclaró que no hay presentaciones, sino una entrega de trabajo que se estima para finales de abril, posiblemente el 29, pero esa fecha se confirmará la próxima semana (02:44:46). lse posgrados recordó que la entrega debe estar justificada, incluir un modelo base para comparación y tener conclusiones .

Revisa las notas de Gemini para asegurarte de que sean precisas. Obtén sugerencias y descubre cómo Gemini toma notas

*Cómo es la calidad de **estas notas específicas?** Responde una breve encuesta para darnos tu opinión; por ejemplo, cuán útiles te resultaron las notas.*

📖 Transcripción

9 abr 2026

Aprendizaje de Máquina (6/8) - a242b25 - Transcripción

00:00:00

Ise posgrados: Hola, ¿cómo están?
Gabriel Quiroga: ¿Qué tal?
Lucia T. Capon Paul: Buenas,
Ise posgrados: Buenas. Bueno, qué poquitos que son. Igual vamos a empezar. Cambio de planes. Eh, iban a haber calibración con Facundo, pero bueno, hubo un cambio. Vamos a ver. de eh aprendizaje no supervisado hoy y calibración la semana que viene. Así que bueno, vamos a arrancar. Es bastante el contenido de hoy, así que bueno, espero no que no se que no se haga muy largo, pero bueno, ya les aviso que que son bastantes cosas eh porque estamos juntando un tema que es eh todos los los modelos no supervisados, todos en una sola clase, así que bueno, mucho no se puede abreviar. Vamos a arrancar. A ver, voy a compartir. Bueno, si se bajaron, si tienen las presentaciones, esta sería la de la clase, la clase siete, no la clase seis. Eh, pero bueno, el contenido eh es el mismo. Primero, como siempre, hacemos un pequeño repaso de lo que vimos la clase pasada. Si se acuerdan, vimos métodos de ensamble y dentro de los métodos de ensamble vimos como distintas variantes, vimos modelos que votan, vimos baging, eh random forest y boosting.

00:07:13

Ise posgrados: Los vamos a repasar muy rápidamente. Los métodos de ensamble son eh métodos que consisten en modelos, es decir, eh los modelos combinados se llaman ensambles. Entonces, los métodos de ensamble son los métodos que combinan estos modelos para obtener una una predicción más precisa que si yo ejecutara o entrenara solamente uno de esos modelos. Y la idea es usarlos cuando ya probamos arquitecturas simples, ajustamos los datos, ajustamos los parámetros, todo y no nos convence los resultados, no nos terminan de dar bien. Entonces, probamos varias arquitecturas simples, las combinamos y esperamos que eso dé un poquito mejor. Esa es la idea de usar un ensamble y habíamos visto, bueno, ¿qué hacemos cuando tenemos muchos modelos? Porque yo tengo, no sé, cinco modelos y todos me dan una salida diferente, ¿con cuál salida me quedo? Cuando estamos

hablando de clasificación, teníamos el hard voting classifier, que que eh sería cuando entrenamos varios modelos, miro todos los resultados y me quedo con el más votado. Si tengo una clasificación binaria y tres modelos votan uno y dos modelos votan cero, me quedo con el uno. Después estaba el soft, que es eh el caso cuando los eh modelos tienen salidas probabilísticas.

00:08:33

lse posgrados: Entonces ahí pondero esas esas esas probabilidades que tengo como salida. No solo me fijo en la salida de los modelos, sino en la probabilidad o la confianza que me dan esos modelos respecto de esas salidas. Así que es un poco como más justo también. Y en el caso de regresión, lo que hago es simplemente promediar las salidas de de todos los modelos. Cada modelo me va a devolver un numerito y yo agarro todos esos numeritos y los promedio o puedo tomar la media eh, perdón, la mediana si quisiera. Bueno, la la cosa es esa cuando es eh regresión. Una alternativa que habíamos visto es eh baging, que es el caso donde todos los modelos pueden ser iguales o distintos, pero aunque sean iguales, lo que me cambia principalmente son los datos. Yo para los datos eh lo que hago es una muestra de mis datos originales, de todo mi dataset. Yo hago una muestra aleatoria con eh muestreo con reemplazo, que este método se llama bootstrapping. Habíamos visto un ejemplo eh de en qué consiste este muestreo. Habíamos visto en una notebook que básicamente era hacer una muestra con reemplazo para calcular un estadístico. Por ejemplo, puedo calcular la media haciendo estas muestras. En el caso de ensamble, lo que hago es una muestra de los datos.

00:09:50

lse posgrados: así, una muestra diferente para cada modelo para que cada uno de estos modelos, justamente como se entrenó con un dataset distinto me de un resultado diferente. Entonces, de esa forma estoy logrando esa variedad de modelos, porque de nada sirve hacer un ensamble de modelos que sean todos iguales o parecidos. La gracia es que busquemos modelos que sean lo más eh distintos posibles o variados, ya sea que el modelo es distinto, como en este caso tipo de modelo es distinto o si el modelo es igual, que los datos sean diferentes. Luego vimos Random Forest o bosques aleatorios, pero se los conoce más como Random Forest, que son una mejora al bagin que lo que incorporan además de esa aleatoriedad o esas muestras eh diferentes en los datos. también hace una selección de las features, no es que entrena siempre con todas ni con todas las

mismas, sino que selecciona los atributos. Cada uno de los bosques selecciona un conjunto diferente de atributos. Ahí la variedad eh la puedo ver en el sentido que si yo tengo, por ejemplo, un atributo que es muy buen predictor de mi variable target, ese atributo no necesariamente va a estar en todos los bosques. Algunos me lo van a elegir y algunos ni siquiera lo van a usar. De esa manera me aseguro que los bosques van a ser distintos, los árboles van a ser distintos, entonces las salidas van a ser variadas y después, bueno, las voy a poder combinar y y sacar de ahí un resultado.

00:11:17

Ise posgrados: Y por último vimos posting, que a diferencia de todo lo anterior también son varios modelos que yo combino, pero en vez de hacer correrlos en paralelo, los corro en forma secuencial. Y dentro de Boosting habíamos visto como dos categorías. El boosting adaptativo, el modelo, habíamos visto el ensamble boost, que lo que hace es entré en un modelo, me fijo cuáles son las muestras o las observaciones que se clasificaron mal en el caso de una clasificación. A esas les pongo como un peso eh más importante para que el modelo siguiente le preste más atención a esas, o sea, se enfoque en que esas queden bien clasificadas. ese modelo hace lo mismo y se lo pasa al siguiente, al siguiente al siguiente. Entonces, así como voy mejorando mis resultados. Ese es el adaptativo. Y el gradient boosting se fija en los errores. Cada modelo trata de corregir los errores del modelo anterior. Son como dos enfoques diferentes, pero en cualquiera de los casos son modelos que corren secuencialmente uno después del otro. y implementaciones del gradient boosting. Habíamos visto un ejemplo con Ex Boost, que es una biblioteca eh que externa, digamos, a las que conocemos, a las que estamos acostumbrados a usar acá.

00:12:33

Ise posgrados: es otra biblioteca que es el por ahí el más utilizado de estas de este tipo de de ensambles, pero hay otras muy usadas que son la HIVM y Catbost que hacen lo mismo también, ¿no? El ensamble eh basado en el eh gradient boosting. No sé si los han podido probar, pero está bueno que que las prueben, no digo las tres, pero que miren un poco, no sé, la documentación para ver si alguna de las tres las convence y la quieren usar. Y entonces e bueno, si se lo instalan, lo prueban, pueden entrenar modelos con eso. A ver qué a ver qué les parece. Nosotros hicimos ejemplos solamente con con Exibost. Y eso sería todo el repaso de la clase pasada.

¿Alguna pregunta? Bueno, vamos a ver entonces aprendizaje no supervisado. Todas las clases anteriores, absolutamente todas, vimos aprendizaje supervisado, distintos cada clase fuimos viendo distintos modelos y hoy vamos a ver los no supervisados. ¿En qué consisten? Tenemos un dataset, tenemos n observaciones, p atributos, pero en este caso no tenemos target, no tenemos esa clase para predecir y queremos queremos eh hacer grupos de observaciones. Entonces, ¿cuál es el desafío acá?

00:13:56

Ise posgrados: Primero que no tenemos un objetivo simple. No sabemos ni siquiera cuántos grupos queremos. No sabemos si queremos dos, tres, cinco, no, no lo sabemos. O sea, a lo mejor nos imaginamos o ponemos una cláusula, bueno, quiero dos, pero en principio no sabemos si dos es un buen número. Ese es el primer objetivo eh desafío que tenemos. Y el segundo desafío es que una vez que entrenemos estos modelos y obtengamos, por ejemplo, tres grupos, no tenemos forma de validar si eso está bien, porque no hay contra qué validar, pues yo no tenía una una target, no tengo una target, entonces yo separo en tres y y yo qué sé si eso está No está mal. No, no tengo forma de saber. Eh, no, no puedo aplicar nada. Validación, validación cruzada, nada de eso es válido. Acá yo separo en tres grupos y listo. Entonces, eso es como el desafío de los mecanismos de aprendizaje no supervisado. Bien. Y entonces, ¿por qué haríamos esto? El objetivo principal de estos algoritmos es descubrir eh un como patrones escondidos que no están visibles en los datos o una estructura que esté por debajo que no la estoy viendo.

00:15:02

Ise posgrados: Me puedo imaginar más o menos por dónde va, cómo las agruparía en forma manual, pero no es tan evidente. Entonces, con estos algoritmos yo puedo hacer esa clasificación. A modo de ejemplo, imagínense que ustedes tienen un sitio de de e-commerce donde ustedes capturan eh información de cómo se comportan los los que visitan la página web, los que visitan y se van o los que visitan dejan cosas del carrito de compras y se van, los que compran, los que entran todos los días a mirar y no hacen nada, los que los que compran todos los días algo distinto. O sea, ustedes pueden ir capturando toda esa información y después quieren hacer clasificar tipos de consumidores. Eso a mano como no es tan fácil, porque no es que uno uno podría decir, bueno, el que compró y el que no compró. Esa es una clasificación muy muy fácil, pero si uno quiere combinar un poco todo ese comportamiento, hacerlo en forma manual, no es tan obvio. Entonces, con un

algoritmo de estos podría eh agrupar estos comportamientos, estos clientes en dos grupos, en tres, en cuatro. Y la idea es que después, ¿para qué lo hago eso? Bueno, no sé, para hacer campañas de marketing, por ejemplo, o eh email marketing o para mandar promociones o para para modificar la web de alguna manera.

00:16:17

Ise posgrados: Eh, bueno, para hacer ese tipo de cosas, yo primero tengo que identificar ese tipo de clientes y a cada tipo de clientes le voy a eh aplicar capaz un un una acción diferente. Eso es un caso de uso de una algoritmo de no supervisado. Vamos a ver el concepto de clustering. Clúer se refiere a agrupaciones, o sea, un clúster es un grupo o una agrupación de observaciones y el clering se refiere a todas las técnicas para armar estos grupos. La idea principal cuando hacemos clering, en este caso, como siempre, bueno, esto se aplica para muchas dimensiones, pero siempre es más fácil verlo visualmente así cuando tengo dos dimensiones. Por eso la mayoría de los ejemplos están así. Yo tengo acá dos dimensiones y estas son todas mis observaciones. Y acá está dividido en tres grupos que están pintados de color. En la vida real uno no anda pintándolos de color, pero están pintados para que sea fácil distinguirlos. Tengo tres grupos identificados. La idea del clustering, este K = 3, normalmente le decimos K, llamamos K al número de grupos. eh estos tres grupos o en general el número de grupos que tengamos, la idea, lo que estamos buscando es que yo si tomo cualquiera de estas observaciones, cualquiera de estos puntos, lo que quiero es que se parezca mucho a los que están en el mismo clúster y sea muy distinto a los que están en otros clústers.

00:17:42

Ise posgrados: Ese es el objetivo que buscamos, que todos estos se parezcan entre sí, pero que sean suficientemente distintos de los demás. Hay muchos algoritmos de clustering. Nosotros hoy en la clase de hoy vamos a ver camins, eh clustering jerárquico y modelos de mixtura gauciana. Ahora, antes de ver los modelos, vamos a ver el tema de eh a qué le llamamos que se parezcan entre sí o que sean distintos. Lo que acabo de decir, eso eh yo lo dije con palabras, pero al algoritmo, ¿cómo le decimos que algo se parece o no se parece? O sea, es imprescindible poder decírselo. Y acá viene el tema de las medidas de distancia. Y a ver si se acuerdan cuándo vimos medidas de distancia y qué medidas de distancia había. Espero que se acuerden porque no fue hace tanto. Yo tengo acá el mismo ejemplito, ¿no? Dos observaciones, este puntito y este puntito y yo necesito saber la distancia de acá

hasta acá. ¿De qué manera lo puedo hacer? Mientras usted me hablan,
Cesar Orellana: con la
Ise posgrados: me conecto a permiso, me conecto a la clase en el celular. Sí, díganme,

00:18:52

Cesar Orellana: con la distancia euclidea o podemos también la Hay varios
Ise posgrados: por ejemplo. Exactamente. La distancia clidiana es una forma de de saber la distancia entre dos puntos. Me me conecto acá con el con el teléfono, así los puedo ver. Eh, esa es una manera de saber las distancias. Ay. Ay, ahí está. Bueno, eh acá está a modo repaso, lo habíamos visto en KNN, distancia de Manhattan, que es la distancia como si yo caminara por cuadras de por cuadras o por un tablero que voy caminando en forma recta hacia abajo, hacia el costado, ¿no? euclidiana, que es la línea recta, la distancia en dos dimensiones, una línea recta. E chefev es la distancia en uno de los dos sentidos, o sea, si miro la distancia en dos dimensiones, hacia arriba hacia al costado, me quedo con la máxima. Y Vinkovski es la la esta genérica que yo le pongo un valor a P y bueno, acá obtengo una métrica diferente. En el caso particular de P = 2 es la distancia euclidiana. P = 1 es Manhattan y P = infinito es eh Chevicher.

00:20:03

Ise posgrados: Estas no son las únicas. Habíamos visto la distancia coseno. La distancia coseno me mide eh la distancia entre vectores, que no se refiere a la magnitud de los vectores, sino a la separación de la dirección de los vectores. Si los dos vectores apuntan hacia el mismo lugar, la distancia es cero y a medida que se van separando, apuntando hacia hacia eh lugares distintos, eh la distancia se va agrandando. Esta distancia por ahí no la usamos mucho en este tipo de datos con los que trabajamos acá, pero no la pierdan de vista, no la desestimen porque se usa muchísimo después en eh algoritmos avanzados, en redes neuronales, en en procesamiento de lenguaje, se usa mucho la distancia coseno. Así que quizás acá en este momento no les resulte muy útil o interesante, pero la van a usar bastante después. Y también habíamos visto medidas de distancia eh para datos binarios o para datos categóricos. Todo esto como un repaso rápido lo que vimos cuando vimos KNN. Por otro lado, para lo que es clustering, vamos a necesitar métodos para calcular distancias entre distintos clusters, lo que llamamos linkage. Linkage es un método para definir cuán lejos o cuán cerca está un cláuster de otro.

00:21:24

Ise posgrados: El linkage me va a decir cómo calculo esta distancia, la distancia del clúster rosado al clúster verde. ¿Qué se les ocurre? ¿Cómo lo harían ustedes? Yo quiero saber la distancia de acá. Acá.
Gabriel Quiroga: definiendo un centroide para cada cláuster.
Ise posgrados: Definiendo un centroide es una buena forma de eh medir las distancias entre cláss. Así es. Es una de las formas posibles sería esto. Si yo tengo dos clusters, yo calculo el centroide o el centro de masa. En este caso estaría por acá, calculo el centroide acá y la distancia entre los entroides sería mi distancia entre clusters. Después hay otras métricas y esto se lo paso uno por como parámetro a los algoritmos. Eh, después en Python tengo el single linkage, que es cuando eh mido todas las distancias de todos los rojos a todos los verdes y me quedo con la más chica en dos dimensiones. Acá es fácil verla que es esta y esta, la, o sea, esta es la distancia más corta entre puntos de un cláster y del otro. Después el complete es la distancia más larga, o sea, como los dos puntos más alejados, mido la distancia, con esa me quedo.

00:22:34

Ise posgrados: Esa es la distancia que considero entre dos claster. Después tengo la promedio que lo que hago es eh mido todos contra todos y saco el promedio de esas distancias. Es bastante pesado, ¿no?, computacionalmente, pero bueno, así se calcula esta. Estas serían como las cuatro formas de calcular distancias entre clusters. Entonces acá modo repaso, el single es la distancia mínima, el complete es la distancia máxima, el average usa el promedio de todas, el centroid es la que basada en los centroides, como decía Gabriel y después está el método Word, que no se basa en distancias, es otra forma de calcular qué tan cerca o lejos están dos clusters. Lo vamos a ver en un rato cuando tengas porque acá no tiene mucho, no tiene sentido, mejor dicho, explicarlo, no hacia el contexto, pero más al final de la clase vamos a ver el método W. Y ahora vamos al primer eh algoritmo de aprendizaje no supervisado que es el camins. No sé si lo habrán sentido nombrar. A mí es el algoritmo que más me gusta porque es el primer algoritmo de la vida que yo conocí hace 25 años. Hace mucho ya existía el Camins y lo tuve que programar en C porque no existía Cycle Lan, así que por eso yo lo quiero.

00:23:53

Ise posgrados: Me encanta este algoritmo. ¿En qué consiste el K? es de eh como les decía antes, el K cuando decimos K nos hacemos hacemos referencia a la cantidad de grupos, a la cantidad de clusters. Yo con camins voy a hacer K clusters distintos y no superpuestos, ¿no? Es como yo hago una partición de mis datos, cada uno de mis datos va a pertenecer a un cluster, eh no va a quedar un dato suelto por ahí y un dato no puede pertenecer a dos clusters, pertenece a uno, pertenece a otro. Algo que tengo que hacer antes de correr este algoritmo es definir cuántos grupos quiero, cuántos clusters. Yo digo, "Bueno, quiero tres." Y a partir de ahí corro el algoritmo. O sea, no puedo eh decidirlo a medida que voy entrenando. O sea, de antemano, yo lo que tengo que decir es un hiperparámetro del método en verdad, la cantidad de clusters. Y acá ejemplo el mismo dibujito de antes. Tengo dos clusters, tengo tres clusters, tengo cuatro clusters. Calla se empieza a mezclar todo, no tiene Bueno, esto es un ejemplo retonto y refácil que uno diría, bueno, dos o tres cláusteres estaría más o menos bien, ¿no?

00:25:01

Ise posgrados: Ya cuatro es cualquier cosa. Pero a modo ejemplo, para que vean que yo puedo decir dos y le digo al algoritmo, bueno, haceme dos grupos. El algoritmo se arregla, ¿no? Hace lo que puede. Y acá nada más un poco de anotación. Esto es lo mismo que les decía recién. Si yo tengo estos serían los índices de mi eh de mi dataset, si yo guardo en C1, C2, C subk los índices de las observaciones que pertenecen al cláuster 1, dos, etcétera, si yo hago la unión de todos ellos, tengo que obtener todos los índices de todo mi dataset. Y si yo hago la intersección de dos cualesquiera distintos, esta intersección me tiene que dar vacía. Es decir, una observación no puede estar en dos clusters. es solamente para formalizar un poquito lo mismo que les dije antes. Y la idea del algoritmo, además de construir la cantidad de grupos que yo le digo, es minimizar una métrica que le llamo acá W sub C, que me representa la variación dentro de un clúster. Yo lo que quiero es minimizar la suma de todas las variaciones dentro de los clusters. Y ese WK se define así.

00:26:17

Ise posgrados: Para que se entienda más fácil, lo vamos a ver con un ejemplo. Yo tengo acá abierto un dataset que lo vamos a usar después en el en la notebook que

es de clientes. Tengo acá clientes, género, edad, ingreso y un score. Eh, vamos a mirar por momento solamente estas numéricas. Imaginémonos que ya está normalizado, no lo vamos a hacer. Pero bueno, estos son los datos que yo le voy a dar al modelo. Acuérdense que es reimportante cuando hablo de modelos que usan distancia que los datos estén normalizados. O sea, eso es super importante. Acá no está normalizado. Nada más sépanlo que esto solo porque les quiero mostrar cómo se calcula ese score, eh, perdón, ese ese numerito, ese W. Esto es así. La idea de ese de esa fórmula me dice lo siguiente. Imagínense que yo tengo un cláster de la fila 1 a la 10. No, desde ahí para arriba todos pertenecen a un clúster. ¿Cómo calculo ese W para ese clúster? Calculo la distancia del primero al segundo. La distancia, ¿cómo la calculo?

00:27:17

lse posgrados: 19 - 21^2 + 15 - 15^2 + 39 - 81^2 e y lo promedio. Lo divido por la cantidad de observaciones, quiero decir, o sea, por dos. Lo divido por dos. Y esa es la el W, no, perdón, esa es la distancia partecita de esa fórmula, o sea, este versus este. Después hago este versus el tercero, lo mismo, 19 - 20^2, 15 - 16^2 39 - 6^2, después versus este, así, uno versus todo el resto hasta el último y después el segundo con el tercero, el segundo con el cuarto, el segundo con el quinto. Todas las combinaciones de estos 10 elementos hago todas las combinaciones posibles, todas esas cuentitas. La sumo y ahora vuelvo a la presentación. ¿Dónde me quedó? Todas esas cuentitas que le acabo de decir es todo esto. La división, perdón, les dije mal, la división es después. Acá lo divido por el número de observaciones que son 10. En el ejemplo que les acabo de decir. Esto me da el W para ese clúster.

00:28:23

lse posgrados: Esta sumatoria es la sumatoria de todas las columnas. P sería la cantidad de atributos. En mi ejemplo eran tres atributos. Estas son las cuentitas y esta sumatoria que está acá me está eh identificando todas las combinaciones posibles de las 10 observaciones. En mi ejemplo de los 10 eh observaciones que tengo es el uno con el dos, el uno con el tres, el uno con el cuatro, o sea, todas las combinaciones. Imagínense la cantidad de cuentas que tengo que hacer, ¿no? Para hacer esto con todo mi dataset, o sea, son muchísimas. Entonces, lo que se hace, vamos a simplificar esta fórmula, lo que se hace es calcular el centroide. Y ahora vuelvo de vuelta al a la notebook. Calculo el centroide. ¿Cuál es el centroide? Es el promedio de la edad de acá, que vamos a supon, no sé cuánto es, no hice la cuenta,

pero vamos a suponer que es 25. 25. el promedio de acá que será 17 y el promedio de esta que acá tengo una cantidad de datos, no tengo idea. Bueno, vamos a suponer que es 50. Entonces, el centroide de este clúster es 25 1750. Y el W, ¿cómo lo calculo?

00:29:40

Ise posgrados: Cada fila contra el centroide. En vez de hacer la fila esta contra todas las demás, hago solamente esta contra el centroide. Entonces, hago 19 - 25^2 + 15 - 17^2 + 39 - 50^2 y después esta versus el centroide, después esta y son 10 operaciones nada más, 10 sumatorias, va, 10 cuentitas, vamos a decir. Entonces, reduje enormemente la la cantidad de operaciones. Eso es porque lo estoy haciendo eh previamente estoy calculando el centroide. Calculo el centroide y la fórmula me queda así. Vuelvo a una slide para atrás. lo que tenía acá con estas dos sumatorias, ahora lo simplifiqué y tengo esto. Ya no la primera sumatoria era todos contra todos y acá lo único que estoy haciendo es cada punto versus el centroide que está identificado acá como si fuese el la media. Bueno, este es el centroide. Esta es la métrica que yo voy a usar para medir la calidad del camín. Yo lo que quiero es minimizar estos números. Intuitivamente se pueden imaginar que lo que quiero es que los datos estén muy cerca entre sí, o sea, que número que esos estén chiquititos es que cada cuenta esa que yo haga eh de cada punto versus el centroide sea lo más lo más chica posible, es decir, que el punto es esté cerca del centroide.

00:31:06

Ise posgrados: Esa sumatoria que quiero minimizar se la conoce como inercia. Así que el camins, o sea, el el entrenamiento del camins, que al entrenar camin lo que estamos queriendo decir es la búsqueda de esos grupos consiste en eh armar, asignar puntos a los distintos clústers buscando minimizar esta métrica. Es un proceso iterativo que asigna puntos. Ahora vamos a dar un ejemplo. Asigna puntos a los distintos cláuster y va iterando, iterando, iterando, eh buscando minimizar eh esta métrica, es decir, buscando que los grupos sean lo más compactos posibles cada cada con cada iteración. Vamos a hasta ahí. Preguntas. Estamos bien. Eh, les voy a mostrar acá visualmente cómo funciona el algoritmo. Nuevamente es un ejemplo parecido al de recién. Tenemos en estos puntos así en 2D y yo quiero armar clusters. E bueno, de entrada yo pinté aleatoriamente en tres colores, o sea, de entrada yo quiero armar tres clusters y les voy a los voy a pintar de tres colores. De entrada yo no tengo ninguna agrupación, o sea, son todos iguales, no tengo nada. Yo

esto lo pinté así en forma totalmente random.

00:32:32

Ise posgrados: Eso es lo que hacen los algoritmos. Asignan en forma aleatoria, por ejemplo, estos dos y este de arriba los asignó al claster rojo. Estos los asignó al azul y esto de afuera sí los asignó al verde aleatoriamente. Total. Sí. sin ningún criterio. Por supuesto, yo los miro así, están redesordenados. A mí me gustaría, no sé, mi intuición me dice que estos cinco tendrían que estar juntos y después acá no sé, bueno, el algoritmo se arreglará. Acá va a tener que dividir esto en dos, pero de entrada esa es la selección que que apareció. Luego, ¿qué hace el algoritmo? Calcula el centroide de cada uno de estos. O sea, yo tengo acá estos rojos y el centroide vendría a estar más o menos por ahí. Ustedes me dicen si no están de acuerdo con algo de lo que digo, ¿eh? Si les parece que estoy haciendo algo mal. El azul, el centroide de los azules era más o menos por acá, ¿no? Ahí. Y los verdes que quedaron super desparramados. Bueno, el centroide que estará por acá más o menos, ¿no?

00:33:28

Ise posgrados: Porque los partes quedaron unos por acá, otros por allá. Así empieza el algoritmo. Seleccionó, pintó, vamos a decir, aleatoriamente, es decir, asignó aleatoriamente cada observación a un cláster distinto y calculó losides. La primera versión. Esta es mi mi inicialización del algoritmo. Esa es una forma. Otra forma de inicializar el algoritmo, tengo acá tengo los puntos totalmente en blanco, o sea, como arranco, no tengo nada. En vez de pintarlos así como random, lo que hace es pone los centroides en un lugar random, por ejemplo, acá en el aire así o arriba de un punto, no importa. Pongo, por ejemplo, el rojo ahí, el azul acá y el verde acá en cualquier lado. Esa es otra forma de inicializar. Y después que hice eso, lo que hace es asigna los las distintas observaciones a el centroide más cercano. Entonces, por ejemplo, estos tres están más cerca del rojo que bueno, este no sé, está dudoso. Estos dos están eh más cerca del rojo que de cualquier otro. Entonces, los pinta de rojo. Eso es lo que hace. Todos estos están más cerca.

00:34:41

Ise posgrados: Uy, que se me pintó. Bueno, eh todos estos están cerca del verde,

¿no? Así que todos estos los va a pintar de verde. Este también. Y fíjense que lo que yo estoy haciendo acá es el mismo set de observaciones, pero los clers iniciales son bien distintos entre sí. Nada que ver este con el otro. Y acá, bueno, estos dos son azules. Vamos a suponer que todos estos son azules. Bueno, esta es la inicialización del algoritmo. A ver. Y me falta este. Bueno, entonces lo inicialicé de dos formas distintas y este me quedó así y el otro así. O sea, vieron que nada que ver y esto puede pasar. O sea, yo ejecuto un algoritmo de cambio en dos veces seguidas y me va a dar resultado distinto. Eso es un problema. Ahora vamos a ver cómo se resuelve, pero eso pasa incluso hasta aunque haga la misma el mismo método, aunque haga este mismo método, no este de la izquierda, este mismo dos veces seguidas me va a dar distinto. Bueno, ¿cómo sigue esto? ¿Cuál les gusta más?

00:35:42

lse posgrados: ¿De la izquierda o a la derecha? Así sigo. Es lo mismo, eh,
Lucia T. Capon Paul: sería el de la izquierda.
lse posgrados: el izquierda. Bueno, vamos a la izquierda.
Gabriel Quiroga: Yeah.
lse posgrados: Vamos a seguir con esto. ¿Cómo sigue? A partir esta es la inicialización. A partir de acá es igual para cualquiera de las dos. No importa como empecé, es igual. ¿Qué hago? Recomputo los centroides. Ahora el centroide verde vendría a estar más o menos por acá, ¿no? Más o menos. El azul está bastante bien. Lo puedo poner un poquito más ahí. Y el rojo, el centroide rojo estará acá. Y una vez que recomputé los entroides, reasigno, o sea, me fijo si todos están en su lugar, o sea, vuelvo a mirar para cada uno de ellos cuál es el centroide más cercano. Y por ejemplo, acá veo este verde que quedó medio en el aire, está más cerca del azul, así que lo asigno al azul y el resto parece que estuviera bien.

00:36:35

lse posgrados: Y otra vez recalculo los entroides. Este verde me va a venir más acá, este azul va a quedar un poquito más abajo. Y nuevamente me fijo y resigno. Así la iteración, reasigno, recalculo los entroides, reasigno, recalculo los entroides. Así hasta que no tengo más movimientos. Acá a simple vista ya ya no puedo hacer más nada, ya están todos en su lugar, o sea, no tengo más nada para hacer. Pero podría pasar que esto está acá y de repente digo, "Ah, no, este es verde." Y lo pinto de verde. Recalculo y me queda cerca del azul. Ah, no, es azul y lo pinto azul y es azul y verde. Azul y verde y no termino más. Entonces, también tengo que poner un límite. Digo,

bueno, hasta 100 veces. y a la vez número 100 me quedo ahí y este quedó donde quedó. Así que esos son los dos criterios de que pare el algoritmo cuando ya no tengo más movimientos o cuando llegué a un límite que yo le puse 100 iteraciones, por ejemplo. Así funciona. Entonces volvemos a la presentación.

00:37:32

Ise posgrados: E acá está el algoritmo. Esto es lo que acabamos de hacer. Primero asigno aleatoriamente a cada observación a modo de inicialización le asigno un cláster a cada una de las observaciones y después para cada clúster computo al centroide, reasigno, en el caso que estén mal asignados, reasigno las observaciones al clúster cuyo centroide se encuentre más cercano. Y ahí yo no lo dije, pero eso de cercano ya tenía yo definida una instancia, ¿no? Ahí visualmente yo usé la euclidiana, me fui a la parte a la que estaba en distancia recta más cerca. Yo ya la distancia la tengo que tener definida. es un hiperparámetro también. De entrada yo eh no lo dije recién, pero asumí que estoy usando la distancia euclidiana. Entonces, usando esa distancia me fijo cuál es el más cerca y reasigno en caso que haga falta. Calculo el valor de la inercia. Eso no lo hicimos en la pizarra, pero es calcular eso, la qué tan compacto está el el clúster. E eso es para ir viendo cómo se va a chicando, pero la naturaleza del algoritmo hace que con cada iteración la inercia sea más chica, no es que en el camino la voy a hacer más grande.

00:38:38

Ise posgrados: por las formas de funcionar del algoritmo, sí o sí, cada vez que yo itero estoy haciendo esa inercia más chiquita porque eh porque el clúster va quedando, los clásters que estoy armando van quedando cada vez más mejor definidos y más compactos. Entonces, itero, itero, itero hasta que no cambia más o hasta que llegué al la cantidad de iteraciones que me había propuesto. Y acá hay otro ejemplo que es un poco lo mismo que vimos recién. Tengo todos estos datos mezclados, asigno en forma random, que acá fue random, de verdad, está totalmente una ensalada de puntos. Calculo el centroide. Como están todos remezclados, los centroides también están acá montonados en el medio. Sin embargo, todos estos puntos arriba están más cerca del rosa que estos dos de abajo. Así que en la primera iteración ya estoy haciendo una división bastante buena. Acá todos estos están cerca del rosa, los pinto de rosa, o sea, los reasigno, quiero decir, al clúster rosa. Todos estos los reasigno al clúster verde y estos al azul. Recomputo, recalculo los entroides y casi que ya no puedo hacer más nada. En dos

pasos armé, ya tengo los tres clers.

00:39:48

Ise posgrados: Bien, esto es lo que les decía recién, el algoritmo por la forma que está hecha ya me garantiza que con cada iteración la inercia se va achicando. Así que no, no es que la calculo, la puedo calcular para dejar un rastro y ver cómo va se va achicando, pero no es que la necesite calcular porque ya la forma en que funciona el algoritmo está eh minimizando ese esa inercia. ¿Qué más? E, y esto otro que también les comentaba antes, como los entroides se eligen de forma aleatoria, si yo ejecuto el algoritmo dos veces con el mismo dataset, es probable que llegue un resultado diferente. Entonces, muchas veces lo que se hace es se ejecuta varias veces, se calcula la inercia final de cada una de esas ejecuciones y me quedo con la mejor solución, o sea, la de menor inercia. Eso es lo que se hace. Por ejemplo, esto es el mismo ejemplo del principio. Está ejecutado en dos momentos distintos. Fíjense los colores, o sea, el cláster rosa está bastante parecido, pero acá estos dos nada que ver en esta ejecución y en esta ejecución. Este es el valor de la inercia para cada uno de ellos.

00:41:01

Ise posgrados: Esta inercia es más chiquitita. Entonces, me quedo con esta solución. Y visualmente yo me podría dar cuenta también que esta es mejor porque estos verdes están como mezclados con los azules. Están como este verde está más cerca de los azules que de los de su propio clúster. O sea, visualmente ya se nota que esta solución no es buena. Esta está los clásters como más compactos y el número de la inercia me lo me lo confirma. Y bueno, como les dije al principio de antes de ejecutar un camin, yo le tengo que decir al algoritmo, quiero tres grupos, quiero cinco, o sea, tengo que decirle, no puedo no saber, no puedo no decirle porque vieron cómo funciona. Yo ya tengo definidos, tengo que elegir tres tres entroides, así como lo armamos en el ejemplo. Yo puse tres porque yo ya sabía que quería tres. No, no hay forma de no decirle cuántos clusters quiero. Entonces, ¿por qué es un problema? Porque justamente es un dataset donde yo no tengo nada, no tengo nada, quiero agrupar y ni siquiera sé cuántos grupos me van a servir, cuántos quiero, cuántos son buenos para mi para mis datos. Entonces, por eso es un problema.

00:42:13

Ise posgrados: Pero bueno, eh para eso existen métodos que me permiten elegir el número óptimo de clusters. Todo esto siempre y cuando yo no tenga ni idea. A veces yo de entrada ya sé que quiero dos o tres, entonces todo esto no vale, pero en general no sé. Y bueno, entonces tengo que ponerme a probar, a probar y comparar. Y para eso tengo estos métodos. Tengo otros también, pero estos son los que vamos a ver hoy. El método del codo, el índice de la silueta, son como los más usados, después está la fuerza de predicción y otros que no veremos. Vamos a ver estos tres. El método del codo o elbow. Eh, bueno, ya lo dijimos, ¿no? Es para determinar el número óptimo de clusters. El método del codo es el método gímetro, o sea, miro más o menos, o sea, no hago cuentas nada. Es lo miro y digo, "Ah, más o menos son tres." Y ahora van a ver cómo funciona. Yo lo que hago es busco una métrica de calidad. Generalmente la inercia, que es la que vimos recién, podría buscar otra métrica, pero la inercia me funcionaría.

00:43:14

Ise posgrados: ¿Cómo funciona el método de codo? Elijo eh ejecuto el algoritmo, por ejemplo, para dos cluster, para tres, para cuatro, para cinco, hasta 10. ejecuto el algoritmo 10 veces para para distinto número de cluster. Cada vez que lo ejecuto, calculo la inercia y la guardo en una tablita y después hago un gráfico, cantidad de clusters versus inercia. Y ahí en el grafiquito busco a ver cuál es el que me dio mejor o cuál es, perdón, no, cuál que me dio mejor, cuál es el que mejoró muchísimo con respecto al anterior. Vamos a ver el dibujito. Yo tengo acá un ejemplo que ejecute de un a 19 clústers. Bueno, uno tiene gracia, un cluster es todo el dataset, no, no tiene sentido un cluster, pero bueno, dos clusters. Yo ejecuté camin para dos clusters, calculé la inercia y me dio 250.000. ejecuté el algoritmo para tres eh clusters, calculo la inercia y me dio 100,000, muchísimo menos que la mitad de la anterior. Calculo para, o sea, ejecuto para cuatro y así. Fíjense que las primeras iteraciones, las primeras ejecuciones del algoritmo, esto bajó dramáticamente, o sea, fue como de golpe la inercia se achicó un montón.

00:44:32

Ise posgrados: A partir de acá, y esto como les digo, es ojímetro, yo lo estoy mirando a partir de acá ya no baja tanto. Es muy poquita la diferencia entre cinco clusters y seis clusters. La inercia me da casi igual, siete, ocho baja muy poquitito, no estoy

ganando mucho. Si tenía cinco y después digo, "No, mejor voy a probar con seis, no estoy ganando mucho en inercia." Entonces, ¿qué me dice el método? Bueno, quédate con cinco. Y es exactamente esto que estamos mirando. Es la vista. Si ustedes tienen mala vista, no van a poder usar este método porque es mirar y darse cuenta más o menos. Uno podría hacer las cuentas matemáticamente de esta eh de esta recta, cuánto cambió la Sí, se puede, pero para eso usa otro método. O sea, este método es para mirarlo y decir, "Ah, sí, más o menos con cinco ando bien." Este es el método del codo. Eh, por supuesto, yo digo, "Bueno, cinco." Fíjense que acá también hay como un codito más chiquitito, o sea, yo puedo decir, "Bueno, tres, o sea, no es que es una regla exacta. Esto es para más o menos darse cuenta.

00:45:35

Ise posgrados: Yo de entrada no tenía ni idea, lo ejecuté para dos cláuster 3 cu hasta 20 y ahí me doy idea de que bueno, con tres o con cinco más o menos anda bien. Ahora vamos a ver el índice de las que este sí es con cuentitas y me da un número preciso. El índice de la silueta es así. Eh, es una métrica que me combina dos cosas, la cohesión y la separación. La cohesión es para cada una de mis observaciones, para cada puntito de mi dataset, miro cuán cerca o cuánta cohesión hay de ese punto con el resto de su cláuster, o sea, el punto individual, qué tan cerca está de todos los otros de su cláuster. Y la separación es este mismo punto, ¿qué tan lejos está de todos los puntos de los otros clusters? Eso lo hago para cada uno de los puntos. Yo tengo 100 observaciones, calculo la cohesión y la separación para las 100 observaciones. Tengo 100 cuentitas de cohesión y 100 cuentitas de operaciones de separación. Entonces, yo podría medir solo la cohesión y mirar, me quedo con los con los que tienen más cohesión. O podría mirar solo la separación y me quedo, sumo todas las separaciones y me quedo con la opción de eh donde más separación hay.

00:46:46

Ise posgrados: Podría hacerlo eso por separado, pero el índice de la silueta lo que hace es combina las dos métricas. Bueno, esto es lo mismo en adelante. La cohesión es una medida cuán cerca está un punto de los de a los de su mismo cláuster y la separación es cuán lejos está cada punto de los otros de los otros clústers. Entonces, el índice de la silueta se calcula así. Hago la diferencia. Fíjense acá vuelvo. Eh, B es la separación, A es la cohesión. Entonces, hago la diferencia de la separación menos la cohesión. dividido el máximo entre los dos. Entonces, si este

valor me da cercano a uno, significa que la observación está mu es muy eh similar a la de a su claser y muy distinta de las otras porque este número es muy cercano a cero, digamos. Si es eh si este número me da cercano a cero, me está indicando que los cláser están superpuestos. O sea, cada observación está tan lejos de los de su cluster como de los otros clusters. Y si me da -1, directamente me está indicando que la observación está mal ubicada, está en un cláúster incorrecto, porque está más cerca de los otros clúers que de su propio clúster.

00:47:57

lse posgrados: Esa sería un poco la la interpretación del índice de la silueta. Yo lo que quiero es que me dé uno o cercano a uno. Uno es medio imposible, pero quiero que este número me dé cercano a uno. Fíjense que por definición la furnita que estaba en dos slides atrás me está calculando cada punto respecto a todos los otros puntos. lo que otra vez nos presenta el problema este de las millones de cálculos. Lo que en realidad se hace es cada punto versus el centroide de su propio clúster y cada punto versus el centroide de los otros clústers. Con eso reduzco un montón la cantidad de operaciones. Y este grafiquito hermoso me muestra el índice de la silueta que parece en cuchillos. Es como si uno no se no lo conoce como es re raro el gráfico, pero en realidad es reútil y y muy interesante. Fíjense acá a la izquierda tengo dos clásers. Lo verde me representa un clúster y lo gris oscuro me representa otro. Acá este dataset después lo vamos a ver porque este es un ejemplo de la notebook. Tengo 200 observaciones o 200 y pica. Esto que parece una masa compacta verde, en realidad son líneas, lo que pasa que están amontonadas y queda como pintado todo de verde, pero en realidad son líneas horizontales.

00:49:22

lse posgrados: Cada línea, supóngase que yo agarro esta línea, imagínense que acá hay, estoy pintando una línea, ¿no? Esta línea es una observación del dataset y lo que me está indicando es que para esa observación el índice de la silueta es 045 más o menos. O sea, acá en el eje de las X tengo el índice de la silueta. Cualquier línea que yo tome acá es una observación diferente y si miro hasta dónde llega me está diciendo cuál es el índice de la silueta para esa observación. El color me está diciendo a qué clúster pertenece. Es decir, todas estas observaciones de la 100 a las 200 pertenecen al cláster verde y están ordenados por índice de la silueta de mayor a menor. Entonces, tengo algunas observaciones cuyo índice me dio 0,5 más o menos y tengo acá unas observaciones cuyo índice me dio 0,1. Si el índice estaba

cerca de cero, significaba que ese esa observación medio que se superpone con el con el otro clúster. Lo que yo quiero que que esto sea lo más grande posible. Y esto que está acá son unas 10 observaciones, serán un poquito menos, cuyo índice de la celota medio negativo. Son observaciones que fueron a parar al cláster gris, pero eh seguramente eh tendrían que haber sido asignadas al otro cláster que el índice de cicleta medio negativo.

00:50:42

Ise posgrados: No, no está bueno esto. Y acá a la izquierda, a la derecha, tenemos para los mismos datos, un camins. Se corrió un camins con cinco clusters. Acá tengo los cinco colores, me representan los cinco clusters. Fíjense que los clusters no necesariamente tienen la misma cantidad de observaciones. Por ejemplo, este azul tiene casi 100 observaciones. Este verde tiene, no sé, 20 capas de observaciones. Yo le digo cinco, pero puede distribuirse de manera muy eh desigual. Eso no es un ni es un requisito ni significa que esté mal. Es así. Fíjense que en este caso el índice de la silueta, fíjense acá los números abajo, me da mucho mayor que que en este otro ejemplo. Acá yo tengo, por ejemplo, para el azul tengo índices de casi 08. Es buenísimo. También tengo índices chiquititos. O sea, fíjense acá abajo, hay como, no sé si alcanzan a ver, hay como un cerruchito. Hay observaciones acá que también tiene el índice chiquitito, 02, 03. Pero bueno, hay muchos acá cercanos al 07, 08. Esto es muy bueno.

00:51:48

Ise posgrados: En general esto está muy alto y esto que tengo acá es mucho mejor que este otro de acá. Estos son muy chiquititos, estos índices. Estos son más potables. Lo que se hace en general, yo no miro el índice de la silueta individual de cada una de las 250 observaciones, sino que lo que hago es saco el promedio. Ahora lo vamos a ver con números, pero a ojo, yo podría decir que el promedio de índice de la silueta del clúster azul es más o menos, no sé, 06 capaz. Es bastante bueno. Hasta ahí. ¿Alguna alguna pregunta, inquietud?
Gabriel Quiroga: Yo tengo una duda de cómo quedan índices negativos si entrando el camino no debería quedar siempre del color, por así decir, el color del cler más cercano. Ah.
Ise posgrados: La silueta porque esto pasa porque, mira, voy a ir un poco para atrás, un poco bastante hasta encontrar un ejemplo de un dibujito acá, por ejemplo, este verde que está acá. Quedó verde, pero fíjate que está cerca de los azules. Está más

cerca de los azules que de los verdes. Si vos calculás el índice de la silueta para este verde, seguramente te dé negativo, porque te va a dar la cuenta, te va a dar que está más cerca del centroide azul, que es este, que el centroide verde que está por acá arriba.

00:53:09

Ise posgrados: Entonces, el índice de silueta de este punto verde te va a dar negativo, lo que está indicándote que está mal asignado, que seguramente tendría que haber sido azul.
Gabriel Quiroga: Pero eso porque faltó una iteración más, por ejemplo.
Ise posgrados: Eso porque faltó una iteración, por ejemplo, o porque el número de cluster por ahí no es óptimo. Fíjate al bueno, si voy para atrás no voy a volver más. Al principio, en el ejemplo que había puesto, uno de eh cuatro grupos también igual, bueno, voy a ir total así como voy volver al principio. Acá acá K igual a 4. Acá también tengo el mismo problema. Este violeta está mucho más cerca del centroide azul que el centroide violeta. este del borde. Entonces este probablemente el índice de la celeta me dé negativo. Pero, ¿qué pasa acá? Capaz que cuatro es un número muy grande para este dataset. O sea, este puede ser el problema también, no solo que faltaron iteraciones, sino que cuatro no es un número bueno para mi para mi dataset. Es como que estoy forzando cosas que está muy difícil acá de separar. En este dataset sería mejor tres o incluso dos.

00:54:13

Ise posgrados: Así que esa puede ser otra posibilidad de que por qué me dio negativo.
Gabriel Quiroga: Okay,
Ise posgrados: Sí.
Gabriel Quiroga: gracias.
Ise posgrados: Bueno,
Gabriel Quiroga: M.
Ise posgrados: entonces volvemos a la silueta. Estos métodos que estamos viendo, el codo de la silueta, sirven para otros algoritmos también. Lo estamos viendo acá en el camino, ejemplo, pero después sirven para otros algoritmos también. Entonces,
Tomas Mc Nally: Profe,
Ise posgrados: tenemos la silueta.
Tomas Mc Nally: yo ahí tengo otra consulta e para entender bien el cálculo.

lse posgrados: Sí, sí, sí. Sí,
Tomas Mc Nally: Si en ese caso que tenemos 200 observaciones decidimos que K sea
lse posgrados: sí,
Tomas Mc Nally: 200, entiendo que el índice de cohesión sería uno,
lse posgrados: claro. O sea,
Tomas Mc Nally: ¿no?
lse posgrados: cada 200 sería 200 cluster de uno de un elemento cada uno.
Tomas Mc Nally: Claro. Sí,
lse posgrados: Claro.
Tomas Mc Nally: pero la cohesión sería uno y la separación con los otros, ¿cuánto? ¿Qué valor tendría?
lse posgrados: La separación con los otros, eh, la separación con los otros tendría depende la separación con los otros depende qué tan separado estén los puntos entre sí.

00:55:13

lse posgrados: Cada cluster va a ser un punto, ¿no? La separación sería qué tan separados están los puntos entre sí, eh, pero eso siempre va a estar entre cero y un porque el denominador de esta de esta cuenta es el máximo entre los dos. Así que esto siempre va a estar entre cer entre perdón entre -1 y 1.
Tomas Mc Nally: Okay, pero el valor de de ese eh sería uno para ese caso que tenemos un claster por cada observación o no
lse posgrados: Sí, eh,
Tomas Mc Nally: necesariamente
lse posgrados: sí te va a dar uno porque a ver, espera, déjame pensar porque el espérate. Y si no hagan el ejercicio, la cuentita.
Tomas Mc Nally: Ok.
lse posgrados: El B es la separación.
Tomas Mc Nally: Ok.
lse posgrados: Eh, la separación poner que sea 10 y A es la cohesión. La cohesión consigo misma. Y sería eh es que me cuesta pensarlo con un cláter de uno solo. E la cohesión, la distancia a sí mismo es cero, ¿no? Entonces, si b el el denominador es 10, eh, te va a dar uno. Sí. te va a dar uno.
Tomas Mc Nally: Claro.

00:56:17

lse posgrados: A ver si ayúdeme a razonar,
Tomas Mc Nally: Bien. M.
lse posgrados: eh, pero yo creo que te va a dar uno. O sea, B puede ser 10, 100, no sé, depende qué tan lejos esté eh un cláster del otro, en este caso, en este ejemplo que me estás diciendo, una observación de otra, pero A es certo es el único y es el centroide de sí mismo, así que A es C0 y el denominador es es B porque el máximo entre 0 y B va a ser B.
Tomas Mc Nally: Claro.
lse posgrados: Entonces,
Tomas Mc Nally: Bien,
lse posgrados: esto te va a dar uno.
Tomas Mc Nally: perfecto. Gracias.
lse posgrados: Sí, bueno. Ah, como les decía, acá uno no anda haciendo después no usa como referencia el índice de la silueta individual de cada observación, sino que usa el promedio del clúster. Por ejemplo, el índice del de esta de este azul es más o menos 05 04 y el índice de toda la de toda la el entrenamiento este es el promedio de todo. El promedio de todo esto así a ojo es 05. Vamos a suponer lo que yo miro es el promedio, ¿no?

00:57:20

lse posgrados: Yo hice una clasterización, hice cinco grupos, calculé el índice de la silueta y el promedio de todo esto es más o menos, yo digo más o menos porque estoy viendo el gráfico, pero después en Python ustedes cuando hacen las cuentas tienen el número exacto, eh, no es que tienen que andar haciendo nada así más o menos, es eh bueno, está por acá, ¿no? Es nuevamente yo calculo, o sea, entreno un camin con dos claster, con tres, con cuatro, con cinco, con 20. Para cada ejecución calculo el promedio. Vuelvo para atrás. Eh, acá para esta ejecución que son dos clusters, el promedio es más o menos 03. Para esta que son cinco clusters, el promedio es más o menos 05. Entonces acá dos clusters 03 para cinco clusters 0. Bueno, 055, o sea, para la distinta cantidad de clusters, yo tengo acá el promedio del índice de la silueta, cómo fue dando. Y acá sí veo que el índice de la silueta más alto fue acá con cinco clusters. Entonces, esto me está dando un indicio que cinco es buen número. A ver, disculpen un segundo. Y fíjense que 05 era lo mismo que intuitivamente vimos con el codo, porque es el mismo ejemplo, pero acá ya no es intuitivo.

00:58:51

lse posgrados: Acá estoy, hice las cuentas y el número más alto de índice de cicleta me dio con cinco clusters. Bien, entonces vimos el codo que es de lojímetro, el índice de la silueta que es este que acabamos de ver. Y ahora vamos a ver la fuerza de predicción, que es como es un poco más raro. Eh, este índice está inspirado en los clasificadores de aprendizaje supervisado, ¿no? Que e que acá no tenemos no tenemos target, no podemos hacer nada de supervisación, pero sin embargo vamos a tomar prestada la idea de la supervisación para calcular eh este índice. Se enfoca el índice se enfoca. Acá lo dice en el error de predicción. Ya vamos a ver de qué se trata, porque no estamos haciendo ninguna predicción acá, pero se enfoca en el error en vez de enfocarse en la suma, como el caso del codo, o en la cohesión de separación como el caso de la silueta. Y acá está el la cuestión, ¿cómo me voy a fijar en un error si estoy en un modelo de cluster en donde yo no sé si está bien o mal clasificado o agrupado, lo que hago es separo los datos en train y test, entreno en este caso camins, pero bueno, esto se puede usar para otros algoritmos, pero en este ejemplo que estamos haciendo es camins, así que entreno un modelo de camins en train y entreno camins en test.

01:00:24

lse posgrados: Elijo, por ejemplo, tres clusters. Entreno un camin para K = 3 en train y entreno camins para K igual a tres en test. Justo elegí tres y me entraba la lengua. Bueno, supóng que tengo estos puntitos que son repoquitos, pero bueno, yo entreno en test, ¿no? Tres clusters y estos son mis entroides, estas crucecitas. Ahí me quedaron, me fueron a parar los entroides y entreno en train también tres clusters y los roides me quedaron acá, me quedaron en lugares distintos porque los datos son distintos. Los que fueron a parar a test no son los mismos que fueron a parar a train y por lo como vimos como funciona el algoritmo, eh, por supuesto que no me va a dar exactamente igual. Los puntos están en otro lado, así que los centroides no van a coincidir, pero están en este ejemplo en particular están bastante parecidos. Este centroide está en 01, las coordenadas 01 y este acá me quedó en -0,5 casi un Están muy parecidos, no están iguales, pero están muy parecidos. Este acá, este acá y si bien los colores cambiaron, porque acá está, ah, no están los mismos.

01:01:32

lse posgrados: Claro, cambiaron los colores, le cambió el acá el naranja queedó

arriba abajo, pero olvídense de los colores. Fíjense que la agrupación también quedó muy parecida enitest, ¿no? Esto es lo que yo quiero, o sea, está bien, para mí está bien que sea esto, pero no necesariamente va a funcionar así. ¿En qué consiste este esta fuerza de predicción? Entonces, yo hago esto, ¿no? Entreno en test, entreno en train y ahora hago una tablita. Tengo ocho observaciones, o sea, ocho, ocho valores, ocho, sí, ocho observaciones en mi dataset. Hago una grilla acá de 8* 8 y pongo acá para el clero, le lo identifico con una letra, con un número. Para el cláuster uno, yo pongo eh acá un uno en las observaciones que son parte de ese clúster. Vamos a suponer que la observación uno y dos eh 1 2 0 0 1 y 2 son parte de ese clúster. Entonces, yo pongo un uno en todos esos casilleros. O sea, esto lo único que me está diciendo es que las observaciones 0 1 y 2 pertenecen al mismo clúster en test.

01:02:41

Ise posgrados: La diagonal no la pongo porque obviamente el cero está con el cero, el uno está con el uno, o sea, la diagonal la ignoro. O sea, todos estos unos me están diciendo que estas tres observaciones fueron a parar al mismo clúster. Y ahora me fijo si en train esas tres observaciones también fueron a parar el mismo clúster. Y si veo que no, por ejemplo, el dos, la observación dos en train fue para un cluster diferente, acá le pongo un cero. O sea, que el cluster e esa observación en tren y en test eh no no iría, o sea, si uso los centroides de tren y los centroides de test, esa observación cambia de lugar, no va a parar al mismo lado. Yo con eso hago este índice que me calcula cuántas conexiones se mantuvieron y cuántas conexiones se perdieron, o sea, cuántos unos y cuántos ceros versus cuántos ceros hay en esa grilla. Calculo el mínimo de todas estas cuentitas y ese valor es el que me dice eh la fuerza de predicción. Yo quiero idealmente que las conexiones se mantengan todas, es decir, vuelvo para atrás. Acá, no, acá si yo este puntito, por ejemplo, que en test quedó agrupado acá abajo, si yo lo muevo a train me quede en el mismo clúster, no se me vaya a parar a otro clúster.

01:04:16

Ise posgrados: Entonces, cuando hago esa cuentita, un poco lo que me dice, me da una indicación de que si el número de cluster que elegí es apropiado o no. Si el número de clusters era apropiado, los entroides de train y de test van a estar parecidos y la fuerza de predicción va a ser alta. Si la cantidad de clusters no es apropiada en tren y en test, probablemente los entroides vayan a parar a distintos lados y ese test me dé muy mal la fuerza de predicción. Acá nada más a modo de

ejemplo, ¿qué podría pasar? Que yo tengo dos clusters en en test, los entroides quedaron por acá y en train quedaron en cualquier otro lado que nada que ver. Y cuando haga el cálculo a fuerza de predicción me va a dar bastante mal. Un valor que en train estaba por acá lo voy a asignar a este clúster. Pero cuando yo vaya a test eh el centro está acá abajo. Entonces ese punto probablemente no lo asigne al mismo test, o sea, al mismo clúster, perdón. Eh y la fuerza de precisión me va a dar mal. Y acá en este otro ejemplo que tengo tres clusters, los centrales de train y de test bastante cerca entre sí y seguramente cuando yo calcule la fuerza de predicción me va a dar bien.

01:05:33

lse posgrados: Esa sería un poco la idea de este método. Otra cosa que se puede hacer, pero si yo tengo un dataset bastante grande, en vez de separar entre y test es hacer validación cruzada. con la misma la misma idea. Hago 10 carpetas, dejo una fuera, prueba con nueve y con y después con una eh de test y voy camb voy digamos voy haciendo avaliación cruzada, ¿no? Voy dejando iterativamente cada carpeta fuera y haciendo la las pruebas cruzadas. Eso se puede hacer también. Y lo vamos a ver en una notebook. ¿Cómo vienen hasta ahora? ¿O quieren un recreo? antes de ver el ejemplo.
Lucia T. Capon Paul: Yo voto por el ahora.
lse posgrados: Vemos eh el ejemplo ahora sí,
Lucia T. Capon Paul: Voto por el ejemplo ahora.
lse posgrados: así no se les olvida. Listo. Bueno, eh estamos acá el método de clasering. Vamos a empezar con camins. El ejemplo de los datos es el que le mostr les mostraba recién, que es este que está acá, ¿no? Los clientes, el género, edad, ingresos y un score, ¿no?

01:06:44

lse posgrados: Son 200 observaciones o 200 algo. A ver, 200. Bueno, ese es el ejemplo que vamos a a tomar para la para el camins. Tengo acá un preview. Bajo un poquito, eh escalo los datos, que acuérdense como estoy usando medidas de distancia es importante escalar los datos para que todo me dé bien. Y acá de learn voy a importar el camins. Acá tienen como siempre el link a la documentación. ¿Y cómo hago? Acuérdense que yo les dije que yo le tengo que decir algoritmo con anticipación cuántos cluster quiero. Lo que voy a hacer acá para probar eh lo mismo que les mostraba en las diapositivas, voy a probar con con clusters 2 3 4 hasta 20.

Entonces lo tengo en un for acá para cada cantidad de clusters. Acá es donde armo los clusters. Llamo a Mins, le digo cuántos clusters quiero, le digo, ¿cómo los quiero inicializar? Yo puedo inicializarlos en forma random o por defecto le puedo pasar esto. Camis más más que lo que hace es una inicialización que le ayuda a converger rápido. Esto hace como muestras y mira la probabilidad de los datos y se fija ahí más o menos dónde meter los entroides para que eh con con vistas a que esto converja rápido, como que hace un previo análisis de la muestra de los datos.

01:08:07

lse posgrados: Entonces, no es realmente random esta inicialización, pero existe la la opción random para inicializar los entides en forma random o los puntos en forma random. Este es el límite de iteraciones, hasta cuándo iterar, o sea, si esto no converge después de la iteración 30 igual paro. Y esto es cuántas veces ejecuto el algoritmo. ¿Vieron que yo les dije que si yo ejecuto varias veces me va a dar resultados distintos? Entonces esto lo que hace es ejecuta. Le estoy viendo, ¿no? Que ejecute 10 veces. va a ejecutar 10 veces y se va a quedar con la mejor. Con el fit lo que hace es entrenar, hace todo lo que le dije, vamos a decir, y me quedo con eh la cantidad de cláuster que le pedí. Fíjense que acá voy de 1 a 20. El uno, bueno, medio que no tiene sentido un cluster, pero bueno, acá va de 1 a 20. Para cada entrenamiento, me guardo acá en una listita las inercias para después poder hacer los eh los eh grafiquitos estos que les mostraba también en las diapositivas. Listo, acá entrenó, hizo todos los entrenamientos de de cláuster de 1 a 20 y acá dibuja el codo.

01:09:15

lse posgrados: O sea, no hay una función que me diga dibujar el codo. Yo estoy dibujando las inercias que que acumulé en el en el en la celda acá de acá arriba. Acá las dibujo y acá fíjense que es el en donde hace el codito más notorio y yo digo, bueno, cinco clusters estaría más o menos bien. Y vamos a ver ahora la silueta. La silueta sí tiene sus sus métodos para dibujar y para calcular y para eh para sí, para calcularlo y para hacer los gráficos de la silueta. Voy a bajar acá. Calculo el gráfico de la silueta. Le tengo que decir con qué métrica calcular, con qué distancia. Acá le estoy diciendo de culidiana y acá está el dibujito para acá. Igual a cinco. Fíjense que el gráfico este ya le tengo que decir cuál gráfico hacerme, o sea, este es el gráfico con los índices para K igual a 5 cuando lo entrené con cinco clusters. Estos son los valores y esta línea que está vertical es el promedio de todo. O sea, el índice de la

silueta para el entrenamiento de cinco clusters me dio 0555. es la media de todos, de las 200 observaciones, de los 200 índices individuales.

01:10:38

lse posgrados: Y por último acá lo que hace es, bueno, otra vez entrena todo para mostrar e esto que también lo vimos en la diapositiva, los índices de silueta para todas las para todas las posibilidades, para todos los entrenamientos, para dos cluster, para tres, para cuatro, para cinco. Este es el mismo grafiquito que veíamos en la diapositiva. Y acá vemos como el máximo es se da acá en cinco. Con cinco claster tengo el máximo valor de silueta, de índice de silueta. Y ah, pensé que que terminaba, pero esto sigue. La fuerza de predicción. Claro, la fuerza de predicción no hay un método en cycle learn, hay un método implementado acá eh en una en un punto p en una en un archivo que código de Python. Sí, acá lo pueden ver si les interesa, pero está hecho a mano. Está hecho a mano y acá en la notebook simplemente lo importo y lo uso la fuerza de predicción con validación cruzada. Y acá abajo estoy dibujando la fuerza de predicción también de 2 a 19 clusters. Y estas rayitas es porque dice valiación cruzada. Son los 10 valores, evaluación cruzada de 10 era o de cinco.

01:11:57

lse posgrados: De 10, eh, no, de cinco. Estos son los cinco valores distintos que me dio eh en cada iteración. Entonces, eh, bueno, lo dibujo así y en este caso de la fuerza de predicción me dio que la mejor combinación, perdón, la mejor cantidad de clusters es cinco, pero también me da un buen número para tres. En los casos anteriores veía que el cinco era el que más se destacaba el resto, pero acá el cinco y el tres pareciera como que los dos son buenos números de cláuster para eh para camins medidos con esta métrica.
Lucia T. Capon Paul: En el gráfico de no habíamos visto también como que había un
lse posgrados: Se veía el tres como más chiquito.
Lucia T. Capon Paul: segundo
lse posgrados: Sí, sí, también. Mira, subo, subo, subo, subo.
Lucia T. Capon Paul: ahí.
lse posgrados: Acá. Sí, sí, sí.
Lucia T. Capon Paul: Claro.
lse posgrados: Se ve.
Lucia T. Capon Paul: Bien.

Ise posgrados: Acá se ve un poquito. Sí, también. Sí. Eh, así que bueno, estos son los tres métodos que, como les digo, los estamos viendo con camins, pero estos tres métodos se aplican a otros algoritmos también, no son exclusivos de Camin, son métodos para ver eh cuál cantidad de clusters es óptima, ya sea que calcule con camins o con otras con otros métodos de aprendizaje no supervisado.

01:13:10

Ise posgrados: Y hasta ahí llegamos con la fuerza de predicción. Hm. Una cosa que esto ya no es el algoritmo, ya supóng que ya hice la clasterización, ¿no? Eh, acá la hace de vuelta solo para reforzar. Voy a hacer cinco grupos. Camins, nuevamente, esto es lo mismo que arriba, ¿no? Invoco a Camins, le digo cluster 5, le digo el método de inicialización que itere 300 veces. Esto es exactamente lo mismo acá arriba, pero acá en vez de ponerlo en un for, lo estoy haciendo explícitamente para cinco clusters. hago el fit predict, o sea, estoy entrenando, armando los grupos y y me está devolviendo para cada una de mis observaciones a qué clúster pertenece. Y esto, ¿a qué cláter pertenece? me queda en un vector de 200 valores que tienen el valor, el número de cluster al que pertenece cada una de las observaciones. Entonces, yo concateno mi dataset principal, el data frame, con este vector. Lo que tengo es lo que tenía originalmente más una nueva columna que me dice el número de claster. Ahora, fíjense que el algoritmo me va a decir 1 2 3 4 5. Yo tengo que inter ahora es mi trabajo interpretar que habrá puesto el algoritmo en el cláuster tres.

01:14:34

Ise posgrados: O sea, el algoritmo no me dice en el tres puse los que gastan mucho, pero son jóvenes o o sea, no me dice nada. encontró que eran parecidos y los puso en el cláuster tres. Ahora yo tendría que más o menos mirar, explorar, hacer gráficos o lo que sea y mirarme y darme cuenta más o menos si veo algo en los del cluster 3 que me que me diga, "Ah, son clientes que no sé que gastan, que compran mucho y gastan mucho, por ejemplo." Eh, pero eso el algoritmo no me lo va a decir. El algoritmo me agrupa y después es mi tarea a ver qué hago con eso. Después de alguna exploración fantástica y que no sabemos que habrá sucedido acá en el camino, eh yo me doy cuenta que el algoritmo puso eh, no sé, en el clúster dos personas conservadoras, en el en el en el clúster uno gastadoras. Bueno, acá tiene una etiqueta puesta totalmente a mano. Sí. Esto es después de haber observado a ver qué grupos hizo el algoritmo. Le agrego entonces, a ver, eh estas etiquetas se las agrego acá como una nueva columna. A los de cluster 3 le pongo eh cautelosos.

01:15:44

lse posgrados: Bueno, o sea, usando estas etiquetas, además de la columna esta con el número de cláuster que me dio el algoritmo, yo agrego otra columna con la etiqueta. Entonces, ahora ya tengo todo mi dataset original con los clusters, con el número que me di algoritmo y la etiqueta que le puse yo. Vamos a visualizar y como se imaginarán, este es un dataset hermoso porque es de juguete y están, o sea, lo podría haber hecho a mano, no necesito llamar al camín para hacer estos cinco clusters, pero bueno, el algoritmo se dio cuenta y los agrupó bien. Y así es como veo, por ejemplo, estos le puse la etiqueta gastadores porque son los que tienen un ingreso alto y un score alto será que que consume mucho. mejor, pero yo me imagino que es gastan eh ganan mucho, gastan mucho. Estos de acá abajo, el azul son cautelosos, eh, ganan poquito, pero tampoco se lo gastan, no derrochan. Bueno, en fin, acá están los cinco grupos, cada uno con su etiqueta, perfectamente clasterizados. Tengo los cinco los cinco clusters y hasta ahí eh hasta ahí llegamos con con lo que es camins. Bueno, si no no sé si tienen preguntas, alguna duda o vamos al recreo y volvemos y seguimos.

01:17:08

lse posgrados: Todo bien. Vamos a 10 minutos. Estamos para volver. Bueno, eh preguntitas rápidas para ver si están ahí. ¿Qué qué es una qué es un algoritmo de aprendizaje no supervisado en una oración super cortita, ¿quién me dice? Yo no avanzo hasta que no me respondan. Eh,
Cristian A. Aballay: No tenemos un fecho
lse posgrados: no tenemos un target. Claro, o sea, tenemos datos, no tenemos un target. Tenemos que hacer grupos y no sabemos cómo. Básicamente no tenemos un target. Bien. Eh, tenemos varios algoritmos de eh aprendizaje no supervisado. Vimos Camins. ¿Qué hace Camins? ¿Cuál es el propósito?
Tomas Mc Nally: Gracias.
Pa. Santiago Rodriguez Castro: clasterizar las observaciones.
lse posgrados: Clasterizar las observaciones. Buenísimo. Yo le digo, "Quiero tres grupos y el algoritmo me arma tres grupos de observaciones. Me separa las observaciones en tres grupos." Perfecto. Entonces, la el los parámetros, los hiperparámetros principales de mi algoritmo son el número de clusters y también le tengo que decir la distancia que quiero que use, que nosotros usamos la euclidiana.

01:29:13

lse posgrados: Bueno, la distancia tiene otros parámetros más ahí lo vimos, pero bueno, principalmente esos. Bien, ¿cómo puedo detectar yo el número óptimo de clusters?
Pa. Santiago Rodriguez Castro: Método del codo,
lse posgrados: Meto el codo.
Pa. Santiago Rodriguez Castro: silueta o eh olvid
lse posgrados: Fuerza de predicción. Bueno, esos son los que vimos. Hay otros, esos son los que vimos y el del codo y en la índice de silueta son los más usados, ¿eh? Así que vimos esos. Esos me van a servir para camins, pero también me van a servir para otros métodos. Buenísimo. Eh, entonces podemos avanzar. Ahora vamos a ver otros métodos. Vamos a seguir con el modelo de mixtura gauciana. Yo no sé qué tanto habrán avanzado en probabilidades, pero un poquito de probabilidades vamos a traer acá. No sé si eso es una buena o una mala noticia, pero vamos a tratar de no marearnos. Eh, ¿qué qué pasa con Camins? Porque Camins es fácil de entender, es un modelo simple. Sí. Lo que pasa es que una cosa que tiene Camins es que tiene una naturaleza no probabilística.

01:30:20

lse posgrados: Camin me dice este esta observación pertenece al claser uno, no me dice si está muy seguro, si más o menos, si cree que a lo mejor no, o sea, es uno, este es dos, este es tres, no es una salida probabilística, me lo separa y ya está. Esa es una cuestión que tiene Camins. Em, en la vida real, por ahí eso no me funciona del todo bien, no es el único problema. Entonces, ahora vamos a ver qué problemas viene a resolver el modelo de mixtura gauciana. Lo podemos pensar como una extensión de camins, no es necesariamente, no es una extensión del modelo, pero lo podríamos pensar como una extensión de camins. Y vamos a ver por qué. Eh, nosotros tenemos acá estos grupos, ¿no?, que si uno los mira así, a ojo diría que podría formar fácilmente cuatro grupos, ¿cierto? No, no es muy difícil pensar que ahí yo puedo armar cuatro grupos y ya está. con Camin lo podría resolver así. Listo, ya tengo mis cuatro grupos. Ahora, Camín me haría esto. Buenísimo. ¿Qué pasa? Eh, yo tengo, por ejemplo, acá este puntito rosa, está en el cláter rosa, pero está ahí al borde de ser azul, o sea, está muy en el borde.

01:31:37

Ise posgrados: Eh, Camíz me dijo que era rosa. No hay problema, vamos a ponerle que está bien. Pero estos que están acá son totalmente dudosos. Este verde cayó verde, pero podría haber sido azul y si yo lo dejo iterar más, va a empezar a a rebotar entre un grupo y otro. Realmente fue verde de casualidad, pero no sabemos. O sea, la verdad que a mí me gustaría que me dijera, "Y es verde, pero no estoy tan seguro. Eso yo quisiera o me gustaría que me diga Camins, pero Camins no hace eso." Y otro problema de Camins es que Camins me busca eh zonas de observaciones en forma en dos dimensiones, cosas circulares, formas circulares o en tres dimensiones cosas esféricas. no me encuentra este tipo de cluster. Si yo tengo los datos así que a ojo yo diría esto es un grupo y este es otro, Camins no me lo va a encontrar. Camins va a hacer lo mejor posible, pero va a hacer esto. No, no me va a encontrar estos clássters así como están pintados ahí. No es flexible para eso. Ahí Camis no funciona, o sea, va a funcionar mal.

01:32:46

Ise posgrados: Entonces, el modelo mixtura gauciana viene a resolver esos problemas. Estos modelos pueden encontrar los mismos cluster que camins. Lo que pasa es que además va a resolver los problemas estos que mencionamos. El modelo este lo que va a encontrar primero que nada es distribuciones gaucianas o normales. En este ejemplo que yo tengo cuatro clusters va a encontrar cuatro distribuciones normales. Cada una de estas, por ejemplo, nos concentramos acá en la naranja, me va a decir, "Bueno, acá está la media de los datos. que caen en este clúster y esta es la varianza, se desparraron más o menos por acá. O sea, me va me va a describir una distribución normal y me va a decir los eh los puntitos naranjas tienen esta distribución, este punto tiene alta probabilidad de pertenecer a este cláster. Eso es más o menos a grandes rasgos de qué se trata el modelo mixtura gauciana. Y lo que va a pasar es, fíjense, a ver dónde está el dibujito. Acá. Fíjense, por ejemplo, este punto azul que está acá, no sé si alcanzan a ver, pero tiene el mismo tamaño que los demás, pero el modelo Mistura gauciana lo va a ver como un punto chiquitito, o sea, le va a dar poca probabilidad de pertenecer al azul.

01:33:59

Ise posgrados: Me va a decir, "Sí, es azul, pero más o menos, o sea, no estoy tan seguro. Y acá en este dibujito me está que ese azul me está me quedando por

afuera del del rango principal de de datos. El modelo este me va a detectar esos casos y me va a decir, "Este punto es azul, pero con una probabilidad medio baja." Eso por un lado. Lo mismo acá, estos puntos que están acá también me va a decir y la verdad que este punto tiene 50% de probabilidades de pertencer al verde, 50% de pertenecer al azul. Y otra cosa que viene a resolver este modelo es esto. El modelo Mistura gausiana me va a encontrar estos clusters. Esto esto es una gran diferencia con el camins. El camin no encuentra esto. El modelo este sí me va a encontrar estas cuatro clastas. va a encontrar cuatro distribuciones normales que van a tener una media acá y esta y esta varianza, digamos, se van a desparramar así en este en esta orientación, en este sentido. Y los puntos que tengan alta probabilidad de pertenecer a esta distribución los va a clasificar como rosa y acá como verde, como celeste y como naranja. Así que esas son las dos cosas principales, las dos ventajas principales de este modelo respecto del camins.

01:35:14

Ise posgrados: Y bueno, ¿cómo funciona este modelo? Tiene esta expresión. Esto, ¿qué significa? Acá como siempre es el número de clusters. lo que hace es combinar K funciones de distribución normal multiada, es decir, de muchas de muchas variables. Cada variable es cada una de mis columnas, cada una de mis variables de mi data de mi dataset. Entonces eh yo voy a tener funciones de distribución normal multivariada con media mu subj y covarianza, bueno, esta la covarianza subj. ¿Esto qué significa? Esto es un vector de todas las medias. Por ejemplo, en el ejemplo anterior que teníamos cuatro clusters, esto es un vector de cuatro medias y esta es la covarianza eh para esas cuatro eh distribuciones. El modelo me va a combinar cuatro distribuciones normales y a cada una le va a dar un peso, que es este fi sub j, es decir, le va a dar más importancia a unas que a otras de esas cuatro, el ejemplo, ¿no?, de esas cuatro eh distribuciones gaucianas. Ahora lo vamos a ver con un ejemplo para que se entienda un poquito, bajar un poco más a tierra y no quedarnos en la fórmula, pero la idea es que el modelo es una combinación así de K funciones de distribución con un peso cada una.

01:36:36

Ise posgrados: La cosa es que esos musupj, las covarianzas y los fi, que son los pesos, son parámetros que yo no conozco. Si vuelvo para atrás, esto es lo que yo quisiera encontrar, pero yo de entrada no lo conozco. El modelo lo que va a tener que hacer es descubrir que acá hay cuatro distribuciones, o sea, que son estas. Yo le voy

a decir, "Quiero cuatro clusteres." Eso se lo voy a decir de entrada, igual que antes. Pero entonces eh el modelo va a tener que descubrir dónde están esas cuatro, cuáles son las medias, cuáles son las varianzas y cuál es el peso que le va a dar a cada una de ellas. Todo esos son parámetros que yo no conozco y el modelo va a tener que encontrar. Por eso dice acá los valores mus subj, las las covarianzas y los fi son parámetros para entrenar. ¿Y cómo los voy a encontrar? con un algoritmo que se llama algoritmo de de eh expectation maximization em que es un algoritmo de optimización con el criterio de máxima verosimilitud. Todo eso que parece chino. Lo vamos a ver ahora en un ejemplo con numerito para que se entienda de qué estamos hablando. Acá explica.

01:37:42

Ise posgrados: Bueno, no se asusten, eh, parece complicado, pero no es no es para tanto. Para simplificar el ejemplo, vamos a imaginarnos que tenemos solo dos clusters, no cuatro como el ejemplo, ni seis ni nada, dos. Vamos a imaginarnos que tenemos dos clusters y que tenemos un solo atributo, una sola columna de datos. No tenemos 4, 5, 20. Tenemos una sola columna de datos y dos clusters. Lo que hace este modelo primero plantea dos funciones de eh de distribución normal. Esto ya vieron en prueba o no toda esta fórmula. ¿Sí o no? Manito arriba, manito abajo.
Lucia T. Capon Paul: Sí.
Ise posgrados: Tenemos acá la fórmula para la primera distribución gauciana y esta para la segunda. Fíjense en qué difieren, que cada una tiene su media y su varianza. Como estamos hablando de una sola columna, no tenemos acá un vector de medias ni una ni una matriz de covarianza, tenemos una media y una varianza. Esto sería, yo tengo una columna con números, esta es la media de mi columna y esta es la varianza de de esa columna, de esa variable. Lo que pasa que son valores que no conozco, son los que tengo que salir a buscar.

01:38:55

Ise posgrados: El tema es como tengo dos clusters, yo voy a tener dos funciones, una con mu sub un y sigma sub1 y esta otra con mu sub2 y sigma sub2. Tengo dos funciones. Estos cuatro parámetros son los que tengo que averiguar. El mu sub1, sigma sub1, mu sub2 y sigma sub2. Y además dijimos que a cada una le voy a dar un peso para empezar, cuando arranca el algoritmo va a inicializar ese muy ese sigma con algún valor que ya vamos a ver de dónde lo saca. Y el peso que le va a dar a cada una va a ser 1 sobre K, en este caso 1/2io, o sea, le va a dar un medio de

peso a esta y un medio de peso a esta. Lo que estamos haciendo es buscando o lo que vamos a hacer es buscar todos estos parámetros, estos y estos y estos. ¿Cómo los inicializo? Muy sigma, los puedo inicializar en forma random y el fi lo inicializo eh dándole el mismo peso a cada una de las dos. Yo con esto voy a crear dos clusters, pero todavía no voy a crear los clusters. Lo primero que tengo que hacer es buscar esas funciones. O sea, si yo vuelvo para atrás acá, lo primero que quiero hacer es buscar eh cómo digamos qué forma tienen, dónde está la media y qué varianza tienen.

01:40:10

lse posgrados: Todavía no no voy a hablar de clusters, o sea, eso es al final de todo. Ahora lo único que tengo que concentrarme es en buscar los parámetros de esa función. Si yo tengo estas dos, vamos a suponer estas dos de acá, quiero encontrar eh cuál es la media de este de esta distribución, cuál es su varianza, cuál es la media y la varianza de esta y cuánto peso le doy a cada una de las dos. Eso es lo que quiero averiguar. Después de averiguar eso, después al final de todo voy a armar mis clusters. Bien. Bueno, hasta ahí la idea de lo que vamos a hacer. ¿Se entiende? Vamos a Ah, no, acá vamos a hacerlo con cuentitas para que se entienda lo que digamos para no perdernos acá en las fórmulas, porque este es el algoritmo, es un algoritmo iterativo, el de expectation maximization. Yo lo que hago es estimo las probabilidades de los de los de cada observación, actualizo los parámetros, vuelvo para arriba, estimo las probabilidades, actualizo los parámetros. es algo iterativo, pero si nos quedamos con las fórmulas ahí nos vamos a perder el camino. Entonces mejor vamos a hacerlo con un ejemplo.

01:41:25

lse posgrados: Eh, vamos a imaginar, como les decía recién, dos clusters y una única variable. Yo tengo mi dataset tiene solo una columna nada más. Entonces, a modo ejemplo, yo tengo acá los valores graficados. Así en horizontal tengo los valores de eh mis eh mis observaciones. No sé cuántas son, son un montón, pero están todas ahí graficadas. Si yo hago un histograma de mis valores, se ven estas barras grises atrás. Ese es el histograma de mis valores. Esto azul y naranja son las distribuciones que yo tengo que averiguar. No las conozco. Yo las dibujé acá porque tengo la máquina del tiempo. Yo ya sé lo que tengo ahí, pero en realidad el algoritmo no sabe. El algoritmo tiene que salir a buscar y descubrir cuál es la media de la primera distribución, que será más o menos -1,5 más o menos. ¿Cuál es la media de esta

otra que es más o menos tres? Va a tener que salir a averiguar cuál es la varianza de esta y cuál es la varianza de esta. Y también va a tener que salir a averiguar qué peso darle a cada uno. A simple vista más o menos, yo diría que no sé, que esta tiene más datos, ¿no?

01:42:32

Ise posgrados: Como que a esta distribución le podría dar un peso de 06 capaz y a esta 04, o sea, en total tiene que sumar uno, ¿no? Le tengo que dar eh todo el peso repartido entre las distintas distribuciones. El algoritmo tiene que averiguar todo eso. Yo acá lo dibujé porque yo estoy armando el ejemplo. Yo ya sé que esta es la distribución, pero de antemano en realidad yo no lo sé. Yo tengo todos estos puntos por el mismo motivo, yo ya los pinté azul y naranja porque yo ya sé esto porque el ejemplo está armado así, pero de entrada yo tengo dos puntos ahí que no tengo idea y tengo un histograma que puedo imaginarme más o menos que tengo ahí dos distribuciones, pero no sé más nada, no sé la media, la varianza, no sé nada. Esto es una mezcla de gausiucianas. Tengo dos gausianas en un dataset tengo dos gausianas, esta y esta. El algoritmo tiene que encontrar las dos medias, las dos varianzas y el peso que le va a dar cada una. Ese es el objetivo del algoritmo. Y olvídense de los clusters. Todavía no estamos hablando de cluster, estamos hablando de un algoritmo para descubrir todos esos parámetros.

01:43:36

Ise posgrados: Entonces, ¿cómo hago? Primero que nada, el algoritmo inicializa la media y la varianza con valores random o puede sacar una muestra y fijarse la media y decir, "Bueno, inicializo eh este con media cero y este con media cco, o sea, no importa, es un valor random que después se va a ir acomodando. Lo que sí inicializa es el 50% para acá y el 50% para acá. Y ahora, eh, ¿cómo funciona esto? Esto se calcula por separado para cada una de las dos gausianas que tengo que encontrar. Vamos a imaginarnos que queremos encontrar esta, la naranja. Entonces, ¿qué hace para cada una de las observaciones? Para cada una de estas, vamos a imaginarnos, por ejemplo, acá, no sé, cinco para el valor, para el número cinco, ¿no? Tengo acá x los números que tengo. Vamos a hacer número cinco. Para el valor cinco, acá está el algoritmo. Para el valor 5co calcula todo esto, o sea, la función de densidad, suponiendo que ya conoce sigma y mu, pero esos sigma y mu son los que inicializó en forma aleatoria, o sea, no son los verdaderos, son los que inicializó, que pueden ser totalmente random, parecidos, cercanos a los a los reales, no lo sé, pero no

importa.

01:44:50

Ise posgrados: Haya sido lo que haya sido que inicializó, calcula esto y calcula toda esta fórmula. ¿Qué es esta fórmula? es la función de densidad de la función multiplicada por el peso que le dio a esa gauciana, que la primera vez lo inicializó con 05 y lo divide por esta suma que es son las dos funciones de las dos gaucianas multiplicadas por los pesos. La cuestión es que todo esto está hecho así para que esto sea una probabilidad. O sea, no nos vamos a meter en las cuentitas porque no nos vamos a perder en esa cuenta. Pero la cosa es que todo esto cuando yo lo calcule me da una probabilidad. ¿Qué significa esa probabilidad? Es la probabilidad de que este punto pertenezca a esta distribución. Vamos a suponer, vamos a suponer que hacemos toda esa cuenta y me da, no sé, 0 8. O sea, el punto que vale cinco de mis observaciones. Este punto que vale cinco según esta cuenta y como inicialicé esos valores random me dice que tiene 0,8% de probabilidad de pertenecer a esta distribución. Y lo mismo voy a hacer para todos los puntos. Si tengo 100 puntos, voy a hacer esto 100 veces.

01:45:59

Ise posgrados: Pero bueno, yo no lo voy a hacer 100 veces ahora. Voy a hacerlo, voy a inventarme algunos números. Por ejemplo, para el ocho, que sería este valor, me va a decir toda esa cuenta, me va a decir que tiene 0,95% de pertenecer a a esa distribución. No sé si el punto me va a andar. Le pongo una coma. Ahí está. Después le voy a poner el número, qué sé yo, -1. El -1 cuando yo haga toda esta cuenta, me va a decir que tiene 0,006% probabilidad de pertenecer a la a la gauciana esta. Y bueno, vamos a hacer dos más. ¿Qué s yo? Tres me va a decir que tiene 1%, o sea, que con que está segurísima esta cuenta me va a dar uno. Pertenece a la gociana y vamos a poner, qué sé yo. El cuatro me va a decir que tiene, no sé, cero. Estoy inventando estos números, no estoy haciendo ninguna cuenta. debería ser toda esa cuenta, pero bueno, supóng yo para esos cinco, esas cinco observaciones, hago esta cuenta, calculo esa probabilidad y todo esto me dice que el valor 5 tiene 80% de probabilidades de pertenecer de ser una muestra de esta distribución.

01:47:07

Ise posgrados: El 8 me dice 095 y así cada uno. Esto lo tendría que hacer para los 100 valores. Si tuviera 100 para los 100 valores, yo lo voy a dejar ahí. Voy a hacer una cuentita acá, una cuentita auxiliar que me va a servir suma de todo esto. Bueno, ahora una vez que hice yo ya todas las cuentas, lo que tengo que hacer es en base a los valores reales que yo tengo, porque estos son valores reales, esto ya no es inventado, estos son los valores que yo tengo en mi muestra. Entonces, en base a las cuentas que yo hice, recalculo mu y sigma, que venían la primera vez era un valor aleatorio, pero yo en cada iteración los voy ajustando. Entonces, acá los tengo que recalcular. ¿Y cómo los recalculo? Imagínense que acá en vez de haberme dado probabilidades, acá en todos los casos decía uno, o sea, que me decía el esas cuentas me decían que con seguridad todos estos datos pertenecen a la distribución naranja. Acá en vez de esto, supóng que dijera todo uno. Si esto con seguridad pertenece a la distribución naranja, entonces la nueva media de mis datos va a ser la media de esto.

01:48:16

Ise posgrados: O sea, que acá está 3,8. Sería 3,8. La nueva media, el nuevo mu, que es el parámetro que yo estoy ajustando en cada iteración, lo voy ajustando. El nuevo mu sería la media de esto, sería 3,8. Pero la realidad es que todo esto no está con seguridad en la distribución naranja. Tengo una probabilidad, entonces el mu que yo calculeé lo tengo que ponderar. Yo no puedo poner cinco en ese cálculo, tengo que poner el 80% de C. O sea, el mu que yo voy a estimar en esta iteración va a ser una media que va a salir de acá, pero ponderada. Eso es lo que dice esta fórmula. Voy a sumar todo esto multiplicado, o sea, voy a sumar esto multiplicado por esto ahí y lo voy a dividir por este número de acá. O sea, esto va a ser la suma de todo aquello dividido esto. La nueva media en iteración este mu sub j va a ser 5,033. Es decir, no es la media exacta de mis números, sino que es la media ponderada por las probabilidades que calculé. La media exacta me daba 3,8, la media ponderada me da cinco, o sea, es otro número, está ponderado por estas probabilidades.

01:49:37

Ise posgrados: Y de la misma forma voy a calcular el nuevo sigma. El nuevo sigma, la cuentita es parecida, solo que tengo que multiplicar el valor este. Tengo que multiplicar el valor este menos el mu que calculé, así al cuadrado. Y todo esto lo

tengo que sumar. Lo tengo que sumar y lo tengo que dividir por esta suma de acá. Esto que hice acá es la el nuevo mu y el nuevo sigma. Es el punto tres de la iteración. Lo que estoy haciendo es reajustando y acomodando el mu verdadero. El mu. Yo estoy buscando el mu verdadero. Estoy reajustando el mu y el sigma de esta campana. Yo todavía no sé cuál es valor verdad, lo estoy buscando. Entonces, en cada iteración yo voy ajustando así como lo que acabo de hacer, voy ajustando este este esta campana. Por ahora en mi próxima iteración ahora va a ser CCO y sigma va a ser 14. 14 6. ¿Qué me falta? actualizar el fi. El fi es eh las esto es esto dividido el número de observaciones. Tengo cinco observaciones, así que el fi es 70 069 07. ¿Qué significa eso?

01:51:14

Ise posgrados: que a esta campana le voy a dar el 70% de peso y a esta otra azul le va a quedar el 30 restante. Lo que hice acá no fue ni más ni menos que ajustar las variables que estoy buscando, que son mu, sigma y fi para la campana naranja. Todo esto mismo lo tengo que repetir para la campana azul. Y ahí tengo los parámetros que estoy buscando actualizados. Todavía no son los definitivos, los tengo actualizados. Yo esto vuelvo arriba y hago esto otra vez, otra vez y otra vez y estos se van ajustando cada vez y cada vez más se van aproximando al valor verdadero, a estas que yo las dibujé porque sé porque yo inventé el ejemplo, pero en realidad el algoritmo no sabe que estas son las campanas. El algoritmo está buscando estas campanas después de muchas iteraciones. El mu de la naranja va a ser seguramente tres o algo así. El sigma, bueno, no sé que será dos, eh, y el fi, capaz que 06, no sé, porque por lo que veo el 60% de los datos está acá. Después de muchas iteraciones, estos valores se van a ir acercando al valor verdadero. Acá dice, el algoritmo continúa hasta que los valores no cambian más.

01:52:29

Ise posgrados: Después de ciertas iteraciones, estos valores van a estar siempre estáticos o quietos, bastante quietos. o lo mismo que en Camí. Digo, bueno, después de tantas iteraciones para no no sigas más porque por ahí puede estar eternamente ajustando, ajustando, ajustando por decimales. En un punto termina, pero la idea es esa, itero, itero, itero para cada una de las dos. Este ejemplito que hicimos fue suponiendo que tengo solo cinco observaciones, pero esto lo haría para todas las observaciones y el ejemplo que hicimos fue solo para la campana naranja. Esto mismo lo tiene que hacer para cada una de las campanas, para la celeste en este

caso también. preguntas.
Lucia T. Capon Paul: A mí me resulta un poco raro pensar como, ¿qué pasa si no se distribuye como una campana de Gaus? O sea, es como o o medio que uno está forzando los datos a que se ajusten a eso.
lse posgrados: está forzando, está forzando y y sí, si no es que uno espera que se distribuyan como variables normales,
Lucia T. Capon Paul: Ok.
lse posgrados: si no, o sea, no es que se va a romper el algoritmo, pero probablemente me dé algo malo, pero en verdad uno espera que encuentre que encuentre en los datos estas distribuciones.

01:53:43

lse posgrados: Uno espera que sí las encuentre. Eh, sería esperable que las encuentre.
Lucia T. Capon Paul: Ok. Muy bien.
lse posgrados: Bueno, la cosa es que hace esto, pega la vuelta, pega la vuelta, sigue, sigue, sigue tirando y va mejorando estos parámetros, estos tres parámetros. Voy a volver a la presentación acá. ¿Qué hizo? Estoy acá, ¿no? Lo que hice yo, ese se ve B que calculé fue esto e y después calculé esto, el mu y calculé el sigma y calculé el fi. O sea, todo esto es lo que hice en el ejemplito. Esto eh lo hace una y otra vez. Bueno, esto está en dos slides, pero acá empieza el algoritmo. Paso uno, paso dos, paso tres y paso cuatro. Itera, itera, itera, itera. y va mejorando la precisión, vamos a decir, de estos tres parámetros para cada una de las campanas. En algún momento eso se estabiliza y ahí termina. ¿Y qué pasó? Todavía no tengo clusters, o sea, todavía no llegué a eso. Lo único que pasó fue que yo ahora sé cuáles son las distribuciones de esas dos campanas, en este caso que son dos clusters.

01:54:59

lse posgrados: Tengo la media de la campana uno, la media de la campana dos, la varianza de la campana uno, la varianza campana dos y el peso que le voy a dar a la uno y el peso que le voy a dar a la dos. Todo eso ya lo tengo y eso es lo que voy a usar para armar los clusters. Acá tengo otro ejemplo visual de lo mismo que vimos recién en la en el en el Google Sheet. Imagínense que yo tengo las campanas verdaderas que no conozco, que son las que tengo que buscar, son estas naranjas. Imaginen que imagínense que son esas, no las conozco, es lo que tengo que buscar. Yo inicializo con datos random, entonces digo, "Bueno, mis campanas random van a

ser estas, la fucsia o va la magenta y la celeste. empiezo acá, pero a medida que voy iterando el mu, el sigma y el fi se van actualizando y estas campanas se van moviendo, se van moviendo, se van moviendo hasta que idealmente se superponen con las ideales, con las que las verdaderas, que yo las desconozco, pero eh la idea es que se van con cada iteración se van moviendo, moviendo, moviendo hasta que llegan al lugar, digamos, más eh más eh realamos o más eh parecido a las verdaderas campanas que están ahí escondidas, o sea, son las que yo estaba buscando.

01:56:19

lse posgrados: Bueno, acá las parece que las encontré. Interación 40 dice, "Yo no sé si este dibujo sale de algún ejemplo." No, no está en la notebook ni nada esto, pero dice en la iteración 40, bueno, llegó a las campanas eh buscadas. ¿Cómo armamos los clusters? Cuando yo ya tengo las distribuciones gaucianas, en este caso tengo dos, eh, sí, tengo dos, ¿cómo hago la clasterización? Agarro un valor cualquiera, una observación, calculo, este es el mismo que estaba en en el algoritmo, esta fórmula B. Calculo la probabilidad de pertenecer a la campana celeste, el ejemplo, y me da 06. Calculo la probabilidad de pertenecer al otro y me da 04. Entonces digo una de dos. O digo en la muestra pertenece al cláter azul porque fue el mayor o digo pertenece al cláter azul con probabilidad 06 y al otro con probabilidad 04. Puedo elegir si quiero usar las probabilidades o me quedo con la con la más probable. Le llamo asignación débil porque justamente no le estoy diciendo con seguridad pertenece al azul, estoy diciendo que con mucha probabilidad pertenece al azul. De esta manera, para cada una de las observaciones, yo calculando esto, puedo decir a qué clúster pertenece cada una de todas las observaciones.

01:57:47

lse posgrados: Fíjense que esto es una fórmula. El mu, el sima y el fi son los parámetros que encontré recién. Con esa iteración yo encontré estos valores. Así que yo acá simplemente reemplazo y calculo. Es una fórmula simple matemática. reemplazo la función de distribución normal y los parámetros estos que encontré, el x que es mi observación y hago la cuentita y obtengo la probabilidad. Bueno, acuérdense que el ejemplo que vimos era para, bueno, dos gacianas y para una sola variable, una sola variable, un dataset y una sola columna. Ahora, si nosotros tenemos eh muchas variables, vamos a tener un un vector de medias, una matriz de covarianza, vamos a tener, o sea, una unos parámetros más complejos, ¿no? Y el

tamaño de los clusters, eh, a veces puede ser como camisa, una cosa redonda, a veces va a ser una elipse, o sea, va a tener diferentes formas. Justamente yo les prometí que este modelo era mejor que Camíns y me encontraba formas diversas. Eso eh es algo que yo le tengo que decir al al modelo eh en particular, bueno, cuando yo ejecute ahora vamos a ver en Python este este modelo, yo le voy a tener que decir eh qué forma va a tener mi clúster.

01:59:18

Ise posgrados: O sea, si yo le digo, "Buscame la forma que encuentres, ajustate y busca la mejor, buscar lo que encuentres, o sea, acomodate a los datos." es el modelo va a poder hacer eso, pero eh va a ser más costoso. Entonces, yo tengo la opción de decirle, "Mira, el tamaño del cluster es independiente para cada dimensión, o sea, puede ser alargado para arriba, para el costado, pero en cada dimensión se va a mover por separado o puedo decirle se mueve junto para todos lados como camino, o sea, es redondo, vamos a suponer en dos dimensiones." le digo al modelo, eh, mis claser tienen que ser redondos o le puedo decir, se mueven juntas, entonces me va a encontrar eles giradas. O sea, esto son distintos niveles de complejidad que yo le voy a decir al modelo, bueno, eh, fíjate, encontrame clusters o super redonditos o cláusters algados o adaptate a los datos como vengan. Esas son eh parámetros del modelo. Si yo le estos son las tres las tres opciones, esto sería como camins, yo le digo encontrar cosas redondas, aunque mis datos estén así en forma distribuidos como en forma alargada, el camín va a encontrar esta distribución gauciana, así.

02:00:24

Ise posgrados: Este caso es el primero para encontrar que es alargado en una dimensión y achatado en la otra dimensión. Y este es el más complejo que es, bueno, mi distribución oceana se adapta a la forma de mis datos. Esto, cada uno de estos es un parámetro que yo le voy a pasar a la función en Python. Pero por supuesto el modelo no es perfecto porque esto no me lo va a encontrar. Yo acá si tengo esto, el ojo humano, ¿qué dice? Que tengo acá un clúster y acá abajo tengo otro. Bueno, el modelo no va a encontrar una distribución gaciana acá porque esto es cualquier cosa. Este dato está más cerca de este, o sea, no va a encontrar esto, la verdad. Va a ser algo así. va encontrar cualquier cosa, eh, ni Camíz ni lo que acabamos de ver va a encontrar esas dos media lunas. Entonces, ¿cómo resolvemos ese problema? Lo que podemos hacer en este ejemplo es decirle,

"Bueno, modélame 16 gaucianas." Y entonces las va a encontrar perfecto. Va a encontrar así como esta cadena gauciana, una al lado de la otra y va a encontrar esto, pero perfectamente.

02:01:38

Ise posgrados: O sea, no, si le digo dos no va a encontrar nada, pero si le digo 16 va a encontrar esto. Va a andar buenísimo. Un eh una aplicación de esto es para hacer, por ejemplo, generar datos sintéticos. Si yo quiero datos sintéticos, eh no sé si eh se fijaron en los códigos de Python cuando generamos datos así inventados para los ejemplos que uno le dice, "Bueno, generame datos con distribución normal, uniforme, etcétera." Eh, no hay ninguna opción que me genere esto, pero yo acá si encuentro las 16 gaucianas, después puedo agarrar cada una de esas y generar datos sintéticos que vayan rellenando toda esta media luna y que tengan esta misma forma. Eh, eso podría hacer, por ejemplo. Y bueno, ¿cómo medimos nuevamente? Acá estamos con otro modelo que no es eh camins, ¿cómo medimos el número óptimo de clusters? Eh, fíjense que en este caso, bueno, vuelvo al ejemplo acá. En este caso, el tema de las distancias no me va a servir. El tema ese de la de la los clusters compactos no me va a servir porque estos no son cláusters compactos, son otra cosa.

02:02:52

Ise posgrados: Bueno, justamente esto no, pero a ver, eh, bueno, no tengo, no reljos los ejemplos, pero bueno, esto vamos a suponer esto. E supóng que tengo acá uno así y otro así. El tema de las distancias no me va a servir porque, por ejemplo, este punto capaz que está más cerca de esto que su propio clúster, pero sin embargo está bien clasificado acá. Entonces, yo empiezo a trabajar con las distancias glidianas. Acá no me va a funcionar absolutamente para nada. No, no va a funcionar. Entonces, en estos casos, eh vamos a obviar los otros métodos y vamos a usar o la fuerza de predicción o vamos a usar estos criterios que están basados en estadística, criterio de información de acá aque o el criterio de información valleciana. Eh, y con esto sí va a funcionar bien eh la selección de número óptimo de clusters. Acá en este ejemplo que es el mismo recién, sí está eh entrenado el modelo para dos cláuster 3 4 5 hasta 20. Y acá están graficados los índices estos. Acá hay que eh el BIC. Lo que me está diciendo esto que el índice óptimo para acá que el número óptimo de clusters está acá entre 10 y 12. es el número menor, ¿no?

02:04:08

Ise posgrados: Entre 10 y 12, que sería este de acá abajo. No sé cuántos hay acá, pero pareciera que hay 10, 3, 6, no, 12 parece que hay acá. Y para el índice BIC me dice que seis sería un número óptimo de clusters, que sería este de acá. O sea, menos clusters es más simple, pero también es como más duro la la separación. Capaz que este es más lindo, ¿no? Pero bueno, yo con estos índices puedo elegir el número óptimo de clusters en estos casos para en la mixtura gauciana. Hasta ahí venimos bien. Les prometo que el próximo modelo es más simple, el último. Vamos a ver eh acá en la notebook cómo hacemos esto.
Gabriel Quiroga: Yo tengo una duda antes de pasar a eso que está bien,
Ise posgrados: Sí. Sí,
Gabriel Quiroga: ahí definimos varios cluster, pero nosotros a ojo podíamos saber que eran dos grupos, dos medialunas.
Ise posgrados: sí,
Gabriel Quiroga: Después, una vez que yo tengo seis cluster definidos,
Ise posgrados: sí.
Gabriel Quiroga: que lo agarran perfectamente, tengo alguna forma, algún número, algún índice que me diga, "Che, estos tres cluster van juntos y estos otros tres van por otro

02:05:18

Ise posgrados: No, no, ahí tendría, no, la verdad que no.
Gabriel Quiroga: lado.
Ise posgrados: Ahí tendrías que vos verlo y unificarlos en ese ejemplo puntual, unificarlos vos. manualmente si quisieras como agruparlos en un mismo, o sea, como en dos, como lo que estábamos pretendiendo hacer.
Gabriel Quiroga: Okay, gracias.
Ise posgrados: Eh, bueno, entonces, ¿qué vamos a usar? Se lear. Acá mixtura gauciana está el link a la documentación. Sí. Acá, ¿cómo hacemos el entrenamiento? Llamamos acá mixtura gauciana, le decimos cinco componentes, serían cinco distribuciones gaucianas. El tipo de covarianza, eh son esas esas opciones que les mostré. Si quiero que mire eh una forma redonda como el camin o quiero que mire eh por separado la orientación horizontal y la vertical, o sea, las las orientaciones de las distintas variables por separado o quiero que se acomode a mis datos. Esa sería la versión full, que es la más costosa, pero es la la que va a andar

mejor, la que me va a dar mejor resultado. Entonces, acá le digo full. Ese es el tipo de covarianza.

02:06:27

lse posgrados: Acá hago el fit. El fit lo que hace es buscar todos esos parámetros, todos los mu, las varianzas, la fi, todo eso, eh están acá en esta sola línea de código. Y el predict lo que me hace es asignarme eh eh todas las eh las probabilidades, todos los resultados. Acá abajo, acá está dibujado cómo me asignó los clusters. Eh, al mismo ejemplo del que vimos en Camins de los clientes, así me asignó las cinco distribuciones gaucianas. Pueden ver que acá, por ejemplo, bueno, este verde hizo una elipse medio torcidita, pero claramente, o sea, acá el camín ya andaba bien, o sea, no hacía falta hacer esto. Pero bueno, si yo esto lo hago con mixtura gauciana, me encuentra estas cinco distribuciones que son muy parecidas, no son iguales, pero son muy parecidas a las que encontré con Camisa. Y con fuerza de predicción hago el dibujito y nuevamente me dice, es más, acá parecía más alto esto, como dos con dos cláusteres estaría bien, me dice. Y si no, con cinco en este caso. Bueno, no es gran cosa. ejemplo, es eso, o sea, eh defino el modelo con los parámetros que que quiero, eh hago el fit y después hago lo que sería el predict, que es en base a lo que encontró, me dice las probabilidades y me asigna los clusters eh a cada una de mis

02:08:10

lse posgrados: observaciones. Eso no es más que eso. Sí.
Alejandro Valle: A mí solo no me quedó claro la covarianzas es por cada cluster que que se calcula o todos los features.
lse posgrados: No, todos, todos. O sea, mira a ver la la presentación, esto decís vos, la el parámetro de covarianza que le digo. este el parámetro de coberencia que yo le digo, o sea, este dibujo acá es un solo cláuster, pero cuando yo le digo, le doy el parámetro, no me acuerdo cómo llama el parámetro, pero le digo el parámetro que mire por separado eh la orientación de cada variable, yo se lo estoy diciendo para todos los clústers, no le digo para cada búscame un cláster horizontal, otro vertical, o sea, yo el parámetro que le paso es para todo el entrenamiento. Entonces, el que mejor se va a adaptar es este último, porque yo a lo mejor tengo clusters alargados, cláusters redondos. E voy a tener cluster de distintas formas. Entonces, si yo le paso el este parámetro, el último, el full, me va a encontrar eh va a ser el mejor, porque, por ejemplo, acá en la notebook, si se fijan, bueno, es medio sutil, pero acá encontró

diferentes formas y diferentes orientaciones.

02:09:23

Ise posgrados: Eso porque le pasé el parámetro full. Si yo le hubiera pasado el parámetro, no me acuerdo de memoria, ¿cómo se llama el parámetro? Pero el parámetro que me busca eh como los círculos de camins, me hubiera encontrado, no sé si igual, pero casi igual al camín, todas cosas redondas con el parámetro que yo le pasé, el full. Eh, fíjense que me está encontrando elipses con distintas orientaciones porque se acomoda la forma de mis datos. No sé si esa era tu pregunta, eh.
Alejandro Valle: Sí, sí. Gracias. Yeah.
Ise posgrados: Bueno, ¿qué hora es? Las 9. ¿Quieren otro cortecito chiquito antes de ir al jerárquico que es el último? Sí. Bueno, vamos otro corte chiquito. Bueno, la última partecita. Estamos un dos están tres. Ahí está. Bueno, cláuster jerárquico es el último de los modelos eh de aprendizaje no supervisado que vamos a ver hoy. El clástre jerárquico me resuelve una potencial desventaja. ¿Por qué potencial? Eh, yo tengo en el en los casos anteriores habíamos dicho que de entrada tengo que decirle, bueno, quiero tres cluster, quiero cinco, quiero ocho.

02:21:33

Ise posgrados: De entrada puede ser que yo ya sepa que quiero tres clusters, pero muchas veces no sé. Entonces, por eso entre pares de potencial, no siempre, pero en general yo no sé cuántos clusters quiero y el cláster en jerárquico me viene a resolver ese esa cuestión. No tiene el prererequisito del número de clusters. ¿Alguno le suena este dibujito que estamos viendo a la derecha? ¿Qué es? ¿O a qué les suena? ¿A qué les hace acordar
Gabriel Quiroga: el dendorrama que está en análisis de datos.
Ise posgrados: el dendograma que vimos para análisis de nulos? Es lo mismo. En ese caso estábamos haciendo un clasering de eh de datos nulos. Era un clustering, no sabíamos, pero estábamos haciendo un clustering. En ese caso, este es un dendrograma. ¿Cómo cómo funciona esto? Yo tengo acá nuevamente el mismo ejemplo de antes, pero no sé si quiero tres cláusters, no sé cuántos quiero. Entonces, yo agarro mi dataset y se lo tiro al modelo y el modelo me va a armar un árbol con todas mis observaciones con cláuster jerárquicos.

02:22:45

Ise posgrados: Ahora lo vamos a ver en detalle. Todos estos son grupitos jerárquicos que son clusters. Y yo después que el modelo me armó, el algoritmo me armó todo esto, yo después voy a decidir cuántos clusters me quedo. O sea, es al revés. Armo todo y después digo cuántos clusters. Entonces, ¿en qué consiste el cláuster jerárquico? Es un algoritmo de aprendizaje automático no supervisado, igual que camins, igual que Mextura Gauciana, que agrupa datos en función de su similitud, pero en este caso armo una estructura de árbol sin necesidad de decirle cuántos claster quiero. ¿Cómo arma el árbol? Va buscando las observaciones que se parecen más entre sí y las va agrupando y agrupa los parecidos y agrupa, agrupa, agrupa hasta que llega arriba a una raíz y ahí tiene todo el árbol. O sea, empieza con todos con todas las observaciones buscando similitudes y las va agrupando hasta que llega a unirlas todas en una raíz. Este dibujito que vimos es el dendrograma, que no son los clásers. El dendrograma es simplemente una representación gráfica de lo que construyó. ¿Cómo funciona?

02:23:58

Ise posgrados: Tenemos por ejemplo acá estos datos que son 10 datos, los pone acá abajo. Vieron que no están ordenados numéricamente, están ordenados por la similitud. Cada uno de estos de estas observaciones está acá abajo. Cada uno es una hoja del árbol que después se va agrupando con otras hojas recursivamente hasta que están todas unidas acá arriba en la raíz del árbol. Es decir, todas estas observaciones vienen a parar acá abajo como hojas del árbol que después se van agrupando hasta formar el árbol completo. La longitud de estas ramas me indica qué tanto son similares o diferentes las ramas entre sí. Por ejemplo, yo tengo acá el cinco y el siete. El algoritmo me dijo que se parecen mucho entre sí. Yo veo como siempre. Una vez más el ejemplo en 2D es el más fácil de ver. Yo veo que acá el cinco y el siete están muy cerca, o sea, yo considero que están que son muy similares y el algoritmo consideró lo mismo, las puso acá juntas. Después con un nivel más de los puso la misma altura que el ocho, pero en segunda instancia los unió con el ocho acá, o sea, unió este grupito, este clúster que es el cinco con el siete, lo unió con el ocho.

02:25:16

Ise posgrados: Y hasta acá las ramas estas no son muy altas, pero acá de repente

pega un salto porque este nueve que está por acá sí se diferencia bastante de todas estas otras. Entonces esa diferencia esta grande que está acá la está representando con la altura de esta rama. Esta altura me dice que el nueve no es tan parecido a este otro grupo que tiene el dos, incluso el dos está acá, el dos, el ocho, el 5 y el siete. En última instancia los va a tener que unir porque el algoritmo va a tener que unir todas las observaciones de alguna manera. Aunque, supóng, aunque el tres y el cuatro, el uno y el seis no tengan nada que ver con estos, en última instancia los va a terminar uniendo porque el algoritmo une todo. Une todo, empezando por los más similares, hasta las que son más distintas entre sí. Y acá tenemos un ejemplo psicoélico donde la para que vean que la se equivoca, eh, ¿cómo hago yo después que tengo el árbol? No. Y digo, bueno, listo, ya tengo el árbol, quiero cuatro clusters. Entonces, agarro y trazo una línea horizontal. Imagínense que esta línea en vez de estar acá está un poquito más arriba. Yo trazo la línea horizontal, estoy cortando cuatro ramas.

02:26:31

Ise posgrados: Sí. Y eso significa que cada una de esas ramas va a ser uno de mis clásers. Esta rama azul es un cláúster, esta rama verde es otro, la amarilla es otro y la roja es otro. Este dibujo que está acá abajo, en realidad, si se fijan, está cortando cinco ramas. Esta verde la está cortando en dos. Está cortando dos ramas acá. Estos serían dos clusters. el azul, acá dos verdes, el amarillo y el rojo. La altura de esta línea horizontal me va a decir cuántos cláss me va a determinar cuántos clusters eh van a quedar eh formados. Si yo corto acá arriba, estaría haciendo dos clusters y corto acá. Ahí. Bueno, el algoritmo lo que hace es construir toda esta jerarquía combinando iterativamente clásters parecidos. ¿Y qué significa cláuster parecido? Similares. Volvemos a la primera slide. Tengo que tener una medida de distancia. En este caso, lo que necesito es una medida de distancia entre clusters. Y ahí hemos visto las distancias estas basadas en el centroide, la distancia mínima, la máxima, la promedio y habíamos mencionado también otra que ahora la vamos a ver eh, que era la W, eh, la vamos a ver en un ratito, la vamos a ver en este en este modelo.

02:27:55

Ise posgrados: ¿Cómo funciona el algoritmo? Primero pone todas las hojas, ¿vieron? Ahí abajo de todo están todas las observaciones. Cada una de esas observaciones es un cláuster separado. Como hoy no me acuerdo quién era Tomás que me

preguntó si tengo 200 clusters. Bueno, en este caso sí vas a tener 200 clusters de un elemento cada cluster. Y ahora empieza a iterar. Computa la distancia entre clusters usando el linkage que elegí. Por ejemplo, si elegí el método de eh centroides, bueno, usando ese método computo la distancia entre todos los pares de clusters y me quedo con el menor, las dos que están más juntos. En este caso serían dos observaciones, porque cuando empiezo cada observación es un cluster. Me quedo con los que están más juntos y eso los fusiono en un único clúster. El siguiente paso, otra vez computo todas las distancias. Ahora no tengo todas hojas, tengo todas hojas y un cláster de dos elementos con eh computo todas las distancias y vuelvo a fusionar. A lo mejor fusiono dos hojas, a lo mejor funciono este cláster que tenía dos con otra hoja. Bueno, según la distancia voy a estar fusionando distintas cosas, pero hago esto iterativamente, fusiono, fusiono, fusiono hasta que me llego a la raíz, siempre comparando con esa eh distancia que elegí.

02:29:07

Ise posgrados: Y acá es donde aparece este otro método que es el el método Word, que cómo funciona. Eh, para computar la distancia entre dos clusters, ¿qué hace? Eh, mide la varianza dentro de cada cler. Supóngase que la varianza dentro de este clúster es cinco y la varianza de este dentro de este otro clúster es 10. Si yo uno esos dos eh clusters, imagínense que yo tengo los puntos todos amontonados por acá y amontonados por ese otro lado. Si yo los uno, la varianza de todo eso va a ser más grande que la individual de cada cluster, porque va a estar todo más separado. Entonces, yo tenía cinco, tenía 10 y si yo lo uno y calculo la varianza, a lo mejor me da 15, ¿no? No me va a dar más chica que cinco ni que 10, porque tengo dos cláusters separados. Cuando los una varianza de la unificación me va a dar más grande. Ese 15. es el valor que voy a usar para el linkage word. O sea, miro cuánto sería la varianza si yo los uno. En realidad no 15, sino cuánto aumenté. Yo tenía cinco, tenía 10. Perdón, empiezo el ejemplo de nuevo.

02:30:11

Ise posgrados: Perdón, olvídense de los números. Tengo, ¿qué dije? Tengo cinco y tengo 10. La suma de los dos es 15. Si yo recalculo la varianza de los dos clásters unificados, a lo mejor me da 20. Hago 20 - 15, ese 5, ese es el el valor que usa el linkage word. No sé si los perdí porque me confundí con los números. Si no, lo explico de vuelta. ¿Entiende cómo se calcula este método? O sea, veo cuánto aumenta la varianza si esas dos cosas que yo las tenía separadas, ahora las tengo

juntas. Ese numerito es el que usa, en el caso que yo elija este método, ese es el número que usa para decidir eh si combina o no combina dos eh clusters. Va a combinar los que modifiquen menos esa varianza eh al fusionar dos clusters. Vamos a ver eh en la notebook cómo funciona esto. Eh acá cláter jerárquico. Eh el cláuster jerárquico vamos a hacerlo de dos maneras distintas. Primero, bueno, primero que nada está generando acá datos sintéticos eh inventados, no son los del cliente, son otros datos totalmente acá inventados.

02:31:35

lse posgrados: Lo primero que vamos a usar es un método de SPI, no de cycle learn, un método de CPI que una biblioteca, mejor dicho, un paquete de CPI que se llama clustering jerárquico, que tiene más funcionalidades que llan por eso lo vamos a hacer con este, pero después vamos a usar Cy Len al final de la Nodus. Con Saippi, ¿qué vamos a tener? Primero que nada, un método que se llama linkage, que lo que hace, le paso el método que voy a usar, que en este caso es Word, le paso mis datos y el linkage lo que va a hacer es calcular toda esa jerarquía, o sea, va a hacer todos los cálculos, no va a ni armar cluster ni armar un dentograma, solamente va a ser los cálculos. dentro de este Z internamente voy a tener todos los cálculos, quién se relaciona con quién, cómo es la distancia de cada uno, cómo se fusionan, o sea, todos los cálculos necesarios para para armar el dendograma, para armar el eh para elegir los cláter, todo va a estar eh internamente guardado en esta variable Z. Entonces, una vez que calculé todo, yo con la función dendrogramo dibujar. Le paso la variable Z como parámetro y lo dibujo. Y acá está.

02:32:47

lse posgrados: Este es el dendrograma de esos datos sintéticos que inventé arriba. Acá abajo no se ven porque son muchísimos, pero son todas las observaciones. Cada una de esas hojitas una observación y las fue agrupando, agrupando, agrupando y quedó así el tendrograma. Ahora, eh, si yo digo, bueno, quiero tres clusters, sería como cortar con una línea horizontal acá, ¿no? Acá yo tengo este cláser, este otro y este otro. ¿Cómo hago eso? Llamo a esta función f cluster, le paso esa estructura, esa variable Z que tiene todo calculado adentro, le digo que quiero tres y acá algunas selecciones de algunas opciones de con qué criterio elegir. Esto creo, no estoy segura, pero creo que tiene que ver con que, por ejemplo, si yo le digo quiero cuatro, capaz que no hay un lugar donde corte y sean cuatro. Bueno, no estoy segura porque no se ve muy bien, pero si yo corto acá me da tres, si corto acá me da

cinco. A lo mejor si corto más o menos acá me da cuatro, pero por ahí según la altura de las ramas y todo, capaz que no hay un lugar donde corte y d cu. Entonces va a ser lo mejor posible para recombinar eso y darme cuatro clusters.

02:33:56

lse posgrados: La cuestión es que con esta F cluster le digo, "Dame tres." Y en base a toda esta estructura que ya calculo y tiene guardada, me va a devolver eh los datos separados en tres clases. Y una vez que los tengo, que los tengo acá, acá, bueno, los estoy graficando, pintando por colores, según cómo me los me los dio agrupados esos tres que le pedí. Todo eso con la biblioteca de con Saipay. Ahora con sec learn tengo eh esta opción de cluster aglomerativo. Enak len por defecto usa distancia euclidiana entre los entre observaciones y entre cluster usa el Word también, pero a diferencia del anterior, yo acá le tengo que decir cuántos cluster quiero. Acá lo invoco. Cláster aglomerativo. Cláuster tres. Le paso el linkage que creo que es por defecto, no hace falta pasárselo. ¿Y qué es lo que hace esto? Arma el árbol. O sea, es un cláster jerárquico. Lo que pasa es que yo le estoy diciendo clúster 3. Entonces, va a ir armando el árbol, lo va armando, armando, armando y cuando llega a tres corta, no, no termina de procesar.

02:35:15

lse posgrados: Tres es como que va a llegar casi al límite del árbol, pero si yo le dijera, "Ámame cinco, capaz que llega, bueno, va a llegar mucho antes a cinco, ¿no? Empieza a armar, armar, armar. Cuando llega a cinco, eh, corta. Si yo no le hubiera dicho cinco, eso puede seguir a lo mejor muchísimo más hacia arriba, pero eh cuando llega el número de cluster que yo le dije, listo, eh aborta y y ya está. Así es como funciona el de learn. Y es parecido, es bastante igual. Este es el resultado de SELAM, cómo quedaron agrupados los tres eh cláuster de mis datos sintéticos. Bueno, acá los este lo vamos a hacer el ejemplo con los datos de los clientes. Acá tenemos la variable que ya está calculado. Los datos vienen de allá arriba, ¿no? Es la misma notebook. Vamos a agrupar eh usando la primera biblioteca, ¿no? La learn. para hacer los ctering de los clientes con este método. Entonces, así los agrupo. Acá cada hojita es un cliente porque así es como funciona el árbol.

02:36:23

Ise posgrados: Primero en las hojas están todos los clientes y los empieza a agrupar por similitud, agrupa, agrupa y acá cortaría para hacer los cinco clusters, ¿no? Acá el dentrama lo hice con el conpi, pero acá el cluster aglomerativo lo estoy haciendo con cycit learn. Eh, armo los clusters, hago el fit predict, asigno las etiquetas igual que antes y acá los dibujo. Y para sorpresa de nadie me hizo más o menos los mismos cluster que los que ya habíamos visto antes. Tengo acá los clusters obtenidos con los tres métodos, con camins, con gausiana y con clústering jerárquico. A simple vista son reiguales. Si lo miran con lupa, hay pequeñas diferencias, pero son mínimas claramente porque estos son datos de juguete, eh, completamente inventados y prolijos para para los ejemplos. Entonces, no van a haber mucha diferencia entre ellos. Acá en los límites, por ejemplo, acá hay un puntito naranja. Este mismo acá está clasificado como verde, eh, y bueno, y por ahí hay alguna otra diferencia más, pero a grandes rasgos, este, la clasificación dio igual en los tres con los tres métodos. Ahí está.

02:37:55

Ise posgrados: Preguntas de la notebook o vuelvo a la presentación. Bueno, fíjense que acá tengo abierta la documentación de Seit learn clustering. Hay un montón de métodos que nosotros no vimos. Vimos algunos nada más. Eh, acá tenemos eh mixtura gauciana. Ah, no veía. El primero es camin mixtura gauciana. ¿Cómo clasifica? Bueno, en dos dimensiones eh distintas formas de de mis datos, ¿no? Acá, por ejemplo, está el ejemplito de de estas cosas así como alargadas. El camín clasifica superm y el Mistura gauciana hace una clasificación perfecta en tres grupos. Eh, hay formas que ni el camín ni la mctura gauciana resuelven. Este es como el ejemplo de las medialunas. Bueno, acá está el ejemplo de las medialunas, la mixtura gauciana. Si yo le digo, "Dame dos clusters." Bueno, no las encuentra esas medialunas, como yo le llamo. Acá hay otros métodos que sí las encuentran porque funcionan diferente. Así que acá tienen para investigar si quieren ver otros métodos. Hay hay unos cuantos.

02:39:11

Ise posgrados: Y bueno, y por último, les voy a mostrar un, esto es un dato, un bonus, dato de color de un ejemplo de cómo aplicaría yo esto a otro tipo de información que no tiene nada que ver con las tablas que venimos trabajando, filas y columnas.

Vamos a ver cómo aplicar estos algoritmos a una imagen. Esto es un ejemplo, un un recorte de una imagen satelital de la cordillera. Y algo que se hace con estas imágenes es clasificar los tipos de suelo. Capaz que no es tan común clasificar un un imagen acá de la cordillera, pero es más normal en una imagen de cultivos, por ejemplo, en tipos de cultivo que a simple vista yo miro y a lo mejor veo todo verde o todo amarillo, pero en el fondo miro con lupa, miro con detalle los píxeles, los valores de píxeles, puedo ver que hay diferentes clases. Entonces, eh para clasificar esto, bueno, yo puedo usar estos métodos. Imaginémos, ¿no? En esta en esta imagen yo quiero clasificar, tengo ahí a simple vista tengo acá, no sé, nieve, valle, tengo acá, no sé, unas lagunas parecieras así, hay como varias coberturas y a lo mejor hay algunas que no estoy llegando a ver porque el ojo humano por ahí no detecta diferencias más sutiles.

02:40:24

lse posgrados: Yo tengo esta imagen, imagínense si esta fuera una imagen de 100 píxeles por lado, 100%, eh, ¿cuántos valores tendría? 100 1000 10000 10,000 píxeles, ¿no? O sea, si esto yo miro cada uno, o sea, la imagen está conformada por píxeles de distintos colores. Yo acá estoy viendo una imagen RGB, o sea, tengo 10,000 multiplicado por 3. Tengo montones, montones de datos. Eh, si yo quisiera clasificar estos píxeles y, o sea, tomo un píxel random cualquiera y digo, "Este píxel es montaña, este píxel es laguna, este píxel es nieve." Imagínense que son serían eh miles y miles de píxeles. Si ustedes se imaginan el el clátering jerárquico tendría 10,000 hojas o no sé cuánto. O sea, sería una locura decir, "Voy a clasificarlo con un pláter jerárquico." Sería inmanejable ese árbol. Pero si me voy al al camins, por ejemplo, digo, bueno, voy a hacerlo con camins, como yo no sé cuántas coberturas hay, eh, voy a estar haciendo camin con dos cluster, con tres cluster, con cuatro, con cinco, con de toda a mano y también es medio plomo, ¿no?

02:41:27

lse posgrados: Ir haciendo cuando no tengo idea cuántos clusters son. Entonces, una cosa que se puede hacer y que se hace, o sea, no no es un invento que a mí se me ocurrió, esto es algo que se hace, es combinar métodos. Acá en vez de tomar todos los píxeles de la imagen, se tomó una muestra de mils, o sea, una muestra salpicada de píxeles a lo largo de toda la imagen de 1000 píxeles. Y esos 1000 píxeles se clasificaron con Camins en 20 clases, en 20 clusters. Yo le digo a Camins, tomá los valores de estos 1000 píxeles y haceme 20 clusters. El Camíz me hace los

20 clusters y acá están pintados de 20 colores distintos. O sea, cada píxel fue a parar a una clase distinta de esas 20 clases y me quedó así que a simple vista y es una porquería, no me sirve para nada. Podría llegar a decir, bueno, estas estos lagos lagunas están acá. La clase verde y azul en realidad es todo lo mismo, pero después es realmente bastante desastre, ¿no? Esto es un esto no le sirve a nadie, pero es un paso.

02:42:29

Ise posgrados: O sea, tengo 20 clases ahora, no tengo una imagen así que no tengo ni idea qué hay. Tengo 20 clases. ¿Qué hago con estas 20 clases? Un cláuster jerárquico. Yo tengo acá las 20 clases. Fíjense acá abajo, son 20 valores con cláster jerárquico. Le digo, "Estas 20 clases, eh, haceme un cláter jerárquico." Me arma este arbolito, este dendrograma y a partir de acá yo le puedo decir, "Bueno, corto con esta línea horizontal." Digo, "Estas 20 clases, separamelas en dos." y me cortó acá y me separó acá en dos. Me fui al otro extremo. Esto no me sirve tampoco porque tengo esta clase que está acá, la clase siete, seguramente es esta estas cosas naranjas que si miro en la foto debe ser esta nieve y todo el resto de la imagen me lo mandó a otra clase, me lo agrupó todo en una bolsa. Entonces este dos no me sirve, pero yo puedo empezar a jugar porque ya tengo todo calculado. Entonces, puedo empezar a jugar.

02:43:25

Ise posgrados: Digo, bueno, dos no. Corto acá en tres y acá tengo tres colores. Tengo acá las nieves, acá las montañas y acá no sé qué. Digo, bueno, todavía me falta detalle, lo corto acá en cinco y acá ya empiezo a ver más cosas. Tengo la foto clasificada en capaz que cuatro, no sé, la nieve, la montaña y no sé, y la no sé las altas cumbres que no son nieve capaz y no sé como que ya empiezo a identificar coberturas. Esto es algo más o menos que ya me hace sentido de la foto. Esto era muy poco, no sirve para nada. Estas 20 clases es un montón, tampoco me sirve para nada. Pero yo acá que ya tengo todo calculado, puedo ir jugando con esa línea de corte para ver cuántos clusters a mí me sirven eh para clasificar los tipos de cobertura o los tipos de de eh suelo que yo veo en esa foto. Acá es un ejemplo real de aplicación y encima combinado de dos métodos diferentes. ¿Alguna pregunta? ¿Se entendió la idea del de cómo de cómo se usa acá? Bien. Bueno, ese era un ejemplito no más para que vean algo un poco diferente.

02:44:46

lse posgrados: Eso. Ahí. Listo. Eso es todo. Terminamos la clase de hoy. ¿Tiene alguna pregunta? ¿Alguna duda de lo que vimos de sus trabajos de otra cosa?
Alejandro Valle: Sí.
lse posgrados: No,
Alejandro Valle: ¿Cuándo serían las presentaciones?
lse posgrados: sí. ¿Cómo?
Alejandro Valle: Si es que hay ¿Cuándo
lse posgrados: Perdón, perdón. Presentaciones, no hay presentaciones. Eh, ustedes tienen que entregar el trabajo.
Alejandro Valle: serían?
lse posgrados: Eh, no me acuerdo la fecha, pero creo que es hasta tres días después del cierre de bimestre, que esto sería capaz que el no no sé exacto, pero por ahí la semana que viene lo lo recordamos. No sé si el lunes 27, debe ser 28 29 de abril.
Alejandro Valle: Okay. Solamente entregamos el K entonces.
lse posgrados: Sí. Sí. Solamente entregan el trabajo. Sí. Acuérdense las recomendaciones que vimos el otro día, ¿no? O sea, todo justificado, bien contado, ¿por qué hicieron eso? ¿Por qué eligieron los modelos? Conclusiones, o sea, no se olviden las conclusiones. Midan, comparen, usen un modelo de base y comparen contra es, uno o dos. Bueno, y comparen contra ese. Sí. Eh, cierre. Ah, eso lo vi. Domingo 26. Ah, yo te estaba regalando un día, dos días. Bueno, está bien. Por las dudas igual retomemos esto la semana que viene a ver si si realmente es esa fecha, pero bueno. Eh, la semana que viene es la última clase teórica es calibración de modelos y listo. La clase ocho es de consulta. ¿Está bien? ¿Me preguntas?
Cristian A. Aballay: No, no.
lse posgrados: Bueno, listo. Entonces, los libero. Buenas
Lucia T. Capon Paul: Chao. Buenas noches.
lse posgrados: noches,
Gabriel Quiroga: Gracias.
Luis Ali: Sí,
Agustin Biancardi: Ce
Luis Ali: gracias.
Pa. Santiago Rodriguez Castro: No seas.
Marcos Lund: Gracias.
Gabriela Sol Salazar: Och
Alejandro Valle: Buenas noches.
Leonardo Villalva: M.

La transcripción finalizó después de 02:46:39

Esta transcripción editable se ha generado por ordenador y puede contener errores. Los usuarios también pueden cambiar el texto después de que se haya generado.