📝 Las notas

abr 16, 2026

Aprendizaje de Máquina (7/8) - a242b25

Invitado facundolucianna@gmail.com macroldan@fi.uba.ar Aprendizaje de Máquina - CEIA 24Co2025

Archivos adjuntos Aprendizaje de Máquina (7/8) - a242b25

Registros de la reunión Transcripción Grabación

Resumen

La última clase cubrió la calibración del modelo como práctica fundamental después de una revisión del aprendizaje no supervisado, el debate sobre el K-Means y los modelos de mezcla gaussiana.

Repaso de Modelos de Clustering
Se revisó el aprendizaje no supervisado, enfocándose en el clustering, el cual encuentra agrupaciones de datos similares con la medición de la distancia. Se discutió el modelo K-Means, su proceso iterativo, y los desafíos en la determinación del número óptimo de clústeres (K).

Calibración y Medición de Modelos
Se enfatizó que la calibración asegura que las probabilidades predichas reflejen las frecuencias reales, un aspecto crucial para la toma de decisiones críticas. Los métodos de calibración, como Platt Scaling y Regresión Isotónica, son esenciales para modelos con discriminación alta pero mal calibrados.

Directrices para el Proyecto Final
La documentación de la estructura narrativa y la evolución del proceso del modelo, incluyendo la prueba de opciones alternativas, fueron

requisitos cruciales para el trabajo práctico. Se confirmó que el plazo de entrega es el 26 de abril.

Próximos pasos

- [ ] [Ise posgrados] Revisar Modelo: Revisar entrenamiento modelo para verificar la recalibración.
- [ ] [El grupo] Entregar Proyecto: Cerrar proyecto, entregar notebook con trabajo. Detallar proceso completo antes de 26 de abril a las 23:59.
- [ ] [El grupo] Conexión Clase: Conectarse a clase consulta solo si tienen dudas.
- [ ] [El grupo] Documentar Proceso: Estructurar notebooks con buen storytelling. Separar procesos lógicos, mostrando la evolución de modelos probados.
- [ ] [El grupo] Crear Baseline: Desarrollar un modelo heurístico base simple. Usar reglas lógicas de negocio para comparación de métricas posteriores.
- [ ] [El grupo] Incluir Conclusiones: Añadir una sección de conclusiones al trabajo final. Detallar qué se aprendió y si los resultados fueron suficientes.
- [ ] [El grupo] Llenar Encuesta: Dejar sugerencias accionables en la encuesta de fin de bimestre. Evitar comentarios vagos que impidan mejoras futuras.

Detalles

- **Introducción y Contexto de la Clase Final**: El inicio de la sesión marca la última clase, enfocándose en un tema que consideran muy relevante, aunque a menudo se omite en los planes de estudio de aprendizaje automático: la calibración de modelos (00:00:00). Se enfatiza que la calibración no es opcional, sino una práctica fundamental que se debe realizar siempre (00:10:01).
- **Repaso del Aprendizaje No Supervisado**: Se realizó un breve repaso de la clase anterior, que cubrió el aprendizaje no supervisado, en particular el **clustering** con diferentes técnicas (00:10:01). También se mencionó la **reducción de dimensionalidad** como la otra gran rama del aprendizaje no supervisado, y su objetivo es descubrir estructuras inherentes en los datos, a diferencia del aprendizaje supervisado que busca entrenar para un resultado específico (00:11:07).

- **Aplicación Tradicional del Clustering**: Un ejemplo clásico de aplicación del clustering es la **segmentación de clientes** (compradores) basada en su historial de navegación y compras. Al agrupar usuarios con comportamientos similares, se facilita la creación de algoritmos de recomendación (00:12:04).
- **Definición y Medición del Clustering**: El clustering se define como la técnica que permite encontrar agrupaciones de datos o clústeres, donde los grupos son similares entre sí y diferentes de otros grupos. Para medir esta similitud o diferencia, se requiere una **medida de distancia**; las distancias utilizadas son a menudo las mismas que se ven en el algoritmo KNN, como la distancia de Manhattan, aunque también se pueden usar métricas personalizadas (00:12:53).
- **Modelos de Clustering K-Means y Centroid Calculation**: Se repasó el modelo K-Means, el cual es el más popular y conocido (00:14:27). La lógica de K-Means implica calcular el centroide de cada clúster y luego encontrar la posición de los centroides que minimice la **suma de la distancia al cuadrado (inercia)** de todos los puntos de cada clúster con respecto a su centroide (00:15:13).
- **Proceso Iterativo de K-Means**: El proceso de K-Means es iterativo, comenzando con una asignación aleatoria de puntos a clústeres para obtener centroides iniciales. Posteriormente, los puntos se reasignan al centroide más cercano, y los centroides se recalculan hasta que la inercia alcanza un mínimo local, lo que puede requerir múltiples ejecuciones del algoritmo para encontrar un mejor valor (00:16:58).
- **Determinación del Número Óptimo de Clústeres (K)**: Un desafío en K-Means es definir la cantidad óptima de clústeres (K), ya que este parámetro no tiene técnicas de automatización tan sencillas como en otros modelos (00:18:28). Se mencionó el **método del codo** (Elbow method), que busca un cambio significativo en la caída de la inercia a medida que aumenta K, aunque se considera propenso a errores y poco riguroso (00:19:05) (00:21:11).
- **Otras Técnicas para Evaluar K**: Se presentaron otras técnicas, como la **silueta** (Silhouette), que ayuda a medir qué tan bien clasificado está un punto en su clúster y si tendría más sentido en otro (00:19:40). También se mencionó una técnica de **fuerza de predicción** (prediction strength) que utiliza *cross-validation* para automatizar la búsqueda del número de clústeres (00:21:11).
- **Modelos de Mezcla Gaussiana (Gaussian Mixture Models)**: Se revisaron los Modelos de Mezcla Gaussiana, que son interesantes porque no solo ubican clústeres, sino también una **distribución probabilística** gaussiana. Estos modelos permiten obtener la probabilidad de que un punto pertenezca a un

clúster y son capaces de manejar distribuciones con varianzas distintas, donde K-Means no funciona bien (00:21:56).

- **Ventajas de los Modelos de Mezcla Gaussiana**: Un beneficio adicional de estos modelos es su utilidad para la **generación de datos sintéticos**, al permitir simular datos basados en la distribución que capturan de los datos observados (00:23:19). Esto puede ser útil para expandir clases minoritarias en problemas de clasificación (00:24:02).
- **Clustering Jerárquico y Dendrogramas**: Se introdujo el Clustering Jerárquico como una alternativa que no requiere la elección previa de K (00:24:02). Este método construye una jerarquía mediante **dendrogramas** basados en similitudes entre puntos. Esta estructura jerárquica es útil para comprender cómo se ordenan y agrupan los datos, especialmente en campos como el lenguaje natural (00:25:06).
- **Transición al Tema de Calibración de Modelos**: La segunda parte de la clase se dedicó a la **calibración de modelos**, específicamente para clasificadores binarios (00:26:36). Se planteó el ejemplo de un clasificador de spam, donde una probabilidad predicha del 0.7 debería significar que el evento ocurre realmente el 70% de las veces (00:27:14).
- **Discriminación vs. Calibración**: La **discriminación** se refiere a qué tan bien un modelo separa las clases positivas de las negativas, lo que se mide con las métricas de clasificación habituales (00:28:59). La **calibración**, en cambio, se enfoca en si las probabilidades predichas por el modelo reflejan las frecuencias reales observadas. Un modelo puede discriminar bien pero estar mal calibrado, como cuando predice un 0.9 para positivos que solo ocurren el 40% de las veces (00:29:51).
- **Importancia de la Calibración en la Toma de Decisiones**: La calibración es crucial en escenarios donde la probabilidad del evento es más importante que la simple clasificación, como en **diagnósticos médicos**, evaluaciones de **riesgo crediticio** o en **vehículos autónomos** (00:30:34). Se presentó un ejemplo de riesgo crediticio donde un modelo no calibrado podría llevar a pérdidas financieras a largo plazo al subestimar la probabilidad de incumplimiento (00:33:39) (00:35:14).
- **Modelos Comunes con Calibración Deficiente**: Muchos modelos producen probabilidades "ingenuas" que no reflejan frecuencias reales, tendiendo a ir a los extremos (cercanos a 0 o 1) (00:36:44). El **Naive Bayes Gaussiano** tiende a ir a los extremos porque asume que las *features* son independientes, lo que infla las probabilidades (00:37:29). El **Support Vector Machine (SVM)** también sobreestima las probabilidades extremas porque

usa la distancia a la frontera y solo busca maximizar el margen, no la probabilidad (00:39:03).

- **Comportamiento de Calibración de Random Forest y Boosting**: El **Random Forest** tiende a ser "tibio", dando probabilidades bajas (cercanas a 0.5) porque promedia muchos árboles, lo que dificulta obtener valores extremos como 0.99 (00:40:34). Por el contrario, los modelos de **Boosting** (como Gradient Boosting) tienden a empujar rápidamente las probabilidades a los extremos (0.9, 0.01) debido a que encuentran reglas complejas que separan muy bien los casos (00:41:28).
- **Regresión Logística como Modelo Base Calibrado**: La **Regresión Logística** se destaca como un modelo que está **bien calibrado de base**. Esto se debe a que su diseño busca encontrar parámetros que maximicen la probabilidad de que las predicciones coincidan con las frecuencias observadas (00:42:22).
- **Medición de la Calibración con la Curva de Calibración y Brier Score**: Para evaluar la calibración, se utiliza la **curva de calibración**, que compara la probabilidad predicha con la frecuencia real. Si la curva se alinea con la diagonal, está bien calibrado (00:43:18). Esto se logra dividiendo las predicciones en *bins* y calculando el promedio de probabilidad y la fracción de positivos reales (00:44:16). El **Brier Score** es una métrica numérica que cuantifica qué tan lejos están las probabilidades de la realidad (un valor más cercano a cero es mejor), aunque mide tanto la calibración como la precisión, dificultando la comparación entre modelos diferentes (00:45:43).
- **Ejemplo Práctico de Calibración con Naive Bayes Gaussiano**: Se inició un ejemplo práctico usando un *dataset* de diagnóstico de tumores (benignos o malignos) (00:48:49). El modelo Naive Bayes Gaussiano tuvo un buen rendimiento en precisión (*score*) al separar las clases (00:50:58). Sin embargo, la curva de calibración mostró que el modelo estaba **bastante descalibrado**, con un Brier Score de 0.049 (00:51:48).
- **Impacto de la Descalibración en Diagnóstico Médico**: Se analizó el impacto de la descalibración en el ejemplo de diagnóstico: una predicción de 0.5 (azar) correspondía en realidad a una frecuencia de positivos del 0.7 (00:52:44). En un contexto médico, la diferencia entre una probabilidad del 50% y el 70% tiene un impacto significativo (00:53:45).
- **Preparación para la Calibración de Modelos**: Se señaló que el Naive Bayes Gaussiano mostró un comportamiento típico de producir probabilidades extremas. Se hizo una pausa antes de mostrar la comparación con modelos calibrados y modelos como Regresión Logística y Random Forest (00:54:28).

- **Introducción a la Calibración de Modelos**: Se revisó el concepto de calibración de modelos y la forma en que se mide, destacando que es una métrica adicional junto con técnicas como el gráfico de calibración. Se mencionó que el BR score tiene la particularidad de medir tanto la calibración como la discriminación, por lo que la curva de calibración es la mejor manera de evaluar si un modelo está bien calibrado (00:56:05).
- **Solución para Modelos Descalibrados**: La calibración de modelos descalibrados se logra mediante la creación de un modelo auxiliar que utiliza la salida o "score" del modelo original como *feature*. Este enfoque es útil porque no se limita a modelos que producen una probabilidad, sino a cualquier modelo que genere una puntuación, sin requerir que el modelo original haya sido entrenado específicamente con esa intención (01:07:38).
- **Entrenamiento del Modelo de Calibración**: Para entrenar el modelo de calibración, se puede utilizar un conjunto de datos diferente al de entrenamiento y evaluación, o se puede emplear la validación cruzada para evitar el sobreajuste (*overfitting*), aunque esta última opción es más lenta. Es crucial que el modelo de calibración sea entrenado en un conjunto de datos distinto para garantizar su efectividad (01:08:36).
- **Método de Calibración de Platt Scaling (Regresión Logística)**: Una de las técnicas de calibración es el *Platt scaling*, que consiste en aplicar una regresión logística a la salida del modelo original (01:08:36). Este método asume que la distribución de la salida cruda del modelo sigue una forma sigmoide y transforma la salida en una probabilidad mediante la optimización por máxima verosimilitud. El *Platt scaling* es un tipo de regresión logística con una sola *feature*, que es la salida del modelo (01:09:31).
- **Casos de Uso de Platt Scaling**: El *Platt scaling* funciona particularmente bien con modelos de máximo margen como las Support Vector Machines (SVM), ya que convierte distancias arbitrarias a la frontera de decisión en probabilidades. Este método permite que cualquier distancia o score arbitrario, incluso el valor de la distancia directa a la frontera en una SVM, se transforme para obtener una probabilidad calibrada (01:10:22).
- **Método de Calibración Isotónica (Regresión Isotónica)**: El segundo método de calibración es la regresión isotónica, que es un modelo no paramétrico que no asume una forma funcional específica para la salida, como la sigmoide (01:10:22). El único supuesto es que si la puntuación del modelo sube, la probabilidad real no debe bajar (es decir, debe ser monótonamente creciente). Este método ajusta una función escalonada que agrupa rangos donde la probabilidad empírica es similar y minimiza la diferencia entre la salida

predicha y la salida real al cuadrado, sujeto a la restricción de que las predicciones deben estar ordenadas (01:11:30).

- **Ejemplo Práctico de Regresión Isotónica**: Se ilustró la regresión isotónica con un ejemplo donde la monotonicidad se rompe, como cuando un score mayor no resulta en una compra real. Para resolver esto, el algoritmo promedio los valores adyacentes que violan la monotonicidad hasta que la curva de probabilidad resultante sea monótonamente creciente (01:13:42). Este proceso asegura que la función escalonada resultante sea consistentemente creciente (01:14:22).
- **Comparación de Platt Scaling e Isotónica**: Se señaló que el *Platt scaling* es adecuado para conjuntos de datos pequeños porque asume la forma sigmoide, mientras que la regresión isotónica requiere muchos datos para evitar pasos grandes en su función escalonada, pero tiene la ventaja de ajustarse a cualquier forma de distribución. El *Platt scaling* ajusta una sigmoide, mientras que la isotónica se ajusta a la forma de los datos mediante el promediado de valores (01:15:14).
- **Uso de Datos Sintéticos para Demostración**: Se generó un conjunto de datos sintéticos con cinco *features* informativas y cinco redundantes, invirtiendo el 2% de los valores de salida, para entrenar un modelo de regresión logística y un Random Forest. Esto permitió simular comportamientos complejos y utilizar el set de entrenamiento para calibrar los modelos mediante validación cruzada (01:16:01) (01:17:38).
- **Implementación de Calibración con Scikit-learn**: La calibración se puede realizar automáticamente con Scikit-learn, pasando el método deseado (sigmoide para *Platt scaling* o isotónica) (01:19:11). Se explicó que la calibración se puede hacer usando un set de calibración o validación cruzada, y la implementación por defecto verifica si el modelo ya está entrenado (01:20:24). Para la calibración con *Platt scaling* o isotónica, es crucial que el modelo base tenga el método `predict_proba` (01:20:58).
- **Análisis de Curvas de Calibración de Random Forest**: Se observó que la curva de calibración de Random Forest sin calibrar mostraba que el modelo tendía a ser "tibio" y sus distribuciones eran más amplias alrededor de 0.2-0.4, debido a que muchos árboles deben estar de acuerdo para alcanzar una alta probabilidad (01:23:34). Tras la calibración, especialmente con el método isotónico, las predicciones se acercaron mucho más a la diagonal ideal, lo que indica una mejor calibración (01:22:50).
- **Evaluación de Brier Score**: Al medir el Brier score, se observó que la regresión logística tenía un score peor (más alto) que el Random Forest calibrado, lo cual es de esperar, ya que el Brier score también mide la discriminación. Las

calibraciones con *Platt scaling* e isotónica para el Random Forest resultaron en valores muy cercanos y significativamente mejores que el modelo sin calibrar (01:24:38).

- **Aplicación en el Conjunto de Datos de Cáncer**: Aplicando la calibración a un modelo de Gaussian Naive Bayes en un conjunto de datos de cáncer, que inicialmente tendía a ser extremo en sus predicciones, la calibración isotónica distribuyó más los valores hacia el medio (01:26:17). Se logró una mejora en la métrica del Brier score (pasó de 0.5 a 0.03), aunque el modelo aún podría mejorarse, dado que la escasez de datos en la zona media del modelo original puede introducir variabilidad (01:27:09).
- **Calibración Multiclase**: Para problemas multiclase (no binarios), la calibración se aborda utilizando el enfoque *one versus rest*. Esto implica calibrar un clasificador para cada clase contra el resto, y luego normalizar las múltiples salidas para que la suma de las probabilidades resulte en uno (01:28:57). Se recordó que la calibración busca medir bien la incertidumbre, no necesariamente mejorar la clasificación (01:29:42).
- **Caso Práctico: Predicción de Tasa de Clic (CTR)**: Se presentó un caso práctico de predicción de la tasa de clic (CTR) para optimizar el retorno de inversión en publicidad digital, similar a la lógica de la predicción de préstamos (01:30:36) (01:33:14). Una predicción de probabilidad de clic precisa es crucial, ya que la oferta máxima en una subasta publicitaria se calcula como el valor del clic multiplicado por la probabilidad de clic (01:33:59). Una mala calibración del modelo puede llevar a pérdidas significativas, ya sea por subestimar y perder ingresos (Caso 1) o por sobreestimar y gastar dinero en impresiones inútiles, como bots (Caso 2) (01:34:40) (01:46:19).
- **Características del Problema de CTR**: Se detallaron las características utilizadas para la predicción de clics, las cuales incluyen datos de usuario (como recencia, historial de clics y poder adquisitivo estimado), calidad del anuncio (como coincidencia de palabras clave y fatiga creativa), y contexto técnico (como autoridad del dominio y tiempo de carga de la página). En este entorno, el tiempo de carga de la página es vital, ya que si es lento, el usuario podría irse antes de que se cargue el anuncio (01:36:04) (01:39:56).
- **Modelo Base de Máquina de Soporte Vectorial (SVM)**: En el escenario práctico, el equipo tenía un modelo de SVM que no proporcionaba salidas probabilísticas directas (01:41:35). Se tuvo que recurrir a una normalización manual mediante una sigmoide aplicada a la *decision function* (distancia a la recta) para obtener un *score* que se aproximara a una probabilidad (01:42:45).

- **Análisis de la Curva de Calibración del Modelo Base**: La curva de calibración inicial del modelo mostró distorsiones significativas, en forma de una S, lo que implica una mala calibración. En la zona baja, el modelo sobreestimaba la probabilidad real de clic (se pegaba al piso), y en la zona alta, subestimaba la probabilidad (se pegaba al techo), resultando en pérdidas de ingresos y presupuestos mal gastados (01:44:14) (01:46:19).
- **Resultados de la Calibración en el Modelo de CTR**: Tras aplicar tanto *Platt scaling* como regresión isotónica, se logró una mejora del 53% en el Brier score en comparación con el modelo original (01:47:45). Las curvas de calibración para ambos métodos se superpusieron y mostraron una mejora significativa con respecto al modelo base, lo que confiere más seguridad en la estimación de probabilidades en producción (01:48:53).
- **Contexto y Cierre de la Calibración**: Se reiteró que la calibración solo es esencial en situaciones donde la probabilidad predicha influye directamente en decisiones críticas, como inversiones, vidas humanas, o cualquier escenario con un retorno económico a largo plazo (01:51:23). Se enfatizó que el calibrar el modelo no es un requisito para el proyecto final de la materia, aunque es valorado si lo realizan (01:52:17).
- **Finalización del Contenido del Curso y Próxima Sesión**: Se anunció el fin del contenido de la materia. La próxima clase será exclusivamente de consulta, sin asistencia obligatoria, para abordar dudas sobre la realización del trabajo práctico (01:53:06).
- **Fecha Límite del Trabajo Práctico**: Se confirmó que la fecha límite para la entrega del trabajo práctico es el domingo 26 de abril a las 23:59, dando tiempo adicional a los estudiantes. El trabajo práctico será evaluado por el proceso completo de solución de un problema, presentado en un *notebook* (01:54:27).
- **Revisión del Dataset y Consigna de Entrega**: Los participantes ya eligieron su *dataset* y se confirmó que casi todos enviaron su selección, aunque el orador de *Ise posgrados* no revisó si lo hicieron todos. Respecto a la entrega, Alejandro Valle preguntó si es necesario un documento formal o si es suficiente con explicar el proceso en los *notebooks* mediante *markdown* (01:55:10). La respuesta fue que el método queda a discreción del estudiante, siempre que la comunicación del resultado sea efectiva, pudiendo utilizar el *notebook* como un informe bien explicado o un documento separado, según se considere la mejor forma (01:55:49).
- ****Estructura Narrativa (*Storytelling*) del Trabajo****: Se hizo hincapié en que la narración (*storytelling*) es crucial y que el trabajo debe documentar cómo se desarrolló el proceso, incluyendo qué modelos se probaron y cómo se

evolucionó hasta el modelo final (01:56:27). Si un solo *notebook* resulta ser demasiado extenso (*bodoque*), se recomienda separarlo en varios con una lógica clara, como 'primer modelo', 'segundo modelo', etc., para que la lectura sea comprensible. Es importante incluir modelos alternativos probados porque el desarrollo de modelos en la vida real implica probar varias opciones antes de seleccionar la mejor (01:57:07).

- ****Importancia de la Selección de Features y el *Baseline*****: Se subrayó la importancia de documentar cualquier selección de *feature* nueva o modificaciones que hayan afectado las métricas. Se recordó la necesidad de establecer un *baseline* o línea base, que no debe ser un modelo complejo de los vistos en clase, sino una heurística basada en la lógica y el análisis de los datos que represente la predicción mínima esperada (01:57:49). Este *baseline*, aunque sea simple, sirve como la métrica fundamental para comparar y justificar si los modelos más sofisticados aportan una mejora significativa (01:58:32).
- ****Definición y Ejemplos de *Baseline*****: Hubo una discusión sobre si la regresión logística puede considerarse un *baseline*, con *Ise posgrados* aclarando que un *baseline* debe ser más simple que un modelo como la regresión logística, pues esta última ya implica una interacción y aprendizaje de *features* (01:58:32) (02:00:09). El *baseline* ideal es una regla heurística o una lógica simple, como una correlación con una variable. Ejemplos de *baselines* incluyen usar la mayor ocurrencia de una clase en problemas de clasificación o, en problemas de *forecasting*, predecir las ventas de hoy basándose en las ventas de ayer o de hace siete días (02:00:42) (02:02:00).
- **Criterios de Éxito y Conclusiones del Proyecto**: Se reiteró que el objetivo del *baseline* es servir como punto de comparación; si un modelo no mejora la predicción de la línea base, no vale la pena (02:02:20). En cuanto al contenido del trabajo, se mencionó que la calibración de probabilidad es opcional y que la inclusión de *Feature Importance* (importancia de las *features*) no es requerida por la materia, aunque es un plus si se investiga (02:03:02). La parte final del trabajo debe incluir conclusiones claras, reconociendo que no siempre se alcanza un resultado perfecto o el "camino feliz", y que una conclusión negativa (la necesidad de mejores *features* o más trabajo) también es válida (02:03:59).
- **Despedida y Anuncios Finales de la Materia**: *Ise posgrados* recordó que esta es la última clase de contenido y que la próxima sesión será solo de consulta, instando a los estudiantes a organizarse en grupo y venir con sus dudas ya preparadas (02:04:48). Se destacó que los modelos de *boosting* (como XGBoost, LightGBM y CatBoost) suelen tener muy buen rendimiento, aunque se anima a los estudiantes a construir su base de conocimiento, ya

que en futuras materias verán modelos más sofisticados como *deep learning* (02:06:32). Finalmente, se hizo un pedido especial para dejar sugerencias "accionables" en la encuesta de fin de bimestre si hay algo que mejorar en la materia (02:08:09).

- **Tratamiento del Trabajo Individual y Agradecimientos**: E. Alan Cornejo consultó sobre la obligatoriedad de trabajar en grupos mínimos de dos personas, ya que ellos estaban sin compañero, a pesar de haber elegido un *dataset* (02:09:35). Se les permitió trabajar en solitario, aunque se les instó a avisar con antelación en el futuro (02:09:58). Varios participantes, incluyendo a Mariano Jauffroy y Cristian A. Aballay, agradecieron por la cursada (02:08:36).

Revisa las notas de Gemini para asegurarte de que sean precisas. Obtén sugerencias y descubre cómo Gemini toma notas

*Cómo es la calidad de **estas notas específicas?** Responde una breve encuesta para darnos tu opinión; por ejemplo, cuán útiles te resultaron las notas.*

📖 Transcripción

16 abr 2026

Aprendizaje de Máquina (7/8) - a242b25 - Transcripción

00:00:00

lse posgrados: Buenas, Buenas,
Jose Miguel Silva: Buenas, Buenas,
lse posgrados: Hola, Hola,
Pa. Santiago Rodriguez Castro: Gracias. Gracias.
lse posgrados: Bueno, Bueno, estamos estamos en en hora hora más más un un poquitos. poquitos. Ahora Ahora sí. sí. Bueno, Bueno, estamos estamos en en la la última última clase. clase. Eh, Eh, ¿qué ¿qué está está haciendo? haciendo? ¿Qué ¿Qué hacemos? hacemos? ¿Qué ¿Qué hacemos? hacemos? ¿Qué ¿Qué hace hace el el bicho bicho este? este? Eh, Eh, ah, mira, pon pon. yo Yo no no quería quería hacer hacer eso. eso. Ahora. Bueno, Bueno, eh eh, como como les les decía, decía, estamos estamos la la última última clase, clase, la la clase clase, dos dos clase clases, estaban estaban listos listos para para ese ese trabajo trabajo final. final. tuvieron tuvieron la la clase clase pasada pasada con con Karina Karina a a pesado.

00:10:01

lse posgrados: pesado. Y Y hoy hoy vamos vamos a a ver ver un un tema tema super super interesante interesante que que está está bueno bueno verlo, verlo, que que generalmente generalmente no no se se lo lo da da muchas muchas currículas currículas de de de de aprendizaje aprendizaje de de máquina máquina y y que que está está a a verlo, verlo, pero pero no no es es una una no no es es algo algo que que es es un un más, más, es es algo algo que que tenés tenés que que sí sí o o sí sí hacer hacer siempre, siempre, ¿no? ¿no? Vamos Vamos a a ver ver ahora ahora el el contexto contexto tiene tiene sentido sentido en en la la idea idea de de calibrar calibrar números. modelos. Antes Antes que que pasemos pasemos a a a a la la clase, clase, digamos, digamos, vamos vamos a a hacer hacer un un repaso repaso de de lo lo que que vimos vimos la la clase clase pasada. pasada. Eh, Eh, vimos vimos eron, eron, digamos, digamos, eh eh aprendizaje aprendizaje no supervisado, supervisado, particularmente particularmente clustering clustering con con diferentes diferentes técnicas técnicas de CL. de entiendo entiendo que que en en

análisis análisis de de datos datos o o sí sí verán están están viendo viendo o o vieron vieron e e vieron vieron el pasado pasado, estim, estre, ¿cómo ¿cómo se se llama llama?

00:11:07

lse posgrados: el el tema tema de de eh reducción reducción de de dimensionalidad, dimensionalidad, que que es es otro otro gran gran tema tema de de presaje presaje no no supervisado. supervisado. Básicamente Básicamente la las dos dos grandes grandes ramas. ramas, lo Lo similar similar a a lo lo que que es es revisión reacción y y clasificación clasificación de de aprendizaje aprendizaje supervisado supervisado es es eh eh ser ser digíamos digíamos clastering clasering y y reducción reducción dimensionalidad dimensionalidad a a veces veces que que no no supervisado. supervisado. Hay Hay otras otras eh eh temas temas también también de de personajeado, personajeado, pero pero son son como como las las dos dos grandes grandes áreas áreas que que se se llevan llevan la la mayoría mayoría de de las las cosas. cosas. La La idea idea de de para para qué qué usamos usamos aprendizaje aprendizaje superizado, superizado que que lo lo hemos hemos visto visto eh eh también también inteligencia inteligencia artificial, artificial este este tema tema es es cuando cuando yo yo quiero quiero buscar buscar o o quiero quiero descubrir descubrir estructuras estructuras que que hay hay inherentes inherentes en en mis mis datos. datos, Bien, o o sea, sea, no no es es el el caso caso del de presaje superado superizado donde donde yo yo quiero quiero eh eh entrenar entrenar algo algo para para un un resultado, resultado, sino sino quiero quiero encontrar encontrar esa esa estructura.

00:12:04

lse posgrados: estructura. Eso Eso lo lo que que habamos visto visto la la clase clase pasada. pasada. El El clásico clásico ejemplo ejemplo que que está está ahí ahí es es uno uno de de los los ejemplos ejemplos más más tradicionales tradicionales que que se se usa usa cuando cuando yo yo quiero quiero segmentación segmentación de de clientes, clientes, en en este este caso caso de de compradores, compradores, en en base base a a su su historial historial de de navegación navegación y y compras compras similares. similares. Si Si yo yo logro logro encontrar encontrar que que hay hay usuarios usuarios que que se se comportan comportan de de forma forma similar, similar, puedo puedo armar armar claster claster de de esos esos y y después después puedo puedo hacer hacer

fácilmente fácilmente un un algoritmo algoritmo de de recomendación recomendación en en me me fijo fijo quiénes quiénes son son similares similares a a estos estos usuarios usuarios y y bueno, bueno, me me fijo fijo que que compraron compraron los los otros otros usuarios, usuarios, pero pero tiene tiene este este y y bueno, bueno,
Pa. Santiago Rodriguez Castro: Yeah. Yeah.
lse posgrados: te te recomiendo recomiendo los los otros otros usuarios. usuarios. Entonces Entonces de de eso eso eh eh es es una una técnica técnica tradicional tradicional o o muy muy típica típica que que se se usa usa de de esta esta técnica.

00:12:53

lse posgrados: técnica. Lastering Lastering es es este este una una como como dicho dicho, una una de de las las ramas ramas que que queizado queizado que que es es técnicas técnicas que que nos nos permiten permiten esto esto encontrar encontrar cler clúster de de grupamientos grupamientos de de datos. datos. La La idea idea es es esta esta como como dice dice la la definición definición ahí ahí que que han han visto visto la la clase clase pasada pasada que que es es okay okay grupos grupos que que sean sean similares similares entre entre sí sí y y que que sean sean diferentes diferentes a a otros otros grupos. grupos. El El tema tema está está en en la la gran gran diferencia diferencia de de qué qué es es eh eh similar similar y y qué qué es es diferente diferente y y para para eso eso eh eh no no lo lo puse puse me me iba iba a a acordar acordar el memoria. mor. Ah, Ah, está está acá. acá. Eh, Eh, para para eso eso necesitamos necesitamos una una medida medida de de distancia distancia o o algo algo que que nos nos permita permita medir medir esa esa similitud similitud y y diferencia, diferencia, el el cual cual tranquilamente tranquilamente podemos podemos usar usar para para para para medir medir distancias distancias similitud.

00:13:43

lse posgrados: similitud. Las Las mismas mismas distancias distancias que que vimos vimos para para KNN. KNN. Y Y en en efecto efecto que que más más se se usa, usa, ¿no? ¿no? La La que que más más se se usa usa es es la la instancia distancia de de digamos digamos llamab llamab de de la la no no importa importa ese Manhattan Manhattan son son las las dos dos más más usadas.
lse posgrados: ¿Cómo ¿Cómo se se llamaba?
lse posgrados: usadas.

lse posgrados: llamaba? ¿Cuál? ¿Cuál?
lse posgrados: La La la la genérica, genérica, la la
lse posgrados: Ah, Ah, la la genérica,
lse posgrados: min, minas,
lse posgrados: genérica, la la Sí.
lse posgrados: o o sea, sea, la la genérica genérica con con algún algún P P típico, típico, P1 P1 o o P2, P2, son son más más adelante las las dos dos distancias distancias más más usadas usadas que que hay, hay, pero pero bueno, bueno, recuerden recuerden que que la la idea idea es es algo algo que que nos nos permita permita medir medir esa esa esa esa distancia.

00:14:27

lse posgrados: instancia y Y en muchos muchos casos casos vamos vamos a a tener tener algo algo que que tenga tenga sentido sentido geométrico geométrico para para estas estas distancias, distancias, pero hay pero muchas hay muchas veces veces que que no no cosas cosas que que no no tienen tienen un sentido un sentido geométrico geométrico y y la la similitud similitud de de distancia distancia va a estar va a dado estar dado por por otra otra métrica métrica que puede que ser puede ser realmente realmente custom custom armada armada para para ese ese caso. caso. Eh, Eh, en base en base a esa a esa distancia distancia había, había, bueno, bueno, hay hay varios varios modelos modelos que que nos nos permiten permiten hacer hacer clasterings. clasterings. Eh, bueno, base Bueno, a distancia distancia no no distancia distancia las vamos las a vamos cambiar a cambiar simitud simitud diferencia. diferencia. Eh, básicamente el vimos Camins camins y y modelo modelo de de mistura mentura causiana. causiana. El de El de Camins Camins es es eh eh el el más más conocido, conocido, el más el más usado, usado, el el más más popular, popular, es el es más el más sencillo sencillo inclusive inclusive de de de de pensar. pensar.

00:15:13

lse posgrados: La La idea idea es es arar arar clúster clúster de, de, o o sea, sea, como cuando tenemos tenemos un un clúster, clúster, calcular calcular el el centroide centroide y y sobre sobre ese ese centroide centroide calcular calcular las las distancias distancias de de los los puntos. puntos. La La idea idea es es calcular, calcular, encontrar encontrar para para una una para para una una como como hiperparámetro hiperparámetro definido, definido, cantidad cantidad de de claster

claster que que quiero quiero obtener, obtener, encontrar encontrar la la digamos digamos la la posición posición de de estos estos este este de de estos estosid droides y y por por consiguiente consiguiente formación formación de de clusters clusters que que minimicen minimicen esta esta suma suma intracuster, intracustter, que que fíjense fíjense que la que suma la suma intercustter intercustter es es simplemente simplemente la la distancia distancia eh eh la la suma suma de de distancia distancia al al cuadrado cuadrado de de todos todos los los puntos puntos de de cada cada cluster cluster con con respecto respecto al al centroide. centroide. Entonces Entonces calculamos calculamos eso eso y y fíjense fíjense que que digo, digo, esa esa distancia, distancia, este este caso caso es es está está claramente claramente está está usando usando la la distancia, distancia, ¿bien?

00:16:10

lse posgrados: ¿bien? O sea, O sea, si si estamos estamos usando usando distancia distancia cuadrado cuadrado esana. esana. Obviamente Obviamente esta esta fórmula fórmula cambiaría cambiaría si si usáramos usáramos otra otra distancia, distancia, media media de de distancia. distancia. Y Y la la forma forma en en que que lo lo que que queramos queramos minimizar minimizar es es esa, esa, es decir decir, ese ese esa esa distancia distancia entre entre ese ese distancia distancia entre entre clas clas minimizar minimizar y y eso lo eso que lo se que llama se llama como como inercia. inercia. habrá habrá encontrado encontrado muchas muchas veces veces muchas muchas las las documentas documentas es es minimizar minimizar este este valor valor la la sumatoria sumatoria de de tod tod todos todos los los clásters, clásters, el el el el valor valor de de mos mos cláter cláter es es ese ese proceso proceso que que vamos vamos a a ir ir generando generando para para que que llegu llegu a a encontrar encontrar la la ubicación ubicación de de los los introdid o entrers de los cláster que que mejor mejor que que minimicen minimicen este este valor. valor. Entonces Entonces es es un proceso un proceso iterativo iterativo que que arranca arranca con con los los datos.

00:16:58

lse posgrados: datos. Lo que Lo que hace hace para para poder poder arrancar arrancar y poder y arrancar arrancar a un a un lado, lado, que arrancar que arrancar de un de un lado, lado, automáticamente automáticamente asigna asigna cada cada punto punto un un a qué a qué clase clase pertenece. pertenece. En este En este caso caso fina, fina, verde verde y y azul. azul. Deci Deci la azar. azar. Con Con eso

eso obtiene obtiene los los primeros primeros entroides entroides que que probablemente probablemente van a van estar a estar medio medio cerquitas cerquitas del del estado estado por porque elegió eligió el el azar azar deses deses esperado, esperado, pero pero va a va haber a haber más más de de uno uno otro otro por por simple simple para un para lado. un lado. Entonces Entonces van van a hacer a hacer que que los los centrales centrales estén estén uno uno más más arriba, arriba, más más izquierdo, izquierdo, derecha. derecha. De De ahí ahí va va ahora ahora sí sí usando usando la la distancia distancia entre entre clusters, clusters, eh, eh, la la distancia distancia distancia distancia del del clúster, clúster, eh, eh, sí, sí, distancia distancia el el cláter cláter va a va volver a volver a a reaccioninar reaccioninar a a los los a a los los puntos puntos al al al al plaster plaster que que pertenezca pertenezca al al centro centro de más de más cercano cercano a a ellos.

00:17:46

lse posgrados: ellos. Entonces Entonces todo todo esto esto viene viene arriba arriba que que rosa, rosa, celeste celeste, y todos todos verdes. verdes. Luego Luego vuelve vuelve a a calcular calcular los los centroides, centroides, calcula calcula el el el el la inercia laer esa y sigue y sigue el el proceso proceso activo activo hasta hasta que llegue que llegue un mínimo. un mínimo. Básicamente Básicamente va por va un por un gradiente gradiente descendiente descendiente se se pensar pensar y y va va llegando llegando al al mínimo mínimo y y llega llega un punto un punto y y termina termina ahí. ahí. Bien, Bien, donde donde tiene tiene una una vez se vez puede se puede quedar quedar al mínimo al mínimo local. local. Por Por eso eso eh a eh veces a veces se se recomienda recomienda hacer hacer varias varias dicciones dicciones de de ese ese algoritmo, algoritmo, porque porque puede puede para para ver ver partir partir de de lugares lugares distintos distintos a ver a si ver si llegamos llegamos a a una una eh eh menor menor valor valor de de de de este este de esta de esta inercia. inercia. es es muy muy es muy es muy sencillo sencillo y muy y muy sencillo sencillo inclusive inclusive de de implementarlo.

00:18:28

lse posgrados: implementarlo. Si ustedes Si ustedes lo lo pueden pueden hacer hacer en en código código muy muy poco poco tiempo, tiempo, en un en un día se día se sientan sientan y lo y lo sacan sacan en dos en dos para cada para cada un un camín camín básico básico perreta, perreta, ¿no? ¿no? Obviamente Obviamente no

no es es con con todas las todas las optimizaciones optimizaciones y y todo todo dando dando vueltas, vueltas, pero pero algo algo que que hace hace esta esta interacción interacción es es relativamente relativamente sencillo sencillo de de implementar. implementar. El El tema tema está está en en el que el que vieron vieron es, es, okay, okay, cuántos cuántos clases voy a voy a usar, usar, cuántos cuántos voy a voy a poner poner y y es es un un tema tema bastante bastante es es un un parámetro parámetro que que además además no no hay hay no no hay hay técnicas técnicas tan tan cómodas cómodas o o automatizables automatizables como como el el caso caso que que vimos vimos en la pizzado. superado. Entonces, Entonces, habíamos habíamos visto visto que que estaba estaba el el método método del del codo, codo, en en el el cual cual básicamente básicamente hacemos hacemos esto.

00:19:05

lse posgrados: esto. Vamos Vamos midiendo midiendo este este esta inercia inercia a a medida medida de de diferentes diferentes números números de de clusters clusters y y vamos vamos viendo viendo cómo cómo baja, baja, porque porque obviamente obviamente hay hay un un punto punto donde donde este este valor valor de de inercia inercia hace cero. cero. Hay Hay hay hay un un punto punto muy muy obvio obvio que que va va a a ser ser cero cero que que va va a a ser ser en en cual cual tenga tenga tantos tantos cluster cluster como como datos datos tengan. tengan. Si Si yo yo tengo tengo 10, 10, simplifica simplifica 100 100 puntos. puntos. Si Si tengo tengo 100 100 cluster, cluster, cada cada punto punto va va a a ser ser un un cluster. cluster. Entonces Entonces la la inercia inercia hace hace cero cero porque porque la la distancia distancia contra contra contra contra el el cluster cluster hace hace cero. cero. Entonces Entonces no no puedo puedo encontrar encontrar un un valor valor mínimo, mínimo, o o sea, sea, no no uso uso el el K K con con los los valor valor mínimos. mínimos.

00:19:40

lse posgrados: Entonces Entonces tengo tengo que que buscar buscar el el método método del del codo. codo. Es Es un un método método de de buscar buscar en en donde donde yo yo veo veo que que hay hay un un cambio cambio significativo significativo en en este, este, fíjense fíjense en en que que acá acá como como que que el el cambio cambio acá acá es es fuerte. fuerte. Así Así bueno, bueno, listo. listo. Definir Definit cinco, cinco, pero pero esto esto es es s s propenso propenso a a

a a errores errores también. también. Uno Uno tranquilamente tranquilamente podría podría ser ser el el tres tres también también podría podría haber haber significado significado un un cambio cambio en en tendencia. tendencia. Entonces, Entonces, bueno, bueno, puedo puedo usar usar el el tres tres bien bien también también eso eso las la clases clase pasadas. pasada. Eh, Eh, entonces entonces hay hay otras otras técnicas técnicas como como dice dice la la silueta silueta que que sería sería también también bueno bueno que que tiene tiene siluetas siluetas que que además además te te permite permite ver ver no no solo solo e e si si los los gastos gastos son son son si si está está bueno bueno también también es es te te permite permite ver ver cuáles cuáles fueron fueron mal mal clasificados clasificados para para este este índice.

00:20:26

lse posgrados: índice. índice índice mide, mide, digamos, digamos, básicamente básicamente las las dos dos cosas cosas que que es es eh eh si si un un punto, punto, o o sea, sea, que que tan tan sentido sentido tenga tenga que que ese ese que que ese ese punto punto sea sea de de de de ese ese clúster clúster y y eh eh que que tanto tanto sentido sentido tendría tendría que que estuviera estuviera en en otro otro en en otro otro cláser. cláser. Por Por ejemplo, ejemplo, y y todo todo lo lo que que son son negativos, negativos, índices índices negativos negativos de de la la silueta, silueta, nos nos está está indicando indicando que que estos estos puntos puntos para para este este índice índice tendrían tendrían más más sentido sentido que que pertenezcan pertenezcan a a otro otro clan, clan, ¿no? ¿no? se Se nos nos puede puede dar dar una una idea idea de de esa esa idea, idea, también también nos nos puede puede dar dar una una idea idea de de tamaño. tamaño. Entonces, Entonces, voy voy a a hacer hacer acá acá las las gráficas. gráficas. Fíjense, Fíjense, cada cada línea línea de de estas estas sería sería un un punto punto del del clúster clúster y y cuando cuando más más grande grande más más en en ese ese en en ese ese valor valor cuando cuando más más cercano cercano cero cero menos menos y y negativo negativo es es que que el otro,

00:21:11

lse posgrados: pero Pero yo yo después después puedo puedo calcular calcular un un valor valor promedio promedio tengo tengo acá acá que que puedo puedo con con eso eso hacer hacer también también un un cálculo cálculo y y encontrar encontrar donde donde es es máximo. máximo. No No me me acuerdo acuerdo si si

hacend hacend máximo máximo y y ahí ahí elegí elegí también. también. Hay Hay otra otra técnica técnica eh eh que que la la dejé dejé que que es es la la fuerza fuerza de de predicción, predicción, que que a a mí mí me me encanta, encanta, que que es es una una técnica técnica relativamente relativamente moderna moderna que que intenta intenta eh eh usar usar técnicas técnicas de de cross cross validation validation para para hacer hacer también también búsqueda búsqueda de de cuántos cuántos clusters clusters y y ese ese bueno bueno es que que yo yo lo lo puedo puedo automatizar, automatizar, yo yo puedo puedo hacer hacer un un algoritmo algoritmo que que lo lo corre corre automático automático usando usando esas esas matrices matrices de de conexión conexión y y y y haciendo haciendo esos esos cálculos, cálculos, puedo puedo tener tener una una forma forma mucho mucho más más sistemática sistemática que que el el método método del del codo, codo, que que para para mí mí es es aberr aberr que que les les diga diga Pero Pero bueno, bueno, a a veces veces no no te te queda queda otra otra cosa cosa de de ese método, método, pero pero es es como como todo todo lo lo que que hay hay un un humano humano diga, diga,

00:21:56

lse posgrados: a a mí mí me me parece, parece, no, no, me me parece parece que que no no es es muy muy muy muy muy serio seria la la cosa, cosa, ¿no? ¿no? Pero Pero bueno, bueno, eh, eh, es es lo lo que que hay. hay. Después Después vemos vemos lo lo vieron vieron los los modelos modelos de de mistura mistura que que son son buenísimos, buenísimos, los los modelos modelos son son super super interesantes interesantes porque porque obviamente obviamente intentan intentan ubicar ubicar ahora ahora no no solo solo una una los los cler, cler, sino sino también también una una distribución, distribución, ¿no? ¿no? Intenta Intenta se se basa basa en en una una una una distribución distribución probabilística. probabilística. gauciana, gauciana, digamos, digamos, ubica ubica de de Gaut, Gente literalmente ahí, ahí, eh eh y y con con eso eso también, también, o o sea, sea, no no solo solo nos nos da da información información también, también, ¿qué ¿qué es es tan tan probable probable que que pertenezca pertenezca ahora ahora puedo puedo tener tener probabilidades? probabilidades? Entonces, Entonces, eso también también está está buenísimo.

00:22:35

lse posgrados: buenísimo. Voy Voy más más rápido, rápido, 17 17 horas, horas, eh,

eh, pero pero digamos digamos da da esos esos esos esos castill castill además además permiten permiten situaciones situaciones como como esta esta en donde donde las las distribuciones, distribuciones, digamos, digamos, las las varianzas varianzas son son distintas, distintas, donde donde camisa, camisa acá no no nos le le va va muy muy bien. bien. Este Este tipo tipo de de modelos modelos le le puede puede dependiendo dependiendo qué qué qué qué variancia variancia usemos, usemos, cómo cómo usemos usemos la la forma forma que que usamos usamos el el modelo, modelo, puede puede capturar capturar este qué tipo tipo de de comportamiento comportamiento y y lograr lograr eh eh claster claster este este tipo tipo de de situaciones. situaciones. Y Y como como ven, ven, fíjense fíjense ahí ahí los los puntos puntos que que están están viendo viendo que que está está medio medio medio medio todos todos iguales. iguales. Este Este punto punto una una idea idea de de eso. eso. El El tamaño tamaño de de los los puntos puntos técnicamente técnicamente es es que que tan tan poco poco probable, probable, o o sea, sea, la la probabilidad probabilidad fí fí es es menos menos probable probable que que sea sea el el verde verde que que este este punto punto de de acá acá en en el el centro,

00:23:19

lse posgrados: centro, no no es es como como que que eso eso está está incarado incarado el el tamaño. tamaño. Entonces Entonces está está bueno bueno ese ese tipo tipo de de cosas cosas y y además además que que tiene tiene otro otro plus plus tipo tipo de de modelos modelos que que no no es es solo solo para para hacer hacer clastering, clastering, sino sino también también para para hacer hacer simulaciones. simulaciones. Yo quiero hacer hacer datos datos sintéticos sintéticos basado basado en la en la distribución distribución de de datos. datos. unos unos gatos gatos que se que se mearon mearon a un a un lado lado con con cierta cierta estructura estructura produce pued el uso el modelo modelo de de mixtura mixtura gausiana gaociana que que logre logre capturar capturar usando usando diferentes diferentes números números de de de de clastro, clastro vamos a vamos a decir decir diferentes diferentes distribuciones distribuciones que que armen armen la la estructura estructura de de ese ese de esa de esa distribución distribución que que yo yo quiero quiero estoy estoyendo en mitad en mitad y después y después la la puedo puedo usar usar para para generar generar datos datos y me y va me a va a generar generar si si yo yo genero genero datos datos voy a voy a generar generar datos datos sintéticos sintéticos que que tiene tiene un un comportamiento comportamiento similar a los los datos datos que que obtuve, obtuve, digamos.

00:24:02

Ise posgrados: digamos. Entonces Entonces está está bueno bueno para para cuando cuando uno uno quiere quiere expandir expandir o o hacer hacer tipo tipo de de cosas cosas de de de trabajo, trabajo, no no sé, sé, clasificación clasificación y y yo yo quiero quiero aumentar el el una una de de las las clases clases que que está en está minoritaria, Italia, bueno, bueno, puedo puedo hacer hacer algo algo de de eso eso con con o o entre entre ciertos ciertos cuidados, cuidados, no no no las las mandemos mandemos a a veces veces tenemos tenemos que que hacerla hacerla bien bien ese ese trabajo trabajo podemos podemos fácilmente fácilmente meter meter eh eh y y que que diferentes diferentes cosas. cosas. Entonces Entonces tenemos tenemos que que trabajar trabajar bien bien eso análisis análisis de datos. datos. Entonces Entonces si si lo lo hacen hacen como como como como les les enseño análisis análisis de de dato datos hacer hacer las las cosas cosas no no van van a a tener tener problema. problema. Y Y el el último último que que es es un un modelo modelo que que okay todos estos estos otros otros todos todos tenemos tuvemos tuvos que que definir definir cuántos cuántos clas clas usar. usar. Vimos Vimos otro otro tipo tipo de de de de modelos modelos que que dec, dec, bueno, bueno, listo, listo, buscamos buscamos alguno alguno que que yo yo no no tenga tenga que que indicar indicar cuánto cuánto que que yo yo pueda pueda ver, ver, que que buscar buscar en en un un punto punto algo algo que que que que me me permita permita de de cierta cierta forma forma eh eh tener tener como como prearmado prarmado cierta cierta jerarquía jerarquía y y de de esa esa forma forma ver ver en en dónde dónde puedo puedo elegir elegir sin sin tener tener

00:25:06

Ise posgrados: que que tener tener previamente previamente elegir elegir un un número, número, probar probar y y ver. ver. Bien. Bien. Y Y eso eso es es lo lo que que hace hace eh H Castarma castarma esta esta jerarquía jerarquía usando usando los los delogramas, delogramas, usando usando simplemente simplemente similitudes similitudes entre entre diferentes diferentes puntos puntos y y te te va va armando armando esta esta estructura estructura de de cómo cómo se se va va sepando separando y y genera genera tú tú una una estructura estructura de de jerarquía jerarquía que que es es super super interesante interesante y y hay hay ciertos ciertos casos casos de de uso uso que que son son muy muy buenos buenos esas ideas ideas porque porque a a veces veces no no solo solo querés querés saber saber eh cómo cómo están están agrupados agrupados los los datos, datos, sino sino también también cómo cómo están están ordenados ordenados y y eso eso hay hay mucho mucho. eso en En el el lenguaje lenguaje natural natural ocurre

ocurre mucho mucho cuando cuando yo yo tengo tengo representaciones representaciones de de cosas cosas y y yo yo quiero quiero Quiero entender entender cómo cómo se se ordena. ordena. Entonces, Entonces, imagínense imagínense eh eh yo yo la la palabra palabra fútbol fútbol y y deportes deportes son son dos dos palabras palabras que que son son similares, similares, o sea, las las puedo puedes poner poner en en un un cláter, cláter, pero pero además además hay hay jerarquía, jerarquía, o o sea, sea, deporte, deporte, fútbol fútbol es es parte parte del del deporte, deporte, digamos.

00:25:54

lse posgrados: digamos. Ese Ese tipo tipo de de modelo modelos como como clastering clastering te te permite permite encontrar encontrar esas esas estructuras estructuras un un poco poco más más complejas complejas que que no no solo, solo, simplemente simplemente como como están están clasterizadas, clasterizadas, yo yo puedo puedo armar armar el el árbol árbol del delogramo, tecnograma mejor mejor dicho, dicho, y y con con eso eso puedo puedo eh eh en en efecto efecto tomar tomar ese ese tipo tipo de de de de análisis análisis y y entendimiento entendimiento de de mis mis dados. datos. Y Y bueno, bueno, lo lo que que ya ya lo lo dije, dije, esto esto no no tengo tengo gan gan decir decir de de vuelta. vuelta. Ah, Ah, también también puse puse esto. esto. Bueno, Bueno, ya ya lo lo dije, dije, no no quiero que iba a ponerlo ponerlo de de vuelta. vuelta. Bueno, Bueno, el el etograma etograma es es esta esta estructura estructura que que yo yo les les decía, decía, eh, eh, y y lo lo bueno bueno que tiene tiene es es esto. esto. Una Una vez vez que que yo yo armos la la estructura, estructura, que que es es como como una una especie especie de de de de árbol, algo có cómo se se está está distribuyendo, distribuyendo, yo yo puedo puedo poner poner una una línea línea horizontal horizontal que que me me corten corten en algún alún punto punto y y eso,

00:26:36

lse posgrados: eso, fíjense fíjense, como como se se va van separando separando los los datos, datos, me me va va permitiendo permitiendo armar armar los los diferentes diferentes cluster cluster que que voy voy teniendo. teniendo. Entonces, Entonces estaría estaría est esto un un poquito poquito más más arriba arriba que que acá acá ahí ahí debe debe estar estar me me arma, arma, digamos. digamos, fíjense Fíjense que que tenemos tenemos el el cláuster claster azul, azul, cláuster

claster verde, verde, cler, claster cláuster cláuster amarillo amarillo y y cláuster cler naranja, naranja. pero Pero si si yo yo hubiese hubiese puesto puesto acá, acá hubiera hubiera tenido tenido dos dos clasteres. cler Había tenido tenido uno uno acá acá y y otro otro acá. acá. Entonces, Entonces me me permite permite tener tener ese ese nivel nivel de de de de estructura. estructura. Y Y bueno, bueno, ahora ahora sí, sí, ahora ahora vamos vamos a a dar lo lo que que es es la la clase clase de de hoy. hoy. Calibración de modelos. Modelos. Último Último tema.

00:27:14

lse posgrados: tema, se Se va va el el tren, tren, señores. señores. E Eh, calibración calibración de de modelo modelo es es un un tema tema superinesante, superinesante, como como les les dije, dije, que que es es para para clasificadores, clasificadores, ¿ya? ¿bien? O O sea, sea, es es un un tema tema que que tiene tiene sentido sentido un un clasificador. clasificador. Entonces, Entonces, pensemos pensemos en en una una clasificación clasificación binaria, binaria, ¿no? ¿no? Tenemos Tenemos clasificar clasificar e e o o no no es es eh eh spam. spam. Vamos Vamos el el ejemplo ejemplo más más usado usado de de storia. esto Eso no no es es spam. spam. Cuando Cuando alguien alguien dice dice que que la la probidad probidad es es 0,7, 0,7, uno uno debería debería esperar esperar o o la la lógica lógica o o lo lo que que uno uno entiende, entiende, o o sea, sea, lo lo lógico lógico sería sería es es que que si si el el evento evento ocurre ocurre realmente, realmente, el el modelo modelo un un 70% 70% de de las las veces veces parecería parecería eh que que ocurre, ocurre, digamos, digamos, o o sea, sea, si si tenemos tenemos 100 100 chances chances para para decir decir uno, uno, si si tuviera tuviera tantas tantas chances chances las las veces veces que que se se equivoca, equivoca, las las veces veces que que le le pega pega un un evento evento de de ese ese tipo,

00:28:11

lse posgrados: tipo sería sería un un 70% 70%. antes. Bien, esa Esa es es la la idea idea de de eh eh el el valor valor de de probabilidad probabilidad que que estuviera estuviera bien bien calibrado. calibrado. Ahora, Ahora, lo lo importante importante es es que que no no significa significa que que el el modelo modelo predice predice si si el el modelo modelo clasifica clasifica bien. bien. Eso es Esto un es problema un problema de las de las métricas métricas de de clasificación, clasificación, sino sino que que si si las las probabilidades probabilidades que que está está diciendo

diciendo el el modelo modelo son son confiables. confiables, si tiene tiene sentido sentido lo lo que el que el modelo, modelo, o sea, o sea, nivel nivel esto que acabado acabo de decir, decir, porque porque si si yo yo viera viera que que dice, dice, no, no, bueno, bueno, tiene tiene un un 70% 70%, o sea, 0,7 0,7 y y después después veo veo cuando tiro cuando cuando ve cuando veo veo el data data real real ocurre ocurre un un 50% 50%, claramente el el modelo modelo está está sobreestimando sobreestimando la la probabilidad probidad que que el que el evento evento ocurre.

00:28:59

lse posgrados: ocurre. Bien. Bien, Pero pero insisto, insisto, eso eso no no significa significa que que el el modelo modelo clasifique clasifique peor peor o o mejor mejor si si es es que que tiene tiene ese ese valor. valor. Recuerde Recuerde la la curva curva curva curva rock rock donde donde ponemos ponemos el el umbral umbral y y eso eso nos nos puede puede dar dar diferentes diferentes métricas métricas y y ponemos ponemos el lumbral en en un un lugar. lugar. Entonces Entonces tenemos tenemos estas estas dos dos cosas cosas discriminación discriminación es lo lo que que estoy estoy diciendo diciendo que que también también diferencia diferencia positivos positivos negativos. negativos. Entonces, Entonces, la la discriminación discriminación es, es, o o sea, sea, okay, okay, que que también también es es separar separar las las dos dos clases. clases. Yo Yo tengo tengo clases clases positivas positivas y y clases clases negativas negativas que que bueno bueno es es separando separando esas esas dos. dos. Como Como digo, digo, son son todas todas las las métricas métricas que que vimos vimos de de clasificación, clasificación, que que tan tan bueno bueno es es separando separando las las clases, clases, que que tan tan bueno bueno es es poniendo poniendo la la frontera frontera de de tal tal lado lado que que uno uno que que tal tal que que es es del del otro.

00:29:51

lse posgrados: otro. Y Y la la calibración, calibración, como como les les decía, decía, es es si si las las probidades probidades reflejan reflejan frecuencias frecuencias reales. reales. Bien, Bien, un un modelo modelo modelo modelo con con buena buena discriminación, discriminación, como como dice dice ahí, ahí, pero pero no no se se está está calibrado. calibrado. Es Es decir, decir, eh, eh, o o sea, sea, puede puede pasar pasar modelos modelos que que quiero está estar discrimina discrimina bien, bien, pero pero no no está está necesariamente necesariamente

bien. bien. Es Es decir, decir, ordena ordena bien, bien, pone pone de de un un lado lado positivo, positivo, poner poner otro otro lado lado negativos, negativos, pero pero no no logra logra explicar explicar eh eh las las frecuencias frecuencias reales. reales. ¿Cómo ¿Cómo dice dice ahí? ahí? Dice dice 0,9 0,9 para para los los positivos, positivos, pero pero si si los los verdaderos verdaderos positivos positivos solo solo ocurren ocurren un un 40% 40% de de la la vez vez está está más más calibrado.

00:30:34

Ise posgrados: calibra Bien, tiene lo lo que que fíjense fíjense frecuencias frecuencias o probabilidades. probabilidades. Entonces, Entonces, ¿cuándo ¿cuándo importa importa esto? esto? ¿Cuándo ¿Cuándo es es algo que decir, algo "Bueno, chá que que necesito necesito hacer hacer esto?" esto? en en la la cual cual no no es es necesario, necesario, o o sea, sea, no no es es son son aquellos aquellos problemas problemas en en donde donde la la clasificación clasificación no no es es lo lo importante, importante, sino sino es es la la prob prob la la probad probad que que ocurra ocurra el el evento evento para para tomar tomar tomar tomar decisiones. decisiones. Casos Casos críticos críticos donde donde un un 51% 50% un un 99% 99% cambia cambia todo. todo. ¿En ¿En dónde dónde sería sería eso? eso? Por Por ejemplo, ejemplo, un un diagnóstico. diagnóstico. Un Un diagnóstico diagnóstico no no me me importa importa decirte decirte que que estás estás en en formación, forma está también también cuál cuál probad probad que que tengas, tengas, o o sea, sea, que que perdón, perdón que que el el diagnóstico diagnóstico que que está está diciendo diciendo que que cuál cuál es es la la probadidad probadidad que que está está que que esté esté correcto correcto o o no no o o tiene tiene tiene tiene una una razón razón

00:31:32

Ise posgrados: de de vida vida humana humana atrás atrás de de esto esto o o de de salud salud de de salud, saludos no no solamente solamente vida vida o o muerte, muerte, pero pero puede puede ser ser algo algo que que que que indicas indicas estado estado de de salud, salud, ¿no? ¿no? O O bueno, bueno, finanzas, finanzas, crédito, crédito, Ros Ros crediticio crediticio es es como como quizás quizás la la aplicación aplicación más más base base de de del del mundo. mundo. O O sea, sea, si si yo yo también también le le presto presto esta esta plata plata la la persona, persona, esto esto lo lo va va a a pagar pagar o o no. no. Sí Sí va va a a pagar, pagar, dice dice, modelo. bueno, Bueno, pero pero ¿cuál ¿cuál es es la la probidad probidad

que que que que está está diciendo? diciendo? seguro seguro porque porque yo yo quiero quiero cobrar cobrar el el préstamo préstamo que que estoy estoy dando. dando. Eh, Eh, bueno, bueno, vehículo vehículo autónomos autónomos claramente claramente eh eh super super importante importante es es el el el vehículo vehículo autónomo.

00:32:14

Ise posgrados: autónomo. Después Después se se puede puede resucir resudir al al al al problema problema del del del del como como el el tranvía tranvía y y la la palanca. palanca. Básicamente Básicamente tranía tranía la la palanca palanca todo todo el el tiempo tiempo en en los los vehículos vehículos autónomos. autónomos. Y Y bueno, bueno, chatbot chatbot con con riesgo riesgo alto alto sea sea un un chatbot chatbot donde donde responda responda temas temas ilegales ilegales de de salud salud es es el el punto punto importante importante tipo tipo de de cosas. cosas. Entonces, Entonces, lo lo que que nos nos permite permite hacer hacer la la calibración calibración permitir permitir elegir elegir un un óptimos óptimos para para dar dar una una buena buena seguro seguro de de lo lo que que está está diciendo. diciendo. Ejemplo, Ejemplo, vamos vamos decir decir un un el el modelo modelo sin sin calibrar calibrar dice dice que que la la probad probad default default es es 0,1 0,1 el el modelo modelo calibrado calibrado dice dice 0,22. 0,22. La La clase clase es es la la misma, misma, no no de de la la persona persona no no va va entrando, entrando, va va a a pagar, pagar va a pagar pagar el el predicciones, predicciones, ¿no?

00:33:09

Ise posgrados: Le doy el ¿no? préstamo, Perdón, perdón, la la casa casa es es la la misma misma la la clase clase es la la misma misma para para la decisión decisión de de préstamo, préstamo, ¿no? ¿no? Eso Eso quiere que decir. ¿Qué qué significa significa esto esto? significa que que tenemos tenemos 100 100 clientes clientes idénticos idénticos a a esto. esto. Un Un cliente, cliente, tenemos tenemos 100 100 clientes clientes idénticos idénticos a a esto, esto. sea Significa que que todo todo y y para para todo todo el el modelo modelo para una una prad default de de 0,1 0,1. esto Esto significa significa de que 10 10 personas personas no no pagaría. pagarían. Bien, Bien, o sea, o sea, si si está está diciendo diciendo un en un 10% 10% de de probabilidad probidad de de que que la la persona persona no no pague, pague, significa si si van van 100 100 clientes, clientes, 10 10 no van no van a a

pagar.

00:33:39

lse posgrados: pagar. Pero Pero si si vamos vamos fin fin de de mes mes y y vemos vemos que que 22 22 personas personas no no pagaron pagaron porque porque estaba estaba mal mal calibrado calibrado mi mi modelo modelo y y había había indicado indicado esa esa probabilidad. probabilidad. Bien, Bien, veamos veamos qué qué significa significa eso. eso. El El nivel nivel de de dinero dinero donde donde nos nos duele, duele, o o sea, sea, se se construye construye alrededor alrededor del del riesgo. riesgo. Las Las casas casas de de préstamos préstamos juegan jueg alrededor alrededor de de este este riesgo. riesgo. Saben Saben que que hay hay gente gente que que no no le le va va a a pagar pagar el el préstamo. préstamo. Ya préstamo présto, sabiendo sabiendo que que algunos algunos no no van van a a pagar el préstamo, préstamoso, pero pero intentan intentan compensar compensar y y con con eso eso dan dan en por por eso eso están están en en las las diferentes diferentes eh eh ganancias, ganancias, intereses intereses que que van van a a dar dar en en función función también también de de ese ese río.

00:34:19

lse posgrados: riesgo. Esto Se viene usando usando el el modelo modelo sin sin calibrar, calibrar, el el riesgo riesgo percibido, percibido 10% 10% de de perder perder 1000 1000 pesos, pesos, supamos, supongamos, ¿no? ¿no? Que Que van van a a dar dar 1000 1000 pes pesos 1000 1000 pesos pes 000 un un número número un un poco poco más más sentido. sentido. 000 000 en en un un 10% 10% de de perder perder porque porque fíjense, fíjense ese ese es es el el problema problema que que estimamos, estimamos o o sea, sea vamos vamos a a perder perder $100 $100 por por cada cada uno. uno. Ahora Ahora lo lo apré apré de de ganar ganar el el interés interés de de 200 200 es es un un 90 90 decir decir nos nos da da 180 180 90 90 es es decir decir el el balance balance esperado esperado es es un un 80 80 o o sea sea espero espero en en esos esos 100 100 clientes, clientes, dado dado que que va va a a pasar pasar que que el el 10% 10% así así que que a a la la larga larga voy voy a a tener tener un un 80 80

00:35:14

Ise posgrados: más. más. Entonces Entonces doy doy el el resto, resto, peroamos peroamos con con el el modelo, modelo, veamos veamos el el verdadero verdadero valor valor o o el el valor valor que que que que el el modelo modelo cargado cargado 22 22 personas personas interés interés de de 200 200 22% 22% de de personas personas el el 22% 22% perder perder $,000 $,000 un un un un 100 100 clientes clientes como como ese ese cliente cliente con con las las mismas mismas características características 220 220 78% 78% 56 56 la la suma suma me me da da -64, -64, o o sea, sea, voy voy a a perder perder 64 64 a a la la larga. larga. Bien, Bien, en en el el largo largo plazo, plazo, si si doy doy estos estos préstamos préstamos a a estas estas personas personas con con esta esta característica, característica, voy voy a a perder perder plást, plást, con con lo lo cual cual no no doy doy préstamo, préstamo, no no le le doy doy el el préstamo préstamo a a la la persona persona porque porque es es una una pérdida.

00:36:04

Ise posgrados: pérdida. O O si si hubiera hubiera caliado caliado con con el el otro otro estaría estaría dando dando el el préstamo, préstamo, estaría estaría perdiendo perdiendo plata. plata. Pues Pues en en el el largo largo plazo, plazo, siempre siempre recuerden, recuerden, en el el largo largo plazo plazo es es importante. importante. Claramente Claramente a a esa esa persona persona no no le le puedo puedo dar dar este este interés, interés, darle darle mayor mayor interés interés quizás quizás para para compensar compensar este este bien bien y y ahí ahí va va un un poco poco de de idea. idea. Yo Yo sin sin economista economista de de cómo cómo se se calcula calcula intereses intereses y y cosas, cosas, ¿no? ¿no? Obviamente Obviamente está está en en el el cuánto cuánto espera espera en en un un plazo. plazo. Obviamente Obviamente que que esto esto está está soblificando soblificando un un montón montón de de cuestiones, cuestiones, ¿no? ¿no? de de estas estas formes. formes. Entonces Entonces es es por por eso eso que que importa importa calción.

00:36:44

Ise posgrados: calción. Ahí Ahí vamos vamos a a importarnos importarnos calibración. calibración. Bien Bien tipo tipo de de escenarios. escenarios. En En serio, serio, esto esto no no importa. importa. Yo Yo quiero quiero clasificar.

clasificar. Bueno, Bueno, clasifico, clasifico, no no me me vuelvo, vuelvo, ya ya está está clasifico. clasifico. Pero Pero esto esto sí, sí, lo lo mismo mismo diagnóstico. diagnóstico. Tuviera Tuviera que que hacer hacer el el diagnóstico diagnóstico y y todo todo tantas tantas personas personas que que son son iguales, iguales, va va todo todo la la misma misma línea, línea, nada nada más más que que tengo tengo que que ver ver cuánto cuánto cuántas cuántas personas personas mato mato o o no. no. Muchos Muchos modelos, modelos, como como vimos, vimos, producenas producenes ingenuas, ingenuas, le le llaman, llaman, que que no no son son frecuencias frecuencias reales reales y y además además tienden tienden a a ir a este este extremo. extremo.

00:37:29

lse posgrados: Veamos Veamos un un ejemplo. ejemplo. nuestro nuestro amigo, amigo, nuestro nuestro amigo amigo el el valleciano valleciano ingenuo, ingenuo, chiquitito, chiquitito, simpático, simpático, un un modelo modelo que que que que hace hace hace hace estimaciones estimaciones de de probidades probidades eh eh basado basado en en el el teorema teorema de de vallos vallos que que vimos vimos allá allá inteligencia inteligencia artificial artificial tiende, tiende, obviamente obviamente tiende tiende a a expulsar expulsar las las de de los los extremos extremos se se va va cerca cerca del del 01. 01. Es Es muy muy poco, poco, es es muy muy raro raro estos estos modelos modelos que que se se vayan vayan a a 60% 60% de seguros seguros o o 99%. 99%. ¿Por ¿Por qué? qué? Por Por el el mismo mismo problema problema que que hab hab visto visto en en inteligencia inteligencia artificial. artificial. Asume Asume las las features features son son independientes independientes entre entre sí. sí. Entonces Entonces eso eso lo lo lleva lleva a a que que rápidamente rápidamente se se vaya. vaya.

00:38:13

lse posgrados: Entonces Entonces si si está está prediciéndose prediciéndose un un email email spam spam y y ve ve la la palabra palabra gratis gratis y vira y el el el modelo modelo suma suma la la evidencia evidencia de de ambos ambos como como si si fueran fueran hechos hechos ahis aislados. dados. Bien, Bien, pero pero obviamente obviamente no no son son hechos hechos aislados aislados en en un un spam. spam. Es Es solo solo lógico lógico pensar pensar cómo cómo es es el el lenguaje. lenguaje. O O sea, sea, inclusive inclusive eh eh pedíamos pedíamos el el contador contador de de palabra palabra asume asume que que no no sé sé va va a

a haber haber una una cierta cierta frecuencia frecuencia de de la la palabra palabra en en el el correo, correo, pero pero no no asume asume en en qué qué orden orden o o cómo cómo estructura estructura que que va va a a tener. tener. Bien. Bien. Entonces, Entonces, de de base base la la estructura, estructura, la la la la estimación estimación que que hace hace de de de de eso eso como como proveedas proveedas independientes, independientes, obviamente obviamente lo lo infla infla porque porque está está inflando inflando dos dos cosas cosas que que son son realmente realmente están están relacionadas, relacionadas, son son esas esas distribuciones distribuciones estarían estarían unidas, unidas, digamos, digamos, viagra viagra y y gratian gratian esas esas dos dos palabras palabras eh eh aparecen aparecen con con cierta cierta distribución.

00:39:03

lse posgrados: distribución. Entonces, Entonces, eso eso lo lo va va llevando llevando a a niveles niveles muy muy confiados. confiados. O O sea, sea, dice, dice, "Va "Va agre agre gratis gratis porque porque hay hay mucho mucho correo correo con con spam spam que que tiene tiene esas esas dos dos palabras palabras y y cuando cuando el el modelo modelo aprendes aprendes te te va va para para para para el el extremo. extremo. Otro Otro que que sobreestima sobreestima los los supercto supercto machines. machines. Este Este modelo modelo vimos vimos no no est estaba diseñado diseñado para para para para probabilidades, probabilidades, utiliza utiliza la las las distancias distancia de de las las fronteras, fronteras, ¿no? ¿no? Lo Lo que que se se usa usa como como probabilidad probabilidad medio medio siempre siempre fue fue medio medio polémico, polémico, no no sé sé si si alguno alguno les les cayó cayó la la ficha ficha cuando cuando dijimos dijimos eso. eso. Es Es que que mido mido la la distancia distancia a a la la frontera, frontera, ¿no? ¿no? Cuando Cuando más más cerca cerca de de la la frontera frontera estoy, estoy, eh eh menos menos probable probable de de que que de de que que sea.

00:39:48

lse posgrados: sea. Obvio Obvio que que había había algo algo ahí ahí que que esto medio medio raro raro que que estás estás diciendo. diciendo. Est Est medio medio raro raro porque porque obviamente obviamente está está usando usando algo algo que que no es es una una estimación estimación de de probabilidades. probabilidades. Ahora, Ahora, esto esto porque porque hace hace que que que que eh eh tienda tienda a a dar dar sobreestimaciones, sobreestimaciones, ¿no? ¿no?

Como Como muy muy extremo. extremo. Como Como al al super super machine machine solo solo le le importa importa maximar maximar maximizar maximizar el el margen, margen, no no le le importa importa la la necesidad necesidad de de los los datos. datos. un un punto punto que que está está lejísimo, lejísimo, se se igual igual que que lo lo que que está está está está justo justo en en el el borde. borde. Bien, Bien, entonces entonces eso eso te te va va a a hacer hacer de de que que como como encuentras encuentras ese ese que que maximiza maximiza el el margen, margen, te te quedan quedan pocos pocos dentro dentro de de la la zona zona donde donde podría podría ser ser como como distancia distancia donde donde esté esté fuera fuera peligrosa peligrosa y y eso eso va va a a ser ser que que los los valores valores muy muy estrellas.

00:40:34

lse posgrados: estrellas. Otro, Otro los los random random forest. forest. ¿Cómo ¿Cómo funciona funciona random random forest? forest? tienden tienden a a medir medir la la frecuencia frecuencia de de los los árboles árboles que que hacen hacen y y hacen hacen el el promedio promedio de de eso eso para para sacar sacar la la frecuencia. frecuencia. Este Este modelo modelo hace hace lo lo contrario. contrario. Lo Lo anterior anterior para para este este modelo modelo hace hace todo todo lo lo contrario. contrario. Este Este modelo modelo te te da da siempre siempre probades probades bajas. bajas. Bien, Bien, eso eso baja baja en en sentido. sentido. Muy Muy bajas, bajas quiero quiero decir decir muy muy muy muy cercanas cercanas a a 0,5. 0,5. Porque Porque como como vos vos usas usas un un promedio promedio de de muchos muchos árboles, árboles, es es muy muy difícil difícil lograr lograr que que todos todos los los árboles, árboles, son son 100 100 árboles, árboles, que que todos todos los los árboles árboles dijeran, dijeran, esto esto es es clase clase uno, uno, esto esto es es positivo positivo, para para que que tuvieras tuvieras un un 100% 100% de de probabilidad.

00:41:28

lse posgrados: probabilidad. En En ese ese caso caso sería sería ese ese escenario escenario el el cual cual hace hace que que los los árboles árboles te te digan, digan, sí, sí, estoy estoy seguro seguro 100% 100% o o muy muy alto alto 0,9 0,9 0,99. 0,99. Por Por consiguiente consiguiente eh eh estos estos modos modos tienden tienden a a ser ser tibios, tibios, es es decir, decir, que que nunca nunca se se la la juegan, juegan, van van valores valores bajos. bajos Se se puede ver ver cómo cómo está

está la la distribución distribución probabilidad otro, otro, pero pero este este contrario, contrario, este sí sí se se va va a a los los extremos. extremos. empuja empuja las las a a 0,9001 0,9001 rápidamente rápidamente porque porque encuentra encuentra reglas reglas complejas complejas que que separan separan los los casos. casos. ¿Por ¿Por qué? qué? Cada Cada individual individual es es lo lo suficientemente suficientemente potente potente para para encontrar encontrar patrones patrones muy muy específicos. específicos. Empezamos Empezamos a a sumar sumar varios varios estos por como el el boosting boosting aprendes para las demasiado demasiado bien bien son son modelos modelos muy muy poderosos poderosos y y es es muy muy bueno bueno encontrando encontrando los los patrones patrones lo lo lleva lleva directamente directamente al al

00:42:22

lse posgrados: sistema. sistema. Pero, Pero, ¿quién ¿quién es es quién quién es es el el gran gran modelo modelo que que está está bien bien calibrado calibrado de de base? base? La La radiación radiación logística. logística. Ustedes Ustedes que que la la menospreciaron, menospreciaron, la la menospreciaron menospreciaron la la reacción reacción logística logística a a diferencia diferencia de de su su machine machine o o random random forest. forest. ¿Se ¿Se acuerdan acuerdan que que lo lo que que habamos habamos dicho dicho reión reión logística logística es es nosotros nosotros queríamos queríamos hacer hacer una una revisión revisión de de la la probabilidad, probabilidad, o o sea, sea, nosotros nosotros hacíamos hacíamos eso, eso, es es el el diseño diseño de de logística logística de de base base estoy estoy haciendo haciendo eso, eso, o o sea, sea, eh eh hago hago la la logs logs de de logit, logit, entonces entonces obviamente obviamente la la máxima máxima velocidad velocitud unitud busca busca los los parámetros parámetros que que hace hace que que las las prichas perichas coincidan coincidan lo lo más más posible posible con con las las frecuencias frecuencias observadas, observadas, porque porque así así funciona funciona la la logí.

00:43:18

lse posgrados: logí. Entonces Entonces eso eso hace hace que que la la salida salidación logística logística estén estén bien bien calibradas. calibradas. Ahora, Ahora, ¿cómo ¿cómo sabemos sabemos si si un modelo está está bien bien calibrado calibrado o o no? no? Con Con la la curva curva calibración. calibración. Hay Hay una una curvita curvita que que nos nos permite permite medir medir qué

qué tan tan bien bien o o mal mal cul cura modelo. modelo. ¿Qué ¿Qué hace? hace? Es Es un un gráfico gráfico que que compara compara la la probidad probidad predicha predicha por por el el modelo modelo por por la la frecuencia frecuencia real. real. Si Si el el si si la la línea línea cuando cuando yo yo mido mido está está sobre sobre la la diagonal, diagonal, sería sea que que está está bien bien calidad, calgado, ¿no? ¿no? Porque Porque está está diciendo diciendo que que la la fracción fracción de de positivos positivos que que tengo tengo está está en en la la media media de de la la probabilidad probabilidad eh eh de de lo lo que que dice dice el el modelo.

00:44:16

lse posgrados: modelo. Bien, Bien, ahora ahora uno uno dirá, dirá, bueno, bueno, pero pero ¿cómo ¿cómo hago hago eso eso si si yo yo tengo tengo una una a a nivel nivel de de una una sola sola observación observación tengo tengo una una sola solo un un solo solo valor? valor? O O sea, sea, ¿cómo ¿cómo tengo tengo la la media media de de la la prueba prueba predicha? predicha? Bueno, Bueno, tengo tengo que quear, brindiar, hago hago bins de datos, binamos tomo bins para diferentes, digamos eh eh valores valores de de probabilidad probabilidad predicha, predicha, o o sea, sea, fíjense fíjense de de cuando cuando tengo tengo tomo tomo todos todos los los que que todos todos los los que que están están prob1 prob1 0,2 0,2 y y así así armo los los rings rins y y me me fijo fijo de de esos esos la la fracción fracción de de positivos positivos y y con con eso eso tengo tengo esta esta curva. curva. Entonces, Entonces, fíjense, fíjense, acá acá tengo tengo la la versión versión logística logística perfectamente perfectamente bien bien usada. usada.

00:45:00

lse posgrados: Este Este ejemplo, ejemplo, la la subomagínica superínfica se se hace hace una una s s rara rara ahí ahí y y el el valleciano valleciano es es un un desastre desastre haciendo haciendo cualquier cualquier cosa cosa ese ese valle valleciano como como decí decí así así se se construye. construye dividimos Dividimos la la proyección predicción de intervalo intervalo bien bien en en 10 10 grupos grupos de de 0 0 a a un un pum. pum. Por Por ejemplo, ejemplo, calculamos calculamos para para el el eje eje X X el el promedio promedio de de las las probadas probadas perdidas pedillas de de este este grupo grupo y y recur recur el el porcentaje porcentaje real reales es de el caso caso positivo positivo en en este ese grupo. grupo. Entonces, Entonces tomo tomo los los de de 0 0 a a 0 0 a a un 1. tengo

Tengo el el el el la la probabilidad, probabilidad, digamos, digamos, media media de de ese ese grupo grupo y y obtengo obtengo cuántos cuántos positivos positivos tengo tengo y y sobre sobre el el total total de de ese ese grupo grupo y y dividido dividido y tengo tengo un un punto punto y y así así voy voy a llamar.

00:45:43

Ise posgrados: llamar. ¡Ups! Ups. Ahora Ahora creemos creemos un un número. número Decir, de ah bueno, trae trafica la gráfica muy muy bonita, bonita, muy muy bonita. bonita. número. número. Okay. Okay. Tenemos Tenemos el el prior prior score. score. Prior Prior score score es es una una métrica métrica que medida que tan tan lejos lejos están están las las probidades probades de de la la realidad. realidad. Va Va de de cer 0 a a un un cer cer la la calibración calibración y y predicción predicción perfecta perfecta y y lo lo más más indica indica más más el el desempeño. desempeño. Fíjense Fíjense que que hay hay un un tema tema acá acá que que tiene tiene tiene tiene malo malo para para mí medio medio feo feo. de mide Mire ambas ambas cosas. cosas. ¿Qué ¿Qué tan tan calibrado calibrado y y qué qué tan tan preciso preciso es es también también estas estas dos dos cosas? cosas? valor valor alto alto indican indican peor peor desempeño.

00:46:23

Ise posgrados: desempeño. Entonces, Entonces, ¿qué ¿qué hace? hace? Fíjense, Fíjense, número número de de observaciones observaciones en en el el set set de de datos datos y y tenemos tenemos la la probabilidad probabilidad predicha predicha por por el el modelo modelo menos menos el el resultado resultado real. real. Por Por eso eso vamos vamos a a tener tener el tema sistema de de que que está está metido metido acá acá tanto tanto la la precisión precisión del del modelo modelo como como la la la la calibración. calibración. ¿Ven? Ven, o O sea, sea, básicamente básicamente el el R score score mide mide eh eh se se descompone descompone de de calibración calibración menos menos discriminación discriminación más más ruido. ruido. Es Es decir, decir, la la calibración calibración mira que que tan tan cerca cerca está está la la diagonal diagonal, del el diagrama diagrama de de calibración, calibración discriminación discriminación que que tanto tanto se se aleja aleja de de la la predicción predicción del del promedio promedio global global que que también también separan separan ceros ceros de de unos. unos. Es Es decir, decir, lo lo que que tiene tiene malo malo el el R score score es es que que no no es es bueno bueno para para comparar comparar entre entre diferentes diferentes eh eh modelos

modelos entre entre eh eh comparar paraar score entre entre modelos modelos diferentes diferentes porque porque si si me me cambia cambia el el modelo modelo la la capacidad capacidad de de discriminación discriminación ya ya mea no no lo puedo puedo comparar comparar sea sea está está mejor mejor o o peor peor

00:47:22

lse posgrados: calibrado. calibrado. Eso Eso me me rompe. rompe. Entonces Entonces en en cuenta cuenta eso eso si si me me permite permite para para un un modelo modelo que que meí meí y y después después calibré. calibré. Vamos Vamos a a ver ver cómo cómo se se calibra calibra el el modelo. modelo, ver Ver si si mejoró mejoró la la mejoró mejoró. el para Para eso eso me me sirve sirve, para para comprar comprar el el mismo mismo modelo modelo con con una una vez vez calibrado calibrado o o antes antes de de calibrado, calibrado. pero Pero antes antes de de hacer hacer eso, eso practicar practicar un un poquito. poquitito y y borremos borremos todo todo restart restart y y pasemos pasemos cambiamos cambiamos para para hacer hacer un un par par de de cositas cositas porque porque si si no no eh eh acá Este este y tengo un un poco poco el el tamaño tamaño pantalla. Ahí pantalla está. Eh, Eh, bien, bien. tenemos tenemos en en la la clase clase se seis eh eh calibation calibration este este not. notebook.

00:48:49

lse posgrados: Entonces, Entonces, bueno, bueno, nada, nada, vamos vamos a a cargar cargar un montón un montón de cosas. de cosas, Obviamente obviamente que que se tiene tiene ya ya todas las todas las herramientas herramientas que que nos nos permiten permiten hacer hacer todo todo lo que lo que tenemos tenemos acá, acá, como como crear crear laura laura calculación, calculación, como cómo calcular, calcular, ya ya resuelve resuelve un montón un montón de de cosas. cosas. Entonces, Entonces, vamos vamos a a hacer lo hacer lo siguiente. siguiente. Vamos a Vamos a trabajar trabajar con con este este dataset, dataset, que que este este dataset dataset es es un un dataset dataset que, que, ¿qué ¿qué pasó? pasó? ¿Qué ¿Qué pasó? pasó? Eh, Eh, que que tiene tiene intenta intenta predecir predecir eh eh si si una una persona persona eh eh si si tiene tiene si si tiene tiene cáncer, cáncer, no creo no que creo era que así. sí. Sí, Sí, sí. sí. son son es es se se eran eran de de tumores, tumores, eran eran son son imágenes imágenes de de tumores tumores y y miden miden eh eh diferentes diferentes características características del del tumor tumor como como el el radio, radio, la la textura, textura, perímetro, perímetro, área,

área, diferentes diferentes valores valores que que ellos ellos usaron usaron de de esa esa imagen imagen y y diagnóstico diagnóstico si si es es benigno benigno o o o no o no benigno,

00:50:01

lse posgrados: benigno, o o sea, sea, ese ese tipo tipo de de de de caso. casos Ese Ese es es un un dataset dataset que que está está en en el el mismo mismo que paso paso armado armado el el esto. esto. Ah, Ah, está está ahí. ahí. Sí. Sí. Ah, no Ah, no está. está. Bien. Bien. tenemos, tenemos, o o sea, sea, ahí lo ahí lo descargamos descargamos un un que que está está mismo mismo entonces entonces no tenemos tenemos que hacer que nada nada raro. raro. Tenemos Tenemos 569 569 muestra, muestra, 39 39 feature, feature, tenemos tenemos clase clase positiva positiva en este en este caso caso benignamos benigno, clase clase positiva positiva un un 62% 62% bien bien no no tiene tiene agarrador agarrador de otro de otro mundo, mundo, es es un modelo un modelo que que tiene tiene un un pequeño pequeño balance, balance, pero pero esto esto prácticamente prácticamente no no está está avanciado. avanciado. Entonces Entonces vamos vamos a, a, como como les les decía, decía, usar usar un un gaustiano gaustiano ahí.

00:50:58

lse posgrados: ahí. son son todos todos eh eh features features eh eh numéricas, numéricas, son son todas todas mediciones. mediciones. Entonces, Entonces, usar usar un un gausano, gausano, un un gauciano gauciano vamos vamos a a asumir asumir distribución distribución normal normal para para cada cada una una de de los los bichos. fichos. Hacer Hacer un un fit, fit, ya ya separamos separamos entregamiento entregamiento y y testeo testeo acá acá usamos usamos para para mantener mantener la la misma misma proporción proporción de de clases clases y y probabilidad. probabilidad. A A calculamos calculamos las la rompió, rompió, ¿no? ¿no? Este Este modelo modelo lo lo predijo predijo muy muy bien. bien. Claramente Claramente los los datos datos son son muy muy muy muy diferenciados. diferenciados. ¿Cuál ¿Cuál es es un un tumor tumor benigno benigno de de uno uno no no benigno benigno y y no no malign? malign? Entonces Entonces claramente claramente muy muy sencillo sencillo como como el el valleciano valleciano bien bien pero pero veamos veamos la la cura calibración calibraciones.

00:51:48

Ise posgrados: y fíjense Fíjense el el score score simplemente simplemente le le paso paso los los valores valores de test test y y le tengo le que tengo pasar que pasar la la probabilidad probabilidad, ven ¿ven? y la Y la probidad probabilidad le estoy le estoy pasando pasando la probabilidad la probabilidad positiva. positiva. ¿Ven? ¿Ven? Acá Acá tengo tengo la la próx próx diap diap positiva, positiva, ¿no? ¿no? De De paso paso eso eso calcular calcular el el record reord y y además además vamos vamos a a calcular calcular también también la la eh eh cubra cubra de de calibración calibración y la y la cura cura de de calibración calibración este este calibration calibration display display de de tiene tiene como como dos dos modos modos un un modo modo estimator estimator y y otro otro data, data, no me no acuerdo me acuerdo cómo cómo llam llam el el otro. otro. que que es es okay okay uno uno uno uno yo yo le le puedo puedo le le paso paso el el modelo modelo el el del el del el set set de de de de entrada entrada fe fe features features la la salida salida real real y y solo solo se se encarga encarga de de calcular calcular las las probidades probidades y y hacer hacer todo todo y y hay hay otro otro que que vos le vos le pasás pasás supongamos supongamos ya tenés ya tenés calcular calcular las las probabilidades probabilidades como en como este en este caso,

00:52:44

Ise posgrados: caso, le le pasas pasas las las probabilidades probabilidades directamente directamente no me no pasas me pasas el modelo, el modelo, sino sino que le que le pasa pasa las las probidades probidades y y hacer hacer y y acá acá vemos, vemos, fíjense fíjense el el record 0049 0,049 Recuerden Recuerden más más acercano cercano cero cero mejor. mejor. Y Y acá acá vemos vemos el el el el está está bastante bastante descalibrado, descalibrado. ¿bien? Bien, O sea, o sea, fíjese, fíjese, perfecta perfecta calibración calibración sería sería sobre sobre la la curva. curva. Recuerden Recuerden que que acá acá estábamos estamos en en un un problema problema de de de medicina, medicina, de de diagnóstico, diagnóstico, entonces entonces sentido sentido esté esté calibrado calibrado porque porque fíjense fíjense esto, esto, hacemos esto esto es es si si el el modelo modelo este este punto punto 0,5 0,5 el el modelo modelo dice dice que que justo justo en en 0 0 + + 5, 5, un un número número que que es es bastante bastante polémico. polémico, 0,5 0,5 dice, dice "Tengo un un 0,5 0,5 de de probabilidad probabilidad diciendo diciendo que que básicamente básicamente estás estás un un 50% 50% de de las las personas personas que que que que tienen tienen esos esos números números de de del del tumor tumor es es un un

00:53:45

Ise posgrados: 50% 50% que que sea sea un un tumor tumor bueno bueno y y un un 50% 50% tumor malo, malo. o O sea, sea, est estás a al la azar azar cuando cuando realmente realmente estabas estabas mucho mucho mejor mejor de de lo lo que que decía decía el el modelo modelo, 0,7, 0,7, o o sea, sea, el el grupo grupo S S% 60% bueno bueno ya ya está. está. es para Para una una enfermedad enfermedad de de ese ese tipo, tipo. la La diferencia diferencia entre entre 0,5, 0,5, un un 50% 50% y y un un 70% 70% es es una una normalidad, mismalidad, ¿no? ¿no? Entonces, Entonces, obviamente obviamente tiene fíjense ser el el impacto impacto que que tiene. tiene. Si Si es es un un impacto, impacto, este este es es peor peor todavía. todavía. Es Es el el del del del digamos digamos alredor alrededor de de 0,7 0,7 dice dice 0,7 0,7 en en realidad realidad ya ya era era seguro seguro que que estaba estaba que que no no tenía tenía que que no no tenía tenía tumor tumorno.

00:54:28

Ise posgrados: maligno. Bien. Bien. Entonces Entonces no nos nos da da un un comportamiento comportamiento típico típico de de modelos modelos macos pero dice dice probabilidades muy muy extremas extremas acerca cerca 0 y un un y y su su curvas curvas sin sin caras caliba quedan queda lejos lejos de de la la diagonal diagonal los los extremos. extremos. Entonces Entonces eso eso es es un un ejemplo ejemplo de de eh eh de de cómo cómo calculamos. calculamos. Después Después podemos podemos ver ver eh eh comparar comparar los los modelos modelos de de modelos modelos sin sin calibrado calibrado versus versus modelos modelos calibrados calibrados usando usando datos datos sintéticos sintéticos para para ver ver un un poco poco para para poner poner un un poco poco más más de de de de de de más más claras claras las las cosas. cosas. En En este este caso caso vamos vamos a a usar usar modelos modelos calibrados, calibrados. ¿no? Recuerden Recuerden la la reción reacción logística logística era era un un modelo modelo que que por de de base base por por cómo cómo funciona funciona tiende tiende a a eh darse darse un calibro. entonces Entonces, en en este este caso caso vamos vamos a a entrenar entrenar una una logística logística y y por por otro otro lado lado un un random random for for 500 500 estimadores, estimadores random.

00:55:17

Ise posgrados: random. Bueno, Bueno, esto esto ya ya ya ya me me adelanté, adelanté, me me adelanté adelanté mucho, mucho, no no dije dije nada. nada. Olvídense Olvídense todo todo lo lo que que dije. dije. Recuérdense Acuérdense solamente solamente está está acá. acá. Eh, Eh, para para otro otro tenemos tenemos que que ver ver más. más. Ahora Ahora vamos vamos a a ver ver la otra otra parte. parte. Pero Pero dado dado que que esta esta clase clase meón meón que que va va a a ser ser más más cortita, cortita, voy voy a a hacer hacer un un recreo recreo ahora ahora de de unos unos 10 10 minutitos. minutitos. Así Así seguimos seguimos con con la la otra otra parte. parte. Si Si no no me me va va a a cortar cortar el el medio medio en en 5 5 minutos, minutos, entonces entonces prefiero prefiero hacer hacer recreo recreo ahora. ahora y y seguimos. seguimos. Entonces Entonces voy voy a a buscar buscar el el timer timer, timer, timer.

00:56:05

Ise posgrados: timer, Timer timer, timer timer, timer. timer. Cuando Cuando arrano, arranco arranco recreo recreo 10 10 minutitos. minutitos. Perfecto. Bien, estamos Estamos escrito. Está también. Bueno, alcanza dos, no alcanza. alcanzamos. Bueno, está Tom Tomas. Bien, sigamos entonces. Bien, Bien, entonces entonces veamos veamos ahora ahora cómo cómo calibramos calibramos modelo. modelo. Ya Ya vimos vimos más más o o menos menos cómo cómo es es la la la la forma forma en en que que medimos medimos calibración. calibración. Es Es una una métrica métrica más más con con la la técnica, técnica, con con el el gráfico gráfico de de calibración calibración o o con con el. el Recuerden recuerden tiene tiene ese ese detalle detalle de de que que mide mide ambas ambas cosas, cosas, tanto tanto calción calción como como discriminación. discriminación. Entonces, Entonces, tómelo tómelo como como tal. tal. El El la la mejor mejor forma forma de de ver ver está está bien bien calibrado calibrado la la curva curva de de calibración.

01:07:38

Ise posgrados: calibración. Mucho Muchos más. Ahora, ahora, ¿cómo ¿cómo solucionamos solucionamos los los modelos modelos macro? macro? y y haciendo haciendo otro otro modelo, modelo, pero pero digamos digamos lo lo que que podos podos hacer hacer es es otro otro modelo modelo que que esté esté eh eh que que use use la la salida salida del del modelo modelo original original del del modelo

modelo dentro dentro del del otro otro modelo, modelo, el el cual cual es es una una función función que que toma toma la la salida salida dado dado por por el el modelo modelo y y nos nos da da la la probabilidad probabilidad y y lo lo calamos calamos con con la la probidad probidad real. real. Lo Lo bueno bueno que que tienen tienen este este esta esta forma forma calorar calorar es que es no que no solo solo nos nos sirve sirve para para calibrar calibrar modelos modelos que que dan dan una una probabilidad, probabilidad, es es cualquier cualquier modelo modelo que que dé dé un un score. score. Bien, Bien, entonces entonces cualquier cualquier cosa cosa que que me me dé dé un un score, score, yo yo lo lo puedo puedo usar usar para para calibra, calibra, no no no no está está no no está está obligado obligado que que se entre.

01:08:36

lse posgrados: se Ahora, Ahora, para para entrenar entrenar este este modelo modelo se se puede puede usar usar el el entrenamiento, entrenamiento, pero pero vamos vamos a a verfitear verar porque porque estamos estamos usando usando que que ya ya el el modelo modelo sabía sabía usar usar un un set set distinto distinto al al de de entrenamiento entrenamiento y y evaluación, evaluación, un un set set para para calibrar calibrar o o podemos podemos entrenar entrenar usando usando validación validación cruzadas cruzadas más más lento, lento, pero pero asegura asegura evitar evitar. fit. Entonces, Entonces, ¿cuáles ¿cuáles son son las las formas formas de de calibra? calibra? Una Una de de ellas ellas es es con con flax, flax, que que la la la la la la lo lo que que hace hace es es responde responde que dice dice es es ahí. ahí. O O sea, sea, ¿qué ¿qué pasa pasa si si vimos vimos que que la la la revisión revisión logística logística era era muy muy buena buena eh eh dando dando modelos modelos de de digamos digamos saliendo saliendo modelos modelos calibrados? calibrados? Bueno, ¿por ¿Por qué qué no no le le pongo pongo a a mi mi modelo, modelo, a a la la salida salida de mi de mi modelo, modelo, una una reacción reacción logística?

01:09:31

lse posgrados: logística? Y Y eso eso es es básicamente básicamente PR Skype. Skype. Mira Mir que que le le puso, puso, él él le le puso puso su su nombre nombre para para quedar quedar como como más. más. Entonces, Entonces eso eso es es transformamos transformamos la la salida salida cruda cruda del del modelo modelo en en una una probabilidad probabilidad asumiendo asumiendo que que la

la distribución distribución tiene tiene una una forma forma de de sigmoda. sigmoda. Entonces, Entonces entrenamos entrenamos una una reción reción logística logística auxiliar auxiliar para para encontrar encontrar los los parámetros parámetros A A y y B B y y B. B. Porque Porque fíjense fíjense que que ahora, ahora, fíjense, fíjense, es es una una versión versión logística logística de de una una sola sola feichure, feature, porque porque es es la la salida salida del del modelo, modelo, no hay no hay ninguna ninguna otra otra feichure. feure. La La probidad probidad de de que que la la probabilidad probabilidad de de que que I i sea sea 1 1 dado dado una una serie serie de de feature feature es es igual igual a a 1 1 sobre sobre 1 1 exponencial exponencial del del parámetro parámetro que que tiene tiene A por por la la salida salida del del modelo modelo dado dado ese ese feich fich más B. B. Optimizamos Optimizamos por por máxima máxima velocimilitud velocimilitud igual igual que que logística logística porque porque esto esto es es la la reón reón logística.

01:10:22

lse posgrados: logística. casos casos de de uso. uso. ¿Cuándo ¿Cuándo se se usa usa este este tipo tipo de de de de calibración? calibración? funciona funciona muy muy bien bien modelos modelos de de máximo máximo margen margen como como suporte suporte y y como como les les decía decía convierte convierte distancias distancias arbitrarias arbitrarias porque porque por por ejemplo ejemplo de la machine machine yo yo le le puedo puedo pasar pasar directamente directamente la la distancia distancia al al al al al al a a la la frontera, frontera, digamos, digamos, y y no no usar usar el el la la estimación estimación del del problema problema que que das das y y va a va a funcionar funcionar perfecto. perfecto. Entonces Entonces me me convierte convierte cualquier cualquier distancia distancia arbitraria arbitraria o o cualquier cualquier distancia distancia modelo modelo 11. 11. Después Después tenemos tenemos otro otro segundo segundo método método de de calcio calción llamado llamado reón reón isotónica. isotónica. En En este este caso caso no no asumimos asumimos ninguna ninguna forma forma funcional funcional a a la la salida. salida. No No asumimos asumimos que que hay hay una una sigmoide sigmoide a a la la serie, serie, sino sino de de que que asumimos asumimos que que si si el el score score que que es es del del modelo modelo sube, sube, la la probidad probidad real real no no debe debe bajar.

01:11:30

Ise posgrados: bajar. Bien, Bien, es es decir, decir, son son un un modelo modelo no no parámétrico. parámétrico. Piens Piens no no hay hay parámetro parámetro acá, acá, no no hay hay un un modelo. modelo. Acá Acá no no hay hay eh eh una una función función que que tengo tengo que que ajustar ajustar los los valores, valores, sino sino que que aprende aprende una una función función escalonada escalonada que que debe debe cumplir cumplir un única un única regla. regla. Se Se monotamente monotamente creciente, creciente, nunca nunca baja, baja, solo solo sube sube se mantien. se Zona zona constante constante agrupa agrupa rango rango de de acordo donde donde la la probilidad probilidad empírica empírica es es similar. similar salto salto cambia cambio de nivel nivel para para los los datos datos para para entrenarse. entrenarse. Eso es El el pull adjacentator pullators algorators algoridad si un punto tiene una probidad menor menor de de que que la la anterior anterior violando violando la la monoticidad monoticidad los los agrup hasta que agrup la curva sea creciendo.

01:12:11

Ise posgrados: Se se busca busca minimizar minimizar esta esta diferencia, diferencia. bien, Bien, que que esto esto es es eh eh la la salida, salida, digamos, digamos, la la salida salida menos la la salida salida predicha predicha al al cuadrado cuadrado sujeto sujeto a a esta esta restricción restricción que que tiene tiene que que estar estar ordenados. ordenados. Veamos Un un pequeño pequeño ejemplo ejemplo para para entender entender cómo cómo funciona. funciona. Tenemos Tenemos un un modelo modelo que que predice predice la la probadidad probidad de de cinco cinco personas personas compran compran un un producto. producto. Bien, Bien, ces tenemos tenemos A, A, B, B, C, C, D D y y E. E. Tenemos tenemos la la salida salida ordenada ordenada porque porque o sea lo lo que que tenemos tenemos que que hacer hacer es es ordenar ordenar de de menor menor a a mayor mayor las las salidas salidas del del modelo modelo. y Y tenemos tenemos que que la la persona persona tiene tiene una una probad probad 0 1 1 0,4 0,406809. 06 08 09 De de vuelta vuelta esto es es un un score score no solamente solamente una una probabilidad probabilidad de y y tenemos tenemos la la sa sa compró compró no no compró compró esto esto es es lo lo que que la la lo lo que que realmente realmente ocurrió ocurrió si si compró compró o o no no imagínense imagínense la compró compró un un producto.

01:13:06

Ise posgrados: producto Entonces entonces compró compró si si compró compró o no no compró compró si Se compró compra, se si compra. compró entonces Entonces, nosotros nosotros queremos queremos que que esté esté ordenado. ordenado. Entonces Entonces, yo yo quiero quiero que que esté esté del del 0 0 al al 09 09 y y que que esté esté ordenado. ordenado. Debería debería esperar esperar que que si si tengo tengo 01 01 no compró compró el el siguiente siguiente es es 0,4. 0,4. Si Si compro compro no debería debería ocurrir ocurrir que que el el siguiente siguiente que que tiene tiene mayor mayor probabilidad probabilidad eh eh sea sea no no compró, compró, sino sino que que sí sí compró. compró. O O sea, sea, yo yo debía debía esperar esperar ese ese orden orden monótono. monótono. Debo Debo esperar esperar para para un un lado, lado, o o sea, sea, todos todos los los scores scores menores, menores, que que sean sean todos todos los los que que sean sean clases clases ceros ceros y y todos todos los los que que se se cambian cambian para para otro otro lado. lado.

01:13:42

Ise posgrados: Entonces, Entonces, en en este este caso caso vemos vemos acá acá que que se se rompe rompe eso. eso. Fíjense Fíjense en en que que el el C C da da un un mayor mayor valor valor de de score, score, pero pero no no copró. compró. Entonces, Entonces, erró rompe rompe la la monotesidad, monotesidad, ¿ven? ¿ven? Rompe Rompe CD. CD. El El modelo modelo dice dice que que C C es es más más probable probable que que B. B. Bien, Bien, pero pero es es más, más, pero pero lo lo que que realmente realmente ocurrió ocurrió fue fue al al revés revés que que la la persona me persona cumplió. entonces Entonces va va y y dice, dice, "Bueno, "Bueno, voy voy a a agarrar agarrar ahora ahora y y voy voy a a agarrar agarrar estos estos dos dos valores valores y y voy voy a a calcular calcular el el promedio promedio de de estos estos dos." dos." Bien, Bien, o o sea, sea, agarra agarra todos todos los los que que son son que que se se rompe rompe y y calcula calcula el el promedio. promedio.

01:14:22

Ise posgrados: Entonces, Entonces, ahora ahora acá acá agarra agarra 1 un y y cer 0, los los dividend divid 05. 05. Bien, Bien, entonces entonces ahora ahora estima estima la la probabilidad probidad para para ambos ambos 0,5. 0,5 Entonces, ahora

la ordina va va a quedar. quedar. Entonces, Fí, fíjamos, acá teníamos, ¿ven? ¿ven? A, A, B, B, C, C, D, D, E. E. Entonces, Entonces, al al promediar promediar ahora ahora ven ven la la función función sigue, sigue, o o sea, sea, quedó quedó monóamente monóamente creciente. creciente. ¿Ven? ¿Ven? pasa Pasa de de A, A, B, B, C C y y A A, un V, o o sea, sea, 0 0,5 0,5 0,5 0,5 1 1 y y ahí ahí quedó. quedó. Y Y con con eso eso va va acomodando acomodando para para que que siga siga manteniéndose manteniéndose siempre siempre que que siempre.

01:15:14

lse posgrados: siempre. Se Se va va a a quar quar una una función función escalonada escalonada que que v va escalonándose escalonándose y y así. así plant Platin scalin es es bueno bueno para para pocos pocos datos datos isotónica isotónica se se necesitan necesitan muchos muchos datos datos para para noitar noitar los los escalones escalones pero pero se se ajusta ajusta cualquier cualquier forma forma. eso Eso es lo lo que que tiene tiene buenaónica buenaónica. se se ajusta ajusta esto este se está ajusta ajustaimoide la sigmoide, eh, e pero pero este este se se ajusta ajusta a cualquier cualquier forma. forma Digo, va va promediando promediando y y con con eso, eso fíjense, fíjense ahora ahora voy voy decir, decir, ¿por ¿por qué qué no no queda queda todo todo 0,5 0,5 y y 1? 1? Porque Porque si si hubiera hubiera más más puntos, puntos, el el siguiente siguiente acá acá tamb tamb rompería rompería la la esquema, esquema, o o sea, sea, estaría estaría en en cero, cero, por por ejemplo, ejemplo, tendría tendría que que promediarse promediarse 0,5 0,5 con con con con el el cero cero y y ahí ahí seguiría, seguiría, ¿no?

01:16:01

lse posgrados: ¿no? Entonces Entonces de de eso eso se se va va armando armando todos todos los los valores valores y y se se armando armando todos todos los los escalones escalones posibles, posibles, te te va va quedando quedando algo algo escalonado escalonado en en función función de de eso. eso. Lo Lo importante importante es es eso, eso, que que se se quede quede de de esa esa forma forma creciendo. creciendo. Y Y bueno, bueno, ahora ahora sí sí vamos vamos a a practicar. practicar. Ahora Ahora vamos vamos a a ver ver con con el el ejemplo ejemplo que que paré paré yo yo antes antes de de seguir. seguir. Eh, Eh, acá. acá. Bien, Bien, entonces entonces tenemos tenemos eh eh vamos vamos a a un un dato dato sintético. sintético. Sé Sé que que no no da da esta esta función

función que que te te permite permite armar armar datos datos sintéticos sintéticos muy muy fácilmente fácilmente para para hacer hacer clasificación. clasificación. Le Le pasás pasás cuántas cuántas muestras muestras querés, querés, cuántos cuántos features, features, cuántas cuántas features.

01:16:55

Ise posgrados: features. Eh, Eh, informativo informativo que que me me olvid olvid que que acá acá mostrame mostrame el el coso. coso. Normalmente Normalmente lo lo muestra muestra no lo lo qui quiero mostrar mostrar este este coso. coso. Puedes eh te Te bas pasas un un error error eh es informativas informativ número número de de features ficha informativas. informativas, o O sea, sea, ¿cuántas ¿cuántas feures features tienes? tienes? ¿Cuántas ¿Cuántas features features son son realmente? realmente Es es eso, eso? te Te permite permite armar amar como como diferentes diferentes estructuras. estructuras. ¿Cuántas ¿Cuántas realmente realmente están están afectando afectando hacia hacia las las clases? clases? ¿Cuántas ¿Cuántas son son redundantes? redundantes? ¿Cuántas ¿Cuántas son son repetidas? repetidas? Creo Creo que que puedas puedas algunas algunas que que no, no, o o sea, sea, creo creo que que por por defecto defecto quedan quedan las las otras otras que que no, no, o o sea, sea, como como te te mete mete ruido, ruido, cosas cosas así.

01:17:38

Ise posgrados: así, como como puedo puedo simular simular eh comportamientos comportamientos que que yo yo quiera, quiera, tan tan complejo complejo como como yo yo quiero. quiero. Entonces, Entonces, acá acá fíjense, fíjense, le le paso paso cinco cinco faturas faturos redundantes, redundantes, cinco cinco informativas, informativas, eh, eh, y y esto esto es es que que cada cada tanto tanto al al azar azar invierte invierte algún algún algún algún valor valor de de del del de de la la salida. salida. Un Un 2% 2% de de los los valores valores lo los invierte. invierte. Entonces Entonces generamos generamos un un dataset dataset con con eso eso generamos, generamos, fíjense fíjense el el set set de de entrenamiento entrenamiento. y entregamos Entregamos la la región reción logística logística que que teníamos teníamos hoy. hoyamos Entreamos random random forest. for. Ahora, Ahora, ¿qué ¿qué vamos vamos a a hacer? hacer? Vamos Vamos a a hacer hacer Está lento lento este. ah Ah, lento. lento.

01:18:26

Ise posgrados: 7 segundos. Segundos Ustedes dicen dicen lento. lento. 7 7 segundos. segundos. exagerados. exagerados. Eh, Eh, entr entonces random random forest forest y y ahora ahora sí sí eh eh vamos vamos a a entrenar entrenar un un random random forest forest con con calibrado calibrado con con plim. plat. Entonces Entonces, para para para calibrar calibrar esa qui nos nos da da la la forma forma que que yo yo visto, visto, había había varias varias formas. formas. Una Una era era usando usando el el set set de de calibración, calibración, tener tener un un un un un un tercer tercer un un tercer tercer set. set. Y Y otra otra forma forma es es usar usar variación variación cruzada, cruzada, el el cual cual va va a a usar usar eh eh va va a a calibrar calibrar con con entrenamiento, entrenamiento, pero pero tres tres de de en en este este caso caso cruzada cruzar cinco cinco, sean sean cinco cinco del del f f para para para para entrenar entrenar el el modelo modeloción deción valida valida y y así así va va viendo viendo todas todas las las comencias.

01:19:11

Ise posgrados: comencias. Entonces Entonces hace hace eso eso y y obtiene obtiene el el valor valor promedio. promedio. Entonces Entonces con con eso eso pues usamos usamos esto esto y y te te lo lo hace hace automático. automático. Y Y fíjense, fíjense, yo yo le le paso paso acá acá el el método, método, le le dio dio sig sigmoid es es la la reacción reacción de de plat, plat, lo lo haces, haces, lo lo hace hace automáticamente. automáticamente Y y si si le le paso paso isotónico, isotónico, hace hace la la reacción reacción isotónica. isotónica. Lo Lo que que tiene tiene interesante interesante esto esto es es que que esto esto creo creo que que todo todo entero entero, no no me me tierra. No me acuerdo acuerdo si si eso eso lo lo volvía volvía a a calibrar calibrar o o no no lo volventar entrenar de de cero cero que que no no me me acuerdo acuerdo revisar revisar mientras mientras pasa pasa esto. esto. Ok. Ah, Ah, no, o o sea, sea, así así como como está, está, no no creo creo que que por por defecto defecto Ahí ahí está.

01:20:24

Ise posgrados: está. Sí, Sí, no no hace. hace Puede puede hacer hacer ambas ambas cosas. cosas. Si Si vos vos le le pones pones eh eh hay hay un un un hiperpar

hiperparente que se llamado llama ensamble ensamble de de ensamble. ensamble. Si Si le le pongo pongo true, true eh eh, hace hace todo. todo. Si Si le le pongo pongo false, false, le pongo pongo false, false, asume asume que que está está calibrado calibrado el el modelo. modelo. Ya Ya está está entrenado entrenado el el modelo. modelo. Y Y si si eh eh lo lo dejas dejas por por defecto, defecto, se se fija fija si si el el modelo modelo está está entrenado entrenado o o no. no. ¿Se Se acuerdan acuerdan que que cuando cuando vos vos entrenas entrenase un un modelo modelo tiene tiene una una tiene tiene un un atributo atributo que que diga diga está este entrenado entrenado, o no? ¿no? Entonces Entonces se se fija fica eso eso y y si si está está entrenado entrenado lo lo lo lo deja.

01:20:58

lse posgrados: deja, digamos. Lo Lo que que sí sí te te lo lo es importante importante que que tiene tiene que que tener tener por por lo lo menos menos en en el el cycle cycle learn learn es es por por más más que que las la las las calibraciones calciones no no te te lo lo no no te te lo lo digan, digan, pero pero sí sí esta esta versión versión de de que que estos estos modelos modelos tian ti tener tener el el método método predict predict proba proba si si no no no no funcion funciona dice dice el el el bicho bicho le le agar agar mira mira esto esto es es nuevo nuevo le le agar agar otro otro método método de calción eso Eso es es nuevo. lo Estoy estoy viendo viendo acá acá que que eh eh okay, Okay. tiene Tiene otro otro métodos método de de calibración calibración la a parte partir de de la la 1.8 1.8 segimos isotónica isotic una llama llama temperatura. temperatura. Entonces Entonces generamos generamos las las salidas. salidas. Una Una vez vez que que tenemos tenemos modo modo entrenado, entrenado, vamos vamos a a generar generar las las probabilidades probabilidades de de testeo testeo tanto tanto de de la la reacción reacción eh eh del del árbol árbol sin sin calibrar calibrar y y de de los los calibrados.

01:22:01

lse posgrados: calibrados. Y Y veamos veamos las las gráficas gráficas de de refiquemos refirios las las las progicciones proyecciones originales originales son o las las calibradas. cadenas. Entonces, Entonces, fíjense fíjense qué que estoy estoy viendo viendo acá acá en en la la probabilidad probabilidad calibrada calibrada y y la la probad probad original. originalidad la probidad que que indicaba indicaba el el modelo modelo y y esto esto como como lo lo calibró. calibró. Fíjense Fíjense que

que se se arma arma esta esta S. S. La La naranja naranja es es la la isotónica, isotónica, la la eh eh celestita celestita es es la la de de plan. plan. Entonces, Entonces, fíjense fíjense cómo, como o o sea, sea, qué ¿qué nos interpretamos interpretamos acá acá? es que que cómo, como fíjense, fíjense tenemos tenemos las las originales originales, eh eh, acá acá o ha sea las las paredes calibradas, calibradas, las las que que estaban estaban distribuidas distribuidas en en esta este primer primer rango rango, las las acumuló, acumuló, no no me me equivoco, equivoco, interpreto interpreto bien.

01:22:50

lse posgrados: bien. Sí, Sí, en en este este rango. rango. Y Y acá acá también también es es como como que que los los extremos extremos los los los colapsó, colapsó, digamos, digamos, básicamente. básicamente es un estado estado diagonal, diagonal estado quedado perfectamente perfectamente calibrado, calibrado, es es un un estado estado calibre. calibre. Ahora Ahora veamos vemos las las gráficas gráficas de de calibración. calibración. Entonces, Entonces, fíjense, fíjense, traversión versión logística, logística, fíjense, fíjense, no no tuvo tuvo ningún ningún problema. problema. La La perfectamente perfectamente calibrado. calibrado. Lo Lo que que vemos vemos acá acá eh eh por por detrás detrás como como como como una una especie especie de de sombra sombra es es eh la la distribución distribución de donde donde están están distribuidos distribuidos los los valores, valores bien bien de de las las diferentes diferentes los diferentes diferentes puntos. puntos. Este, Este este este es es el el diagrama diagrama de de histograma histograma de de de de distribución distribución de de de de probabilidad probabilidad predicha predicha por por el modelo.

01:23:34

lse posgrados: modelo. Entonces, Entonces, esto esto es es cómo como quedó. quedó. Fíjense Fíjense en en la la random random forest forest por por fuera fuera de de los los extremos, extremos, pero pero cuando cuando calibramos calibramos eno en bien, bien, pero pero isotónico anduo ando mejor. mejor. Fíjense Fíjense que que salía salía mucho mucho más. más. eh eh mucho mucho más más cerca cerca del del digamos digamos del del ejeco. ejempo Ven que que acá acá las las distribuciones distribuciones están están como como más más anchas anchas alrededor alrededor de de 0,204 0,204 y y acá acá los los fuegos enfo 0 y y un un se se acuerdan acuerda que yo yo les les había había dicho dicho que que random

random forest forest eh eh tiende tiende a a ser ser tibio tibio porque porque para para poder poder tener tener muy muy buenas buenas calibraciones, calibraci muy muy buenas buenas predicciones predicciones, tienes tienes que que eh eh tener que que todos todos los los árboles árboles tienen tienen que que decir decir para para tener tener una una alta alta tienes tien muchos muchos árboles árboles tienen tienen que que decir decir tengo tengo 500 500 árboles árboles para paración una una calibación calción para para una una probabilidad probabilidad exactamente exactamente de de uno, uno o o sea, sacar cada uno uno debería debería tener tener alrededor alrededor de de 500 500 árboles árboles diciendo diciendo que que es es de de clase clase uno.

01:24:38

lse posgrados: uno. Entonces, Entonces por por eso eso vemos vemos esta esta distribución distribución que que se se tiende tiende más más ancha ancha sobre sobre los los costados costados y y cuando cuando calibramos calibramos claramente claramente estaba estaba haciendo haciendo tibio. tibio. Esto era estado Estado muy muy seguro seguro el el árbol. árbol este Este árbol árbol logra logra capturar capturar muy muy bien bien y y lo está está llevando llevando bienos. bien, entonces Entonces tenemos tenemos bien bien calibradas calibradas las las curvas. curvas. Después Después tenemos tenemos el el BR score score que que medimos. medimos. Acá Acá están están los los valores. valores. Recuerden Recuerden como como yo yo les les decía, decía, el el BR BRCORE score para para compararción compararción logística logística de de los los otros otros no no me me sirve, sirve, pero pero sí sí me me sirve sirve para para comparar comparar estos estos entre entre sí. sí. Bien, Bien, fíjense fíjense acá acá el el random random foren for si calibrar calibrar tengo tengo 0,6 0,6 y y cuando cuando calibro calibro tengo tengo 0,04 0,04 0,04 0,04 ambas ambas calibraciones calibraciones muy muy cercanas cercanas entre entre sí.

01:25:34

lse posgrados: sí. Y Y fíjense fíjense en en esto, esto, el el sí sí prácticamente prácticamente lo no cambió. cambió. Bien, Bien, entonces entonces como como ven ven acá acá el el primer BR score score es es peor peor en en este este caso caso. es Es un un desastre desastre entre entre comillas comillas. si Si uno uno dice dice acá, acá, pero pero está está perro perro bien en cayado, calorado, ¿por ¿por qué qué es es peor? peor? Como Como yo yo les les decía decía hoy, hoy la lación reción

energía logística una una curva curva que casi casi se se ajusta ajusta perfectamente perfectamente a la la curva curva ideal, ideal, pero pero eh eh mide mide también también la la discriminación. discriminación. Entonces, Entonces, radiación radiación logística logística produce predice una una probidad probidad de de 0,055. 0,055. El El error error es es 1 1 - - $0,5^2$ $0,5^2$ 0,2. 0,2. F Fue la la probidad, probidad, el el error error es es de de 0,01.

01:26:17

lse posgrados: 0,01. la la descomposición descomposición entre entre ambos. ambos. Eh, el tiene tiene un un error error menor menor porque porque se se equivoca equivoca menos, menos, eh, eh, y y es es así así que que justamente justamente me me discrimine discrimine mejor, mejor, pero pero no no eh eh no no esté esté calibrado. calor. Volvamos Volvamos a a la la tase tase de de la la digamos digamos del del cáncer cáncer de de digamos digamos de de de R R cáncer. cáncer. Eh, Eh, entonces entonces los los tumores. tumores. Teníamos Teníamos acá, acá, por por ejemplo, ejemplo, el el modelo modelo gauciano. gaciano. Entrenamos Estrenamos modelo de de hoy, hoy, veamos, veamos, eh, eh, armamos armamos la la la la calibración. calibración. En este En este caso, caso, fíjense fíjense acá, acá, sí sí, meto meto todo todo una una sola sola cosa cosa y y hago hago que que entrene entrene y y automáticamente automáticamente se se da da cuenta cuenta organización organización isotónica.

01:27:09

lse posgrados: isotónica. Veamos Veamos los los resultados. resultados. histogramas Histogramas ser seres sin sin calibrar. calibrar. En este este caso caso hacer hacer lo lo contrario contrario tendía tendía a a ser ser extremo extremo y y eh eh fíjense fíjense ahora ahora cuando cuando cuando cuando usamos usamos el el el el calibrado calibrado tendó tendó a a a a distribuirlo distribuirlo más más a los a los valores. valores. Fí Fíjense, hay hay más más valores valores en en el el medio. medio. Hagamos Hagamos la la curva curva de de calibración. calibración y Y también termina. sigue Sigue siendo siendo muy muy bueno, bueno, pero pero mejor mejor un un poco, poco, bastante bastante más más sobre sobre el el que que original. original. Veamos Veamos un un print, print, no. no. Veamos Veamos métricas métricas y y hacer mejoró. mejoró. Pasó Pasó de de 0,5 0,5 a a 0,03.

01:28:01

lse posgrados: 0,03. Logramos Logramos mejorar mejorar el el eh la la calción, calción, pero pero bueno, bueno, se se puede puede hacer hacer mejor. mejor. ¿Saben ¿Saben cuál cuál es el es el problema problema también también acá? acá? Es que Es el que el modelo, modelo, ¿se ¿se acuerdan? acuerdan Quio que ser ser altísimo, altísimo, entonces entonces como como que que está está muy muy seguro, seguro, se se va va muy muy fácil fácil extremo, extremo, entonces entonces te te queda queda muy muy pocos pocos datos datos en en la la zona zona eh eh en la en la zona zona del del medio, medio, entonces entonces tiene tiene pocos pocos puntos. puntos. Entonces Entonces estos estos puntos puntos lo lo ven vencas como tiene pocas observaciones observaciones hace hace que que tenga tenga mucha mucha más más variabilidad. variabilidad. Entonces, No eso sé tendría pasar. pasar Y y bien, bien no se me qued la la clase, clase si si no no vamos vamos a a ah ah una una cosa cosa más más antes antes que que pasemos pasemos a la a la última última parte parte práctica práctica para para ustedes.

01:28:57

lse posgrados: ustedes. Bien, Bien, entonces entonces por por último último nos nos queda queda la la calción calción multiclase. multiclase. Todos Todos métodos métodos que que vimos vimos son son todo todo binarios. binarios. Si Si hablamos hablamos clase clase binarios. binarios. ¿Cómo ¿Cómo hacemos hacemos con con el el multiclase? multiclase? Multiclase Multiclase tenemos tenemos que que hacer hacer la la solución solución one one versus versus rest, rest, o o sea, sea, calibrar calibrar un un clasificador clasificador de de clase. clase. Hacemos Hacemos decomponemos decomponemos igual igual que que en la en la versión versión logística. logística. en en eh eh una una clase clase contra contra las las otras otras y y tenemos tenemos múltiples múltiples salidas, salidas, bien ¿bien? y Y normalizamos normalizamos para para que que las las salidas salidas sean sean iguales. iguales. Bueno, Bueno, hacemos hacemos eso eso exactamente exactamente acá. acá. tanto tanto para para Prat Prat como como para para la la isotónica, isotónica, eh eh hacemos hacemos exactamente exactamente el el mismo mismo proceso.

01:29:42

lse posgrados: proceso. Obtenemos, Obtenemos, fíjese, fíjese, la la salida salida

para para la la salida salida para para la la probabilidad probabilidad de de que que pertenga pertenga a la a la clase clase K, K, dado dado que que F, F, o o sea, sea, tenemos tenemos la la calción calción para para esa esa clase clase o o en en esa esa clase clase de de salida. salida. Como Como cada cada es es independiente, independiente, las las sumaran sumaran uno, uno, tenemos tenemos que que normalizar normalizar L1 L1 para para que que simpamente simplemente sumamos sumamos dividimos dividimos todo todo por por la la sumatoria sumatoria total total de de todas todas modelos modelos y inte exactamente exactamente igual igual en el en caso el caso de de reón reón logística, logística, por por eso eso eh eh no no hay hay mucha mucha ciencia. ciencia. Se Se recuerda, recuerda, la lación creación no lo busca busca clasificar clasificar mejor, mejor, sino sino medir medir bien bien la la incertidumbre. incertidumbre. un un modelo modelo más marcao calado puede puede ser ser pedoso pedoso en en aplicaciones aplicaciones reales reales en en donde donde realmente realmente ser ser importante importante eso eso y y realmente realmente es es relativamente relativamente sencillo sencillo de de calibrar calibrar con con con con las las técnicas técnicas que que estamos estamos viendo.

01:30:36

lse posgrados: viendo. Entonces, Entonces antes antes de de terminar terminar la la clase, clase vamos vamos a a hacer hacer una una una una parte parte práctica práctica más. más. Siente Siente notebook notebook está está ahí. ahí. A A ver, ver, compartamos. compartamos. Oh, Oh, qué qué cosa. cosa. Cambiamos Cambiamos la la pantalla. pantalla. Entonces, Entonces, para para el el último último caso, caso, vamos vamos a a usar usar algo algo que que se se usa usa mucho mucho en en el el mundo mundo dech, dech, que que es la es la predicción predicción de de click click de de sí, sí, predicción predicción de de de de tasa tasa de de click. click. Para Para los que los que no no conocen, conocen, es es toda toda la la tecnología tecnología alrededor alrededor de de los los ads ads en en internet. internet. Cuando Cuando uno uno entra entra a a una una página página donde donde donde donde Google Google hizo hizo millones, millones, bien, bien, donde donde Google Google es es la la empresa empresa que que es es es es por por por por entro entro al al lugar lugar quiero quiero mostrar mostrar la la publicidad publicidad y y quiero quiero maximizar maximizar la la tasa tasa de de Quick, Quick, porque porque significa significa que que eh eh en en mi mi hago hago es es esa esa tecnología.

01:31:40

Ise posgrados: tecnología. Por Por ejemplo, ejemplo, Google Google quiero quiero lograr lograr yo yo Google Google les les paga paga o o perdón, perdón, los los auspiciantes auspiciantes le le pagan pagan a a Google Google en la en función función de de cuántos cuántos clic clic hagan hagan en en su su anuncio. anuncio. Bien, Bien, entonces entonces Google Google tiene tiene un un interés. interés. Claro, Claro, de de que que hagan hagan más más clics clics y y la la empresa empresa de de de de publicidad publicidad o o la la que que hace hace la la publicidad publicidad quiere quiere que que la la gente gente haga haga clic clic en en su su en en su su en en su sus anuncios anuncio y y para para logar lograr eso eso quiere quiere que que se se lo lo muestren muestren a las las personas personas que que harían harían clic clic en en sus sus anuncios. anuncios. Entonces, Entonces estamos estamos una empresa, estamos con con de una una empresa empresa de de publicidad publicidad digital digital llamado en tiempo tiempo real real llam solution. solution. Imagínense genericio. Entonces Entonces, cuando cuando se se presenta presenta un un espacio espacio de de producción producción en en la la página página web, web, el el instante instante exacto exacto que que us us ingresa ingresa al al sitio, sitio, lo lo que que ocurre ocurre ahí ahí es es una una tecnología tecnología sumamente sumamente avanzada.

01:32:26

Ise posgrados: avanzada. Eso Eso está está lo lo usa usa eh eh principalmente principalmente controlada controlada por por Google Google todo todo esto, esto, pero pero esto esto no no es es el el único único actor. actor. Lo Lo que que ocurre ocurre en en ese ese momento momento cuando cuando un un usuario usuario entra entra a a una una página página web web y y mientras mientras está está cargando, cargando, en en ese ese momento momento ocurren ocurren milisegundos milisegundos una una subasta subasta el el cual cual dice dice entró entró un un usuario usuario de de estas estas características características con con estos estos parámetros. parámetros. Eh, Eh, y y por por ejemplo ejemplo esta esta empresa empresa que que estamos estamos simulando simulando acá, acá, TR TR está está en en ese ese lugar, lugar, decide decide milisegundos milisegundos y y anuncios anuncios de de los los que que están están disponibles disponibles eh eh para para poner poner y y además además cuánto cuánto ofertar ofertar por por esa esa anuncio. anuncio. O O sea, sea, bueno, bueno, listo, listo, al al al al proveedor, proveedor, al al dueño dueño de de la la página página le le pago pago tanto tanto eh eh por por esta esta impresión.

01:33:14

Ise posgrados: impresión. Ahora Ahora correctamente correctamente el el CTR, CTR, el el TR TR rate, rate, cuánto cuánto le le van van a a hacer hacer clic clic crítico crítico para para esta esta empresa empresa porque porque justamente justamente muy muy similar similar al al caso caso del del préstamo préstamo busca busca optimizar optimizar retorno retorno de de inversión, inversión es es decir, decir esta esta empresa empresa paga paga al al proveedor proveedor para para mostrarse mostrarse o o a a la la donde donde muestra muestra la la publicidad publicidad para para mostrar mostrar la la publicidad publicidad y y él él recibe recibe plata plata si si la la persona persona se se suscribe, suscribe dado dado que que se se busca busca optic optic retorno retorno de de inversión, inversión, no no no no bastará bastará con con una una clasificación clasificación binaria binaria hacia hacia ese ese probabilidad probabilidad exacta. exacta. ¿Por ¿Por qué? qué? Muy Muy similar similar a a lo lo que que vimos vimos con con el el préstamo. préstamo. Si Si el el modelo modelo predice predice un un 90% 90% de de probidad probidad de de clic clic y y el el sistema sistema lo lo que que va va a a hacer hacer va va a a ofertar ofertar agresivamente.

01:33:59

Ise posgrados: agresivamente. Si Si yo yo sé sé que que el el 90% 90% de de las personas personas hace hace click, click, listo, listo, te te pago pago porque porque yo yo sé sé que que esta esta persona persona va va a a hacer hacer click click y y si si todas todas estas estas personas personas que que son son así así van van a a hacer hacer click, click, doy doy mucha mucha porque porque yo yo sé sé que que a a la la larga larga voy voy a a ganar ganar más. más. Entonces, Entonces, eh eh si si si si la la probidad probidad real real era era del del 20%, 20%, haber haber pagado pagado un un montón montón de de plata plata por por algo algo que que la la persona persona me me va va a a ignorar ignorar ni ni me me va va a a mirar mirar y y le le va va a a interesar interesar lo lo que que estoy estoy ofertando. ofertando. Entonces Entonces el el cálculo cálculo de de la la oferta oferta máxima máxima a a obtener obtener es es el el valor valor del del clic clic por por la la probidad probidad del del clic. clic. Si Si el el valor valor de de un un clic clic es es $5 $5 y y el el modelo modelo dice dice 0,8, 0,8, ofertamos ofertamos $.

01:34:40

Ise posgrados: $. Bien, Bien, hace hace esa esa ese ese cálculo cálculo de de esa esa forma forma hace hace la la la la oferta oferta para para para para ver ver si si gana gana la la subastapa, subasta. ¿no? Si Si el el modelo modelo está está descalado descalado decir decir la la probad probad es es es es de de probidades probidades de de clic clic 0,2os 0,2os ofertado ofertado estamos estamos perdiendo perdiendo $3 $3 por por la la impresión. impresión. Entonces Entonces, quiero quiero carno, carno, la la predicción predicción de de click click puede puede costarnos costarnos caros. caros. Los Los clientes clientes de de la la empresa, empresa, o o sea, sea, los los que que vienen vienen a a nosotros, nosotros, los los contratan contratan para para que que poner poner sus sus publicidades publicidades ahí, ahí, eh, eh, quieren quieren que que el el sistema sistema sea sea los los que que digamos digamos y y tienen tienen un un presupuesto presupuesto ellos ellos para para gastar. gastar. Dice, Dice, "Bueno, "Bueno, yo yo voy voy a a gastar gastar $10,000, $10,000, no no sé, sé, dice dice un un número, número, no no sé, sé, $,000 $,000 en en publicidad publicidad con con este este anuncio.

01:35:19

Ise posgrados: anuncio. Ese Ese es es mi mi presupuesto presupuesto que que tengo. tengo. Ese Ese es es el el monto monto de de que que usa usa para para como como base base para para hacer hacer las las subastas." subastas." Entonces Entonces ellos ellos quieren quieren que que se se ofrezcan ofrezcan eh eh las las publicidades publicidades de de mayor mayor cantidad cantidad de de insistes insist de de usuarios usuarios que que van van a a hacer hacer clic clic en en su su cosa. cosa. Entonces Entonces esperan esperan que que eh eh se se ofrezca ofrezca lo lo justo justo para para obtener obtener un un máximo máximo setup, setup. o O sea, sea, ¿cuál ¿cuál es es lo lo que que yo yo tengo tengo que que ofertar ofertar para para asegurarse asegurarse el el set? set? Si Si esto esto no no ocurre, ocurre, sus sus presupuestos presupuestos se se escutarán escutarán si si generan generan el el impacto impacto que que esperamos. esperan. O O sea, sea, por por ejemplo, ejemplo, quemamos quemamos los los $1,000, $1,000, nunca nunca eh eh ni ni nadie nadie hace hace clic, clic, no no genera genera y y después después lo lo van van a a ver ver en en sus sus en en sus sus resultados resultados que que esperan esperan que que esa esa campaña campaña les les genere genere impacto impacto y y no no va va a a generar generar el el impacto impacto en en espera.

01:36:04

Ise posgrados: espera. Es Es decir, decir, si si se se construye construye un un modelo modelo de de predicción predicción de de clic, clic, no no solo solo nos nos interesa interesa que que sea sea bueno bueno clasificando clasificando si si el el uso uso va va a a clicar claro, o no, sino sino que que nos nos interesa interesa que que sea sea bueno bueno prediciendo prediciendo la la probabilidad probabilidad de de que que uso uso va va a a cirar. girar. Vamos Vamos a a usar usar datos, datos, vamos vamos a a usar usar diferentes diferentes datos datos de de usuario. usuario. Tenemos Tenemos un un perfil perfil de de usuario, usuario, o o sea, sea, tenemos tenemos información información del del usuario, usuario, por por ejemplo, ejemplo, y y esta esta información información está, está, o o sea, sea, esa esa información información está está disponible disponible y y no no es es muy muy loco loco de de de de que que de obtener. obtener. Sepan Sepan que que estas estas cosas, cosas, aunque aunque es es un un ejemplo ejemplo ficticio, ficticio, está está basado basado en en en en un un ejemplo ejemplo real, real, en en un un tema tema real.

01:36:45

Ise posgrados: real. Reencia Resencia es es número número de de minutos minutos de de tiempo tiempo desde desde la la última última visita visita de de usuario usuario a a esa esa página. página. Eh, Eh, es es muy muy loco loco de de medir. medir. Yo Yo puedo puedo con con los los cookies cookies, puedo puedo saber saber muy muy fácilmente fácilmente cuando cuando entras entr a a mi mi página página y y no no son son las las cookies cookies que que ustedes ustedes piensan piensan que que es son, no no son son esas esas cookies cookies. aceptar nuestras cookies. No, No, no no son son las las cookies cookies que que que que ellos ellos pueden pueden usar usar tranquilamente, tranquilamente. no No son son de de esas, esas, son son las las cookies cookies que que no no hay hay ningún ningún problema problema. uso. Historia Historia de de click. click. ¿Cuánto ¿Cuánto anuncio anuncio cliqueó cliqueó en en la la última última hora hora el el usuario? usuario? Tenemos Tenemos información. información. Esas Esas sí sí son son las las cookies cookies que que ustedes ustedes tienen tienen que que aceptar.

01:37:26

Ise posgrados: aceptar. Eh, Eh, spending spending powercore, powercore, o o sea, sea, es es una una estimación estimación de nivel nivel socioeconómicos.

socioeconómicos. Hay Hay muchas muchas estas estas empresas empresas de de hacen hacen estimaciones estimaciones de de cuánto cuánto es es cuánta cuánta persona persona ganan. ganan. Muchas Muchas veces veces porque porque tienen tienen información información del del usuario. usuario. Eh, Eh, si si la la persona persona está está registrada registrada en en la la página página web, web, por por ahí ahí tienen tienen información información de de un un mail mail y y con con un un mail mail pueden pueden saber saber en en un un dato dato de de un un buró buró los los datos. datos. Así Así de de sencillo sencillo se se puede puede hacer. hacer. a A veces veces est en en en en eh eh nada, los los gobiernos gobiernos los los gobiernos gobiernos no no importa, importa, por por ejemplo, ejemplo, para para decir sol voy voy a a ser ser solar solamente de local, local, pero pero piensan piensan que que todo todo el el mundo mundo es es igual. igual, e Eh, no no importa importa qué qué provincia, provincia, todos todos tomen vienen en sus sus datos datos de de sus sus de de sus sus de de sus sus digamos de de las las personas, personas digamos, y y pueden pueden sacar sacar mucha mucha información información de de ahí.

01:38:13

lse posgrados: ahí. eh Eh, uno uno de de los los mejores mejores proveedores proveedores de de esa esa información información es el estado. estado. Eh, pero Pero otra otra forma forma que que se se hace hace es es usando usando el el nivel nivel socioeconómico. socioeconómico, por Por ejemplo, ejemplo, podés podés medir medir si si vos vos entró entró con con iPhones iPhones modernos. modernos lo lo dice dice iPhone iPhone 15 15 el el último, último eh, e versus son son un iPhone iPhone antiguo antiguo o o celular celular antiguo antiguo más o menos menos y y estimado estimado alo función de de la la localidad localidad que sea device de price price index index que que está está claro el dispo dispositivo dispositivo dispositivo versus versus promedio promedio celular la la profundidad profundidad de de la la sesión. sesión ¿Cuántas cuántas páginas páginas visitó visitó en en la la sesión sesión actual? actual se tuvo tuvo entró entró con en las las páginas páginas de de sitio sitio web web que que estamos estamos viendo viendoas cuántas entró entró eh la la afinidad afinidad de de la la categoría categoría, o O sea, sea, con con respecto respecto al al al al producto, producto, o o sea, sea, dentro dentro de la señ de de porte porte que que sea, sea, propensión propensión a a la la convertibilidad, convertibilidad, o o sea, sea, propon propi la la tenta tienta a a comprar, comprar, velocidad velocidad, de scroll que que velocidad velocidad crolea y y la la probabilidad probilidad de de estimada estimada de de rebote rebote inmediato.

01:39:14

lse posgrados: inmediato. El Reboto otro indante cuando cuando entra entra y y se se van van cuando cuando la la persona persona dice, dice, "Ah, "Ah, esto esto no no quiero quiero se llamar." llama eso Eso a a nivel nivel de de usuario. usuario." Después Después tenemos tenemos a a nivel nivel calidad calidad de de anuncios anuncios estos estos features, features, keyword keyword match, match, o o sea, sea, si si entró entró por por ejemplo una una página página web web con, con no sé, imagino una una página página de de noticias, noticias, digamos, ¿qué ¿qué tanto tanto tiene tiene que que ver ver en en palabras palabras el el artículo, artículo la la sección sección? ¿Está está viendo viendo o un un buscador buscador si si buscó buscó algo algo con con respecto respecto a a la al al anuncio? anuncio? Patiga Patiga creativa, creativa, o o sea, sea, cuántas cuántas veces veces se se vio vio noo banner Nob y otra vez se usa usa mucho mucho el el color color contraste. contraste a a veces veces nosotros usa información información también también del del del tipo tipo de de anuncio anuncio que que hay, hay, ¿no? como Como que que tanto tanto destaca destaca el el bar bar sobre sobre el el fondo fondo del del sitio, sitio, por por ejemplo.

01:39:56

lse posgrados: ejemplo. Y Y después después tenemos tenemos contextos contexto técnicos técnicos a a veces, veces no autoridad autoridad de dominios dominio, calidad calidad del del sitio sitio donde donde se se muestra muestra el el anuncio anuncio, mostrar mostrar un anuncio anuncio en en Clarín Clarín que que eh eh noticias noticias de de no no sé sé de de la la Farrer Farrer digamos digamos un un sistema sistema obviamente obviamente va a tener mucho mucho menos menos autoridad autoridad de decir, decir, o o sea, sea, en en calidad calidad de de de visitas visitas y y y y de de importancia, importancia, ¿no? ¿no? y y o o qué qué s s yo yo, un un sitio sitio web web donde donde se se pone, pone, no no sé, sé, apuestas, apuestas, cosas cosas un un poco poco menos menos legales, legales, claramente claramente va va a a ser ser menos, menos, va va a a tener tener menos menos menos menos autoridad. autoridad. El El tiempo tiempo de de carga carga en en la la página página web web es es vital vital y y eso eso por por eso eso también, también, ¿por ¿por qué qué creen creen que que Google Google insiste insiste mucho mucho a a a a las las coordinadores páginadores que que caben caen rápido?

01:40:42

Ise posgrados: rápido? Por Por esto esto no no es es porque porque no no importa importa la la velocidad velocidad de de internet, internet, eh, eh, porque porque si si es es lenta lenta de cargar cargar la la página, página, la la persona persona ya se se fue fue antes antes de de que que se se cargue cargue la la denuncia. denuncia. Bien, Bien, después después es visibilidad visibilidad del del banner, banner, o o sea, sea, que que tanto tanto cubre, cubre, digamos, digamos, la la pantalla. pantalla. Score Score de de que que es es un un boto boto que que entró, entró, velocidad velocidad de de conexión, conexión, densidad densidad de de competes, competidores, ¿cuántos cuánto otros otros compiten compiten por por el el mismo mismo spot, spot, el mismo slot? slot. y y la la hora hora el el horario horario obviamente obviamente eso eso va va a a ser ser va va a a cambiar. cambiar Tenemos tenemos esos esos fichos. fichos hicimos, Hicimos, imagínense, imagínense, estamos estamos de de vuelta, vuelta, estamos estamos en en un un contexto, contexto, viene viene un un colega, colega, dice, dice, "Yo "Yo hice hice mi mi super machine machine porque porque a a m mí me me gusta gusta su machine machine y y yo yo vi vi ahí ahí hice mis mis datos, datos, bla bla, bla, hice hice este este modelo modelo y y te te dicen, dice, bueno, pues bueno, vamos vamos a a trabajar trabajar con con este este modelo modelo" o o a a veces veces pasé pasemos dice,

01:41:35

Ise posgrados: "No, tenemos este este modelo, modelo, este este modelo modelo se se hizo hizo y y no no podes podés tocar tocar ese ese modelo modelo porque porque no no podés podes tocar tocar es es el el modelo modelo que que está, está es es lo lo que que está. está. Entonces Entonces acá acá simplemente simplemente entramos entregamos el el modelo modelo para para paraamos paraamos están están los los datos datos si si quieren quieren ver ver otro otro mundo. mundo. Eh, Eh, la la descripción descripción ir más más rápido rápido por por acá. acá. No No tengo tengo ganas ganas de de hablar hablar de de esto. esto. Tiramos Tiramos el el target target que que target target es es hizo hizo clic click o o no, no. digamos Digamos simplemente simplemente es es target. target. Eh, Eh, ¿dónde ¿dónde está? está? Fíjense, Fíjense, va va a a ser ser unos unos y y ceros ceros si si hizo suscrito el anuncio anuncias estas características características y y eh eh armamos armamos acá acá está está el el modelo modelo que que armó

armó esta esta persona persona con con un un stand escaler unc uncundo mundo de modelo modelo y y está está fíen piensen que que un un super super machine machine lineal lineal por por una una tenemos tenemos estas estas métricas métricas de que que a a nivel nivel de de de de digamos digamos de de de de cubac curacy y y de de precision precision y y recall recall eh eh para para la la clase clase positiva positiva tiene tiene una una presión presión alta alta con con un un recol recol medio medio

01:42:45

lse posgrados: bajito, bajito, o o sea, sea, no no son no no son son malos, malos, pero pero no no son son excelentes. excelentes. Bien, Bien, está está bien, bien, es es un un modelo modelo que que va va eh eh pero pero quiero qué rematir, rematir, este este modelo modelo no no tiene tiene salida salida probadística. probadística. Fíjense, Fíjense, si si yo yo le le digo, digo, "Che, "Che, dame dame la la la la salida salida probabilística, probabilística, me me sale sale un un error, error, dice, dice, no, no, chéquense, chéquense, esto esto no no tiene tiene est estadística, probadística, no no tiene. tiene. Entonces, Entonces, no no podemos podemos tener tener probabilidad. probabilidad. Entonces Entonces viene viene y y lo lo que que hicieron hicieron estimaron estimaron bueno bueno hacimos hacimos esta esta fórmula, fórmula, el el cual cual obtiene obtiene la la distancia, distancia, la la decisión decisión fusction fusction nos nos da da las las distancias distancias a a la la recta recta y y hacemos hacemos una una normalización normalización de de esta esta forma.

01:43:34

lse posgrados: forma una una pequeña pequeña sigmoidea sinmoide y y tenemos tenemos probé. probí Esto esto está está hecho. hecho. Insisto, Insisto, esto esto se se acerca acerca mucho mucho la la vida vida real real en en donde donde uno uno llega llega a a un un lugar lugar y y está está esto, estas estas cosas, cosas uno uno tiene tiene control, control decir, decir, "Ah, "Ah, voy voy a a cambiar cambiar modelo, modelo." te Te sacan sacan volando." volando. Ahí tu Tu tarea tarea es es que que el el modelo, modelo, este este modelo modelo que que están están usando, usando, mejore mejore la la la la propia, no no puede puede cambiar cambiar el el modelo. modelo. Aparte Aparte de de juguete, juguete, imagínense imagínense que que esto esto es se entrega entrega rápido. rápido. Imagínense Imagínense un un problema problema más más complejo complejo donde donde realmente realmente no no es

es fácil fácil reentrenar. reentrenar. Entonces Entonces vamos vamos trabajo. trabajo. Listo. Listo. Tenemos Tenemos estas estas con estas probidades probidades.

01:44:14

lse posgrados: y Listo. veamos Veamos la la curva curva de de calibración calibración de de nuestros nuestros modelos modelos y y no no da da si si fuera fuera perfectamente perfectamente calibrado calibrado y y vemos vemos que que tiene tiene esta esta curva. curva. Esta Esta curva curva es es de de S. Sigar. Zona Zona baja baja. La la la curva curva se se mantiene mantiene pegada pegada al al piso piso como como ven ven acá. acá. Es decir, Sí, aunque aunque el el modelo modo PR dice dice que que la la probad probad de sube sube de de 03 03 a a 04 04 no no no sube. sube. Bien, Bien, eso eso es es peligroso. peligroso. O O sea, sea, estamos estamos estimando estimando mayor mayor probabilidad probabilidad de de que que real es prácticamente prácticamente en en la la zona zona alta alta se se pega pega al el techo. techo. Bien. Bien, entonces Entonces la la curva curva se se pega pega al al techo. techo. Es Es decir, decir, apenas apenas el el módulo módulo aparece aparece 0,7 0,7 ya ya en en realidad realidad cuando cuando ya ya el el modelo modelo está está diciendo diciendo estos estos valores, valores, ya ya está está casi casi en en uno uno el los valores.

01:44:58

lse posgrados: valor L ya. ya. Entonces Entonces acá, acá, ¿qué ¿qué significa significa eso? eso? No No sé sé si si te te explica explica eso. eso. Abajo Abajo sí. sí. Entonces Entonces veamos veamos eso eso y y la la media media de de un un salto salto abrupto abrupto plum. plum. Este Este valor valor de de acá acá siempre siempre es es por por una una cuestión cuestión de de de de de si si quedas quedas y y mueves mues para para eso eso te te baja baja el el valor valor. el El valor valor debería debería seguir segir por por acá. acá Ha que que llegar acá. lleg. Entonces, Entonces fíjense fíjense las las dos dos distorsiones distorsiones que que tenemos. tenemos. En En el el caso caso uno, uno, en en la la zona zona baja, baja, ingresa ingresa un un la la zona zona alta, alta, perdón, perdón, ingresa ingresa un un usuario usuario con con prida real real de de clic clic 095. 095. El El modelo modelo predice dice 0,7 0,7 por por lo lo que que ofrece ofrece menos menos publicidad publicidad porque porque 095 0, es okay, okay, estamos estamos seguros seguros que que persona persona hace hace click.

01:45:34

Ise posgrados: click. Ofrezco Ofrezco la, la o sea, el el mayor mayor monto monto posible posible con con la la fórmula fórmula que que hemos hemos visto visto porque porque listo, listo, yo yo sé sé que que hacer hacer click. click. Recuerden, Recuerden, estoy estoy compitiendo compitiendo contra contra otros, otros. yo Yo no no estoy estoy solo solo haciendo haciendo esa esa publicidad. publicidad, hay Hay otros otros que que también también quieren quieren ganar ganar esa esa subasta. suta. Entonces Entonces este este modelo modelo dice, dice, no, "No, no, no, no, no. no. Probad Probar clic click 0,7. 0,7 esta persona no, no, o o sea, sea, tiene tiene menos menos probidad probidad deir de lo lo que que debería debería tener, tener, que que es es verdad, verdad, como como sabemos sabemos ahí ahí arriba. arriba, entonces Entonces, no no sé, sé, por pon dó porque porque no no vale vale la la pena pena gastar gastar eh más más en en esa esa subasta, subasta, pero pero dado dado que que subestimamos subestimamos, si si es peor peor de de la la subasta, subasta, imagínense, imagínense, perdemos perdemos la la subasta subasta porque porque otra otra empresa empresa ofrece ofrece más más y y es es decir, decir, perdemos perdemos la la oportunidad oportunidad de de ingresos ingresos y y eso eso es es de de que que pierde pierde la la oportunidad oportunidad de de mostrar mostrar un anuncio,

01:46:19

Ise posgrados: anuncio, anuncio anuncio que que le le interesa. interesa porque Porque aparte aparte estoy estoy poniendo poniendo eh eh también también por eso está está la la está está en en el el medio medio la la otra otra propiedad probad grana la subasta subasta, que que es es otro otro tema tema también también que que estoy estoy simplificando simplificando en en este este caso caso. y Y después después tenemos tenemos el el caso caso dos, dos que el el usuario usuario ingresa ingresa a a un un sitio sitio con con prove real 0,05. 0,05 es Es una una basura, basura, un un bot bot, es es un un bot bot. que una Una vi vi muy muy baja, baja dice dice que que es es un un bot bot prácticamente prácticamente. eh Eh, el el modelo modelo p p 0,3 0,3 ofrezco ofrezco plata, plata, gano gano porque porque quién qui todos todos detectaron detectaron que que un un bot bot todo. todos los Los otros otros detectaron detectaron que un bot bot de de eso. es. Entonces Entonces vos vos haces haces la la oferta oferta, ganas ganas y y estás quemando quemando plata plata en en algo algo que que que nunca nunca va a comprar comprar porque

porque es es un un bot.

01:46:57

lse posgrados: bot. estás Estás quemando quemando plata. plata Además más que que teas teas tener tener un un modelo modelo de de detección detección de de Bueno, Bueno, en en real realidad estabamos estamos viendo viendo que que había había un un feature feature que que era era detección, detección, pero pero bueno, bueno, porque porque después después en en general general en en en los los los los sitios sitios web web casi casi un un 70% 70% de de los los las las visitas visitas son son bots. bots. El el la la no No sé sé si si escucharon escucharon la la teoría teoría de de de internet internet muerta, muerta que mayoría mayoría de internet internet es es bot bot comunicándose. comunicándose. Hay Hay algo, algo, hay hay algo algo de de verdad verdad en en eso. eso. Entonces, Entonces, bueno, bueno, ya ya vemos, vemos, calculemos calculemos el el primer primer score score 0,1. 0,1. Bien, Bien, entonces entonces ahora ahora calibramos calibramos con con las las diferentes. diferentes. Bien, Bien, entonces entonces eh eh el el platin platin vamos vamos a a usar.

01:47:45

lse posgrados: usar. Entonces, Simplemente simplemente calibramos calibramos como como hicimos hicimos previamente, previamente, usamos usamos estándar escala, escala, usamos, usamos, perdón, perdón, usamos usamos la la calción, calción, quiero quiero decir decir eso eso también también varía. varía. Método Método sigmid sigmid variación variación cruzada cruzada tres tres el el fit fit en en este este caso caso entreno entreno todo todo para para simplemente simplemente hacerlo hacerlo pero pero tranquilamente tranquilamente para para usar usar modo entrenado entrenado. hacemos Hacemos una una una una obenemos obenemos las las probabilidades probabilidades y y también también hagamos hagamos la la isotónica isotónica para para tener tener más más isotónicaamos isotónamos el el re re cor core. tenemos Tenemos el el re core core con con eh scal escal tiene tiene 0 0,05 05 y y el el isotónico isotónico también también muy muy similar, similar, es es decir, decir, ambos ambos tienen tienen prácticamente prácticamente la la misma misma mejora, mejora, un un 53% 53% con con respecto respecto al al original. original. O O sea, sea, mejoramos mejoramos la la con con respecto respecto con con respecto respecto esto esto nivel nivel simplemente simplemente es es cuánto cuánto mejoró mejoró la porcentaje porcentaje de mejor.

01:48:53

Ise posgrados: mejor. Veamos Veamos la la curva curva de de calibración. calibración. Y Y fíjense fí ambos ambos modelos modelos son son muy muy parecidos, parecidos fíjense, están prácticamente prácticamente encima. encima. Pero Pero fíjense fíjense cómo cómo mejorar mejorar con con respecto respecto al al rojo. rojo. Entonces, Entonces, esto esto nos nos mejora mejora significativamente. significativamente. Entonces, Entonces, vamos vamos a a las las métricas métricas del del modelo modelo sin sin clasificar clasificar y y las las de de el el modelo modelo eh eh eh modelo sin sin calibrar calibrar y y el el modelo modelo calibrado calibrado, las las métricas. métricas. Y Y fí fíjos modelos muy muy poquito, poquito, siempre se se mueve mueven muy muy poquito, poquito, digamos, digamos. eh, son Son bastante bastante los los mismos mismos números. números Y y eso tenemos tenemos un un modelo modelo que que está está bien bien cargado. cargado. Entonces Entonces ahora ahora este este modelo modelo está está la la producción, producción tenemos tenemos más más seguridad seguridad de de que que este este modelo modelo logre logre estimar estimar bien bien las las probidades probidades y y ahora ahora sí sí cuando cuando vaya vaya la la subasta subasta realmente realmente esté esté haciendo haciendo un un valor valor

01:49:55

Ise posgrados: más más eh eh a a corno. corno. Ahora Ahora imagínense imagínense que que hicimos hicimos esta esta calibración calibración y y empezamos empezamos, decir, us uso un modelo que que esté esté calibrado, calibrado, dejémoslo dejémoslo de de no no usemos usemos ese ese porquería porquería super super machine, machine, usemos usemos un un modelo modelo y y logramos logramos convencer convencer a a nuestro nuestro jefe jefe o o quien quien sea sea nuestro nuestro a a que que si si no no deja deja entregar entregar modo modo vieron vieron que que empezó empezó a a funcionar funcionar todo todo mejor, mejor, estamos estamos teniendo teniendo menos menos problemas problemas y y tenemos tenemos ahora ahora un un modelo modelo calibrado calibrado una una logística logística Veamos Veamos las las métricas métricas son son parecidas, parecidas, no no pasa pasa nada. nada. Eh, Eh, ¿por ¿por qué? qué? Porque Porque ambos ambos monos modos están están ajustando ajustando la la frutera frutera lineal. lineal. Y Ya o o sea, sea, no no tenemos tenemos nada nada de de otro otro mundo. mundo.

01:50:43

Ise posgrados: Ambos Ambos monos monos están están poniendo poniendo frutera frutera lineal. lineal. Es Es esperable esperable que que las las métricas métricas estén estén parecidas. parecidas. Eh, Eh, veamos veamos a a nivel nivel de de calibración. calibración. Recuerden, Recuerden, me me dio dio 0,05. 0,05. Recuerden Recuerden acá acá es es más más un un poquito poquito más más comparable comparable porque porque fíjense fíjense que que de de por por sí sí tiene tiene métricas métricas parecidas parecidas y y eso eso hace hace desde desde que que bueno, bueno, quizás quizás como como las las métricas métricas de de discriminación discriminación son son medias medias parecidas parecidas podría podría ser ser comparable, comparable, pero pero igual igual siguen siguen recuerden recuerden que que también también no no sigue sigue siguen siguen tom tom con con pinzas pinzas pero pero lo lo interesante interesante que que fí fí tiene tiene un un valor valor muy muy parecido parecido a a los los de de los los del del anterior. anterior. calibración, calibración. una Una delicia.

01:51:23

Ise posgrados: delicia. Miren Miren lo lo bien bien que que está está esa esa rción. rción. Laí. Laí, no No es es ni ninguna una sorpresa sorpresa que que más más o o menos menos sí sí está está más más encima encima de de la la verde verde porque porque recuerden recuerden que que la la la verde verde es es su su logística, logística pero del del score scor de es es otro otro modelo modelo y y bueno, bueno, listo. listo. O O sea, sea, esa esa es es la la forma forma de de calibrar. calibrar. No No hay hay ningún ningún no no hay hay no no hay hay pirotecnia pirotecnia de interesante, interesante, simplemente simplemente es es salir salir de de algo algo que que nos nos dé dé una una estadía estadía política política que tenga tenga sentido sentido con con la la realidad. realidad. Insisto, Insisto, eso eso solo solo tiene tiene sentido sentido en en situaciones situaciones como como esta esta que que estamos estamos viendo viendo acá. acá. No No tiene tiene sentido sentido en en problemas problemas en en donde donde este este valor valor de de probidad probidad es es decisorio decisorio en en toma toma de de decisiones, decisiones, en en inversiones inversiones o o en en cosas cosas de de que que o o por por ejemplo ejemplo vida vida humana, humana, en en cosas cosas donde donde hay hay un un long long term term equivocarte equivocarte y y y el y el pegarle, pegarle, bien bien, y y hay hay como como un un retorno retorno de de algo algo ahí ahí,

01:52:17

lse posgrados: bien bien, económico, económico, vidas humanas humana o o lo que lo que sea sea, que que haya haya un un retorno retorno de de alo alo en en general general no no tiene tiene mucho mucho sentido. sentido. calibrar calibrar el el modelo. modelo. Eh, Eh, si si si si solamente solamente quiero quiero hacer hacer clasificación clasificación y y quiero que decir si si si es es spam spam no no spam, spam, eh, eh, lo no tengo tengo calibrado calibrar model. modo. Bien, Bien, tengan tengan en en cuenta cuenta eso eso porque porque no no es es que que tienen tienen que que calibrar calibrar y y no no esperamos esperamos que que en en el el en el en el proyecto proyecto de de la la materia materia calibren calibren el el modelo. modelo. No es No es algo algo que que esperamos. esperamos. Si lo Si lo hacen, hacen, buenísimo, buenísimo, pero pero no no es algo es algo que que que que tienen tienen que que hacer hacer necesariamente. necesariamente. Y Y con con eso eso terminamos terminamos unas unas horas horas antes antes porque porque es es un tema un tema más más cortito, cortito, eh, ¿eh?

01:53:06

lse posgrados: No. No.
lse posgrados: y Y con eso con eso terminamos terminamos la la bateria, materia, no hay no hay más, más. terminó, Terminó tengo más más contenido. contenido. Eh, Eh, la la última última clase clase es es de de consulta, consulta, bien, bien, porque tienen tien que hacer que hacer TP TP todavía, todavía, o sea, o sea, tien tien que hacer que hacer lo más lo más difícil. difícil. Ahora Ahora ustedes ustedes lo lo tienen tienen que que hacer hacer las las cosas. cosas. Entonces Entonces hacemos hacemos la la última última clase, clase, nos nos conectamos conectamos sin sin asistencia, asistencia, o sea, o sea, no no no no pase sin sin asistencia, asistencia, ¿eh? eh, Y y conéctense conéctense solo solo si si tienen tienen dudas dudas realmente. realmente No, no no no vengan vengan a a estar estar así. así. Yo Yo estoy estoy viendo viendo si si alguien alguien me me hace hace pregunta pregunta, y no no venga venga, con duda, alguna duda, duda, ¿eh? y así así nos nos vemos vemos y y vamos vamos vamos vamos evacuando evacuando todas las pero pero bueno, bueno, con con eso eso en en sin sin contenido contenido es es todo.

01:53:51

lse posgrados: todo.
lse posgrados: Eh, Eh, la la fecha fecha límite límite era era el el domingo domingo porque porque el el otro otro día día preguntaron,
lse posgrados: Eh, Eh,
lse posgrados: preguntaron, yo yo no no estaba estaba segura. segura.
lse posgrados: a a ver, ver, yo yo me me filo filo antes antes de de decir decir cualquier cualquier cosa. cosa.
Alejandro Valle: este este domingo domingo o o el el otro. otro.
lse posgrados: El El otro, otro,
lse posgrados: Es el Es el domingo domingo después después de la de la última.
lse posgrados: el el otro. otro.
lse posgrados: última. Sí, Sí, sí, sí, sí. sí.
lse posgrados: Ok.
lse posgrados: Pero Pero por por las las dudasemos dudasemos es es igual igual cuá cu está en está el el aula aula virtual. virtual, Entonces, entonces lo lo pueden pueden ver ver si si está en está el en aula el aula virtual. virtual en el en el horno. horno Vayan vayan que gas. agregarse. ¿Qué ¿Qué pasó pasó acá? acá? ¿Qué ¿Qué es es esto?

01:54:27

lse posgrados: esto? Ah, no Ah, no toqué toqué el el botón. botón. Eh, Eh, oraciones final final tienen tienen 10 10 días días, o sea, el el domingo domingo 26 26 de de abril abril a a las las 23:59. 23:59. Bien. Le queda queda un un domingo domingo más, más como como acabamos acabamos de de decir, decir, a a ver. ver. 20. Sí, Sí, sí, sí, sí, sí, sí. sí. Confirmado, Confirmado, señores. señores. Tiene Tiene hasta el hasta 26 el 26 de de abril. abril, Entonces, tienen tienen la la clase clase en en consulta consulta el el siguiente siguiente jueves jueves para para paraar para las las dudas dudas finales, finales, vayan vayan cerrando cerrando y y eh eh estaría. estaría, digamos, Recuerden recuerden notebook notebook con con el el trabajo trabajo hecho hecho con con todo todo el el proceso proceso, se se evaluar evaluar eh eh proceso proceso típico típico de de un un de de un un problema.

01:55:10

lse posgrados: problema. Bueno, ya Bueno, ya ya ya lo lo vios vios diciendo,

diciendo, ya ya eligieron. eligieron. Imagino Imagino que que todos todos tienen el tienen data Ced. Cet. Hay Hay nadie nadie que que sigue sigue sin sin data data. C. Eh, Eh, habían habían mandados mandados varios. varios, No no sé si sé si mandaron mandaron todos. todos. Yo no Yo no vi vi todos, todos,
lse posgrados: No No volvió volvió a a ver,
lse posgrados: pero pero sí que sí que varios varios mandaron.
lse posgrados: ver, pero pero estaban estaban casi casi todos.
lse posgrados: mandaron.
lse posgrados: todos. Ahí Ahí me me fijo. fijo.
lse posgrados: Bien, Bien, pero pero bueno. bueno, Eh, eso, es Alejandro, Alejandro, perdón.
Alejandro Valle: Perdón, Perdón,
lse posgrados: No.
lse posgrados: perdón.
Alejandro Valle: una una consulta. consulta. No No sé sé si si lo lo detalla detalla la la consigna consigna o o algo, algo, pero pero no no sé sé si si es es necesario necesario como como un un documento documento que que explique explique todo todo lo lo que que hicimos hicimos o o solamente solamente comentar comentar en en los los notebooks notebooks en en el el markdown markdown de de forma forma ordenada.

01:55:49

Alejandro Valle: ordenada.
lse posgrados: Y Y es es el el método método que que vos vos decidas decidas hacerlo hacerlo en la en la forma forma mínima. mínima, Es es decir, decir, la la notebook notebook es es bien bien explicativa, explicativa, pero la pero notebook tiene tiene tiene ese ese ese juego juego de de informe informe resultados, resultados, pero pero si si consideras consideras que que es es mejor mejor de un un documento, documento eso Eso que está tenés tenés que comunicar comunicar un un resultado,
Alejandro Valle: A A ver, ver,
lse posgrados: resultado, digamos, digamos, ten ten que ver que con ver la con la mejor mejor forma forma que que consideres, consider,
Alejandro Valle: gracias. gracias. M. M.
lse posgrados: ¿no? ¿no?
lse posgrados: Están Están todos todos con con dataset, dataset,
lse posgrados: Para Para Bueno,
lse posgrados: por por lo lo menos menos en en la la planilla. planilla.
lse posgrados: Bueno,

Ise posgrados: Sí. Sí.
Ise posgrados: espectacular, espectacular, espectacular. espectacular. Entonces, Entonces, ya ya están están todos, todos, imagin imaginamos, terminamos, ¿eh? ¿eh?

01:56:27

Ise posgrados: Bueno, sí, Sigue, sí, Santiago. Santiago.
Pa. Santiago Rodriguez Castro: Eh, Eh, sí, sí, me me acuerdo acuerdo que que habían habían comentado comentado algo algo de de che, che, no, no, no no armen armen un un notebook notebook simplemente simplemente corriendo corriendo a a todos todos los los algoritmos algoritmos que que vivimos vivimos en en clase. clase. Elijan Elijan los los que que les les parezca parezca que que aplican aplican mejor mejor a a la, la, o o sea, sea, nosotros nosotros ya ya probamos probamos varios, varios, nos nos dio dio que que un un exhibost exhibost con con Optuna, Optuna, que que es es lo lo mejor mejor que que vivimos vivimos en en la la materia, materia, es es lo lo que que mejor mejor performa. performa. dejamos dejamos solo solo el el el final final de de la la historia historia o o o o mostramos mostramos lo lo que que fuimos fuimos corriendo corriendo en en el el medio, medio, la la comparación comparación inicial inicial que que hicimos hicimos entre entre los los algoritmos algoritmos y y que vimos vimos que que el el exhibus exibus era era el el mejor mejor y y después después decidimos decidimos ir ir por por por por la la búsqueda búsqueda de de hiperparámetros hiperparámetros con conna.

01:57:07

Pa. Santiago Rodriguez Castro: tuna.
Ise posgrados: Sí, Sí, es es el el storytelling storytelling es es super super importante, importante, o o sea, sea, cómo cómo fueron fueron trabajando, trabajando, que que fueron fueron probando. probando.
Pa. Santiago Rodriguez Castro: Eh, Eh,
Ise posgrados: Porque Porque si si ahío ahío una una notebook notebook es es lo lo mínimo. mínimo. Si Y si si ven ven que que por por ahí ahí una notebook una es un un bodoque bodoque de de cosas cosas que que si si no no es es manejable, manejable, se se paren paren varias varias notebook notebook y y que que vay vay tener tener una una lógica lógica y y bueno, bueno, primer primer modelo, modelo, segundo segundo modelo modelo y y así, así, pero pero siempre siempre como como buen buen storytelling storytelling que que te te va va llevando llevando y y que

que uno uno lee lee y y va va entendiendo entendiendo cómo cómo fue fue trabajando, trabajando. pero Pero sí, sí otros otros modelos modelos sí, sí, porque porque uno uno cuando cuando trabaja trabaja desarrolla desarrolla modelos modelos es es así. así, uno va va probando probando modelos, modelos, va va haciendo haciendo y y vas vas evolucionando evolucionando hasta un un punto punto donde donde vas vas sintiéndote, sintiéndote, bueno, bueno, listo, listo, cumple cumple el el objetivo, objetivo, ya ya sea sea a nivel nivel que qué modelo modelo eligieron.

01:57:49

lse posgrados: eligieron ustedes ustedes ustedes ustedes decir decir la la búsqueda búsqueda de parámetro parámetro que que tiene tiene todo un un significativo significativo ahí ahí esa esa parte parte como como también también si si hicieron hicieron alguna alguna selección selección de de feature feature nueva nueva o o algo algo distinto distinto que que haya haya cambiado cambiado el el mes. m Todos todo ese ese tipo tipo de de cosas cosas son son super super importantes. importantes ¿Cómo cómo partieron partieron de de una una base base y y llegaron llegaron nadie nadie hacia hacia la la primera primera bien? bien Nunca. nunca recuerden Recuerden eso eso sí,
Pa. Santiago Rodriguez Castro: Bien. Bien. M.
lse posgrados: sí no no sé sé si si lo lo hicieron hicieron por por el el testido tiro les les podía podía todo. todo. Hagan Hagan la la el el baseline baseline baseline. baseline. No No me me no no me me no no me me ha hagan no no me me hagan hagan ir el el baseline. baseline. Baseline, Line, recuerden, recuerden, no no es es un un modelo modelo de de los los que que vimos, vimos, es es una una urística urística en en función función del del sua, suedo lo que que analizaron, analizaron, lo lo que que ustedes ustedes considerarían considerían lo lo mínimo, mínimo, o o sea, sea, con con una una regla regla lógica lógica que que les les haga haga una una como una predicción predicción entre entre comillos, comillos, ¿no?

01:58:32

lse posgrados: ¿no? Listo. Listo. Sí, Sí, sí. sí. Tal Tal tal tal cosa cosa y y esa esa va va a a ser ser la la base base por por la la cual cual luego luego parto parto y y empiezo empiezo a a hacer hacer otros otros modelos. modelos. Bien, Bien. ¿Por qué?
Pa. Santiago Rodriguez Castro: Puede Puede ser ser una una regresión,

lse posgrados: porque
Pa. Santiago Rodriguez Castro: regresión,
lse posgrados: Ah,
Pa. Santiago Rodriguez Castro: una una regresión regresión simple, simple, digamos, digamos, eh, eh, puede puede ser ser el el baseline baseline
lse posgrados: sí, sí, pero pero ya ya es es su su modelo, modelo, o o sea, sea, ya ya estás estás ya ya estás estás dándole dándole una una interacción interacción de de feature feature que que vos vos no no vos vos no no estás estás siendo siendo consciente consciente de de qué qué es. es. en en en en en en el el en en el el en en el el PL PL que que yo yo digo digo urístico, urístico, yo yo hice hice una una edad, edad, más más o menos menos vi vi cómo cómo son son los los datos datos y y me me doy doy ciertas ciertas nociones nociones y y armo armo yo yo alguna alguna regla regla dura dura que que haga haga una una predicción, predicción, que que va va a a ser ser una una porquería, porquería, digamos, digamos, sepamos sepamos que que no no no no es es que que tiene tiene que que si si es es muy muy buena buena es es uno unos groso,

01:59:23

lse posgrados: groso, digamos, digamos, porque porque igual igual el el paso paso después después muchas muchas veces veces en en la la vida vida real real muchas muchas veces veces resuelven resuelven con con heurísticas heurísticas las las cosas, cosas, no no resolvemos resolvemos con modelos. model. Entonces, Entonces, pero pero lo importante siempre siempre es es partir partir de de un un lugar, lugar, o o sea, sea, yo yo digo, digo, listo, listo, esta esta es es mi mi base, base. yo. Yo Entonces, entonces todo todo modelo modelo que que haga haga después después tendría tendría lógica, lógica, esperaríamos esperaríamos que que mejore mejore sobre sobre esa esa métrica. métrica. ¿Y ¿Y cuánto cuánto mejora? mejora? Es Es todo todo lo lo que que me me permite permite para para hacer hacer esas esas comparaciones. comparaciones.
Alejandro Valle: Sí, Sí, ahorita ahorita que que mencionan mencionan eso eso del del baseline, baseline,
lse posgrados: Alejandro, Alejandro,
Alejandro Valle: entonces entonces digamos digamos nosotros nosotros tenemos tenemos un un problema problema de de de de de clasificación, clasificación, no no sería, sería, digamos, digamos, buena buena práctica práctica como como baseline baseline hacer hacer una una regresión regresión logística logística simple simple y y de de ahí ahí partir partir con con el el resto resto de de modelos modelos que que hemos hemos visto.

02:00:09

Alejandro Valle: visto.
lse posgrados: cómo cómo me me insultan insultan la la logística. logística. Sí, Sí, no, no, lación lación son son buenos buenos modelos, modelos, ¿eh? ¿eh? No, No, no, no, no, algo algo más más sencillo sencillo es es simple, simple, no no sé, sé, no no sé sé cuál cuál sería sería el el problema, problema, pero pero qué qué sé sé yo, yo, yo yo doy doy un un ejemplo, ejemplo, ¿no? no O sea, sé, supongo supongo, tengo tengo predecir predecir de de que que hincha hincha club club de de fútboles. fútboles. Eh, Eh, bueno, bueno, me me pongo pongo si si viven viven cerca cerca de de la la cancha, cancha, un un estadio estadio de de fútbol fútbol es es hincha hincha de de ese ese club. club. Como Como un un clasterización clasterización sobre sobre eso. eso y Listo. listo. Cuando Cuando más más cerca cerca está está de de la la cancha cancha de de Boca, Boca, de de Boca, Boca, cuando cuando más más cerca cerca de de cancha cancha de de arriba arriba está está de de Boca.

02:00:42

lse posgrados: Boca. No No hay hay ningún ningún modelo modelo y y es es simplemente simplemente logística logística que que me me hace hace eso. eso. Esa Esa es es mi mi base. base. Digamos logística Logística es es un un modelo modelo que que va va a a ser ser una una estimación, estimación, o o sea, sea, va va a a tener tener una una va va a a interpretar interpretar los los datos datos que que le le entreguené entregé y y va va a a aprender aprender algo algo más más simple simple que que eso. eso.
Leonardo Villalva: Puede puede ser ser algo algo así así tipo tipo una una correlación correlación con con alguna alguna de de las las otras otras variables, variables, como como decías decías vos, vos, o o o o la la mayor mayor ocurrencia ocurrencia de de de de una una clase clase dentro dentro de de una una clasificación.
lse posgrados: Sí. Sí.
Leonardo Villalva: clasificación,
lse posgrados: Sí, También también también.
Leonardo Villalva: una cosa así,
lse posgrados: también Sí, sí,
Leonardo Villalva: cosas cosas que que vimos vemos en en
lse posgrados: un un ejemplo. ejemplo. Claro. Claro. Sí, sí, sí, sí, sí, sí.

02:01:21

lse posgrados: Por Por ejemplo, sé, no ejemplo, la Sí. us Usar la la mayor mayor correlación, correlación la varia de mayor mayor correlación. correlación.
Leonardo Villalva: Claro. Claro.
lse posgrados: Lista.
Leonardo Villalva: Exacto.
lse posgrados: Sí, Sí, sí, sí, es es un unos clásico, clásicos, pero pero generalmente generalmente tiene tiene búsquen busquen sentido sentido también también en en el el negocio, negocio, o o sea, sea, en en el el problema, problema, ¿no? ¿no? Como Como que que bueno bueno si si si si esta esta clase clase porque porque bueno, bueno, yo yo esperaría esperaría estar esta tu tu situación. situación, Bueno, me me parece parece tiene tiene sentido sentido como como que que tenga tenga un un sentido sentido también también en el contextual contextual del del problema, problema, digamos. digamos. Eh, Eh, siempre siempre para para mí mí son son muy muy fácil, fácil, por por ejemplo, ejemplo, los los problemas problemas de de forecasting, forecasting, para para mí mí son son muy muy fáciles fáciles ahí ahí hacer hacer modelos modelos de de baseline basline porque porque siempre siempre es es por ejemplo te que decir decir el el el cuántas, cuántas s yo yo tengo tengo un un negocio negocio que que vende vende hamburguesas, hamburguesas, cuántas cuántas hamburguesas hamburguesas voy voy a a vender vender hoy hoy o o mañana.

02:02:00

lse posgrados: mañana. Bueno, Bueno, me me fijo fijo cuántas cuántas vendía vendía ayer. ayer. Ese Ese es es un un baseline baseline básico básico y y se se van van a a sorprender sorprender lo lo bueno bueno que que es es ese ese model modelo que que están
lse posgrados: o o las las que que vendí vendí hace hace 7 7 días,
lse posgrados: están cerca cerca de de oí Oh,
lse posgrados: días, porque porque por por ahí ahí se se repite repite lo lo mismo mismo al al fin fin de de semana,
lse posgrados: me di hace 7 7 días. días.
lse posgrados: semana,
lse posgrados: Claro, Claro,
lse posgrados: lo lo mismo mismo según según el el día día de de semana,

Leonardo Villalva: Claro. Claro.
lse posgrados: claro.
lse posgrados: semana,
lse posgrados: claro. Sí, Sí, sí, sí,
lse posgrados: pero pero es es básico.
lse posgrados: sí, sí, sí.
lse posgrados: básico.
lse posgrados: sí.
Leonardo Villalva: Mhm. Mhm.
lse posgrados: Exactamente. Exactamente.
lse posgrados: Sí. Sí.
lse posgrados: Y Y y y les les aseguro aseguro que que funcionan funcionan muy muy bien, bien, digamos.

02:02:20

lse posgrados: digamos. Eh, Eh, está está muy muy bien, bien, pero pero funciona funciona bastante bastante bien, bien, pero pero esa eso es es una una base. base. Listo. Listo. Sé si Si me me comparo comparo cualquier cualquier modelo modelo que que haga haga predicciones predicciones, tengo tengo que que mejorar mejorar que que es, es, o o sea, sea, si si si si es es peor peor que que es es que que lo lo que que vendí vendía ayer ayer o hace hace 7 7 días, días, ¿para ¿para qué qué hago hago modelo? modelo? Básicamente Básicamente esa esa es la la el el motivo motivo por por el el cual cual hacemos hacemos la lo base base y y además además te te da da una una idea idea de de vuelta vuelta qué qué tanto tanto mejoramos mejoramos con con pero Pero sí, sí, sí, sí, pero pero no no no no uso uso el el modelo, modelo, no no me me gustan gustan recibes recibes logísticas logísticas, déjenmelas déjenmela de de insultar insultar a a la la pobre pobre ver logística logística, ¿eh? eh usen usen una una una una como como acabo acabo de de decir decir vos vos leo leo ahí ahí una una alguna alguna correlación corración alguna alguna estructura, estructura, algo algo que que pero pero que que tengan tengan también también búsquen búsquen sentido sentido en en el el problema problema tiene tiene sentido sentido que que que que está está variable

02:03:02

lse posgrados: variable entonces entonces la la uso. uso. ¿Alguna ¿Alguna otra otra duda? duda? Poco Poco disturbio lo lo esperaba me esperaba. parece.

Pa. Santiago Rodriguez Castro: Una Una más más tengo. tengo. Eh, Eh, el el trabajo trabajo es es hasta hasta la la comparación comparación de de los los modelos modelos finales finales y y las las métricas métricas de de performance performance o o incluimos incluimos eh eh filature filance, importance, algún algún shap, shap, eh eh algún algún una una calibración calibración a a probabilidad probabilidad de de repente repente por por último último
lse posgrados: Fater Fer Import import no no vimos,
Pa. Santiago Rodriguez Castro: tema. tema.
lse posgrados: vimos, así así que que sería sería un un plus plus por por si si vos vos querés querés investigar, investigar, pero pero no no es es absolutamente absolutamente para para nada nada parte parte de de la la materia. materia. Eh, Eh, la la calibración, calibración, como como dijo dijo Facundo Facundo hace hace un un rato, rato, es es optativa. optativa. Si Si les les interesa interesa también también practicar practicar y y si si no no es es necesario necesario para para la la el el problema problema que que ustedes ustedes resuelven, resuelven, bueno, bueno, no no hace hace falta, falta, pero pero como como eso eso es es totalmente totalmente opcional.

02:03:59

lse posgrados: opcional. Y Y sí, sí, una una última última parte parte que que sea sea conclusiones, conclusiones, o o sea, sea, alguna alguna conclusión conclusión y y qué qué pasó pasó con con todo todo esto esto y y con con qué qué me me quedo, quedo, no no sé. sé.
Pa. Santiago Rodriguez Castro: Parol. M.
lse posgrados: Bien, Bien, también también puede puede llegar llegar a a veces veces que que para para que que tengan tengan en en cuenta, cuenta, ¿no? no todo Todo igual igual que que los los eligieron eligieron tienen tienen llegan un un resultado, resultado, pero pero a a veces veces llegamos llegamos a a esto esto claramente claramente no no nos nos alcanza alcanzaamos digamos claramente claramente mejores mejores features, features, cosas, cosas, o o sea, sea, también también puede puede ser ser una una conclusión conclusión esa, esa, ¿no? ¿no? O O sea, sea, no no no no siempre siempre vamos vamos a el el modelo modelo y y el el camino camino feliz. feliz. Y además Además, en en la la vida vida real real pocas veces veces llega el la camino vida feliz feliz, siempre siempre es mucho mucho laburo laburo y y lleva lleva mucho mucho tiempo tiempo hacemos hac modelos.

02:04:48

lse posgrados: modelos que resultados resultados buenos buenas y y que que otras otras cosas cosas pueden pueden de de la la vida vida real real. muchas Muchas veces veces empa pensa que que hay hay modelo modelo atrás atrás y y no no mucha mucha urística urística, usar usar muchas mucha hurística urística como como bases base para para sus sus predicciones predicciones, e eh, pero pero no no tener tener en en cuenta cuenta eso eso también también, o o sea sea, puede puede llegar llegar puede puede llegar llegar a una a una conclusión conclusión negativa negativa y y eso eso está está perfecto perfecto, pero pero no no no no hay hay como como tiene tiene que que hacer hacer un un modelo modelo que que tiene tiene una una 90 90 y y tanto tanto por por C, no, no eso no es es punto, punto no no no nos nos interesa interesa eso. Bueno, Bueno, si si no no hay hay más más dudas, dudas, terminamos terminamos por por hoy. hoy. Vamos Vamos a a comer. comer. Eso Eso es lo lo malo malo de de otra otra clase clase que que llegas llegas al al final final de de hambre. hambre. Eh, Eh, pero pero bueno, bueno, eh, eh, como como digo, digo, es es la la última última clase clase e eh, clase clase clase clase de de de de contenido, contenido, que que viene viene consulta consulta super super importante, importante, insisto, insisto, porque porque para para consultar consultas tenemos tema ustedes, ustedes, pero pero sin sin asistencia asistencia púsenla púsenla en en la la forma forma que que ustedes ustedes consideran consideran apropiados, apropiados, pónganse pónganse de de acuerdo acuerdo en en el el grupo,

02:05:57

lse posgrados: grupo, vayan vayan charlando charlando y y como como que que vayan vayan directamente ya ya la la clase clase con con las las dudas, dudas, eh, eh, pero pero bueno, bueno, eso eso es es todo todo el el contenido. contenido. Yo Yo nunca nunca sé sé si si esta esta clase clase despedirme despedirme o o no. no. Siempre Siempre me me esa esa situación situación rara rara porque porque la la última última vez vez no no los los veo. veo. Entonces Entonces, le le digo digo algo. este, Este, espero espero que que le le haya haya gustado gustado las las
lse posgrados: Por Por la la duda duda despedite despedite porque porque la la el el bimestre bimestre pasado pasado no no vino vino nadie nadie a a la la clase clase de de
lse posgrados: clases. clases.
lse posgrados: consultas. consulta.
lse posgrados: Nadie estábamos Estamos solos. solos.
lse posgrados: Estábamos Estábamos solos. solos.

Pa. Santiago Rodriguez Castro: que que era era diciembre. diciembre.
lse posgrados: Bueno, Bueno,
lse posgrados: Sí, Sí,
lse posgrados: puede puede ser,

02:06:32

lse posgrados: sí, sí,
lse posgrados: ser,
lse posgrados: estaban estaban todos.
lse posgrados: pero pero igual igual este este por por las las dudas,
lse posgrados: todos,
lse posgrados: dudas, qué qué sé sé yo. yo. Ah. Ah.
lse posgrados: pero Buen buen punto. punto. Pero Pero bueno, bueno, espero espero les les haya haya gustado gustado la la clase. clase. Eh, es Es un un tema, tema, digamos, digamos, fíjense, fíjense, son son modelos modelos que que que que son son de de los los shallows, shallows, modelos modelos chiquititos chiquititos entre entre comillas. comillas. Igual Igual hay hay uno uno ahí ahí que que ya ya un un poco poco Santi Santi ya ya ya ya estuvo estuvo diciendo diciendo lo lo robó robó muy muy bien bien y y se se van van a a sorprender sorprender lo lo bueno bueno ese ese modelo modelo es es buenísimo buenísimo y y y y sus sus variantes, variantes, ¿no? ¿no? el el ICBM ICBM y y el el Cat catboost, Boost, o o sea, sea, todos todos los los modelos modelos de de boosting boosting son son modelos modelos que que la la mayoría mayoría de de los los casos casos van van a a performar performar muy muy bien bien y y no no van van a a tener tener ningún ningún problema,

02:07:05

lse posgrados: problema, pero pero después después van van a a en en otras otras materias materias van van a a haber haber modelos modelos muchos muchos más más sofisticados sofisticados como como deep deep learning, learning, todo todo ese ese tipo tipo de de cosas, cosas, van van a a haber haber otros otros modelos, modelos, pero pero esta esta es es la la base base para para que que ustedes ustedes puedan puedan construir construir eso eso y y saber saber que que también también la la historia historia del del empezó empezó desde desde acá acá y y se se fue fue yendo yendo hacia hacia esos esos modelos modelos más más avanzados, avanzados, eh, eh, pero pero es es una una materia materia que que sido sido

fundacional fundacional aspecto. aspecto. No, No, a a mí mí a a a a vos vos car Carina, te te siguen siguen viendo. viendo. Sí, Sí, a a vos vos te te siguen siguen viendo viendo en en otras otras materias. materias.
lse posgrados: Eh, Eh, sí, sí, en en las las de de taller. taller. Sí, Sí, sí, sí. así Así que que falta falta un un montón,
lse posgrados: Bueno, Bueno,
lse posgrados: montón, ¿no?

02:07:39

lse posgrados: ¿no? Bueno, Bueno, en en gestión gestión de de proyectos, proyectos,
lse posgrados: ustedes ustedes
lse posgrados: pero pero estoy estoy muy muy poquito poquito ahí, ahí, pero pero sí, sí, sí sí los los vuelvo vuelvo a a ver. ver.
lse posgrados: a a ver, ver, pero pero bueno, bueno, te te van van a a seguir seguir sufriendo. sufriendo. A A mí mí van van a a odiar odiar como como siempre siempre les les digo, digo, la la siguiente siguiente sigente sigente van van a a ver ver conmigo conmigo operaciones operaciones de de de de aprendizaje aprendizaje de de máquinas. máquinas. es es una una materia materia un un poco poco más más dura dura en en aspecto aspecto eh eh contenido,
lse posgrados: Hm. Hm.
lse posgrados: contenido, decir decir es es un un contenido contenido más más cercano cercano a a la ciencia, ciencia, a a ciencia, ciencia, no, no, perdón, perdón, a a ingeniera ingeniera software, software, ese ese tipo tipo de de cosas, cosas, inclusive inclusive ni ni siquiera siquiera eso eso es es poner poner el el modelo modelo de de producción producción y y con con todo todo lo lo que que significa significa eso.

02:08:09

lse posgrados: eso. E E pero pero bueno, bueno, seguimos seguimos viendo, viendo, no no es es que que no no los los vamos vamos a a ver, ver, pero pero bueno, bueno, en en esta esta materia materia en en particular particular sí sí insisto, insisto, espero espero que que les les hayan hayan gustado, gustado, eh, gracias gracias por por venir, venir, digamos, digamos, y y también, también, bueno, bueno, consultas, consultas, dudas dudas que que tengan tengan y y bueno, bueno, suerte suerte en en tanto tanto en en nuestra nuestra materia materia como como el el resto resto de de las las

lse posgrados: No, No,
lse posgrados: carreras. carreras.
lse posgrados: un un pedido. pedido. Bueno, Bueno, ya ya lo lo mismo mismo que que ya ya me me escucharon escucharon decir decir el el bimestre bimestre pasado, pasado, un un pedido pedido especial especial en en la la encuesta encuesta de de fin fin de de bimestre, bimestre, si si hay hay algo algo que que no no les les gustó gustó o o hay hay algo algo que que podría podría estar estar mejor, mejor, o o sea, sea, se se agradece agradece que que dejen dejen una una sugerencia, sugerencia,

02:08:36

lse posgrados: Yeah. Yeah.
lse posgrados: algo algo accionable, accionable, que que no no pongan pongan no no me me gustó gustó y y nada nada más más o o que que pongan pongan oc oc y y nada nada más más porque, porque, o o sea, sea, no no podemos podemos hacer hacer nada nada con con eso. eso. Si Si se se les les ocurre ocurre que que hay hay algo algo que que se se podría podría hacer hacer de de otra otra manera, manera, está está bueno bueno que que si si toman toman dos dos minutitos minutitos lo lo dejan dejan por por escrito. escrito. Sirve Sirve todo, todo, sirve sirve todo todo suma. suma. Bueno, Bueno, nos nos vemos vemos todos todos el el jueves jueves que que el el no, no, el el jueves, jueves, jueves jueves que que viene viene en en la la clase clase de de consulta.
lse posgrados: jueves.
lse posgrados: consulta. Ahí Ahí está. está.
Mariano Jauffroy: Bueno, Bueno,
Cristian A. Aballay: Perfecto. Perfecto.
Mariano Jauffroy: profes, profes,
Cristian A. Aballay: Muchas Muchas gracias.

02:09:18

Mariano Jauffroy: nos nos
Cristian A. Aballay: gracias. Nos Nos vemos. vemos.
lse posgrados: juegos.
Cristian A. Aballay: Gracias. Gracias.
Leandro Britez: Ya, Ya,
lse posgrados: Gracias.
Leandro Britez: gracias. gracias.

Leonardo Villalva: Muchas gracias.
Alan Vignolo: Muchísimas Muchísimas gracias gracias a a Dios.
Mariano Jauffroy: vemos. vemos.
Jose Miguel Silva: Gracias.
Luis Ali: Co. C.
Jose Miguel Silva: Gracias.
Alan Vignolo: Dios.
Luis Ali: Ciao. Chao.
Marcos Lund: Yes. Us.
Gabriel Quiroga: Chao. Chao. Muchas Muchas gracias. gracias.
Mariano Jauffroy: Muchas Muchas gracias, gracias, profes. profes, Que que anden anden bien. bien. Hermosa Hermosa la la materia, materia, la la verdad. verdad. Muy Muy lindo.
lse posgrados: Bueno,
Mariano Jauffroy: lindo.
lse posgrados: gracias, Bueno,
lse posgrados: Gracias.
lse posgrados: gracias,
lse posgrados: Gracias, Gracias,
lse posgrados: Mariano. Mariano.
lse posgrados: Marian.

02:09:35

Mariano Jauffroy: Lo Lo vemos vemos que que anden anden
E. Alan Cornejo: Buenas Buenas noches. noches. Eh, Eh, perdón, perdón,
Mariano Jauffroy: bien. bien.
E. Alan Cornejo: yo yo tenía tenía una una una una consultita consultita que que era era relacionada relacionada a a los los a a la la tarea tarea final.
lse posgrados: Mariano.
lse posgrados: Sí. Sí.
E. Alan Cornejo: final. Eh, Eh, bueno, bueno, han han mencionado mencionado de de que que era era sí sí o o sí sí entre entre mínimo mínimo dos dos personas, personas, ¿no? ¿no? Eh, Eh, en en mi mi caso, caso, en en la la planilla, planilla, eh, eh, si si bien bien marqué marqué el el dataset, dataset, pero pero no no tengo tengo un un compañero compañero de de trabajo, trabajo, o o sea, sea,
lse posgrados: Te Te vi, vi,
E. Alan Cornejo: habrá habrá la la posibilidad posibilidad de de que que no no trabaje trabaje solo.
lse posgrados: te te vi vi recién recién que que estabas estabas solo solo en en el el

en en la la
E. Alan Cornejo: solo.

02:09:58

lse posgrados: Sí.
E. Alan Cornejo: Eh, Eh,
lse posgrados: Sí.
E. Alan Cornejo: ¿hay ¿hay algún algún inconveniente inconveniente con con ello ello o o me me tendría tendría que que dirigir dirigir a a otro otro grupo?
lse posgrados: planilla. planilla.
E. Alan Cornejo: grupo? La La verdad verdad quería quería trabajar trabajar con con ese ese dataset dataset porque porque me me interesaba interesaba más más ese ese
lse posgrados: No No sé.
E. Alan Cornejo: apartado. apartado.
lse posgrados: sé.
lse posgrados: Y bueno, Y y ya ya estamos. estamos Sí,
lse posgrados: Ya Ya estamos. estamos que ¿Qué vas?
lse posgrados: ya ya está.
lse posgrados: va.
lse posgrados: está La solo. solo. Bueno, Pero pero pero bueno, hubieras hubieras avisado avisado un un poco poco antes antes o hab visto, visto,
lse posgrados: Está
lse posgrados: pero pero ahora ahora no no hay hay problema.
E. Alan Cornejo: Y Y bueno, bueno, tuve tuve inconvenientes, inconvenientes,
lse posgrados: problema.
E. Alan Cornejo: la la verdad verdad es es una una hora hora de de desfase desfase con con Argentina Argentina y y bueno, bueno, llego llego acá acá casi casi a a mitades mitades de de clase clase o o a a veces veces estoy estoy solamente solamente escuchando escuchando y y no no puedo puedo ver ver muchas muchas

02:10:38

E. Alan Cornejo: cosas. cosas. Eh, Eh, por por otro otro lado, lado, eh, profe profe Facundo, Facundo, no no sé, sé, le le he mandado mandado un un correíto correíto a a ver ver si si es es que que me me puede puede ayudar ayudar con con eso eso o o leerlo leerlo luego. luego. Eh, Eh, solo solo eso eso y y bueno, bueno, agradecer

agradecer por por la la cursada, cursada, la la verdad verdad estoy estoy muy muy contento contento con con ello. ello. Hasta Hasta luego. luego. Muchas Muchas gracias. gracias.
lse posgrados: Natal.
lse posgrados: Chao. Ev.
lse posgrados: Muchas Muchas gracias.
E. Alan Cornejo: M.
lse posgrados: gracias.
lse posgrados: Chao.
E. Alan Cornejo: Yeah.
lse posgrados: Bueno, Bueno, Martín Martín está está por por ahí. ahí. No No está. está. No No lo lo Ah, Ah, vos vos lo lo sacaste. sacaste. Después, Después. se fue. Bueno, bueno, Bueno,
lse posgrados: est est
lse posgrados: eh, eh, bueno, bueno, listo. listo. Yo el otro día más o menos les había dicho también esto del storytelling, que armen todo, que no pongan

La transcripción finalizó después de 02:11:24

Esta transcripción editable se ha generado por ordenador y puede contener errores. Los usuarios también pueden cambiar el texto después de que se haya generado.